



UNIMORE
UNIVERSITÀ DEGLI STUDI DI
MODENA E REGGIO EMILIA

UNIVERSITÀ DEGLI STUDI DI MODENA E REGGIO EMILIA

Dipartimento di Ingegneria “Enzo Ferrari”

Corso di Laurea Triennale in Ingegneria Informatica (L-08)

Progettazione e Valutazione di un Network Intrusion Detection System basato su Machine Learning per il Trasferimento dal Dominio Terrestre al Dominio Satellitare

Relatore:

Prof. Mirco Marchetti

Correlatore:

Dott. Dimitri Galli

Candidato:

Alessandro Marchesini


Matricola 187179

ANNO ACCADEMICO 2025/2026

“Security is a process, not a product.”

— Bruce Schneier

*A chi ha dedicato, dedica e dedicherà il proprio tempo
a costruire il progresso e a proteggerlo.*



Sommario

La crescente integrazione di infrastrutture satellitari all'interno delle moderne reti di comunicazione introduce nuove esigenze in termini di monitoraggio e rilevamento delle intrusioni. In tale contesto, l'impiego di sistemi di *Network Intrusion Detection* basati su tecniche di *Machine Learning* risulta particolarmente promettente, ma è condizionato dalla capacità dei modelli di mantenere prestazioni adeguate quando la distribuzione dei dati osservata in fase operativa differisce da quella utilizzata durante l'addestramento.

Il presente lavoro analizza il problema della generalizzazione *cross-domain* di classificatori addestrati su traffico di rete terrestre e successivamente valutati su traffico riconducibile al dominio satellitare. A tale scopo è stato sviluppato un framework metodologico che armonizza i dataset UNSW-NB15 e STIN all'interno di uno spazio condiviso delle feature mediante un operatore di mappatura volto a preservare la coerenza semantica e dimensionale delle grandezze considerate.

Il protocollo sperimentale confronta tre differenti paradigmi di addestramento: modelli addestrati esclusivamente sul dominio sorgente, una configurazione di baseline denominata INJECTION, nella quale una quota limitata di osservazioni malevole target viene introdotta nel training set sorgente, e modelli ibridi addestrati utilizzando direttamente la componente malevola del dominio target. Le sperimentazioni sono state condotte mediante Decision Tree, Random Forest e Histogram-based Gradient Boosting, adottando una procedura multi-seed e una valutazione sistematica sia sul dominio sorgente sia sui differenti benchmark target.

L'analisi quantitativa è stata affiancata da tecniche diagnostiche e di spiegabilità. Le proiezioni PCA e le stime di densità KDE sono state utilizzate per caratterizzare le differenze distributive tra i domini, mentre l'analisi SHAP ha consentito di esaminare la rilevanza delle feature nelle differenti configurazioni. La robustezza delle evidenze sperimentali è stata inoltre approfondita attraverso l'analisi della variabilità inter-seed e l'impiego del test t di Welch.

I risultati mostrano una marcata differenza tra i paradigmi considerati. I modelli addestrati esclusivamente sul dominio sorgente mantengono buone prestazioni sui dati omologhi, ma evidenziano una significativa riduzione della sensibilità nella valutazione *cross-domain*. I modelli ibridi raggiungono invece prestazioni molto elevate sui benchmark target, a fronte di una perdita

della capacità di riconoscere gli attacchi appartenenti al dominio sorgente. La baseline INJECTION presenta il comportamento più equilibrato, preservando sostanzialmente le prestazioni sul dominio sorgente e incrementando al contempo la capacità di rilevamento sul dominio target.

Nel complesso, il lavoro evidenzia come la composizione del dataset di addestramento rappresenti un elemento determinante per la generalizzazione di un NIDS in presenza di *domain shift*. I risultati ottenuti mostrano inoltre l'importanza di affiancare alla valutazione in-domain una sperimentazione *cross-domain*, al fine di caratterizzare in modo più realistico la capacità di generalizzazione dei modelli destinati a scenari di rete eterogenei.

Indice

Sommario	i
1 Introduzione	1
1.1 Contesto e Motivazioni	2
1.2 Problema di Ricerca	4
1.3 Obiettivi e Domande di Ricerca	7
1.4 Approccio Metodologico	10
1.5 Contributi della Tesi	14
1.6 Organizzazione della Tesi	16
2 Contesto di Riferimento e Stato dell'Arte	19
2.1 Telecomunicazioni	19
2.1.1 Telecomunicazioni terrestri	20
2.1.2 Telecomunicazioni satellitari	21
2.1.3 Analisi comparativa e necessità di monitoraggio intelligente	22
2.2 Sistemi NIDS basati su Machine Learning	24
2.2.1 NIDS in Machine Learning per le telecomunicazioni terrestri	25
2.2.2 NIDS in Machine Learning per le telecomunicazioni satellitari	26
2.3 Adattamento di Dominio e Scarsità dei Dati	30
2.3.1 Il fenomeno del domain shift nei sistemi NIDS	30
2.3.2 Adattamento di dominio supervisionato per la mitigazione dello sbilanciamento	31
2.4 Sintesi dello Stato dell'Arte e Research Gap	33
3 Formulazione Teorica e Framework Metodologico	35
3.1 Modello del Sistema e Spazi di Rappresentazione	35
3.1.1 Formalizzazione dei Domini e Composizione Asimmetrica del Traffico	37
3.1.2 Allineamento dello Spazio delle Feature e Preprocessing Astratto	42

3.2	Tassonomia delle Architetture di Classificazione e Valutazione Multi-Modello . . .	45
3.2.1	Modello di Riferimento (Baseline) e Modelli Aggregati	46
3.2.2	Decomposizione Specialistica Biclasse	51
3.2.3	Spazio delle Famiglie di Decisione Alberiformi ed Ensembling	55
3.3	Framework di Adattamento, Granularità e Stabilità Statistica	60
3.3.1	Incertezza Stocastica e Valutazione Multi-Seed	61
3.3.2	Granularità della Risposta: Formulazione Binaria vs. Multiclasse	67
3.4	Framework Analitico, Spiegabilità e Significatività Statistica	70
3.4.1	Caratterizzazione Densometrica e Proiezioni Latenti	70
3.4.2	Spiegabilità e Attribuzione delle Feature	75
3.4.3	Metriche, Soglia e Significatività dei Confronti	78
3.5	Sintesi del Capitolo e Raccordo con la Campagna Sperimentale	82
4	Implementazione del Framework Metodologico	83
4.1	Ambiente Sperimentale e Riproducibilità	84
4.1.1	Repository e Organizzazione del Codice	84
4.1.2	Stack Tecnologico e Dipendenze	86
4.1.3	Gestione della Riproducibilità Stocastica	87
4.2	Caratterizzazione dei Dataset e Composizione dei Benchmark	87
4.2.1	Dominio Sorgente: UNSW-NB15	88
4.2.2	Domini di Destinazione: Segmento Satellitare/Terrestre STIN	89
4.2.3	Parametrizzazione e Istanziamento dei Benchmark	91
4.3	Allineamento delle Feature e Pipeline di Preprocessing	95
4.3.1	Feature Grezze e Criteri di Filtraggio Applicati	97
4.3.2	Implementazione dell'Operatore di Mappatura	99
4.3.3	Verifica dell'Omissione della Scalatura Esplicita	105
4.4	Implementazione dei Classificatori	106
4.4.1	Algoritmi di Base e Iperparametri	106
4.4.2	Istanziamento dei Modelli Aggregati	108
4.4.3	Istanziamento dei Modelli Biclasse	111

4.5	Protocollo di Addestramento e Valutazione	112
4.5.1	Orchestrazione del Ciclo di Addestramento Multi-Seed	113
4.5.2	Calcolo delle Metriche e Costruzione della Matrice di Valutazione	116
4.5.3	Implementazione del Test di Welch	123
4.6	Strumenti di Analisi Diagnostica e Spiegabilità	128
4.6.1	Standardizzazione Diagnostica, PCA e KDE	130
4.6.2	Implementazione di SHAP e TreeSHAP	136
4.6.3	Pipeline di Aggregazione SHAP-KDE	141
4.7	Sintesi della Pipeline Implementativa	144
5	Analisi dei Risultati e Discussione Sperimentale	149
5.1	Diagnostica Spaziale e Distributiva	149
5.1.1	Proiezioni PCA dello Spazio delle Feature	150
5.1.2	Stime di Densità di Kernel (KDE) e Domain Shift	154
5.2	Valutazione della Baseline INJECTION	160
5.2.1	Prestazioni Quantitative del Modello di Baseline	161
5.2.2	Analisi di Spiegabilità SHAP della Baseline INJECTION	164
5.3	Valutazione dei Modelli Sorgente rispetto alla Baseline	168
5.3.1	Prestazioni dei Modelli Biclasse e Aggregato Sorgente	168
5.3.2	Analisi Comparativa Incrociata: Modelli Sorgente vs Baseline	171
5.3.3	Analisi SHAP del Modello Aggregato Sorgente NB15	174
5.3.4	Analisi della Significatività Statistica (Test t di Welch) dei Modelli Sorgente vs Baseline	178
5.4	Valutazione dei Modelli Ibridi rispetto alla Baseline	180
5.4.1	Prestazioni dei Modelli Biclasse e Aggregati Ibridi	181
5.4.2	Analisi Comparativa Incrociata: Modelli Ibridi vs Baseline	184
5.4.3	Analisi SHAP del Modello Aggregato Ibrido NB15_STIN	187
5.4.4	Analisi della Significatività Statistica (Test t di Welch) dei Modelli Ibridi vs Baseline	191
5.5	Discussione Generale e Quadro Comparativo Globale	193

5.5.1	Quadro Comparativo Globale	193
5.5.2	Mappatura delle Associazioni tra Proprietà della Rete e Comportamento del Modello	197
5.5.3	Compromesso tra Complessità Computazionale e Prestazioni	201
5.5.4	Considerazioni Operative per l'Applicabilità in Ambito NIDS Satellitare . .	203
5.6	Sintesi e Conclusioni del Capitolo	207
6	Conclusioni Finali	211
6.1	Sintesi del Lavoro Svolto	211
6.2	Risposte alle Domande di Ricerca	213
6.2.1	RQ1 – Trasferibilità Diretta e Domain Shift	213
6.2.2	RQ2 – Adattamento mediante Conoscenza Target Sparsa	215
6.2.3	RQ3 – Granularità, Specializzazione e Generalizzazione	217
6.2.4	RQ4 – Architettura, Stabilità e Struttura Decisionale	220
6.3	Contributi e Implicazioni del Lavoro	223
6.4	Limiti dello Studio	227
6.5	Sviluppi Futuri	230
6.6	Considerazioni conclusive	234
A	Dettagli Implementativi e Listati del Framework	237
A.1	Campionamento e Istanziamento dei Benchmark	237
A.2	Nomenclatura e Identificazione Automatica dei Modelli	239
A.3	Calcolo delle Metriche e Gestione dei Casi Limite	240
A.4	Implementazione del Test t di Welch	241
A.5	Dettagli Implementativi della Pipeline SHAP	243
B	Risultati Numerici Completi	245
B.1	Risultati Completi della Baseline INJECTION	245
B.1.1	Matrici di Confusione	245
B.1.2	Metriche Complementari	246
B.2	Risultati Completi dei Modelli Sorgente	247

B.2.1	Prestazioni sul Dominio Sorgente e su INJECTION	248
B.2.2	Prestazioni Cross-Domain	249
B.2.3	Specificità Multi-Seed	249
B.2.4	Confronto Completo con la Baseline INJECTION	250
B.2.5	Mappe di Calore Aggregate della TPR	252
B.3	Risultati Completi dei Modelli Ibridi	256
B.3.1	Prestazioni sui Benchmark Omologhi	256
B.3.2	Cross-Evaluation dei Modelli Ibridi	256
B.3.3	Mappe di Calore Aggregate della TPR	257
B.4	Risultati Completi dei Test Statistici	261
B.4.1	Modelli Sorgente rispetto alla Baseline INJECTION	261
B.4.2	Modelli Ibridi rispetto alla Baseline INJECTION	262
Bibliografia		265
Ringraziamenti		271

Elenco delle Figure

1.1	Sintesi concettuale del problema di ricerca e collegamento tra le principali dimensioni sperimentali e le domande di ricerca.	7
2.1	Architettura di rete integrata Terrestre-Spaziale: rappresentazione della superficie d'attacco e posizionamento dei punti di monitoraggio <i>Network Intrusion Detection System</i> (NIDS).	23
2.2	Confronto schematico tra la valutazione intra-dominio (Scenario A) e l'impatto del domain shift sul trasferimento delle prestazioni tra il contesto terrestre e quello satellitare (Scenario B).	29
3.1	Pipeline logica astratta: allineamento dello spazio delle feature $\mathcal{X}$, isolamento preventivo Train/Test anti- <i>data leakage</i> , sintesi parametrica con ratio ρ senza reinserimento (con ancoraggio alla classe minoritaria) e istanziazione logica dei benchmark. I blocchi tratteggiati indicano le elaborazioni logiche, mentre i blocchi a linea continua rappresentano gli insiemi di dati e le categorie di output.	40
3.2	Flusso di mappatura e omogeneizzazione dello spazio delle <i>feature</i> : gli operatori ψ_S e ψ_T , definiti separatamente per ciascun dominio grezzo, convergono verso lo stesso spazio condiviso $\mathcal{X}$ attraverso i tre criteri comuni di filtraggio e armonizzazione descritti nel testo.	44
3.3	Flusso concettuale del protocollo di addestramento, inferenza e disaggregazione delle prestazioni per i modelli aggregati ($\mathcal{M}_{\text{base}}$, $\mathcal{M}_S$, $\mathcal{M}_H^{(T)}$). I modelli, congelati post-ottimizzazione, vengono valutati sia sull'intero benchmark multi-classe per misurare la generalizzazione di dominio, sia sulle singole partizioni per famiglia d'attacco $\mathcal{D}_a^{(\text{test})}$ per l'analisi di disaggregazione puntuale.	51
3.4	Flusso concettuale del protocollo di valutazione incrociata (<i>cross-evaluation</i>). Il modello specialistico $\mathcal{M}_{S,a}$, addestrato esclusivamente sulla singola minaccia a , rimane invariato e viene proiettato in fase di inferenza sull'intero benchmark eterogeneo $\mathcal{D}^{(\text{test})}$	55

3.5	Confronto logico-procedurale tra gli schemi di aggregazione. A sinistra, il paradigma <i>Bagging</i> esegue un addestramento parallelo su campionamenti bootstrap indipendenti. A destra, il paradigma <i>Gradient Boosting</i> adotta un approccio sequenziale in cui ciascun albero mira a correggere i residui iterativi generati dall'insieme precedente.	60
3.6	Diagramma di flusso del protocollo di isolamento e valutazione stocastica. La stabilità della partizione dei dati è forzata top-down dall'unico seed deterministico s_0 , delegando la totalità della varianza osservata tra le matrici H_k all'inizializzazione stocastica dettata dall'insieme dei seed $\mathcal{S}$ interni agli stimatori.	63
3.7	Rappresentazione bidimensionale nello spazio delle caratteristiche $\mathcal{X}$ dell'impatto del <i>domain shift</i> (vettore di traslazione $\boldsymbol{\eta}$) a seconda della granularità del modello. A sinistra, la maggiore ampiezza spaziale del modello aggregato garantisce tolleranza generalista; a destra, l'ottimizzazione specialistica sul singolo supporto malevolo determina rigidità sotto perturbazione.	69
3.8	Mappatura della probabilità a posteriori $f(\mathbf{x})$ sulla regola decisionale binaria $\hat{y}(\tau)$ in funzione della soglia τ	79
3.9	Rappresentazione schematica dell'Area Sottesa alla Curva (AUC) per le analisi grafiche ROC (a) e Precision-Recall (b).	81
4.1	Rappresentazione schematica semplificata della gerarchia delle directory del progetto e delle risorse generate a runtime.	85
4.2	Diagramma di flusso del processo di estrazione, pulizia, campionamento vincolato ($\rho = 10$) e partizionamento stratificato 80/20 per la generazione dei benchmark fisici aggregati e biclasse.	95
4.3	Diagramma di flusso della pipeline di preprocessing e armonizzazione tra il dominio sorgente $\mathcal{D}_S$ e i domini target $\mathcal{D}_T$, dall'estrazione delle feature grezze alla generazione dello spazio coordinato finale a 16 dimensioni.	96
4.4	Architettura del flusso dati per l'addestramento dei Modelli Aggregati. Le percentuali indicano l'origine logica dei pacchetti che compongono i <i>training set</i> , forzati strutturalmente al vincolo $\rho_{\text{ben/mal}} = 10/1$	110

4.5	Flusso operativo dell'orchestrazione multi-seed e isolamento degli artefatti persistiti.	114
4.6	Pipeline a due stadi per il calcolo delle metriche di classificazione, tracciamento su file system e aggregazione statistica multi-seed.	121
4.7	Pipeline di trasformazione dei dati per l'esecuzione del Test t di Welch, dal recupero delle metriche sui singoli seed alla persistenza degli esiti statistici.	125
4.8	Schema concettuale della Standardizzazione Diagnostica Dipendente dal Sorgente: le statistiche di centralità e variabilità (μ_S, σ_S) e gli autovettori della PCA ($\mathbf{W}_S$) vengono stimati esclusivamente sul benchmark sorgente S e congelati. La trasformazione dei benchmark target T_k avviene per applicazione diretta di tali parametri, preservando lo scostamento distributivo reale (<i>domain shift</i>).	131
4.9	Architettura della pipeline di spiegabilità SHAP per i modelli di classificazione. Il diagramma illustra le quattro fasi sequenziali disposte in blocchi verticalmente allineati con connessioni di flusso circolare (effetto Pacman) sul margine destro/sinistro tra le diverse fasi.	139
4.10	Diagramma architetturale del raccordo <i>Human-in-the-Loop</i> tra l'analisi diagnostica (SHAP) e la valutazione densometrica (KDE). L'intervento manuale (Fase 2) funge da disaccoppiamento metodologico tra le due pipeline automatizzate.	142
4.11	Architettura software end-to-end e flusso di esecuzione unificato: dall'ingestione dei dataset grezzi, passando per l'armonizzazione delle feature e il ciclo di addestramento multi-seed, fino alla biforcazione tra ramo inferenziale (valutazione prestazionale) e ramo diagnostico (PCA, KDE e TreeSHAP).	147
5.1	Proiezione PCA bidimensionale del benchmark sorgente NB15 nel sistema di riferimento ottenuto mediante standardizzazione e fitting sul dominio sorgente.	151
5.2	Proiezione PCA bidimensionale del benchmark INJECTION, utilizzato per l'addestramento della baseline $\mathcal{M}_{\text{base}}$, nel sistema di riferimento PCA definito dal dominio sorgente.	152
5.3	Proiezione PCA bidimensionale del benchmark ibrido NB15_STIN, composto da traffico nominale sorgente NB15 e traffico malevolo target STIN, nel sistema di riferimento PCA definito dal dominio sorgente.	153

5.4	Stime KDE delle feature <code>pkts_per_sec</code> , <code>total_bytes</code> e <code>dst_win_byt</code> per il benchmark sorgente NB15, espresse mediante standardizzazione ancorata al dominio sorgente.	156
5.5	Stime KDE delle feature <code>pkts_per_sec</code> , <code>total_bytes</code> e <code>dst_win_byt</code> per il benchmark INJECTION, utilizzato per l'addestramento della baseline $\mathcal{M}_{\text{base}}$	157
5.6	Stime KDE delle feature <code>pkts_per_sec</code> , <code>total_bytes</code> e <code>dst_win_byt</code> per il benchmark ibrido NB15_STIN, costituito da traffico nominale sorgente NB15 e traffico malevolo target STIN.	158
5.7	Summary plot SHAP della baseline INJECTION per Decision Tree, Histogram-based Gradient Boosting e Random Forest, valutati sul test set INJECTION con seed $s = 42$. 165	
5.8	Summary plot SHAP del modello aggregato sorgente NB15 implementato mediante Decision Tree, Histogram-based Gradient Boosting e Random Forest, valutati sul test set aggregato NB15 con seed $s = 42$	175
5.9	Summary plot SHAP del modello aggregato ibrido NB15_STIN implementato mediante Decision Tree, Histogram-based Gradient Boosting e Random Forest, valutati sul benchmark NB15_STIN con seed $s = 42$	188
B.1	Matrice aggregata della TPR per Decision Tree nel confronto tra modelli sorgente e baseline INJECTION. Per ciascuna cella sono riportate la media e la varianza calcolate sui $K = 10$ seed.	253
B.2	Matrice aggregata della TPR per Histogram-based Gradient Boosting nel confronto tra modelli sorgente e baseline INJECTION. Per ciascuna cella sono riportate la media e la varianza calcolate sui $K = 10$ seed.	254
B.3	Matrice aggregata della TPR per Random Forest nel confronto tra modelli sorgente e baseline INJECTION. Per ciascuna cella sono riportate la media e la varianza calcolate sui $K = 10$ seed.	255
B.4	Matrice aggregata della TPR per Decision Tree nel confronto tra modelli ibridi e baseline INJECTION. Per ciascuna cella sono riportate la media e la varianza calcolate sui $K = 10$ seed.	258

B.5	Matrice aggregata della TPR per Histogram-based Gradient Boosting nel confronto tra modelli ibridi e baseline INJECTION. Per ciascuna cella sono riportate la media e la varianza calcolate sui $K = 10$ seed.	259
B.6	Matrice aggregata della TPR per Random Forest nel confronto tra modelli ibridi e baseline INJECTION. Per ciascuna cella sono riportate la media e la varianza calcolate sui $K = 10$ seed.	260

Elenco delle Tabelle

2.1	Sintesi comparativa dello stato dell'arte sui NIDS nei domini terrestre e satellitare e posizionamento del presente lavoro.	28
3.1	Sintesi della notazione matematica e dei simboli del framework.	36
3.2	Tassonomia astratta delle cinque categorie di benchmark sperimentali istanziate dinamicamente.	42
3.3	Sintesi della notazione relativa alle architetture e ai parametri di classificazione. . .	46
3.4	Sintesi comparativa dei modelli di riferimento e aggregati: composizione del training set e finalità concettuale.	50
3.5	Sintesi dei modelli biclasse specializzati: composizione del <i>training set</i> e finalità concettuale.	53
3.6	Confronto delle proprietà architetture e degli obiettivi di ottimizzazione tra i paradigmi di <i>ensembling</i> Bagging e Gradient Boosting.	59
3.7	Sintesi della notazione relativa al framework di valutazione e alla stabilità statistica.	61
3.8	Rappresentazione concettuale della matrice di valutazione incrociata $H_k \in \mathbb{R}^{ \mathcal{M} \times \mathcal{B} }$.	64
3.9	Sintesi della notazione relativa al framework analitico, all'interpretabilità e alla valutazione statistica.	70
3.10	Sintesi del ruolo e dell'impatto della standardizzazione dipendente dal sorgente (μ_S, σ_S) sulle componenti diagnostiche del framework.	75
3.11	Struttura della Matrice di Confusione parametrizzata rispetto alla soglia τ	79
4.1	Stack tecnologico, librerie e relative versioni vincolate nell'ambiente di runtime. . .	86
4.2	Distribuzione delle istanze del dataset UNSW-NB15 a seguito della procedura di <i>minority removal</i>	89
4.3	Distribuzione delle istanze del dataset TER20 a seguito del processo di <i>minority merge</i> .	90
4.4	Distribuzione delle istanze del dataset SAT20.	91
4.5	Riepilogo delle cardinalità finali per i benchmark aggregati.	93

4.6	Prospetto sintetico della cardinalità e del partizionamento per i Set Nativi Sorgente Biclasse e Ibridi Biclasse.	94
4.7	Feature eliminate durante la fase di pre-processing nei domini sorgente e target. . .	98
4.8	Sintesi del processo di selezione e allineamento dimensionale tra il dominio sorgente ($\mathcal{D}_S$) e i domini di destinazione ($\mathcal{D}_T$).	99
4.9	Formulazione algebrica dell'operatore di mappatura vettoriale nei domini $\mathcal{D}_S$ e $\mathcal{D}_T$	100
4.10	Descrizione semantica delle feature coordinate.	101
4.11	Configurazione degli iperparametri di default e classi scikit-learn utilizzate per ciascuna famiglia di classificatori.	107
4.12	Struttura e campi del record di tracciamento persistito nel registro <code>models_metadata</code>	108
4.13	Istanze dei modelli biclasse generati per il dominio sorgente e i domini target ibridizzati.	112
4.14	Metriche di valutazione delle prestazioni utilizzate per la caratterizzazione dei modelli di apprendimento automatico.	117
4.15	Tassonomia e suddivisione concettuale dei campi costituenti il record di tracciamento delle prestazioni.	119
4.16	Struttura e descrizione dei campi costituenti i file CSV per le matrici delle metriche individuali e aggregate ($M \times D$).	123
4.17	Struttura e descrizione semantica dei campi costituenti il file di registro statistico <code>welch_ttest</code>	128
4.18	Confronto sinottico tra gli strumenti diagnostici (PCA, KDE) e di spiegabilità (TreeSHAP) integrati nell'architettura software.	130
4.19	Confronto sinottico tra le procedure diagnostiche di proiezione PCA e stima della densità KDE nel modulo <code>plotting</code>	136
4.20	Sintesi dei parametri di configurazione e delle scelte ingegneristiche della pipeline SHAP.	141
4.21	Distribuzione delle frequenze di occorrenza C_j delle caratteristiche registrate nelle prime tre posizioni dei grafici SHAP.	143
4.22	Riepilogo dell'architettura software end-to-end.	145

5.1	Statistiche descrittive delle tre feature KDE per il traffico nominale sorgente e per le componenti malevole di NB15, INJECTION e NB15_STIN.	155
5.2	Precision, TPR e TNR della baseline INJECTION con DT, HGB e RF sui 16 test set per il seed $s = 42$	162
5.3	Prime cinque feature nella graduatoria SHAP della baseline INJECTION per DT, HGB e RF al seed $s = 42$	166
5.4	Prestazioni dei modelli sorgente sui rispettivi test set omologhi per il seed $s = 42$. .	168
5.5	Confronto multi-seed tra modello aggregato sorgente e baseline. Le differenze Δ sono calcolate come baseline meno modello sorgente.	172
5.6	Prime cinque feature nella graduatoria SHAP del modello aggregato sorgente NB15 per DT, HGB e RF al seed $s = 42$	176
5.7	TPR media dei tre modelli aggregati sui nove benchmark target.	182
5.8	Differenze di TPR e TNR tra i modelli aggregati ibridi e la baseline INJECTION. I valori sono calcolati come modello ibrido meno baseline.	184
5.9	Prime cinque feature nella graduatoria SHAP del modello aggregato ibrido NB15_STIN per DT, HGB e RF al seed $s = 42$	189
5.10	Quadro comparativo globale dei modelli aggregati sorgente, baseline e ibridi. Per $\mathcal{M}_H$ gli intervalli rappresentano i valori minimo e massimo osservati tra i tre modelli aggregati ibridi.	194
5.11	Mappatura sinottica delle associazioni osservate tra evidenze distributive, rilevanza SHAP e comportamento prestazionale. Le associazioni riportate descrivono corrispondenze empiriche tra i fenomeni osservati, senza implicare relazioni causali dimostrate.	200
5.12	Sintesi qualitativa del compromesso tra articolazione del modello e prestazioni osservate nella configurazione INJECTION.	203
5.13	Sintesi delle implicazioni operative dei tre paradigmi di addestramento nell'ambito del protocollo NIDS considerato.	206
6.1	Sintesi delle risposte alle domande di ricerca e delle relative evidenze sperimentali.	223

B.1	Cardinalità complete delle matrici di confusione della baseline INJECTION con DT, HGB e RF sui 16 test set per il seed $s = 42$	246
B.2	F1-Score e PR-AUC completi della baseline INJECTION con DT, HGB e RF sui 16 test set per il seed $s = 42$	247
B.3	TPR media sui 10 seed dei modelli sorgente valutati sui benchmark sorgente e sul test set INJECTION.	248
B.4	TPR media sui 10 seed dei modelli sorgente valutati sui benchmark target aggregati e biclasse.	249
B.5	Media e varianza della TNR sui 10 seed per i modelli sorgente. Il valore è indipendente dal test set malevolo poiché la componente nominale rimane invariata all'interno del protocollo sperimentale.	250
B.6	Media e varianza della TPR sui benchmark target aggregati per il modello sorgente aggregato e la baseline.	251
B.7	Vantaggio TPR della baseline rispetto al migliore modello sorgente disponibile su ciascun benchmark target.	252
B.8	TPR e F1-Score dei modelli ibridi sui rispettivi test set target omologhi per il seed $s = 42$	256
B.9	TPR media multi-seed dei modelli ibridi sui benchmark sorgente, INJECTION e target. Le colonne NB15 e Target rappresentano rispettivamente la media sui sei e sui nove test set dei corrispondenti gruppi.	257
B.10	Media e deviazione standard campionaria dei valori $\overline{F1}_i^{(k)}$ sui 10 seed per la baseline e i modelli sorgente. $\Delta F1$ è calcolato come baseline meno modello sorgente. . . .	261
B.11	Risultati del test t di Welch tra injection_aggregate e i modelli sorgente, con $\alpha = 0,05$	262
B.12	Media e deviazione standard campionaria dei valori medi di F1-Score sui 10 seed per la baseline e i modelli ibridi. $\Delta F1$ è calcolato come baseline meno modello ibrido.	262
B.13	Risultati del test t di Welch tra injection_aggregate e i modelli ibridi, con $\alpha = 0,05$.	263

Elenco dei Codici

4.1	Trasposizione operativa dell'operatore di mappatura ψ_k tramite vettorializzazione pandas per il dominio UNSW-NB15.	103
4.2	Trasposizione operativa dell'operatore di mappatura ψ_k tramite vettorializzazione pandas per il dominio STIN.	104
4.3	Nucleo implementativo per l'estrazione dei campioni e l'esecuzione del Test t di Welch.	126
4.4	Standardizzazione, adattamento e trasformazione PCA ancorati al benchmark sorgente. 132	
4.5	Standardizzazione dipendente dal sorgente, trasformazione delle feature e generazione delle stime KDE.	134
4.6	Inizializzazione dinamica dello spiegatore SHAP con catena di fallback.	138
A.1	Routine di campionamento per l'istanziamento dei benchmark.	238
A.2	Routine di bilanciamento stratificato per l'istanziamento dei benchmark.	238
A.3	Estrazione procedurale dell'etichetta di attacco per la generazione dinamica della nomenclatura del modello.	240
A.4	Gestione difensiva dei casi limite e calcolo delle metriche in <code>calculate_metrics()</code> . 240	
A.5	Estrazione dei campioni ed esecuzione del Test t di Welch.	242
A.6	Campionamento stratificato del test set per l'analisi SHAP.	243
A.7	Calcolo, normalizzazione dimensionale e rendering dei valori SHAP.	244

1. Introduzione

La crescente integrazione tra infrastrutture di telecomunicazione terrestri e segmenti spaziali sta progressivamente estendendo il perimetro operativo delle reti moderne, introducendo nuove opportunità in termini di copertura, continuità del servizio e interconnessione geografica, ma anche ulteriori criticità sotto il profilo della sicurezza. La coesistenza di canali trasmissivi caratterizzati da proprietà fisiche, topologiche e operative differenti determina infatti un ambiente fortemente eterogeneo, nel quale i meccanismi di protezione devono essere in grado di mantenere la propria efficacia anche al variare delle condizioni di rete e delle distribuzioni statistiche del traffico.

In tale scenario, i *Network Intrusion Detection Systems* (NIDS) basati su Machine Learning costituiscono uno strumento rilevante per l'identificazione automatizzata di comportamenti anomali e attività malevole all'interno dei flussi di comunicazione. La loro efficacia dipende tuttavia dalla capacità dei modelli appresi di mantenere proprietà discriminative anche quando il contesto operativo differisce da quello utilizzato durante la fase di addestramento. Questo requisito assume particolare importanza nella transizione tra domini terrestri e satellitari, dove le differenze nelle caratteristiche del traffico e nelle dinamiche trasmissive possono produrre un significativo disallineamento tra le distribuzioni osservate durante il *training* e quelle incontrate in fase di inferenza.

Il presente lavoro affronta tale problematica mediante la definizione e la validazione sperimentale di un framework per l'analisi della robustezza e della trasferibilità cross-domain di classificatori supervisionati applicati a sistemi NIDS. L'indagine considera differenti regimi di disponibilità della conoscenza target e differenti configurazioni della componente malevola, con l'obiettivo di valutare non soltanto la capacità di adattamento verso nuove distribuzioni, ma anche la conservazione dell'informazione precedentemente acquisita nel dominio sorgente.

A partire da tali premesse, il presente lavoro definisce e valida sperimentalmente un framework per l'analisi della robustezza e della trasferibilità cross-domain di classificatori supervisionati applicati a sistemi NIDS. Il capitolo introduce il contesto dell'indagine, formalizza il problema di ricerca e i relativi obiettivi, sintetizza l'approccio metodologico e identifica i principali contributi della tesi, concludendo con l'organizzazione della trattazione.

1.1 Contesto e Motivazioni

Le infrastrutture di telecomunicazione costituiscono un elemento fondamentale per il funzionamento dei moderni sistemi digitali, supportando l'interconnessione di servizi, dispositivi e infrastrutture distribuite su scala geografica. La crescente dipendenza da tali reti rende la continuità e l'integrità delle comunicazioni requisiti essenziali non soltanto per applicazioni convenzionali, ma anche per servizi critici e scenari nei quali un'interruzione o una compromissione del canale può produrre conseguenze sistemiche [1], [2].

L'estensione delle architetture di comunicazione verso il segmento spaziale amplia ulteriormente tale scenario. Le infrastrutture satellitari consentono infatti di superare i limiti geografici e orografici delle reti di superficie, garantendo copertura su vaste aree e introducendo forme di ridondanza utili in contesti remoti o caratterizzati da limitata disponibilità di infrastrutture terrestri [3]. Contestualmente, l'integrazione tra segmenti terrestri e orbitali determina un ambiente trasmissivo eterogeneo, nel quale coesistono canali caratterizzati da differenti condizioni di propagazione, latenza, disponibilità di banda e variabilità temporale.

A tale complessità operativa corrisponde un ampliamento della superficie di attacco. Le minacce tradizionalmente associate alle reti terrestri, quali attacchi volumetrici, scansioni, accessi non autorizzati e manipolazioni del traffico, si affiancano nei segmenti satellitari a ulteriori vulnerabilità derivanti dalla natura radio del mezzo trasmissivo e dalla maggiore esposizione fisica del canale [4]. La protezione di infrastrutture integrate richiede pertanto meccanismi di monitoraggio capaci di osservare continuamente i flussi e identificare variazioni compatibili con attività malevole lungo contesti operativi differenti.

In tale ambito, i NIDS basati su Machine Learning rappresentano un'evoluzione rispetto ai soli sistemi di rilevamento deterministici fondati su firme. L'impiego di modelli di apprendimento consente infatti di caratterizzare statisticamente il comportamento dei flussi e di costruire funzioni decisionali capaci di discriminare tra traffico nominale e malevolo sulla base delle caratteristiche osservate [5], [6]. Tale proprietà risulta particolarmente rilevante quando le minacce non sono completamente descrivibili mediante pattern statici o quando la complessità del traffico rende impraticabile una codifica manuale esaustiva delle condizioni di attacco.

L'efficacia di un classificatore supervisionato rimane tuttavia strettamente connessa alla rappre-

sentatività dei dati utilizzati durante l’addestramento. Le metodologie convenzionali di valutazione assumono implicitamente una sostanziale coerenza statistica tra il dominio sul quale viene appreso il modello e quello sul quale esso viene successivamente impiegato. Quando tale ipotesi viene meno, la capacità di generalizzazione può essere compromessa dal fenomeno di *domain shift*, ossia dalla variazione delle distribuzioni associate alle osservazioni tra il dominio sorgente e quello di destinazione [7].

La transizione tra traffico terrestre e traffico appartenente a infrastrutture integrate terrestrespaziali costituisce un caso particolarmente significativo di tale problematica. Le differenti condizioni trasmissive e le differenti modalità di generazione e acquisizione dei flussi possono riflettersi direttamente nello spazio delle caratteristiche utilizzato dal NIDS, determinando distribuzioni target non coincidenti con quelle osservate durante l’apprendimento. Di conseguenza, prestazioni elevate ottenute in una valutazione esclusivamente intra-domain non costituiscono, di per sé, una garanzia di robustezza quando il medesimo classificatore viene trasferito verso un contesto differente.

La problematica è ulteriormente aggravata dalla disponibilità limitata di traffico satellitare etichettato. La raccolta di dataset rappresentativi del segmento spaziale risulta infatti più complessa rispetto al contesto terrestre, sia per i vincoli operativi associati alle infrastrutture considerate sia per la difficoltà di acquisire e rendere pubblicamente disponibili tracce realistiche di traffico malevolo [3], [8]. L’addestramento di un classificatore completamente nativo per ogni nuovo dominio può quindi risultare difficilmente praticabile, rendendo rilevante lo studio di strategie capaci di sfruttare la conoscenza già disponibile nel dominio sorgente.

Da tali considerazioni deriva la motivazione centrale del presente lavoro: analizzare sistematicamente il comportamento di classificatori NIDS supervisionati quando la conoscenza appresa su un dominio di riferimento viene trasferita verso distribuzioni differenti e valutare come differenti livelli di disponibilità dell’informazione target incidano sul compromesso tra adattamento e conservazione della conoscenza precedentemente acquisita. L’interesse non è quindi limitato alla ricerca della massima prestazione su uno specifico dominio, ma riguarda più in generale la capacità del sistema di mantenere un comportamento discriminativo stabile attraverso scenari eterogenei.

Questa prospettiva richiede di superare una valutazione circoscritta alla sola accuratezza intra-domain e di considerare congiuntamente la generalizzazione cross-domain, la stabilità rispetto alla componente stocastica dell’addestramento, la sensibilità alle differenti distribuzioni malevole e la

struttura della funzione decisionale appresa. Su tali presupposti viene formulato, nella sezione successiva, il problema di ricerca affrontato dalla tesi.

1.2 Problema di Ricerca

Il problema affrontato nel presente lavoro riguarda la capacità di un sistema NIDS supervisionato di preservare le proprie proprietà discriminative quando il dominio operativo differisce da quello utilizzato per l'addestramento. In una valutazione convenzionale intra-domain, il modello viene infatti addestrato e verificato su partizioni appartenenti alla medesima distribuzione di riferimento. Tale condizione consente di misurare l'efficacia del classificatore all'interno del contesto conosciuto, ma non permette di stabilire direttamente se la funzione decisionale appresa sia trasferibile verso distribuzioni di traffico differenti.

Formalmente, il framework considera un dominio sorgente $\mathcal{D}_S$ e uno o più domini target $\mathcal{D}_T$, rappresentati all'interno di uno spazio condiviso delle caratteristiche $\mathcal{X}$. Pur mantenendo una rappresentazione semanticamente omogenea delle osservazioni, le relative distribuzioni possono risultare differenti:

$$P_S(\mathbf{x}) \neq P_T(\mathbf{x}), \quad (1.1)$$

configurando una condizione di *domain shift* nella quale le osservazioni incontrate durante la fase di inferenza non seguono necessariamente la stessa distribuzione dei dati utilizzati per l'apprendimento [7].

Nel contesto considerato, tale problema assume una particolare rilevanza poiché il dominio sorgente è rappresentativo di traffico di rete terrestre, mentre i domini di destinazione introducono distribuzioni provenienti da un'infrastruttura integrata terrestre-spaziale. Il trasferimento viene pertanto studiato in presenza di sorgenti dati eterogenee, ricondotte a uno spazio comune mediante un processo di armonizzazione delle caratteristiche, senza assumere a priori che la conoscenza discriminativa acquisita nel dominio sorgente rimanga invariata nei differenti contesti target.

Il problema sperimentale viene circoscritto alla variazione della componente malevola del traffico. Nei benchmark cross-domain adottati, la componente nominale ($Y = 0$) rimane derivata dal dominio sorgente, mentre le differenti configurazioni modificano la provenienza e la composizione delle osservazioni malevole ($Y = 1$). Di conseguenza, l'indagine consente di valutare la capacità

dei classificatori di riconoscere famiglie di attacco caratterizzate da distribuzioni differenti da quelle osservate nel dominio sorgente, ma non costituisce una valutazione del *domain shift* associato al traffico nominale.

All'interno di tale perimetro, la sola valutazione di un modello addestrato sul sorgente non è sufficiente a caratterizzare l'intero problema. La disponibilità di conoscenza target può infatti variare da una condizione di completa assenza fino alla disponibilità estesa di esempi provenienti dal nuovo dominio. Il framework considera pertanto tre regimi principali di addestramento, concepiti come differenti livelli di esposizione del classificatore all'informazione target:

1. **Modello sorgente ($\mathcal{M}_S$):** il classificatore viene addestrato esclusivamente sul dominio sorgente $\mathcal{D}_S^{(\text{train})}$. Tale configurazione rappresenta il caso privo di adattamento e consente di quantificare la trasferibilità diretta della conoscenza appresa verso distribuzioni non osservate durante il *training*;
2. **Modello baseline ($\mathcal{M}_{\text{base}}$, INJECTION):** il dominio sorgente viene integrato con una quantità fortemente limitata e controllata di osservazioni target. Questa configurazione rappresenta una condizione intermedia, nella quale il classificatore dispone di una conoscenza preventiva sparsa del dominio di destinazione senza sostituire la struttura informativa acquisita sul sorgente;
3. **Modelli ibridi ($\mathcal{M}_H^{(T)}$):** la componente nominale sorgente viene combinata con la componente malevola del dominio target considerato. Tali configurazioni rappresentano il caso di maggiore esposizione alla distribuzione di destinazione e consentono di osservare il comportamento di classificatori fortemente specializzati sul nuovo dominio.

Il confronto tra questi tre regimi consente di trasformare il problema della trasferibilità in un problema più generale di equilibrio tra *adaptation*, intesa come acquisizione di conoscenza relativa al dominio target, e *retention*, intesa come preservazione della capacità discriminativa precedentemente acquisita sul dominio sorgente. Un sistema capace di ottenere prestazioni elevate sul solo dominio sorgente può infatti risultare poco sensibile alle distribuzioni target; simmetricamente, una forte specializzazione sul dominio di destinazione può compromettere la capacità di riconoscere configurazioni precedentemente apprese. La robustezza cross-domain viene quindi interpretata non come la massimizzazione isolata delle prestazioni su uno specifico benchmark, ma come la

capacità di acquisire informazione relativa al nuovo dominio preservando, per quanto possibile, la conoscenza discriminativa precedente.

Una seconda dimensione del problema riguarda la granularità con cui viene rappresentata la componente malevola durante l'addestramento. Lo spazio di uscita del classificatore rimane in ogni configurazione binario,

$$\mathcal{Y} = \{0, 1\}, \quad (1.2)$$

dove $Y = 0$ identifica il traffico nominale e $Y = 1$ quello malevolo. La distinzione tra modelli aggregati e modelli biclasse non riguarda quindi la cardinalità dello spazio di output, bensì il numero di famiglie d'attacco simultaneamente rappresentate all'interno della classe positiva.

I modelli aggregati apprendono una frontiera decisionale a partire da più famiglie di minaccia appartenenti al medesimo dominio, mentre i modelli biclasse specialistici sono costruiti isolando una singola famiglia d'attacco rispetto alla componente nominale. Tale distinzione consente di analizzare se una rappresentazione malevola più ampia favorisca una maggiore tolleranza alle variazioni distributive oppure se una maggiore specializzazione migliori la discriminazione locale a costo di una minore capacità di generalizzazione.

A questa componente si aggiunge infine l'effetto dell'architettura algoritmica. Il protocollo confronta classificatori ad albero caratterizzati da differenti strategie di costruzione della funzione decisionale, verificando se il comportamento cross-domain dipenda prevalentemente dalla composizione del training set oppure venga modificato in misura sostanziale dalla famiglia di stimatore impiegata. L'obiettivo non consiste tuttavia nell'identificare a priori un classificatore universalmente ottimale, bensì nel caratterizzare il compromesso tra sensibilità, specificità, stabilità e capacità di trasferimento nelle differenti condizioni sperimentali.

Il problema di ricerca può pertanto essere sintetizzato nella valutazione sistematica di come **composizione del dominio di addestramento, quantità di conoscenza target, granularità della componente malevola e architettura del classificatore** concorrano a determinare la robustezza di un NIDS in condizioni cross-domain.

La Figura 1.1 sintetizza graficamente il problema di ricerca, evidenziando il passaggio tra dominio sorgente e dominio target e le principali dimensioni sperimentali attraverso cui viene valutata la robustezza cross-domain.




Figura 1.1: Sintesi concettuale del problema di ricerca e collegamento tra le principali dimensioni sperimentali e le domande di ricerca.

Su tale formulazione vengono definite, nella sezione successiva, le domande di ricerca e gli obiettivi specifici che guidano il protocollo sperimentale.

1.3 Obiettivi e Domande di Ricerca

Alla luce del problema delineato nella sezione precedente, l'obiettivo generale del presente lavoro consiste nel definire e validare un framework sperimentale per la valutazione della robustezza cross-domain di sistemi NIDS supervisionati, con particolare riferimento alla capacità di trasferire conoscenza da un dominio sorgente terrestre verso distribuzioni malevole appartenenti a contesti target eterogenei.

L'indagine non mira esclusivamente a misurare la prestazione predittiva raggiunta all'interno di ciascun dominio, ma a caratterizzare il comportamento dei classificatori lungo differenti regimi di disponibilità dell'informazione target. L'attenzione viene pertanto posta sul compromesso tra

capacità di adattamento verso nuove distribuzioni e conservazione della conoscenza precedentemente acquisita, valutando contestualmente l'effetto della granularità della componente malevola, dell'architettura algoritmica e della variabilità stocastica del processo di addestramento.

A partire da tale obiettivo generale, il lavoro persegue i seguenti obiettivi specifici:

1. **Caratterizzare il disallineamento distributivo tra dominio sorgente e domini target**, analizzando come le differenti configurazioni di benchmark occupino lo spazio condiviso delle caratteristiche e individuando evidenze empiriche compatibili con la presenza di *domain shift*;
2. **Quantificare la trasferibilità diretta dei classificatori addestrati esclusivamente sul dominio sorgente**, verificando la variazione delle prestazioni quando i modelli vengono esposti a distribuzioni malevole non osservate durante la fase di addestramento;
3. **Valutare l'effetto dell'introduzione di conoscenza target nel processo di apprendimento**, confrontando una condizione di adattamento sparso con configurazioni caratterizzate da una maggiore esposizione alla componente malevola target e analizzando contestualmente la capacità di preservare la conoscenza sorgente;
4. **Analizzare l'impatto della granularità e dell'architettura di classificazione sulla robustezza cross-domain**, confrontando modelli aggregati e specialistici e differenti famiglie di classificatori rispetto a sensibilità, specificità, stabilità e organizzazione della funzione decisionale;
5. **Verificare la stabilità e la significatività delle differenze prestazionali osservate**, integrando valutazioni *multi-seed* e analisi inferenziale per caratterizzare la variabilità associata all'addestramento, affiancate da strumenti diagnostici post-hoc per l'interpretazione delle variazioni distributive e decisionali.

Gli obiettivi così definiti vengono tradotti nelle seguenti domande di ricerca (*Research Questions*, RQ), che costituiscono il riferimento logico per la progettazione del protocollo sperimentale e per la successiva interpretazione dei risultati.

RQ1 – Trasferibilità diretta e Domain Shift. *In quale misura un NIDS supervisionato, addestrato esclusivamente sul dominio sorgente, mantiene la propria capacità discriminativa quando viene valutato su distribuzioni malevole appartenenti ai domini target?*

La prima domanda considera il regime privo di adattamento, rappresentato dai modelli sorgente $\mathcal{M}_S$, e mira a determinare se prestazioni ottenute in condizioni intra-domain risultino trasferibili verso distribuzioni differenti. Il confronto tra valutazioni sorgente e target consente quindi di quantificare il degrado associato al trasferimento cross-domain e di verificare se la sola conoscenza terrestre sia sufficiente a garantire robustezza rispetto a minacce appartenenti a contesti non osservati durante l'addestramento.

RQ2 – Adattamento mediante Conoscenza Target Sparsa. *In quale misura l'introduzione di una quantità limitata e controllata di conoscenza target consente di migliorare la capacità di generalizzazione cross-domain preservando contemporaneamente la conoscenza discriminativa acquisita sul dominio sorgente?*

La seconda domanda riguarda il regime intermedio rappresentato dalla baseline $\mathcal{M}_{\text{base}}$. L'obiettivo è verificare se una conoscenza preventiva fortemente sparsa del dominio di destinazione possa modificare favorevolmente la funzione decisionale senza produrre una specializzazione tale da compromettere il riconoscimento delle distribuzioni precedentemente apprese. Il comportamento della baseline viene pertanto confrontato sia con il regime privo di adattamento sia con le configurazioni caratterizzate da una maggiore esposizione al dominio target.

RQ3 – Granularità, Specializzazione e Generalizzazione. *Come incide la granularità della rappresentazione della componente malevola sulla capacità del classificatore di generalizzare in presenza di variazioni distributive?*

La terza domanda confronta modelli aggregati, nei quali più famiglie d'attacco contribuiscono alla costruzione della regione decisionale positiva, e modelli biclasse specialistici, addestrati rispetto a una singola famiglia di minaccia. L'analisi mira a verificare il compromesso tra ampiezza della conoscenza rappresentata durante l'apprendimento e specializzazione discriminativa, valutando se una frontiera costruita su un supporto malevolo più eterogeneo risulti maggiormente tollerante al *domain shift* rispetto a una formulazione più ristretta.

RQ4 – Architettura, Stabilità e Struttura Decisionale. *In quale misura l’architettura del classificatore modifica il compromesso tra sensibilità, specificità, stabilità e robustezza cross-domain nei differenti regimi di addestramento?*

La quarta domanda considera le differenti famiglie di classificatori adottate nel framework e analizza se le rispettive strategie di costruzione della funzione decisionale producano comportamenti sistematicamente differenti al variare della composizione del training set. La valutazione viene estesa alla stabilità rispetto alle inizializzazioni stocastiche e alle caratteristiche maggiormente coinvolte nelle decisioni, al fine di confrontare il ruolo dell’architettura algoritmica con quello della composizione dei dati disponibili durante l’addestramento.

Le quattro domande di ricerca definiscono pertanto una progressione che muove dalla verifica della trasferibilità diretta, introduce progressivamente la conoscenza del dominio target e analizza infine il ruolo della granularità e dell’architettura del classificatore. La loro valutazione richiede un protocollo capace di integrare misure prestazionali, confronto cross-domain, analisi della variabilità stocastica e strumenti diagnostici dello spazio delle caratteristiche e della funzione decisionale.

La sezione successiva sintetizza l’approccio metodologico adottato per tradurre tali obiettivi in una campagna sperimentale riproducibile.

1.4 Approccio Metodologico

Per rispondere alle domande di ricerca definite nella sezione precedente, il presente lavoro adotta un approccio sperimentale strutturato secondo una pipeline progressiva che integra armonizzazione dei dati, costruzione controllata dei benchmark, addestramento supervisionato, valutazione cross-domain e analisi diagnostica.

L’impostazione metodologica è concepita per mantenere distinte le differenti sorgenti di variabilità che possono influenzare il comportamento dei classificatori. In particolare, la composizione dei dataset, la disponibilità di conoscenza target, la granularità della componente malevola, l’architettura del modello e l’inizializzazione stocastica vengono analizzate secondo configurazioni controllate, consentendo di confrontarne sistematicamente l’associazione con le variazioni prestazionali osservate nel perimetro sperimentale considerato.

L’approccio complessivo si articola nelle seguenti fasi principali.

1) Definizione dei domini sorgente e target. Il dominio sorgente $\mathcal{D}_S$ viene istanziato mediante il dataset UNSW-NB15 [9], utilizzato come rappresentazione del traffico terrestre di riferimento. I domini target $\mathcal{D}_T$ vengono invece derivati dal dataset STIN [10], articolato nei segmenti TER20 e SAT20, rappresentativi rispettivamente della componente terrestre e satellitare dell’infrastruttura integrata.

Le sorgenti dati presentano strutture, tassonomie e insiemi di caratteristiche differenti. Per consentirne il confronto, ciascun dominio viene pertanto sottoposto alle procedure di filtraggio e riorganizzazione necessarie a ottenere una rappresentazione coerente delle componenti nominali e malevole considerate dal protocollo.

2) Armonizzazione dello spazio delle caratteristiche. Le rappresentazioni grezze dei differenti domini vengono ricondotte a uno spazio condiviso

$$\mathcal{X} \subseteq \mathbb{R}^{16}$$

mediante gli operatori di mappatura ψ_S e ψ_T formalizzati nel Capitolo 3.

Il processo mantiene esclusivamente caratteristiche semanticamente confrontabili tra le sorgenti dati, applicando, ove necessario, trasformazioni algebriche, conversioni dimensionali e armonizzazione delle unità di misura. Gli identificatori locali e gli attributi non trasferibili tra domini vengono esclusi al fine di ridurre il rischio che il classificatore apprenda correlazioni specifiche del singolo dataset anziché proprietà generalizzabili del traffico.

La pipeline principale di classificazione non applica una standardizzazione globale delle caratteristiche. La trasformazione mediante Z-score viene mantenuta separata dal processo di addestramento e utilizzata esclusivamente nel ramo diagnostico dedicato alle analisi PCA e KDE, secondo la formulazione sviluppata nei Capitoli 3 e 4.

3) Costruzione dei benchmark sperimentali. A partire dai domini armonizzati vengono generate differenti configurazioni di benchmark, mantenendo preventivamente separate le partizioni di addestramento e di test per evitare contaminazioni informative.

La composizione dei dataset è regolata da un rapporto di proporzionamento

$$\rho_{\text{ben/mal}} = 10/1,$$

con partizionamento 80%/20% tra training e test. Il protocollo produce configurazioni aggregate, nelle quali la componente malevola comprende più famiglie d'attacco, e configurazioni biclasse specialistiche, nelle quali viene isolata una singola famiglia di minaccia.

All'interno di tale struttura vengono istanziati i tre principali regimi di apprendimento descritti nella Sezione 1.2: modello sorgente $\mathcal{M}_S$, baseline $\mathcal{M}_{\text{base}}$ con conoscenza target sparsa e modelli ibridi $\mathcal{M}_H^{(T)}$ caratterizzati da una maggiore esposizione alla componente malevola target.

4) Addestramento multi-seed e famiglie di classificatori. La valutazione viene condotta utilizzando tre famiglie di classificatori supervisionati basati su alberi di decisione:

- *Decision Tree* (DT);
- *Random Forest* (RF);
- *Histogram-based Gradient Boosting* (HGB).

Per evitare che le conclusioni dipendano da una singola inizializzazione stocastica, la campagna sperimentale viene replicata su un insieme di $K = 10$ semi distinti:

$$\mathcal{S} = \{0, 1, 7, 42, 101, 123, 999, 1337, 2026, 12345\}. \quad (1.3)$$

I dataset pre-elaborati rimangono invariati tra le differenti esecuzioni, mentre il parametro `random_state` dei classificatori viene modificato secondo il seme considerato. Tale separazione permette di valutare la variabilità associata al processo di apprendimento senza modificare contestualmente la composizione dei benchmark.

5) Cross-Evaluation e validazione statistica. Una volta addestrati, i modelli vengono mantenuti fissi e valutati sulle differenti configurazioni di test previste dal protocollo. La valutazione incrociata consente di confrontare il comportamento del medesimo classificatore sia rispetto alle distribuzioni coerenti con il proprio training set sia rispetto a benchmark appartenenti a domini differenti.

Le prestazioni vengono analizzate attraverso metriche derivate dalla matrice di confusione, con particolare attenzione a *Recall*/TPR, TNR, *Precision* e *F1-Score*, affiancate dalla PR-AUC per caratterizzare la qualità della graduatoria probabilistica indipendentemente dalla singola soglia operativa.

I risultati ottenuti sui differenti seed vengono successivamente aggregati per caratterizzare media e dispersione delle prestazioni. Il confronto tra la baseline e le altre configurazioni viene inoltre supportato mediante il test t di Welch applicato all'*FI-Score*, al fine di verificare se gli scostamenti osservati risultino compatibili con la sola variabilità inter-seed oppure rappresentino differenze statisticamente significative secondo il criterio adottato.

6) Diagnostica distributiva e spiegabilità. Parallelamente al percorso principale di addestramento e valutazione viene mantenuto un ramo diagnostico separato, finalizzato a caratterizzare sia la struttura dei dati sia la funzione decisionale dei classificatori.

L'analisi utilizza tre strumenti complementari:

- **Principal Component Analysis (PCA):** impiegata per osservare la disposizione dei benchmark all'interno di una rappresentazione latente comune e individuare variazioni geometriche associate al cambio di dominio;
- **Kernel Density Estimation (KDE):** utilizzata per confrontare le distribuzioni delle caratteristiche maggiormente rilevanti e analizzare traslazioni, variazioni di dispersione e sovrapposizioni tra traffico nominale e malevolo;
- **SHAP/TreeSHAP:** impiegato come strumento post-hoc di spiegabilità per identificare le caratteristiche maggiormente coinvolte nelle decisioni dei modelli e confrontarne l'organizzazione nei differenti regimi di addestramento.

La combinazione di valutazione predittiva, analisi statistica e diagnostica post-hoc consente di affrontare le Research Questions da prospettive complementari. Le metriche quantificano la capacità di discriminazione dei modelli, la valutazione multi-seed ne caratterizza la stabilità, il test statistico qualifica le differenze globali tra configurazioni e gli strumenti PCA, KDE e SHAP forniscono elementi interpretativi sulle variazioni distributive e decisionali associate al trasferimento cross-domain.

La formalizzazione completa del framework viene sviluppata nel Capitolo 3, mentre il Capitolo 4 ne descrive l'istanziatura software, i dataset, i parametri sperimentali e le procedure operative. I risultati prodotti mediante tale protocollo costituiscono infine l'oggetto dell'analisi quantitativa e interpretativa presentata nel Capitolo 5.

1.5 Contributi della Tesi

Il presente lavoro fornisce un insieme di contributi metodologici, sperimentali e implementativi orientati allo studio della robustezza cross-domain dei sistemi NIDS supervisionati. Il contributo complessivo non consiste nella proposta di una nuova architettura di classificazione, bensì nella definizione di un quadro sistematico attraverso il quale modelli esistenti possano essere addestrati, trasferiti e confrontati in presenza di distribuzioni di traffico eterogenee e differenti livelli di disponibilità della conoscenza target.

I principali contributi della tesi possono essere sintetizzati nei seguenti punti.

1. Definizione di un framework metodologico per la valutazione cross-domain dei NIDS.

È stato formalizzato un modello generale per rappresentare domini sorgente e target eterogenei all'interno di uno spazio condiviso delle caratteristiche, introducendo operatori di mappatura specifici per ciascuna sorgente dati e criteri comuni di filtraggio, armonizzazione semantica e prevenzione del *data leakage*.

Il framework separa esplicitamente la composizione dei domini, la granularità della componente malevola, la strategia di addestramento e il protocollo di valutazione, permettendo di analizzare il fenomeno di *domain shift* senza vincolare la formulazione teorica alle peculiarità implementative di un singolo dataset.

2. Definizione di un protocollo controllato di addestramento e cross-evaluation.

Sono stati formalizzati e confrontati tre differenti regimi di disponibilità della conoscenza target: il modello sorgente $\mathcal{M}_S$, privo di adattamento; la baseline $\mathcal{M}_{\text{base}}$, caratterizzata da conoscenza target sparsa; e i modelli ibridi $\mathcal{M}_H^{(T)}$, maggiormente esposti alla distribuzione malevola del dominio di destinazione.

Ciascun modello viene mantenuto immutato dopo l'addestramento e valutato su un insieme comune di benchmark eterogenei. Tale impostazione consente di studiare simultaneamente trasferibilità, specializzazione e conservazione della conoscenza precedentemente acquisita, superando una valutazione limitata alla sola prestazione sul dominio utilizzato durante il training.

3. **Valutazione sperimentale dell'adattamento mediante conoscenza target sparsa.**

La configurazione INJECTION introduce nel training set una quantità controllata e fortemente minoritaria di osservazioni appartenenti al dominio target, mantenendo dominante la struttura informativa del dominio sorgente.

Tale configurazione viene utilizzata come riferimento sperimentale intermedio tra l'assenza di adattamento e la sostituzione estesa della componente malevola con osservazioni target. Il protocollo permette quindi di valutare sistematicamente se una conoscenza preventiva limitata del nuovo dominio possa modificare la generalizzazione cross-domain senza richiedere l'addestramento completo su una distribuzione target integralmente disponibile.

4. **Analisi congiunta di granularità, architettura e stabilità della funzione decisionale.**

Il framework introduce una distinzione esplicita tra modelli aggregati e modelli biclasse specialistici, mantenendo invariato lo spazio decisionale binario $\mathcal{Y} = \{0, 1\}$ ma variando il numero di famiglie d'attacco rappresentate all'interno della classe positiva.

Tale dimensione viene studiata congiuntamente all'architettura del classificatore mediante il confronto tra Decision Tree, Random Forest e Histogram-based Gradient Boosting. La valutazione viene replicata su $K = 10$ semi stocastici e integrata con il test t di Welch sull'*FI-Score*, consentendo di caratterizzare non soltanto le prestazioni puntuali ma anche la loro stabilità e la significatività degli scostamenti osservati tra le differenti configurazioni.

5. **Integrazione di un apparato diagnostico e realizzazione di una pipeline software riproducibile.**

Alla valutazione predittiva viene affiancato un ramo diagnostico indipendente dal processo di addestramento, composto da PCA, KDE e SHAP/TreeSHAP. Questi strumenti vengono impiegati rispettivamente per caratterizzare la geometria dei benchmark, analizzare le variazioni distributive delle caratteristiche e identificare le feature maggiormente coinvolte nelle decisioni dei classificatori.

L'intero protocollo è stato inoltre tradotto in una pipeline software modulare che separa acquisizione e preprocessing dei dati, costruzione dei benchmark, addestramento, inferenza, valutazione statistica, diagnostica e persistenza degli artefatti. La struttura è progettata per

garantire riproducibilità delle esecuzioni e consentire l'estensione del framework mediante l'integrazione di ulteriori dataset target o famiglie di classificatori senza modificare la logica centrale del processo sperimentale.

Nel loro insieme, tali contributi permettono di affrontare la robustezza cross-domain dei sistemi NIDS come un problema multidimensionale, nel quale la sola prestazione predittiva non costituisce un criterio sufficiente di valutazione. La metodologia proposta considera invece congiuntamente provenienza e composizione dei dati di addestramento, quantità di conoscenza target disponibile, granularità della rappresentazione delle minacce, architettura del classificatore, stabilità stocastica e struttura informativa della funzione decisionale.

Il perimetro dei contributi rimane circoscritto alle grandezze effettivamente valutate nel protocollo sperimentale. In particolare, il lavoro non fornisce una caratterizzazione quantitativa dei costi computazionali di deployment, quali latenza di inferenza, occupazione di memoria o consumo energetico, né valuta il trasferimento cross-domain della componente di traffico nominale. Tali aspetti costituiscono pertanto dimensioni complementari rispetto ai contributi sviluppati nella presente tesi e vengono demandati alle successive considerazioni sui limiti e sulle possibili estensioni del lavoro.

1.6 Organizzazione della Tesi

La trattazione è organizzata secondo una progressione che muove dalla definizione del contesto applicativo e del problema di ricerca alla formalizzazione metodologica, alla relativa implementazione e alla successiva validazione sperimentale. Il lavoro si articola complessivamente in sei capitoli, cui si aggiunge un'appendice dedicata alla raccolta dei risultati numerici completi.

Il **Capitolo 2**, *Contesto di Riferimento e Stato dell'Arte*, introduce il quadro tecnologico e scientifico nel quale si colloca il lavoro. Vengono analizzate le caratteristiche delle infrastrutture di telecomunicazione terrestri e satellitari, le principali problematiche di sicurezza associate alla loro integrazione e il ruolo dei sistemi NIDS basati su Machine Learning. La trattazione approfondisce inoltre il fenomeno del *domain shift*, la scarsità di dati etichettati nel dominio target e le principali strategie di adattamento considerate in letteratura, culminando nell'identificazione del *research gap* affrontato dalla tesi.

Il **Capitolo 3**, *Formulazione Teorica e Framework Metodologico*, traduce il problema individuato in una struttura formale indipendente dalle specificità implementative dei dataset. Vengono definiti i domini sorgente e target, lo spazio condiviso delle caratteristiche, gli operatori di mappatura, le differenti configurazioni di benchmark e la tassonomia dei modelli di classificazione. Il capitolo introduce inoltre il protocollo di valutazione cross-domain, la gestione della variabilità stocastica mediante repliche *multi-seed*, la nozione di granularità della componente malevola e gli strumenti statistici e diagnostici adottati per l'interpretazione dei risultati.

Il **Capitolo 4**, *Implementazione del Framework Metodologico*, descrive la trasposizione operativa della formulazione teorica in una pipeline software concreta e riproducibile. Sono presentati l'ambiente sperimentale, i dataset utilizzati, le procedure di preprocessing e armonizzazione, la costruzione dei benchmark, l'istanziamento dei classificatori e l'orchestrazione del ciclo di addestramento e valutazione. La trattazione comprende inoltre l'implementazione delle procedure statistiche e degli strumenti diagnostici PCA, KDE e SHAP/TreeSHAP, mantenuti funzionalmente separati dal flusso principale di training e inferenza.

Il **Capitolo 5**, *Analisi dei Risultati e Discussione Sperimentale*, presenta la validazione empirica del framework. L'analisi prende inizialmente in esame la struttura geometrica e distributiva dei benchmark, per poi confrontare le prestazioni della baseline INJECTION con quelle dei modelli addestrati esclusivamente sul dominio sorgente e delle configurazioni ibride. I risultati puntuali vengono integrati con le statistiche aggregate sulle repliche *multi-seed*, con il test t di Welch e con l'analisi post-hoc delle caratteristiche maggiormente coinvolte nelle decisioni dei classificatori. La parte conclusiva del capitolo ricompone le evidenze quantitative, distributive e interpretative al fine di caratterizzare i differenti regimi di generalizzazione osservati.

Il **Capitolo 6**, *Conclusioni Finali*, ricondurrà le evidenze sperimentali alle domande di ricerca formulate nella Sezione 1.3. La trattazione sintetizzerà i principali risultati ottenuti, discuterà il contributo complessivo del framework rispetto al problema della robustezza cross-domain e distinguerà le conclusioni direttamente supportate dal protocollo dai relativi limiti sperimentali. Saranno infine delineate le principali direzioni di sviluppo futuro, con particolare riferimento alle dimensioni non investigate nella presente campagna sperimentale.

L'**Appendice B**, *Risultati Numerici Completi*, raccoglie infine il dettaglio numerico delle valutazioni sviluppate nel Capitolo 5. Le matrici di confusione, le metriche complementari e gli esiti

completi delle verifiche statistiche vengono mantenuti separati dalla discussione principale al fine di preservarne la leggibilità, garantendo contestualmente la tracciabilità quantitativa delle analisi presentate.

2. Contesto di Riferimento e Stato dell'Arte

Il presente capitolo delinea il quadro concettuale, metodologico e bibliografico all'interno del quale si posiziona il lavoro di ricerca, ponendo le basi per l'analisi dei sistemi di rilevamento delle intrusioni in ambienti di rete complessi ed eterogenei. L'obiettivo primario è chiarire come la natura del canale trasmissivo e le relative dinamiche fisiche influenzino la rappresentazione vettoriale dei dati, condizionando la stabilità e la capacità di generalizzazione dei modelli di sicurezza basati su Machine Learning.

La trattazione si articola come segue. La Sezione 2.1 analizza le caratteristiche strutturali, le vulnerabilità e i profili di rischio che differenziano le infrastrutture terrestri dai segmenti spaziali, evidenziando la necessità di paradigmi di monitoraggio attivo. La Sezione 2.2 esamina i principi operativi dei *Network Intrusion Detection Systems* (NIDS) guidati dall'apprendimento automatico, fornendo una disamina critica della letteratura principale e identificando i limiti dei modelli attuali nel gestire transizioni tra domini differenti. Successivamente, la Sezione 2.3 formalizza rigorosamente i fenomeni di disallineamento distributivo (*domain shift*) e di scarsità dei dati etichettati, definendo le strategie di adattamento di dominio supervisionato. Infine, la Sezione 2.4 sintetizza i gap metodologici emersi dallo stato dell'arte e colloca l'approccio considerato nel presente lavoro rispetto ai principali assi di confronto individuati nella letteratura.

2.1 Telecomunicazioni

L'evoluzione delle infrastrutture di rete ha elevato i sistemi di telecomunicazione a componenti abilitanti fondamentali per la società moderna, la cui resilienza rappresenta un prerequisito imprescindibile per la protezione delle infrastrutture critiche e la continuità dei servizi essenziali [1]. Con l'affermazione di un paradigma trasmissivo interamente digitale, la convergenza di supporti fisici elettrici, ottici ed elettromagnetici su topologie geografiche complesse ha determinato un ampliamento esponenziale della superficie d'attacco¹.

¹La superficie d'attacco definisce l'insieme complessivo dei vettori di ingresso, delle vulnerabilità software, delle interfacce di rete e dei nodi fisici attraverso cui un agente malevolo può tentare di accedere, degradare o alterare un

La compromissione o la degradazione intenzionale di un canale trasmissivo non si limita a generare una temporanea interruzione della connettività, ma è in grado di innescare fallimenti sistemici a cascata, inficiando l'integrità dei flussi e paralizzando processi decisionali in tempo reale [2]. In un panorama di minacce caratterizzato dall'azione di attori malevoli ad alta persistenza², la difesa dei vettori di trasmissione non può prescindere da una progettazione orientata alla sicurezza nativa (*security-by-design*).

Tale paradigma mira a garantire i requisiti fondamentali di riservatezza, integrità, disponibilità e autenticità dei flussi informativi. L'impostazione di un'efficace strategia difensiva richiede pertanto una disamina puntuale dei vincoli strutturali e dei profili di rischio che caratterizzano i diversi contesti trasmissivi, tracciando una distinzione rigorosa tra le peculiarità delle reti di superficie e le criticità emergenti dei canali orbitali.

2.1.1 Telecomunicazioni terrestri

In questo quadro, la conformazione delle infrastrutture di comunicazione terrestri evidenzia un profondo compromesso tra prestazioni trasmissive e complessità delle contromisure di sicurezza. Da un lato, la combinazione di mezzi guidati ad elevata ampiezza di banda — quali le fibre ottiche — e di vettori radio ad alta frequenza garantisce latenze di propagazione estremamente ridotte, rendendo tali reti il supporto d'elezione per le applicazioni in tempo reale [1]. Dall'altro, la natura distribuita e fisicamente accessibile dei nodi e degli apparati di instradamento intermedi espone l'infrastruttura a un ampio spettro di minacce, agevolando sia intercettazioni sulla tratta fisica sia attacchi logici di tipo *Man-in-the-Middle* (MitM) e *Denial of Service* (DoS) [2].

Sebbene i protocolli crittografici a livello di rete e trasporto (quali IPsec e TLS³) garantiscano la riservatezza e l'integrità dei dati contro l'ascolto passivo, essi si dimostrano intrinsecamente insufficienti a proteggere l'infrastruttura nella sua interezza. Tali meccanismi non ostacolano infatti

sistema di comunicazione.

²Con minacce ad alta persistenza (*Advanced Persistent Threats*, APT) si identificano campagne d'attacco mirate e prolungate nel tempo, condotte da organizzazioni strutturate che impiegano tecniche avanzate per infiltrarsi e mantenere un accesso stealth non autorizzato all'infrastruttura.

³IPsec (*Internet Protocol Security*) opera a livello di rete (Livello 3 del modello ISO/OSI) cifrando l'intero pacchetto IP o il relativo payload, mentre TLS (*Transport Layer Security*) agisce a livello di trasporto/sessione (Livelli 4-5 ISO/OSI) per proteggere il canale sopra protocolli orientati alla connessione come il TCP.

l'analisi del traffico e dei metadati⁴ condotta da osservatori esterni, né risultano efficaci nel contrastare aggressioni volumetriche di tipo DoS o manomissioni strutturali della catena trasmissiva. Si rende quindi indispensabile l'integrazione di sistemi di monitoraggio attivo, come i *Network Intrusion Detection Systems* (NIDS), capaci di analizzare continuamente i flussi di rete per identificare tempestivamente deviazioni dal comportamento nominale prima che si traducano in disservizi sistemici [5].

Ciononostante, la sola protezione del segmento di superficie si rivela insufficiente laddove si richieda la copertura di regioni orograficamente complesse, l'interconnessione di nodi isolati o una ridondanza critica per la continuità operativa. Tali vincoli impongono l'estensione dell'architettura trasmissiva verso il segmento spaziale, introducendo nuove dinamiche di canale e ulteriori sfide di sicurezza.

2.1.2 Telecomunicazioni satellitari

In tale contesto di integrazione, l'impiego di piattaforme orbitali rappresenta una soluzione architetturealmente imprescindibile per garantire una copertura geografica globale, introducendo tuttavia severe sfide operative e di sicurezza. La capacità di superare i vincoli orografici rende i collegamenti spaziali il vettore primario per la connettività in contesti isolati o d'emergenza, garantendo un'essenziale ridondanza per le infrastrutture terrestri [3]. Tuttavia, la natura *broadcast* del canale radio e la vasta impronta a terra (*footprint*) dei fasci di copertura espongono il segnale a continui rischi di intercettazione passiva e a tentativi di *jamming* volti alla saturazione dello spettro [4].

A tali vulnerabilità si sovrappongono i vincoli fisici e trasmissivi specifici delle diverse orbite. Se da un lato i collegamenti in orbita geostazionaria (GEO) sono penalizzati da un elevato ritardo di propagazione (con tempi di *Round Trip Time*, RTT, di circa 500 ms) che degrada le prestazioni dei meccanismi di controllo della congestione del TCP, dall'altro le costellazioni in orbita bassa (LEO) introducono elevate dinamiche di spostamento Doppler (*doppler shift*, con scostamenti fino a ± 100 kHz nelle bande Ku/Ka) e frequenti disconnessioni di *handoff* dovute al ridotto tempo di visibilità dei satelliti (5–10 minuti) [3].

⁴L'analisi del traffico (*traffic analysis*) consiste nell'estrazione di informazioni sensibili tramite l'osservazione dei metadati non cifrati (es. indirizzi IP di sorgente e destinazione, dimensione dei pacchetti, frequenza dei flussi e distribuzioni temporali degli interarrivi), anche in presenza di un payload completamente cifrato.

Inoltre, la potenziale iniezione non autorizzata di pacchetti o comandi di controllo verso il segmento spaziale evidenzia la chiara inadeguatezza della sola cifratura passiva. In conformità con le linee guida di difesa in profondità e monitoraggio continuo per i segmenti di terra e di bordo [4], risulta indispensabile combinare contromisure a livello fisico — quali tecniche di modulazione a spettro espanso a protezione della trasmissione (*TRANSEC*)⁵ — con sistemi di rilevamento delle intrusioni (NIDS) a livello logico, capaci di identificare tempestivamente deviazioni comportamentali del traffico prima che compromettano la disponibilità dell'intero collegamento.

2.1.3 Analisi comparativa e necessità di monitoraggio intelligente

In questa prospettiva di sintesi, l'analisi comparativa tra le architetture di telecomunicazione terrestri e satellitari evidenzia una fondamentale complementarità strutturale, affiancata da sostanziali divergenze operative nei profili di prestazione, copertura e superficie di vulnerabilità. Se le infrastrutture terrestri garantiscono elevati valori di *throughput* e latenze di propagazione ridotte grazie ai mezzi guidati, esse risultano vincolate da una rigida topologia e da un'alta densità di nodi esposti ad aggressioni sia fisiche sia logiche [1]. Al contrario, i segmenti spaziali offrono una connettività pervasiva e affrancata da barriere orografiche, ma introducono criticità legate ai ritardi di propagazione, alle attenuazioni atmosferiche e alla vulnerabilità intrinseca del canale etere a intercettazioni e interferenze intenzionali (*jamming*) [3].

La convergenza di questi ambienti eterogenei nei moderni ecosistemi di comunicazione definisce un perimetro difensivo complesso (schematizzato nella Figura 2.1). In tale contesto, le contromisure di sicurezza tradizionali — quali la sola cifratura del dato o l'impiego di firewall statici — si dimostrano intrinsecamente insufficienti a contrastare vettori d'attacco dinamici e tecniche di evasione avanzate [2]. Ciò impone la transizione verso paradigmi di monitoraggio attivo e resiliente, in grado di rilevare tempestivamente anomalie di flusso lungo l'intero percorso trasmissivo.

Per rispondere a questa crescente complessità, si rende indispensabile l'integrazione di architetture *Network Intrusion Detection Systems* (NIDS) concepite per l'ispezione continua e non invasiva del traffico trasversale alle tratte terrestri e orbitali. Tuttavia, la massiva volumetria dei flussi e

⁵Le contromisure *TRANSEC* (*Transmission Security*) agiscono a livello fisico mediante modulazioni a spettro espanso, quali *DSSS* (*Direct Sequence Spread Spectrum*) o *FHSS* (*Frequency Hopping Spread Spectrum*), per rendere il segnale indistinguibile dal rumore di fondo o garantirne la resilienza contro interferenze intenzionali.

le fluttuazioni stocastiche del canale radio rendono i tradizionali NIDS basati su firme (*signature-based*⁶) inadeguati nei confronti di attacchi inediti (*zero-day*) o di alterazioni comportamentali sottili.

In tale scenario, l'adozione di modelli di Machine Learning si rivela determinante per profilare la dinamica del traffico nominale e identificare in tempo reale deviazioni marginali riconducibili ad attività malevole [5]. L'apprendimento automatico consente di automatizzare l'analisi predittiva e la correlazione di sicurezza multi-dominio, fornendo un presidio difensivo adattivo sia per le tratte di superficie sia per quelle satellitari. Ai fini di un'adeguata contestualizzazione del ruolo di tali strumenti nell'infrastruttura di rete, la sezione seguente introduce la formalizzazione teorica e metodologica dei NIDS e dei modelli di Machine Learning che ne costituiscono il motore analitico.




Figura 2.1: Architettura di rete integrata Terrestre-Spaziale: rappresentazione della superficie d'attacco e posizionamento dei punti di monitoraggio *Network Intrusion Detection System* (NIDS).

⁶I sistemi NIDS basati su firme, quali ad esempio Snort o Suricata, eseguono un'ispezione deterministica del traffico confrontando il contenuto dei pacchetti con un database di regole e pattern malevoli predefiniti, risultando ciechi di fronte a variazioni di formato, traffico cifrato o minacce non ancora catalogate.

2.2 Sistemi NIDS basati su Machine Learning

Muovendo da tali premesse, l'evoluzione delle minacce informatiche all'interno delle moderne infrastrutture di rete ha confermato l'inadeguatezza delle sole difese perimetrali e dei controlli d'accesso, rendendo indispensabile l'adozione di sistemi di rilevamento delle intrusioni basati su rete (*Network Intrusion Detection Systems*, NIDS) per il monitoraggio profondo e continuo del traffico logico. A differenza delle architetture *Host-based* (HIDS), progettate per analizzare i log locali e le chiamate di sistema del singolo dispositivo, un NIDS opera nei punti snodo dell'infrastruttura, ispezionando i flussi di dati per identificare tentativi di accesso non autorizzato, violazioni delle politiche di sicurezza o compromissioni dell'integrità del canale [6].

Tradizionalmente, la rilevazione delle intrusioni nei NIDS si articola in due macro-approcci: l'**ispezione basata sulle firme** (*Signature-based Detection*) e la **rilevazione basata sulle anomalie** (*Anomaly-based Detection*). Sebbene il primo garantisca un'elevata accuratezza nel riconoscere minacce note confrontando il traffico con un database di pattern malevoli predefiniti, esso mostra un'intrinseca inefficacia di fronte ad attacchi inediti (*Zero-Day*) e a varianti strutturali concepite per eludere i controlli [5]. Tale limite ha orientato la ricerca verso modelli analitici capaci di apprendere la profilazione comportamentale del traffico nominale.

Per superare la rigidità dei meccanismi deterministici basati su firme, l'integrazione delle tecniche di Machine Learning nei NIDS consente di apprendere rappresentazioni statistiche del traffico e funzioni decisionali a partire dalle osservazioni disponibili. Attraverso la formalizzazione di *feature* statistiche e sintattiche rilevanti⁷ — quali la frequenza dei pacchetti, la dimensione degli *header* e la distribuzione dei tempi di interarrivo —, un NIDS basato su Machine Learning può discriminare tra differenti configurazioni di traffico senza richiedere necessariamente la corrispondenza con una firma malevola predefinita [5], [6].

In questo contesto, i classificatori supervisionati sfruttano osservazioni etichettate per apprendere una funzione decisionale tra le classi considerate. Rispetto alle tecniche puramente non supervisionate, tale disponibilità informativa può contribuire a contenere i falsi allarmi e a rendere

⁷Nei NIDS moderni, la caratterizzazione del traffico poggia sull'estrazione di attributi di flusso (es. formato NetFlow/IPFIX), tra cui la dimensione degli *header*, la frequenza dei pacchetti, la dimensione delle finestre TCP e la distribuzione temporale degli interarrivi.

quantitativamente verificabile la capacità discriminativa del modello, pur mantenendo la prestazione dipendente dalla rappresentatività delle distribuzioni utilizzate durante l'addestramento [11].

2.2.1 NIDS in Machine Learning per le telecomunicazioni terrestri

L'applicazione dei *Network Intrusion Detection Systems* (NIDS) basati su Machine Learning alle infrastrutture di telecomunicazione terrestri risponde alla necessità imperativa di proteggere canali ad elevata ampiezza di banda e ad altissima densità di traffico. Nelle reti di terra ad alta velocità, i vettori d'attacco si manifestano prevalentemente attraverso aggressioni volumetriche di tipo *Distributed Denial of Service* (DDoS) o mediante attività di scansione coordinata (*port scanning*) finalizzate alla mappatura delle vulnerabilità del sistema [5], [6]. I modelli analitici sviluppati in letteratura si dividono principalmente tra approcci non supervisionati e classificatori supervisionati, ciascuno caratterizzato da specifici compromessi tra flessibilità applicativa e stabilità operativa [11]. Tuttavia, l'analisi dello stato dell'arte evidenzia un limite metodologico diffuso: la quasi totalità della letteratura valuta tali modelli esclusivamente all'interno del medesimo contesto di addestramento, sottovalutando il severo degrado prestazionale causato dalla variazione delle condizioni del canale e della distribuzione dei dati.

Un primo filone di ricerca nell'ambito del monitoraggio non presidiato poggia sull'analisi fondamentale di Sommer e Paxson [12], incentrata sullo studio critico dei limiti dell'anomaly detection basata su Machine Learning non supervisionato in reti di grande scala. Sebbene questo paradigma offra il vantaggio teorico di identificare deviazioni dal profilo di traffico nominale senza richiedere dataset etichettati — promettendo una potenziale copertura contro minacce inedite —, lo studio ne evidenzia i severi vincoli operativi. In particolare, l'assenza di confini di decisione guidati da etichette rende i modelli non supervisionati estremamente sensibili al rumore di fondo e alle fluttuazioni stocastiche del traffico, traducendosi in un elevato e inaccettabile tasso di falsi allarmi (*False Positive Rate*, FPR). Per superare tali criticità analitiche, la nostra trattazione privilegia l'apprendimento supervisionato, al fine di garantire confini di separazione stabili, interpretabili e misurabili di fronte al disallineamento distributivo.

Spostando l'attenzione sui modelli guidati da dati etichettati, un primo contributo pionieristico per i classificatori supervisionati terrestri è rappresentato dallo studio di Tavallaee et al. [13]. Gli autori hanno formalizzato le metodologie di *benchmarking* per la sicurezza di rete attraverso

la bonifica dei bias di ridondanza con il dataset NSL-KDD⁸. Nonostante l'importanza storica di tale lavoro nel validare l'accuratezza dei modelli supervisionati, il nostro approccio se ne discosta nettamente: la valutazione condotta da Tavallae et al. rimane circoscritta a un dominio sintetico e stazionario, senza indagare il comportamento dei classificatori di fronte a fenomeni di *domain shift*⁹.

Successivamente, Sharafaldin et al. [14] hanno esteso la caratterizzazione dei NIDS supervisionati a flussi ad alta dimensionalità e a vettori d'attacco complessi tramite l'introduzione del dataset CIC-IDS2017. Sebbene tale contributo costituisca un riferimento consolidato per la modellazione del traffico moderno, la relativa valutazione rimane prevalentemente circoscritta a un singolo dominio di riferimento.

Il presente lavoro considera invece il comportamento dei classificatori in condizioni cross-domain e introduce un confronto tra differenti livelli di granularità della rappresentazione della componente malevola. Lo spazio di uscita rimane binario, mentre varia il numero di famiglie d'attacco rappresentate simultaneamente all'interno della classe positiva, consentendo di confrontare **configurazioni aggregate** e **rilevatori specialistici** rispetto alla rispettiva capacità di generalizzazione.

2.2.2 NIDS in Machine Learning per le telecomunicazioni satellitari

L'impiego dei *Network Intrusion Detection Systems* (NIDS) basati su Machine Learning nelle comunicazioni satellitari deve misurarsi con vincoli operativi e dinamiche di canale radicalmente divergenti rispetto al contesto terrestre. Le tratte orbitali sono penalizzate da elevati tempi di latenza di propagazione, capacità di canale fortemente asimmetriche e da una marcata suscettibilità al rumore atmosferico e ai fenomeni di *fading* stocastico del segnale [3]. In questo scenario, ai tradizionali vettori d'attacco logici si sovrappongono minacce specifiche del canale radio spaziale, quali le interferenze intenzionali di tipo *jamming* e l'iniezione non autorizzata di telecomandi

⁸Il dataset NSL-KDD ha risolto i problemi di duplicazione dei record presenti nell'originale KDD'99, i quali sbilanciavano le metriche di valutazione e alteravano la capacità dei classificatori di apprendere pattern di attacco rari.

⁹Con *domain shift* (o scostamento distributivo) si intende la variazione della distribuzione di probabilità congiunta dei dati tra il dominio di addestramento e quello di test ($P_S(X,Y) \neq P_T(X,Y)$), la quale determina un drastico decadimento della capacità di generalizzazione del modello.

malevoli (*command injection*) [4]. In ambienti caratterizzati da tale variabilità, la scelta di adottare classificatori supervisionati si rivela essenziale per contenere il tasso di falsi allarmi (*False Positive Rate*, FPR), a cui i modelli non supervisionati risultano strutturalmente vulnerabili quando esposti alle fluttuazioni stocastiche della rete [3], [5]. Tuttavia, la barriera primaria allo sviluppo di NIDS nativi per lo spazio risiede nella severa indisponibilità di dataset pubblici e realistici contenenti tracce etichettate di traffico satellitare malevolo [8].

Nell'ambito della letteratura focalizzata sulle reti integrate spazio-terra, un punto di riferimento di primaria importanza è costituito dallo studio di Wan et al. [15], incentrato su un NIDS distribuito basato su *Federated Learning* per la protezione delle infrastrutture satellitari. Il pregio principale di questo contributo risiede nell'adozione di un paradigma di addestramento cooperativo che tutela la riservatezza dei dati locali e riduce l'ampiezza di banda richiesta sui collegamenti spaziali. Ciononostante, il presente lavoro si differenzia sostanzialmente da tale impostazione. Lo studio di Wan et al. presuppone infatti un'architettura federata attiva, basata su cicli periodici di aggregazione e sincronizzazione dei parametri tra i nodi della costellazione. Il framework considerato nella presente tesi non introduce invece procedure federate né meccanismi di sincronizzazione distribuita: tra i regimi analizzati viene valutata la trasferibilità diretta (*zero-shot*¹⁰) di classificatori supervisionati addestrati sul dominio terrestre e, separatamente, l'effetto dell'introduzione controllata di conoscenza target. Tale impostazione evita per costruzione lo scambio iterativo di parametri caratteristico dei protocolli federati, senza tuttavia fornire una quantificazione dei costi computazionali o comunicativi associati a un eventuale deployment operativo.

Infine, un ulteriore filone di ricerca sulle reti integrate spazio-aria-terra (SAGIN¹¹) è rappresentato dal lavoro di Alam e Song [16], focalizzato sull'orchestrazione dinamica delle risorse mediante l'impiego combinato di *Graph Neural Networks* (GNN) e *Deep Reinforcement Learning* (DRL). Il principale elemento distintivo di tale approccio risiede nella capacità di adattare le decisioni di allocazione alla topologia dinamica dei nodi spaziali. Il presente lavoro si colloca su un piano differente: l'obiettivo non riguarda l'orchestrazione delle risorse infrastrutturali, bensì la valutazione

¹⁰Nel contesto considerato, l'approccio *zero-shot* indica la valutazione diretta delle prestazioni di un classificatore addestrato esclusivamente sul dominio sorgente nei confronti di distribuzioni target non osservate durante l'addestramento, senza applicare procedure di adattamento o *fine-tuning*.

¹¹*Space-Air-Ground Integrated Networks*: architetture di rete tridimensionali ed eterogenee che integrano la segmentazione spaziale (satelliti LEO/MEO/GEO), aerea (droni, HAPS) e terrestre.

della robustezza cross-domain di classificatori NIDS supervisionati. Il protocollo adottato utilizza classificatori ad albero e non prevede meccanismi di riaddestramento online o di sincronizzazione distribuita, concentrando l'analisi sulle proprietà predittive, sulla stabilità e sulla trasferibilità della funzione decisionale.

Tabella 2.1: Sintesi comparativa dello stato dell'arte sui NIDS nei domini terrestre e satellitare e posizionamento del presente lavoro.

Rif.	Dominio	Approccio
[12]	Terrestre	ML Unsupervised
Contributo Rilevamento di minacce <i>zero-day</i> senza dataset etichettati.		
Limite Elevato tasso di falsi allarmi (FPR) dovuto alle fluttuazioni stocastiche di rete.		
[13]	Terrestre	ML Supervised
Contributo Benchmarking rigido e bonifica dei bias di ridondanza (NSL-KDD).		
Limite Analisi circoscritta a dati sintetici e stazionari; assenza di valutazione su <i>domain shift</i> .		
[14]	Terrestre	ML Supervised
Contributo Caratterizzazione di flussi ad alta dimensionalità (CIC-IDS2017).		
Limite Ristretto alla sola risposta multiclasse; omette la valutazione binaria e cross-dominio.		
[15]	Spazio-Terra	Federated Learning
Contributo Addestramento distribuito e cooperativo con tutela della privacy.		
Limite Elevato <i>overhead</i> per sincronizzazione continua dei parametri su tratte orbitali.		
[16]	SAGIN	GNN + DRL
Contributo Adattamento dinamico alle topologie spaziali ad alta variabilità.		
Limite Elevato carico computazionale; orientato alle risorse anziché alla rilevazione.		
Presente lavoro	Terrestre / Terrestre-Spaziale	ML Supervised; Cross-Domain
Contributo Valutazione <i>zero-shot</i> , conoscenza target sparsa, cross-evaluation e analisi <i>multi-seed</i> .		
Limite <i>Benign-domain shift</i> non valutato; assenza di misure di latenza, memoria e consumo energetico per il deployment.		

L'analisi dello stato dell'arte, i cui contributi fondamentali e i relativi elementi di discontinuità sono sintetizzati nella Tabella 2.1, evidenzia come la valutazione di NIDS basati su Machine

Learning per infrastrutture integrate richieda di superare l'ipotesi di stazionarietà¹² e di considerare esplicitamente la trasferibilità della funzione decisionale.

Il posizionamento del presente lavoro evidenzia in particolare l'interesse verso un regime intermedio tra la valutazione puramente intra-domain e le architetture adattive distribuite: il problema viene studiato mediante classificatori supervisionati sottoposti a cross-evaluation tra domini eterogenei e attraverso differenti livelli di disponibilità della conoscenza target.

Come illustrato nello schema concettuale di Figura 2.2, tale prospettiva richiede di formalizzare il degrado prestazionale potenzialmente associato al disallineamento distributivo del traffico (*domain shift*) e la contemporanea scarsità di osservazioni target etichettate. Tali problematiche costituiscono l'oggetto della trattazione sviluppata nella sezione seguente.




Figura 2.2: Confronto schematico tra la valutazione intra-dominio (Scenario A) e l'impatto del domain shift sul trasferimento delle prestazioni tra il contesto terrestre e quello satellitare (Scenario B).

¹²L'ipotesi di stazionarietà assume che le proprietà statistiche dei flussi di rete, quali media, varianza e distribuzione delle caratteristiche osservate, rimangano sostanzialmente invariati tra i contesti considerati. Tale assunzione può venire meno nel trasferimento tra domini eterogenei.

2.3 Adattamento di Dominio e Scarsità dei Dati

A completamento dell'analisi delle criticità connesse all'integrazione di sistemi di sicurezza basati sull'apprendimento automatico nei moderni ecosistemi di telecomunicazione, risulta indispensabile esaminare le problematiche metodologiche e teoriche legate alla variazione dei contesti operativi e alla disponibilità delle informazioni. La transizione da architetture trasmissive omogenee a scenari eterogenei impone infatti di superare i limiti strutturali associati non solo alla natura fisica dei canali, ma anche alla portabilità dei modelli analitici e alla disomogeneità statistica dei dataset di riferimento.

2.3.1 Il fenomeno del domain shift nei sistemi NIDS

L'efficacia dei modelli di Machine Learning applicati ai Network Intrusion Detection Systems (NIDS) poggia fondamentalmente sull'assunto teorico che i dati di addestramento e quelli operativi siano indipendenti e identicamente distribuiti (*i.i.d.*). Tuttavia, nelle infrastrutture di rete reali la natura dinamica e fortemente variabile del traffico invalida frequentemente tale ipotesi, introducendo un marcato scostamento distributivo [7]. In questo scenario, i paradigmi di *transfer learning* costituiscono una possibile strategia per mitigare il decadimento prestazionale associato al trasferimento tra distribuzioni differenti. Tali approcci mirano a riutilizzare la conoscenza acquisita nel dominio sorgente quando la disponibilità di osservazioni etichettate nel dominio target è limitata, riducendo la necessità di costruire un modello completamente indipendente a partire dal solo dominio di destinazione.

In termini formali, un dominio $\mathcal{D}$ è definito dalla coppia costituita da uno spazio delle *feature* $\mathcal{X}$ ¹³ e da una distribuzione di probabilità marginale $P(X)$, tale per cui $\mathcal{D} = \{\mathcal{X}, P(X)\}$. Assumendo uno spazio delle *feature* condiviso ($\mathcal{X}_S = \mathcal{X}_T = \mathcal{X}$), dati un dominio di origine (*source*) $\mathcal{D}_S = \{\mathcal{X}, P_S(X)\}$ e un dominio di destinazione (*target*) $\mathcal{D}_T = \{\mathcal{X}, P_T(X)\}$, il fenomeno del *domain shift* si verifica quando le distribuzioni marginali differiscono tra i contesti, ossia $P_S(X) \neq P_T(X)$ (*covariate shift*). In alternativa, o in concomitanza, esso si manifesta quando muta la distribuzione condizionata delle classi $Y \in \mathcal{Y}$ rispetto alle osservazioni, ovvero $P_S(Y|X) \neq P_T(Y|X)$ (*concept drift*) [7].

¹³Nel contesto dei NIDS basati su flussi di rete, lo spazio $\mathcal{X}$ codifica attributi statistici del traffico, quali la dimensione media dei pacchetti, la durata dei flussi e i tempi di interarrivo.

Nelle telecomunicazioni, questa discrepanza matematica si traduce in una tangibile alterazione dei profili di traffico. La transizione dal canale terrestre a quello satellitare introduce, infatti, elevati tempi di latenza di propagazione¹⁴, fluttuazioni stocastiche della larghezza di banda e severi effetti di attenuazione atmosferica. Tali dinamiche fisiche modificano pesantemente la distribuzione dei tempi di interarrivo dei pacchetti e l'architettura dei flussi trasmessi, determinando una distorsione diretta nella rappresentazione vettoriale delle *feature* estratte dal sensore NIDS [3], [8]. Geometricamente, tale scostamento trasla i vettori di test rispetto agli iperpiani di separazione appresi durante la fase di *training* terrestre, provocando un grave collasso della capacità discriminativa del classificatore e un incremento incontrollato dei falsi allarmi [17].

In letteratura, il problema dell'adattamento di dominio (*domain adaptation*) viene affrontato prevalentemente ricercando uno spazio latente invariante o minimizzando metriche di distanza statistica (es. *Maximum Mean Discrepancy*) tra le distribuzioni. In questo ambito, il contributo di Wilson e Cook [18] fornisce un'esauritiva analisi teorica dei metodi di *unsupervised domain adaptation*, finalizzati a riallineare le distribuzioni marginali senza ricorrere a etichette nel dominio *target*. Tuttavia, sebbene efficaci nell'abbattere il *bias* in scenari standard, questi metodi sono calibrati su ambienti di rete intrinsecamente omogenei. Di conseguenza, il nostro approccio si differenzia posizionandosi in un'area ancora poco esplorata: la gestione della profonda asimmetria strutturale e della drastica corruzione dei profili di traffico indotte dal trasferimento diretto della sorveglianza dal canale terrestre a quello orbitale.

2.3.2 Adattamento di dominio supervisionato per la mitigazione dello sbilanciamento

Sul piano metodologico, la risoluzione del *domain shift* deve misurarsi con il severo sbilanciamento informativo tra gli ambienti di origine e destinazione. Nelle applicazioni reali di Network Intrusion Detection (NIDS), infatti, la cronica scarsità di campioni etichettati appartenenti al dominio *target* costituisce l'ostacolo primario all'addestramento di modelli di classificazione nativi. Tale vincolo configura scenari di apprendimento semi-supervisionato o a pochi campioni (*few-shot learning*), nei quali la disponibilità di osservazioni etichettate nel contesto di destinazione è estremamente

¹⁴Nei collegamenti satellitari geostazionari (GEO), il solo ritardo di propagazione *one-way* si attesta tipicamente sui 250-280 ms, alterando radicalmente le dinamiche temporali del protocollo TCP rispetto alle reti terrestri.

ridotta o del tutto assente. Come formalizzato nel paradigma del *transfer learning* [7], in presenza di un set limitato di dati nel dominio *target*, è possibile trasferire la conoscenza strutturata appresa dal dominio di origine per preservare le proprietà di generalizzazione del classificatore.

Nelle comunicazioni satellitari, tale criticità risulta ulteriormente esacerbata dalla marcata assenza di tracce di traffico etichettate relative al segmento spaziale. Tale carenza è imputabile a stringenti vincoli di riservatezza industriale e militare, agli elevati costi operativi di monitoraggio in orbita e alla natura intrinsecamente critica delle infrastrutture spaziali, fattori che rendono arduo il reperimento di dataset operativi rappresentativi [3], [8]. Sebbene parte della letteratura proponga l'impiego di modelli puramente non supervisionati per prescindere dalle etichette, tali approcci — basati sulla sola stima della densità di probabilità — mostrano un'intrinseca fragilità nei contesti ad alto rumore stocastico¹⁵. Essi tendono infatti a scambiare le fisiologiche fluttuazioni dinamiche del canale radio per attività malevole [4], [5].

Per preservare la capacità di definire confini di decisione netti tipica dei classificatori supervisionati, una strategia rigorosa consiste nell'adottare paradigmi di *supervised domain adaptation* basati sull'ottimizzazione congiunta del rischio empirico (*joint empirical risk minimization*) [19], [20].

In termini formali, sia $\mathcal{D}_S = \{(x_i^S, y_i^S)\}_{i=1}^{N_S}$ il dataset etichettato di origine terrestre e $\mathcal{D}_T^{sub} = \{(x_j^T, y_j^T)\}_{j=1}^{N_T}$ un sottoinsieme estremamente ridotto di campioni etichettati del segmento satellitare ($N_T \ll N_S$), con $y_i^S, y_j^T \in \mathcal{Y}$. L'addestramento del modello $f(\cdot; \theta)$ viene condotto minimizzando una funzione di perdita (*loss function*) congiunta $\mathcal{L}(\theta)$:

$$\mathcal{L}(\theta) = \frac{1}{N_S} \sum_{i=1}^{N_S} \ell(f(x_i^S; \theta), y_i^S) + \alpha \frac{1}{N_T} \sum_{j=1}^{N_T} \ell(f(x_j^T; \theta), y_j^T) \quad (2.1)$$

dove $\ell(\cdot)$ rappresenta la funzione di perdita istantanea (es. *cross-entropy*) e $\alpha > 0$ è un iperparametro di ponderazione della perdita¹⁶.

L'ottimizzazione congiunta rappresentata nell'Equazione (2.1) mira a modificare la funzione decisionale incorporando l'informazione disponibile nel dominio di destinazione, preservando con-

¹⁵Nelle tratte satellitari, le variazioni di canale (es. attenuazione da pioggia, effetto Doppler e ritardi stocastici) alterano la distribuzione statistica delle *feature* di rete, inducendo elevati tassi di falsi allarmi nei modelli basati su anomalie puramente non supervisionati.

¹⁶L'iperparametro α compensa la sproporzione quantitativa tra N_S e N_T , evitando che il gradiente calcolato sui dati terrestri sovrasti il segnale di adattamento proveniente dal dominio satellitare.

testualmente la conoscenza strutturata acquisita sul dominio sorgente [20]. In termini generali, tale formulazione costituisce quindi un riferimento teorico per la mitigazione del disallineamento distributivo in presenza di una disponibilità limitata di campioni target etichettati.

L'efficacia dell'adattamento non può tuttavia essere assunta a priori, poiché dipende dalla relazione tra le distribuzioni coinvolte, dalla quantità e dalla rappresentatività della conoscenza target e dal classificatore adottato. Nel presente lavoro tale principio viene pertanto investigato sperimentalmente attraverso configurazioni controllate del training set, descritte formalmente nel capitolo successivo, senza identificare l'Equazione (2.1) con una specifica funzione di perdita implementata nella pipeline.

2.4 Sintesi dello Stato dell'Arte e Research Gap

L'analisi della letteratura scientifica sviluppata nel presente capitolo evidenzia come la convergenza tra infrastrutture di comunicazione terrestri e segmenti trasmissivi spaziali abbia ampliato il perimetro operativo e di sicurezza delle reti moderne. In tale contesto, i sistemi NIDS basati su Machine Learning costituiscono uno degli strumenti disponibili per il rilevamento di comportamenti malevoli non completamente descrivibili mediante regole o firme statiche [5], [6].

Lo stato dell'arte esaminato mette tuttavia in evidenza due criticità metodologiche complementari:

1. **NIDS valutati prevalentemente in condizioni intra-domain:** una parte rilevante della letteratura relativa alle reti terrestri concentra la validazione su partizioni appartenenti al medesimo dominio utilizzato durante l'addestramento. Tale impostazione consente di caratterizzare le prestazioni in condizioni stazionarie, ma fornisce informazioni limitate sulla capacità del classificatore di mantenere proprietà discriminative in presenza di variazioni distributive;
2. **Soluzioni adattive per ambienti satellitari caratterizzate da architetture distribuite o altamente specializzate:** gli studi rivolti a contesti satellitari e SAGIN considerano frequentemente paradigmi quali Federated Learning, Graph Neural Networks e Deep Reinforcement Learning [15], [16]. Tali approcci affrontano aspetti rilevanti quali cooperazione distribuita, dinamismo topologico e orchestrazione delle risorse, ma non rispondono direttamente al

problema di quantificare la trasferibilità di un classificatore NIDS supervisionato tra domini eterogenei e sotto differenti livelli di disponibilità della conoscenza target.

Da tale quadro emerge il *research gap* di riferimento per il presente lavoro: risulta di interesse una valutazione sistematica della **trasferibilità cross-domain** di classificatori supervisionati addestrati a partire da conoscenza terrestre e della loro capacità di adattarsi a distribuzioni target eterogenee quando la disponibilità di osservazioni etichettate del nuovo dominio è fortemente limitata.

La scarsità di dataset pubblici rappresentativi del traffico malevolo in infrastrutture satellitari rende inoltre rilevante l'analisi di regimi intermedi tra due condizioni estreme: l'**assenza completa di conoscenza target**, corrispondente alla valutazione diretta *zero-shot*, e una **maggiore esposizione del classificatore alle distribuzioni di destinazione**. In tale intervallo si colloca il problema dell'**adattamento mediante conoscenza target sparsa**, nel quale l'acquisizione di informazione sul nuovo dominio deve essere valutata congiuntamente alla capacità di preservare la conoscenza precedentemente acquisita sul sorgente.

Il posizionamento sintetizzato nella Tabella 2.1 conduce pertanto a considerare la robustezza cross-domain come una proprietà distinta dalla sola prestazione intra-domain e dalla sola specializzazione sul dominio di destinazione. La sua valutazione richiede un protocollo capace di confrontare sistematicamente differenti composizioni del training set, differenti granularità della componente malevola e differenti famiglie di classificatori, controllando contestualmente la variabilità associata al processo di apprendimento.

Definito il contesto scientifico e circoscritto il relativo *research gap*, il Capitolo 3 introduce la formulazione teorica e il framework metodologico adottati per tradurre tali problematiche in un protocollo sperimentale formalmente controllato.

3. Formulazione Teorica e Framework Metodologico

Il presente capitolo definisce l'impalcatura teorica e il framework metodologico alla base dell'intera indagine sperimentale, fornendo gli strumenti formali necessari per la modellazione, l'analisi e l'adattamento dei sistemi di *Network Intrusion Detection* (NIDS) in contesti operativi eterogenei. L'obiettivo primario risiede nell'instaurazione di un paradigma valutativo rigoroso, strutturalmente svincolato dalle specificità implementative dei singoli dataset, che consenta di quantificare oggettivamente i fenomeni di traslazione di dominio (*domain shift*) e di validare le performance di generalizzazione isolando i reali contributi algoritmici dalla varianza stocastica.

La trattazione si articola secondo una progressione logica suddivisa in quattro sezioni principali:

- La **Sezione 3.1** formalizza il modello astratto del sistema, definendo rigorosamente gli spazi vettoriali di rappresentazione, gli operatori di proiezione per l'armonizzazione delle *feature* e le regole architetturali di partizionamento dei domini.
- La **Sezione 3.2** delinea la tassonomia delle architetture di classificazione adottate e le relative strategie di *transfer learning*, uniformando le metriche di confronto mediante una formulazione omogenea basata sulla stima della probabilità a posteriori.
- La **Sezione 3.3** stabilisce il protocollo valutativo per la stabilità statistica, affrontando la gestione dell'incertezza stocastica tramite valutazione *multi-seed* e definendo gli indici morfologici di granularità dello spazio decisionale.
- Infine, la **Sezione 3.4** completa l'architettura metodologica descrivendo l'apparato diagnostico e di *explainability*, integrando strumenti di stima di densità e metriche di rilevanza fondate sulla teoria dei giochi cooperativi per la caratterizzazione e l'interpretazione causale delle divergenze distributive.

3.1 Modello del Sistema e Spazi di Rappresentazione

La presente sezione formalizza l'impalcatura teorica e matematica del framework analitico, definendo in modo rigoroso gli spazi vettoriali di rappresentazione e le distribuzioni di probabilità

necessarie per modellare i fenomeni di transizione cross-dominio nel contesto NIDS delineato nel capitolo precedente. L'obiettivo è stabilire un modello astratto, indipendente dalle peculiarità di implementazione dei singoli dataset, in grado di garantire il rigore metodologico, la comparabilità delle metriche e l'assenza di contaminazione informativa.

A tal fine, la trattazione introduce preliminarmente la formalizzazione dei domini di origine e destinazione, delineando la semantica a doppia etichettatura (Y, A) , le regole di partizionamento preventivo anti-*data leakage* e il vincolo di proporzionamento parametrico ρ alla base delle cinque categorie astratte di benchmark istanziabili dal framework. Successivamente, viene definito l'operatore di proiezione ψ_k , specifico per ciascun dominio $k \in \{S, T\}$, che mappa le caratteristiche grezze eterogenee nello spazio delle *feature* condiviso $\mathcal{X}$, esplicitando i criteri concettuali di filtraggio e armonizzazione degli attributi. La trattazione si conclude motivando, sulla base della proprietà di invarianza rispetto a trasformazioni monotoniche propria dei classificatori a partizionamento ricorsivo, l'omissione della fase esplicita di scalatura dalla definizione dello spazio delle *feature*.

Per facilitare la lettura della trattazione successiva, i principali simboli e costrutti matematici adottati sono sintetizzati nella Tabella 3.1.

Tabella 3.1: Sintesi della notazione matematica e dei simboli del framework.

Simbolo	Significato
$\mathcal{D} = (\mathcal{X}, P(\mathbf{x}))$	Dominio di traffico e relativa distribuzione
$\mathcal{X} \subseteq \mathbb{R}^d$	Spazio condiviso delle <i>feature</i>
$\mathbf{x} = (x_1, \dots, x_d)^\top$	Vettore delle <i>feature</i> di un flusso
$\mathcal{Y} = \{0, 1\}$	Etichetta binaria: 0 normale, 1 malevolo
$A \in \mathcal{A}$	Classe specifica del flusso: <i>Normal</i> o famiglia d'attacco
$\mathcal{A}_S, \mathcal{A}_T$	Famiglie di attacco sorgente e target
$\mathcal{D}_S, \mathcal{D}_T$	Domini sorgente e target
$\mathcal{D}_k^{(train)}, \mathcal{D}_k^{(test)}$	Partizioni di addestramento e test del dominio k
$\psi_{k \in \{S, T\}}(\cdot)$	Operatore di proiezione nello spazio condiviso $\mathcal{X}$
$N(\cdot)$	Cardinalità dell'insieme considerato

3.1.1 Formalizzazione dei Domini e Composizione Asimmetrica del Traffico

Il framework analitico richiede la definizione rigorosa degli spazi di rappresentazione vettoriale e delle distribuzioni di probabilità associate ai diversi contesti di rete considerati. Si definisce un dominio $\mathcal{D}$ come la coppia $(\mathcal{X}, P(\mathbf{x}))$, dove $\mathcal{X} \subseteq \mathbb{R}^d$ rappresenta lo spazio delle *feature* d -dimensionale condiviso e $P(\mathbf{x})$ la distribuzione di probabilità marginale definita sul vettore delle caratteristiche $\mathbf{x} = (x_1, x_2, \dots, x_d)^\top \in \mathcal{X}$.

Associato a ciascun dominio, la semantica del traffico è modellata tramite una doppia etichettatura. Lo spazio discreto primario $\mathcal{Y} = \{0, 1\}$ stabilisce la natura del flusso, dove $Y = 0$ indica il traffico nominale (*Normal*) e $Y = 1$ identifica genericamente un vettore malevolo. In aggiunta, si definisce un'ulteriore variabile descrittiva $A \in \mathcal{A}$ che specifica il nome della classe, garantendo una caratterizzazione puntuale sia per la componente benevola ($Y = 0$), per la quale A assume tipicamente un unico valore costante (*Normal*), sia per le diverse famiglie di attacco ($Y = 1$), per le quali A è genuinamente multi-valore.

Caratterizzazione Astratta dei Domini e Tassonomia delle Classi

Il framework analitico modella il fenomeno di transizione cross-dominio a partire da due macro-distribuzioni di partenza distinte:

1. **Dominio di Riferimento ($\mathcal{D}_S$):** rappresenta l'ambiente stazionario di origine, contenente sia istanze di traffico nominale ($Y = 0, A \in \mathcal{A}_S$) sia flussi malevoli ($Y = 1, A \in \mathcal{A}_S$). Per eliminare le componenti ad elevata sparsità ed esigua rappresentatività statistica, si applica una procedura di rimozione delle classi minoritarie (*minority removal*) sull'insieme $\mathcal{A}_S$, garantendo una caratterizzazione stabile del baseline di superficie.
2. **Domini di Destinazione ($\mathcal{D}_T$):** rappresentano i contesti soggetti a variazioni trasmissive o canali eterogenei, composti esclusivamente da vettori di traffico malevolo ($Y = 1, A \in \mathcal{A}_T$). Tali domini vengono strutturati applicando, laddove necessario, un raggruppamento delle classi minoritarie (*minority merge*) per accorpare famiglie d'attacco semanticamente affini e preservare la significatività campionaria.

Isolamento Preventivo delle Partizioni e Politiche Anti-Data Leakage

Per garantire il rigore metodologico ed evitare fenomeni di contaminazione informativa tra la fase di addestramento e quella di valutazione (*data leakage*)¹, la partizione di ciascun dominio primario $\mathcal{D}_k$ nei sotto-insiemi di addestramento ($\mathcal{D}_k^{(train)}$) e di verifica ($\mathcal{D}_k^{(test)}$) viene definita a monte di qualsiasi aggregazione o composizione dei benchmark derivati². In tutte le configurazioni sperimentali viene adottata una suddivisione stocastica stratificata con proporzione fissa:

$$\mathcal{D}_k = \mathcal{D}_k^{(train)} \cup \mathcal{D}_k^{(test)}, \quad \text{con } \mathcal{D}_k^{(train)} \cap \mathcal{D}_k^{(test)} = \emptyset \quad (3.1)$$

garantendo la totale indipendenza strutturale dei vettori impiegati per l'inferenza.

Sintesi dei Benchmark e Vincoli di Proporzionamento Riconfigurato

Sia per le configurazioni generate internamente al dominio sorgente sia per i benchmark ibridi ricomposti cross-dominio (necessari per l'assenza di traffico nominale etichettato nei contesti di destinazione), il framework applica una politica di proporzionamento controllato.

Per rispecchiare le condizioni realistiche di rete e prevenire uno sbilanciamento artificiale dei classificatori³, il framework impone un vincolo di proporzionamento parametrico ρ tra la componente benevola e la componente malevola complessiva:

$$\frac{N(Y = 0)}{\sum_{a \in \mathcal{A}_m} N(Y = 1, A = a)} = \rho \quad (3.2)$$

Tale vincolo definisce in modo esplicito l'asimmetria volumetrica tra il traffico nominale ($Y = 0$) e il traffico malevolo ($Y = 1$). Dove $N(\cdot)$ indica la cardinalità dei campioni estratti, $\mathcal{A}_m$ rappresenta l'insieme delle specifiche famiglie di attacco incluse nella configurazione e $\rho \in \mathbb{R}^+$ costituisce il fattore di asimmetria volumetrica prescritto dal protocollo metodologico.

¹L'esecuzione dello split a monte di qualsiasi fusione previene che campioni identici della classe nominale, riutilizzati per benchmark diversi, compaiano simultaneamente negli insiemi di addestramento e di test.

²Dal punto di vista metodologico, tale partizionamento e la successiva ricomposizione dei vettori vengono eseguiti prima di qualsiasi composizione dei benchmark, evitando la creazione di dataset intermedi.

³Nei sistemi NIDS reali, il traffico lecito costituisce la stragrande maggioranza del volume di rete. La parametrizzazione del rapporto emula tale asimmetria mantenendo una densità di attacchi sufficiente a garantire la stabilità statistica delle metriche.

A livello di estrazione, come regola generale si adotta il campionamento senza reinserimento (*without replacement*), precludendo la duplicazione sintetica delle istanze. Qualora, a seguito dell'applicazione del rapporto ρ , una delle due classi $Y \in \{0, 1\}$ non disponga di una quantità di dati sufficiente a raggiungere il volume teorico prefissato, il framework rifiuta l'uso del *replacing*. In tale evenienza, il dimensionamento complessivo del benchmark si ridimensiona ancorandosi alla classe minoritaria (ovvero quella con minore disponibilità di campioni): l'estrazione per l'altra classe viene riproporzionata di conseguenza per soddisfare il rapporto ρ , accettando la potenziale perdita o il mancato utilizzo di una quota di campioni della classe maggioritaria pur di preservare l'unicità e l'integrità statistica delle osservazioni.

Nei benchmark di tipo aggregato (sia sorgenti che ibridi), la composizione interna del sottoinsieme malevolo non adotta l'equiprobabilità artificiale tra le classi d'attacco. Si preserva invece la distribuzione naturale *a priori* $P(A = a \mid Y = 1)$ caratteristica dei domini di origine, evitando alterazioni sintetiche e mantenendo la fedeltà alle frequenze di occorrenza reali delle minacce.

L'intero processo di isolamento procedurale e ricomposizione dei benchmark è schematizzato nella Figura 3.1.




Figura 3.1: Pipeline logica astratta: allineamento dello spazio delle feature $\mathcal{X}$, isolamento preventivo Train/Test anti-*data leakage*, sintesi parametrica con ratio ρ senza reinserimento (con ancoraggio alla classe minoritaria) e istanziazione logica dei benchmark. I blocchi tratteggiati indicano le elaborazioni logiche, mentre i blocchi a linea continua rappresentano gli insiemi di dati e le categorie di output.

Tassonomia Astratta delle Configurazioni Sperimentali

L'applicazione sistematica delle regole metodologiche descritte porta alla generazione dinamica di cinque categorie funzionali di benchmark. Ognuna di queste configurazioni viene istanziata logicamente rispettando il preventivo isolamento logico delle partizioni di train e test e imponendo il vincolo di proporzionamento parametrico ρ tra traffico benevolo e malevolo:

1. **Set Nativo Sorgente Aggregato:** composto dalla baseline nominale $Y = 0$ di $\mathcal{D}_S$ unita alla totalità delle famiglie di attacco sorgenti $A \in \mathcal{A}_S$ (a valle della procedura di *minority removal*),

preservando la distribuzione naturale a priori $P(A = a \mid Y = 1)$ caratteristica del dominio di origine.

2. **Set Nativi Sorgente Biclasse:** formati dall'unione della classe nominale $Y = 0$ con una singola famiglia di attacco $A = a \in \mathcal{A}_S$ isolata all'interno del dominio sorgente.
3. **Set Ibridi Aggregati:** composti dalla classe nominale $Y = 0$ del dominio sorgente unita alla totalità delle minacce dei domini di destinazione $A \in \mathcal{A}_T$ (strutturate tramite *minority merge*), preservando le frequenze *a priori* originali del dominio target.
4. **Set Ibridi Biclasse:** formati dalla combinazione della classe nominale $Y = 0$ sorgente con le singole famiglie d'attacco $A = a \in \mathcal{A}_T$ isolate all'interno dei domini target.
5. **Set di Iniezione di Riferimento:** progettato in conformità agli standard di letteratura [8], mantiene l'intera distribuzione nativa del dominio sorgente (sia il traffico nominale che l'aggregato malevolo di $\mathcal{D}_S$) integrandola con un'iniezione sparsa e controllata di vettori d'attacco provenienti dai domini target $\mathcal{D}_T$.

I dettagli analitici di composizione per ciascuna delle cinque categorie, opportunamente suddivisi per natura del traffico, sono riassunti nella Tabella 3.2.

Tabella 3.2: Tassonomia astratta delle cinque categorie di benchmark sperimentali istanziate dinamicamente.

Categoria Benchmark	Componente Benevola (Y = 0)	Componente Malevola (Y = 1)
Set Nativo Sorgente Aggregato	Baseline nativa $P_S(\mathbf{x} \mid Y = 0, A \in \mathcal{A}_S)$	Tutte le minacce sorgente $P_S(\mathbf{x} \mid Y = 1, A \in \mathcal{A}_S)$ con distribuzioni <i>a priori</i> naturali.
Set Nativo Sorgente Biclasse	Baseline nativa $P_S(\mathbf{x} \mid Y = 0, A \in \mathcal{A}_S)$	Singola minaccia sorgente $P_S(\mathbf{x} \mid Y = 1, A = a)$ isolata ($a \in \mathcal{A}_S$).
Set Ibrido Aggregato	Baseline nativa $P_S(\mathbf{x} \mid Y = 0, A \in \mathcal{A}_S)$	Tutte le minacce target $P_T(\mathbf{x} \mid Y = 1, A \in \mathcal{A}_T)$ con distribuzioni <i>a priori</i> naturali.
Set Ibrido Biclasse	Baseline nativa $P_S(\mathbf{x} \mid Y = 0, A \in \mathcal{A}_S)$	Singola minaccia target $P_T(\mathbf{x} \mid Y = 1, A = a)$ isolata ($a \in \mathcal{A}_T$).
Set di Iniezione di Riferimento	Baseline nativa $P_S(\mathbf{x} \mid Y = 0, A \in \mathcal{A}_S)$	Minacce sorgente in aggregato $P_S(\mathbf{x} \mid Y = 1, A \in \mathcal{A}_S)$ + iniezione altamente sparsa da $\mathcal{D}_T$ ($A \in \mathcal{A}_T$).

3.1.2 Allineamento dello Spazio delle Feature e Preprocessing Astratto

La disomogeneità strutturale tra le sonde di rilevamento e i formati di tracciamento adottati nei diversi ambienti di rete comporta un'asimmetria nativa negli spazi delle caratteristiche grezze. Per consentire la comparabilità cross-dominio, il framework definisce una procedura astratta di riallineamento spaziale e un impianto di trasformazione che mappa osservazioni eterogenee in uno spazio vettoriale comune, preservando la semantica trasmissiva e ottimizzando l'efficienza concettuale. L'intero flusso di mappatura è sintetizzato in Figura 3.2.

Mappatura e Omogeneizzazione dello Spazio Vettoriale

Siano $\mathcal{X}_S^{(grezzo)} \subseteq \mathbb{R}^{d_S}$ e $\mathcal{X}_T^{(grezzo)} \subseteq \mathbb{R}^{d_T}$ gli spazi delle caratteristiche grezze associati rispettivamente al dominio sorgente e ai domini di destinazione. Per superare le differenze nomenclaturali, metriche e strutturali tra le d_S e d_T variabili native, si definisce, per ciascun dominio $k \in \{S, T\}$, un operatore di trasformazione e combinazione funzionale $\psi_k : \mathbb{R}^{d_k} \rightarrow \mathbb{R}^d$ tale per cui⁴:

$$\mathbf{x}_k = \psi_k(\mathbf{x}_k^{(grezzo)}) = \left(\psi_{k,1}(\mathbf{x}_k^{(grezzo)}), \psi_{k,2}(\mathbf{x}_k^{(grezzo)}), \dots, \psi_{k,d}(\mathbf{x}_k^{(grezzo)}) \right)^T \in \mathcal{X} \subseteq \mathbb{R}^d \quad (3.3)$$

Ciascuna componente $\psi_{k,j}$ ($j = 1, \dots, d$) rappresenta una combinazione algebrica o un'estrazione semantica costruita a partire dalle variabili primarie disponibili nel dominio k . Sebbene ψ_S e ψ_T siano definite separatamente per adattarsi alle rispettive variabili native grezze, entrambe sono vincolate a produrre uno spazio d'arrivo $\mathcal{X}$ condiviso e semanticamente equivalente, secondo i criteri di armonizzazione descritti di seguito. La formulazione consente di derivare un set di *feature* condiviso e omogeneo $\mathcal{X}$, indipendentemente dalle difformità applicative dei formati di origine.

Invarianza Concettuale e Filtraggio degli Attributi

La definizione dello spazio proiettato $\mathcal{X}$ risponde a rigorosi vincoli di filtraggio e armonizzazione basati su tre criteri fondamentali:

1. **Rimozione degli identificatori univoci e locali:** gli attributi legati all'identità specifica delle sessioni (es. indirizzi IP, marcatori temporali assoluti o porte di rete puntuali) vengono esclusi a priori per prevenire fenomeni di memorizzazione o correlazioni spurie (*shortcut learning*)⁵, garantendo che i modelli apprendano esclusivamente pattern trasmissivi e comportamentali generalizzabili.
2. **Vincoli di calcolabilità e misurabilità cross-dominio:** le variabili per le quali non sussiste la possibilità fisica o analitica di calcolo equivalente in entrambe le distribuzioni P_S e P_T vengono omesse dal set condiviso. Ciò garantisce che ogni dimensione $x^{(j)} \in \mathcal{X}$ possieda un significato concettuale identico e direttamente confrontabile tra i domini.

⁴La dimensione ridotta d costituisce una costante uniforme per l'intero framework.

⁵Nei contesti NIDS, lo *shortcut learning* si verifica quando il classificatore apprende associazioni mnemoniche tra identificatori locali rigidi (es. un IP specifico) e la classe malevola, perdendo qualsiasi capacità di generalizzare su topologie di rete non viste.

3. **Armonizzazione delle unità di misura ed equivalenza dimensionale:** qualora una medesima metrica sia presente o ricavabile in entrambi i domini ma espressa mediante scala o unità di misura differenti, l'operatore ψ_k applica le necessarie trasformazioni dimensionali per ricondurla a una grandezza standard condivisa. L'uniformazione preventiva delle unità di misura garantisce che discrepanze puramente nominali nelle scale originarie non vengano erroneamente interpretate dai modelli come fenomeno di *domain shift*.




Figura 3.2: Flusso di mappatura e omogeneizzazione dello spazio delle *feature*: gli operatori ψ_S e ψ_T , definiti separatamente per ciascun dominio grezzo, convergono verso lo stesso spazio condiviso $\mathcal{X}$ attraverso i tre criteri comuni di filtraggio e armonizzazione descritti nel testo.

Invarianza Monotonica e Omissione della Scalatura Esplicita

La gestione della scala delle variabili è centrale. Sebbene le tecniche di riscaldamento lineare o di standardizzazione (Z-score, Min-Max scaling) siano ampiamente adottate in letteratura per uniformare i domini di variabilità, il framework teorico sfrutta una nota proprietà algebrica delle famiglie di classificatori impiegate in questa tesi [21], [22].

Per la classe dei modelli basati sul partizionamento ricorsivo dello spazio dei dati⁶, la funzione di suddivisione $s(\mathbf{x})$ lungo ciascuna dimensione j poggia sull'ordinamento relativo dei valori rispetto a una soglia $\theta \in \mathbb{R}$:

$$s(\mathbf{x}) = \mathbb{I}\left(x^{(j)} \leq \theta\right) \quad (3.4)$$

Poiché l'indicatore di partizione $\mathbb{I}(\cdot)$ è rigorosamente invariante rispetto a qualsiasi trasformazione monotonica strettamente crescente $h : \mathbb{R} \rightarrow \mathbb{R}$, si verifica che:

$$\mathbb{I}\left(x^{(j)} \leq \theta\right) \iff \mathbb{I}\left(h(x^{(j)}) \leq h(\theta)\right) \quad (3.5)$$

Di conseguenza, la topologia dell'albero di decisione e la costruzione dei confini di separazione risultano algebricamente identiche sia operando sulle componenti nello spazio nativo $\mathbf{x}$, sia applicando una trasformazione di scala $h(\mathbf{x})$. Omettendo la fase di normalizzazione esplicita, il framework preserva la geometria naturale dei dati senza alterare la capacità discriminativa dei modelli, riducendo l'overhead computazionale nello stadio di parsificazione iniziale.

È opportuno precisare che tale omissione riguarda **esclusivamente lo stadio di addestramento e inferenza dei classificatori**. Qualora strumenti diagnostici non invarianti alla scala (es. *Principal Component Analysis* o stime di densità kernel, *KDE*) vengano impiegati a valle per l'ispezione visiva del *covariate shift* o per finalità di spiegabilità, essi richiedono una normalizzazione dedicata, applicata **unicamente a scopo diagnostico-visivo** e non reintrodotta nello stadio di classificazione.

3.2 Tassonomia delle Architetture di Classificazione e Valutazione Multi-Modello

La presente sezione formalizza la tassonomia delle architetture di classificazione impiegate all'interno del framework metodologico, delineando i criteri per la valutazione multi-modello e l'analisi prestazionale incrociata. L'intera architettura condivide una formulazione matematica unificata

⁶Tale famiglia include architetture ad albero di decisione singolo e relative estensioni ad *ensemble*. La presente derivazione, e la conseguente omissione della scalatura esplicita, è valida esclusivamente per questa famiglia di modelli; qualora il framework venisse esteso a classificatori sensibili alla scala delle variabili (es. reti neurali, SVM a kernel, k -NN, regressione logistica regolarizzata), la normalizzazione andrebbe reintrodotta esplicitamente nello stadio di elaborazione iniziale.

fondata sulla stima della probabilità a posteriori: subordinando l'assegnazione finale della classe a una soglia decisionale parametrica τ , viene garantita una base di confronto rigorosa, omogenea e strutturalmente indipendente dallo specifico algoritmo di apprendimento sottostante.

La trattazione procede definendo lo spazio dei modelli aggregati e le relative strategie di *transfer learning*, per poi introdurre la decomposizione in classificatori specialistici biclasse per l'isolamento analitico delle singole minacce e il relativo protocollo di valutazione incrociata (*cross-evaluation*). La sezione si conclude con la caratterizzazione formale delle famiglie di decisione alberiformi e dei paradigmi di *ensembling* (Bagging e Gradient Boosting), evidenziandone le proprietà algebriche di invarianza e robustezza rispetto alle distorsioni di canale.

Per agevolare la consultazione, i formalismi architetturali e i parametri funzionali introdotti in questa sezione sono riepilogati nella Tabella 3.3.

Tabella 3.3: Sintesi della notazione relativa alle architetture e ai parametri di classificazione.

Simbolo	Significato
$f_{\theta}(\mathbf{x}) \approx P(Y = 1 \mid \mathbf{x})$	Stima della probabilità di traffico malevolo
$\hat{Y} \in \{0, 1\}$	Classe binaria predetta
$\tau \in (0, 1)$	Soglia decisionale del classificatore
$\mathcal{M}_{\text{base}}$	Modello baseline addestrato sul Set di Iniezione
$\mathcal{M}_S$	Modello aggregato addestrato sul dominio sorgente
$\mathcal{M}_H^{(T)}$	Modello aggregato ibrido con attacchi target
$\mathcal{M}_{S,a}, \mathcal{M}_{H,T,a}$	Modelli biclasse specializzati sulla minaccia a
$\mathcal{L}$	Funzione BCE della formulazione astratta dell'apprendimento
$I(R_m)$	Criterio di impurità della regione o nodo R_m

3.2.1 Modello di Riferimento (Baseline) e Modelli Aggregati

In questa sezione si formalizza lo spazio dei classificatori supervisionati operanti all'interno del framework analitico. Indipendentemente dalle specifiche architetture algoritmiche impiegate per la stima dei parametri, il problema di rilevamento delle intrusioni viene modellato in chiave **rigorosamente binaria**. Sebbene i sottoinsiemi malevoli racchiudano al loro interno un insieme eterogeneo di famiglie d'attacco $A \in \mathcal{A}$, la funzione di decisione appresa mappa lo spazio delle *feature* $\mathcal{X} \subseteq \mathbb{R}^d$

direttamente sulla natura del flusso $\mathcal{Y} = \{0, 1\}$, isolando le componenti lecite ($Y = 0$) da qualsiasi manifestazione anomala o minaccia ($Y = 1$).

Formulazione Matematica Astratta dell'Apprendimento Supervisionato

Sia $\mathcal{D}^{(\text{train})}$ una generica partizione di addestramento generata dalle procedure di sintesi descritte nella Sezione 3.1.1, definita come:

$$\mathcal{D}^{(\text{train})} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N, \quad \mathbf{x}_i \in \mathcal{X}, \quad y_i \in \{0, 1\} \quad (3.6)$$

Un classificatore parametrico o non parametrico viene rappresentato astrattamente da una funzione $f_\theta : \mathcal{X} \rightarrow [0, 1]$, dove $f_\theta(\mathbf{x})$ stima la probabilità a posteriori $P(Y = 1 \mid \mathbf{x})$ dato il vettore delle caratteristiche $\mathbf{x}$.

Seguendo il principio di Minimizzazione del Rischio Empirico (ERM) proposto da Vapnik [23], l'addestramento si configura come la ricerca della configurazione parametrica θ^* che minimizza la perdita media valutata sul dataset di addestramento. Adottando la funzione di perdita canonica di *Binary Cross-Entropy* (BCE), definita per il singolo campione come:

$$\mathcal{L}(f_\theta(\mathbf{x}_i), y_i) = -[y_i \log f_\theta(\mathbf{x}_i) + (1 - y_i) \log (1 - f_\theta(\mathbf{x}_i))] \quad (3.7)$$

il problema di ottimizzazione assume la seguente formulazione analitica:

$$\theta^* = \arg \min_{\theta} \mathcal{R}_{\text{emp}}(\theta; \mathcal{D}^{(\text{train})}) = \arg \min_{\theta} \frac{1}{|\mathcal{D}^{(\text{train})}|} \sum_{(\mathbf{x}_i, y_i) \in \mathcal{D}^{(\text{train})}} \mathcal{L}(f_\theta(\mathbf{x}_i), y_i) \quad (3.8)$$

Per la classe di modelli basati su alberi di decisione adottata nel framework, tale formalizzazione esprime la minimizzazione diretta dell'errore nel caso di ensemble additivi basati su boosting (es. *Gradient Boosted Decision Trees*), in cui l'ottimizzazione avviene tramite discesa funzionale del gradiente sulla loss BCE. Nel caso di foreste casuali (es. *Random Forest*), l'addestramento locale minimizza i criteri di impurità nei nodi e $f_\theta(\mathbf{x})$ rappresenta la frequenza relativa dei campioni malevoli nelle foglie, rendendo la BCE il criterio di misura globale dell'errore di calibrazione probabilistica.

La decisione binaria finale $\hat{Y} \in \{0, 1\}$ per un generico vettore di test viene determinata applicando la funzione indicatrice $\mathbb{I}(\cdot)$ rispetto a una soglia canonica di decisione τ ⁷:

$$\hat{Y} = \mathbb{I}(f_{\theta^*}(\mathbf{x}) \geq \tau) \quad (3.9)$$

Il Modello Baseline Proposto ($\mathcal{M}_{\text{base}}$)

Contrariamente agli approcci convenzionali della letteratura che adottano come baseline modelli addestrati su sole distribuzioni stazionarie native, il framework metodologico propone come **unico modello baseline di riferimento** ($\mathcal{M}_{\text{base}}$) un classificatore addestrato sulla partizione di train del *Set di Iniezione di Riferimento* ($\mathcal{D}_{\text{inj}}^{(\text{train})}$).

Questo modello definisce un'ancora di prestazione per contesti affetti da transizione trasmissiva (es. il passaggio da reti terrestri a canali satellitari). In tale ruolo, $\mathcal{M}_{\text{base}}$ fornisce un riferimento stabilizzante per la valutazione dei modelli e consente di confrontare le prestazioni lungo una traiettoria di cambiamento di canale reale. $\mathcal{M}_{\text{base}}$ è un sistema NIDS ad elevata capacità adattiva, in grado di generalizzare non solo su minacce non viste della medesima distribuzione, ma anche su distribuzioni eterogenee grazie alla conoscenza preventiva sparsa. Il vettore dei parametri ottimali θ_{base}^* viene ottenuto mediante:

$$\theta_{\text{base}}^* = \arg \min_{\theta} \mathcal{R}_{\text{emp}}(\theta; \mathcal{D}_{\text{inj}}^{(\text{train})}) \quad (3.10)$$

dove la composizione del dataset di addestramento incorpora la baseline unita all'iniezione target:

$$\mathcal{D}_{\text{inj}}^{(\text{train})} = \mathcal{D}_S^{(\text{train})} \cup \Delta \mathcal{D}_T^{(\text{train})} \quad (3.11)$$

con $\Delta \mathcal{D}_T^{(\text{train})}$ rappresentante il campionamento ridotto ed altamente sparso delle classi d'attacco ($Y = 1, A \in \mathcal{A}_T$)⁸.

In conformità al rigoroso protocollo di isolamento delle partizioni, il modello $\mathcal{M}_{\text{base}}$ viene inizialmente addestrato su $\mathcal{D}_{\text{inj}}^{(\text{train})}$ e validato sulla rispettiva partizione di test isolata $\mathcal{D}_{\text{inj}}^{(\text{test})}$, garantendo la riproducibilità e l'assenza di *data leakage*.

⁷Sebbene $\tau = 0.5$ sia neutro sotto costi simmetrici, nei contesti NIDS reali la soglia viene adattata lungo la curva ROC in funzione del trade-off tra sensibilità e falsi positivi. L'Area Under the ROC Curve (AUC) quantifica la capacità discriminativa complessiva indipendentemente dalla soglia.

⁸Matematicamente, la condizione di sparsità è definita dal vincolo cardinale $|\Delta \mathcal{D}_T^{(\text{train})}| \ll |\mathcal{D}_S^{(\text{train})}|$, emulando uno scenario di *few-shot learning* in cui la visibilità sul canale di destinazione è limitata a pochissimi campioni rappresentativi.

Classificatori Aggregati e Mappatura delle Distribuzioni

Per isolare in modo analitico l'impatto del *domain shift* e valutare le capacità di trasferimento della conoscenza, il framework affianca alla baseline proposta due categorie di modelli aggregati multi-classe (ma a decisione binaria):

1. **Modello Aggregato Nativo Sorgente ($\mathcal{M}_S$):** addestrato esclusivamente sulla partizione di addestramento del dominio sorgente nativo ($\mathcal{D}_S^{(\text{train})}$). Rappresenta il sistema NIDS tradizionale addestrato su sole distribuzioni stazionarie:

$$\theta_S^* = \arg \min_{\theta} \mathcal{R}_{\text{emp}} \left(\theta; \mathcal{D}_S^{(\text{train})} \right) \quad (3.12)$$

La valutazione di $\mathcal{M}_S$ sui benchmark target consente di misurare la pura degradazione prestazionale causata dalle distorsioni di canale senza alcuna forma di adattamento.

2. **Modelli Aggregati Ibridi ($\mathcal{M}_H^{(T)}$):** per ciascun contesto di destinazione T , viene istanziata un'opportuna variante di modello ibrido $\mathcal{M}_H^{(T)}$ addestrata sulla relativa partizione di addestramento ricomposta ($\mathcal{D}_{H,T}^{(\text{train})}$):

$$\mathcal{D}_{H,T}^{(\text{train})} = \mathcal{D}_S^{(\text{train})} \Big|_{Y=0} \cup \mathcal{D}_T^{(\text{train})} \quad (3.13)$$

in cui la classe nominale $Y = 0$ di origine è unita alla totalità dei vettori d'attacco $Y = 1$ del contesto di destinazione ($\mathcal{D}_T^{(\text{train})}$). Il rispettivo vettore di parametri ottimali risponde alla formulazione:

$$\theta_{H,T}^* = \arg \min_{\theta} \mathcal{R}_{\text{emp}} \left(\theta; \mathcal{D}_{H,T}^{(\text{train})} \right) \quad (3.14)$$

Tali modelli formalizzano il limite teorico di rilevamento (*upper bound*) raggiungibile quando il classificatore acquisisce piena visibilità della componente malevola nel dominio target⁹.

⁹Nella letteratura del trasferimento di dominio, $\mathcal{M}_H^{(T)}$ risponde al paradigma dell'*Oracle supervised*: fornisce la massima accuratezza raggiungibile se si disponesse del dataset target integralmente etichettato.

Tabella 3.4: Sintesi comparativa dei modelli di riferimento e aggregati: composizione del training set e finalità concettuale.

Modello	Composizione del <i>Training Set</i>	Finalità Concettuale
$\mathcal{M}_{\text{base}}$	$\mathcal{D}_{\text{inj}}^{(\text{train})} = \mathcal{D}_S^{(\text{train})} \cup \Delta \mathcal{D}_T^{(\text{train})}$	Baseline proposta: ancora di prestazione con conoscenza preventiva sparsa (<i>few-shot</i>) sul canale target.
$\mathcal{M}_S$	$\mathcal{D}_S^{(\text{train})}$	NIDS tradizionale addestrato su sole distribuzioni stazionarie; misura la degradazione da <i>domain shift</i> senza adattamento.
$\mathcal{M}_H^{(T)}$	$\mathcal{D}_{H,T}^{(\text{train})} = \mathcal{D}_S^{(\text{train})} _{Y=0} \cup \mathcal{D}_T^{(\text{train})}$	Limite teorico (<i>upper bound</i> , paradigma <i>Oracle supervised</i>) con piena visibilità della componente malevola target.

Conservazione dei Modelli, Inferenza e Disaggregazione delle Prestazioni

Al completamento della fase di ottimizzazione parametrica e dopo la verifica della convergenza sui rispettivi set di test locali, tutti i modelli generati ($\mathcal{M}_{\text{base}}$, $\mathcal{M}_S$ e le istanze $\mathcal{M}_H^{(T)}$) vengono mantenuti fissi nella propria struttura.

Il protocollo di valutazione per tali classificatori, schematizzato in Figura 3.3 secondo la notazione standard a diagramma di flusso (*flowchart*)¹⁰, segue un doppio binario analitico:

1. **Valutazione di Generalizzazione Globale:** ciascun modello immutabile viene proiettato sulle partizioni di test eterogenee $\mathcal{D}^{(\text{test})}$, consentendo di quantificare la tolleranza al cambio di canale e la capacità di generalizzazione rispetto a minacce target mai osservate in addestramento;

¹⁰A differenza degli schemi architetturali e compositivi delle Figure 3.1 e 3.2, che rappresentano relazioni statiche tra insiemi di dati, la Figura 3.3 e la successiva Figura 3.4 descrivono un protocollo procedurale con un autentico punto di biforcazione (il confronto $f_{\theta^*}(\mathbf{x}) \geq \tau$). Per tale ragione si adotta qui la notazione a diagramma di flusso convenzionale (nodi ellittici per gli insiemi di dati, rombi per i punti di decisione, rettangoli per i processi), coerentemente con la prassi diffusa in letteratura per la rappresentazione di protocolli algoritmici a bivi condizionali.

2. **Disaggregazione delle Prestazioni per Classe:** i modelli aggregati vengono contestualmente valutati sulle singole sottopartizioni per famiglia d’attacco $\mathcal{D}_a^{(\text{test})} \subseteq \mathcal{D}^{(\text{test})}$, ristrette ai soli vettori con $A = a$ per una data classe di minaccia $a \in \mathcal{A}$. Tale analisi disaggregata evita l’effetto di mascheramento delle prestazioni (*class shadowing*), verificando se un’elevata accuratezza globale celi un decadimento selettivo su specifiche classi di minaccia.

È fondamentale sottolineare che l’insieme di test $\mathcal{D}^{(\text{test})}$ non rappresenta un bacino dati specifico e isolato, locale alla sola famiglia dei modelli aggregati. Al contrario, esso coincide formalmente con l’insieme universale condiviso dei benchmark $\mathcal{B}$, che verrà rigorosamente definito nella Sezione 3.3.1. Di conseguenza, l’intero pool di modelli (siano essi aggregati o biclasse) viene proiettato sistematicamente sull’intera totalità di $\mathcal{B}$, garantendo un incrocio analitico esaustivo tra tutte le architetture e tutte le partizioni sperimentali.

Si precisa che la formalizzazione dei modelli biclasse specialistici e il relativo protocollo di *cross-evaluation* speculare sono trattati separatamente nella Sezione 3.2.2.




Figura 3.3: Flusso concettuale del protocollo di addestramento, inferenza e disaggregazione delle prestazioni per i modelli aggregati ($\mathcal{M}_{\text{base}}, \mathcal{M}_S, \mathcal{M}_H^{(T)}$). I modelli, congelati post-ottimizzazione, vengono valutati sia sull’intero benchmark multi-classe per misurare la generalizzazione di dominio, sia sulle singole partizioni per famiglia d’attacco $\mathcal{D}_a^{(\text{test})}$ per l’analisi di disaggregazione puntuale.

3.2.2 Decomposizione Specialistica Biclasse

In integrazione ai modelli aggregati definiti nella Sezione 3.2.1, il framework metodologico prevede una formalizzazione specialistica basata sulla decomposizione del problema di rilevamento in

classificatori biclasse focalizzati su singole famiglie d'attacco $a \in \mathcal{A}$. L'obiettivo primario di tale decomposizione non consiste nella riconfigurazione dell'architettura di inferenza, bensì nell'isolamento analitico delle singole tipologie di minaccia per valutarne la rilevabilità puntuale rispetto al profilo di traffico nominale e confrontarne direttamente le prestazioni con le rispettive varianti multi-classe¹¹.

Sintesi e Bilanciamento delle Partizioni Biclasse

Ciascun dataset biclasse viene generato rispettando rigorosamente il medesimo protocollo di partizionamento, il rapporto di suddivisione train/test e il bilanciamento tra componente lecita e malevola formalizzati nella Sezione 3.1.1. Per ogni specifica famiglia d'attacco a , sia la partizione di addestramento che quella di test comprendono:

1. una frazione di traffico lecito ($Y = 0$), costantemente estratta dalla distribuzione sorgente nativa $\mathcal{D}_S$;
2. una frazione di traffico anomalo ($Y = 1$), ristretta esclusivamente ai vettori associati alla specifica classe di minaccia a .

Tassonomia dei Modelli Biclasse

A differenza della caratterizzazione adottata per i classificatori aggregati, la famiglia dei modelli biclasse **esclude la formulazione di architetture basate su iniezione sparsa** (ovvero non è definita alcuna variante biclasse analoga a $\mathcal{M}_{\text{base}}$)¹². Lo spazio dei modelli biclasse si articola pertanto nelle seguenti due categorie:

1. **Modelli Biclasse Sorgente ($\mathcal{M}_{S,a}$):** specializzati sulle singole famiglie d'attacco $a \in \mathcal{A}_S$ appartenenti al dominio sorgente nativo. La relativa partizione di addestramento $\mathcal{D}_{S,a}^{(\text{train})}$ è

¹¹La decomposizione introduce un costo computazionale di addestramento proporzionale alla cardinalità del set delle minacce $O(|\mathcal{A}|)$. Tale overhead rappresenta un compromesso metodologico consapevole, poiché l'obiettivo primario della formulazione risiede nell'isolamento analitico della rilevabilità e non nell'ottimizzazione dell'efficienza.

¹²L'assenza di modelli biclasse con iniezione deriva dalla volontà di valutare la risposta specialistica o nella condizione di assoluta assenza di adattamento (sorgente pura) o nella condizione di visibilità integrale della minaccia nel dominio target (ibrido/oracle).

definita come:

$$\mathcal{D}_{S,a}^{(\text{train})} = \mathcal{D}_S^{(\text{train})} \Big|_{Y=0} \cup \mathcal{D}_S^{(\text{train})} \Big|_{Y=1, A=a} \quad (3.15)$$

Il vettore ottimale dei parametri $\theta_{S,a}^*$ viene determinato mediante la minimizzazione del rischio empirico ristretto al dominio dell'attacco a :

$$\theta_{S,a}^* = \arg \min_{\theta} \mathcal{R}_{\text{emp}} \left(\theta; \mathcal{D}_{S,a}^{(\text{train})} \right) \quad (3.16)$$

2. **Modelli Biclasse Ibridi/Target ($\mathcal{M}_{H,T,a}$):** istanziati per ciascuna sotto-distribuzione target T e per ciascuna specifica famiglia d'attacco $a \in \mathcal{A}_T$ presente nel dominio di destinazione. La composizione del dataset ricomposto $\mathcal{D}_{H,T,a}^{(\text{train})}$ adotta la componente lecita sorgente unita alla sola classe malevola a del contesto target:

$$\mathcal{D}_{H,T,a}^{(\text{train})} = \mathcal{D}_S^{(\text{train})} \Big|_{Y=0} \cup \mathcal{D}_T^{(\text{train})} \Big|_{Y=1, A=a} \quad (3.17)$$

con la corrispondente stima parametrica fornita da:

$$\theta_{H,T,a}^* = \arg \min_{\theta} \mathcal{R}_{\text{emp}} \left(\theta; \mathcal{D}_{H,T,a}^{(\text{train})} \right) \quad (3.18)$$

Le caratteristiche essenziali e le finalità concettuali delle due categorie di modelli biclasse sono sintetizzate nella Tabella 3.5.

Tabella 3.5: Sintesi dei modelli biclasse specializzati: composizione del *training set* e finalità concettuale.

Modello	Composizione del <i>Training Set</i>	Finalità Concettuale
$\mathcal{M}_{S,a}$	$\mathcal{D}_{S,a}^{(\text{train})} = \mathcal{D}_S^{(\text{train})} \Big _{Y=0} \cup \mathcal{D}_S^{(\text{train})} \Big _{Y=1, A=a}$	Rilevatore specialistico addestrato su una singola minaccia sorgente $a \in \mathcal{A}_S$; valuta la selettività senza distorsioni di canale.
$\mathcal{M}_{H,T,a}$	$\mathcal{D}_{H,T,a}^{(\text{train})} = \mathcal{D}_S^{(\text{train})} \Big _{Y=0} \cup \mathcal{D}_T^{(\text{train})} \Big _{Y=1, A=a}$	Limite teorico (<i>Oracle</i> specialistico) per la singola minaccia $a \in \mathcal{A}_T$ nel dominio target T .

Invarianza dell’Inferenza, Valutazione Incrociata e Persistenza

Il meccanismo decisionale dei classificatori biclasse rimane del tutto identico a quello formalizzato nell’Equazione (3.9): la funzione appresa $f_{\theta^*,a}(\mathbf{x})$ stima la probabilità a posteriori $P(Y = 1 \mid \mathbf{x})$, e la decisione finale $\hat{Y} \in \{0, 1\}$ viene determinata dal confronto con la soglia canonica τ .

Poiché l’output di classificazione è limitato al dominio binario $\mathcal{Y} = \{0, 1\}$ (presenza o assenza di intrusione), ciascun modello biclasse è strutturalmente autocontenuto e indipendente. Non viene applicata alcuna regola di aggregazione d’insieme (es. sistemi di voto o regole di massimo); i modelli rimangono invariati nello stato post-addestramento, rispecchiando la procedura di conservazione definita per i modelli aggregati.

In fase di valutazione sperimentale, il protocollo per i classificatori biclasse, schematizzato in Figura 3.4 secondo la medesima notazione a diagramma di flusso introdotta in Figura 3.3, segue due direttive analitiche complementari:

1. **Valutazione Nominale Specialistica (*In-Domain*):** ciascun modello $\mathcal{M}_{S,a}$ (o $\mathcal{M}_{H,T,a}$) viene inizialmente testato sulla partizione dedicata alla singola minaccia $\mathcal{D}_a^{(\text{test})}$, stabilendo la prestazione ideale del classificatore nel proprio dominio di addestramento primario;
2. **Valutazione Incrociata di Classe (*Cross-Evaluation*):** il modello specialistico viene successivamente proiettato sull’intera gamma di benchmark multi-classe eterogenei $\mathcal{D}^{(\text{test})}$. Tale analisi permette di verificare se la firma appresa per la minaccia a generi falsi allarmi su attacchi $b \neq a$, quantificando la selettività di classe e l’eventuale polarizzazione dello spazio decisionale.

Come anticipato per la famiglia dei modelli aggregati, l’insieme eterogeneo $\mathcal{D}^{(\text{test})}$ impiegato nella *cross-evaluation* coincide esattamente con l’insieme universale dei benchmark $\mathcal{B}$ (Sezione 3.3.1). In quella sede verrà introdotta la matrice strutturata $H_k \in \mathbb{R}^{|\mathcal{M}| \times |\mathcal{B}|}$, in cui verranno incrociati tutti i modelli formulati $\{\mathcal{M}_{\text{base}}, \mathcal{M}_S, \mathcal{M}_H^{(T)}, \mathcal{M}_{S,a}, \mathcal{M}_{H,T,a}\}$ con l’intera estensione dei domini di test generati, fornendo così la rappresentazione visiva e matematica unificata che concretizza questo incrocio prestazionale.




Figura 3.4: Flusso concettuale del protocollo di valutazione incrociata (*cross-evaluation*). Il modello specialistico $\mathcal{M}_{S,a}$, addestrato esclusivamente sulla singola minaccia a , rimane invariato e viene proiettato in fase di inferenza sull'intero benchmark eterogeneo $\mathcal{D}^{(\text{test})}$.

3.2.3 Spazio delle Famiglie di Decisione Alberiformi ed Ensembling

La modellazione della superficie di decisione nei sistemi di *Network Intrusion Detection* (NIDS) operanti su canali ibridi terrestri-spaziali richiede architetture di apprendimento capaci di gestire elevata non-linearità, eterogeneità delle metriche e degradazioni del segnale trasmissivo. Questa sezione formalizza lo spazio delle famiglie di decisione basate sul partizionamento dello spazio delle caratteristiche, analizzandone le proprietà di invarianza e l'estensione a schemi di stima aggregata (*ensembling*).

Partizionamento Ricorsivo dello Spazio delle Caratteristiche

Sia $\mathcal{X} \subseteq \mathbb{R}^d$ lo spazio delle caratteristiche d -dimensionale rappresentativo delle metriche di traffico di rete e telemetria, e sia $\mathcal{Y} = \{0, 1\}$ lo spazio delle etichette corrispondente a traffico lecito o malevolo. Un albero di decisione [21] definisce una mappa $f : \mathcal{X} \rightarrow [0, 1]$ mediante un partizionamento ricorsivo dello spazio $\mathcal{X}$ in M regioni disgiunte e iper-rettangolari $\{R_m\}_{m=1}^M$, tali per cui:

$$\bigcup_{m=1}^M R_m = \mathcal{X} \quad \text{e} \quad R_m \cap R_k = \emptyset, \quad \forall m \neq k \quad (3.19)$$

La funzione di decisione associata all'albero assume la forma analitica espressa da:

$$f(\mathbf{x}) = \sum_{m=1}^M c_m \mathbb{I}(\mathbf{x} \in R_m) \quad (3.20)$$

dove $\mathbb{I}(\cdot)$ denota la funzione indicatrice e $c_m \in [0, 1]$ rappresenta la stima della probabilità a posteriori della classe malevola all'interno della regione R_m , coerentemente con la formulazione $f_\theta : \mathcal{X} \rightarrow [0, 1]$ introdotta nella Sezione 3.2.1. Sulla base del dataset di addestramento $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$, tale stima è definita come la frequenza relativa empirica della classe positiva nella foglia:

$$c_m = \frac{1}{|R_m|} \sum_{\mathbf{x}_i \in R_m} \mathbb{I}(y_i = 1) \quad (3.21)$$

La decisione binaria finale $\hat{Y}$ viene poi ottenuta applicando la soglia canonica τ già formalizzata nell'Equazione (3.9), in coerenza con l'intero framework di ottimizzazione ERM/BCE.

La selezione delle soglie ottimali di split θ_j per la j -esima caratteristica x_j avviene ricorsivamente minimizzando un criterio di impurità $I(R_m)$, come l'indice di Gini o l'entropia cross-entropica [21]. Formalmente, in un task di classificazione binaria, tali criteri sono espressi in funzione della probabilità stimata c_m come:

$$I_{\text{Gini}}(R_m) = 2c_m(1 - c_m), \quad I_{\text{entropy}}(R_m) = -c_m \log_2(c_m) - (1 - c_m) \log_2(1 - c_m) \quad (3.22)$$

Proprietà di Invarianza e Tolleranza alle Distorsioni di Canale

Gli alberi di decisione esibiscono proprietà algebriche e geometriche fondamentali che li rendono intrinsecamente robusti alle perturbazioni introdotte dai canali trasmissivi radiofrequenza (RF) e dalle perdite di pacchetto.

Invarianza alle Trasformazioni Monotone Come introdotto nella Sezione 3.1.2 a giustificazione dell'omissione della fase di scalatura esplicita, le metriche estratte dai canali spaziali possono subire variazioni di scala, attenuazioni o calibrazioni non-lineari. La proprietà viene qui derivata in forma rigorosa e generalizzata a trasformazioni specifiche per singola caratteristica. Sia $h_j : \mathbb{R} \rightarrow \mathbb{R}$ una trasformazione strettamente monotonica crescente applicata alla caratteristica x_j . Poiché la decisione di uno split ad un generico nodo dell'albero è governata dalla funzione di soglia $\mathbb{I}(x_j > \theta_j)$, si osserva che:

$$x_j > \theta_j \iff h_j(x_j) > h_j(\theta_j) \quad (3.23)$$

Definendo la nuova soglia $\theta'_j = h_j(\theta_j)$, l'ordinamento topologico dei punti all'interno dello spazio $\mathcal{X}$ rimane inalterato, garantendo l'invarianza della partizione R_m e della decisione $f(\mathbf{x})$:

$$f(\mathbf{x}) = f(h_1(x_1), h_2(x_2), \dots, h_d(x_d)) \quad (3.24)$$

Tale proprietà elimina la necessità di normalizzazioni rigide (es. z-score o Min-Max) che risulterebbero instabili sotto condizioni di variabilità dinamica del canale.

Robustezza a Rumore Additivo e Distorsione Si consideri una misura corrotta da distorsione o rumore di canale $\tilde{\mathbf{x}} = \mathbf{x} + \boldsymbol{\eta}$, dove $\boldsymbol{\eta}$ rappresenta una componente stocastica con $\mathbb{E}[\boldsymbol{\eta}] = \mathbf{0}$. Poiché le regioni R_m sono delimitate da iperpiani di decisione paralleli agli assi coordinati, la classificazione del vettore perturbato $\tilde{\mathbf{x}}$ risulta invariante rispetto al vettore nominale $\mathbf{x}$ per qualsiasi perturbazione limitata che non attraversi il confine dell'iperpiano:

$$f(\tilde{\mathbf{x}}) = f(\mathbf{x}), \quad \forall \boldsymbol{\eta} \text{ t.c. } \text{sgn}(x_j + \eta_j - \theta_j) = \text{sgn}(x_j - \theta_j) \quad (3.25)$$

Questa natura a scalino (*step function*) riduce la sensibilità al rumore gaussiano e alle fluttuazioni di piccola entità rispetto ai modelli a separazione lineare o a base di distanza euclidea.

Gestione Nativa dei Dati Mancanti (*Packet Loss*) In presenza di perdite di pacchetti o corruzione dei dati di header, alcune caratteristiche x_j possono risultare non disponibili ($x_j = \text{NaN}$). Le strutture alberiformi gestiscono tale incompletezza mediante due meccanismi distinti proposti in letteratura, entrambi privi della necessità di imputazione esplicita del dato: gli *split surrogati*, introdotti nella formulazione originaria di CART [21], che individuano uno split alternativo su una caratteristica correlata a x_j qualora quest'ultima risulti mancante; e l'instradamento a *direzione predefinita* (*default direction*), proposto nel contesto degli algoritmi di boosting scalabili [24], in cui la direzione ottimale $\delta_j^* \in \{\text{sinistra}, \text{destra}\}$ per ciascun nodo di split su x_j viene appresa direttamente durante l'addestramento, minimizzando la perdita empirica sui pattern di sparsità osservati:

$$\text{Posizione}(\mathbf{x}) = \begin{cases} \text{Sinistra} & \text{se } x_j \leq \theta_j \\ \text{Destra} & \text{se } x_j > \theta_j \\ \delta_j^* & \text{se } x_j = \text{NaN} \end{cases} \quad (3.26)$$

Formulazione Generale degli Ensemble per la Riduzione dell'Errore

Sebbene il singolo albero di decisione presenti un basso errore di bias, esso soffre di elevata varianza. Per mitigare tale limite, si ricorre a tecniche di *ensembling* che combinano B stimatori base $\{f_b(\mathbf{x})\}_{b=1}^B$ per formare un predittore aggregato $F(\mathbf{x})$:

$$F(\mathbf{x}) = \sum_{b=1}^B \beta_b f_b(\mathbf{x}) \quad (3.27)$$

Questa astrazione unifica i due principali approcci¹³: l'addestramento parallelo per la riduzione della varianza e l'addestramento sequenziale per la riduzione del bias, le cui differenze chiave sono schematizzate in Tabella 3.6 e in Figura 3.5.

Riduzione della Varianza via Bagging (*Bootstrap Aggregating*) Nello schema Bagging, di cui le architetture *Random Forest* [25] costituiscono l'estensione fondamentale, ciascun stimatore $f_b(\mathbf{x})$ viene addestrato in modo indipendente su un campionamento bootstrap del dataset $\mathcal{D}_b^*$, introducendo un'ulteriore de-correlazione mediante la selezione casuale di un sottoinsieme di $k < d$ caratteristiche a ciascun nodo.

Sia σ^2 la varianza del singolo albero e ρ il coefficiente di correlazione campionaria medio tra le predizioni di due alberi distinti. La varianza dello stimatore mediato $\bar{f}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B f_b(\mathbf{x})$ si esprime analiticamente come [22]:

$$\text{Var}(\bar{f}(\mathbf{x})) = \rho \sigma^2 + \frac{1 - \rho}{B} \sigma^2 \quad (3.28)$$

Al crescere del numero di alberi $B \rightarrow \infty$, il secondo termine tende a zero, riducendo la varianza complessiva del modello al limite teorico $\rho \sigma^2$. La de-correlazione forzata delle caratteristiche riduce il fattore ρ , garantendo un'elevata capacità di generalizzazione anche su traffico malevolo mai osservato.

Riduzione del Bias via Gradient Boosting A differenza dell'approccio parallelo del Bagging, gli algoritmi di *Gradient Boosting* [26] (incluso il paradigma con discretizzazione a istogrammi

¹³Come formalizzato nei paragrafi seguenti, nel caso del Bagging si assegna un peso uniforme $\beta_b = 1/B$, mentre la ricorsione additiva del Boosting, se srotolata su B passi, si riconduce a questa formulazione ponendo $\beta_b = \nu$ (a meno di un predittore costante iniziale F_0).

Histogram-based Gradient Boosting [27]) costruiscono l'ensemble in modo sequenziale ed additivo. Dato un modello al passo $b - 1$ pari a $F_{b-1}(\mathbf{x})$, lo stimatore successivo $f_b(\mathbf{x})$ viene addestrato per approssimare i pseudo-residui $r_{i,b}$, definiti come il gradiente negativo della funzione di perdita differenziabile $L(y_i, F(\mathbf{x}_i))$ valutato sulla predizione corrente:

$$r_{i,b} = - \left[\frac{\partial L(y_i, F(\mathbf{x}_i))}{\partial F(\mathbf{x}_i)} \right]_{F(\mathbf{x}_i)=F_{b-1}(\mathbf{x}_i)} \quad (3.29)$$

L'aggiornamento del modello aggregato avviene secondo la regola:

$$F_b(\mathbf{x}) = F_{b-1}(\mathbf{x}) + \nu \cdot f_b(\mathbf{x}) \quad (3.30)$$

dove $\nu \in (0, 1]$ rappresenta il tasso di apprendimento (*learning rate*). Tale approccio garantisce una minimizzazione progressiva del bias dell'errore di classificazione, consentendo di catturare sottili pattern di attacco ad alta dimensionalità tipici delle minacce cibernetiche complesse.

Tabella 3.6: Confronto delle proprietà architetturali e degli obiettivi di ottimizzazione tra i paradigmi di *ensembling* Bagging e Gradient Boosting.

Caratteristica	Bagging	Gradient Boosting
Costruzione	Parallela, stimatori indipendenti	Sequenziale, additiva
Obiettivo primario	Riduzione della varianza	Riduzione del bias
Combinazione	Media: $\bar{f} = \frac{1}{B} \sum f_b$	Somma pesata: $F_b = F_{b-1} + \nu f_b$
Target addestramento per f_b	Etichette originali su campionamenti bootstrap $\mathcal{D}_b^*$	Pseudo-residui $r_{i,b}$ valutati al passo $b - 1$




Figura 3.5: Confronto logico-procedurale tra gli schemi di aggregazione. A sinistra, il paradigma *Bagging* esegue un addestramento parallelo su campionamenti bootstrap indipendenti. A destra, il paradigma *Gradient Boosting* adotta un approccio sequenziale in cui ciascun albero mira a correggere i residui iterativi generati dall'insieme precedente.

3.3 Framework di Adattamento, Granularità e Stabilità Statistica

La valutazione dell'efficacia delle architetture e delle strategie di *transfer learning* precedentemente formalizzate richiede un apparato metodologico capace di isolare i reali guadagni prestazionali dal rumore stocastico intrinseco ai processi di apprendimento. Questa sezione definisce il framework di valutazione e di analisi teorica adottato per garantire la solidità e la riproducibilità dei risultati.

Nella prima parte della trattazione viene affrontato il problema dell'incertezza algoritmica legata ai modelli ad albero, introducendo un rigoroso protocollo di valutazione *multi-seed*. Vengono definite le metriche prestazionali di aggregazione e viene formalizzato l'impiego del test t di

Welch per stabilire oggettivamente la significatività statistica degli scostamenti osservati rispetto al modello di riferimento (*baseline*). Successivamente, l'analisi si sposta sulle proprietà strutturali e geometriche dello spazio decisionale. Viene introdotto l'indice di granularità per valutare l'impatto della formulazione del problema — differenziando tra partizioni a grana grossa e a grana fine — sulla morfologia dei confini decisionali, discutendo il compromesso teorico tra rigidità specialistica e tolleranza al *domain shift*.

Per agevolare la consultazione delle metriche e dei parametri statistici discussi, la notazione principale introdotta in questa sezione è riepilogata nella Tabella 3.7.

Tabella 3.7: Sintesi della notazione relativa al framework di valutazione e alla stabilità statistica.

Simbolo	Significato
s_0	Seed fisso per partizionamento e composizione dei benchmark
$\mathcal{S} = \{s_1, \dots, s_K\}$	Insieme dei K seed di addestramento
H_k	Matrice delle prestazioni ottenute con il seed s_k
$\hat{\mu}(M, D), \hat{\sigma}^2(M, D)$	Media e varianza delle prestazioni sui K seed
t, ν_{eff}	Statistica e gradi di libertà del test t di Welch
$\Gamma(M) = \mathcal{A}_m(M) $	Numero di famiglie d'attacco osservate in addestramento
$R_1(M)$	Regione decisionale associata alla classe malevola
$\text{supp } P(\mathbf{x} \mid Y = 1, A = a)$	Supporto della distribuzione della minaccia a

3.3.1 Incertezza Stocastica e Valutazione Multi-Seed

Le famiglie di classificatori adottate nel framework (Sezione 3.2.3) presentano componenti algoritmiche intrinsecamente stocastiche: il campionamento bootstrap e la selezione casuale del sottoinsieme di caratteristiche per nodo negli ensemble Bagging, così come le procedure di inizializzazione e di sotto-campionamento stocastico tipiche degli algoritmi di Gradient Boosting. Di conseguenza, la prestazione puntuale di un singolo modello addestrato con un'unica inizializzazione non costituisce, di per sé, una stima affidabile della sua reale capacità discriminativa: un risultato favorevole isolato potrebbe essere l'esito di una particolare configurazione stocastica favorevole, piuttosto che un'evidenza sistematica della superiorità del modello. Il framework metodologico

introduce pertanto un protocollo di valutazione *multi-seed*, volto a stimare non solo il valore atteso della prestazione, ma anche la sua dispersione, e a verificarne la significatività statistica rispetto al modello di riferimento.

Separazione tra Seed di Composizione del Dataset e Seed di Addestramento

Per isolare la stocasticità algoritmica dei classificatori da qualsivoglia variabilità indotta dalla composizione dei dati, il framework distingue rigorosamente due categorie di seed pseudo-casuali, aventi ruolo e ambito di applicazione disgiunti:

- **un seed deterministico s_0** , fissato una tantum e impiegato esclusivamente nelle procedure di split stratificato e di sintesi dei benchmark descritte nella Sezione 3.1.1. Tale seed determina univocamente le partizioni $\mathcal{D}_k^{(\text{train})}$, $\mathcal{D}_k^{(\text{test})}$ e la composizione di ciascun benchmark derivato, mantenendole identiche e invarianti per l'intero protocollo sperimentale;
- **un insieme di K seed indipendenti $S = \{s_1, s_2, \dots, s_K\}$** , impiegati esclusivamente nelle fasi di addestramento dei classificatori (inizializzazione degli stimatori, campionamento bootstrap, selezione casuale delle caratteristiche), con K inteso come parametro simbolico del framework teorico.




Figura 3.6: Diagramma di flusso del protocollo di isolamento e valutazione stocastica. La stabilità della partizione dei dati è forzata top-down dall'unico seed deterministico s_0 , delegando la totalità della varianza osservata tra le matrici H_k all'inizializzazione stocastica dettata dall'insieme dei seed S interni agli stimatori.

La netta separazione tra s_0 e S garantisce che tutti i modelli, per ciascuna replica k , operino esattamente sullo stesso insieme di dati di addestramento e di test: nessun seed di modello risulta favorito da una composizione del dataset a lui più congeniale, e l'intera variabilità osservata tra le K repliche è pertanto attribuibile univocamente alla stocasticità algoritmica del classificatore, e non a un artefatto della partizione dei dati.

Metriche di Valutazione e Aggregazione Multi-Seed

Per un generico modello M (istanza di una qualsiasi delle famiglie $\mathcal{M}_{\text{base}}, \mathcal{M}_S, \mathcal{M}_H^{(T)}, \mathcal{M}_{S,a}, \mathcal{M}_{H,T,a}$) addestrato con il seed $s_k \in \mathcal{S}$ e valutato su un benchmark di test D , siano TP_k, TN_k, FP_k, FN_k le cardinalità della matrice di confusione ottenute dal confronto tra $\hat{Y}$ e l'etichetta reale Y^{14} . Si definiscono la *True Positive Rate* (TPR, sensibilità) e la *True Negative Rate* (TNR, specificità) come:

$$\text{TPR}_k(M, D) = \frac{TP_k}{TP_k + FN_k}, \quad \text{TNR}_k(M, D) = \frac{TN_k}{TN_k + FP_k} \quad (3.31)$$

Per ciascun seed s_k , i valori $\text{TPR}_k(M, D)$ e $\text{TNR}_k(M, D)$ vengono organizzati in una matrice $H_k \in \mathbb{R}^{|\mathcal{M}| \times |\mathcal{B}|}$, con righe indicizzate dai modelli $M \in \mathcal{M}$ e colonne dai benchmark di test $D \in \mathcal{B}$ coinvolti nel protocollo di valutazione incrociata (Sezioni 3.2.1 e 3.2.2), corredata da una colonna aggiuntiva di media di riga:

$$\bar{H}_k(M) = \frac{1}{|\mathcal{B}|} \sum_{D \in \mathcal{B}} H_k(M, D) \quad (3.32)$$

L'impianto metodologico fin qui descritto culmina nella definizione della matrice H_k , che concretizza l'operazione di proiezione incrociata di *tutte* le architetture formulate (siano esse aggregati multiclasse o specialisti biclasse) sull'intera estensione dei domini di test disponibili. Come illustrato nella Tabella 3.8, lo spazio delle valutazioni si articola in una griglia strutturata che elimina ogni barriera valutativa tra le categorie di classificazione e quelle di benchmark, rendendo esplicita l'universalità dell'insieme di test $\mathcal{B}$.

Tabella 3.8: Rappresentazione concettuale della matrice di valutazione incrociata $H_k \in \mathbb{R}^{|\mathcal{M}| \times |\mathcal{B}|}$.

$\mathbf{H}_k \in \mathbb{R}^{ \mathcal{M} \times \mathcal{B} }$	$\mathcal{D}^{(\text{test})}$	$\mathcal{D}_a^{(\text{test})}$	$\mathcal{D}_{b \neq a}^{(\text{test})}$
	(Aggregati)	(Biclasse In-Domain)	(Biclasse Cross)
$\mathcal{M}_{\text{base}}$	✓	✓	✓
$\mathcal{M}_S$	✓	✓	✓
$\mathcal{M}_H^{(T)}$	✓	✓	✓
$\mathcal{M}_{S,a}$	✓	✓	✓
$\mathcal{M}_{H,T,a}$	✓	✓	✓

¹⁴Rispettivamente: veri positivi, veri negativi, falsi positivi e falsi negativi, secondo la convenzione per cui $Y = 1$ denota traffico malevolo.

La stima puntuale del valore atteso e della dispersione prestazionale per la coppia (M, D) , marginalizzata sulle K repliche stocastiche, è data dalla media e dalla varianza campionarie:

$$\hat{\mu}(M, D) = \frac{1}{K} \sum_{k=1}^K H_k(M, D), \quad \hat{\sigma}^2(M, D) = \frac{1}{K-1} \sum_{k=1}^K (H_k(M, D) - \hat{\mu}(M, D))^2 \quad (3.33)$$

La matrice aggregata $\hat{H} = [\hat{\mu}(M, D)]$, corredata dai corrispondenti valori di $\hat{\sigma}^2(M, D)$, costituisce la sintesi prestazionale multi-seed per ciascuna tipologia di modello, riducendo l'influenza di configurazioni stocastiche anomale sulla valutazione complessiva del framework.

A partire dalle medesime cardinalità TP_k, TN_k, FP_k, FN_k , si definiscono inoltre le metriche di *Precision* e di *F1-Score*, quest'ultima impiegata specificamente nel protocollo di verifica della significatività statistica formalizzato nella Sezione 3.3.1:

$$\text{Precision}_k(M, D) = \frac{TP_k}{TP_k + FP_k}, \quad \text{F1}_k(M, D) = \frac{2 \cdot \text{Precision}_k(M, D) \cdot \text{TPR}_k(M, D)}{\text{Precision}_k(M, D) + \text{TPR}_k(M, D)} \quad (3.34)$$

dove l'F1-Score, in quanto media armonica di Precision e Recall ($\equiv$ TPR), costituisce una metrica sintetica particolarmente indicata a penalizzare squilibri tra falsi positivi e falsi negativi, coerentemente con l'asimmetria di classe intrinseca ai benchmark del framework (Sezione 3.1.1).

Verifica di Significatività Statistica mediante Test di Welch

La sola stima di $\hat{\mu}$ e $\hat{\sigma}^2$ non è sufficiente a stabilire se lo scostamento prestazionale tra un modello M e il modello baseline M_{base} sia statisticamente rilevante o riconducibile alla naturale variabilità campionaria. Il framework adotta a tal fine il test t di Welch [28], nella sua formulazione per campioni indipendenti a varianza non necessariamente omogenea.

La letteratura sul confronto statistico di classificatori [29] sconsiglia, in generale, l'impiego di test parametrici quando il confronto avviene su un numero ridotto di dataset eterogenei, per i quali ciascun dataset fornisce un singolo valore appaiato e l'assunzione di normalità risulta difficilmente verificabile; in tali condizioni sono raccomandate alternative non parametriche (test dei ranghi con segno di Wilcoxon, test di Friedman). Lo scenario qui considerato è tuttavia strutturalmente distinto: ciascuna osservazione $\overline{\text{F1}}_k(M)$ non è un valore puntuale su un singolo dataset, bensì la media di riga dell'F1-Score, calcolata su $|\mathcal{B}|$ benchmark di test per un dato seed s_k . In virtù del Teorema del Limite Centrale, tale quantità aggregata tende a una distribuzione approssimativamente normale al

crescere di $|\mathcal{B}|$, indipendentemente dalla distribuzione delle singole osservazioni F1 per dataset, fornendo una base più solida per l'impiego di un test parametrico rispetto al caso di confronto diretto su valori singoli non aggregati. La formulazione di Welch, in particolare, è preferita alla variante omoschedastica dello Student's t -test poiché non assume l'uguaglianza delle varianze tra le distribuzioni per-seed del modello M e del baseline, condizione non garantita a priori tra famiglie di modelli strutturalmente eterogenee.

Per ciascun modello M (con esclusione del baseline stesso), sia $\overline{\text{F1}}_k(M) = \frac{1}{|\mathcal{B}|} \sum_{D \in \mathcal{B}} \text{F1}_k(M, D)$ la media di riga dell'F1-Score per il seed s_k , definita in analogia all'Equazione (3.32) a partire dalla metrica dell'Equazione (3.34). Siano $\{\overline{\text{F1}}_k(M)\}_{k=1}^K$ e $\{\overline{\text{F1}}_k(\mathcal{M}_{\text{base}})\}_{k=1}^K$ le rispettive sequenze di medie per seed per il modello M e per il baseline. Definita l'ipotesi nulla $H_0 : \mu_M = \mu_{\text{base}}$, la statistica del test è espressa come:

$$t = \frac{\bar{x}_M - \bar{x}_{\text{base}}}{\sqrt{\frac{s_M^2}{K} + \frac{s_{\text{base}}^2}{K}}} \quad (3.35)$$

dove $\bar{x}_M$, $\bar{x}_{\text{base}}$ e s_M^2 , s_{base}^2 denotano rispettivamente la media e la varianza campionaria dell'F1-Score calcolate sulle K osservazioni per-seed di M e di $\mathcal{M}_{\text{base}}$. I gradi di libertà effettivi ν_{eff} sono stimati mediante l'approssimazione di Welch–Satterthwaite:

$$\nu_{\text{eff}} = \frac{\left(\frac{s_M^2}{K} + \frac{s_{\text{base}}^2}{K} \right)^2}{\frac{(s_M^2/K)^2}{K-1} + \frac{(s_{\text{base}}^2/K)^2}{K-1}} \quad (3.36)$$

Il valore p risultante viene confrontato con una soglia di significatività α : qualora $p < \alpha$, l'ipotesi nulla viene rigettata, e lo scostamento prestazionale tra il modello M e il baseline $\mathcal{M}_{\text{base}}$ è considerato statisticamente significativo e non attribuibile alla sola variabilità stocastica intrinseca degli stimatori. Il confronto viene condotto in modo puntuale per ciascun modello rispetto al baseline, coerentemente con il ruolo di $\mathcal{M}_{\text{base}}$ quale ancora di prestazione di riferimento stabilita nella Sezione 3.2.1.

3.3.2 Granularità della Risposta: Formulazione Binaria vs. Multiclasse

Sebbene lo spazio di uscita del framework rimanga rigorosamente binario ($\mathcal{Y} = \{0, 1\}$, cfr. Sezione 3.1.1)¹⁵, le due famiglie di classificatori sin qui formalizzate differiscono strutturalmente per il numero di famiglie d'attacco rappresentate simultaneamente all'interno della medesima frontiera di decisione. Si definisce pertanto un indice di *granularità di rappresentazione* $\Gamma(M)$, pari alla cardinalità dell'insieme delle famiglie d'attacco incluse nella partizione di addestramento di un modello M :

$$\Gamma(M) = |\mathcal{A}_m(M)|, \quad \mathcal{A}_m(M) \subseteq \mathcal{A} \quad (3.37)$$

dove $\mathcal{A}_m(M)$ denota l'insieme delle famiglie d'attacco osservate in addestramento dal modello M . Per i modelli aggregati (Sezione 3.2.1) si ha $\Gamma(\mathcal{M}_S) = |\mathcal{A}_S|$ e $\Gamma(\mathcal{M}_H^{(T)}) = |\mathcal{A}_T|$, ossia l'intera tassonomia disponibile nel rispettivo dominio; per i modelli biclasse (Sezione 3.2.2) si ha invece $\Gamma(\mathcal{M}_{S,a}) = \Gamma(\mathcal{M}_{H,T,a}) = 1$ per costruzione. In questo senso, i modelli aggregati costituiscono l'estremo a **granularità grossolana** ("*multiclasse*", in quanto la loro frontiera deve generalizzare simultaneamente su una molteplicità eterogenea di segnature d'attacco), mentre i modelli biclasse costituiscono l'estremo a **granularità fine** ("*biclasse*" propriamente detto, con una frontiera dedicata alla singola famiglia).

Regione Decisionale e Copertura del Supporto Malevolo

Sia $R_1(M) = \{\mathbf{x} \in \mathcal{X} : f_{\theta^*}(\mathbf{x}) \geq \tau\}$ la regione decisionale positiva associata al modello M , secondo la regola già formalizzata nell'Equazione (3.9). Per un modello aggregato, tale regione deve necessariamente coprire l'unione dei supporti delle distribuzioni condizionate di ciascuna famiglia d'attacco osservata:

$$R_1(\mathcal{M}_S) \supseteq \bigcup_{a \in \mathcal{A}_S} \text{supp } P_S(\mathbf{x} \mid Y = 1, A = a) \quad (3.38)$$

¹⁵Nell'ambito della presente trattazione, l'uso dei termini "multiclasse" e "biclasse" non si riferisce alla cardinalità dello spazio di codifica delle uscite $\mathcal{Y}$, che rimane sempre scalare e binario, bensì alla granularità semantica delle componenti d'attacco aggregate all'interno della medesima etichetta positiva $Y = 1$.

mentre per un modello biclasse la regione positiva è calibrata in modo mirato sul supporto di un'unica sotto-distribuzione¹⁶:

$$R_1(\mathcal{M}_{S,a}) \supseteq \text{supp } P_S(\mathbf{x} \mid Y = 1, A = a) \quad (3.39)$$

Tale distinzione strutturale ha una diretta implicazione geometrica, coerente con il partizionamento ricorsivo $\{R_m\}_{m=1}^M$ formalizzato nella Sezione 3.2.3: al crescere di $\Gamma(M)$, la regione $R_1(M)$ deve estendersi su un volume dello spazio $\mathcal{X}$ tendenzialmente più ampio ed eterogeneo, risultante dalla composizione delle regioni foglia associate a più sotto-distribuzioni distinte; al diminuire di $\Gamma(M)$ (limite $\Gamma = 1$), $R_1(M)$ si concentra invece attorno a un unico manifold di supporto, con margine decisionale calibrato sulla sola distribuzione della famiglia a .

Compromesso tra Rigidità Specialistica e Copertura Generalista

La calibrazione di $R_1(M)$ su un manifold ristretto ($\Gamma(M) = 1$) produce un confine decisionale a elevata specificità: il classificatore biclasse è, per costruzione, ottimizzato per discriminare la sola famiglia a dal traffico nominale, senza compromessi indotti dalla necessità di generalizzare su signature eterogenee. Tale specificità comporta tuttavia una maggiore *rigidità* del confine sotto *domain shift*: qualora il vettore osservato nel dominio di destinazione risulti sistematicamente perturbato secondo il modello $\tilde{\mathbf{x}} = \mathbf{x} + \boldsymbol{\eta}$ già discusso in Sezione 3.2.3, uno spostamento del manifold malevolo oltre il margine appreso in fase di addestramento non è compensato da alcuna informazione di supporto proveniente da altre famiglie d'attacco, risultando in un decadimento prestazionale puntuale e localizzato.

Al contrario, un modello aggregato, essendo vincolato a costruire una regione $R_1(M)$ che copra congiuntamente più sotto-distribuzioni (Equazione (3.38)), sviluppa margini decisionali strutturalmente più ampi e meno specifici per la singola famiglia d'attacco. Tale maggiore ampiezza può conferire una tolleranza intrinseca a perturbazioni locali di una singola sotto-distribuzione, a scapito però della purezza discriminativa per classe¹⁷.

¹⁶In un contesto d'apprendimento induttivo reale, la regione decisionale $R_1(\mathcal{M}_{S,a})$ racchiude il supporto effettivo $\text{supp } P_S(\mathbf{x} \mid Y = 1, A = a)$ estendendosi oltre di esso per un margine di generalizzazione $\epsilon > 0$, indotto dalla struttura dell'iperpiano o dagli split degli alberi decisionali.

¹⁷Questo compromesso è la controparte teorica dei fenomeni empirici già anticipati nel framework: il *class shadowing* (Sezione 3.2.1), per cui un'elevata accuratezza aggregata può mascherare un decadimento su famiglie




Figura 3.7: Rappresentazione bidimensionale nello spazio delle caratteristiche $\mathcal{X}$ dell’impatto del *domain shift* (vettore di traslazione η) a seconda della granularità del modello. A sinistra, la maggiore ampiezza spaziale del modello aggregato garantisce tolleranza generalista; a destra, l’ottimizzazione specialistica sul singolo supporto malevolo determina rigidità sotto perturbazione.

Il Modello Baseline come Punto di Riferimento Intermedio

Il modello $\mathcal{M}_{\text{base}}$ (Sezione 3.2.1) occupa, rispetto all’indice Γ , una posizione concettualmente intermedia tra i due estremi. La sua regione decisionale eredita la copertura ad ampio spettro propria dei modelli aggregati, essendo $\mathcal{A}_S \subseteq \mathcal{A}_m(\mathcal{M}_{\text{base}})$, ma viene incrementalmente perturbata da una conoscenza mirata e altamente sparsa del dominio target ($\Delta\mathcal{D}_T^{(\text{train})}$, Equazione (3.11)), la cui esiguità cardinale ($|\Delta\mathcal{D}_T^{(\text{train})}| \ll |\mathcal{D}_S^{(\text{train})}|$) ne impedisce una piena riqualificazione come copertura multiclasse del dominio di destinazione. $\mathcal{M}_{\text{base}}$ costituisce pertanto l’ancora di riferimento rispetto alla quale entrambi gli estremi della granularità — l’ampia copertura generalista dei modelli aggregati $\mathcal{M}_S, \mathcal{M}_H^{(T)}$ e l’elevata specificità dei modelli biclasse $\mathcal{M}_{S,a}, \mathcal{M}_{H,T,a}$ — vengono confrontati, secondo il protocollo di verifica statistica formalizzato in Sezione 3.3.1, al fine di determinare quale livello di granularità offra il compromesso più favorevole tra specificità discriminativa e robustezza al *domain shift*.

specifiche, e la polarizzazione dello spazio decisionale osservabile in fase di *cross-evaluation* per i modelli biclasse (Sezione 3.2.2).

3.4 Framework Analitico, Spiegabilità e Significatività Statistica

La presente sezione definisce il framework analitico, diagnostico e statistico adottato per caratterizzare lo scostamento distributivo (*domain shift*), decodificare le logiche decisionali dei modelli e valutare la significatività delle variazioni prestazionali tra domini eterogenei. L'impianto metodologico integra tecniche di riduzione dimensionale, stima non parametrica di densità e attribuzione dell'importanza delle caratteristiche fondata sulla teoria dei giochi cooperativi, affiancandole a un formalismo rigoroso per la gestione delle soglie e la verifica di ipotesi statistiche.

Per agevolare la consultazione della trattazione, i simboli matematici, i costrutti diagnostici e le metriche prestazionali introdotti in questa sezione sono riepilogati nella Tabella 3.9.

Tabella 3.9: Sintesi della notazione relativa al framework analitico, all'interpretabilità e alla valutazione statistica.

Simbolo	Significato
$\mathbf{Z}_D$	Matrice del benchmark D standardizzata sul sorgente
$\Sigma_D, \mathbf{W}_D$	Matrice di covarianza e proiezione PCA
$\hat{f}_y(z), h_{\text{KDE}}$	Densità KDE della classe y e relativa <i>bandwidth</i>
$\phi_j(\mathbf{x})$	Contributo SHAP della <i>feature</i> j alla predizione
$I_j^{(D)}, C_j$	Importanza SHAP media e frequenza nella <i>top-3</i>
$TP(\tau), FP(\tau), TN(\tau), FN(\tau)$	Conteggi della matrice di confusione alla soglia τ
AUC_{ROC}, AUC_{PR}	Aree sottese alle curve ROC e Precision–Recall
ΔF_1	Variazione di F_1 tra dominio sorgente e target

3.4.1 Caratterizzazione Densometrica e Proiezioni Latenti

L'analisi dello scostamento distributivo (*domain shift*) e la valutazione della separabilità geometrica tra traffico nominale e traffico malevolo richiedono l'impiego di tecniche di riduzione dimensionale e stima di densità. Come anticipato nella Sezione 3.1.2, mentre l'architettura di classificazione basata su modelli ad albero gode dell'invarianza alle trasformazioni monotoniche e prescinde dalla

scala dei dati, gli strumenti diagnostici e visivi (PCA e KDE) sono sensibili alla grandezza numerica delle variabili.

Prima dell'estrazione delle proiezioni e della stima densometrica, viene applicata una normalizzazione dedicata a ciascun benchmark $D \in \mathcal{B}$, secondo l'insieme dei benchmark di test già introdotto nella Sezione 3.3.1. Tale trasformazione è ancorata unicamente alle statistiche del dominio sorgente $\mathcal{D}_S$ e rimane rigorosamente disaccoppiata dallo stadio di addestramento dei modelli.

Standardizzazione Diagnostica Dipendente dal Sorgente

Per evitare fenomeni di contaminazione informativa (*data leakage*), derivati dall'estrazione di statistiche da domini target incogniti, e per preservare la reale ampiezza del *domain shift*, i dati di ciascun benchmark $D \in \mathcal{B}$ vengono standardizzati **utilizzando esclusivamente la media μ_S e la deviazione standard σ_S calcolate sul benchmark sorgente** di riferimento S .

Sia $\mathbf{X}_D \in \mathbb{R}^{N_D \times d}$ la matrice dei dati grezzi del generico benchmark D . Il generico elemento della matrice trasformata $\mathbf{Z}_D \in \mathbb{R}^{N_D \times d}$ è definito come:

$$\mathbf{Z}_{D,ij} = \frac{\mathbf{X}_{D,ij} - \mu_{S,j}}{\sigma_{S,j} + \epsilon} \quad (3.40)$$

dove $\mu_{S,j}$ e $\sigma_{S,j}$ rappresentano la media e la deviazione standard campionarie della j -esima caratteristica stimata sul set sorgente S , e $\epsilon > 0$ è una costante infinitesima introdotta a scopo di stabilità numerica, per prevenire divisioni per valori prossimi a zero in presenza di caratteristiche a varianza sorgente quasi nulla (es. indicatori binari fortemente sbilanciati).

L'ancoraggio a (μ_S, σ_S) , anziché a statistiche ricalcolate localmente su ciascun benchmark D , garantisce che eventuali traslazioni di media o contrazioni di varianza presenti nel benchmark D non vengano annullate artificialmente: una standardizzazione locale ricentrerebbe infatti ogni benchmark sulla propria origine, occultando esattamente lo scostamento distributivo che l'analisi si propone di rendere visibile. Questo ancoraggio è una scelta di riferimento per la sola finalità diagnostico-visiva e non implica alcuna dipendenza dalla scala da parte del classificatore: come dimostrato nella Sezione 3.1.2, la decisione dei modelli ad albero è invariante rispetto a qualsiasi trasformazione monotona crescente, ancorata o meno al dominio sorgente. L'ancoraggio a (μ_S, σ_S) risponde dunque esclusivamente all'esigenza di disporre di un sistema di riferimento fisso e interpretabile per l'ispezione visiva, non a un requisito del modello di classificazione.

Proiezioni Ortogonali e Relatività dello Spazio Latente (PCA)

Per ispezionare visivamente le relazioni topologiche del traffico di rete, lo spazio delle caratteristiche viene mappato in un sottospazio latente a due dimensioni tramite Analisi delle Componenti Principali (PCA) [30], [31].

Necessità tecnica dello scaling per la PCA La PCA si basa sulla decomposizione spettrale della matrice di covarianza Σ_D , massimizzando la varianza lungo gli assi ortogonali. In assenza della trasformazione espressa nell'Equazione (3.40), l'impiego diretto di caratteristiche in scala grezza eterogenea (es. volumi in byte con varianze dell'ordine di 10^6 affiancati a *ratio* adimensionali compresi in $[0, 1]$) causerebbe una dominanza artificiale della matrice di covarianza da parte delle variabili a magnitudo numerica maggiore. La prima componente principale si schiaccerebbe unicamente sulle variabili a scala più ampia, indipendentemente dal loro effettivo valore informativo o discriminante.

Sulla matrice standardizzata $\mathbf{Z}_D$, la matrice di covarianza campionaria Σ_D è formulata come:

$$\Sigma_D = \frac{1}{N_D - 1} \mathbf{Z}_D^T \mathbf{Z}_D \quad (3.41)$$

La matrice di proiezione $\mathbf{W}_D \in \mathbb{R}^{d \times 2}$ è composta dagli autovettori ortonormali associati ai due principali autovalori di Σ_D .

La standardizzazione preventiva isola una proprietà rilevante del framework: sebbene i campioni della classe lecita ($Y = 0$) derivino dalla medesima distribuzione stazionaria di base in tutti i benchmark, la loro proiezione nel piano latente muta geometricamente al variare del benchmark D . Poiché Σ_D risente della varianza congiunta dell'intero set di dati, l'accoppiamento con vettori malevoli ($Y = 1$) eterogenei riorienta gli assi di massima varianza. L'eliminazione degli artefatti di scala mediante (μ_S, σ_S) assicura che tali rotazioni non siano attribuibili a discrepanze puramente dimensionali, ma riflettano la specifica struttura dell'attacco contestuale e il relativo *domain shift*. Va precisato che, trattandosi di una tecnica non supervisionata, la PCA massimizza la varianza totale dei dati senza impiego esplicito dell'etichetta Y : l'osservazione secondo cui l'asse di massima varianza tende a riflettere la separazione tra le classi è pertanto un comportamento empiricamente frequente, ma non una proprietà garantita in generale, a differenza di tecniche supervisionate come l'Analisi Discriminante Lineare (LDA).

Stima di Densità (KDE) su Sub-spazio Selettivo

Per quantificare la sovrapposizione distributiva e l'incertezza decisionale tra le classi, l'analisi si avvale della *Kernel Density Estimation* (KDE) univariata, i cui fondamenti teorici risalgono ai lavori di Rosenblatt [32] e Parzen [33]. Per garantire l'interpretabilità geometrica e superare la sparsità dei dati in alta dimensione, la KDE viene confinata alle tre caratteristiche di maggiore rilevanza empirica individuate tramite l'aggregazione dei valori di Shapley (SHAP, Sezione 3.4.2).

Motivazione metodologica dello scaling per la KDE A differenza della PCA, dal punto di vista strettamente matematico la forma della stima di densità univariata è equivariante alle trasformazioni lineari (la geometria della curva non si distorce, ma trasla e si riscalda coerentemente). Tuttavia, l'applicazione della standardizzazione Z-score dipendente dal sorgente risulta indispensabile per tre ragioni pratiche e metodologiche:

1. **Preservazione visiva del Domain Shift:** l'utilizzo delle metriche del sorgente $(\mu_{S,j}, \sigma_{S,j})$ fa sì che se una caratteristica nel benchmark D subisce una traslazione sistematica della media, la curva di densità KDE risulti fisicamente traslata rispetto all'origine $z = 0$, rendendo immediata l'ispezione visiva del *domain shift*;
2. **Comparabilità grafica cross-feature:** le tre *feature* selezionate mediante SHAP, originariamente espresse in unità di misura disomogenee (es. microsecondi vs. byte/s), vengono mappate sullo stesso asse adimensionale espresso in deviazioni standard dal sorgente, consentendone l'affiancamento visivo su scale omogenee;
3. **Calibrazione stabile della Bandwidth (h_{KDE}):** la condivisione dello spazio adimensionale ($z \sim \mathcal{N}(0, 1)$ sul dominio sorgente) stabilizza l'ottimizzazione della larghezza di banda del kernel h_{KDE} , prevenendo fenomeni di *undersmoothing* (una banda eccessivamente stretta, che produce una curva frastagliata e sovra-adattata al singolo campione osservato) o di *oversmoothing* selettivo (una banda eccessivamente ampia, che appiattisce dettagli distributivi rilevanti) tra variabili a diversa varianza grezza.

Sia $z \in \mathbb{R}$ la variabile standardizzata derivata tramite l'Equazione (3.40) per una singola caratteristica del sottoinsieme SHAP. Coerentemente con la natura dicotomica delle decisioni dei

sistemi NIDS, i dati vengono raggruppati secondo l'etichetta binaria $Y \in \mathcal{Y} = \{0, 1\}$ (traffico lecito vs. malevolo). La stima marginale di densità continua $\hat{f}_y(z)$ per la classe $Y = y$ calcolata su N_y campioni è definita da:

$$\hat{f}_y(z) = \frac{1}{N_y h_{\text{KDE}}} \sum_{i=1}^{N_y} \kappa\left(\frac{z - z_{i,y}}{h_{\text{KDE}}}\right) \quad (3.42)$$

dove h_{KDE} è il parametro di lisciamento (*bandwidth*), da non confondersi con la trasformazione monotonica h_j della Sezione 3.2.3, e $\kappa(\cdot)$ è la funzione kernel, per la quale si adotta la forma gaussiana standard¹⁸:

$$\kappa(u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{u^2}{2}\right) \quad (3.43)$$

Compensazione dello Squilibrio di Classe tramite Scala Logaritmica

Per contrastare lo schiacciamento visivo della classe minoritaria derivante dal forte sbilanciamento cardinale ($P(Y = 0) \gg P(Y = 1)$ o viceversa nei vari benchmark), i valori di densità stimata $\hat{f}_y(z)$ vengono proiettati su scala logaritmica in base 10:

$$\hat{f}_{y,\log}(z) = \log_{10}\left(\hat{f}_y(z) + \epsilon\right) \quad (3.44)$$

dove $\epsilon > 0$ è una costante infinitesima di stabilizzazione numerica. La rappresentazione logaritmica permette di ispezionare visivamente le code delle distribuzioni e le micro-aree di sovrapposizione ad alta incertezza, fornendo supporto analitico alla comprensione dei falsi positivi al variare della soglia decisionale τ .

Il ruolo e l'impatto della standardizzazione dipendente dal sorgente sulle diverse componenti diagnostiche del framework sono sintetizzati nella Tabella 3.10.

¹⁸Il simbolo $\kappa(\cdot)$, anziché la più comune notazione $K(\cdot)$, è adottato per evitare ambiguità con la cardinalità K dell'insieme dei seed stocastici $\mathcal{S}$ introdotta nella Sezione 3.3.1.

Tabella 3.10: Sintesi del ruolo e dell’impatto della standardizzazione dipendente dal sorgente (μ_S, σ_S) sulle componenti diagnostiche del framework.

Strumento	Natura del Requisito	Impatto Tecnico e Motivazione Metodologica
Classificatori (Tree-Based)	Nessuno (Nessuna Trasformazione)	Invarianza Monotonica: gli algoritmi basati su albero operano su ordinamenti relativi dei dati. Nessun impatto sulle metriche di accuratezza.
PCA	Matematicamente Indispensabile	Prevenzione della Dominanza delle Scale: la matrice di covarianza Σ_D richiede unità adimensionali; in caso contrario, le componenti principali catturano solo la scala numerica grezza più ampia.
KDE	Metodologico e Visivo	Preservazione del Shift e Omogeneità: non altera la forma intrinseca della stima 1D, ma rende visibile lo spostamento di media dal sorgente $z = 0$, rende i grafici affiancati comparabili e stabilizza la <i>bandwidth</i> h_{KDE} .

3.4.2 Spiegabilità e Attribuzione delle Feature

Allo scopo di decodificare le logiche decisionali dei classificatori *black-box* e isolare le caratteristiche dello spazio condiviso $\mathcal{X}$ che governano la stima della probabilità a posteriori al variare dei domini, il framework integra un impianto di interpretabilità basato su SHAP (*SHapley Additive exPlanations*) [34]. Tale approccio, fondato sui rigorosi principi della teoria dei giochi cooperativi [35], consente di quantificare analiticamente il contributo marginale esatto di ciascuna variabile vettoriale alla stima predittiva locale.

Formulazione Teorica dei Valori di Shapley e Proprietà Assiomatiche

Nella teoria dei giochi, il valore di Shapley definisce un metodo per distribuire equamente un "guadagno" totale tra un insieme di giocatori cooperanti. Nel contesto dell’apprendimento supervisionato formalizzato dal framework, il "gioco" corrisponde alla funzione decisionale parametrica $f_{\theta^*}(\mathbf{x})$, e i "giocatori" coincidono con le caratteristiche in ingresso.

Sia $\mathcal{F}$ l'insieme totale delle caratteristiche a disposizione del modello (con $|\mathcal{F}| = d$) e $C \subseteq \mathcal{F}$ un generico sottoinsieme (coalizione) di esse. Definita $v(C)$ la funzione di valore che esprime l'output atteso del modello condizionato al solo sottoinsieme C ¹⁹, il valore di Shapley $\phi_j(\mathbf{x})$ per la j -esima caratteristica del singolo vettore $\mathbf{x} \in \mathcal{X}$ è calcolato come:

$$\phi_j(\mathbf{x}) = \sum_{C \subseteq \mathcal{F} \setminus \{j\}} \frac{|C|!(|\mathcal{F}| - |C| - 1)!}{|\mathcal{F}|!} [v(C \cup \{j\}) - v(C)] \quad (3.45)$$

La robustezza di SHAP e la sua superiorità metodologica rispetto a metriche di impurità alternative risiedono nel soddisfacimento di quattro assiomi matematici fondamentali²⁰:

1. **Efficienza Locale (Additività):** la somma dei valori SHAP di tutte le caratteristiche eguaglia la differenza tra la predizione per lo specifico vettore $\mathbf{x}$ e la predizione media del modello (baseline). Ovvero: $f_{\theta^*}(\mathbf{x}) = \phi_0 + \sum_{j=1}^d \phi_j(\mathbf{x})$.
2. **Simmetria:** se due caratteristiche i e j apportano il medesimo contributo marginale a ogni possibile sottoinsieme C , i loro valori SHAP risultano algebricamente identici ($\phi_i = \phi_j$).
3. **Giocatore Nullo (Missingness):** una caratteristica che non altera mai la predizione, indipendentemente dal sottoinsieme di attributi a cui viene aggiunta, possiede un valore SHAP rigorosamente pari a zero.
4. **Coerenza:** se un modello viene modificato in modo tale che il contributo marginale di una caratteristica aumenti (o rimanga invariato), il relativo valore SHAP non può diminuire.

TreeSHAP e Ottimizzazione Algoritmica

Dal punto di vista algoritmico, l'estrazione dei valori ϕ_j è condotta tramite un'ottimizzazione basata sulla struttura interna degli stimatori. Considerata l'architettura dei classificatori impiegati,

¹⁹In un contesto applicativo di apprendimento automatico, tale funzione coincide con il valore atteso condizionato della stima parametrica, ovvero $v(C) = \mathbb{E}[f_{\theta^*}(\mathbf{x}) \mid \mathbf{x}_C]$.

²⁰L'aderenza a questi assiomi garantisce che l'importanza delle *feature* sia equa e non soggetta a paradossi di attribuzione tipici delle metriche puramente empiriche.

basati sul partizionamento ricorsivo dello spazio (e.g., *Random Forest*, *Histogram-based Gradient Boosting*), la metodologia sfrutta l’algoritmo *TreeSHAP* [36]²¹.

Per garantire la stabilità statistica delle stime limitando contestualmente l’overhead computazionale, la spiegazione locale viene calcolata su un sottoinsieme $\mathcal{D}_{\text{sample}}^{(\text{test})} \subset \mathcal{D}^{(\text{test})}$, estratto mediante campionamento stratificato. Tale campionamento preserva inalterato il vincolo di proporzionamento parametrico ρ originario tra il traffico nominale ($Y = 0$) e il traffico malevolo ($Y = 1$).

L’output dell’operazione consiste in matrici ad alta dimensionalità contenenti i valori ϕ_j . Limitando l’analisi al dominio di classificazione binario e alla classe malevola ($Y = 1$), tali valori esprimono l’impatto sul margine non normalizzato del modello (es. *log-odds*) e vengono resi interpretabili attraverso proiezioni a dispersione (*summary dot plot*). In tali costrutti visivi, la posizione sull’asse orizzontale quantifica il valore SHAP (intensità e direzione dell’impatto decisionale), mentre lo spettro cromatico codifica il valore quantitativo grezzo della caratteristica, consentendo di individuare relazioni dirette o inverse tra le metriche trasmissive e l’etichetta di intrusione.

Aggregazione Trasversale e Selezione per l’Analisi Densometrica

I risultati prodotti da SHAP a livello locale per ciascuna configurazione di benchmark sono stati impiegati per alimentare l’indagine densometrica trasversale descritta nella Sezione 3.4.1. A tal fine, è stata definita una metrica di aggregazione progettata per estrarre le tre dimensioni dello spazio $\mathcal{X}$ globalmente più influenti.

Per ogni generico benchmark di test $D \in \mathcal{B}$, le caratteristiche vengono inizialmente ordinate in senso decrescente in base alla loro importanza media assoluta $I_j^{(D)}$:

$$I_j^{(D)} = \frac{1}{N} \sum_{i=1}^N \left| \phi_j(\mathbf{x}_i^{(D)}) \right| \quad (3.46)$$

dove $N = |\mathcal{D}_{\text{sample}}^{(\text{test})}|$ rappresenta la cardinalità del sottoinsieme campionato estratto in precedenza, e non l’intero dataset a disposizione.

Sia $\mathcal{T}_D \subset \mathcal{F}$ l’insieme contenente le prime tre caratteristiche classificate nel benchmark D . Per identificare i descrittori maggiormente resilienti e discriminanti ai confini tra domini $\mathcal{D}_S$ e $\mathcal{D}_T$, si

²¹*TreeSHAP* [36] abbatte la complessità computazionale del calcolo esatto dei valori di Shapley da esponenziale $O(2^{|\mathcal{F}|})$ a polinomiale $O(TLD^2)$, dove T è il numero di alberi dell’ensemble, L il numero massimo di foglie e D la profondità massima.

definisce un contatore di frequenza globale C_j :

$$C_j = \sum_{D \in \mathcal{B}} \mathbb{I}(j \in \mathcal{T}_D) \quad (3.47)$$

dove $\mathbb{I}(\cdot)$ è la funzione indicatrice che assume valore 1 se la caratteristica j figura nella *top-3* dello scenario D , e 0 altrimenti. Le tre dimensioni vettoriali associate ai valori massimi di C_j al termine di tutte le combinazioni di addestramento e inferenza costituiscono il nucleo stabile informativo utilizzato per tracciare le curve KDE precedentemente illustrate. Questo processo di selezione garantisce che la valutazione del *domain shift* si concentri unicamente sulle proiezioni spaziali che i modelli considerano universalmente più critiche per l'isolamento delle anomalie.

3.4.3 Metriche, Soglia e Significatività dei Confronti

Per valutare analiticamente le prestazioni dei modelli di classificazione formalizzati nella sezione precedente e quantificare l'impatto del *domain shift*, si definisce un framework di valutazione fondato sulla teoria della decisione statistica. In particolare, si distingue la valutazione puntuale delle prestazioni, riferita a una specifica soglia decisionale, dall'analisi del comportamento discriminativo del classificatore al variare della soglia di decisione.

Formalizzazione della Matrice di Confusione

Richiamando la regola di decisione parametrica introdotta nella Sezione 3.2.1, la classe predetta $\hat{y}_i(\tau)$ consente di definire le cardinalità della matrice di confusione, espresse come funzioni della soglia decisionale τ :

$$TP(\tau) = \sum_{i=1}^N \mathbb{I}(y_i = 1 \wedge \hat{y}_i(\tau) = 1) \quad (3.48)$$

$$FP(\tau) = \sum_{i=1}^N \mathbb{I}(y_i = 0 \wedge \hat{y}_i(\tau) = 1) \quad (3.49)$$

$$TN(\tau) = \sum_{i=1}^N \mathbb{I}(y_i = 0 \wedge \hat{y}_i(\tau) = 0) \quad (3.50)$$

$$FN(\tau) = \sum_{i=1}^N \mathbb{I}(y_i = 1 \wedge \hat{y}_i(\tau) = 0) \quad (3.51)$$

Le quattro quantità rappresentano rispettivamente il numero di veri positivi, falsi positivi, veri negativi e falsi negativi prodotti dal classificatore per una determinata soglia decisionale.

Tabella 3.11: Struttura della Matrice di Confusione parametrizzata rispetto alla soglia τ .

Classe Predetta ($\hat{y}(\tau)$) × Classe Reale (y)	Positivo ($y = 1$)	Negativo ($y = 0$)
Positivo ($\hat{y} = 1$)	True Positive ($TP(\tau)$)	False Positive ($FP(\tau)$)
Negativo ($\hat{y} = 0$)	False Negative ($FN(\tau)$)	True Negative ($TN(\tau)$)




Figura 3.8: Mappatura della probabilità a posteriori $f(\mathbf{x})$ sulla regola decisionale binaria $\hat{y}(\tau)$ in funzione della soglia τ .

Formalizzazione delle Metriche Derivate

Per rendere la valutazione indipendente dalla numerosità del campione di test, si introducono i principali tassi relativi derivati dalla matrice di confusione [37]:

$$TPR(\tau) = \frac{TP(\tau)}{TP(\tau) + FN(\tau)}, \quad FPR(\tau) = \frac{FP(\tau)}{FP(\tau) + TN(\tau)} \quad (3.52)$$

cui corrispondono i rispettivi complementari

$$\begin{aligned} FNR(\tau) &= 1 - TPR(\tau) & TNR(\tau) &= 1 - FPR(\tau) \\ &= \frac{FN(\tau)}{TP(\tau) + FN(\tau)}, & &= \frac{TN(\tau)}{TN(\tau) + FP(\tau)}. \end{aligned} \quad (3.53)$$

L'affidabilità delle segnalazioni generate dal classificatore è invece misurata dalla *Precision*:

$$Precision(\tau) = \frac{TP(\tau)}{TP(\tau) + FP(\tau)} \quad (3.54)$$

Per sintetizzare il compromesso tra capacità di rilevamento degli attacchi e contenimento dei falsi allarmi si utilizza l'*F1-score*, definito come media armonica tra Precision e Recall²²:

$$F_1(\tau) = 2 \cdot \frac{Precision(\tau) \cdot TPR(\tau)}{Precision(\tau) + TPR(\tau)} \quad (3.55)$$

Infine, l'*Accuracy* rappresenta la proporzione complessiva di classificazioni corrette:

$$Accuracy(\tau) = \frac{TP(\tau) + TN(\tau)}{N} \quad (3.56)$$

Tale indicatore assume tuttavia un ruolo secondario nei problemi di intrusion detection, poiché non risulta sufficientemente informativo in presenza di distribuzioni fortemente sbilanciate tra traffico nominale e traffico malevolo.

Dinamica della Soglia e Analisi Grafica (ROC e PR AUC)

La valutazione puntuale delle metriche presuppone la scelta di uno specifico valore della soglia decisionale (ad esempio $\tau = 0.5$). Una caratterizzazione più completa del comportamento discriminativo del classificatore richiede invece l'analisi dell'intero intervallo di valori della soglia, $\tau \in [0, 1]$.

A tale scopo si impiegano le curve *Receiver Operating Characteristic* (ROC) e *Precision-Recall* (PR), sintetizzate mediante l'area sottesa alla rispettiva curva (*Area Under the Curve*, AUC):

$$AUC_{ROC} = \int_0^1 TPR d(FPR), \quad AUC_{PR} = \int_0^1 Precision d(TPR) \quad (3.57)$$

²²Nei sistemi NIDS la media armonica è preferita alla media aritmetica poiché penalizza maggiormente modelli caratterizzati da un forte sbilanciamento tra sensibilità agli attacchi e precisione delle segnalazioni.




Figura 3.9: Rappresentazione schematica dell'Area Sottesa alla Curva (AUC) per le analisi grafiche ROC (a) e Precision-Recall (b).

L'indice AUC_{ROC} fornisce una misura della capacità discriminativa complessiva del classificatore, mentre AUC_{PR} risulta particolarmente indicato nei sistemi NIDS, dove la forte prevalenza del traffico legittimo rende più significativa la valutazione del compromesso tra Precision e Recall [38].

Degrado Prestazionale e Significatività Statistica (Welch's t-test)

Il trasferimento di un modello tra domini caratterizzati da differenti distribuzioni marginali delle caratteristiche $P(\mathbf{x})$ (*covariate shift*) può determinare una degradazione delle prestazioni di classificazione [7]. Tale variazione dell'efficacia discriminativa di un modello M , valutato sul dominio sorgente $\mathcal{D}_S$ e sul dominio target $\mathcal{D}_T$, può essere espressa come

$$\Delta F_1 = F_1(M, \mathcal{D}_S) - F_1(M, \mathcal{D}_T). \quad (3.58)$$

Per valutare la significatività statistica delle differenze prestazionali tra modelli differenti, oppure tra un modello e una baseline di riferimento, si adotta il test t di Welch, appropriato nel caso di campioni indipendenti con varianze non necessariamente uguali. Date due distribuzioni campionarie della metrica di interesse, caratterizzate da medie $\bar{x}_1, \bar{x}_2$, varianze s_1^2, s_2^2 e numerosità n_1, n_2 , la statistica del test è definita da

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}. \quad (3.59)$$

I corrispondenti gradi di libertà effettivi sono stimati mediante l'approssimazione di Welch–Satterthwaite:

$$\nu \approx \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{(s_1^2/n_1)^2}{n_1-1} + \frac{(s_2^2/n_2)^2}{n_2-1}}. \quad (3.60)$$

L'ipotesi nulla di uguaglianza delle medie,

$$H_0 : \mu_1 = \mu_2,$$

viene respinta qualora il valore p associato alla statistica t risulti inferiore al livello di significatività prefissato α (tipicamente $\alpha = 0.05$), indicando che la differenza prestazionale osservata è statisticamente significativa e non può essere ragionevolmente attribuita al solo errore campionario.

3.5 Sintesi del Capitolo e Raccordo con la Campagna

Sperimentale

L'impalcatura teorica e metodologica formalizzata nel presente capitolo definisce un modello astratto e rigoroso per la valutazione dei sistemi NIDS soggetti a *domain shift*. Attraverso l'allineamento degli spazi delle *feature*, la formalizzazione dei modelli di classificazione (aggregati e specialistici) e la definizione di un protocollo stocastico fondato su valutazioni *multi-seed* e test di significatività, il framework garantisce l'isolamento dei reali contributi algoritmici dal rumore di misura.

Tuttavia, la validità dei vincoli analitici e delle proprietà di invarianza descritte richiede un riscontro quantitativo su scenari operativi concreti. Nel Capitolo 4, il framework teorico viene pertanto istanziato ed eseguito empiricamente. Verranno presentati la caratterizzazione dei dataset di traffico reale, il setup infrastrutturale di addestramento e la discussione critica dei risultati ottenuti, valutando le capacità di generalizzazione e le prestazioni dei modelli al variare dei contesti di rete.

4. Implementazione del Framework Metodologico

Il presente capitolo traduce l’impalcatura teorica e il framework metodologico, definiti nel Capitolo 3, in una configurazione sperimentale concreta e riproducibile. L’obiettivo primario risiede nel dettagliare l’istanziamento software, le scelte architetturelle e i protocolli operativi impiegati per l’addestramento e la valutazione dei sistemi di *Network Intrusion Detection* (NIDS), rimanendo esplicitamente l’analisi dei risultati empirici e delle metriche prestazionali al Capitolo 5. Questa trasposizione materiale garantisce la totale trasparenza tecnologica e fornisce gli strumenti implementativi necessari per quantificare oggettivamente i fenomeni di *domain shift*.

La trattazione si articola secondo una progressione logica suddivisa in sette sezioni principali:

- La **Sezione 4.1** descrive l’ambiente sperimentale, dettagliando l’organizzazione modulare della repository software, lo stack tecnologico adottato e i rigorosi meccanismi di isolamento per la gestione della riproducibilità stocastica.
- La **Sezione 4.2** analizza le fonti di dati originarie, definendo la caratterizzazione del dominio sorgente e dei segmenti di destinazione, per poi formalizzare la parametrizzazione che guida la composizione fisica dei benchmark aggregati e ristretti.
- La **Sezione 4.3** illustra la pipeline di pre-elaborazione, declinando operativamente l’operatore di mappatura per l’allineamento degli spazi delle *feature* e giustificando la scelta architetturelle di omettere la scalatura esplicita globale.
- La **Sezione 4.4** dettaglia l’infrastruttura di classificazione supervisionata, specificando gli algoritmi di base, la configurazione degli iperparametri e le logiche di istanziamento dei modelli aggregati e biclasse.
- La **Sezione 4.5** completa la descrizione del framework operativo definendo l’orchestrazione gerarchica del ciclo di addestramento *multi-seed*, le procedure di inferenza sugli insiemi di collaudo e le logiche costruttive delle matrici di valutazione.

- La **Sezione 4.6** formalizza l'implementazione degli strumenti diagnostici e di spiegabilità, integrando le proiezioni PCA, le stime di densità KDE con ancoraggio al sorgente e l'infrastruttura TreeSHAP per l'interpretazione dei modelli ad albero.
- Infine, la **Sezione 4.7** fornisce la sintesi dell'architettura software end-to-end, illustrando la separazione funzionale tra il flusso computazionale principale di addestramento/valutazione e il ramo diagnostico.

4.1 Ambiente Sperimentale e Riproducibilità

Al fine di garantire la totale trasparenza e la riproducibilità end-to-end degli esperimenti, la presente sezione dettaglia la struttura della repository software, le dipendenze tecnologiche impiegate e i meccanismi di controllo dell'aleatorietà stocastica.

4.1.1 Repository e Organizzazione del Codice

L'intera architettura software sviluppata è stata resa pubblicamente accessibile su piattaforma GitHub¹. Il progetto, distribuito sotto licenza open-source MIT alla versione v4.0.0, è organizzato secondo una struttura modulare concepita per disaccoppiare la logica di pre-elaborazione dei dati, la definizione dei modelli, l'esecuzione della suite sperimentale e la produzione degli artefatti documentali.

La gerarchia fondamentale delle directory, illustrata nella Figura 4.1, si articola nei seguenti moduli principali:

- `src/`: racchiude il core logico dell'applicazione, integrando i moduli di pre-elaborazione (`data_preprocessing.py`), definizione dei classificatori (`models.py`), esecuzione delle procedure di classificazione (`classification.py`) e generazione grafica (`plotting.py`). La sotto-cartella `utils/` gestisce le configurazioni di sistema (`config.py`), l'I/O su disco (`file_utils.py`) e la formalizzazione delle metriche (`metrics.py`).
- `data/`: destinata alla memorizzazione dei dataset nello stato successivo alle fasi di pulizia e trasformazione (`preprocessed/`) unitamente ai relativi metadati.

¹<https://github.com/marchesinia187179/earth-trained-satellite-ids>

- `runs/`: ambiente di persistenza strutturato per tipologia di modello usato per il confronto con la baseline (es. `hybrid_models/`, `nb15_models/`) e scomposizione per seme stocastico. Ogni cartella raccoglie gli artefatti serializzati dei modelli (`models/`), le misurazioni grezze (`results/`) e i prodotti delle analisi di significatività statistica (es. test t di Welch e mappe di calore).
- `doc/`: contiene i sorgenti $\text{\LaTeX}$ e le risorse grafiche della documentazione scientifica.




Figura 4.1: Rappresentazione schematica semplificata della gerarchia delle directory del progetto e delle risorse generate a runtime.

L'esecuzione dell'infrastruttura non richiede configurazioni manuali complesse. L'avvio del punto di ingresso principale (`main.py`), previa installazione delle dipendenze dichiarate nel file di testo `requirements.txt`, attiva un'interfaccia a riga di comando (CLI) interattiva. Tale interfaccia guida l'operatore attraverso le fasi di preparazione dei dati, addestramento multi-seed e generazione delle analisi comparative.

4.1.2 Stack Tecnologico e Dipendenze

L'infrastruttura software è stata sviluppata adottando l'interprete Python (v3.14.4) quale ambiente di esecuzione. Per isolare il runtime e prevenire conflitti con librerie di sistema, le dipendenze sono state gestite in un ambiente virtuale dedicato tramite il modulo nativo `venv`.

Le librerie e i pacchetti impiegati per la manipolazione dati, l'addestramento dei modelli e le verifiche statistiche sono riassunti nella Tabella 4.1.

Tabella 4.1: Stack tecnologico, librerie e relative versioni vincolate nell'ambiente di runtime.

Libreria	Versione	Scopo Applicativo
Python	3.14.4	Ambiente di esecuzione e interprete base
pandas	3.0.3	Manipolazione ed elaborazione di strutture dati tabulari
numpy	2.5.1	Calcolo scientifico e operazioni vettoriali ad alte prestazioni
scikit-learn	1.9.0	Pre-elaborazione <i>feature</i> e addestramento classificatori
scipy	1.18.0	Verifiche di significatività statistica (es. test <i>t</i> di Welch)
shap	0.52.0	Calcolo dei valori Shapley per l'analisi di <i>explainability</i> (XAI)
joblib	1.5.3	Serializzazione e caricamento efficiente dei modelli su disco
matplotlib	3.11.1	Generazione di grafici e diagrammi prestazionali
seaborn	0.13.2	Visualizzazione avanzata e mappe di calore comparative

La suite sperimentale è stata eseguita su un calcolatore Apple MacBook Air 2020 (modello A2179), equipaggiato con un processore quad-core Intel Core i5, una GPU Intel Iris Plus Graphics e con 8 GB di memoria RAM unificata². Per azzerare l'overhead della virtualizzazione e garantire

²Tale configurazione impone un vincolo operativo sull'impronta mnemonica (*memory footprint*) dell'ambiente di calcolo, richiedendo un'ottimizzazione accurata delle strutture dati `pandas.DataFrame` e la profilazione dei vettori

un controllo diretto sulle risorse hardware, l'esecuzione è avvenuta in ambiente nativo *dual-boot* sotto distribuzione Linux Xubuntu.

4.1.3 Gestione della Riproducibilità Stocastica

Il controllo della variabilità stocastica negli algoritmi di apprendimento automatico costituisce un requisito imprescindibile del framework. L'aleatorietà viene gestita separando nettamente la fase di preparazione deterministica del dato dall'addestramento dei classificatori.

La fase di pulizia e trasformazione del dataset originale è vincolata in modo univoco al **seme stocastico primario** $s_0 = 127001$. Tale vincolo assicura che la generazione dei metadati e il salvataggio dei dati pre-elaborati in `data/preprocessed/` avvengano in maniera deterministica e immutabile.

La campagna di addestramento e validazione si sviluppa invece su un **insieme di $K = 10$ semi stocastici distinti**:

$$\mathcal{S} = \{0, 1, 7, 42, 101, 123, 999, 1337, 2026, 12345\} \quad (4.1)$$

L'iniezione del controllo stocastico avviene tramite l'assegnazione esplicita del parametro `random_state` nelle routine di `scikit-learn`. Per evitare contaminazioni incrociate (*cross-seed contamination*), il framework garantisce l'isolamento dei processi: ogni esecuzione riferita a un seme $s_k \in \mathcal{S}$ opera in maniera autonoma, leggendo le risorse e scrivendo i propri artefatti esclusivamente nella directory dedicata (es. `runs/hybrid_models/rf/42/`).

4.2 Caratterizzazione dei Dataset e Composizione dei Benchmark

La presente sezione è dedicata alla traduzione dell'impianto teorico del framework, definito nel capitolo precedente, in una configurazione sperimentale concreta e riproducibile. Affinché i modelli di *Intrusion Detection* possano essere addestrati e valutati rispetto alle sfide imposte dal *domain shift*, è fondamentale istanziare fisicamente il dominio sorgente ($\mathcal{D}_S$) e i domini di destinazione ($\mathcal{D}_T$). Nelle sottosezioni seguenti verranno analizzate le fonti di dati originarie, descrivendo le tassonomie

numpy durante la fase di allineamento e trasformazione delle feature.

di minaccia native e le relative procedure di pulizia e normalizzazione (Sezioni 4.2.1 e 4.2.2). Infine, la Sezione 4.2.3 formalizzerà l'algoritmo di campionamento e scalatura che ha guidato l'aggregazione di tali fonti, culminando nella generazione dei benchmark fisici standardizzati su cui poggeranno le successive fasi di addestramento e classificazione.

4.2.1 Dominio Sorgente: UNSW-NB15

Il dataset UNSW-NB15 [9]³ è stato adottato come rappresentazione concreta del dominio sorgente $\mathcal{D}_S$. Il dataset, acquisito nella sua formulazione tabulare in formato CSV, comprende inizialmente un volume complessivo di 257.673 record.

La tassonomia nativa delle minacce, indicata formalmente con $\mathcal{A}_S$, include oltre alla classe di traffico lecito (*Normal*) nove categorie di attacco: *Fuzzers*, *Analysis*, *Backdoors*, *DoS*, *Exploits*, *Generic*, *Reconnaissance*, *Shellcode* e *Worms*.

Al fine di prevenire il degrado prestazionale dei modelli di apprendimento automatico causato da un marcato sbilanciamento delle classi, è stata applicata una procedura di rimozione delle classi fortemente minoritarie (*minority removal*), in accordo con la metodologia validata in letteratura da Azar et al. [8]. In particolare, sono state eliminate quattro categorie di attacco caratterizzate da una frequenza relativa estremamente ridotta nell'insieme originario:

- *Analysis* (1,141% delle istanze totali);
- *Backdoors* (0,996% delle istanze totali);
- *Shellcode* (0,646% delle istanze totali);
- *Worms* (0,074% delle istanze totali).

A seguito dell'eliminazione delle classi minoritarie, la volumetria complessiva del dominio sorgente si attesta a 250.982 record. La distribuzione dettagliata delle istanze per le sei classi residue è riassunta nella Tabella 4.2. Il successivo campionamento e la scalatura in funzione del parametro ρ vengono formalizzati nella Sezione 4.2.3.

³<https://research.unsw.edu.au/projects/unsw-nb15-dataset>

Tabella 4.2: Distribuzione delle istanze del dataset UNSW-NB15 a seguito della procedura di *minority removal*.

Classe Nativa	Tipologia	Conteggio Istanze
<i>Normal</i>	Traffico Lecito	93.000
<i>Generic</i>	Attacco Malevolo	58.871
<i>Exploits</i>	Attacco Malevolo	44.525
<i>Fuzzers</i>	Attacco Malevolo	24.246
<i>DoS</i>	Attacco Malevolo	16.353
<i>Reconnaissance</i>	Attacco Malevolo	13.987
Totale		250.982

4.2.2 Domini di Destinazione: Segmento Satellitare/Terrestre STIN

I domini di destinazione $\mathcal{D}_T$ sono stati formalizzati a partire dal dataset STIN (*Satellite-Terrestrial Integrated Network*) [10]⁴, focalizzato sull'identificazione di minacce informatiche in architetture di rete e infrastrutture spaziali integrate. Acquisiti nella formulazione tabulare in formato CSV, a differenza del dominio sorgente $\mathcal{D}_S$, i dataset target considerati **contengono esclusivamente traffico malevolo**, con una totale assenza di campioni appartenenti alla classe di traffico lecito (*Normal*)⁵.

La caratterizzazione del target si articola su due segmenti operativi distinti:

- **Segmento Terrestre (TER20):** Rappresenta il traffico rilevato dai nodi di terra dell'infrastruttura STIN.
- **Segmento Satellitare (SAT20):** Modellizza il traffico intercettato dai vettori spaziali, precisamente quelli satellitari.

⁴<https://github.com/kun9717/STIN-data-set/>

⁵La composizione asimmetrica dei dataset STIN è determinata dalla struttura del testbed di cattura originario, progettato unicamente per isolare ed etichettare flussi di attacco in scenari operativi reali. Di conseguenza, per la costruzione dei benchmark di valutazione biclasse cross-dominio, la componente di traffico benigno ($Y = 0$) viene estratta in modo coerente dal dominio sorgente UNSW-NB15, garantendo l'omogeneità del traffico lecito e preservando il rapporto di sbilanciamento prefissato ($\rho = 10$).

Segmento Terrestre (TER20)

Il dataset TER20 comprende originariamente 127.244 record ripartiti su dieci classi native di attacco: *Botnet*, *DDoS*, *Syn_DDoS*, *UDP_DDoS*, *Web Attack*, *Backdoor*, *LDAP_DDoS*, *MSSQL_DDoS*, *NetBIOS_DDoS* e *Portmap_DDoS*.

In linea con la metodologia di accorpamento delle classi minoritarie (*minority merge*) proposta da Azar et al. [8], le categorie con caratteristiche funzionali sovrapponibili e frequenza ridotta sono state raggruppate per preservare la significatività statistica e riflettere la tassonomia delle macro-minacce. Nello specifico:

1. Le classi *Web Attack* e *Backdoor* sono state accorpate alla classe principale *Botnet*;
2. Le sottoclassi di attacco volumetrico *LDAP_DDoS*, *MSSQL_DDoS*, *NetBIOS_DDoS* e *Portmap_DDoS* sono state fuse nella macro-categoria *DDoS*.

A seguito del processo di *minority merge*, la volumetria complessiva rimane invariata a 127.244 record, strutturata nelle quattro macro-classi risultanti riportate nella Tabella 4.3.

Tabella 4.3: Distribuzione delle istanze del dataset TER20 a seguito del processo di *minority merge*.

Macro-Classe Target ($\mathcal{A}_T$)	Classi Native Accorpate	Conteggio Istanze
<i>DDoS</i>	<i>DDoS</i> , <i>LDAP_DDoS</i> , <i>MSSQL_DDoS</i> , <i>NetBIOS_DDoS</i> , <i>Portmap_DDoS</i>	57.292
<i>Botnet</i>	<i>Botnet</i> , <i>Web Attack</i> , <i>Backdoor</i>	40.401
<i>Syn_DDoS</i>	<i>Syn_DDoS</i>	15.713
<i>UDP_DDoS</i>	<i>UDP_DDoS</i>	13.838
Totale		127.244

Segmento Satellitare (SAT20)

Il dataset SAT20 include un totale di 82.320 istanze, focalizzate in modo specifico sulle minacce dirette al segmento spaziale. La tassonomia nativa si articola esclusivamente su due vettori di attacco volumetrico: *UDP_DDoS* e *Syn_DDoS*. Vista l'assenza di classi marginali o fortemente

sbilanciate, non è stata applicata alcuna procedura di *minority merge*. La distribuzione finale del segmento SAT20 è dettagliata nella Tabella 4.4.

Tabella 4.4: Distribuzione delle istanze del dataset SAT20.

Classe Target ($\mathcal{A}_T$)	Tipologia Minaccia	Conteggio Istanze
<i>UDP_DDoS</i>	Attacco Volumetrico Satellitare	43.244
<i>Syn_DDoS</i>	Attacco Volumetrico Satellitare	39.076
Totale		82.320

Per entrambi i dataset target, il successivo campionamento e la scalatura in funzione del parametro ρ vengono formalizzati nella Sezione 4.2.3.

4.2.3 Parametrizzazione e Istanziatura dei Benchmark

Al fine di garantire un confronto rigoroso, equo e immune da bias legati alle fluttuazioni nella cardinalità dei dati tra i diversi scenari di test, la costruzione materiale dei benchmark fisici a partire dai domini sorgente e target ($\mathcal{D}_S$ e $\mathcal{D}_T$) è stata sottoposta a un rigido vincolo di bilanciamento matematico. Il parametro di scalatura e proporzione tra classi, definito formalmente come ρ , è stato fissato a un valore numerico pari a 10. Tale configurazione (NORMAL_ANOMALY_RATIO nell'infrastruttura di codice) impone che per ogni istanza appartenente allo spazio delle etichette primarie malevole ($Y = 1$), siano presenti esattamente dieci istanze relative al traffico lecito ($Y = 0$).

Il processo di istanziatura opera mediante un campionamento stratificato senza reinserimento (*without-replacement stratified sampling*). Poiché l'operatore di cardinalità applicato alla componente benevola del dominio sorgente restituisce $N(\mathbf{x} \in \mathcal{D}_S \mid Y = 0) = 93.000$ record, l'algoritmo vincola l'estrazione della componente anomala a esattamente 9.300 istanze complessive per ciascun benchmark. La partizione dei domini in insiemi di addestramento e collaudo ($\mathcal{D}_k^{(train)}$ e $\mathcal{D}_k^{(test)}$) è mantenuta costante attraverso uno *split* dell'**80% per il training e del 20% per il test**.

La realizzazione pratica del vincolo di bilanciamento $\rho = 10$ e del campionamento senza reinserimento è affidata alle routine ausiliarie implementate nel modulo `file_preprocessing.py`.

In particolare, la funzione `_get_correct_normal_and_anomaly_data_samples` valuta le cardinalità relative delle componenti lecite e anomale, determinando dinamicamente il volume di

campioni da estrarre per rispettare la costante `MLConstants.NORMAL_ANOMALY_RATIO`. Successivamente, la funzione `_safe_stratified_sample` garantisce che il campionamento mantenga inalterata la proporzione originaria tra le partizioni di addestramento e collaudo (`split_type`), prevenendo fenomeni di sbilanciamento tra i sotto-insiemi *train* e *test*.

Le implementazioni complete delle due routine sono riportate nei Listati A.1 e A.2, raccolti nell'Appendice A.1.

L'applicazione di questa logica ha permesso di istanziare i dataset aggregati previsti dal framework teorico. In tutte le configurazioni, la componente benevola corrisponde invariabilmente alle distribuzioni stazionarie originarie del dominio sorgente, $P_S(\mathbf{x} \mid Y = 0)$. La differenziazione degli scenari avviene modulando la componente malevola ($Y = 1$) in funzione della famiglia di attacco esplorata ($A \in \mathcal{A}_S$ oppure $A \in \mathcal{A}_T$):

1. **Set di Iniezione di Riferimento (INJECTION):** Costituisce la baseline proposta dall'architettura ($\mathcal{M}_{base}$). Progettato per fornire un'ancora di prestazione basata su *few-shot learning*, questo set combina le minacce sorgente $P_S(\mathbf{x} \mid Y = 1, A \in \mathcal{A}_S)$ (pari a 9.271 istanze) con l'infusione controllata di una porzione altamente sparsa di traffico target $\Delta\mathcal{D}_T$. La cardinalità di tale quota di iniezione è determinata formalmente dalla relazione:

$$|\Delta\mathcal{D}_T| = \lceil N_{mal,T} \times \eta_{inj} \rceil = \lceil 9.300 \times 0,003 \rceil = 29 \text{ campioni} \quad (4.2)$$

dove $N_{mal,T} = 9.300$ rappresenta la popolazione anomala totale e $\eta_{inj} = 0,3\%$ la percentuale di iniezione prescritta. L'operatore d'arrotondamento per eccesso ($\lceil \cdot \rceil$) garantisce il rispetto della soglia minima teorica.

2. **Set Nativo Sorgente (NB15):** Rappresenta il NIDS tradizionale ($\mathcal{M}_S$). La componente anomala ammonta a 9.300 istanze appartenenti esclusivamente alla tassonomia nativa sorgente $\mathcal{A}_S$. È impiegato per misurare analiticamente la degradazione prestazionale causata dal *domain shift* in totale assenza di adattamento al target.
3. **Set Ibridi Aggregati (NB15_SAT20, NB15_TER20, NB15_STIN):** Formulati per addestrare i modelli aggregati ibridi ($\mathcal{M}_H^{(T)}$), questi dataset istituiscono il limite teorico di rilevamento (*upper bound*, paradigma Oracle). La componente anomala di 9.300 record è interamente governata dalle distribuzioni a priori del dominio target $P_T(\mathbf{x} \mid Y = 1, A \in \mathcal{A}_T)$, prelevate

rispettivamente dal segmento spaziale (SAT20), terrestre (TER20) o dall’ecosistema olistico congiunto (STIN).

Grazie al vincolo imposto da ρ , i cinque benchmark aggregati presentano un’architettura dimensionale e un partizionamento perfettamente identici, come esposto nella Tabella 4.5. Tale standardizzazione volumetrica neutralizza il rischio di divergenze prestazionali derivanti dalle variazioni della mole campionaria.

Tabella 4.5: Riepilogo delle cardinalità finali per i benchmark aggregati.

Benchmark	Istanze Normali <i>Normal $Y = 0$</i>	Istanze Anomale <i>$Y = 1$</i>	Totale Istanze	Training Set <i>(80%)</i>	Test Set <i>(20%)</i>
INJECTION (Baseline)	93.000	9.300	102.300	81.840	20.460
NB15	93.000	9.300	102.300	81.840	20.460
NB15_SAT20	93.000	9.300	102.300	81.840	20.460
NB15_TER20	93.000	9.300	102.300	81.840	20.460
NB15_STIN	93.000	9.300	102.300	81.840	20.460

Infine, a partire dai macro-dataset aggregati e scalati finora descritti, la pipeline di pre-elaborazione procede alla derivazione sistematica dei Set Nativi Sorgente Biclasse e dei Set Ibridi Biclasse. Tramite un filtraggio a livello di etichetta secondaria $A = a$, le singole famiglie di minaccia (es. $a \in \mathcal{A}_S$ per NB15 o $a \in \mathcal{A}_T$ per STIN) vengono isolate e combinate esclusivamente con la baseline nativa lecita $P_S(\mathbf{x} \mid Y = 0)$. Questi dataset ristretti risultano indispensabili per l’addestramento dei rilevatori specialistici ($\mathcal{M}_{S,a}$ e $\mathcal{M}_{H,T,a}$), consentendo di valutare la sensibilità del sistema verso singole tipologie di attacco senza incorrere nelle distorsioni intrinseche generate dalla sovrapposizione di distribuzioni anomale eterogenee.

La struttura dettagliata degli 11 benchmark biclasse così generati — 5 per il dominio sorgente NB15, 4 per il segmento terrestre TER20 e 2 per il segmento satellitare SAT20 — è sintetizzata nella Tabella 4.6. Come si evince dai dati di partizionamento, l’applicazione rigorosa del rapporto $\rho = 10$ garantisce che ciascun rilevatore specialistico ($\mathcal{M}_{S,a}$ o $\mathcal{M}_{H,T,a}$) venga addestrato su una distribuzione uniforme composta da esattamente 93.000 campioni leciti ($Y = 0$) e 9.300 campioni

malevoli ($Y = 1$) dedicati alla singola famiglia d'attacco a , mantenendo costante lo *split* 80/20 tra training (81.840 record) e test set (20.460 record).

Tabella 4.6: Prospetto sintetico della cardinalità e del partizionamento per i Set Nativi Sorgente Biclasse e Ibridi Biclasse.

Dominio	Nome Dataset Biclasse (File CSV)	Istanze Normali Normal ($Y = 0$)	Istanze Attacco Classe a ($Y = 1$)	Totale Istanze	Train Set (80%)	Test Set (20%)
Set Nativi Sorgente Biclasse						
NB15	Normal_Generic.csv	93.000	9.300	102.300	81.840	20.460
NB15	Normal_Exploits.csv	93.000	9.300	102.300	81.840	20.460
NB15	Normal_Fuzzers.csv	93.000	9.300	102.300	81.840	20.460
NB15	Normal_DoS.csv	93.000	9.300	102.300	81.840	20.460
NB15	Normal_Reconnaissance.csv	93.000	9.300	102.300	81.840	20.460
Set Ibridi Biclasse Terrestri						
TER20	Normal_DDoS.csv	93.000	9.300	102.300	81.840	20.460
TER20	Normal_Botnet.csv	93.000	9.300	102.300	81.840	20.460
TER20	Normal_Syn_DDoS.csv	93.000	9.300	102.300	81.840	20.460
TER20	Normal_UDP_DDoS.csv	93.000	9.300	102.300	81.840	20.460
Set Ibridi Biclasse Satellitari						
SAT20	Normal_UDP_DDoS.csv	93.000	9.300	102.300	81.840	20.460
SAT20	Normal_Syn_DDoS.csv	93.000	9.300	102.300	81.840	20.460




Figura 4.2: Diagramma di flusso del processo di estrazione, pulizia, campionamento vincolato ($\rho = 10$) e partizionamento stratificato 80/20 per la generazione dei benchmark fisici aggregati e biclasse.

4.3 Allineamento delle Feature e Pipeline di Preprocessing

La presente sezione illustra l'istanziatura concreta e l'architettura software dell'operatore di mappatura $\psi_k : \mathcal{X}_k \rightarrow \mathcal{X}_{\text{shared}}$, formalizzato sul piano teorico nella Sezione 3.1.2. L'obiettivo primario della pipeline di preprocessing consiste nel colmare il divario strutturale e semantico esistente tra le rappresentazioni grezze del dominio sorgente ($\mathcal{D}_S$, basato su UNSW-NB15) e dei domini di destinazione ($\mathcal{D}_T$, articolato sulle catture STIN TER20 e SAT20), proiettando i rispettivi spazi delle feature in uno spazio coordinato condiviso, omogeneo e privo di distorsioni di tracciamento.

L'architettura generale del flusso di elaborazione e la sua ripartizione in stadi sequenziali sono schematizzate nella Figura 4.3. La pipeline si sviluppa lungo tre fasi principali: un filtraggio preliminare per la rigida eliminazione di attributi non trasferibili o ridondanti, l'applicazione delle trasformazioni algebriche e analitiche definite dall'operatore ψ_k , e la strutturazione della tabella coordinata finale composta da $d = 16$ feature predittive continue e 3 variabili di controllo. Nelle

sottosezioni seguenti vengono analizzati nel dettaglio i singoli criteri di selezione, la formulazione analitica delle trasformazioni e le proprietà di invarianza del grafo computazionale risultante.




Figura 4.3: Diagramma di flusso della pipeline di preprocessing e armonizzazione tra il dominio sorgente $\mathcal{D}_S$ e i domini target $\mathcal{D}_T$, dall'estrazione delle feature grezze alla generazione dello spazio coordinato finale a 16 dimensioni.

4.3.1 Feature Grezze e Criteri di Filtraggio Applicati

La fase preliminare della pipeline di preprocessing è volta ad allineare gli spazi delle feature originariamente eterogenei del dominio sorgente $\mathcal{D}_S$ (UNSW-NB15) e dei domini di destinazione $\mathcal{D}_T$ (STIN, declinato in TER20 e SAT20). Il dataset sorgente si articola originariamente su un vettore di $d_S = 42$ attributi predittivi grezzi (a cui si aggiungono l'identificatore `id` e la doppia etichettatura nativa `attack_cat` e `label`, per un totale di 45 colonne). Diversamente, le sorgenti di destinazione presentano una struttura nativa derivata da catture di flusso composta da $d_T = 30$ attributi predittivi (unitamente all'identificatore `id` e all'etichetta binaria `label`, per un totale di 32 colonne).

Per garantire l'interoperabilità e la generalizzabilità dei modelli di apprendimento automatico rispetto al *domain shift*, la selezione dello spazio delle feature condiviso d è stata regolata da tre criteri di filtraggio sequenziali:

1. **Rimozione di identificatori univoci e metadati di tracciamento:** Sia nel dominio sorgente che in quelli target, l'attributo identificativo progressivo (`id`) è stato rimosso. Tale eliminazione è indispensabile per prevenire fenomeni di correlazione spuria o *overfitting* legati all'ordinamento sequenziale delle registrazioni di rete.
2. **Criterio di non calcolabilità e assenza di corrispondenza cross-dominio:** Sono stati scartati tutti gli attributi presenti esclusivamente in una delle due sorgenti che non potevano essere matematicamente o logicamente ricostruiti a partire dai dati dell'altra, o le cui metriche sono state scartate in favore di un ricalcolo run-time per garantire la consistenza tra i domini. La classificazione dettagliata delle feature eliminate per ciascun dominio in questa fase è sintetizzata nella Tabella 4.7.

Tabella 4.7: Feature eliminate durante la fase di pre-processing nei domini sorgente e target.

Dominio	Categoria	Feature Rimosse
Sorgente ($\mathcal{D}_S$)	Protocolli Applicativi	service, trans_depth, response_body_len, is_ftp_login, ct_ftp_cmd, ct_flw_http_mthd
	Contatori Aggregati	ct_srv_src, ct_state_ttl, ct_dst_ltm, ct_src_dport_ltm, ct_dst_sport_ltm, ct_dst_src_ltm, ct_src_ltm, ct_srv_dst
	TTL e Perdita Pacchetti	sttl, dttl, sloss, dloss, is_sm_ips_ports
	Jitter, TCP e Metriche	sjit, djit, sinpkt, dinpkt, tcprtt, synack, ackdat, stcpb, dtcpb
	Metriche Ridondanti	smean, dmean, rate
Target ($\mathcal{D}_T$)	Statistiche Lunghezza	pkt_len_min, pkt_len_max, pkt_len_std, fw_hdr_len
	Flag TCP	bw_psh_flag, fw_urg_flag, bw_urg_flag, fin_cnt, syn_cnt, psh_cnt, urg_cnt, ece_cnt
	Intervalli Inter-arrivo	fl_iat_min, bw_iat_tot, bw_iat_min
	Contatori Burst	fw_byt_blk_avg, fw_pkt_blk_avg, fw_blk_rate_avg, bw_byt_blk_avg, bw_pkt_blk_avg, bw_blk_rate_avg

3. **Criterio di incompatibilità e impossibilità di armonizzazione:** Gli attributi categoriali ad alta cardinalità relativi al protocollo di trasporto (proto) e allo stato della connessione (state) presenti in UNSW-NB15 sono stati scartati. Tale scelta è stata motivata dall'assenza di attributi categoriali equivalenti nei dataset STIN e dall'impossibilità di stabilire una mappatura biunivoca senza introdurre codifiche arbitrarie che avrebbero distorto lo spazio delle feature.

A seguito dell'applicazione di tali criteri di scarto, in entrambi i domini si isola un sottoinsieme condiviso di 9 feature predittive di base. A partire da queste, mediante operazioni algebriche calcolate a tempo di esecuzione (quali somme, rapporti e differenze dirette), vengono derivate 7 ulteriori feature sintetiche (es. total_bytes, pkts_per_sec, byte_ratio). Si ottiene così uno spazio condiviso armonizzato finale composto da **$d = 16$ feature predittive continue** e quantitative.

Nei dataset pre-processati finali, a questo vettore di 16 dimensioni si affiancano **3 variabili di controllo e destinazione** (class per la macro/micro tassonomia della minaccia, label per la classificazione binaria, e split_type per l'indicazione della partizione di addestramento o collaudo), portando la cardinalità complessiva delle tabelle a 19 colonne. La Tabella 4.8 riassume il processo logico di riduzione, derivazione e allineamento dimensionale.

Tabella 4.8: Sintesi del processo di selezione e allineamento dimensionale tra il dominio sorgente ($\mathcal{D}_S$) e i domini di destinazione ($\mathcal{D}_T$).

Dominio / Sorgente	Colonne Totali	Feature Predittive Grezze	Feature Scartate
Sorgente ($\mathcal{D}_S$)	45	$d_S = 42$	33
Target ($\mathcal{D}_T$)	32	$d_T = 30$	21
Spazio Allineato Finale	19	d = 16	–

4.3.2 Implementazione dell'Operatore di Mappatura

Al fine di proiettare gli spazi delle feature originari in uno spazio latente condiviso omogeneo, è stato implementato formalmente l'operatore di mappatura $\psi_k : \mathcal{X}_k \rightarrow \mathcal{X}_{\text{shared}}$, con $k \in \{S, T\}$. Tale operatore agisce sui vettori grezzi applicando trasformazioni algebriche, conversioni di unità di misura e derivazioni analitiche, garantendo la rigorosa coerenza semantica delle grandezze fisiche e di rete.

La Tabella 4.9 formalizza le trasformazioni scalari $\psi_{k,j}$ applicate a ciascuna feature condivisa j , mettendo a confronto il dominio sorgente (UNSW-NB15) e il dominio target (STIN/TER20/SAT20).

Tabella 4.9: Formulazione algebrica dell'operatore di mappatura vettoriale nei domini $\mathcal{D}_S$ e $\mathcal{D}_T$.

Feature Coordinata (x_j)	Dominio Sorgente ($\psi_{S,j}$)	Dominio Target ($\psi_{T,j}$)	Unità di Misura
duration	$dur \cdot 10^6$	fl_dur	μs
src_bytes	sbytes	l_fw_pkt	Byte
dst_bytes	dbytes	l_bw_pkt	Byte
src_pkts	spkts	fw_pk	Adimensionale
dst_pkts	dpkts	$(bw_pkt_s \cdot fl_dur)/10^6$	Adimensionale
src_win_byt	swin	fw_win_byt	Byte
dst_win_byt	dwin	bw_win_byt	Byte
load_s	$(sload + dload)/8$	fl_byt_s	Byte/s
down_up_ratio	$dpkts/(spkts + \epsilon)$	down_up_ratio	Adimensionale
total_bytes		src_bytes + dst_bytes	Byte
total_pkts		src_pkts + dst_pkts	Adimensionale
src_mean_pkt_size		$src_bytes/(src_pkts + \epsilon)$	Byte
dst_mean_pkt_size		$dst_bytes/(dst_pkts + \epsilon)$	Byte
win_diff		$src_win_byt - dst_win_byt$	Byte
byte_ratio		$dst_bytes/(src_bytes + \epsilon)$	Adimensionale
pkts_per_sec	$total_pkts/(dur + \epsilon)$	$[total_pkts/(duration + \epsilon)] \cdot 10^6$	1/s

Tabella 4.10: Descrizione semantica delle feature coordinate.

Feature Coordinata (x_j)	Descrizione
duration	Durata di esecuzione
src_bytes	Lunghezza totale dei pacchetti in direzione forward
dst_bytes	Lunghezza totale dei pacchetti in direzione backward
src_pkts	Numero totale di pacchetti in direzione forward
dst_pkts	Numero totale di pacchetti in direzione backward
src_win_byt	Lunghezza finestra iniziale in direzione forward
dst_win_byt	Lunghezza finestra iniziale in direzione backward
load_s	Throughput totale
down_up_ratio	Asimmetria dei pacchetti
total_bytes	Bytes totali
total_pkts	Pacchetti totali
src_mean_pkt_size	Dimensione media dei pacchetti in direzione forward
dst_mean_pkt_size	Dimensione media dei pacchetti in direzione backward
win_diff	Differenza di finestra
byte_ratio	Rapporto di byte
pkts_per_sec	Tasso di pacchetti per secondo

Nel processo di mappatura emergono tre aspetti architetturali critici:

- **Conversioni di Scala e Armonizzazione Temporale:** Per allineare le metriche, la durata dei flussi nel dominio sorgente è stata riscalata da secondi a microsecondi (fattore moltiplicativo 10^6). Parallelamente, il throughput nominale (sload, dload), originariamente quantificato in bit/s in UNSW-NB15, è stato convertito in Byte/s (dividendolo per 8) per coincidere con l'unità di misura nativa dei domini target.
- **Derivazione Analitica di Metriche Mancanti:** Nel dominio $\mathcal{D}_T$, il conteggio totale dei pacchetti di destinazione (dst_pkts) non è fornito in forma diretta. Per garantire la ricostruzione fedele dello spazio latente, tale grandezza è stata derivata indirettamente tramite il prodotto

analitico tra il tasso di arrivo pacchetti di ritorno (bw_pkt_s) e la durata del flusso (fl_dur), normalizzato per i microsecondi (10^6).

- **Stabilizzazione Numerica:** Durante il calcolo di indici razionali (come $down_up_ratio$, $byte_ratio$, le densità di pacchetti e il *packet rate*), è stata introdotta una costante di regolarizzazione $\epsilon = 10^{-6}$ ai denominatori. Questo accorgimento previene singolarità algebriche causate da divisioni per zero indotte da flussi anomali o malformati.

A completamento della trattazione teorica, i Listati 4.1 e 4.2 riportano l'implementazione in linguaggio Python delle funzioni `_align_nb15` e `_align_stin`. Tali funzioni costituiscono la trasposizione operativa diretta degli operatori ψ_S e ψ_T , sfruttando l'esecuzione vettorializzata su strutture dati *DataFrame* della libreria pandas per applicare in modo uniforme le trasformazioni definite sull'insieme delle osservazioni.

Codice 4.1: Trasposizione operativa dell'operatore di mappatura ψ_k tramite vettorializzazione pandas per il dominio UNSW-NB15.

```
1 def _align_nb15(data):
2     required_columns = ['dur', 'sbytes', 'dbytes', 'spkts', 'dpkts', 'swin',
3         'dwin', 'sload', 'dload', 'sinpkt', 'dinpkt', 'attack_cat', 'label']
4     # [Controllo di sicurezza per le required_columns...]
5
6     new_df = pd.DataFrame()
7
8     # Trasposizione operativa dell'operatore di mappatura
9     new_df['duration'] = data['dur'] * 1000000
10    new_df['src_bytes'] = data['sbytes']
11    new_df['dst_bytes'] = data['dbytes']
12    new_df['src_pkts'] = data['spkts']
13    new_df['dst_pkts'] = data['dpkts']
14    new_df['src_win_byt'] = data['swin']
15    new_df['dst_win_byt'] = data['dwin']
16    new_df['load_s'] = ((data['sload'] + data['dload']) / 8)
17    new_df['down_up_ratio'] = data['dpkts'] / (data['spkts'] + 1e-6)
18    new_df['total_bytes'] = new_df['src_bytes'] + new_df['dst_bytes']
19    new_df['total_pkts'] = new_df['src_pkts'] + new_df['dst_pkts']
20    new_df['src_mean_pkt_size'] = new_df['src_bytes'] / (new_df['src_pkts'] + 1e-6)
21    new_df['dst_mean_pkt_size'] = new_df['dst_bytes'] / (new_df['dst_pkts'] + 1e-6)
22    new_df['pkts_per_sec'] = (new_df['src_pkts'] + new_df['dst_pkts']) / (data['dur'] + 1e-6)
23    new_df['win_diff'] = new_df['src_win_byt'] - new_df['dst_win_byt']
24    new_df['byte_ratio'] = new_df['dst_bytes'] / (new_df['src_bytes'] + 1e-6)
25    new_df['class'] = data['attack_cat']
26    new_df['label'] = data['label']
27
28    return new_df
```

Codice 4.2: Trasposizione operativa dell'operatore di mappatura ψ_k tramite vettorializzazione pandas per il dominio STIN.

```
1 def _align_stin(data):
2     required_columns = ['fl_dur', 'l_fw_pkt', 'l_bw_pkt', 'fw_pk', 'bw_pkt_s',
3         'fw_win_byt', 'bw_win_byt', 'fl_byt_s', 'fl_iat_min', 'down_up_ratio', 'label']
4     # [Controllo di sicurezza per le required_columns...]
5
6     new_df = pd.DataFrame()
7
8     # Trasposizione operativa dell'operatore di mappatura
9     new_df['duration'] = data['fl_dur']
10    new_df['src_bytes'] = data['l_fw_pkt']
11    new_df['dst_bytes'] = data['l_bw_pkt']
12    new_df['src_pkts'] = data['fw_pk']
13    new_df['dst_pkts'] = data['bw_pkt_s'] * data['fl_dur'] / 1000000
14    new_df['src_win_byt'] = data['fw_win_byt']
15    new_df['dst_win_byt'] = data['bw_win_byt']
16    new_df['load_s'] = data['fl_byt_s']
17    new_df['down_up_ratio'] = data['down_up_ratio']
18    new_df['total_bytes'] = new_df['src_bytes'] + new_df['dst_bytes']
19    new_df['total_pkts'] = new_df['src_pkts'] + new_df['dst_pkts']
20    new_df['src_mean_pkt_size'] = new_df['src_bytes'] / (new_df['src_pkts'] + 1e-6)
21    new_df['dst_mean_pkt_size'] = new_df['dst_bytes'] / (new_df['dst_pkts'] + 1e-6)
22    new_df['pkts_per_sec'] = ((new_df['src_pkts'] + new_df['dst_pkts']) \
23        / (new_df['duration'] + 1e-6)) * 1000000
24    new_df['win_diff'] = new_df['src_win_byt'] - new_df['dst_win_byt']
25    new_df['byte_ratio'] = new_df['dst_bytes'] / (new_df['src_bytes'] + 1e-6)
26    new_df['class'] = data['label']
27    new_df['label'] = 1
28
29    return new_df
```

4.3.3 Verifica dell'Omissione della Scalatura Esplicita

Un elemento caratterizzante dell'architettura della pipeline di preprocessing risiede nella scelta metodologica di **omettere qualsiasi operazione di normalizzazione o re-scalatura globale** dei dati (quali la standardizzazione z -score o il ridimensionamento Min-Max) dalle fasi di addestramento e inferenza valutativa cross-dominio.

Tale impostazione si giustifica formalmente sulla base di tre considerazioni teorico-applicative:

1. **Invarianza Monotonica dei Modelli Adottati:** Gli algoritmi di classificazione integrati nella pipeline principale comprendono *Decision Tree*, *Random Forest* e *Histogram-based Gradient Boosting*. Tali modelli determinano i punti di separazione negli iperpiani di decisione (*split points*) valutando esclusivamente le relazioni d'ordine relativo tra i valori ($x_j \leq \theta$). Essendo tali decisioni invarianti rispetto a qualsiasi trasformazione strettamente monotona, la presenza o l'assenza di scalatura lineare non altera la struttura degli alberi generati né la superficie di separazione appresa.
2. **Preservazione della Semantica Fisica e Trasparenza:** Il mantenimento degli attributi nelle rispettive unità di misura fisiche originarie e derivate (microsecondi per le durate, byte per i volumi e valori adimensionali per i rapporti) preserva la leggibilità diretta delle feature. Ciò risulta determinante per l'interpretabilità dei vettori d'attacco e per l'estrazione di spiegazioni mediante attributori di importanza (*SHAP* e *Permutation Feature Importance*).
3. **Prevenzione del Data Leakage e Invarianza nell'Inferenza:** L'eliminazione dei trasformatori di scala nel flusso di dati principale evita la necessità di stimare e congelare parametri statistici (media e deviazione standard) sul dominio sorgente $\mathcal{D}_S$ da proiettare sui domini target $\mathcal{D}_T$. In contesti di *domain shift*, la proiezione di parametri di scala estratti da sorgenti eterogenee rischia di introdurre distorsioni o anomalie numeriche dovute a valori fuori scala (*outliers*) non previsti.

Si evidenzia che l'utilizzo di algoritmi di normalizzazione è stato rigorosamente **limitato alle sole procedure di diagnostica ed esplorazione delle distribuzioni**, analizzate sul piano teorico nel Capitolo 3. In particolare, la classe `StandardScaler` del modulo `sklearn.preprocessing` è stata impiegata unicamente all'interno del modulo di supporto `plotting.py` per standardizzare

le feature a media nulla e varianza unitaria prima dell'esecuzione dell'Analisi delle Componenti Principali (*PCA*) e della stima della densità di kernel (*KDE*). Tali trasformazioni diagnostiche sono state isolate all'interno delle routine di visualizzazione e non sono mai state integrate nel grafo computazionale di addestramento e inferenza dei classificatori.

4.4 Implementazione dei Classificatori

La presente sezione traduce in architettura software e in moduli operativi l'impianto di classificazione supervisionata introdotto nella Sezione 3.2.3. A valle del processo di armonizzazione e allineamento dello spazio delle feature descritto nel capitolo precedente, l'infrastruttura software è progettata per istanziare, addestrare e tracciare in modo sistematico le diverse famiglie di modelli predittivi. L'obiettivo primario di questo modulo consiste nel definire una pipeline di fitting rigorosa, capace di gestire sia i classificatori basati su dataset aggregati (per la valutazione complessiva del *domain shift*) sia la suite di modelli biclasse (per l'isolamento e l'analisi granulare di minacce mirate).

Nelle sottosezioni seguenti vengono dettagliate le librerie di machine learning adottate, la configurazione degli iperparametri e la struttura dei registri di tracciamento persistenti (Sottosezione 4.4.1). Infine, le Sottosezioni 4.4.2 e 4.4.3 formalizzano le logiche procedurali e i criteri di campionamento stratificato impiegati per la generazione dei rispettivi insiemi di addestramento.

4.4.1 Algoritmi di Base e Iperparametri

L'infrastruttura di classificazione del framework è stata sviluppata in ambiente Python basandosi sulla libreria open-source `scikit-learn` (versione 1.9.0). Coerentemente con le premesse metodologiche discusse nella Sezione 3.2.3, sono state selezionate tre famiglie di algoritmi di apprendimento supervisionato basati su alberi di decisione, caratterizzate da differenti livelli di complessità strutturale e capacità espressiva:

- **Decision Tree (DT):** Classificatore a singolo albero di decisione, implementato tramite la classe `DecisionTreeClassifier`⁶.

⁶Link alla documentazione del classificatore DT

- **Random Forest (RF):** Architettura d'insieme di tipo *bagging*, implementata mediante la classe `RandomForestClassifier`⁷.
- **Histogram-based Gradient Boosting (HGB):** Algoritmo d'insieme di tipo *boosting* ottimizzato per dataset di grandi dimensioni, implementato tramite la classe `HistGradientBoostingClassifier`⁸.

Al fine di valutare la capacità intrinseca di generalizzazione cross-dominio delle diverse famiglie di modelli ed evitare fenomeni di adattamento spurio (*overfitting*) delle configurazioni alle specificità statistiche del solo dominio sorgente $\mathcal{D}_S$, **non sono state applicate procedure di ricerca ed ottimizzazione automatica degli iperparametri** (quali *GridSearchCV* o *RandomizedSearchCV*). Tutti i modelli sono stati pertanto istanziati mantenendo i valori di iperparametri predefiniti (*default*) forniti dall'API di `scikit-learn`.

L'unico parametro esplicitamente vincolato in fase di inizializzazione è il seme di determinismo numerico (`random_state`), il quale viene impostato in modo dinamico iterando su un pool di seed predefiniti (es. `seed = 42`) per garantire la perfetta riproducibilità statistica degli esperimenti. La Tabella 4.11 sintetizza la corrispondenza tra le classi Python adottate e la configurazione degli iperparametri operativi associati.

Tabella 4.11: Configurazione degli iperparametri di default e classi `scikit-learn` utilizzate per ciascuna famiglia di classificatori.

Alg.	Classe <code>scikit-learn</code>	Iperparametri di Default
DT	<code>DecisionTreeClassifier</code>	<code>criterion='gini', max_depth=None, min_samples_split=2</code>
RF	<code>RandomForestClassifier</code>	<code>n_estimators=100, criterion='gini', max_depth=None, max_features='sqrt', min_samples_split=2</code>
HGB	<code>HistGradientBoostingClassifier</code>	<code>learning_rate=0.1, max_iter=100, max_depth=None, max_leaf_nodes=31, l2_regularization=0.0</code>

⁷Link alla documentazione del classificatore RF

⁸Link alla documentazione del classificatore HGB

Per garantire un tracciamento rigoroso del ciclo di vita dei modelli, l’istanziamento e l’addestramento non disperdono lo stato interno degli stimatori. Al termine del fitting di ciascun classificatore su uno specifico dataset di addestramento (sorgente o ibrido) e per ogni seed di esecuzione, le informazioni di configurazione hardware/temporale, l’assetto completo degli iperparametri e le metriche di prestazione in-sample (*training set*) vengono persistite in modo strutturato all’interno del file di registro `models_metadata.csv`.

Tale meccanismo di tracciamento memorizza per ogni modello un record identificativo univoco, la cui struttura logica e i relativi attributi sono riepilogati nella Tabella 4.12.

Tabella 4.12: Struttura e campi del record di tracciamento persistito nel registro `models_metadata`.

Categoria Logica	Campi Registrati
Metadati di Identificazione	<code>id</code> , <code>timestamp</code> , <code>model_name</code> , <code>dataset_type</code> , <code>random_state</code>
Proprietà Struttura Dati	<code>samples</code> , <code>train_split</code> , <code>n_features_in</code> , <code>n_classes</code>
Config. Iperparametrica	<code>n_estimators</code> , <code>max_depth</code> , <code>max_features</code> , <code>criterion</code> , <code>min_samples_split</code> , <code>learning_rate</code> , <code>max_iter</code>
Valutazione In-Sample	Matrice di confusione grezza (TP, TN, FP, FN) e metriche derivate di addestramento (Accuracy, Precision, Recall, F1-Score, ROC-AUC, PR-AUC, TPR, FPR)

L’archiviazione sistematica in `models_metadata.csv` assicura la completa uditabilità dell’infrastruttura di addestramento, fornendo la base informativa per le successive fasi di inferenza e valutazione cross-dominio sui dataset di test target.

4.4.2 Istanziamento dei Modelli Aggregati

La strategia di istanziamento dei classificatori aggregati prevede la generazione di tre distinte classi di modelli per ciascun seed stocastico, corrispondenti alla formalizzazione teorica discussa nella Sezione 3.2.1. Nonostante i dataset integrino l’etichettatura multi-classe (identificando la specifica tipologia di attacco), le architetture aggregate sono addestrate a risolvere un **task di rilevamento binario**, discriminando il traffico benevolo (Normal) dal generico traffico ostile (Attack).

La composizione dei *training set* per l'addestramento segue precise regole di proporzionalità e campionamento, ancorate al parametro di *Injection Ratio* $\rho_{ben/mal} = 10/1$:

1. **Modello Base** ($\mathcal{M}_{base}$): Costituisce la *baseline* teorica. È addestrato su un dataset ingegnerizzato ad hoc tramite un approccio di *injection* controllata. Mantenendo il rapporto 10/1, i campioni benigni sono estratti integralmente dal dataset UNSW-NB15, mentre la componente malevola è ripartita proporzionalmente: $\frac{299}{300}$ dei campioni anomali richiesti proviene da UNSW-NB15, mentre la frazione residua $\frac{1}{300}$ è popolata con attacchi estratti dal dataset satellitare integrato (STIN, composto da TER20 e SAT20). Nei registri di esecuzione, tale modello è identificato come *injection_aggregate*.
2. **Modello Sorgente** ($\mathcal{M}_S$): È il modello aggregato nativo, istanziato esclusivamente sui campioni appartenenti al dominio sorgente terrestre ($\mathcal{D}_S$). Si compone di traffico benigno e attacchi estratti unicamente dal dataset UNSW-NB15, denominato *nb15_aggregate*.
3. **Modelli Ibridi** ($\mathcal{M}_H^{(T)}$): Rappresentano la concretizzazione della procedura di *fine-tuning* in ottica cross-dominio. Vengono istanziati combinando tutti i record benigni nativi del dataset sorgente (UNSW-NB15) con la totalità dei campioni malevoli estratti dai domini target armonizzati ($\Delta\mathcal{D}_T^{(train)}$). Anche per l'addestramento di queste architetture viene garantito e forzato il rigoroso rispetto del rapporto di sbilanciamento $\rho_{ben/mal} = 10/1$. Sono state istanziate tre varianti di modelli ibridi aggregati:
 - *nb15_stin_aggregate*: Ibrido su dataset STIN complessivo.
 - *nb15_ter20_aggregate*: Ibrido sul solo canale target TER20.
 - *nb15_sat20_aggregate*: Ibrido sul solo canale target SAT20.

La Figura 4.4 schematizza visivamente il flusso di composizione dei dati appena descritto, evidenziando il rigoroso mantenimento del vincolo proporzionale tra le classi in fase di addestramento.




Figura 4.4: Architettura del flusso dati per l’addestramento dei Modelli Aggregati. Le percentuali indicano l’origine logica dei pacchetti che compongono i *training set*, forzati strutturalmente al vincolo $\rho_{ben/mal} = 10/1$.

Il prelievo dei campioni dalla partizione target ($\Delta\mathcal{D}_T^{(train)}$) è governato da una procedura di campionamento casuale stratificato (*stratified random sampling*)⁹. Questa metodologia garantisce che i sotto-insiemi estratti rispettino le proporzioni imposte dal ratio 10/1 e salvaguarda la rigida compartimentazione logica tra *train set* e *test set*, risultando fondamentale per scongiurare qualsiasi fenomeno di dispersione dell’informazione (*Data Leakage*) in fase di validazione.

Dal punto di vista dell’ingegneria del software, la pipeline di istanziazione e addestramento è centralizzata all’interno del modulo `models.py`. La logica architetturale espone un punto di accesso pubblico, la funzione `model_processing()`, la quale orchestra dinamicamente l’esecuzione. Tale funzione delega il calcolo matematico del fitting a un *helper* interno denominato `_train_classifier()`, responsabile dell’inizializzazione dell’algoritmo di ML richiesto e della valutazione asincrona delle metriche sul *test set* in-sample. Lo script gestisce inoltre il salvataggio dei pesi strutturali (formato `.joblib`). Tale formato rappresenta lo standard *de facto* nell’ecosistema Python per la serializzazione efficiente di oggetti che ospitano array NumPy di grandi dimensioni, rendendolo particolarmente ottimizzato per il salvataggio dei modelli basati su alberi di decisione,

⁹Implementato avvalendosi della funzione `train_test_split` di `scikit-learn`, valorizzando il parametro `stratify` per garantire la corretta preservazione delle proporzioni relative alle classi originali durante l’estrazione.

garantendo l'aggiornamento automatico del registro `models_metadata.csv` tramite l'assegnazione procedurale del *Naming Standard* in base al dominio analizzato.

4.4.3 Istanziamento dei Modelli Biclasse

Al fine di condurre un'analisi comparativa granulare e valutare le prestazioni analitiche dei classificatori rispetto a minacce mirate, la metodologia prevede l'addestramento di una suite parallela di modelli biclasse, come anticipato nella Sezione 3.2.2. A differenza delle varianti aggregate (discusse nella Sottosezione 4.4.2), ciascun classificatore biclasse è progettato per isolare e discriminare un'unica e specifica famiglia di attacco dal normale traffico di rete (Normal). Tale approccio consente di misurare le metriche di accuratezza del modello dinanzi a pattern di traffico ostile altamente caratterizzati.

Dal punto di vista dell'ingegnerizzazione dei dati, i sotto-insiemi impiegati per il *fitting* di questi modelli vengono strutturati *a priori* durante la macro-fase di pre-elaborazione del file. In questa sede, i record appartenenti a vettori di attacco estranei al contesto di analisi vengono filtrati e scartati, restituendo un dominio di riferimento strettamente binario (es. [Normal, DDoS]). Durante la generazione di questi dataset isolati, l'algoritmo di elaborazione impone rigorosamente il mantenimento del rapporto di sbilanciamento $\rho_{ben/mal} = 10/1$. Contestualmente, viene preservata e fissata la partizione logica dei dati tramite etichettatura statica dei set di *train* e *test*, scongiurando eventuali contaminazioni informative (*Data Leakage*).

In perfetta simmetria con la suddivisione concettuale tra dominio sorgente e domini target ibridizzati, la pipeline ha generato le istanze biclasse riepilogate nella Tabella 4.13.

Tabella 4.13: Istanze dei modelli biclasse generati per il dominio sorgente e i domini target ibridizzati.

Categoria	Dominio
Modelli Sorgente	UNSW-NB15
nb15_dos nb15_exploits nb15_fuzzers nb15_generic nb15_reconnaissance	
Modelli Ibridi Target	SAT20
nb15_sat20_syn_ddos nb15_sat20_udp_ddos	
Modelli Ibridi Target	TER20
nb15_ter20_botnet nb15_ter20_ddos nb15_ter20_syn_ddos nb15_ter20_udp_ddos	

L'integrazione di questa logica all'interno del codice sorgente sfrutta elevati livelli di automazione. L'assegnazione della nomenclatura ai file serializzati e ai registri di metadati è gestita in maniera trasparente dalla subroutine `_get_standardized_model_name()` del modulo `models.py`. La funzione elabora il vettore delle classi uniche del dataset in input: verificata l'esatta cardinalità binaria, estrae computazionalmente l'etichetta divergente dalla stringa `Normal` e la concatena in modo canonico alla tipologia del dataset, generando dinamicamente identificativi quali `dataset_attackname`. Tale soluzione consente di mantenere una nomenclatura uniforme degli artefatti persistiti e dei relativi record di tracciamento. L'implementazione completa della procedura è riportata nel Listato A.3, raccolto nell'Appendice A.2.

4.5 Protocollo di Addestramento e Valutazione

La presente sezione formalizza e declina in moduli operativi il protocollo sperimentale di addestramento, valutazione ed analisi inferenziale introdotto dal punto di vista teorico nel Capitolo 3. A fronte dell'esigenza di garantire la stabilità stocastica dei modelli e la piena riproducibilità dei risultati, l'infrastruttura software è progettata per gestire in modo sistematico l'intero ciclo di vita degli stimatori: dalla fase di fitting strutturata su molteplici semi stocastici, all'inferenza rigorosa sugli insiemi di collaudo, fino alla validazione statistica delle prestazioni relative. L'obiettivo primario di questo modulo consiste nel definire una pipeline esecutiva automatizzata e rigorosa,

capace di integrare la persistenza degli artefatti, la generazione delle matrici di valutazione e la verifica formale delle ipotesi di significatività.

Nelle sottosezioni seguenti vengono dettagliate le componenti e le logiche procedurali che costituiscono l'architettura del protocollo. In primo luogo, la Sottosezione 4.5.1 descrive l'orchestrazione gerarchica del ciclo di addestramento multi-seed, le modalità di serializzazione degli oggetti predittivi e i meccanismi di tracciamento dei metadati nei registri persistenti. Successivamente, la Sottosezione 4.5.2 illustra il flusso di classificazione e inferenza sugli insiemi di test, la gestione difensiva dei casi limite, la derivazione delle metriche di prestazione e la costruzione delle matrici di valutazione per singolo seed ed aggregate. Infine, la Sottosezione 4.5.3 analizza l'implementazione del test t di Welch, dettagliando la procedura di aggregazione dei dati di *F1-Score* e i criteri di decisione statistica adottati per il confronto tra le diverse configurazioni e il modello di riferimento.

4.5.1 Orchestrazione del Ciclo di Addestramento Multi-Seed

L'esecuzione della campagna di addestramento è stata strutturata secondo un'organizzazione gerarchica basata sulla tipologia di modello (`model_type`) e sul seme stocastico (`seed`). I dataset impiegati nel processo sono univoci e vengono istanziati una sola volta durante la fase di preprocessing, utilizzando il seme deterministico primario $s_0 = 127001$, come descritto nella Sezione 4.1.3. Le successive esecuzioni multi-seed operano pertanto sugli stessi dataset pre-processati, senza introdurre nuove istanziazioni o modifiche alla composizione dei benchmark.

L'orchestrazione globale è demandata al punto di ingresso `main.py`, nel quale il ciclo di costruzione dei modelli viene realizzato iterando sul prodotto cartesiano tra l'insieme delle tipologie di classificatore e l'insieme dei seed definiti dal framework. In termini procedurali, per ciascun `model_type` vengono quindi eseguite in successione le dieci configurazioni associate ai semi dell'Equazione (4.1).

Il flusso operativo dell'infrastruttura di addestramento e la relativa logica di persistenza sono schematizzati nella Figura 4.5.




Figura 4.5: Flusso operativo dell'orchestrazione multi-seed e isolamento degli artefatti persistiti.

Tale organizzazione garantisce che ogni combinazione (m, s_k) , con m appartenente all'insieme delle tipologie di modello e $s_k \in \mathcal{S}$, costituisca un'esecuzione logicamente indipendente. Il parametro `random_state` viene trasferito esplicitamente all'istanziamento del classificatore, preservando il controllo della componente stocastica senza alterare i dataset di ingresso. La distinzione tra le diverse configurazioni di algoritmo e seed è quindi mantenuta a livello di file system e di stato interno degli stimatori, in coerenza con il principio di isolamento già adottato nella gestione della riproducibilità.

Dal punto di vista implementativo, la logica di addestramento è centralizzata nel modulo `models.py`. La funzione pubblica `model_processing()` costituisce il punto di ingresso della procedura e riceve il *DataFrame* del benchmark, il relativo `dataset_type`, la tipologia di classificatore e il seed corrente. Tale funzione provvede alla predisposizione della struttura di persistenza associata all'esecuzione, delegando il fitting vero e proprio alla funzione interna `_train_classifier()`. Quest'ultima separa il dataset nelle partizioni `train` e `test`, rimuove le colonne non destinate all'apprendimento e istanzia dinamicamente il classificatore richiesto. La centralizzazione della

pipeline consente di applicare la medesima procedura operativa alle diverse famiglie di modelli ultimate nel framework.

L'istanziamento dell'algoritmo mantiene gli iperparametri ai valori predefiniti forniti da `scikit-learn`, mentre il parametro `random_state` viene vincolato al seed dell'esecuzione. Per la *Random Forest*, inoltre, il parametro `n_jobs=-1` abilita l'impiego parallelo dei processori disponibili durante la costruzione dell'ensemble; per il *Decision Tree* e l'*Histogram-based Gradient Boosting* non viene invece specificata una configurazione equivalente nel codice applicativo. La scelta mantiene separata la parallelizzazione interna dell'algoritmo dalla logica di orchestrazione, che continua a processare sequenzialmente le diverse combinazioni di `model_type` e `seed`.

Una volta completato il fitting, lo stato dello stimatore viene congelato mediante serializzazione su disco. La funzione `_save_model()` utilizza la libreria `joblib` per esportare l'oggetto addestrato in formato binario `.joblib`, registrandone contestualmente il percorso nel registro dei modelli. La struttura gerarchica adottata separa la tipologia di modello dal seed e dagli artefatti prodotti, secondo lo schema generale:

```
runs/model_type/seed/models/
```

Un'istanza concreta è rappresentata dal percorso:

```
runs/hybrid_models/rf/42/models/injection_aggregate.joblib
```

nel quale `rf` identifica la famiglia del classificatore, `42` il seed dell'esecuzione e `injection_aggregate.joblib` il modello serializzato associato al benchmark considerato. La nomenclatura dei modelli viene determinata automaticamente sulla base del `dataset_type` e delle classi presenti nel dataset, così da mantenere una corrispondenza univoca tra configurazione sperimentale e artefatto persistito.

Parallelamente alla serializzazione dello stimatore, per ogni configurazione vengono registrati i relativi metadati nel file `models_metadata.csv`. Il meccanismo di aggiornamento è implementato mediante la funzione `update_or_append_csv()` del modulo `file_utils.py`, la quale verifica preventivamente l'eventuale presenza di un record corrispondente alle chiavi di identificazione e, in assenza di una corrispondenza, genera un nuovo identificatore incrementale. La funzione mantiene inoltre il campo `id` come prima colonna del file e allinea lo schema del nuovo record a quello già presente. Per ciascun modello vengono quindi mantenute, oltre alle informazioni identificative, le

principali proprietà strutturali e configurazionali dello stimatore, inclusi il valore di `random_state`, il numero di feature in ingresso, il numero di classi e gli iperparametri specifici dell'algoritmo. Il registro costituisce pertanto la traccia persistente dell'esecuzione e permette di associare ogni artefatto serializzato alla precisa configurazione che ne ha determinato la costruzione.

La procedura adottata garantisce infine una netta separazione tra produzione e successivo utilizzo degli stimatori. Una volta completato il ciclo di fitting e serializzazione per un determinato seed, il relativo modello non viene più modificato nelle fasi successive: la valutazione viene infatti eseguita caricando da disco l'artefatto precedentemente congelato. In questo modo, la fase di classificazione successiva opera esclusivamente in modalità di inferenza sul modello già addestrato, evitando che le procedure di valutazione possano alterarne lo stato interno.

4.5.2 Calcolo delle Metriche e Costruzione della Matrice di Valutazione

La valutazione dei classificatori è stata implementata mediante una procedura comune a tutte le configurazioni sperimentali, così da garantire uniformità nel calcolo delle metriche e nella successiva organizzazione dei risultati. La fase di classificazione **opera esclusivamente sugli insiemi di collaudo**, identificati tramite il campo `split_type`, mentre le informazioni relative alle feature e alle etichette vengono separate prima dell'esecuzione dell'inferenza. Per ciascun modello precedentemente serializzato, l'artefatto `.joblib` viene ricaricato da disco e utilizzato senza apportare modifiche al suo stato interno.

La procedura è centralizzata nella funzione `classification_processing()` del modulo `classification.py`, che delega il calcolo delle predizioni alla propria funzione interna `_classification()`. Una volta isolato il sottoinsieme associato a `split_type = test`, vengono eliminate dalle feature le colonne `label`, `class` e `split_type`, mentre la variabile `label` viene mantenuta separatamente come vettore delle classi reali. L'inferenza viene quindi effettuata mediante i metodi `predict()` e `predict_proba()`, utilizzando quest'ultimo per estrarre il punteggio associato alla classe positiva. **Non viene applicata una soglia decisionale personalizzata**: le etichette predette sono pertanto quelle direttamente restituite dall'estimatore secondo il comportamento predefinito del classificatore.

Il calcolo delle metriche è stato incapsulato nella funzione `calculate_metrics()` del modulo `src/utils/metrics.py`, con l'impiego delle funzioni messe a disposizione da `sklearn.metrics`.

In particolare, vengono utilizzate le metriche descritte in Tabella 4.14.

Tabella 4.14: Metriche di valutazione delle prestazioni utilizzate per la caratterizzazione dei modelli di apprendimento automatico.

Funzione Scikit-Learn	Descrizione Operativa
<code>confusion_matrix</code>	Matrice di confusione per il conteggio delle predizioni binarie.
<code>accuracy_score</code>	Proporzione complessiva di predizioni corrette rispetto al totale delle istanze.
<code>precision_score</code>	Frazione di istanze malevole identificate correttamente rispetto a tutte quelle classificate come tali.
<code>recall_score</code>	Sensibilità o tasso di veri positivi (<i>TPR</i>): frazione di anomalie rilevate rispetto al totale reale.
<code>f1_score</code>	Media armonica tra Precision e Recall, indicatore sintetico in presenza di sbilanciamento delle classi.
<code>roc_auc_score</code>	Area sotto la curva ROC (True Positive Rate vs False Positive Rate) al variare della soglia decisionale.
<code>average_precision_score</code>	Area sotto la curva Precision-Recall, pesata sull'incremento della Recall ad ogni soglia.

La matrice di confusione viene esplicitamente calcolata imponendo l'ordine delle classi $[0, 1]$ e successivamente scomposta nei quattro termini fondamentali:

$$\mathbf{C} = \begin{bmatrix} TN & FP \\ FN & TP \end{bmatrix} \quad (4.3)$$

A partire da tali quantità vengono inoltre calcolati direttamente il *True Positive Rate* (TPR), il *False Negative Rate* (FNR), il *True Negative Rate* (TNR) e il *False Positive Rate* (FPR), secondo le relazioni riportate nella Sezione 3.4.3.

Il *Recall* restituito da `recall_score()` coincide, nel caso binario adottato dal framework, con il TPR. Le ulteriori metriche calcolate comprendono *Accuracy*, *Precision*, *F1-Score*, *ROC-AUC* e *PR-AUC*. Le metriche *Accuracy*, *Precision*, *Recall* e *F1-Score* sono ottenute a partire dalle etichette predette `y_pred`, mentre *ROC-AUC* e *PR-AUC* vengono determinate utilizzando i

punteggi `y_scores` associati alla classe positiva. Tutti i valori numerici prodotti dalle funzioni di metrica vengono arrotondati al numero di cifre decimali stabilito nella configurazione globale `MLConstants.DECIMAL_DIGITS`¹⁰.

Particolare attenzione è stata riservata ai casi nei quali il vettore delle etichette reali contiene una sola classe. Prima del calcolo delle metriche viene pertanto verificata la presenza di almeno due classi distinte mediante il numero di valori univoci presenti in `y_test`. Qualora tale condizione non sia soddisfatta, le metriche *Accuracy*, *Precision*, *Recall*, *F1-Score*, *ROC-AUC* e *PR-AUC* vengono impostate a `None`. I quattro elementi della matrice di confusione vengono invece sempre ricavati imponendo le classi `[0, 1]`, mentre *TPR*, *FNR*, *TNR* e *FPR* vengono calcolati separatamente e assumono valore `None` esclusivamente quando il denominatore della relativa espressione risulta nullo¹¹.

L'implementazione della logica di gestione difensiva e del calcolo delle metriche è riportata nel Listato A.4, raccolto nell'Appendice A.3.

L'insieme completo dei risultati viene quindi organizzato all'interno del file nominato come `classifications.csv`, generato separatamente per ciascuna combinazione di `model_type` e `seed`. Ogni record contiene i metadati identificativi della classificazione, il tipo di dataset e la relativa composizione delle classi, oltre alle quantità della matrice di confusione e alle metriche derivate. La struttura complessiva del record e la relativa suddivisione funzionale dei campi sono dettagliate nella Tabella 4.15.

¹⁰Nella configurazione sperimentale corrente, il parametro `DECIMAL_DIGITS` è impostato su 4 decimali per preservare la precisione numerica nei calcoli aggregati.

¹¹Questa guardia condizionale esplicita sui denominatori ($(TP + FN) > 0$ e $(FP + TN) > 0$) e sul conteggio delle classi univoche previene eccezioni di divisione per zero e avvisi a runtime (*RuntimeWarning/UndefinedMetricWarning*), garantendo la continuità dell'esecuzione e la tracciabilità dei casi degeneri nei report salvati.

Tabella 4.15: Tassonomia e suddivisione concettuale dei campi costituenti il record di tracciamento delle prestazioni.

Campo	Descrizione Operativa
Metadati ed Esecuzione Sperimentale	
id	Identificatore univoco progressivo della singola esecuzione.
timestamp	Marca temporale di completamento della valutazione.
model_name	Architettura o denominazione del modello di apprendimento valutato.
dataset_type	Tipologia di partizione o dominio di test utilizzato.
classes	Cardinalità o identificativi delle classi analizzate.
samples	Numero totale di campioni elaborati nella sessione.
Conteggi della Matrice di Confusione	
TP	Conteggio dei Veri Positivi (<i>True Positives</i>).
TN	Conteggio dei Veri Negativi (<i>True Negatives</i>).
FP	Conteggio dei Falsi Positivi (<i>False Positives</i>).
FN	Conteggio dei Falsi Negativi (<i>False Negatives</i>).
Metriche di Prestazione Sintetiche	
Accuracy	Tasso di accuratezza globale sul totale dei campioni.
Precision	Frazione di predizioni positive risultate corrette.
Recall	Sensibilità o tasso di rilevamento delle anomalie.
F1-Score	Media armonica bilanciata tra Precision e Recall.
ROC-AUC	Area sotto la curva <i>Receiver Operating Characteristic</i> .
PR-AUC	Area sotto la curva <i>Precision-Recall (Average Precision)</i> .
Tassi e Proporzioni Operative	
TPR	<i>True Positive Rate</i> , coincidente con la Recall.
FNR	<i>False Negative Rate</i> , o tasso di mancato allarme.
TNR	<i>True Negative Rate</i> , o specificità del sistema.
FPR	<i>False Positive Rate</i> , o tasso di falso allarme.

La persistenza viene effettuata mediante `update_or_append_csv()`, che individua un'eventuale voce preesistente sulla base delle chiavi di corrispondenza (`model_name`, `dataset_type` e `classes`)

e, in caso contrario, assegna un identificatore al nuovo record.

A partire dai risultati persistiti viene costruita la matrice di valutazione definita teoricamente nel Capitolo 3. Per ciascun seed $s_k \in \mathcal{S}$, tale matrice può essere formalmente rappresentata come:

$$H_k = \left[h_{ij}^{(k)} \right] \in \mathbb{R}^{M \times D}, \quad (4.4)$$

dove M identifica l'insieme dei modelli addestrati, D l'insieme dei dataset di valutazione e ciascun elemento $h_{ij}^{(k)}$ rappresenta il valore della metrica considerata per la coppia costituita dal i -esimo modello e dal j -esimo dataset al seed s_k .

Nell'implementazione concreta, la rappresentazione generale viene articolata in due matrici indipendenti, una relativa al *True Positive Rate* e una relativa al *True Negative Rate*:

$$H_k^{TPR} = \left[TPR_{ij}^{(k)} \right], \quad H_k^{TNR} = \left[TNR_{ij}^{(k)} \right]. \quad (4.5)$$

Le due matrici presentano la medesima organizzazione bidimensionale, con i modelli addestrati disposti sulle righe e i dataset di valutazione sulle colonne. La suddivisione fisica viene invece effettuata a livello di gruppi di modelli: una matrice raccoglie le configurazioni aggregate del dominio sorgente, i modelli biclasse sorgente e il relativo modello *INJECTION*, mentre l'altra raccoglie le configurazioni aggregate ibride, i modelli biclasse ibridi e il medesimo modello di riferimento *INJECTION*.


Per ciascuna matrice, la colonna finale è reserved al valore medio associato alla riga del modello, mentre il modello *INJECTION* viene riportato in una sezione graficamente separata nella parte inferiore della rappresentazione. Gli artefatti relativi alle singole esecuzioni sono salvati nella directory

runs/<model_group>/<model_type>/<seed>/results/plots/performance/

attraverso i file `TPR_matrix.png` e `TNR_matrix.png`.

L'intero flusso operativo di valutazione e la successiva aggregazione statistica tra i diversi seed sono schematizzati nella Figura 4.6.

Fase 1: Valutazione e Persistenza per Singolo Seed (s_k)



Fase 2: Aggregazione Multi-Seed




Figura 4.6: Pipeline a due stadi per il calcolo delle metriche di classificazione, tracciamento su file system e aggregazione statistica multi-seed.

Al termine dell'elaborazione dei singoli seed, viene eseguita una seconda fase di aggregazione che considera congiuntamente i risultati prodotti per tutti i valori di s_k . La routine `_aggregated_heatmaps()` legge i file `classifications.csv` presenti nelle directory associa-

te ai diversi seed, li concatena in un unico *DataFrame* e associa esplicitamente a ciascun record il seed di provenienza.

Per ciascuna coppia modello–dataset vengono successivamente determinate le statistiche aggregate della metrica considerata sui diversi seed. In particolare, per TPR e TNR viene prodotta un’unica matrice contenente due valori numerici distinti per ogni coppia modello–dataset: rispettivamente la media

$$\bar{h}_{ij} = \frac{1}{K} \sum_{k=1}^K h_{ij}^{(k)}, \quad (4.6)$$

e la varianza

$$\sigma_{ij}^2 = \frac{1}{K} \sum_{k=1}^K \left(h_{ij}^{(k)} - \bar{h}_{ij} \right)^2. \quad (4.7)$$

La rappresentazione aggregata combina quindi l’informazione relativa al valore medio e alla dispersione osservata tra i seed, senza sostituire i dati relativi alle singole esecuzioni. Per ciascun tipo di classificatore, le matrici aggregate vengono memorizzate sotto la directory

runs/<model_group>/<model_type>/aggregated_heatmaps/

con una sottocartella dedicata alla metrica considerata. Per ciascuna metrica vengono conservati sia i valori tabellari della media e della varianza in formato CSV, sia la rappresentazione grafica finale in formato PNG.

La struttura organizzativa e la composizione tabellare dei file CSV generati per rappresentare le matrici aggregate di media ($\bar{h}_{ij}$) e varianza (σ_{ij}^2) sono descritte nella Tabella 4.16.

Tabella 4.16: Struttura e descrizione dei campi costituenti i file CSV per le matrici delle metriche individuali e aggregate ($M \times D$).

Colonna	Tipo Dati	Descrizione Operativa
model_label	Stringa	Architettura o denominazione del modello valutato (i -esima riga della matrice).
<dataset_1>	Float	Valore (puntuale, medio $\bar{h}_{ij}$ o varianza σ_{ij}^2) della metrica sul primo dataset.
<dataset_2>	Float	Valore (puntuale, medio $\bar{h}_{ij}$ o varianza σ_{ij}^2) della metrica sul secondo dataset.
...	...	Valori associati ai restanti dataset di valutazione di test $j \in \{1, \dots, D\}$.
<dataset_D>	Float	Valore (puntuale, medio $\bar{h}_{ij}$ o varianza σ_{ij}^2) della metrica sull'ultimo dataset.
Average	Float	Media complessiva della metrica calcolata per la riga del modello su tutti i D dataset.

La separazione tra risultati per singolo seed e risultati aggregati consente pertanto di mantenere distinti due livelli di organizzazione implementativa: il primo conserva integralmente la configurazione associata a ciascuna realizzazione stocastica, mentre il secondo sintetizza le osservazioni relative alla stessa coppia modello–dataset lungo l’insieme dei seed. Tale organizzazione costituisce la trasposizione operativa della matrice di valutazione H_k definita nel modello teorico e produce gli artefatti persistenti utilizzati nelle successive procedure di analisi statistica.

4.5.3 Implementazione del Test di Welch

La verifica statistica della variabilità associata alle diverse configurazioni di addestramento è stata implementata mediante il test t di Welch, applicato separatamente a ciascuna tipologia di classificatore e al relativo gruppo di modelli. La procedura è stata progettata per confrontare le prestazioni del **modello INJECTION**, assunto come **configurazione di riferimento**, con quelle dei restanti modelli generati durante la campagna multi-seed. L’analisi viene eseguita indipendentemente per

i gruppi `nb15_models` e `hybrid_models`, mantenendo pertanto la distinzione architetturale già adottata nella struttura di persistenza dei risultati.

L'esecuzione della procedura è orchestrata dalla funzione `_welch_ttest()` del punto di ingresso `main.py`. Per una specifica tipologia di classificatore, vengono innanzitutto raccolti i file `classifications.csv` prodotti dalle precedenti fasi di valutazione per tutti i seed appartenenti all'insieme $\mathcal{S}$. I risultati vengono quindi forniti alla funzione `aggregate_welch_ttest_feature_scores_by_seed()`, che costituisce il primo livello di aggregazione dei dati destinati all'analisi statistica.

La funzione di aggregazione opera **esclusivamente sulla metrica *F1-Score***, il cui utilizzo è definito tramite il parametro di configurazione `MLConstants.WELCH_TTEST_FEATURE`. Per ciascun file di classificazione vengono selezionate le colonne `model_name` e `F1-Score`, mentre il seed viene ricavato dalla directory che contiene il file `classifications.csv`. I dati provenienti dalle diverse esecuzioni vengono successivamente concatenati in un unico *DataFrame*.

Poiché ciascun file di classificazione contiene più osservazioni relative a differenti dataset valutati dallo stesso modello, la procedura effettua un'ulteriore aggregazione mediante un raggruppamento per coppia `model_name`–`seed`. Per ciascuna coppia viene calcolata la media della *F1-Score* sui dataset disponibili. Indicando con $f_{ij}^{(k)}$ il valore della *F1-Score* associato al modello i , al dataset j e al seed s_k , il valore utilizzato nel successivo test statistico è pertanto

$$\overline{F1}_i^{(k)} = \frac{1}{D_i} \sum_{j=1}^{D_i} f_{ij}^{(k)}, \quad (4.8)$$

dove D_i rappresenta il numero di dataset di valutazione considerati per il modello i nella configurazione corrente. Ne consegue che ciascun modello è rappresentato da un campione costituito dai valori medi ottenuti sui $K = 10$ seed, anziché dalla totalità delle singole osservazioni modello–dataset.

Il risultato di tale aggregazione viene trasformato in una struttura matriciale mediante un'operazione di *pivot*. I modelli costituiscono le righe, mentre ciascun seed viene trasformato in una colonna distinta. La struttura risultante presenta quindi una configurazione del tipo

`id, model_name, seed_0, seed_1, ... , seed_12345`

e costituisce la matrice di input per il test statistico. L'artefatto viene persistito nella directory

runs/<model_group>/<model_type>/welch_ttest/

con il nome `F1-Score_means.csv`. Tale file rappresenta esclusivamente la sintesi dei valori medi di *F1-Score* per modello e seed e costituisce una rappresentazione intermedia necessaria alla successiva procedura statistica. L'intero flusso di aggregazione dei dati e la pipeline di calcolo del test statistico sono schematizzati nella Figura 4.7.




Figura 4.7: Pipeline di trasformazione dei dati per l'esecuzione del Test t di Welch, dal recupero delle metriche sui singoli seed alla persistenza degli esiti statistici.

Il Welch test viene quindi eseguito dalla funzione `calculate_welch_ttest_from_summary()` del modulo `src/utils/metrics.py`, utilizzando la funzione `ttest_ind()` del modulo `scipy.stats`. L'opzione `equal_var=False` impone esplicitamente l'utilizzo della formulazio-

ne di Welch, nella quale non viene assunta l'uguaglianza delle varianze delle due popolazioni campionarie.

Per ogni gruppo di analisi viene individuato il modello di riferimento ricercando nel campo `model_name` la configurazione contenente la stringa `INJECTION`. La struttura dei benchmark garantisce la presenza di una sola configurazione di questo tipo nel *DataFrame* considerato; tale modello viene pertanto utilizzato come riferimento per tutti i successivi confronti. I valori corrispondenti ai dieci seed del modello di riferimento costituiscono il campione

$$\mathcal{F}_{\text{base}} = \left\{ \overline{F1}_{\text{base}}^{(1)}, \overline{F1}_{\text{base}}^{(2)}, \dots, \overline{F1}_{\text{base}}^{(K)} \right\}. \quad (4.9)$$

Per ciascun modello confrontato m , viene analogamente costruito il campione

$$\mathcal{F}_m = \left\{ \overline{F1}_m^{(1)}, \overline{F1}_m^{(2)}, \dots, \overline{F1}_m^{(K)} \right\}. \quad (4.10)$$

Il test inferenziale viene condotto assumendo l'indipendenza statistica delle osservazioni generate dalle diverse iterazioni con seed sintetici distinti ($s_k \in \mathcal{S}$) e senza vincoli sulla varianza delle due popolazioni. L'ipotesi nulla e l'ipotesi alternativa sono pertanto formulate, per ciascun confronto diretto tra $\mathcal{F}_{\text{base}}$ e $\mathcal{F}_m$, come

$$H_0 : \mu_{\text{base}} = \mu_m, \quad H_1 : \mu_{\text{base}} \neq \mu_m, \quad (4.11)$$

dove μ_{base} e μ_m rappresentano i valori medi teorici della *F1-Score* delle rispettive popolazioni campionarie.

La traduzione dell'impianto teorico nella controparte implementativa è sintetizzata nel Listato 4.3, nel quale vengono evidenziate l'estrazione dei campioni di *F1-Score* dal *DataFrame* di sintesi e la successiva invocazione della funzione `scipy.stats.ttest_ind()`.

L'utilizzo del parametro `equal_var=False` applica la formulazione di Welch senza assumere l'uguaglianza delle varianze delle due popolazioni campionarie. La valutazione viene eseguita a due code, secondo la configurazione predefinita della funzione utilizzata.

L'implementazione completa della procedura, comprensiva della gestione iterativa dei modelli confrontati e della costruzione dei record di risultato, è riportata nel Listato A.5, raccolto nell'Appendice A.4.

Codice 4.3: Nucleo implementativo per l'estrazione dei campioni e l'esecuzione del Test t di Welch.


```

1 ref_row = data[data["model_name"] == reference_model]
2 ref_scores = (ref_row.drop(columns=["id", "model_name"]).values.flatten().astype(float))
3
4 for _, row in data.iterrows():
5     current_model = row["model_name"]
6     if current_model == reference_model: continue
7
8     current_scores = row.drop(["id", "model_name"]).values.astype(float)
9     t_stat, p_value = stats.ttest_ind(ref_scores, current_scores, equal_var=False)

```

Il livello di significatività è stabilito *a priori* al valore di primo tipo

$$\alpha = 0,05, \quad (4.12)$$

acquisito dal parametro di configurazione `MLConstants.WELCH_TTEST_ALFA_VALUE`. La decisione statistica viene determinata direttamente confrontando il *p-value* restituito dal test con tale soglia prefissata. In particolare, la differenza prestazionale tra il modello in esame e la baseline viene marcata come statisticamente significativa quando

$$p < \alpha, \quad (4.13)$$

mentre in caso contrario il confronto viene classificato come non significativo. **Non viene applicata alcuna procedura di correzione per confronti multipli** ai *p-value* ottenuti dai diversi confronti tra modelli¹².

Il confronto del modello *INJECTION* con sé stesso viene esplicitamente escluso dalla procedura, poiché non costituisce un confronto statistico tra configurazioni differenti. Per ciascuno degli altri modelli vengono invece registrati il valore della statistica *t*, il relativo *p-value*, il livello α adottato e l'esito della verifica mediante il campo `is_significant`.

I risultati vengono infine serializzati mediante la funzione `create_csv_from_data()` nel file `welch_ttest.csv`, salvato nella sottocartella di analisi

¹²L'assenza di correzioni per test multipli (quali Bonferroni o Benjamini-Hochberg) è stata adottata in modo deliberato per preservare la sensibilità esplorativa dell'analisi. In tale contesto, ridurre la probabilità di errori di II tipo (falsi negativi) è stato ritenuto prioritario rispetto al controllo rigido del *Family-Wise Error Rate* (FWER), evitando così di smorzare prematuramente deviazioni prestazionali potenzialmente rilevanti indotte dalle diverse configurazioni di addestramento.

runs/<model_group>/<model_type>/welch_ttest/

La struttura complessiva del registro finale e la descrizione semantica dei singoli campi sono dettagliate nella Tabella 4.17. Tale schematizzazione consente di associare univocamente ogni confronto alla configurazione di riferimento, al modello sottoposto a verifica e ai parametri descrittivi restituiti dal test.

Tabella 4.17: Struttura e descrizione semantica dei campi costituenti il file di registro statistico `welch_ttest`.

Campo	Descrizione Operativa
Reference_Model	Denominazione del modello di riferimento assunto come baseline (variante <i>INJECTION</i>).
Compared_Model	Denominazione del modello di confronto sottoposto a verifica statistica.
t_statistic	Valore numerico della statistica t di Welch calcolato tra i campioni di <i>F1-Score</i> .
p_value	Probabilità osservata di ottenere un valore uguale o più estremo sotto l'ipotesi nulla H_0 .
alpha	Livello di significatività stabilito <i>a priori</i> per la decisione statistica ($\alpha = \mathbf{0,05}$).
is_significant	Indicatore booleano dell'esito della verifica (True se $p < \alpha$, False altrimenti).

In tal modo, la pipeline mantiene formalmente separati il livello di aggregazione delle prestazioni sui singoli seed, memorizzato in `F1-Score_means.csv`, e il livello di diagnostica statistica inferenziale, rappresentato da `welch_ttest.csv`.

4.6 Strumenti di Analisi Diagnostica e Spiegabilità

La presente sezione formalizza l'implementazione degli strumenti di analisi diagnostica e di spiegabilità introdotti dal punto di vista metodologico nel Capitolo 3. L'infrastruttura software integra procedure dedicate alla caratterizzazione geometrica e distributiva dei benchmark, mediante proiezioni *Principal Component Analysis* (PCA) e stime di densità *Kernel Density Estimation* (KDE), nonché strumenti di interpretabilità post-hoc basati sui valori di Shapley per l'analisi del contributo

delle singole caratteristiche alle decisioni dei classificatori. Tali componenti sono concepiti esclusivamente come strumenti diagnostici e **non intervengono né nella fase di addestramento né nella modifica degli stimatori** precedentemente serializzati.

Particolare attenzione viene dedicata alla coerenza del sistema di riferimento utilizzato nelle analisi diagnostiche. In accordo con il principio di standardizzazione dipendente dal sorgente introdotto nella Sezione 3.4.1, le statistiche di posizione e scala vengono ancorate al benchmark sorgente e successivamente riutilizzate per la trasformazione dei benchmark considerati, evitando il ricalcolo locale dei parametri di standardizzazione. La medesima impostazione viene applicata alle rappresentazioni PCA e KDE, con finalità rispettivamente orientate all'ispezione della disposizione dei dati nello spazio delle caratteristiche e all'analisi delle distribuzioni delle variabili selezionate.

Nelle sottosezioni seguenti vengono descritte le componenti che costituiscono l'architettura diagnostica. In primo luogo, la Sottosezione 4.6.1 illustra l'implementazione della standardizzazione diagnostica dipendente dal sorgente e delle procedure PCA e KDE, specificando le modalità di trasformazione dei benchmark e la configurazione delle rappresentazioni grafiche. Successivamente, la Sottosezione 4.6.2 descrive l'integrazione di SHAP nella pipeline di classificazione, il campionamento stratificato del test set e la gestione degli *explainer* per i classificatori basati su alberi. Infine, la Sottosezione 4.6.3 illustra il raccordo tra l'analisi SHAP e la successiva selezione delle caratteristiche per la rappresentazione KDE, evidenziando il carattere supervisionato della procedura e la definizione manuale della configurazione KDE_TOP_FEATURES.

La Tabella 4.18 sintetizza le caratteristiche operative, lo spazio di input e i moduli software associati a ciascuno degli strumenti considerati.

Tabella 4.18: Confronto sinottico tra gli strumenti diagnostici (PCA, KDE) e di spiegabilità (TreeSHAP) integrati nell’architettura software.

Strumento	Obiettivo	Spazio Input	Interpretabilità
PCA	Ispezione geometrica della separabilità globale e variabilità nello spazio 2D	Scalato (Z-Score ancorato al benchmark sorgente S)	Globale (riduzione dimensionale per componenti principali)
KDE	Analisi densometrica univariata del <i>domain shift</i> sulle feature chiave	Scalato (Z-Score ancorato sulle Top-3 feature di S)	Distribuzionale (stima della densità per classe in scala symlog)
TreeSHAP	Spiegabilità post-hoc del contributo delle feature alle predizioni dei classificatori	Originale (matrice delle caratteristiche del test set X_{test})	Locale e Aggregata (valori di Shapley e <i>summary plot</i>)

4.6.1 Standardizzazione Diagnostica, PCA e KDE

L’implementazione degli strumenti diagnostici descritti nella Sezione 3.4.1 è centralizzata nel modulo `plotting.py`. Le due procedure ricevono come input il file di configurazione contenente i percorsi dei benchmark e i relativi identificativi di dataset e producono automaticamente le rappresentazioni grafiche previste dal framework. L’analisi è finalizzata esclusivamente all’ispezione diagnostica della distribuzione dei dati e della loro disposizione nello spazio delle caratteristiche, senza intervenire nel processo di addestramento o nella fase di classificazione.

Per entrambe le procedure viene adottato il benchmark identificato dalla costante `SOURCE_IDENTIFIER`, impostata a `nb15_aggr_scaled`, come riferimento per la standardizzazione diagnostica. Tale scelta implementa il principio teorico introdotto nella Sezione 3.4.1, secondo il quale le statistiche di riferimento devono essere mantenute fisse durante la trasformazione dei diversi benchmark, così da preservare nello spazio trasformato eventuali traslazioni distributive riconducibili al *domain shift*.

L’architettura logica di questo processo di trasformazione dipendente dal sorgente è schematizzata nella Figura 4.8. Come mostrato nel diagramma di flusso, la stima dei parametri di posizione

e scala (μ_S, σ_S) , così come la matrice di proiettori vettoriali $\mathbf{W}_S$, viene effettuata in modo atomico durante la fase di *fitting* sul solo benchmark sorgente. Successivamente, tali parametri congelati vengono applicati per via diretta sia a S sia a ciascun benchmark target T_k , garantendo l'invarianza del sistema di riferimento e scongiurando qualunque forma di *data leakage*.




Figura 4.8: Schema concettuale della Standardizzazione Diagnostica Dipendente dal Sorgente: le statistiche di centralità e variabilità (μ_S, σ_S) e gli autovettori della PCA ($\mathbf{W}_S$) vengono stimati esclusivamente sul benchmark sorgente S e congelati. La trasformazione dei benchmark target T_k avviene per applicazione diretta di tali parametri, preservando lo scostamento distributivo reale (*domain shift*).

Proiezione PCA La procedura `save_all_pca_plots()` carica ciascun benchmark indicato nel file di configurazione ed estrae preliminarmente il sottoinsieme associato alla partizione test, identificata tramite la colonna `split_type`. Dalla matrice delle caratteristiche vengono rimosse le colonne `label`, `class` e `split_type`, mentre la variabile `label` viene conservata separatamente per la successiva caratterizzazione delle classi nel grafico.

Per realizzare la standardizzazione diagnostica viene istanziato uno `StandardScaler` di `scikit-learn`. Nel caso della PCA, il modello di scaling viene **adattato esclusivamente al sottoinsieme test del benchmark sorgente**. Indicando con $\mathbf{X}_{S,\text{test}}$ tale matrice, l'operazione di adattamento dello standardizzatore e della PCA è seguita dall'applicazione dei medesimi trasformatori ai benchmark considerati, senza eseguire nuovi adattamenti locali.

La configurazione `PCA_COMPONENTS=2` vincola la trasformazione alla costruzione di un sottospazio bidimensionale, coerentemente con la finalità esclusivamente visuale dell'analisi. Gli autovettori principali sono quindi determinati una sola volta sul riferimento sorgente e successivamente riutilizzati per tutti i benchmark. Il Listato 4.4 sintetizza entrambe le fasi, evidenziando la distinzione tra le operazioni di `fit` sul riferimento sorgente e le successive operazioni di sola trasformazione.

Codice 4.4: Standardizzazione, adattamento e trasformazione PCA ancorati al benchmark sorgente.

```
1 scaler = StandardScaler()
2
3 pca = PCA(n_components=MLConstants.PCA_COMPONENTS, random_state=MLConstants.MAIN_SEED)
4
5 X_source_scaled = scaler.fit_transform(X_source)
6 pca.fit(X_source_scaled)
7
8 X_scaled = scaler.transform(X_test)
9 X_pca = pca.transform(X_scaled)
```

La procedura garantisce pertanto che tutti i benchmark siano rappresentati all'interno del medesimo sistema di riferimento statistico e geometrico. Tale impostazione è coerente con la formulazione teorica della standardizzazione dipendente dal sorgente, nella quale le statistiche (μ_S, σ_S) vengono mantenute fisse per evitare che una standardizzazione locale annulli le traslazioni distributive che si intendono osservare.

Per ogni benchmark viene infine generato uno scatter plot bidimensionale delle prime due componenti principali. Le osservazioni sono differenziate in funzione dell'etichetta binaria, con la codifica `Normal Traffic` per la classe 0 e `Attack/Anomaly` per la classe 1. Il titolo del grafico riporta inoltre la percentuale complessiva di varianza spiegata dalle due componenti, mentre gli assi riportano separatamente il contributo percentuale di PC1 e PC2. I grafici vengono salvati con risoluzione pari a 300 dpi nella directory

`data/preprocessed/metadata/plots/pca/`

in formato png.

Stima KDE delle feature selezionate La procedura `save_all_kde_plots()` realizza invece l'analisi densometrica delle tre caratteristiche definite dalla costante `KDE_TOP_FEATURES`, pari a `pkts_per_sec`, `total_bytes` e `dst_win_byt`. La selezione coincide quindi con il sottoinsieme di caratteristiche individuato a livello metodologico mediante l'aggregazione dei valori SHAP, come previsto nella Sezione 3.4.1.

A differenza della procedura PCA, nella funzione `save_all_kde_plots()` non viene applicato un filtraggio esplicito sulla colonna `split_type`: le caratteristiche selezionate vengono caricate direttamente dai file dei benchmark e utilizzate per la costruzione delle distribuzioni. Il riferimento statistico è nuovamente individuato tramite `SOURCE_IDENTIFIER`; uno `StandardScaler` viene adattato alle sole feature disponibili nel dataset sorgente.

Per ciascun benchmark, la trasformazione viene quindi applicata feature per feature utilizzando la media e il fattore di scala memorizzati nello scaler sorgente. La procedura implementa operativamente l'ancoraggio a (μ_S, σ_S) previsto dall'Equazione (3.40), mantenendo invariato il riferimento statistico anche per i benchmark target¹³.

La stima della densità viene effettuata mediante `seaborn.kdeplot()`, con separazione delle curve sulla base della classe binaria e con normalizzazione indipendente delle densità (`common_norm=False`). La regione sottostante le curve viene riempita mediante `fill=True`, mentre il parametro `cut=0` limita la rappresentazione all'intervallo definito dai dati osservati. Non

¹³Il vettore `scaler.scale_` calcolato da `StandardScaler` contiene la deviazione standard per ciascuna caratteristica, comprensiva del fattore di tolleranza $\epsilon > 0$ introdotto automaticamente dalla libreria per garantire la stabilità numerica ed evitare divisioni per zero in presenza di varianza nulla.

viene specificato esplicitamente alcun parametro di *bandwidth*: la larghezza del kernel è quindi determinata mediante il comportamento predefinito della procedura KDE utilizzata da seaborn.

Poiché l'implementazione deve consentire l'ispezione di distribuzioni caratterizzate da scale molto differenti e da possibili forti sbilanciamenti nella densità, l'asse verticale dei grafici viene rappresentato mediante una scala *symlog*, con parametro `linthresh=1e-5`¹⁴. Questa configurazione è distinta dalla formulazione teorica della proiezione logaritmica della densità riportata nella Sezione 3.4.1: nel codice non viene calcolato esplicitamente $\log_{10}(\hat{f}_y + \epsilon)$, ma viene modificata direttamente la scala dell'asse mediante le funzionalità grafiche di Matplotlib.

Le principali operazioni implementative della procedura sono sintetizzate nel Listato 4.5, che evidenzia l'adattamento dello standardizzatore sul benchmark sorgente, l'applicazione delle statistiche così ottenute ai benchmark considerati e la successiva generazione delle stime KDE.

Codice 4.5: Standardizzazione dipendente dal sorgente, trasformazione delle feature e generazione delle stime KDE.

```
1 scaler = StandardScaler().fit(df_source[valid_source_features])
2
3 for feature in valid_features:
4     if feature in scaler.feature_names_in_:
5         idx = list(scaler.feature_names_in_).index(feature)
6         mu_s = scaler.mean_[idx]
7         sigma_s = scaler.scale_[idx]
8         X_test_scaled[feature] = (X_test_raw[feature] - mu_s) / sigma_s
9
10 sns.kdeplot(
11     data=X_test_scaled, x=feature, hue=labels, fill=True, alpha=0.3, common_norm=False,
12     linewidth=2, palette={'Normal Traffic': '#1f77b4', 'Attack/Anomaly': '#ff7f0e'},
13     ax=ax, warn_singular=False, cut=0
14 )
15
16 ax.set_yscale('symlog', linthresh=1e-5)
```

¹⁴La scala *symlog* (Symmetric Logarithmic) applica una trasformazione logaritmica all'asse y mantenendo un intervallo puramente lineare all'interno della soglia $[-\text{linthresh}, +\text{linthresh}]$. Ciò previene divergenze verso $-\infty$ per densità prossime o pari a zero.

Per ciascun benchmark viene prodotto un pannello contenente una KDE per ogni feature disponibile tra quelle richieste. Le tre caratteristiche selezionate vengono pertanto visualizzate in forma affiancata, con asse orizzontale espresso in termini di *Z-Score* e asse verticale etichettato come densità. I grafici vengono salvati a 300 dpi nella directory

data/preprocessed/metadata/plots/kde/

con nomenclatura determinata dall'identificativo del benchmark e dal nome del dataset.

Nel complesso, le due procedure costituiscono istanze distinte del medesimo principio di standardizzazione diagnostica dipendente dal sorgente: la PCA utilizza il riferimento sorgente per costruire una trasformazione geometrica comune a tutti i benchmark, mentre la KDE utilizza il medesimo riferimento per rendere confrontabili, su scala adimensionale, le distribuzioni delle tre caratteristiche selezionate. La standardizzazione rimane in entrambi i casi confinata alla componente diagnostico-visiva del framework e **non modifica i dati impiegati dall'addestramento dei classificatori**, in accordo con la separazione metodologica stabilita nel Capitolo 3.

A completamento dell'analisi implementativa, la Tabella 4.19 riassume in modo sinottico le principali differenze operative e concettuali che intercorrono tra la procedura di proiezione PCA e la stima della densità KDE. Sebbene entrambe le funzioni condividano la medesima filosofia di standardizzazione ancorata al benchmark sorgente S , esse operano su granularità differenti: la PCA offre una vista spazio-geometrica ad ampio spettro sull'intero set di caratteristiche, mentre la KDE consente un'ispezione analitica e mirata sul comportamento distributivo delle singole variabili a più alto impatto decisionale.

Tabella 4.19: Confronto sinottico tra le procedure diagnostiche di proiezione PCA e stima della densità KDE nel modulo plotting.

Dimensione di Confronto	Procedura <code>save_all_pca_plots()</code>	Procedura <code>save_all_kde_plots()</code>
Obiettivo Diagnostico	Ispezione geometrica della separabilità globale e variabilità nello spazio 2D	Analisi densometrica univariata del <i>domain shift</i> sulle feature chiave
Partizione Input	Filtraggio esplicito della sola partizione di test	Dataset completo senza filtraggio sulla colonna <code>split_type</code>
Feature Considerate	Tutto lo spazio vettoriale (escluse colonne target e meta-dati)	Sottoinsieme ridotto Top-3 SHAP (<code>pkts_per_sec</code> , <code>total_bytes</code> , <code>dst_win_byt</code>)
Ancoraggio Statistico	Fit di <code>StandardScaler</code> e <code>PCA(n_components=2)</code> su $\mathbf{X}_{S,\text{test}}$	Fit di <code>StandardScaler</code> sulle sole 3 feature del sorgente S
Trasformazione Target	Applica <code>scaler.transform()</code> e <code>pca.transform()</code> congelati	Mappatura vettoriale ancorata: $Z_D = (X_D - \mu_S) / (\sigma_S + \epsilon)$
Spazio di Rappresentazione	Spazio proiettato bidimensionale (PC1 vs PC2) con % varianza spiegata	Asse orizzontale in Z-Score adimensionale; asse verticale in scala <code>symlog</code>
Output Grafico	Scatter plot 2D con distinzione cromatica binaria per classe	Pannelli affiancati di stime KDE riempite (<code>fill=True</code>)

4.6.2 Implementazione di SHAP e TreeSHAP

L'analisi di spiegabilità viene integrata nella pipeline di classificazione mediante la funzione `save_shap_plot()`, invocata da `classification_processing()`. La procedura riceve il modello precedentemente addestrato, la matrice delle caratteristiche del test set, le relative etichette e i metadati necessari alla generazione e alla persistenza della rappresentazione grafica. L'analisi rimane pertanto confinata alla fase diagnostica e non modifica il modello precedentemente

serializzato.

Prima della costruzione delle spiegazioni viene effettuato un campionamento stratificato e deterministico del test set (ancorato al seed di esecuzione), utilizzato per definire il dataset di background dell'algoritmo TreeSHAP. La dimensione massima del campione è fissata dalla costante `SHAP_MAX_SAMPLES=500`¹⁵. Le quote assegnate alle due classi sono calcolate mediante il parametro `NORMAL_ANOMALY_RATIO`, secondo:

$$N_{\text{anom}} = \left\lfloor \frac{\text{SHAP_MAX_SAMPLES}}{\text{NORMAL_ANOMALY_RATIO}} \right\rfloor, \quad N_{\text{norm}} = \text{SHAP_MAX_SAMPLES} - N_{\text{anom}}. \quad (4.14)$$

Nel codice il valore effettivamente assegnato a `NORMAL_ANOMALY_RATIO` è pari a 10 (corrispondente al rapporto di sbilanciamento $\rho = 10 : 1$), mentre il campionamento delle singole classi viene effettuato mediante `pandas.Series.sample()` con `random_state=127001`. Gli indici estratti per il traffico nominale e per quello anomalo vengono successivamente concatenati e utilizzati per selezionare le corrispondenti righe di `X_test`. Nel caso in cui non sia disponibile alcun campione valido, viene applicato un campionamento casuale del test set, anch'esso limitato a `SHAP_MAX_SAMPLES` e controllato dallo stesso seed.

L'implementazione completa della procedura di campionamento è riportata nel Listato A.6, raccolto nell'Appendice A.5.

La costruzione dello spiegatore viene effettuata dinamicamente in funzione del classificatore ricevuto. L'implementazione tenta inizialmente di utilizzare `shap.TreeExplainer`, configurato con `feature_perturbation="tree_path_dependent"`¹⁶ e `model_output="raw"`, opzioni orientate all'analisi di modelli ad albero quali `RandomForestClassifier` e `DecisionTreeClassifier`. Nel caso in cui tale configurazione non sia compatibile con il modello, viene eseguito un secondo tentativo mediante `shap.TreeExplainer(model)`. Qualora anche questa inizializzazione fallisca,

¹⁵Il sotto-campionamento deterministico del dataset di background costituisce una misura essenziale per contenere la complessità computazionale del calcolo dei valori di Shapley. Riducendo la cardinalità del campione di riferimento a una quota rappresentativa, si previene un incremento insostenibile dei tempi di esecuzione e dell'occupazione di memoria durante l'algoritmo TreeSHAP, preservando al contempo la convergenza stocastica delle stime empiriche e la stabilità delle spiegazioni rese.

¹⁶La modalità `tree_path_dependent` calcola le aspettative condizionali seguendo la struttura trasversale dei nodi degli alberi senza richiedere un dataset di *background* esplicito (a differenza dell'approccio *interventional*). Ciò riduce drasticamente il costo computazionale e gestisce la correlazione tra le variabili.

viene utilizzato il costrutto generico `shap.Explainer(model, X_test_sampled)`. Tale meccanismo consente di mantenere un'unica interfaccia di generazione delle spiegazioni anche in presenza delle differenti modalità di supporto offerte dalla libreria SHAP ai classificatori considerati, come evidenziato dalla struttura condizionale `try-except` del Listato 4.6.

Codice 4.6: Inizializzazione dinamica dello spiegatore SHAP con catena di fallback.

```
1 # Inizializzazione dinamica dello spiegatore per supportare RF, DT e HGB
2 try:
3     # Primo tentativo: TreeExplainer standard ottimizzato per RF e DT
4     explainer = shap.TreeExplainer(
5         model,
6         feature_perturbation="tree_path_dependent",
7         model_output="raw"
8     )
9 except Exception as explainer_err:
10     # Tentativo di fallback: TreeExplainer generico o Explainer universale
11     try:
12         explainer = shap.TreeExplainer(model)
13     except Exception:
14         explainer = shap.Explainer(model, X_test_sampled)
```

L'intera architettura della pipeline, articolata nelle sue quattro fasi di elaborazione (dal campionamento iniziale alla persistenza dell'artefatto), è schematizzata in Figura 4.9.




Figura 4.9: Architettura della pipeline di spiegabilità SHAP per i modelli di classificazione. Il diagramma illustra le quattro fasi sequenziali disposte in blocchi verticalmente allineati con connessioni di flusso circolare (effetto Pacman) sul margine destro/sinistro tra le diverse fasi.

I valori di Shapley vengono quindi calcolati sul campione selezionato mediante il metodo `shap_values()`. L'implementazione disabilita esplicitamente il controllo di additività mediante `check_additivity=False`¹⁷, quando tale argomento è supportato dallo specifico explainer. In caso contrario, viene eseguita una seconda chiamata senza tale parametro. La procedura prevede inoltre una normalizzazione della struttura restituita dalla libreria, necessaria a gestire le differenti

¹⁷La disabilitazione del controllo di additività previene l'interruzione improvvisa dell'esecuzione dovuta a microscopiche discrepanze numeriche dovute alla precisione in virgola mobile (*floating-point precision*) tra la somma dei valori SHAP e l'output teorico in modelli ad albero complessi.

rappresentazioni possibili dei valori SHAP. In particolare, quando viene restituita una lista di matrici corrispondenti alle due classi, viene selezionata la componente relativa alla classe positiva, ossia Attack/Anomaly. Analogamente, nel caso di un array tridimensionale, viene selezionata la componente associata all'indice di classe 1, mentre una matrice già bidimensionale viene utilizzata direttamente.

La spiegazione risultante è infine visualizzata mediante `shap.summary_plot()` utilizzando la configurazione `plot_type="dot"`. Tale rappresentazione associa a ciascuna caratteristica i valori SHAP osservati sui campioni selezionati, permettendo di rappresentare simultaneamente l'ampiezza e il verso del contributo delle singole variabili alla predizione. Il numero massimo di caratteristiche visualizzate viene impostato dinamicamente al numero di colonne della matrice `X_test_sampled`, mediante il parametro `max_display=n_features`. La dimensione verticale della figura viene inoltre adattata al numero complessivo di feature, secondo una dimensione minima di 6 pollici e un incremento proporzionale pari a 0.4 pollici per caratteristica.

L'implementazione completa della sequenza di calcolo, normalizzazione dimensionale e rendering è riportata nel Listato A.7, raccolto nell'Appendice A.5.

Il grafico SHAP prodotto viene salvato con risoluzione pari a 300 dpi nella directory `shap` e organizzata per modello. Il nome del file png viene costruito combinando il tipo di dataset, il nome del dataset. La procedura consente pertanto di mantenere separati gli artefatti di spiegabilità relativi ai diversi modelli e benchmark analizzati.

A completamento della descrizione implementativa, la Tabella 4.20 sintetizza i parametri principali definiti all'interno del modulo, esplicitando le configurazioni adottate e le rispettive motivazioni ingegneristiche.

Tabella 4.20: Sintesi dei parametri di configurazione e delle scelte ingegneristiche della pipeline SHAP.

Parametro = Impostazione	Scopo Ingegneristico e Funzionale
SHAP_MAX_SAMPLES = 500	Contenimento del costo computazionale e della complessità temporale $O(N)$ nel calcolo dei valori SHAP.
NORMAL_ANOMALY_RATIO = 10	Preservazione del rapporto di sbilanciamento nativo ($\rho = 10 : 1$) tra la classe nominale e quella anomala.
feature_perturbation = "tree_path_dependent"	Calcolo rapido delle aspettative condizionali lungo i percorsi degli alberi senza dipendenza da un dataset di <i>background</i> esplicito.
plot_type = "dot"	Visualizzazione ad alta densità che mostra simultaneamente ampiezza, verso e dispersione dei contributi di ciascuna caratteristica.
check_additivity = False	Prevenzione dell'interruzione della pipeline causata da microscopiche discrepanze numeriche di precisione in virgola mobile (<i>floating-point</i>).

Nel complesso, l'implementazione realizza una pipeline di spiegabilità indipendente dalla fase di addestramento: il modello già addestrato viene utilizzato come input per TreeExplainer o, quando necessario, per l'explainer generico di shap, mentre le spiegazioni vengono calcolate su un campione controllato del test set. Questa separazione mantiene coerente l'analisi con il principio metodologico secondo cui SHAP viene utilizzato come strumento diagnostico post-hoc per analizzare il contributo delle caratteristiche alle decisioni dei classificatori ad albero.

4.6.3 Pipeline di Aggregazione SHAP-KDE

Il raccordo tra l'analisi di spiegabilità SHAP e la successiva analisi densometrica KDE **non è implementato mediante una procedura automatizzata** all'interno del framework software¹⁸. La

¹⁸La scelta di non automatizzare tale raccordo previene la propagazione non controllata di rumore transitorio o di instabilità di *ranking* tra i differenti *seed* sperimentali.

selezione delle caratteristiche destinate alla rappresentazione KDE viene infatti effettuata attraverso un **passaggio di analisi manuale dei grafici SHAP** prodotti dalla pipeline diagnostica.

Al fine di formalizzare la natura ibrida di tale procedura, la Figura 4.10 illustra l'architettura logica del raccordo *Human-in-the-Loop*. Il diagramma evidenzia la scomposizione del flusso di lavoro in tre fasi sequenziali: una prima fase di automazione diagnostica, una fase intermedia di supervisione umana in cui avviene l'estrazione quantitativa del parametro empirico, e una successiva fase di esecuzione densometrica automatizzata.




Figura 4.10: Diagramma architetturale del raccordo *Human-in-the-Loop* tra l'analisi diagnostica (SHAP) e la valutazione densometrica (KDE). L'intervento manuale (Fase 2) funge da disaccoppiamento metodologico tra le due pipeline automatizzate.

Per ciascun grafico SHAP generato vengono considerate le prime tre caratteristiche riportate nel `summary_plot`. Poiché la rappresentazione `plot_type="dot"` ordina le caratteristiche sulla base della loro rilevanza globale, le prime tre righe del grafico costituiscono il sottoinsieme di interesse per la procedura di conteggio. L'analisi viene ripetuta considerando tutti i grafici SHAP prodotti per le combinazioni di modelli, benchmark e seed previste dal protocollo sperimentale.

A partire da tale ispezione viene costruito manualmente un contatore per ciascuna caratteristica j , definito come:

$$C_j = \sum_{r=1}^R \mathbb{I}(j \in \mathcal{T}_r), \quad (4.15)$$

dove R rappresenta il numero complessivo di grafici SHAP analizzati, $\mathcal{T}_r$ denota l'insieme delle tre caratteristiche collocate nelle prime posizioni del grafico r e $\mathbb{I}(\cdot)$ è la funzione indicatrice. Di conseguenza, C_j esprime il numero di occorrenze con cui la caratteristica j compare tra le prime tre posizioni nelle spiegazioni considerate. I risultati del conteggio empirico effettuato sulle spiegazioni diagnostiche sono sintetizzati nella Tabella 4.21.

Tabella 4.21: Distribuzione delle frequenze di occorrenza C_j delle caratteristiche registrate nelle prime tre posizioni dei grafici SHAP.

Caratteristica (j)	Occorrenze (C_j)	Frequenza Relativa (C_j/R)
pkts_per_sec	C_1	$\sim 18.89\%$
total_bytes	C_2	$\sim 17.04\%$
dst_win_byt	C_3	$\sim 11.67\%$

La frequenza così ottenuta viene utilizzata come criterio empirico di selezione delle caratteristiche da sottoporre alla successiva stima KDE. Le tre caratteristiche caratterizzate dai valori di C_j più elevati sono risultate essere `pkts_per_sec`, `total_bytes` e `dst_win_byt`. La selezione viene quindi trasferita manualmente nella configurazione del framework mediante la costante

```
KDE_TOP_FEATURES = ['pkts_per_sec', 'total_bytes', 'dst_win_byt']
```

La funzione `save_all_kde_plots()` utilizza successivamente tale lista come insieme di caratteristiche da analizzare, senza ricalcolare automaticamente il conteggio C_j né eseguire una nuova selezione sulla base dei grafici SHAP. Il passaggio SHAP–KDE deve pertanto essere inteso come una **procedura di selezione supervisionata manualmente dall'analista**: SHAP fornisce il criterio diagnostico per individuare le caratteristiche più ricorrenti nelle posizioni di maggiore rilevanza, mentre la KDE costituisce lo strumento successivo per l'ispezione delle rispettive distribuzioni.

Nel protocollo adottato non si è verificata alcuna situazione di parità tra caratteristiche nei valori del contatore C_j ¹⁹ tali da richiedere una regola di spareggio. La lista finale KDE_TOP_FEATURES rappresenta pertanto la selezione conclusiva utilizzata nella fase di analisi densometrica descritta nella Sezione 4.6.1.

4.7 Sintesi della Pipeline Implementativa

La pipeline implementativa descritta nel presente capitolo costituisce la traduzione operativa del framework metodologico definito nel Capitolo 3. L'architettura è organizzata in moduli logicamente distinti, corrispondenti alle principali fasi del ciclo di elaborazione: acquisizione e armonizzazione dei dati, costruzione dei benchmark, addestramento multi-seed, inferenza, valutazione e analisi diagnostica. Tale decomposizione consente di mantenere separati il flusso computazionale principale e le procedure di analisi, preservando la modularità dell'infrastruttura software e la riproducibilità delle singole fasi. Inoltre, la struttura disaccoppiata garantisce un'elevata estensibilità dell'architettura software: l'integrazione di nuovi dataset target o l'inclusione di ulteriori algoritmi di classificazione può essere effettuata in modo trasparente, agendo unicamente sulle definizioni contenute nel file di configurazione centralizzato (`config.py`), senza dover modificare la logica di elaborazione dei singoli moduli computazionali.

La Tabella 4.22 riassume la mappa dei moduli Python sviluppati, i rispettivi file sorgente, le responsabilità primarie e i flussi di Input/Output che attraversano l'architettura software.

¹⁹In caso di parità nel contatore C_j , la regola formale di spareggio avrebbe previsto un ordinamento secondario decrescente basato sull'impatto medio assoluto di Shapley $|\bar{\phi}_j| = \frac{1}{R} \sum_{r=1}^R |\phi_{j,r}|$, calcolato esclusivamente sulle esecuzioni che hanno generato l'ex aequo.

Tabella 4.22: Riepilogo dell'architettura software end-to-end.

File Sorgente	Responsabilità Principale	Input / Output
Punto di Ingresso		
main.py	Gestione CLI interattiva e orchestrazione del ciclo esecutivo multi-seed (s_0 e S).	In: Comandi CLI, parametri Out: Trigger pipeline esecutive
Allineamento Feature		
src/data_preprocessing.py	Mappatura ψ_k , derivazione metriche e allineamento allo spazio coordinato ($d = 16$).	In: Dataframe parziali Out: Dataframe coordinati (16 feature)
Core Preprocessing		
src/file_preprocessing.py	Pulizia, campionamento stratificato ($\rho = 10$), bilanciamento e split 80/20 train/test.	In: Dataframe coordinati Out: Benchmark (data/preprocessed/)
Gestione Modelli		
src/models.py	Istanziamento, fitting dei classificatori (DT, RF, HGB), naming e serializzazione pesi.	In: Dataset pre-processati Out: Pesi .joblib, update models_metadata.csv
Inferenza & Valutazione		
src/classification.py	Inferenza sui test set, generazione matrici di confusione e calcolo metriche.	In: Modelli .joblib e test set Out: CSV risultati in runs/.../results/
Diagnostica & Visualizzazione		
src/plotting.py	Mappe di calore, diagnostica spaziale (PCA, KDE con StandardScaler) e XAI (TreeSHAP).	In: Matrici, log e dataset Out: Grafici e diagrammi (PNG/PDF)
Configurazione		
src/utils/config.py	Centralizzazione costanti (MLConstants, $\rho = 10$, semi stocastici, path).	In: N.D. Out: Parametri globali di runtime

I/O & Persistenza		
src/utls/file_utils.py	Gestione I/O su disco, salvataggio/caricamento sicuro di artefatti e registri CSV.	In: Oggetti Python, file dati Out: Persistenza strutturata su disco
Metriche Spiegabili		
src/utls/metrics.py	Formalizzazione e calcolo sintetico delle metriche (Accuracy, F1, ROC-AUC, ecc.).	In: Vettori etichette y e $\hat{y}$ Out: Dizionari/Dataframe di metriche

Il processo ha origine dai domini sorgente e target, i cui dati vengono sottoposti alle procedure di filtraggio e allineamento descritte nella Sezione 4.3. L'operatore ψ_k riconduce le rappresentazioni eterogenee a uno spazio condiviso di caratteristiche, sul quale vengono successivamente applicati i criteri di composizione e partizionamento necessari alla costruzione dei benchmark sperimentali. I dataset risultanti costituiscono l'input del modulo di classificazione, senza introdurre alcuna ulteriore scalatura esplicita nel flusso principale, in accordo con quanto discusso nella Sezione 4.3.3.

La fase di apprendimento viene quindi eseguita mediante l'istanziatura dei classificatori *Decision Tree*, *Random Forest* e *Histogram-based Gradient Boosting*, ripetuta sui semi stocastici definiti dal protocollo. Per ogni combinazione tra algoritmo, benchmark e seme vengono prodotti gli artefatti relativi al modello e ai relativi metadati, mantenendo l'isolamento delle diverse esecuzioni nella struttura gerarchica della directory `runs/`.

I modelli così ottenuti vengono successivamente utilizzati nella fase di inferenza sugli insiemi di test, generando predizioni e punteggi di probabilità SHAP. Le predizioni e i relativi punteggi alimentano il calcolo delle metriche e la costruzione delle matrici di valutazione, mentre l'aggregazione delle osservazioni sui diversi semi fornisce gli ingressi per la successiva procedura di confronto statistico. Gli artefatti prodotti lungo tale percorso vengono persistiti secondo la struttura organizzativa descritta nella Sezione 4.1.1, mantenendo distinti modelli, risultati e prodotti delle analisi.

Parallelamente al flusso principale opera il modulo diagnostico. La standardizzazione utilizzata per PCA e KDE viene mantenuta separata dal grafo computazionale di training e inferenza. Le caratteristiche individuate mediante l'ispezione dei grafici SHAP vengono quindi utilizzate per

configurare l'analisi KDE, secondo la procedura supervisionata descritta nella Sezione 4.6.3.

La composizione complessiva degli stadi implementativi è sintetizzata nella Figura 4.11, che evidenzia il flusso principale della pipeline e il relativo ramo diagnostico.




Figura 4.11: Architettura software end-to-end e flusso di esecuzione unificato: dall'ingestione dei dataset grezzi, passando per l'armonizzazione delle feature e il ciclo di addestramento multi-seed, fino alla biforcazione tra ramo inferenziale (valutazione prestazionale) e ramo diagnostico (PCA, KDE e TreeSHAP).

La Figura 4.11 evidenzia pertanto la separazione funzionale tra il percorso principale, destinato alla costruzione e alla valutazione degli stimatori, e il ramo diagnostico, dedicato alla caratterizzazione geometrica, distributiva e interpretativa dei dati e dei modelli. La persistenza degli artefatti costituisce il punto comune tra le diverse fasi, consentendo di mantenere disponibili modelli, metriche, matrici e rappresentazioni grafiche secondo una struttura riproducibile.

La descrizione implementativa si conclude con la definizione di tale catena end-to-end. Gli output generati dalla pipeline costituiscono quindi la base documentale e quantitativa sulla quale viene sviluppata, nel Capitolo 5, l'analisi dei risultati sperimentali.

5. Analisi dei Risultati e Discussione Sperimentale

Il presente capitolo espone e analizza i risultati ottenuti mediante il protocollo sperimentale implementato nel Capitolo 4, ponendo particolare attenzione alla capacità delle differenti configurazioni di classificazione di mantenere un comportamento discriminativo stabile in presenza di variazioni del dominio di traffico.

L'analisi viene condotta secondo una progressione coerente con il framework metodologico definito nel Capitolo 3. In primo luogo, viene esaminata la struttura geometrica e distributiva dei benchmark mediante gli strumenti diagnostici PCA e KDE, al fine di caratterizzare preliminarmente l'entità dello scostamento tra il dominio sorgente e le configurazioni contenenti traffico target. Successivamente, vengono valutate le prestazioni della baseline *INJECTION*, assunta come riferimento sperimentale, e confrontate separatamente con quelle dei modelli addestrati esclusivamente sul dominio sorgente e con quelle dei modelli ibridi.

La valutazione quantitativa viene sviluppata combinando i risultati puntuali ottenuti per il seed rappresentativo $s = 42$ con le statistiche aggregate sulle $K = 10$ repliche stocastiche definite nel protocollo *multi-seed*. Tale impostazione consente di distinguere la descrizione analitica delle singole configurazioni dalla verifica della stabilità dei risultati rispetto all'inizializzazione degli stimatori. Il confronto viene infine completato mediante il test t di Welch sull'*F1-Score* e attraverso l'analisi post-hoc SHAP delle caratteristiche maggiormente coinvolte nelle decisioni dei classificatori.

La parte conclusiva del capitolo integra quindi le evidenze prestazionali, distributive e di spiegabilità, con l'obiettivo di individuare associazioni coerenti tra variazioni dello spazio delle caratteristiche e comportamento predittivo. Le eventuali relazioni individuate vengono interpretate nei limiti consentiti dagli artefatti sperimentali disponibili, distinguendo le evidenze direttamente osservabili dalle interpretazioni compatibili con il protocollo sperimentale.

5.1 Diagnostica Spaziale e Distributiva

Prima di procedere alla valutazione quantitativa dei classificatori, viene caratterizzata la disposizione dei benchmark nello spazio condiviso delle caratteristiche X mediante gli strumenti diagnostici

PCA e KDE implementati nella Sezione 4.6.1. L'analisi considera tre configurazioni rappresentative del protocollo: il benchmark sorgente NB15, la baseline INJECTION e il benchmark ibrido NB15_STIN. Tale sequenza descrive il passaggio da una componente malevola interamente sorgente, a una configurazione contenente una conoscenza target sparsa, fino alla sostituzione completa degli attacchi sorgente con traffico malevolo target.

A seguito del ricampionamento con rapporto $\rho_{\text{ben/mal}} = 10/1$, ciascun benchmark aggregato comprende 102 300 osservazioni, delle quali 93 000 nominali e 9 300 malevole. La proporzione tra le due macro-classi rimane quindi invariata; ciò che varia tra le configurazioni è la composizione e la distribuzione della componente malevola.

5.1.1 Proiezioni PCA dello Spazio delle Feature

Riferimento statistico e composizione dei test set. L'Analisi delle Componenti Principali viene impiegata esclusivamente a scopo diagnostico sulle partizioni di test, utilizzando il sistema di riferimento dipendente dal dominio sorgente definito nel Capitolo 4. Lo standardizzatore è adattato su NB15 e le statistiche (μ_S, σ_S) così ottenute vengono mantenute fisse per le configurazioni successive. Analogamente, la matrice degli autovettori $\mathbf{W}_S$ viene determinata una sola volta mediante il fitting della PCA sul benchmark sorgente standardizzato. Un generico benchmark D viene pertanto proiettato secondo

$$\mathbf{P}_D = \left(\frac{\mathbf{X}_D - \mu_S}{\sigma_S + \epsilon} \right) \mathbf{W}_S, \quad (5.1)$$

senza ricalcolare localmente lo standardizzatore o gli assi principali.

Le tre partizioni di test presentano la medesima cardinalità, pari a 20 460 osservazioni, suddivise in 18 600 campioni nominali e 1 860 malevoli. La composizione della classe positiva risulta tuttavia differente: in NB15 tutti i 1 860 attacchi appartengono al dominio sorgente; in INJECTION, 1 854 sono sorgente e soltanto 6 sono target; in NB15_STIN, tutti i 1 860 attacchi provengono invece da STIN. I 6 campioni target presenti nel test set INJECTION comprendono 1 Botnet, 1 DDoS e 4 UDP_DDoS, senza osservazioni Syn_DDoS. Nel test set NB15_STIN, la componente positiva è costituita da 349 Botnet, 497 DDoS, 494 Syn_DDoS e 520 UDP_DDoS.

Le prime due componenti spiegano rispettivamente il 40.35% e il 16.00% della varianza della distribuzione sorgente, per una quota complessiva pari al 56.36%. Poiché scaler e PCA rimangono

congelati, tali percentuali identificano il sistema di coordinate definito da NB15 e non implicano che i tre benchmark possiedano la medesima struttura di varianza.




Figura 5.1: Proiezione PCA bidimensionale del benchmark sorgente NB15 nel sistema di riferimento ottenuto mediante standardizzazione e fitting sul dominio sorgente.

Distribuzione geometrica del dominio sorgente. La Figura 5.1 costituisce il riferimento geometrico dell'analisi. La maggior parte delle osservazioni occupa una regione relativamente compatta e curvilinea del piano, accompagnata da estensioni periferiche lungo entrambe le componenti. All'interno della regione principale è presente una consistente sovrapposizione tra traffico nominale e malevolo, mentre alcune osservazioni anomale assumono posizioni più periferiche.

Le prime due componenti non evidenziano pertanto una separazione globale netta delle classi. Poiché la PCA non utilizza l'etichetta Y nella costruzione degli assi, tale risultato indica esclusivamente che la struttura discriminativa dello spazio originario a 16 dimensioni non è riconducibile a una semplice separazione lineare nel piano formato da PC1 e PC2.




Figura 5.2: Proiezione PCA bidimensionale del benchmark INJECTION, utilizzato per l'addestramento della baseline $\mathcal{M}_{\text{base}}$, nel sistema di riferimento PCA definito dal dominio sorgente.

Effetto dell'iniezione target sparsa. La configurazione INJECTION, mostrata nella Figura 5.2, conserva una geometria complessivamente prossima a quella sorgente. Dei 1 860 campioni malevoli del test set, infatti, 1 854 appartengono a NB15 (99.68%) e soltanto 6 a STIN (0.32%). La regione maggiormente popolata rimane quindi dominata dalla distribuzione sorgente e conserva l'estesa sovrapposizione tra le due macro-classi osservata in Figura 5.1.

Sono contestualmente presenti osservazioni malevole collocate a notevole distanza dal nucleo principale. La loro posizione è compatibile con valori fortemente esterni alla distribuzione dominante; tuttavia, la rappresentazione codifica esclusivamente le classi *Normal Traffic* e *Attack/Anomaly*, senza distinguere il dominio di origine dei singoli campioni. Non è pertanto possibile attribuire visivamente tali punti periferici ai 6 campioni target presenti nel test set.




Figura 5.3: Proiezione PCA bidimensionale del benchmark ibrido NB15_STIN, composto da traffico nominale sorgente NB15 e traffico malevolo target STIN, nel sistema di riferimento PCA definito dal dominio sorgente.

Sostituzione completa della componente malevola. Una configurazione sostanzialmente differente emerge per NB15_STIN, riportato nella Figura 5.3. In questo caso tutti i 1 860 campioni positivi del test set appartengono a STIN. Proiettati nel sistema statistico adattato esclusivamente su NB15, tali vettori raggiungono coordinate di ordine sensibilmente superiore rispetto al benchmark sorgente, con una scala del piano dell'ordine di 10^6 . Il traffico nominale appare conseguentemente compresso nell'intorno dell'origine, pur mantenendo invariata la propria cardinalità di 18 600 campioni.

L'interpretazione della separazione richiede tuttavia una cautela fondamentale: in NB15_STIN, classe e dominio di origine risultano strutturalmente associati,

$$Y = 0 \Rightarrow D = \text{NB15}, \quad Y = 1 \Rightarrow D = \text{STIN}.$$

La distanza osservata nel piano PCA incorpora quindi sia la differenza tra classe nominale e malevola sia lo scostamento distributivo tra i due domini, senza consentire di separarne i rispettivi

contributi. La proiezione fornisce pertanto evidenza diagnostica di un marcato scostamento rispetto al riferimento sorgente, ma non permette di attribuirlo esclusivamente alla separabilità delle classi.

Sintesi dell'evidenza PCA. Le tre proiezioni descrivono una progressione geometrica coerente con la composizione della componente malevola: NB15 costituisce il riferimento, INJECTION rimane largamente dominato dal sorgente, mentre NB15_STIN presenta un marcato scostamento nel sistema di coordinate ancorato a NB15. La PCA non identifica tuttavia quali caratteristiche dello spazio originario siano maggiormente associate a tale variazione; questo aspetto viene approfondito mediante l'analisi densometrica successiva.

5.1.2 Stime di Densità di Kernel (KDE) e Domain Shift

Impostazione dell'analisi distributiva. L'analisi PCA viene affiancata da un'ispezione delle distribuzioni marginali mediante *Kernel Density Estimation* (KDE). L'analisi è circoscritta alle tre caratteristiche selezionate mediante la procedura SHAP-KDE descritta nel Capitolo 4: `pkts_per_sec`, `total_bytes` e `dst_win_byt`.

I valori sono rappresentati mediante la standardizzazione dipendente dal sorgente definita nel framework metodologico. Di conseguenza, $z = 0$ corrisponde alla media sorgente della specifica caratteristica e gli scostamenti sono espressi rispetto alle statistiche calcolate su NB15.

A differenza della PCA, la routine KDE considera l'intero benchmark ricampionato e non soltanto la partizione di test. Ciascuna configurazione comprende quindi 93 000 campioni nominali e 9 300 malevoli. In NB15 tutti gli attacchi sono sorgente; in INJECTION la componente positiva comprende 9 271 attacchi sorgente e 29 target; in NB15_STIN tutti i 9 300 attacchi appartengono invece al dominio target.

Le densità delle due macro-classi sono normalizzate indipendentemente (`common_norm=False`); l'altezza relativa delle curve non esprime pertanto la diversa numerosità delle classi. L'interpretazione riguarda posizione, dispersione, estensione e sovrapposizione dei rispettivi supporti.

A supporto delle rappresentazioni grafiche, le statistiche disponibili per le singole famiglie d'attacco sono aggregate nelle rispettive componenti malevole. Indicando con C_A l'insieme delle

classi malevole, la media aggregata è

$$\mu_A = \frac{\sum_{c \in C_A} n_c \mu_c}{\sum_{c \in C_A} n_c}, \quad (5.2)$$

mentre la varianza complessiva, comprendente sia la dispersione interna alle classi sia quella tra le rispettive medie, è

$$\sigma_A^2 = \frac{\sum_{c \in C_A} [(n_c - 1)\sigma_c^2 + n_c(\mu_c - \mu_A)^2]}{\sum_{c \in C_A} n_c - 1}. \quad (5.3)$$

La Tabella 5.1 riporta le statistiche così ottenute. I valori descrivono le popolazioni di classe originarie dalle quali sono costruiti i benchmark ricampionati e devono essere utilizzati come riferimento quantitativo dello scostamento distributivo, non come coordinate Z-score dei singoli punti rappresentati nelle KDE.

Tabella 5.1: Statistiche descrittive delle tre feature KDE per il traffico nominale sorgente e per le componenti malevole di NB15, INJECTION e NB15_STIN.

Configurazione	Componente	pkts_per_sec		total_bytes		dst_win_byt	
		μ	σ^2	μ	σ^2	μ	σ^2
NB15	Nominale	6.7933×10^4	5.7237×10^{10}	3.0231×10^4	1.7286×10^{10}	176.6758	1.3836×10^4
NB15	Malevola	2.0131×10^5	5.1871×10^{10}	1.9513×10^4	7.4651×10^{10}	87.5202	1.4658×10^4
INJECTION	Malevola	4.5475×10^8	9.0889×10^{20}	1.9463×10^4	7.4455×10^{10}	87.2266	1.4635×10^4
NB15_STIN	Malevola	1.1202×10^{11}	2.1150×10^{23}	1.0891×10^3	1.4180×10^6	-0.7813	4.0057×10^3




Figura 5.4: Stime KDE delle feature `pkts_per_sec`, `total_bytes` e `dst_win_byt` per il benchmark sorgente NB15, espresse mediante standardizzazione ancorata al dominio sorgente.

Distribuzioni del dominio sorgente. La Figura 5.4 costituisce il riferimento distributivo dell'analisi. Per `pkts_per_sec`, entrambe le macro-classi presentano un'elevata concentrazione in prossimità della regione centrale e una consistente sovrapposizione. Come riportato nella Tabella 5.1, le rispettive varianze risultano dello stesso ordine di grandezza, confermando un'elevata dispersione intraclasse.

Anche `total_bytes` presenta supporti ampiamente sovrapposti, con una dispersione della componente malevola superiore a quella nominale. `dst_win_byt` mostra invece una struttura più articolata e bimodale, accompagnata da varianze confrontabili tra le due macro-classi. Nel complesso, nessuna delle tre feature produce isolatamente una separazione distributiva semplice e completa tra traffico nominale e malevolo, in accordo con la sovrapposizione osservata nel piano PCA sorgente.




Figura 5.5: Stime KDE delle feature `pkts_per_sec`, `total_bytes` e `dst_win_byt` per il benchmark INJECTION, utilizzato per l'addestramento della baseline $\mathcal{M}_{\text{base}}$.

Effetto distributivo dell'iniezione sparsa. La configurazione INJECTION, mostrata nella Figura 5.5, conserva una morfologia dominante prossima al dominio sorgente, coerentemente con la presenza di soli 29 campioni target sui 9 300 attacchi complessivi, pari a circa lo 0.31% della componente malevola.

La variazione più evidente interessa `pkts_per_sec`. Alla regione principale, ancora dominata dagli attacchi NB15, si affianca una coda estremamente estesa verso valori positivi dello Z-score. Rispetto alla componente malevola sorgente, la media aggregata aumenta di oltre tre ordini di grandezza, mentre la varianza cresce di oltre dieci ordini. Una quota target numericamente ridotta produce quindi un effetto chiaramente osservabile sui primi due momenti di questa caratteristica, senza modificare la regione di maggiore densità del benchmark.

Un comportamento differente emerge per `total_bytes` e `dst_win_byt`. Per entrambe le

caratteristiche, media e varianza della componente malevola rimangono prossime ai corrispondenti valori NB15 riportati nella Tabella 5.1, coerentemente con la forte dominanza numerica della componente sorgente.

L'effetto dell'iniezione risulta pertanto eterogeneo tra le dimensioni analizzate: lo scostamento è già marcato per `pkts_per_sec`, mentre risulta molto più contenuto per `total_bytes` e `dst_win_byt`. Il *domain shift* non assume quindi la forma di una traslazione uniforme dell'intero spazio delle caratteristiche.




Figura 5.6: Stime KDE delle feature `pkts_per_sec`, `total_bytes` e `dst_win_byt` per il benchmark ibrido NB15_STIN, costituito da traffico nominale sorgente NB15 e traffico malevolo target STIN.

Domain shift nella configurazione ibrida. La sostituzione completa della componente malevola in NB15_STIN, mostrata nella Figura 5.6, determina una variazione distributiva sensibilmente più pronunciata.

Per `pkts_per_sec`, la media della componente malevola passa da 2.0131×10^5 nel dominio sorgente a 1.1202×10^{11} nel traffico STIN, con un rapporto superiore a 5.5×10^5 . La varianza aumenta contestualmente da 5.1871×10^{10} a 2.1150×10^{23} , ossia di oltre dodici ordini di grandezza. Quando tali osservazioni vengono standardizzate mediante le statistiche sorgente, la presenza di Z-score dell'ordine di 10^6 risulta pertanto coerente con la scala dei momenti empirici e non costituisce di per sé un'anomalia della procedura diagnostica.

Per `total_bytes`, lo scostamento assume una forma differente: la media malevola si riduce da circa 1.95×10^4 Byte a 1.09×10^3 Byte, pari a circa il 5.6% del valore sorgente, mentre la varianza presenta una forte contrazione. Il traffico malevolo target occupa quindi una regione caratterizzata da volumi complessivi inferiori e da una dispersione sensibilmente ridotta.

Anche `dst_win_byt` evidenzia una modifica strutturale: la media passa da 87.52 per gli attacchi NB15 a circa -0.78 per STIN, mentre la varianza diminuisce da circa 1.47×10^4 a 4.01×10^3 . La distribuzione target risulta conseguentemente concentrata in regioni differenti rispetto a quelle maggiormente popolate dal traffico nominale sorgente.

Le tre caratteristiche descrivono quindi modalità distinte di variazione cross-domain: `pkts_per_sec` combina una forte traslazione con una marcata espansione della dispersione; `total_bytes` presenta una riduzione della posizione centrale e una contrazione della varianza; `dst_win_byt` modifica sia la posizione sia la concentrazione della distribuzione. Lo scostamento tra NB15 e STIN non risulta pertanto riconducibile a una singola trasformazione di scala, ma interessa in modo eterogeneo le diverse dimensioni osservate.

Raccordo tra evidenza PCA e KDE. Le analisi PCA e KDE forniscono evidenze diagnostiche complementari. La prima descrive lo scostamento geometrico globale dei benchmark nel sistema di riferimento costruito sul sorgente; la seconda identifica specifiche dimensioni lungo le quali la variazione distributiva risulta osservabile.

In INJECTION, la forte prevalenza della componente sorgente mantiene la geometria complessiva prossima a NB15, mentre la KDE evidenzia già una variazione particolarmente marcata di `pkts_per_sec`. In NB15-STIN, la sostituzione completa della componente malevola è invece associata sia al marcato scostamento nel piano PCA sia a variazioni sostanziali delle tre distribuzioni analizzate.

Tale corrispondenza non consente tuttavia di attribuire alle sole feature selezionate mediante KDE la geometria osservata nella PCA, poiché quest'ultima è calcolata sull'intero spazio condiviso delle 16 caratteristiche. Le due analisi descrivono quindi livelli differenti e complementari del medesimo fenomeno distributivo.

Sintesi della diagnostica distributiva. La diagnostica distingue tre regimi sperimentali: un riferimento sorgente caratterizzato da ampia sovrapposizione tra le macro-classi; una configurazione INJECTION che conserva prevalentemente la struttura sorgente ma rende già osservabile la presenza target lungo specifiche dimensioni; e NB15_STIN, nel quale la sostituzione completa della componente malevola produce il maggiore scostamento distributivo tra le configurazioni considerate.

Tale quadro costituisce il riferimento per la successiva analisi prestazionale, nella quale viene verificato se la conoscenza target sparsa introdotta mediante soli 29 campioni malevoli su 9 300 sia associata a un miglioramento della risposta cross-domain rispetto ai modelli puramente sorgente e come tale comportamento differisca dalla specializzazione ottenuta con i benchmark ibridi.

5.2 Valutazione della Baseline INJECTION

A valle della caratterizzazione geometrica e distributiva sviluppata nella Sezione 5.1, l'analisi si concentra sulla configurazione di riferimento $\mathcal{M}_{\text{base}}$, addestrata sul benchmark INJECTION. Tale configurazione conserva prevalentemente la componente malevola sorgente e integra 29 campioni provenienti da STIN sui 9 300 attacchi complessivamente presenti nel benchmark, pari a circa lo 0.31% della classe positiva.

La medesima strategia di composizione del training set viene applicata ai tre classificatori considerati nel framework: Decision Tree (DT), Histogram-based Gradient Boosting (HGB) e Random Forest (RF). Ciascuna istanza viene successivamente valutata sui 16 benchmark previsti dal protocollo di cross-evaluation, consentendo di confrontarne il comportamento sul dominio sorgente, sul benchmark INJECTION e sulle distribuzioni target aggregate e biclasse.

La valutazione viene sviluppata secondo due livelli complementari. La Sottosezione 5.2.1 analizza il profilo prestazionale, assumendo TPR e TNR come metriche operative principali e

utilizzando Precision, F1-Score, PR-AUC e cardinalità della matrice di confusione come supporto interpretativo. La Sottosezione 5.2.2 esamina invece, mediante SHAP, le caratteristiche maggiormente coinvolte nelle funzioni decisionali delle tre architetture.

5.2.1 Prestazioni Quantitative del Modello di Baseline

Criterio di lettura dei risultati. L'analisi puntuale utilizza l'esecuzione associata al seed rappresentativo $s = 42$, mantenendo invariata la composizione dei benchmark ottenuta mediante il seed deterministico di preprocessing $s_0 = 127001$. La stabilità rispetto all'inizializzazione degli stimatori viene analizzata successivamente sulle $K = 10$ repliche previste dal protocollo multi-seed.

Tutti i test set condividono la medesima cardinalità: 18 600 campioni nominali e 1 860 malevoli, per un totale di 20 460 osservazioni. Tale uniformità rende direttamente confrontabili anche le cardinalità TP , TN , FP e FN . La lettura prestazionale viene tuttavia condotta prioritariamente mediante

$$TPR = \text{Recall}, \quad TNR,$$

che descrivono rispettivamente la sensibilità verso il traffico malevolo e la capacità di preservare il traffico nominale. La matrice completa delle cardinalità ottenute sui 16 benchmark è riportata in Tabella B.1, in Appendice B.1.

Preservazione del traffico nominale e sensibilità agli attacchi. La componente nominale produce un comportamento costante attraverso i 16 benchmark per ciascun classificatore: DT registra 18 305 veri negativi e 295 falsi positivi, HGB rispettivamente 18 540 e 60, mentre RF produce 18 422 veri negativi e 178 falsi positivi. Tale regolarità è coerente con la costruzione sperimentale, nella quale la componente nominale dei diversi test set deriva dalla medesima distribuzione sorgente NB15. La variabilità cross-domain interessa quindi principalmente la risposta alla classe positiva.

La Tabella 5.2 riporta Precision, TPR e TNR per l'intera cross-evaluation.

Tabella 5.2: Precision, TPR e TNR della baseline INJECTION con DT, HGB e RF sui 16 test set per il seed $s = 42$.

Test Set	DT			HGB			RF		
	Precision	TPR	TNR	Precision	TPR	TNR	Precision	TPR	TNR
nb15 (aggregato)	0.8391	0.8274	0.9841	0.9611	0.7968	0.9968	0.8958	0.8226	0.9904
nb15 (DoS)	0.8516	0.9102	0.9841	0.9649	0.8860	0.9968	0.9055	0.9167	0.9904
nb15 (Exploits)	0.8416	0.8425	0.9841	0.9621	0.8183	0.9968	0.8998	0.8591	0.9904
nb15 (Fuzzers)	0.6402	0.2823	0.9841	0.8492	0.1817	0.9968	0.7166	0.2419	0.9904
nb15 (Generic)	0.8620	0.9909	0.9841	0.9685	0.9909	0.9968	0.9119	0.9909	0.9904
nb15 (Reconnaissance)	0.8459	0.8704	0.9841	0.9647	0.8828	0.9968	0.8997	0.8581	0.9904
injection (aggregato)	0.8388	0.8253	0.9841	0.9617	0.8097	0.9968	0.8958	0.8231	0.9904
nb15_stin (aggregato)	0.8585	0.9624	0.9841	0.9590	0.7554	0.9968	0.9123	0.9952	0.9904
nb15_sat20 (aggregato)	0.8619	0.9898	0.9841	0.9636	0.8543	0.9968	0.9126	0.9995	0.9904
nb15_sat20 (Syn_DDoS)	0.8608	0.9812	0.9841	0.9618	0.8129	0.9968	0.9127	1.0000	0.9904
nb15_sat20 (UDP_DDoS)	0.8630	0.9995	0.9841	0.9654	0.8989	0.9968	0.9126	0.9995	0.9904
nb15_ter20 (aggregato)	0.8559	0.9419	0.9841	0.9557	0.6962	0.9968	0.9119	0.9903	0.9904
nb15_ter20 (Botnet)	0.8472	0.8796	0.9841	0.9615	0.8054	0.9968	0.9125	0.9984	0.9904
nb15_ter20 (DDoS)	0.8631	1.0000	0.9841	0.9625	0.8274	0.9968	0.9127	1.0000	0.9904
nb15_ter20 (Syn_DDoS)	0.8588	0.9645	0.9841	0.0000	0.0000	0.9968	0.9068	0.9306	0.9904
nb15_ter20 (UDP_DDoS)	0.8494	0.8946	0.9841	0.9554	0.6914	0.9968	0.9127	1.0000	0.9904

La TNR distingue chiaramente i tre profili: HGB raggiunge 0.9968, RF 0.9904 e DT 0.9841. HGB produce pertanto il numero più contenuto di falsi positivi, ma tale vantaggio non coincide con una sensibilità altrettanto uniforme.

Sui benchmark target aggregati, infatti, la TPR di HGB è pari a 0.7554 su nb15_stin, 0.8543 su nb15_sat20 e 0.6962 su nb15_ter20. DT raggiunge rispettivamente 0.9624, 0.9898 e 0.9419, mentre RF ottiene 0.9952, 0.9995 e 0.9903. Nel seed considerato, RF presenta quindi il profilo di sensibilità più uniforme sulle tre distribuzioni target aggregate, mantenendo contestualmente una TNR pari a 0.9904.

Le valutazioni biclasse confermano tuttavia che la risposta dipende dalla specifica famiglia d'attacco. RF raggiunge TPR pari a 1.0000 su nb15_sat20-Syn_DDoS, nb15_ter20-DDoS e nb15_ter20-UDP_DDoS; DT raggiunge 1.0000 su nb15_ter20-DDoS. Il caso più critico è invece nb15_ter20-Syn_DDoS per HGB, dove $TP = 0$ e $FN = 1\,860$, corrispondenti a TPR nulla.

Una variabilità rilevante emerge anche all'interno del dominio sorgente. Fuzzers costituisce il caso più problematico, con TPR pari a 0.2823 per DT, 0.1817 per HGB e 0.2419 per RF; per Generic, al contrario, tutte le architetture raggiungono 0.9909. La capacità di rilevamento della baseline non risulta quindi uniforme neppure tra le famiglie native NB15.

La Precision completa tale quadro. HGB mantiene generalmente i valori più elevati, coerentemente con la maggiore TNR e il numero ridotto di falsi positivi; tuttavia, una maggiore affidabilità delle predizioni positive deve essere interpretata insieme alla sensibilità. Il caso nb15_ter20-Syn_DDoS, nel quale HGB presenta simultaneamente Precision e TPR nulle, costituisce l'esempio più evidente di tale compromesso.

F1-Score, PR-AUC e dipendenza dalla soglia. L'F1-Score viene utilizzato come sintesi del compromesso tra Precision e TPR, mentre la PR-AUC caratterizza la qualità della graduatoria probabilistica lungo l'intera curva Precision-Recall. I valori completi sui 16 benchmark sono riportati in Tabella B.2, in Appendice B.1.

Sul benchmark INJECTION, l'F1-Score è pari a 0.8320 per DT, 0.8792 per HGB e 0.8579 per RF; le corrispondenti PR-AUC sono 0.7104, 0.9342 e 0.9154. HGB ottiene quindi il maggiore F1-Score sulla distribuzione di riferimento, grazie al compromesso tra Precision elevata e TPR pari a 0.8097.

Sui tre benchmark target aggregati, RF raggiunge F1-Score pari a 0.9519, 0.9541 e 0.9495 rispettivamente su nb15_stin, nb15_sat20 e nb15_ter20. DT ottiene 0.9075, 0.9214 e 0.8969, mentre HGB raggiunge 0.8451, 0.9057 e 0.8056. Per RF, le corrispondenti PR-AUC sono 0.9802, 0.9873 e 0.9746, mostrando che l'elevata sensibilità osservata alla soglia operativa è accompagnata anche da una buona qualità della graduatoria probabilistica.

La criticità di Fuzzers rimane evidente anche nell'F1-Score: 0.3918 per DT, 0.2994 per HGB e 0.3617 per RF, rispetto ai valori 0.9220, 0.9795 e 0.9498 ottenuti sulla famiglia Generic.

Particolare attenzione richiede nuovamente HGB su nb15_ter20-Syn_DDoS. Alla soglia operativa utilizzata dalla pipeline si osserva

$$\text{TPR} = 0, \quad \text{F1} = 0, \quad \text{PR-AUC} = 0.5501.$$

L'F1-Score descrive il fallimento della decisione binaria nella configurazione effettivamente valutata, mentre la PR-AUC indica che la graduatoria probabilistica conserva informazione lungo

soglie alternative. Tale evidenza non viene utilizzata per introdurre una nuova configurazione sperimentale: il protocollo adottato non prevede infatti l'ottimizzazione o la ricalibrazione della soglia decisionale.

Sintesi del profilo prestazionale della baseline. Nel seed $s = 42$, HGB privilegia la preservazione del traffico nominale, raggiungendo la maggiore TNR ma mostrando una sensibilità maggiormente dipendente dalla distribuzione malevola. RF presenta il profilo più uniforme sui benchmark target, mentre DT mantiene prestazioni intermedie associate a un numero superiore di falsi positivi. Tali differenze emergono pur utilizzando la medesima strategia di composizione INJECTION; diventa pertanto rilevante analizzare come le tre architetture organizzino le caratteristiche dello spazio condiviso nella rispettiva funzione decisionale.

5.2.2 Analisi di Spiegabilità SHAP della Baseline INJECTION

Criterio di lettura delle attribuzioni. L'analisi SHAP considera, per tutte e tre le architetture, il seed $s = 42$ e il test set INJECTION, mantenendo quindi lo stesso riferimento sperimentale della valutazione precedente. La procedura segue l'implementazione descritta nella Sottosezione 4.6.2 del Capitolo 4 e considera le attribuzioni relative alla classe positiva *Attack/Anomaly*.

Nei *summary dot plot*, l'ordinamento verticale esprime la rilevanza globale delle feature sul campione analizzato, mentre la posizione orizzontale descrive direzione e ampiezza del contributo all'output del modello. Valori SHAP positivi spostano la risposta verso la classe malevola e valori negativi nella direzione opposta; la codifica cromatica distingue valori elevati e ridotti della caratteristica. Poiché l'implementazione utilizza, ove supportato, l'output raw dello specifico explainer, le ampiezze assolute dei valori SHAP non vengono confrontate quantitativamente tra differenti famiglie di classificatori. Il confronto riguarda pertanto principalmente la gerarchia delle feature e il verso qualitativo dei relativi contributi.




Figura 5.7: Summary plot SHAP della baseline INJECTION per Decision Tree, Histogram-based Gradient Boosting e Random Forest, valutati sul test set INJECTION con seed $s = 42$.

Decision Tree. Nel Decision Tree, Figura 5.7(a), pkts_per_sec occupa la prima posizione, seguita da load_s, total_bytes, src_bytes e byte_ratio. Per load_s e total_bytes, numerosi

valori elevati risultano associati a contributi positivi, mentre `byte_ratio` presenta diversi valori elevati nella regione negativa. `pkts_per_sec`, pur essendo la feature più rilevante, mostra contributi distribuiti su entrambe le parti e non evidenzia una relazione univariata strettamente monotona.

Histogram-based Gradient Boosting. Per HGB, Figura 5.7(b), `pkts_per_sec` rimane in prima posizione, seguita da `load_s`, `down_up_ratio`, `src_bytes` e `src_mean_pkt_size`. Anche in questo caso `pkts_per_sec` presenta una struttura non monotona, mentre `load_s` mostra numerosi valori elevati associati a contributi positivi. Per `down_up_ratio`, al contrario, valori elevati tendono a collocarsi nella regione negativa. Ulteriori andamenti strutturati sono osservabili per `dst_pkts`, prevalentemente negativo in corrispondenza di valori elevati, e per `total_bytes`, dove numerosi valori elevati producono contributi positivi.

Random Forest. Nel Random Forest, Figura 5.7(c), la graduatoria è guidata da `pkts_per_sec`, seguita da `total_bytes`, `src_bytes`, `src_mean_pkt_size` e `load_s`. Anche per RF la caratteristica principale non evidenzia una relazione cromatica strettamente monotona. Per `load_s`, valori elevati tendono invece a essere associati a contributi positivi, mentre `down_up_ratio` mostra prevalentemente il comportamento opposto. Le feature di finestra `src_win_byt` e `dst_win_byt`, pur collocate più in basso nella graduatoria globale, presentano inoltre contributi positivi principalmente in corrispondenza di valori ridotti.

Confronto sinottico delle gerarchie decisionali. Le prime cinque feature delle tre architetture sono sintetizzate nella Tabella 5.3.

Tabella 5.3: Prime cinque feature nella graduatoria SHAP della baseline INJECTION per DT, HGB e RF al seed $s = 42$.

Rank	DT	HGB	RF
1	<code>pkts_per_sec</code>	<code>pkts_per_sec</code>	<code>pkts_per_sec</code>
2	<code>load_s</code>	<code>load_s</code>	<code>total_bytes</code>
3	<code>total_bytes</code>	<code>down_up_ratio</code>	<code>src_bytes</code>
4	<code>src_bytes</code>	<code>src_bytes</code>	<code>src_mean_pkt_size</code>
5	<code>byte_ratio</code>	<code>src_mean_pkt_size</code>	<code>load_s</code>

L'elemento comune più netto è `pkts_per_sec`, collocata al primo posto per tutte le architetture. Anche `load_s` e `src_bytes` costituiscono un nucleo condiviso, pur con ordinamenti differenti. Le principali specificità riguardano invece `total_bytes`, seconda per RF, `down_up_ratio`, terza per HGB, e `byte_ratio`, quinta per DT. La condivisione del medesimo benchmark di addestramento non determina quindi una gerarchia decisionale identica tra i tre classificatori.

Raccordo tra SHAP, diagnostica distributiva e prestazioni. Il collegamento con la diagnostica della Sezione 5.1 risulta particolarmente evidente per `pkts_per_sec`. La feature occupa la prima posizione SHAP in tutte e tre le architetture baseline e coincide con la variabile per la quale la KDE ha evidenziato lo scostamento quantitativamente più marcato tra la componente malevola sorgente e quella target.

La corrispondenza individua quindi un punto di convergenza tra evidenza distributiva e rilevanza decisionale. Essa non dimostra tuttavia che il comportamento cross-domain della baseline sia determinato causalmente da `pkts_per_sec`: i classificatori operano nello spazio multidimensionale e le attribuzioni mostrano il contributo contemporaneo di numerose caratteristiche.

Analogamente, la posizione relativamente bassa di `dst_win_byt` nelle graduatorie della sola baseline non contraddice la sua inclusione tra le feature sottoposte a KDE. La selezione `{pkts_per_sec, total_bytes, dst_win_byt}` deriva infatti dall'aggregazione trasversale delle evidenze SHAP dell'intera campagna sperimentale e non esclusivamente dall'istanza INJECTION analizzata in questa sottosezione.

Nel complesso, la baseline associa una conoscenza target estremamente sparsa a tre profili distinti: maggiore specificità per HGB, maggiore uniformità della sensibilità target per RF e comportamento intermedio per DT. L'analisi SHAP mostra contestualmente una gerarchia condivisa nella feature principale ma differenze nell'organizzazione delle variabili successive. Tale configurazione costituisce il riferimento sperimentale per il confronto con i modelli addestrati esclusivamente sul dominio sorgente sviluppato nella Sezione 5.3.

5.3 Valutazione dei Modelli Sorgente rispetto alla Baseline

Dopo aver caratterizzato il comportamento della configurazione di riferimento $\mathcal{M}_{\text{base}}$, l'analisi viene estesa ai modelli $\mathcal{M}_S$, addestrati esclusivamente sul dominio sorgente NB15 e privi di conoscenza esplicita delle distribuzioni malevole target. Il gruppo comprende il modello aggregato nb15_aggregate e cinque rilevatori biclasse specializzati nelle famiglie DoS, Exploits, Fuzzers, Generic e Reconnaissance, ciascuno istanziato mediante DT, HGB e RF.

La valutazione sui medesimi 16 benchmark impiegati per la baseline permette di distinguere la capacità di riconoscimento in-domain dalla generalizzazione verso distribuzioni differenti. Coerentemente con la gerarchia introdotta nella Sezione 5.2, TPR e TNR costituiscono gli indicatori operativi principali, mentre F1-Score e le ulteriori metriche vengono richiamati quando apportano informazioni complementari.

5.3.1 Prestazioni dei Modelli Biclasse e Aggregato Sorgente

Prestazioni sulle distribuzioni sorgente omologhe. Una prima valutazione considera ciascun modello sulla distribuzione corrispondente alla propria configurazione di addestramento. La Tabella 5.4 riporta TPR, TNR e F1-Score ottenuti nel seed rappresentativo $s = 42$.

Tabella 5.4: Prestazioni dei modelli sorgente sui rispettivi test set omologhi per il seed $s = 42$.

Modello Sorgente	DT			HGB			RF		
	TPR	TNR	F1	TPR	TNR	F1	TPR	TNR	F1
Aggregato	0.8242	0.9826	0.8251	0.8022	0.9964	0.8728	0.8220	0.9917	0.8629
DoS	0.9280	0.9934	0.9307	0.9129	0.9974	0.9415	0.9317	0.9968	0.9491
Exploits	0.8919	0.9906	0.8982	0.8694	0.9954	0.9079	0.9043	0.9942	0.9216
Fuzzers	0.4763	0.9626	0.5150	0.3403	0.9898	0.4720	0.4747	0.9684	0.5303
Generic	0.9876	0.9995	0.9914	0.9882	0.9997	0.9924	0.9866	0.9997	0.9916
Reconnaissance	0.9414	0.9954	0.9473	0.9425	0.9956	0.9488	0.9409	0.9960	0.9501

La difficoltà di classificazione varia sensibilmente tra le famiglie sorgente. Generic presenta il comportamento più favorevole, con TPR comprese tra 0.9866 e 0.9882, TNR prossime all'unità e

F1-Score superiori a 0.991. Prestazioni elevate vengono osservate anche per DoS e Reconnaissance, mentre Exploits assume un comportamento intermedio.

La principale criticità è rappresentata da Fuzzers, per la quale la TPR scende a 0.4763 per DT, 0.3403 per HGB e 0.4747 per RF. Le corrispondenti TNR, pari rispettivamente a 0.9626, 0.9898 e 0.9684, mostrano che il degrado riguarda principalmente la capacità di riconoscere la classe positiva. Anche la PR-AUC conferma la maggiore difficoltà della distribuzione Fuzzers, assumendo valori pari a 0.3568, 0.6498 e 0.6063 per DT, HGB e RF, rispetto a 0.9839, 0.9974 e 0.9953 ottenuti su Generic.

Stabilità multi-seed e risposta sulle distribuzioni sorgente. La sintesi sulle $K = 10$ repliche conferma il comportamento osservato nel seed rappresentativo. Per il modello aggregato, la TPR media risulta pari a 0.8215 per DT, 0.8018 per HGB e 0.8236 per RF, valori prossimi a quelli ottenuti con $s = 42$. Anche la criticità Fuzzers permane nella valutazione multi-seed, con TPR medie pari a 0.4794, 0.3517 e 0.4739. Le varianze osservate sulle configurazioni omologhe risultano generalmente contenute, indicando che tali caratteristiche non sono associate alla sola inizializzazione rappresentativa.

La matrice completa delle TPR medie dei modelli sorgente sui benchmark NB15 e sul test set INJECTION è riportata nella Tabella B.3 in Appendice. Essa evidenzia la specializzazione dei rilevatori biclasse, senza tuttavia mostrare una risposta esclusivamente diagonale. Il modello Exploits, ad esempio, mantiene una TPR elevata sul benchmark DoS, pari a 0.9261, 0.9099 e 0.9282 rispettivamente per DT, HGB e RF; analogamente, Reconnaissance raggiunge valori compresi tra 0.9444 e 0.9785 sulla classe Generic. Altre combinazioni mostrano invece trasferibilità ridotta: Exploits su Generic raggiunge 0.0220, 0.1310 e 0.0224, mentre Generic su Fuzzers si ferma a 0.1213, 0.0913 e 0.1159.

Il modello nb15_aggregate mantiene inoltre sul benchmark INJECTION una risposta prossima a quella osservata sul test aggregato sorgente: la TPR media passa da 0.8215 a 0.8274 per DT, da 0.8018 a 0.8039 per HGB e da 0.8236 a 0.8272 per RF. Tale prossimità risulta coerente con la predominanza della componente sorgente nella distribuzione INJECTION evidenziata nella Sezione 5.1.

Generalizzazione verso i benchmark target. Il comportamento cambia sostanzialmente quando la componente malevola appartiene ai domini target. La matrice completa delle TPR medie sulle nove distribuzioni target aggregate e biclasse è riportata nella Tabella B.4 in Appendice.

Per il modello aggregato, considerando congiuntamente i sei benchmark sorgente, la TPR media è pari a 0.7870, 0.7601 e 0.7833 rispettivamente per DT, HGB e RF. Sui nove benchmark target i valori si riducono invece a

$$0.3234 \quad (\text{DT}), \quad 0.0607 \quad (\text{HGB}), \quad 0.3035 \quad (\text{RF}).$$

Il degrado è particolarmente pronunciato per HGB, il cui modello aggregato raggiunge TPR medie pari a 0.0662, 0.1055 e 0.0438 sui benchmark aggregati nb15_stin, nb15_sat20 e nb15_ter20. DT raggiunge rispettivamente 0.3807, 0.1947 e 0.5294, mentre RF ottiene 0.3601, 0.2613 e 0.4564.

Il degrado non implica tuttavia l'assenza di qualunque trasferimento tra famiglie. Per DT, il rilevatore DoS raggiunge TPR pari a 0.9528 su nb15_sat20-Syn_DDoS e 0.8877 su nb15_ter20-UDP_DDoS. Il modello Fuzzers raggiunge invece sulla classe Botnet 0.8898 per DT, 0.6226 per HGB e 0.9191 per RF; sulla classe UDP_DDoS di SAT20, RF raggiunge 0.9023. Si osservano quindi trasferimenti locali tra specifiche distribuzioni, ma non una capacità di generalizzazione target uniforme.

Il modello Reconnaissance rappresenta il caso opposto: HGB produce valori sostanzialmente nulli sull'intero insieme target e RF non supera 0.0200, mentre DT presenta prevalentemente sensibilità ridotte. Nel complesso, la risposta cross-domain dipende quindi dalla specifica combinazione tra modello sorgente e distribuzione target e risulta compatibile con il domain shift osservato mediante PCA e KDE, senza consentire di attribuirne causalmente l'effetto a una singola caratteristica.

Preservazione del traffico nominale. La riduzione della sensibilità target non è accompagnata da un analogo deterioramento della TNR. La Tabella B.5 in Appendice riporta media e varianza della specificità per tutte le configurazioni. I valori risultano generalmente elevati e presentano variabilità inter-seed molto contenuta. Il modello Generic raggiunge TNR medie comprese tra 0.99950 e 0.99964, mentre l'eccezione principale è nuovamente Fuzzers, con 0.96248 per DT, 0.98900 per HGB e 0.96847 per RF.

La combinazione tra TNR sostanzialmente stabile e TPR fortemente dipendente dal dominio localizza quindi il principale limite dei modelli sorgente nella risposta alla componente malevola: il traffico nominale NB15 continua a essere riconosciuto con elevata specificità, mentre la capacità di associare le nuove distribuzioni d'attacco alla classe positiva non viene trasferita con la stessa regolarità.

Nel complesso, $\mathcal{M}_S$ mostra pertanto buone prestazioni in-domain, con una criticità persistente sulla famiglia Fuzzers, ma una generalizzazione target disomogenea e generalmente ridotta. Tale evidenza motiva il confronto diretto con la baseline INJECTION, volto a quantificare l'effetto prestazionale associato alla presenza di conoscenza target sparsa.

5.3.2 Analisi Comparativa Incrociata: Modelli Sorgente vs Baseline

Criterio di confronto. Il confronto viene condotto separatamente per DT, HGB e RF tra il modello aggregato sorgente nb15_aggregate e la baseline injection_aggregate. Le configurazioni condividono componente nominale, rapporto tra le classi e cardinalità complessiva; la differenza riguarda la classe positiva, poiché la baseline sostituisce 29 dei 9 300 campioni malevoli NB15 con osservazioni provenienti da STIN.

Indicando con $\overline{TPR}_{\text{base},j}$ e $\overline{TPR}_{S,j}$ le TPR medie sui $K = 10$ seed relative al test set j , viene definita

$$\Delta TPR_j = \overline{TPR}_{\text{base},j} - \overline{TPR}_{S,j}, \quad (5.4)$$

dove $\Delta TPR_j > 0$ indica un vantaggio della baseline.

Conservazione delle prestazioni sorgente e incremento cross-domain. La Tabella 5.5 sintetizza il confronto separando i sei benchmark NB15 dai nove benchmark target e riportando, come controllo, la TNR media.

Tabella 5.5: Confronto multi-seed tra modello aggregato sorgente e baseline. Le differenze Δ sono calcolate come baseline meno modello sorgente.

Alg.	TPR media – (NB15)			TPR media – (target)			TNR media	
	$\mathcal{M}_S$	$\mathcal{M}_{\text{base}}$	Δ	$\mathcal{M}_S$	$\mathcal{M}_{\text{base}}$	Δ	$\mathcal{M}_S$	$\mathcal{M}_{\text{base}}$
DT	0.7870	0.7860	−0.0011	0.3234	0.9661	+0.6427	0.98317	0.98460
HGB	0.7601	0.7609	+0.0008	0.0607	0.8297	+0.7690	0.99659	0.99658
RF	0.7833	0.7820	−0.0013	0.3035	0.9882	+0.6847	0.99150	0.99057

L’asimmetria tra comportamento sorgente e cross-domain è netta. Sui sei benchmark NB15, le differenze di TPR media rimangono dell’ordine di 10^{-3} : −0.0011 per DT, +0.0008 per HGB e −0.0013 per RF. Una prossimità analoga si osserva sul test INJECTION, dove le TPR medie sorgente/baseline sono rispettivamente 0.82742/0.82748 per DT, 0.80387/0.80695 per HGB e 0.82719/0.82558 per RF.

Sui benchmark target, al contrario, la baseline incrementa la TPR media da 0.3234 a 0.9661 per DT, da 0.0607 a 0.8297 per HGB e da 0.3035 a 0.9882 per RF, corrispondenti a vantaggi assoluti pari a +0.6427, +0.7690 e +0.6847. L’incremento non è accompagnato da una variazione comparabile della TNR, che passa da 0.98317 a 0.98460 per DT, da 0.99659 a 0.99658 per HGB e da 0.99150 a 0.99057 per RF.

La medesima asimmetria emerge considerando l’intera cross-evaluation: la TPR media sui 16 test set passa da 0.5288 a 0.8899 per DT, da 0.3694 a 0.8025 per HGB e da 0.5161 a 0.9007 per RF. Poiché la risposta sui benchmark NB15 rimane pressoché invariata, il miglioramento globale è associato principalmente alla differente sensibilità verso le distribuzioni target.

Media prestazionale e variabilità sui benchmark target. Le statistiche complete di media e varianza della TPR sui tre benchmark target aggregati sono riportate nella Tabella B.6 in Appendice. Per DT, il passaggio alla baseline associa l’aumento della sensibilità a una riduzione della varianza sulle tre distribuzioni considerate. Un comportamento analogo è osservabile per RF su nb15_stin e, in particolare, nb15_sat20, dove la baseline raggiunge $\overline{TPR} = 0.99954$ con $\text{Var}(TPR) = 9.38 \times 10^{-8}$.

Per HGB, invece, la baseline presenta varianze leggermente superiori rispetto al modello sorgente sui tre benchmark aggregati, ma contestualmente incrementa la TPR da 0.06624 a 0.84945 su nb15_stin, da 0.10553 a 0.90956 su nb15_sat20 e da 0.04378 a 0.81505 su nb15_ter20. La sola stabilità non costituisce pertanto un indicatore di efficacia: una risposta può risultare poco variabile tra seed pur mantenendo una sensibilità sistematicamente ridotta.

Confronto con il migliore rilevatore sorgente disponibile. Per evitare che il confronto con il solo modello aggregato sottostimi la capacità del paradigma sorgente, per ciascun benchmark target viene inoltre considerata la migliore TPR media ottenuta tra il modello aggregato e i cinque rilevatori specialistici. Si definisce

$$\Delta TPR_j^{\text{best}} = \overline{TPR}_{\text{base},j} - \max_{m \in \mathcal{M}_S} \overline{TPR}_{m,j}. \quad (5.5)$$

I 27 valori completi sono riportati nella Tabella B.7 in Appendice e risultano tutti positivi. La baseline presenta quindi una TPR media superiore su ciascuno dei nove benchmark target e per tutte le tre architetture anche quando il termine di confronto viene selezionato a posteriori come il migliore modello sorgente disponibile.

Il vantaggio non è uniforme. Per DT, il modello sorgente DoS si avvicina alla baseline su nb15_sat20–Syn_DDoS, con un margine di +0.02042, e soprattutto su nb15_ter20–UDP_DDoS, dove $\Delta TPR^{\text{best}} = +0.00767$. Per RF, Fuzzers raggiunge 0.91909 sul test Botnet rispetto a 0.98451 della baseline e 0.90226 su UDP_DDoS satellitare rispetto a 0.99965. Nel caso HGB il margine minimo è più ampio, pari a +0.24576 sul test Botnet.

Tali eccezioni confermano l'esistenza di trasferimenti locali tra alcune famiglie sorgente e target, ma non modificano il risultato complessivo: nessuna delle configurazioni puramente sorgente supera la baseline nei 27 confronti considerati.

Raccordo con il domain shift osservato. Il comportamento prestazionale è coerente con la diagnostica della Sezione 5.1. I modelli $\mathcal{M}_S$ apprendono la funzione decisionale esclusivamente su NB15, mentre PCA e KDE hanno evidenziato uno scostamento marcato quando la componente malevola viene sostituita da STIN. Contestualmente, la TNR rimane elevata perché la distribuzione nominale continua a essere costituita da traffico sorgente.

Nel protocollo considerato, l'introduzione nella baseline di soli 29 campioni target è quindi associata a un incremento sostanziale della sensibilità cross-domain, senza una variazione apprezzabile delle prestazioni medie sui benchmark NB15 né della specificità. Tale evidenza rimane, a questo livello, descrittiva: la successiva analisi statistica verifica se le differenze globali osservate lungo le repliche multi-seed risultino compatibili con l'ipotesi di uguaglianza delle medie.

Una rappresentazione sinottica dell'intera matrice di *cross-evaluation* è riportata nelle Figure B.1, B.2 e B.3, raccolte nell'Appendice B.2.5. Le mappe di calore riportano congiuntamente la TPR media e la relativa varianza sui $K = 10$ seed per tutte le combinazioni modello–benchmark, fornendo il dettaglio visuale del comportamento cross-domain sintetizzato nella presente sottosezione.

Nel complesso, il confronto mostra che la conoscenza target sparsa distingue i due paradigmi soprattutto nella risposta cross-domain, mentre la conoscenza sorgente viene sostanzialmente preservata. L'analisi SHAP viene quindi utilizzata per verificare come il modello aggregato sorgente organizzi la rilevanza delle feature in assenza della componente target introdotta nella baseline.

5.3.3 Analisi SHAP del Modello Aggregato Sorgente NB15

Criterio di analisi. L'analisi considera il modello nb15_aggregate per DT, HGB e RF, utilizzando il seed $s = 42$ e il test set aggregato NB15. Il criterio di lettura delle attribuzioni è quello introdotto nella Sottosezione 5.2.2; il confronto tra architetture viene pertanto condotto sulla gerarchia globale delle feature e sulla direzione qualitativa dei contributi, senza confrontare direttamente le ampiezze assolute degli assi SHAP.




Figura 5.8: Summary plot SHAP del modello aggregato sorgente NB15 implementato mediante Decision Tree, Histogram-based Gradient Boosting e Random Forest, valutati sul test set aggregato NB15 con seed $s = 42$.

Decision Tree. Nel DT, Figura 5.8(a), `pkts_per_sec` occupa la prima posizione, seguita da `total_bytes`, `load_s`, `src_mean_pkt_size` e `byte_ratio`. `total_bytes` e `load_s` mostrano numerosi valori elevati associati a contributi positivi, mentre per `byte_ratio` valori elevati tendono maggiormente a collocarsi nella regione negativa. `pkts_per_sec`, pur dominando la graduatoria, non evidenzia invece una relazione univariata strettamente monotona.

Histogram-based Gradient Boosting. Per HGB, Figura 5.8(b), la feature principale rimane `pkts_per_sec`, seguita da `down_up_ratio`, `byte_ratio`, `load_s` e `src_bytes`. Rispetto alle altre architetture, assumono quindi maggiore rilevanza i rapporti tra le due direzioni del flusso. Per `down_up_ratio` e `byte_ratio`, valori elevati risultano prevalentemente associati a contributi negativi, mentre `load_s` presenta una tendenza opposta, con numerosi valori elevati nella regione positiva.

Random Forest. Nel RF, Figura 5.8(c), `pkts_per_sec` è seguita da `total_bytes`, `src_mean_pkt_size`, `duration` e `src_bytes`. La feature principale e `total_bytes` mostrano distribuzioni articolate su entrambi i lati dell'origine, mentre `load_s`, collocata immediatamente dopo le prime cinque caratteristiche, presenta valori elevati prevalentemente associati a contributi positivi. Per `down_up_ratio` si osserva invece una tendenza qualitativamente inversa.

Confronto sinottico delle gerarchie sorgente. La Tabella 5.6 sintetizza le cinque feature principali delle tre architetture.

Tabella 5.6: Prime cinque feature nella graduatoria SHAP del modello aggregato sorgente NB15 per DT, HGB e RF al seed $s = 42$.

Rank	DT	HGB	RF
1	<code>pkts_per_sec</code>	<code>pkts_per_sec</code>	<code>pkts_per_sec</code>
2	<code>total_bytes</code>	<code>down_up_ratio</code>	<code>total_bytes</code>
3	<code>load_s</code>	<code>byte_ratio</code>	<code>src_mean_pkt_size</code>
4	<code>src_mean_pkt_size</code>	<code>load_s</code>	<code>duration</code>
5	<code>byte_ratio</code>	<code>src_bytes</code>	<code>src_bytes</code>

Il principale elemento comune è `pkts_per_sec`, prima in tutte le graduatorie. `total_bytes` occupa inoltre la seconda posizione per DT e RF, mentre HGB attribuisce maggiore priorità a `down_up_ratio` e `byte_ratio`. DT mantiene `load_s` tra le prime tre caratteristiche, mentre RF introduce `duration` nella Top-5 e colloca `load_s` immediatamente al di fuori di essa. Le architetture condividono quindi la principale dimensione informativa, ma organizzano diversamente le feature successive.

Confronto qualitativo con la baseline INJECTION. Il confronto con la Sottosezione 5.2.2 mostra una sostanziale continuità nella feature dominante e variazioni nell'ordinamento delle caratteristiche secondarie. Per DT, `pkts_per_sec`, `total_bytes`, `load_s` e `byte_ratio` rimangono nella Top-5; nella baseline, tuttavia, `load_s` precede `total_bytes` e `src_bytes` sostituisce `src_mean_pkt_size`.

Per RF le prime due posizioni rimangono `pkts_per_sec` e `total_bytes`; nella baseline acquisiscono maggiore priorità `src_bytes` e `load_s`, mentre `duration` esce dalle prime cinque. La riorganizzazione più evidente riguarda HGB: nel modello sorgente `down_up_ratio` e `byte_ratio` occupano la seconda e la terza posizione, mentre nella baseline `load_s` sale al secondo posto e `byte_ratio` non compare più nella Top-5.

Il confronto descrive una diversa organizzazione empirica delle attribuzioni, ma non consente di attribuire causalmente tali variazioni ai soli 29 campioni target. I grafici derivano infatti da modelli addestrati su benchmark differenti e valutati rispettivamente su NB15 e INJECTION.

Raccordo con PCA, KDE e comportamento cross-domain. Il collegamento più evidente con la diagnostica distributiva riguarda `pkts_per_sec`. La feature occupa il primo posto per tutti i modelli aggregati sorgente e, contestualmente, presenta il maggiore scostamento quantitativo osservato mediante KDE tra la componente malevola NB15 e STIN. L'elevata rilevanza decisionale della variabile nel dominio sorgente non implica tuttavia robustezza al cambiamento della sua distribuzione: importanza SHAP e capacità di generalizzazione cross-domain rappresentano proprietà distinte.

Un secondo raccordo riguarda `total_bytes`, seconda feature per DT e RF e caratterizzata nella diagnostica KDE da una sostanziale variazione della distribuzione target. Al contrario, `dst_win_byt`, pur mostrando un evidente scostamento distributivo tra NB15 e STIN, rimane nelle posizioni inferiori delle graduatorie SHAP dei tre modelli sorgente.

L'evidenza complessiva mostra quindi che

ampiezza del domain shift $\neq$ rilevanza predittiva.

Una feature può essere fortemente rilevante nel dominio sorgente e non garantire robustezza rispetto allo shift; analogamente, uno scostamento distributivo marcato non implica che la caratteristica sia tra quelle maggiormente utilizzate dal classificatore.

L'analisi SHAP completa pertanto il quadro prestazionale dei modelli $\mathcal{M}_S$: le architetture condividono alcune dimensioni informative centrali, ma la relativa funzione decisionale rimane appresa esclusivamente sulla distribuzione sorgente. La significatività delle differenze globali rispetto alla baseline viene verificata nella sottosezione successiva.

5.3.4 Analisi della Significatività Statistica (Test t di Welch) dei Modelli Sorgente vs Baseline

Costruzione dei campioni statistici. La verifica inferenziale segue il protocollo definito nel Capitolo 4. Per ciascun modello i e seed s_k , la quantità sottoposta al confronto è la media dell'F1-Score sui 16 test set della cross-evaluation:

$$\overline{F1}_i^{(k)} = \frac{1}{16} \sum_{j=1}^{16} F1_{ij}^{(k)}. \quad (5.6)$$

Ogni configurazione è quindi rappresentata da $K = 10$ valori $\overline{F1}_i^{(k)}$. Il test confronta il vettore della baseline `injection_aggregate` con quello di ciascun modello sorgente mediante un test t di Welch bilaterale, senza assumere uguaglianza delle varianze:

$$H_0 : \mu_{\text{base}} = \mu_m, \quad H_1 : \mu_{\text{base}} \neq \mu_m, \quad \alpha = 0.05.$$

La natura della variabile deve rimanere esplicita: il test fornisce una valutazione *globale* del comportamento lungo i 16 benchmark e non una verifica di significatività separata per ciascun test set.

Sintesi descrittiva delle distribuzioni multi-seed. Le statistiche complete dei 10 valori per modello sono riportate nella Tabella B.10 in Appendice. La baseline presenta la maggiore media inter-seed dell'F1-Score per tutte le architetture.

Per DT, `injection_aggregate` raggiunge 0.86039, mentre il migliore modello sorgente è `nb15_dos` con 0.63163, per un divario pari a 0.22876. Nel caso HGB, la baseline raggiunge 0.85407, contro 0.41671 del migliore modello sorgente `nb15_dos`. Per RF, il valore della baseline è 0.89022, mentre `nb15_aggregate` raggiunge 0.57651.

Le deviazioni standard della baseline sono pari a 0.00352 per DT, 0.03634 per HGB e 0.00245 per RF. HGB presenta quindi una dispersione inter-seed superiore rispetto alle altre due architetture, circostanza coerente con l'impiego del test di Welch, che non richiede l'assunzione di varianze uguali.

Risultati del test t di Welch. I valori completi della statistica t e del p -value sono riportati nella Tabella B.11 in Appendice. Tutti i 18 confronti soddisfano il criterio $p < 0.05$; secondo il test adottato, le distribuzioni delle medie F1 multi-seed non risultano quindi compatibili con l'ipotesi nulla di uguaglianza delle medie per nessuna delle configurazioni sorgente considerate.

Tutte le statistiche t assumono inoltre segno positivo. Poiché la baseline costituisce il primo campione fornito al test e presenta in ogni confronto una media inter-seed superiore, la direzione empirica delle differenze è sistematicamente favorevole a $\mathcal{M}_{\text{base}}$.

L'interpretazione rimane necessariamente globale. Il risultato non permette di concludere che la baseline sia statisticamente superiore a ciascun modello sorgente su ognuno dei 16 benchmark considerati individualmente. Esso indica invece che, secondo la misura definita nell'Equazione (5.6), le differenze tra le medie complessive della baseline e quelle dei modelli sorgente risultano significative nel protocollo statistico adottato, tenuto conto della variabilità osservata tra le inizializzazioni.

Coerentemente con la metodologia sperimentale, i p -value non sono sottoposti a una correzione per confronti multipli. L'analisi mantiene quindi carattere esplorativo e ciascuno dei 18 confronti viene valutato individualmente rispetto alla soglia $\alpha = 0.05$.

Sintesi della valutazione dei modelli sorgente. Le evidenze prestazionali, distributive, esplicative e inferenziali convergono su un quadro coerente. I modelli sorgente mantengono buone prestazioni su numerose distribuzioni NB15, ma presentano una sensibilità target generalmente ridotta e fortemente dipendente dalla specifica combinazione modello–attacco, mentre la TNR rimane elevata. L'analisi SHAP mostra inoltre che alcune caratteristiche centrali per la funzione decisio-

nale sorgente, in particolare `pkts_per_sec` e `total_bytes`, appartengono anche alle dimensioni interessate dal domain shift osservato nella diagnostica.

Il confronto con INJECTION mostra contestualmente che la presenza di una quota target sparsa è associata alla sostanziale conservazione delle prestazioni NB15 e a un incremento marcato della sensibilità target. Tale vantaggio permane rispetto al migliore modello sorgente in tutti i 27 confronti target e, nella misura globale utilizzata dal test di Welch, tutti i 18 confronti con la baseline risultano significativi secondo il criterio adottato. La successiva Sezione 5.4 estende il confronto al paradigma nel quale la componente malevola di addestramento viene invece sostituita integralmente da traffico target.

5.4 Valutazione dei Modelli Ibridi rispetto alla Baseline

La valutazione viene ora estesa ai modelli ibridi $\mathcal{M}_H$, nei quali la componente nominale continua a essere derivata dal dominio sorgente NB15, mentre la componente malevola di addestramento appartiene interamente ai domini target. Il gruppo comprende i tre modelli aggregati `nb15_stin_aggregate`, `nb15_sat20_aggregate` e `nb15_ter20_aggregate`, oltre ai sei rilevatori biclasse specializzati nelle famiglie target considerate. Ciascuna configurazione viene istanziata mediante DT, HGB e RF e sottoposta alla medesima cross-evaluation sui 16 benchmark utilizzata nelle sezioni precedenti.

La costruzione dei benchmark ibridi richiede una cautela interpretativa specifica. Nel training, infatti, il traffico nominale appartiene sempre al dominio sorgente, mentre quello malevolo appartiene al dominio target:

$$Y = 0 \Rightarrow D = \text{NB15}, \quad Y = 1 \Rightarrow D = \text{Target}.$$

Classe e dominio risultano pertanto strutturalmente correlati. Prestazioni elevate sul target non possono quindi essere attribuite automaticamente all'apprendimento di proprietà semantiche generali degli attacchi, poiché la funzione decisionale può sfruttare anche differenze distributive associate alla provenienza dei campioni. Tale confondimento viene mantenuto esplicito nell'interpretazione delle evidenze prestazionali e SHAP.

5.4.1 Prestazioni dei Modelli Biclasse e Aggregati Ibridi

Prestazioni sulle distribuzioni target omologhe. Una prima valutazione riguarda le condizioni nelle quali ciascun modello viene applicato alla distribuzione target corrispondente alla propria configurazione di addestramento. I risultati completi per il seed rappresentativo $s = 42$ sono riportati nella Tabella B.8 in Appendice.

Le prestazioni risultano sostanzialmente sature. Sui benchmark aggregati NB15_STIN e NB15_SAT20, DT, HGB e RF identificano 1 859 dei 1 860 campioni malevoli, producendo un solo falso negativo e nessun falso positivo. Ne conseguono TPR pari a 0.9995, TNR e Precision pari a 1.0000 e F1-Score pari a 0.9997. Sul benchmark aggregato NB15_TER20 e sui sei test biclasse omologhi, le tre architetture raggiungono invece TPR, TNR, Precision e F1-Score pari a 1.0000.

Il riconoscimento quasi perfetto della distribuzione utilizzata nel training non è tuttavia sufficiente a caratterizzare la robustezza dei modelli. La generalizzazione deve essere valutata anche sugli attacchi sorgente e sulle distribuzioni target differenti da quella impiegata durante l'addestramento.

Preservazione della componente nominale. Un comportamento completamente uniforme emerge per la specificità. Sulle $K = 10$ repliche, tutti i modelli ibridi e tutte le architetture presentano

$$\overline{TNR} = 1.0000, \quad \text{Var}(TNR) = 0.$$

Il traffico nominale NB15 viene quindi classificato correttamente in tutte le repliche considerate. Tale risultato non deve tuttavia essere interpretato isolatamente: una TNR perfetta non implica l'apprendimento di un criterio generale di rilevamento delle anomalie e deve essere letta congiuntamente alla sensibilità sulle differenti popolazioni positive.

Trasferimento verso dominio sorgente, INJECTION e distribuzioni target. La Tabella B.9 in Appendice riporta la matrice completa delle TPR medie multi-seed, distinguendo tre condizioni: i sei benchmark NB15, il benchmark INJECTION e i nove benchmark target.

L'asimmetria tra dominio sorgente e target è particolarmente netta. Per DT e RF, tutti i modelli ibridi presentano TPR media nulla sui sei benchmark NB15. HGB mostra il medesimo comportamento, con la sola eccezione di nb15_ter20_syn_ddos, la cui media rimane comunque pari a

2.5×10^{-5} . Nel seed $s = 42$, le configurazioni applicate ai test sorgente producono generalmente $TP = 0$, $FN = 1\,860$, $FP = 0$ e $TN = 18\,600$.

La contemporanea presenza di TNR unitaria e TPR nulla descrive quindi un comportamento fortemente polarizzato: il traffico nominale sorgente viene preservato, ma gli attacchi appartenenti allo stesso dominio non vengono associati alla regione positiva appresa mediante traffico target.

Un'evidenza coerente emerge sul benchmark INJECTION. Per i tre modelli aggregati la TPR media è pari a 0.00320 per DT, HGB e RF. Poiché la componente malevola del benchmark è quasi interamente sorgente, il valore è compatibile con la perdita di sensibilità verso gli attacchi NB15. La prossimità numerica rispetto alla ridotta quota target presente in INJECTION non consente tuttavia di identificare quali singoli campioni abbiano prodotto i veri positivi; non è quindi possibile attribuire puntualmente le classificazioni corrette alla sola componente target.

Generalizzazione tra distribuzioni target. Il comportamento cambia radicalmente quando la componente malevola appartiene al dominio target. Per i tre modelli aggregati, la TPR media sui nove benchmark target risulta riportata nella Tabella 5.7.

Tabella 5.7: TPR media dei tre modelli aggregati sui nove benchmark target.

Modello	NB15_STIN	NB15_SAT20	NB15_TER20
DT	0.999922	0.999889	0.999922
HGB	0.999944	0.981796	0.999944
RF	0.999922	0.999894	0.999906

La sensibilità non risulta quindi limitata alla singola distribuzione target utilizzata nel fitting: i modelli aggregati mantengono TPR prossime all'unità anche sulle altre distribuzioni target considerate. Tale evidenza indica un'elevata trasferibilità all'interno del gruppo target, ma non permette di stabilire se essa derivi da proprietà condivise degli attacchi o da caratteristiche distributive comuni ai domini target, dato il confondimento tra classe e provenienza presente nel training.

Specializzazione dei modelli biclasse. I rilevatori specialistici mostrano una maggiore eterogeneità. Pur raggiungendo prestazioni perfette o quasi perfette sulla distribuzione omologa,

la loro sensibilità media sui nove benchmark target può ridursi considerevolmente. Il modello nb15_sat20_syn_ddos, ad esempio, raggiunge TPR unitaria sulla propria classe ma TPR target medie pari a 0.424387, 0.315589 e 0.443831 rispettivamente per DT, HGB e RF.

Una maggiore trasferibilità emerge per nb15_sat20_udp_ddos, che raggiunge 0.974900 per DT, 0.551311 per HGB e 0.898881 per RF. Il modello nb15_ter20_syn_ddos evidenzia invece una forte dipendenza dall'architettura: DT e RF raggiungono rispettivamente 0.999928 e 0.999910, mentre HGB si arresta a 0.629574.

Un'elevata prestazione sulla distribuzione omologa non implica pertanto una generalizzazione cross-target altrettanto elevata. Tale proprietà distingue in particolare i rilevatori biclasse dai modelli aggregati, che presentano una risposta sostanzialmente uniforme nell'intero gruppo target.

Stabilità multi-seed e raccordo con la diagnostica distributiva. La stabilità sulle distribuzioni omologhe risulta molto elevata. Per la quasi totalità delle configurazioni, la TPR media rimane pari a 1.0000 con varianza nulla; anche le varianze non nulle osservate sono dell'ordine di 10^{-8} . Il comportamento rilevato nel seed $s = 42$ non rappresenta quindi un'anomalia isolata della specifica inizializzazione.

La forte asimmetria tra sorgente e target è inoltre compatibile con la diagnostica sviluppata nella Sezione 5.1. La PCA di NB15_STIN ha evidenziato una marcata separazione geometrica tra traffico nominale sorgente e traffico malevolo target, mentre le KDE hanno mostrato variazioni distributive rilevanti per pkts_per_sec, total_bytes e dst_win_byt. Nel paradigma ibrido tali differenze coincidono strutturalmente con la distinzione tra le etichette.

Il profilo

$$TNR_{NB15, \text{benigno}} = 1, \quad TPR_{\text{Target}} \simeq 1, \quad TPR_{NB15, \text{attacco}} \simeq 0$$

risulta pertanto compatibile con una funzione decisionale fortemente allineata alla struttura distributiva presente nei benchmark ibridi. Le sole metriche non consentono tuttavia di determinare quali caratteristiche producano tale separazione né di distinguere informazione di classe e informazione di dominio.

Nel complesso, $\mathcal{M}_H$ presenta quindi una specializzazione target molto pronunciata e stabile, accompagnata dalla perdita quasi completa della sensibilità verso gli attacchi sorgente. Tale polarizzazione motiva il confronto diretto con $\mathcal{M}_{\text{base}}$.

5.4.2 Analisi Comparativa Incrociata: Modelli Ibridi vs Baseline

Criterio di confronto. Il confronto con la baseline viene condotto distinguendo la TPR media sui sei benchmark NB15, la risposta sul benchmark INJECTION, la TPR media sui nove benchmark target e la TPR media sull'intera cross-evaluation.

Per un generico modello ibrido h e un gruppo di benchmark g , viene definita

$$\Delta TPR_{h,g} = \overline{TPR}_{h,g} - \overline{TPR}_{\text{base},g}, \quad (5.7)$$

mentre per la specificità viene utilizzata

$$\Delta TNR_h = \overline{TNR}_h - \overline{TNR}_{\text{base}}. \quad (5.8)$$

Un valore positivo indica quindi un vantaggio del modello ibrido rispetto alla baseline sulla misura considerata.

Confronto dei modelli aggregati. La Tabella 5.8 sintetizza il confronto multi-seed tra i tre modelli aggregati ibridi e injection_aggregate.

Tabella 5.8: Differenze di TPR e TNR tra i modelli aggregati ibridi e la baseline INJECTION. I valori sono calcolati come modello ibrido meno baseline.

Modello Ibrido	ΔTPR_{NB15}	ΔTPR_{INJ}	$\Delta TPR_{\text{Target}}$	ΔTPR_{16}	ΔTNR
DT					
nb15_stin_aggregate	-0.78597	-0.82428	+0.03381	-0.32724	+0.01540
nb15_sat20_aggregate	-0.78597	-0.82428	+0.03377	-0.32726	+0.01540
nb15_ter20_aggregate	-0.78597	-0.82428	+0.03381	-0.32724	+0.01540
HGB					
nb15_stin_aggregate	-0.76085	-0.80375	+0.17025	-0.23979	+0.00342
nb15_sat20_aggregate	-0.76085	-0.80375	+0.15210	-0.25000	+0.00342
nb15_ter20_aggregate	-0.76085	-0.80375	+0.17025	-0.23979	+0.00342
RF					
nb15_stin_aggregate	-0.78198	-0.82238	+0.01171	-0.33805	+0.00943
nb15_sat20_aggregate	-0.78198	-0.82238	+0.01168	-0.33807	+0.00943
nb15_ter20_aggregate	-0.78198	-0.82238	+0.01169	-0.33806	+0.00943

Il segno delle differenze evidenzia una netta inversione del vantaggio in funzione del dominio. Sui benchmark target, tutti i modelli aggregati ibridi presentano una sensibilità media superiore alla baseline. Per DT, l'incremento è pari a circa +0.034; per HGB varia tra +0.15210 e +0.17025; per RF si riduce a circa +0.0117, poiché la baseline raggiunge già una TPR target media pari a 0.98821.

Il vantaggio target è tuttavia accompagnato da una perdita di magnitudine molto maggiore sul dominio sorgente. La TPR media NB15 della baseline è pari a 0.78597 per DT, 0.76085 per HGB e 0.78198 per RF, mentre i tre modelli aggregati ibridi assumono valore nullo. La stessa asimmetria emerge su INJECTION: la baseline raggiunge rispettivamente 0.82748, 0.80695 e 0.82558, contro 0.00320 dei modelli aggregati ibridi.

Vantaggio sui benchmark target e specificità. Considerando separatamente i tre modelli aggregati e i nove benchmark target, DT produce 27 confronti su 27 con TPR superiore alla baseline; il vantaggio varia da +0.00025 a +0.10464. Anche per HGB tutti i 27 confronti risultano favorevoli agli aggregati ibridi, con differenze comprese tra +0.07129 e +0.50114. Per RF, 24 confronti producono un incremento e i restanti tre, relativi alla classe DDoS di TER20, una parità a 1.0000; nessun confronto risulta sfavorevole al modello ibrido e il vantaggio massimo è pari a +0.06032.

Se il criterio fosse limitato alla sensibilità sulle distribuzioni target, gli aggregati ibridi rappresenterebbero quindi le configurazioni più performanti tra quelle considerate.

La TNR introduce tuttavia un'ulteriore cautela. I modelli ibridi raggiungono 1.0000, rispetto a 0.98460 per DT, 0.99658 per HGB e 0.99057 per RF nella baseline. Gli incrementi di specificità, pari rispettivamente a 0.01540, 0.00342 e 0.00943, non possono però essere interpretati indipendentemente dalla TPR nulla sugli attacchi NB15. La classificazione corretta di tutto il traffico nominale sorgente coesiste infatti con la mancata identificazione delle anomalie appartenenti allo stesso dominio.

Generalizzazione lungo l'intera cross-evaluation. Il compromesso diventa evidente considerando la TPR media sui 16 test set. La baseline raggiunge

0.88990 (DT), 0.80246 (HGB), 0.90071 (RF).

Gli aggregati ibridi rimangono invece compresi tra 0.56264 e 0.56266 per DT, tra 0.55246 e 0.56267 per HGB e intorno a 0.56265 per RF. L'incremento di sensibilità sui target non compensa quindi la perdita sui sei benchmark NB15 e su INJECTION.

La configurazione che massimizza la TPR sul solo dominio target non coincide pertanto con quella che presenta la risposta più uniforme sull'intero insieme delle condizioni sperimentali. $\mathcal{M}_{base}$ rinuncia a una quota di sensibilità target rispetto agli aggregati ibridi, ma conserva contestualmente la capacità di riconoscere gli attacchi sorgente.

Modelli biclasse: specializzazione locale e trasferimento cross-target. Il confronto con la baseline conferma la maggiore dipendenza dei rilevatori biclasse dalla specifica distribuzione utilizzata nel training. Per DT, tre dei sei specialisti superano la TPR target media della baseline: nb15_sat20_udp_ddos, con 0.97490; nb15_ter20_syn_ddos, con 0.99993; e nb15_ter20_udp_ddos, con 0.97867.

Per HGB soltanto nb15_ter20_botnet, con 0.84210, supera la baseline, pari a 0.82970. Per RF, la cui baseline raggiunge 0.98821, soltanto nb15_ter20_syn_ddos, con 0.99991, mantiene un vantaggio nella media sui nove benchmark target.

Il risultato distingue quindi specializzazione omologa e generalizzazione cross-target: una TPR unitaria sulla famiglia utilizzata durante il training non implica necessariamente una risposta altrettanto efficace sulle altre popolazioni target.

Raccordo con la struttura distributiva. Il profilo dei modelli ibridi risulta coerente con la separazione osservata mediante PCA e KDE tra traffico nominale NB15 e traffico malevolo target. Nel paradigma ibrido tali differenze distributive sono sistematicamente associate alle etichette durante l'addestramento; nella baseline, al contrario, la classe positiva rimane prevalentemente sorgente e integra soltanto una quota target sparsa.

Le metriche non consentono di determinare se i modelli ibridi utilizzino direttamente informazione riconducibile al dominio o caratteristiche semantiche degli attacchi. Esse mostrano tuttavia una generalizzazione asimmetrica: l'estensione della conoscenza target non determina il mantenimento della sensibilità verso le anomalie sorgente.


La struttura completa di tale comportamento è riportata nelle Figure B.4, B.5 e B.6, raccolte nell'Appendice B.3.3. Le matrici aggregate visualizzano, per ciascuna combinazione tra modello

ibrido e benchmark di test, la TPR media e la relativa varianza sui $K = 10$ seed, completando il quadro numerico della *cross-evaluation* senza introdurre ulteriori criteri di valutazione.


Il confronto quantitativo identifica pertanto due profili distinti: $\mathcal{M}_H$ massimizza la sensibilità sulle distribuzioni target, mentre $\mathcal{M}_{base}$ mantiene un comportamento più uniforme tra dominio sorgente e target. L'analisi SHAP approfondisce la diversa organizzazione delle feature associata a tali profili.

5.4.3 Analisi SHAP del Modello Aggregato Ibrido NB15_STIN


Criterio di analisi. L'analisi considera il modello nb15_stin_aggregate per DT, HGB e RF, utilizzando il seed $s = 42$ e il benchmark NB15_STIN. Il criterio di lettura delle attribuzioni è quello introdotto nella Sottosezione 5.2.2; vengono pertanto confrontate la gerarchia globale delle feature e la direzione qualitativa dei contributi, senza utilizzare l'ampiezza assoluta degli assi SHAP per confronti quantitativi tra architetture.



(a) Decision Tree



(b) Histogram-based Gradient Boosting



(c) Random Forest

Figura 5.9: Summary plot SHAP del modello aggregato ibrido NB15_STIN implementato mediante Decision Tree, Histogram-based Gradient Boosting e Random Forest, valutati sul benchmark NB15_STIN con seed $s = 42$.

Decision Tree. Nel DT, Figura 5.9(a), le prime due posizioni sono occupate da `dst_win_byt` e `src_win_byt`, seguite da `byte_ratio`, `win_diff` e `src_mean_pkt_size`. Per `dst_win_byt`, valori elevati risultano prevalentemente associati a contributi negativi, mentre alcune osservazioni con valori ridotti producono contributi positivi di ampiezza marcata. Le feature successive presentano invece attribuzioni molto più concentrate intorno allo zero.

Histogram-based Gradient Boosting. Per HGB, Figura 5.9(b), `dst_win_byt` e `src_win_byt` mantengono rispettivamente la prima e la seconda posizione, seguite da `duration`, `pkts_per_sec` e `src_bytes`. Anche in questo caso i valori elevati di `dst_win_byt` risultano prevalentemente associati a contributi negativi, mentre alcune osservazioni caratterizzate da valori ridotti producono contributi positivi di ampiezza sensibilmente superiore alle feature successive. La funzione decisionale rappresentata appare quindi fortemente concentrata sulle due variabili di finestra.

Random Forest. Nel RF, Figura 5.9(c), le feature `dst_win_byt` e `src_win_byt` occupano ancora le prime due posizioni, seguite da `dst_mean_pkt_size`, `load_s` e `win_diff`. RF mantiene una distribuzione delle attribuzioni relativamente più articolata rispetto a DT e HGB, ma la centralità delle due feature di finestra rimane evidente.

Per `dst_win_byt`, valori elevati tendono nuovamente a produrre contributi negativi, mentre alcune osservazioni con valori ridotti sono associate agli spostamenti positivi più marcati. Per `src_win_byt` la relazione risulta meno monotona e sono osservabili contributi positivi associati a differenti regioni della feature.

Confronto sinottico delle gerarchie ibride. La Tabella 5.9 sintetizza le prime cinque feature delle tre architetture.

Tabella 5.9: Prime cinque feature nella graduatoria SHAP del modello aggregato ibrido NB15_STIN per DT, HGB e RF al seed $s = 42$.

Rank	DT	HGB	RF
1	<code>dst_win_byt</code>	<code>dst_win_byt</code>	<code>dst_win_byt</code>
2	<code>src_win_byt</code>	<code>src_win_byt</code>	<code>src_win_byt</code>
3	<code>byte_ratio</code>	<code>duration</code>	<code>dst_mean_pkt_size</code>
4	<code>win_diff</code>	<code>pkts_per_sec</code>	<code>load_s</code>
5	<code>src_mean_pkt_size</code>	<code>src_bytes</code>	<code>win_diff</code>

Il risultato principale è la completa concordanza delle prime due posizioni: DT, HGB e RF attribuiscono la maggiore rilevanza globale a `dst_win_byt` e `src_win_byt`. Nei modelli DT e HGB, inoltre, gran parte delle feature successive presenta attribuzioni prossime allo zero, mentre RF mantiene una funzione decisionale relativamente più distribuita.

Riorganizzazione rispetto ai modelli sorgente e alla baseline. La gerarchia ibrida differisce nettamente da quelle analizzate nelle Sottosezioni 5.3.3 e 5.2.2. `pkts_per_sec`, prima feature per DT, HGB e RF sia nel modello sorgente sia nella baseline, scende al settimo posto per DT e RF e al quarto per HGB nel modello ibrido. Analogamente, `total_bytes`, seconda per DT e RF sorgente

e comunque centrale nella baseline, viene collocata al decimo posto per DT, al nono per HGB e all'undicesimo per RF.

Parallelamente, `dst_win_byt` e `src_win_byt` diventano rispettivamente prima e seconda feature in tutte le architetture. Il passaggio al training ibrido è quindi associato a una sostanziale riorganizzazione della gerarchia delle attribuzioni, e non alla semplice amplificazione delle medesime caratteristiche predominanti nei paradigmi precedenti.

Raccordo con KDE e comportamento prestazionale. Il ruolo assunto da `dst_win_byt` trova un riscontro nella diagnostica KDE. Per la componente malevola, la media passa da circa 87.52 nel dominio sorgente a circa -0.78 in STIN, mentre la varianza si riduce da circa 1.47×10^4 a 4.01×10^3 . Nel modello ibrido, i valori ridotti della feature sono contestualmente quelli associati a numerosi contributi SHAP positivi di maggiore ampiezza.

KDE e SHAP identificano pertanto `dst_win_byt` come una dimensione che presenta sia una variazione distributiva tra sorgente e target sia un'elevata rilevanza decisionale nel paradigma ibrido. Tale convergenza non costituisce tuttavia una dimostrazione causale.

`pkts_per_sec` rappresenta il caso complementare: pur mostrando nella KDE lo scostamento quantitativo più marcato tra NB15 e STIN, non occupa le prime posizioni della gerarchia ibrida. Si conferma quindi il principio già emerso nella Sezione 5.3:

ampiezza del domain shift $\neq$ rilevanza predittiva.

Il raccordo con le prestazioni deve inoltre considerare il confondimento strutturale del benchmark NB15_STIN. La combinazione tra TNR unitaria sul traffico nominale sorgente, TPR prossime all'unità sul target, TPR sostanzialmente nulla sugli attacchi NB15 e predominanza SHAP delle feature di finestra è compatibile con una funzione decisionale fortemente allineata alla separazione distributiva presente nel training set.

Non è tuttavia possibile stabilire se le variabili di finestra vengano utilizzate perché descrivono proprietà intrinseche degli attacchi, perché distinguono efficacemente i domini o per una combinazione delle due informazioni. L'evidenza SHAP mostra quindi una concreta riorganizzazione della funzione decisionale rispetto alla baseline, senza permettere di attribuirle un'interpretazione causale univoca.

Nel complesso, il modello aggregato ibrido concentra la propria gerarchia su feature differenti rispetto ai paradigmi sorgente e INJECTION. Tale struttura accompagna una forte specializzazione target e una ridotta trasferibilità inversa verso gli attacchi sorgente. La significatività delle differenze globali viene verificata mediante il medesimo protocollo multi-seed utilizzato nella Sezione 5.3.

5.4.4 Analisi della Significatività Statistica (Test t di Welch) dei Modelli Ibridi vs Baseline

Criterio statistico. La verifica inferenziale utilizza la medesima procedura definita nella Sottosezione 5.3.4. Per ciascun modello e seed viene quindi utilizzata la media dell’F1-Score sui 16 benchmark, $\overline{F1}_i^{(k)}$, definita nell’Equazione (5.6). I $K = 10$ valori seed-level di ciascuno dei nove modelli ibridi vengono confrontati con quelli della baseline *injection_aggregate* mediante un test t di Welch bilaterale, con $\alpha = 0.05$ e senza assumere uguaglianza delle varianze.

Anche in questo caso il test riguarda la prestazione *globale* lungo l’intera cross-evaluation e non produce una verifica separata per i singoli benchmark sorgente o target.

Sintesi descrittiva dell’F1-Score multi-seed. Le statistiche complete sono riportate nella Tabella B.12 in Appendice. Per DT, la baseline raggiunge una media globale pari a 0.860388, mentre i tre modelli aggregati ibridi si attestano intorno a 0.56287. Per HGB, *injection_aggregate* raggiunge 0.854074, contro 0.562881 dei modelli aggregati *nb15_stin_aggregate* e *nb15_ter20_aggregate*. Per RF, la baseline raggiunge 0.890221, mentre gli aggregati ibridi rimangono nuovamente prossimi a 0.56287.

Il valore intorno a 0.5625 non rappresenta una prestazione uniformemente intermedia sui singoli test set. Esso sintetizza due regimi fortemente differenti: prestazioni quasi perfette sui nove benchmark target e prestazioni prossime allo zero sui sei benchmark NB15 e su INJECTION.

Numerose configurazioni ibride presentano inoltre dispersioni inter-seed estremamente contenute, fino a deviazioni standard nulle. Tale stabilità non costituisce di per sé un indicatore di migliore qualità predittiva: una configurazione può riprodurre con elevata regolarità un comportamento fortemente specializzato e mantenere comunque una prestazione globale inferiore alla baseline.

Risultati del test t di Welch. I risultati completi dei 27 confronti sono riportati nella Tabella B.13 in Appendice. Tutti soddisfano la condizione $p < 0.05$ e tutte le statistiche t assumono segno positivo. Secondo il test adottato, le distribuzioni delle medie F1 multi-seed non risultano quindi compatibili con l'ipotesi nulla di uguaglianza delle medie per nessuna delle configurazioni ibride considerate.

Il segno delle statistiche deve essere letto congiuntamente alle medie campionarie: la baseline costituisce il primo campione fornito alla procedura e presenta in ogni confronto una media globale superiore. Il test rimane comunque bilaterale e la direzione empirica del divario deriva dal confronto delle statistiche descrittive, non dalla formulazione dell'ipotesi alternativa.

La significatività globale non implica che la baseline superi i modelli ibridi su ciascun benchmark individualmente. Tale interpretazione sarebbe incompatibile con i risultati precedenti, nei quali gli aggregati ibridi raggiungono TPR superiori alla baseline sulle distribuzioni target. Il test indica invece che, secondo la misura globale sui 16 benchmark, i due paradigmi presentano medie differenti; la direzione osservata è favorevole alla baseline perché quest'ultima conserva contemporaneamente prestazioni elevate sul sorgente e sul target.

I modelli aggregati raggiungono generalmente le maggiori medie globali all'interno del gruppo ibrido, coerentemente con la loro maggiore trasferibilità cross-target. I rilevatori biclasse possono invece ottenere prestazioni perfette sulla distribuzione omologa mantenendo una copertura molto inferiore delle altre famiglie.

Come nella precedente analisi di Welch, i p -value vengono valutati individualmente rispetto a $\alpha = 0.05$ senza applicare correzioni per confronti multipli. La valutazione mantiene pertanto il carattere esplorativo previsto dal protocollo sperimentale e non realizza un controllo globale dell'errore di I tipo sull'insieme dei 27 confronti.

Sintesi della valutazione dei modelli ibridi. La valutazione di $\mathcal{M}_H$ distingue nettamente specializzazione target e generalizzazione globale. I modelli aggregati ibridi raggiungono le maggiori sensibilità sulle distribuzioni target e una TNR sistematicamente unitaria, ma perdono quasi completamente la capacità di riconoscere gli attacchi sorgente. L'analisi SHAP mostra contestualmente una riorganizzazione della gerarchia decisionale verso le feature di finestra, in presenza del confondimento strutturale tra dominio e classe.

La baseline INJECTION, pur non massimizzando la TPR sui soli benchmark target, mantiene un comportamento più uniforme sull'intera cross-evaluation. I 27 confronti Welch risultano significativi secondo il criterio adottato e le medie globali sono sistematicamente superiori per la baseline. Il risultato non identifica pertanto un paradigma intrinsecamente superiore in ogni condizione, ma due strategie con proprietà differenti: specializzazione target per $\mathcal{M}_H$ e maggiore conservazione congiunta della conoscenza sorgente e target per $\mathcal{M}_{\text{base}}$.

La Sezione 5.5 integra tali evidenze con quelle ottenute per i modelli sorgente e per la baseline in un quadro comparativo globale.

5.5 Discussione Generale e Quadro Comparativo Globale

Le sezioni precedenti hanno analizzato separatamente i tre paradigmi di addestramento considerati nel protocollo sperimentale: i modelli puramente sorgente $\mathcal{M}_S$, la baseline con conoscenza target sparsa $\mathcal{M}_{\text{base}}$ e i modelli ibridi $\mathcal{M}_H$. La presente sezione integra tali evidenze in un unico quadro interpretativo, mettendo in relazione capacità di rilevamento, generalizzazione cross-domain, stabilità multi-seed e organizzazione delle feature utilizzate dai classificatori.

L'obiettivo non consiste nel reiterare le singole metriche già discusse, ma nel distinguere tre proprietà complementari: conservazione della conoscenza sorgente, specializzazione verso il dominio target e capacità di mantenere simultaneamente entrambe le componenti. Tale distinzione risulta necessaria poiché la configurazione che massimizza la sensibilità sul solo dominio target non coincide necessariamente con quella che presenta il comportamento più uniforme lungo l'intera matrice di *cross-evaluation*.

5.5.1 Quadro Comparativo Globale

Criterio di sintesi. Il confronto viene effettuato sui medesimi raggruppamenti utilizzati nelle analisi precedenti. Indicando con $\mathcal{G}_S$ l'insieme dei sei benchmark appartenenti alla tassonomia NB15 e con $\mathcal{G}_T$ l'insieme dei nove benchmark target, la sensibilità media di un generico modello i sul gruppo $\mathcal{G}$ viene espressa come

$$\overline{TPR}_{i,\mathcal{G}} = \frac{1}{|\mathcal{G}|} \sum_{j \in \mathcal{G}} \overline{TPR}_{ij}, \quad (5.9)$$

dove $\overline{TPR}_{ij}$ rappresenta la TPR media sulle $K = 10$ repliche per la coppia modello–test set. Il benchmark INJECTION e la media sull’intero insieme dei 16 test vengono mantenuti separati, così da preservare l’informazione relativa all’asimmetria tra comportamento sorgente e target. Per l’F1-Score viene richiamata la misura globale multi-seed già definita nell’Equazione (5.6).

Nel paradigma $\mathcal{M}_S$ viene considerato nb15_aggregate; per $\mathcal{M}_{base}$ viene utilizzato injection_aggregate; per $\mathcal{M}_H$ vengono invece riportati gli intervalli minimo–massimo osservati tra i tre modelli aggregati nb15_stin_aggregate, nb15_sat20_aggregate e nb15_ter20_aggregate.

Sintesi quantitativa dei tre paradigmi. La Tabella 5.10 costituisce il riferimento quantitativo principale della discussione, riunendo le metriche necessarie a confrontare direttamente i tre paradigmi.

Tabella 5.10: Quadro comparativo globale dei modelli aggregati sorgente, baseline e ibridi. Per $\mathcal{M}_H$ gli intervalli rappresentano i valori minimo e massimo osservati tra i tre modelli aggregati ibridi.

Paradigma	Configurazione	$\overline{TPR}_{NB15}$	TPR_{INJ}	$\overline{TPR}_{Target}$	$\overline{TPR}_{16}$	$\overline{TNR}$	$\overline{F1}$
DT							
$\mathcal{M}_S$	nb15_aggregate	0.7870	0.82742	0.3234	0.5288	0.98317	0.56308
$\mathcal{M}_{base}$	injection_aggregate	0.78597	0.82748	0.96612	0.88990	0.98460	0.860388
$\mathcal{M}_H^{aggr}$	NB15+Target	0.0000	0.00320	0.999889–0.999922	0.56264–0.56266	1.0000	0.562863–0.562874
HGB							
$\mathcal{M}_S$	nb15_aggregate	0.7601	0.80387	0.0607	0.3694	0.99659	0.41231
$\mathcal{M}_{base}$	injection_aggregate	0.76085	0.80695	0.82970	0.80246	0.99658	0.854074
$\mathcal{M}_H^{aggr}$	NB15+Target	0.0000	0.00320	0.981796–0.999944	0.55246–0.56267	1.0000	0.556714–0.562881
RF							
$\mathcal{M}_S$	nb15_aggregate	0.7833	0.82719	0.3035	0.5161	0.99150	0.57651
$\mathcal{M}_{base}$	injection_aggregate	0.78198	0.82558	0.98821	0.90071	0.99057	0.890221
$\mathcal{M}_H^{aggr}$	NB15+Target	0.0000	0.00320	0.999894–0.999922	0.56264–0.56266	1.0000	0.562864–0.562874

Tre differenti regimi di generalizzazione. Il paradigma sorgente $\mathcal{M}_S$ conserva una capacità discriminativa significativa sui benchmark NB15 e mantiene TNR elevate, ma mostra una riduzione marcata della sensibilità quando la componente malevola appartiene ai domini target. Il limite

osservato riguarda pertanto principalmente la generalizzazione della regione positiva appresa e non una degradazione generalizzata della classificazione del traffico nominale.

La baseline $\mathcal{M}_{\text{base}}$ mantiene invece sul gruppo NB15 valori sostanzialmente coincidenti con quelli del corrispondente modello sorgente, con differenze della TPR media dell'ordine di 10^{-3} . Il comportamento sul target cambia tuttavia radicalmente: la sensibilità media raggiunge 0.96612 per DT, 0.82970 per HGB e 0.98821 per RF, mentre la TNR rimane sostanzialmente preservata. La presenza di conoscenza target sparsa è quindi associata, nel protocollo analizzato, a una forte estensione della capacità cross-domain senza una corrispondente perdita della sensibilità sorgente.

Il paradigma ibrido $\mathcal{M}_H$ rappresenta l'estremo opposto. I modelli aggregati raggiungono sensibilità target prossime all'unità e TNR pari a 1.0000, ma presentano TPR nulla sui benchmark NB15 e circa 0.00320 su INJECTION. La conoscenza target estesa non produce quindi un semplice ampliamento della funzione decisionale precedente: nei dati osservati emerge una sostituzione della specializzazione, nella quale l'elevata copertura del dominio target è accompagnata dalla perdita della capacità di riconoscere le anomalie sorgente.

Specializzazione target e generalizzazione globale. La progressione tra i tre paradigmi mostra che una maggiore quantità di conoscenza target nel training set non determina un miglioramento monotono della generalizzazione complessiva. Il passaggio da $\mathcal{M}_S$ a $\mathcal{M}_{\text{base}}$ produce un forte incremento della sensibilità target preservando il comportamento sul sorgente; il passaggio successivo a $\mathcal{M}_H$ incrementa ulteriormente la sensibilità target, ma sacrifica quasi completamente la retention delle anomalie NB15.

La conseguenza è evidente nelle metriche globali. La baseline raggiunge la maggiore TPR media sui 16 benchmark per tutte le architetture: 0.88990 per DT, 0.80246 per HGB e 0.90071 per RF. La medesima gerarchia emerge dall'F1-Score globale multi-seed, pari rispettivamente a 0.860388, 0.854074 e 0.890221. I modelli aggregati ibridi, pur massimizzando la sensibilità target, rimangono invece intorno a 0.56 nelle misure globali a causa del comportamento fortemente polarizzato tra i due domini.

Il risultato principale non consiste pertanto nella massimizzazione assoluta di una singola metrica, ma nel compromesso tra adattamento al nuovo dominio e conservazione delle conoscenze precedentemente apprese.

Influenza dell’architettura e della composizione del training set. L’architettura del classificatore modula tale compromesso senza modificarne la struttura generale. Nella baseline, RF presenta il profilo predittivo globale più favorevole, con la maggiore TPR target, la maggiore TPR sui 16 benchmark e il maggiore F1-Score globale. HGB presenta invece la maggiore specificità, pari a 0.99658, accompagnata da una sensibilità target inferiore; DT assume una posizione intermedia e mantiene valori relativamente prossimi a RF nella sensibilità target.

Le variazioni associate alla composizione del training set risultano tuttavia di magnitudine maggiore rispetto a molte delle differenze tra architetture. Il passaggio dal modello aggregato sorgente alla baseline incrementa la TPR target di +0.6427 per DT, +0.7690 per HGB e +0.6847 per RF, mantenendo invariata la famiglia algoritmica. Nel protocollo considerato, la composizione dei dati di addestramento costituisce quindi un fattore determinante per la generalizzazione cross-domain almeno quanto la scelta tra i tre classificatori analizzati.

Stabilità e significatività delle differenze globali. L’analisi multi-seed rafforza il quadro descrittivo. Tutti i 18 confronti di Welch tra baseline e modelli sorgente e tutti i 27 confronti tra baseline e modelli ibridi risultano significativi secondo il criterio $p < 0.05$ adottato dal protocollo. In tutti i casi la media globale dell’F1-Score risulta superiore per INJECTION.

Tale risultato riguarda la misura aggregata sui 16 benchmark e non implica una superiorità della baseline su ciascun test individuale: i modelli aggregati ibridi, ad esempio, mantengono TPR superiori sui benchmark target. I p -value sono inoltre valutati individualmente senza correzione per confronti multipli, per cui l’evidenza inferenziale conserva il carattere esplorativo definito dalla metodologia.

Nel complesso, $\mathcal{M}_S$ identifica il regime di conservazione in-domain con limitata robustezza al *domain shift*, $\mathcal{M}_H$ quello di massima specializzazione target, mentre $\mathcal{M}_{\text{base}}$ realizza il comportamento più uniforme nell’intera matrice sperimentale. Le differenti strutture decisionali associate a tali regimi vengono integrate nella sottosezione successiva con le evidenze distributive e SHAP.

5.5.2 Mappatura delle Associazioni tra Proprietà della Rete e Comportamento del Modello

Criterio interpretativo. Le analisi PCA e KDE hanno caratterizzato lo scostamento tra le distribuzioni sorgente e target, mentre SHAP ha identificato le feature maggiormente coinvolte nelle funzioni decisionali dei classificatori. La presente sottosezione mette in relazione tali evidenze con i profili prestazionali dei tre paradigmi.

Le corrispondenze discusse hanno carattere associativo e non causale. Il protocollo sperimentale non comprende interventi controllati sulle singole feature né studi di ablazione che permettano di isolare il contributo causale di una variabile alle prestazioni. Distribuzione, attribuzioni SHAP e comportamento predittivo vengono quindi considerate come evidenze complementari osservate nella medesima campagna sperimentale.

pkts_per_sec: elevato shift e centralità nei paradigmi sorgente e baseline. Tra le feature analizzate mediante KDE, pkts_per_sec presenta lo scostamento quantitativo più marcato tra la componente malevola NB15 e STIN, con differenze superiori a cinque ordini di grandezza nella media e a dodici ordini nella varianza.

La stessa variabile occupa la prima posizione SHAP per DT, HGB e RF sia nei modelli sorgente sia nella baseline. Una delle dimensioni maggiormente interessate dal *domain shift* coincide quindi con la feature alla quale tali modelli attribuiscono concordemente la maggiore rilevanza globale. Contestualmente, $\mathcal{M}_S$ presenta una forte perdita di sensibilità sul target, mentre $\mathcal{M}_{base}$ conserva la medesima feature dominante ma raggiunge una generalizzazione molto superiore.

L'evidenza non permette di attribuire il degrado dei modelli sorgente a pkts_per_sec isolatamente. Le attribuzioni mostrano infatti un comportamento non monotono e le funzioni decisionali utilizzano simultaneamente più dimensioni. La variabile rappresenta piuttosto un caso nel quale forte variazione distributiva ed elevata rilevanza predittiva coesistono.

Conoscenza target sparsa e conservazione della struttura sorgente. La baseline fornisce un secondo elemento interpretativo. Pur sostituendo soltanto 29 dei 9 300 campioni della componente malevola con traffico target, INJECTION mantiene una gerarchia SHAP largamente sovrapposta a

quella del modello sorgente: `pkts_per_sec` rimane prima per tutte le architetture e numerose feature secondarie continuano a occupare posizioni elevate.

La conoscenza target sparsa non coincide quindi con una completa riorganizzazione della funzione decisionale. Nel protocollo osservato, essa è associata alla conservazione della sensibilità NB15 e, simultaneamente, a un forte incremento della risposta sulle distribuzioni target. Non può essere concluso che i soli 29 campioni siano causalmente responsabili dell'intero incremento; è invece possibile affermare che la loro introduzione distingue sperimentalmente la baseline dal corrispondente paradigma sorgente.

total_bytes: variazione distributiva e rilevanza sorgente. Un comportamento analogo, ma meno estremo, riguarda `total_bytes`. La KDE mostra nel dominio target una forte riduzione della posizione media e della dispersione rispetto alla componente malevola NB15. Contestualmente, la feature occupa la seconda posizione per DT e RF nei modelli sorgente e mantiene elevata rilevanza nella baseline, dove è seconda per RF e terza per DT.

Nel modello aggregato ibrido la feature assume invece un ruolo molto più ridotto. La variazione della sua importanza tra i paradigmi conferma che una caratteristica fortemente informativa nel dominio sorgente non mantiene necessariamente la medesima priorità quando cambia radicalmente la composizione della classe positiva.

Feature di finestra e specializzazione del paradigma ibrido. La riorganizzazione più netta emerge nel modello aggregato NB15_STIN. La KDE mostra per `dst_win_byt` una distribuzione malevola target sensibilmente differente rispetto al riferimento NB15. Nei modelli sorgente tale feature occupa posizioni inferiori nelle graduatorie SHAP; nel paradigma ibrido diventa invece la caratteristica con maggiore rilevanza globale per DT, HGB e RF. `src_win_byt` assume contemporaneamente la seconda posizione in tutte le architetture.

Per `dst_win_byt`, valori ridotti sono frequentemente associati ai contributi SHAP positivi di maggiore ampiezza, mentre valori elevati tendono a produrre contributi negativi. Tale riorganizzazione delle attribuzioni coesiste con il profilo prestazionale caratteristico del paradigma ibrido: TNR unitaria sul traffico nominale sorgente, TPR prossime all'unità sulle distribuzioni target e sensibilità sostanzialmente nulla verso gli attacchi NB15.

L'interpretazione deve tuttavia considerare che nel benchmark NB15_STIN dominio e classe sono strutturalmente confusi: $Y = 0$ identifica traffico nominale NB15 e $Y = 1$ traffico malevolo STIN. Non è pertanto possibile determinare se la centralità delle feature di finestra rifletta proprietà intrinseche degli attacchi, differenze di dominio o una combinazione delle due informazioni.

Domain shift e rilevanza predittiva come proprietà distinte. Il confronto tra `pkts_per_sec` e `dst_win_byt` evidenzia un principio trasversale. La prima presenta lo scostamento quantitativo più estremo nella diagnostica KDE, ma nel paradigma ibrido scende alla settima posizione SHAP per DT e RF e alla quarta per HGB. La seconda presenta uno scostamento meno estremo, ma diventa la feature dominante in tutte le architetture ibride.

Ne consegue che

ampiezza del domain shift $\neq$ rilevanza predittiva.

La distanza marginale tra due distribuzioni e l'utilità della feature nella funzione decisionale descrivono proprietà differenti dello spazio dei dati. La classificazione dipende infatti dall'interazione multidimensionale tra le caratteristiche e non dalla sola entità dello scostamento osservato su una singola variabile.

Ruolo della composizione del training set. La lettura congiunta dei tre paradigmi mostra infine che la composizione della classe malevola è sistematicamente associata a differenti organizzazioni della funzione decisionale. Nel paradigma sorgente, la classe positiva è interamente NB15; nella configurazione INJECTION, il benchmark rimane prevalentemente sorgente e incorpora complessivamente 29 osservazioni target, delle quali 23 appartengono alla partizione di training; nel paradigma ibrido, la classe nominale è sorgente e quella malevola interamente target.

La progressione non descrive quindi un semplice incremento quantitativo della conoscenza target, ma tre differenti condizioni distributive di addestramento. Le rispettive gerarchie SHAP e i profili di generalizzazione mostrano che la modalità con cui il nuovo dominio viene incorporato nel training set è associata al tipo di conoscenza successivamente trasferito dal classificatore.

Mappatura sinottica delle evidenze. La Tabella 5.11 sintetizza le principali associazioni tra diagnostica distributiva, attribuzioni SHAP e comportamento prestazionale.

Tabella 5.11: Mappatura sinottica delle associazioni osservate tra evidenze distributive, rilevanza SHAP e comportamento prestazionale. Le associazioni riportate descrivono corrispondenze empiriche tra i fenomeni osservati, senza implicare relazioni causali dimostrate.

Evidenza distributiva	Evidenza SHAP	Comportamento associato
pkts_per_sec: scostamento più marcato tra componente malevola NB15 e STIN.	Prima feature per DT, HGB e RF nei modelli sorgente e nella baseline; rilevanza inferiore nei modelli ibridi.	Fragilità target dei modelli sorgente e forte incremento della generalizzazione nella baseline, che mantiene la feature dominante.
total_bytes: riduzione marcata di posizione e dispersione nel traffico malevolo STIN.	Elevata rilevanza soprattutto nei modelli sorgente e baseline DT/RF; posizione inferiore nel modello ibrido.	Dimensione rilevante nelle configurazioni che conservano una struttura decisionale maggiormente sovrapposta a quella sorgente.
dst_win_byt: distribuzione target differente e più concentrata rispetto al riferimento sorgente.	Prima feature per DT, HGB e RF nel modello aggregato NB15_STIN.	Centralità associata al profilo fortemente specializzato del paradigma ibrido: TPR target prossime all'unità e TPR sorgente prossime a zero.
src_win_byt: non inclusa tra le tre feature sottoposte a KDE; non viene quindi assunta una caratterizzazione densometrica specifica.	Seconda feature per DT, HGB e RF nel modello aggregato ibrido.	Ulteriore evidenza della riorganizzazione della funzione decisionale nel passaggio a NB15_STIN.
INJECTION: 29 campioni target su 9 300 campioni malevoli; composizione ancora fortemente dominata dal sorgente.	Gerarchie SHAP largamente sovrapposte a quelle dei modelli NB15.	TPR sorgente sostanzialmente preservata e forte incremento della sensibilità target.
Composizione ibrida: classe nominale NB15 e classe malevola interamente target; marcata separazione distributiva.	Centralità condivisa delle feature di finestra e riduzione del ruolo di diverse feature dominanti nel paradigma sorgente.	Massima sensibilità target ma perdita quasi completa del riconoscimento degli attacchi sorgente.

Nel complesso, nessuna singola feature o misura di distanza distributiva fornisce una spiegazione sufficiente del comportamento cross-domain. Le evidenze mostrano invece un'interazione

tra composizione del training set, scostamento delle distribuzioni e caratteristiche effettivamente utilizzate dai classificatori. In tale quadro, la baseline rappresenta la configurazione nella quale l'integrazione di conoscenza target è associata alla modifica della generalizzazione senza una sostituzione completa della struttura decisionale sorgente.

5.5.3 Compromesso tra Complessità Computazionale e Prestazioni

Perimetro dell'analisi. Il confronto tra classificatori deve essere mantenuto entro le grandezze effettivamente raccolte durante la campagna sperimentale. Il protocollo non comprende misure di tempo di addestramento, latenza di inferenza, occupazione di memoria, dimensione dei modelli serializzati, utilizzo della CPU o consumo energetico. Non è pertanto possibile costruire un rapporto quantitativo tra prestazioni e costo computazionale né stabilire quale architettura sia più adatta a specifici vincoli hardware.

Il termine “complessità computazionale” viene quindi utilizzato esclusivamente in senso qualitativo e architetturale. DT è costituito da un singolo albero decisionale; RF aggrega una molteplicità di alberi e, nella configurazione implementata, utilizza `n_jobs=-1`; HGB costruisce invece iterativamente un ensemble mediante gradient boosting su rappresentazioni a istogrammi. Tali differenze non vengono convertite in stime di latenza, memoria o consumo non disponibili sperimentalmente.

Prestazioni delle tre architetture nella baseline. La configurazione INJECTION costituisce il riferimento più informativo per il confronto, poiché il quadro globale ha mostrato che essa realizza il comportamento più uniforme tra sorgente e target.

RF presenta il miglior profilo predittivo complessivo: TPR target pari a 0.98821, TPR globale pari a 0.90071, TNR pari a 0.99057 e F1-Score globale multi-seed pari a 0.890221. DT raggiunge rispettivamente 0.96612, 0.88990, 0.98460 e 0.860388. Rispetto al singolo albero, RF incrementa quindi la TPR target di 0.02209 e l'F1-Score globale di 0.029833.

HGB presenta un profilo differente. La TNR raggiunge 0.99658, valore più elevato tra le tre baseline, mentre la TPR target si riduce a 0.82970 e l'F1-Score globale a 0.854074. Rispetto a HGB, RF presenta quindi un vantaggio di 0.15851 nella TPR target e di 0.036147 nell'F1-Score globale, a fronte di una specificità leggermente inferiore.

Il protocollo evidenzia pertanto un effettivo compromesso tra i due tipi di errore. HGB privilegia maggiormente la preservazione del traffico nominale, mentre RF riduce sensibilmente la quota di attacchi target non riconosciuti. DT mantiene un profilo competitivo mediante la struttura meno articolata tra quelle considerate, senza che tale proprietà possa essere trasformata in un vantaggio computazionale misurato.

Stabilità rispetto alle inizializzazioni. La dispersione della media globale dell’F1-Score lungo i 10 seed è pari a 0.003516 per DT, 0.036341 per HGB e 0.002452 per RF. RF combina quindi il maggiore valore medio con la minore dispersione tra le tre architetture della baseline; DT presenta anch’esso una variabilità contenuta, mentre HGB mostra una maggiore sensibilità all’inizializzazione.

La stabilità non rappresenta una misura di costo computazionale, ma costituisce un ulteriore elemento nella valutazione predittiva: il confronto non riguarda soltanto la prestazione media, ma anche la regolarità con cui essa viene riprodotta nelle differenti repliche.

Composizione del training set e articolazione del modello. Le differenze tra algoritmi devono essere interpretate insieme alla composizione dei dati di addestramento. Mantenendo invariata l’architettura, il passaggio dal modello aggregato sorgente alla baseline incrementa la TPR target di +0.6427 per DT, +0.7690 per HGB e +0.6847 per RF. Tali scostamenti sono sensibilmente superiori alle differenze osservate tra DT, HGB e RF all’interno della sola baseline.

Analogamente, nei modelli aggregati ibridi tutte le architetture convergono verso TPR target prossime all’unità e TPR sorgente nulle. La maggiore articolazione algoritmica non elimina quindi gli effetti associati alla distribuzione utilizzata per il training. Nel protocollo considerato, composizione dei dati e architettura interagiscono nel determinare il comportamento finale, ma la prima produce in diversi confronti le variazioni prestazionali di maggiore magnitudine.

Sintesi qualitativa del compromesso. La Tabella 5.12 riassume il confronto senza attribuire ai classificatori costi computazionali non misurati.

Tabella 5.12: Sintesi qualitativa del compromesso tra articolazione del modello e prestazioni osservate nella configurazione INJECTION.

Articolazione strutturale	Punto di forza osservato	Limite / compromesso osservato
DT: singolo albero	Elevata TPR target (0.96612) e buona prestazione globale.	Prestazioni inferiori a RF; TNR più bassa tra le tre baseline (0.98460).
HGB: ensemble iterativo basato su boosting	Massima TNR (0.99658).	Sensibilità target più ridotta (0.82970) e maggiore dispersione inter-seed dell’F1-Score.
RF: ensemble di alberi	Massima TPR target (0.98821), massimo F1 globale (0.890221) e minore dispersione inter-seed (0.002452).	Struttura più articolata rispetto al singolo DT; il relativo costo computazionale non è quantificato dal protocollo.

Considerando esclusivamente le grandezze misurate, RF costituisce quindi il riferimento prestazionale più favorevole nella baseline, mentre HGB presenta il profilo maggiormente orientato alla specificità e DT conserva prestazioni competitive mediante una struttura algoritmica meno articolata. Non è tuttavia possibile derivare da tali risultati un ordinamento rispetto a latenza, memoria, energia o idoneità a una specifica piattaforma di esecuzione.

5.5.4 Considerazioni Operative per l’Applicabilità in Ambito NIDS Satellitare

Perimetro delle considerazioni operative. Le evidenze sperimentali consentono di derivare alcune implicazioni per la valutazione di un NIDS in presenza di *domain shift*, ma non costituiscono una validazione di deployment satellitare. La campagna misura prestazioni predittive, generalizzazione cross-domain, stabilità multi-seed e caratteristiche della funzione decisionale; non misura invece proprietà della piattaforma quali latenza, memoria o consumo energetico.

Le considerazioni seguenti riguardano pertanto esclusivamente il comportamento osservato nei benchmark e nelle condizioni sperimentali definite dal framework.

Generalizzazione cross-domain come requisito di valutazione. Il primo risultato operativo riguarda i modelli addestrati esclusivamente sul sorgente. Le elevate prestazioni in-domain non vengono preservate in modo uniforme quando la distribuzione degli attacchi viene sostituita dal target, mentre la TNR rimane elevata.

Una valutazione limitata al dataset utilizzato durante l'addestramento non risulta quindi sufficiente a caratterizzare la robustezza del classificatore. Nel protocollo considerato, la matrice di *cross-evaluation* risulta essenziale proprio perché separa la capacità di riconoscere il traffico noto dalla capacità di estendere la regione positiva a distribuzioni malevole differenti.

Conoscenza target sparsa e preservazione della conoscenza sorgente. La baseline INJECTION costituisce l'evidenza principale in questa prospettiva. La sostituzione di 29 campioni sui 9 300 appartenenti alla classe malevola, pari a circa lo 0.31%, è associata a un forte incremento della sensibilità target senza una perdita sostanziale della sensibilità sui benchmark NB15.

Tale risultato deve essere mantenuto strettamente circoscritto alla configurazione sperimentale analizzata. Non dimostra che 29 osservazioni siano universalmente sufficienti per adattare un NIDS a un nuovo dominio; mostra invece che, nel trasferimento NB15→STIN considerato, una conoscenza target molto sparsa distingue nettamente il comportamento della baseline da quello dei modelli puramente sorgente.

Specializzazione target e retention. I modelli aggregati ibridi mostrano il limite complementare. Essi massimizzano la sensibilità sulle distribuzioni target e raggiungono TNR unitaria, ma perdono quasi completamente la capacità di riconoscere gli attacchi NB15. L'adattamento esteso al nuovo dominio non può quindi essere valutato soltanto rispetto alla prestazione ottenuta dopo il cambiamento.

Nel protocollo considerato, un aggiornamento efficace deve essere caratterizzato contemporaneamente rispetto alla nuova distribuzione, alla retention delle anomalie precedentemente apprese e alla preservazione del traffico nominale. La cross-evaluation evidenzia precisamente tale distin-

zione, impedendo che la prestazione quasi perfetta sul target mascheri la perdita della conoscenza sorgente.

Compromesso tra falsi positivi e attacchi non rilevati. Le tre architetture della baseline producono inoltre profili differenti tra sensibilità e specificità. HGB raggiunge la TNR più elevata, 0.99658, ma una TPR target pari a 0.82970; RF associa una TNR pari a 0.99057 a una TPR target di 0.98821; DT raggiunge rispettivamente 0.98460 e 0.96612.

Non emerge pertanto un classificatore che domini simultaneamente ogni dimensione. Se il criterio di selezione è limitato alle prestazioni predittive globali e alla stabilità multi-seed, RF costituisce il riferimento più favorevole tra le configurazioni analizzate. Tale risultato non equivale tuttavia a una selezione definitiva per un sistema operativo, poiché il protocollo non misura il costo dell'esecuzione.

Diagnostica del domain shift e interpretabilità. PCA, KDE e SHAP forniscono inoltre strumenti complementari per caratterizzare variazioni del dominio. Le prime due tecniche evidenziano modificazioni geometriche e distributive dello spazio delle feature, mentre SHAP consente di verificare se tali condizioni siano accompagnate da una riorganizzazione delle caratteristiche maggiormente utilizzate dal modello.

Nel presente lavoro tali tecniche svolgono esclusivamente una funzione diagnostica. Non è definita una soglia automatica di *drift detection* e non viene implementato un meccanismo autonomo di aggiornamento o riaddestramento. Analogamente, SHAP permette di identificare la diversa struttura decisionale dei paradigmi, ma non risolve causalmente il confondimento tra classe e dominio presente nei benchmark ibridi.

Limite della componente nominale condivisa. Un limite sperimentale rilevante riguarda la distribuzione del traffico nominale. Nei differenti benchmark di valutazione la componente nominale proviene sempre dal dominio sorgente NB15; la variazione cross-domain riguarda quindi la componente malevola.

Le TNR elevate osservate dimostrano pertanto la preservazione della classificazione sul traffico nominale effettivamente incluso nel protocollo, ma non permettono di concludere che la specificità

rimarrebbe invariata in presenza di un differente dominio nominale. Il presente esperimento non valuta quindi un *benign-domain shift*.

Soglia decisionale. La pipeline utilizza inoltre le predizioni dei classificatori senza una calibrazione personalizzata della soglia decisionale per i differenti benchmark. Le metriche riportate descrivono quindi la configurazione effettivamente implementata e non il risultato di un’ottimizzazione successiva del compromesso tra falsi positivi e falsi negativi.

Le curve Precision–Recall e le diagnostiche di soglia generate dal framework non vengono utilizzate nel presente capitolo per selezionare una soglia operativa ottimale; nessuna conclusione in tal senso viene pertanto derivata dai risultati.

Sintesi delle implicazioni operative. La Tabella 5.13 riassume le principali implicazioni direttamente supportate dal protocollo sperimentale.

Tabella 5.13: Sintesi delle implicazioni operative dei tre paradigmi di addestramento nell’ambito del protocollo NIDS considerato.

Paradigma	Evidenza favorevole	Criticità osservata	Implicazione operativa
$\mathcal{M}_S$	Conservazione della sensibilità sul dominio sorgente e TNR elevata.	Forte riduzione della TPR sulle distribuzioni target.	La sola validazione in-domain non è sufficiente a caratterizzare la robustezza cross-domain.
$\mathcal{M}_{base}$	Conservazione della TPR sorgente accompagnata da un forte incremento della sensibilità target mediante conoscenza target sparsa.	Prestazioni target inferiori agli aggregati ibridi e dipendenti dall’architettura utilizzata.	Configurazione più uniforme per la copertura simultanea di distribuzioni sorgente e target nell’insieme sperimentale considerato.
$\mathcal{M}_H$	TPR target prossime all’unità e TNR pari a 1.0000 nei modelli aggregati.	Perdita quasi completa della sensibilità verso gli attacchi sorgente.	L’adattamento esteso al nuovo dominio deve essere valutato anche rispetto alla retention delle conoscenze precedentemente apprese.

Nel complesso, i risultati mostrano che la robustezza cross-domain non può essere valutata esclusivamente mediante la massima prestazione ottenuta su un singolo dominio. Nel perimetro sperimentale analizzato, il criterio più discriminante è la capacità di acquisire informazione sul target preservando contemporaneamente la conoscenza sorgente e la corretta classificazione del traffico nominale.

Sotto tale criterio, INJECTION realizza il compromesso più uniforme tra i tre paradigmi considerati. All'interno della baseline, RF presenta il profilo predittivo globale più favorevole, mentre l'assenza di misure computazionali e di una variazione del dominio nominale impedisce di estendere tale risultato a una selezione definitiva per un deployment satellitare. Le evidenze raccolte costituiscono pertanto la sintesi interpretativa della campagna sperimentale e preparano la conclusione del capitolo.

5.6 Sintesi e Conclusioni del Capitolo

Il presente capitolo ha completato la validazione sperimentale del framework attraverso una lettura congiunta delle proprietà distributive dei benchmark, delle prestazioni predittive, della stabilità multi-seed e delle caratteristiche maggiormente coinvolte nelle funzioni decisionali dei classificatori.

La diagnostica mediante PCA e KDE ha mostrato che il passaggio dal dominio sorgente NB15 alle distribuzioni target non corrisponde a una perturbazione uniforme dello spazio delle feature. Le variabili analizzate presentano infatti scostamenti differenti per scala, posizione e dispersione, confermando la presenza di un *domain shift* rilevante tra le componenti malevole sorgente e target. Tale evidenza costituisce il contesto distributivo entro il quale devono essere interpretate le prestazioni dei modelli, senza attribuire a una singola feature un ruolo causale nel comportamento osservato.

Il confronto tra i tre paradigmi di addestramento ha evidenziato regimi di generalizzazione distinti. I modelli puramente sorgente $\mathcal{M}_S$ mantengono una capacità discriminativa significativa sui benchmark NB15 e una TNR elevata, ma presentano una marcata perdita di sensibilità sulle distribuzioni malevole target. I modelli ibridi $\mathcal{M}_H$ raggiungono invece TPR target prossime all'unità e, nelle configurazioni aggregate, TNR pari a 1.0000, ma perdono quasi completamente la capacità

di riconoscere gli attacchi sorgente. La massima specializzazione sul nuovo dominio non coincide pertanto, nel protocollo considerato, con la migliore generalizzazione complessiva.

Tra tali estremi si colloca la baseline $\mathcal{M}_{\text{base}}$, addestrata mediante INJECTION. La configurazione INJECTION è costruita sostituendo 29 dei 9 300 campioni malevoli del benchmark con osservazioni target, pari a circa lo 0.31% della componente positiva complessiva. Tale configurazione risulta associata a un marcato incremento della sensibilità cross-domain senza una perdita sostanziale della sensibilità sorgente. La TPR media sui benchmark target raggiunge 0.96612 per DT, 0.82970 per HGB e 0.98821 per RF, mentre il comportamento sui benchmark NB15 rimane sostanzialmente sovrapposto a quello dei corrispondenti modelli sorgente.

La medesima distinzione emerge considerando l'intera matrice di *cross-evaluation*. La baseline raggiunge la maggiore TPR media sui 16 benchmark per tutte le architetture, pari a 0.88990 per DT, 0.80246 per HGB e 0.90071 per RF. Anche la sintesi multi-seed mediante F1-Score conferma tale comportamento, con valori globali rispettivamente pari a 0.860388, 0.854074 e 0.890221. Il vantaggio della configurazione INJECTION deve quindi essere interpretato come maggiore uniformità tra conservazione della conoscenza sorgente e riconoscimento delle distribuzioni target, e non come massimizzazione della prestazione su ogni singolo benchmark.

L'analisi inferenziale ha qualificato ulteriormente tale risultato. Tutti i 18 confronti di Welch tra la baseline e i modelli sorgente e tutti i 27 confronti con le configurazioni ibride risultano significativi secondo il criterio $p < 0.05$ adottato dal protocollo. Il test è applicato alla media dell'F1-Score sui 16 benchmark per ciascun seed; gli esiti caratterizzano pertanto una differenza globale tra le distribuzioni delle prestazioni multi-seed e non implicano una superiorità della baseline su ciascun test individuale. Secondo il test adottato, tali distribuzioni non risultano compatibili con l'ipotesi nulla di uguaglianza delle medie, tenuto conto della variabilità inter-seed osservata. I risultati mantengono inoltre il carattere esplorativo previsto dalla metodologia, poiché non è stata applicata una correzione per confronti multipli.

Le analisi SHAP hanno mostrato che i differenti regimi prestazionali sono accompagnati da differenti organizzazioni della funzione decisionale. Nei modelli sorgente e nella baseline, `pkts_per_sec` occupa la prima posizione di rilevanza globale per DT, HGB e RF; la baseline preserva quindi una struttura informativa largamente sovrapposta a quella sorgente, pur modificando l'ordinamento delle caratteristiche secondarie. Nel modello aggregato ibrido NB15_STIN, invece,

`dst_win_byt` e `src_win_byt` assumono rispettivamente la prima e la seconda posizione in tutte le architetture. La maggiore specializzazione target risulta pertanto associata anche a una sostanziale riorganizzazione delle feature utilizzate dal classificatore. Le corrispondenze tra diagnostica distribuita, SHAP e comportamento prestazionale devono tuttavia essere interpretate come associazioni empiriche e non come relazioni causali dimostrate.

Il confronto tra le architetture ha infine mostrato che DT, HGB e RF modulano diversamente il compromesso tra sensibilità, specificità e stabilità, senza annullare l'effetto della composizione del training set. Nella baseline, RF presenta il profilo predittivo globale più favorevole, associando la maggiore sensibilità target, la maggiore TPR globale, il maggiore F1-Score medio multi-seed e la minore dispersione di quest'ultimo tra le tre architetture. HGB privilegia maggiormente la specificità, raggiungendo la TNR più elevata a fronte di una sensibilità target inferiore, mentre DT mantiene prestazioni competitive mediante una struttura algoritmica qualitativamente meno articolata.

Tale confronto rimane circoscritto alle grandezze effettivamente misurate. La campagna sperimentale non comprende misure di latenza di inferenza, occupazione di memoria, dimensione dei modelli, utilizzo delle risorse o consumo energetico; non è quindi possibile derivare un ordinamento quantitativo dei classificatori rispetto al costo computazionale né identificare una configurazione definitivamente idonea a un deployment satellitare. Analogamente, la componente nominale dei benchmark rimane sempre derivata da NB15 e non viene quindi valutato un *domain shift* del traffico benigno.

Nel complesso, i risultati mostrano che la robustezza cross-domain non può essere valutata né attraverso la sola prestazione in-domain né mediante la massimizzazione della sensibilità sul nuovo dominio. Nel perimetro sperimentale analizzato, il criterio discriminante è rappresentato dalla capacità di acquisire informazione sul target preservando contemporaneamente la conoscenza precedentemente appresa e la corretta classificazione del traffico nominale. Sotto tale criterio, la configurazione INJECTION realizza il compromesso più uniforme tra i tre paradigmi considerati.

Con la presente sezione si conclude l'analisi sperimentale del framework. Le evidenze quantitative, statistiche e interpretative ottenute costituiscono la base empirica per le conclusioni complessive della tesi, nelle quali il contributo del lavoro verrà ricondotto agli obiettivi definiti nei capitoli precedenti e distinto dai limiti e dalle possibili estensioni del protocollo sperimentale.

6. Conclusioni Finali

Il presente capitolo conclude il percorso di ricerca sviluppato nella tesi, ricomponendo le evidenze metodologiche e sperimentali emerse dall'analisi della trasferibilità cross-domain di *Network Intrusion Detection Systems* (NIDS) basati su Machine Learning.

A partire dai risultati discussi nel Capitolo 5, vengono dapprima sintetizzati gli elementi fondamentali del lavoro svolto e, successivamente, formulate risposte esplicite alle domande di ricerca definite nel Capitolo 1. Le evidenze ottenute vengono quindi ricondotte ai contributi complessivi dello studio, distinguendo le implicazioni metodologiche dalle possibili ricadute per la futura progettazione di sistemi di rilevamento destinati a infrastrutture integrate terrestre-spaziali.

La trattazione si conclude con l'identificazione dei principali limiti della campagna sperimentale e con la definizione di possibili sviluppi futuri, mantenendo le considerazioni formulate entro il perimetro delle grandezze e delle condizioni effettivamente investigate.

6.1 Sintesi del Lavoro Svolto

Il lavoro di tesi ha affrontato il problema della generalizzazione di classificatori NIDS supervisionati in presenza di distribuzioni di traffico eterogenee, con particolare riferimento al trasferimento della conoscenza acquisita in un dominio sorgente terrestre verso domini target rappresentativi di scenari di comunicazione terrestre-spaziali.

La problematica è stata affrontata mediante la definizione di un framework metodologico volto a separare tre aspetti complementari: la rappresentazione comune delle osservazioni provenienti da domini differenti, la composizione controllata della conoscenza disponibile durante l'addestramento e la valutazione sistematica della capacità di generalizzazione dei classificatori.

Sul piano della rappresentazione dei dati, i dataset UNSW-NB15 e STIN, quest'ultimo articolato nei domini TER20 e SAT20, sono stati ricondotti a uno spazio condiviso delle *feature* mediante un operatore di mappatura finalizzato all'armonizzazione semantica e dimensionale delle grandezze di traffico. Tale passaggio ha consentito di definire una base comune sulla quale effettuare l'addestra-

mento e la successiva valutazione cross-domain, evitando che differenze puramente strutturali tra gli schemi originari dei dataset impedissero il confronto tra i domini considerati.

Su tale rappresentazione sono stati definiti differenti regimi di addestramento, caratterizzati da livelli progressivamente differenti di conoscenza del dominio target. La configurazione sorgente considera esclusivamente osservazioni appartenenti al dominio terrestre di origine; la configurazione *INJECTION* introduce invece una quantità fortemente limitata e controllata di campioni malevoli target all'interno del training set; le configurazioni ibride aumentano ulteriormente l'esposizione del classificatore alle distribuzioni target mediante l'impiego della relativa componente malevola disponibile. Questa articolazione ha permesso di analizzare il trasferimento cross-domain non come una condizione binaria tra assenza e piena disponibilità di conoscenza target, ma come un processo dipendente dalla quantità e dalla composizione dell'informazione resa disponibile durante l'apprendimento.

Parallelamente, il problema è stato osservato a differenti livelli di granularità della componente malevola attraverso la costruzione di benchmark aggregati e biclasse. In entrambi i casi il problema decisionale è rimasto binario, distinguendo traffico normale e traffico malevolo, mentre è variata la composizione della classe positiva: eterogenea nei modelli aggregati e circoscritta a una singola famiglia di attacco nei modelli specialistici. Tale distinzione ha consentito di valutare il rapporto tra specializzazione e capacità di generalizzazione rispetto a distribuzioni non coincidenti con quelle utilizzate durante l'addestramento.

La campagna sperimentale ha inoltre confrontato tre differenti famiglie di classificatori ad albero — *Decision Tree*, *Random Forest* e *Histogram-based Gradient Boosting* — attraverso un protocollo *multi-seed* e una matrice di valutazione incrociata tra modelli e benchmark. Le metriche predittive sono state affiancate da analisi statistiche e diagnostiche finalizzate a caratterizzare la stabilità delle prestazioni, il disallineamento distributivo tra i domini e la struttura decisionale appresa dai classificatori.

Nel complesso, i risultati discussi nel Capitolo 5 hanno evidenziato come la robustezza cross-domain non possa essere ricondotta alla sola capacità di ottenere elevate prestazioni sul dominio di addestramento o, alternativamente, alla massimizzazione della sensibilità sul dominio target. Nel perimetro sperimentale considerato, la composizione della conoscenza utilizzata durante l'addestramento è risultata uno dei fattori maggiormente associati al compromesso tra acquisizione di infor-

mazione relativa al nuovo dominio e conservazione delle proprietà discriminative precedentemente apprese sul sorgente.

In tale quadro, la configurazione *INJECTION*, pur incorporando una quantità estremamente ridotta di conoscenza target, ha mostrato un comportamento complessivamente più uniforme rispetto alle condizioni caratterizzate dall'assenza di informazione target o da una più marcata specializzazione verso le relative distribuzioni. Tale evidenza non viene interpretata come dimostrazione della superiorità generale di una specifica strategia di adattamento, ma costituisce il principale elemento sperimentale attraverso cui valutare, nelle sezioni successive, l'effetto della conoscenza target sparsa sulla generalizzazione cross-domain.

La sintesi appena delineata fornisce pertanto il quadro entro il quale ricondurre le evidenze sperimentali alle quattro domande di ricerca formulate all'inizio del lavoro. La sezione seguente analizza separatamente ciascuna domanda, distinguendo le conclusioni direttamente supportate dalla campagna sperimentale dalle interpretazioni che richiedono ulteriori verifiche.

6.2 Risposte alle Domande di Ricerca

Le evidenze sperimentali raccolte consentono di ricondurre i risultati ottenuti alle quattro domande di ricerca formulate nel Capitolo 1. La presente sezione ne fornisce una risposta esplicita, mantenendo distinte le conclusioni direttamente supportate dal protocollo sperimentale dalle interpretazioni che richiederebbero condizioni di validazione ulteriori.

6.2.1 RQ1 – Trasferibilità Diretta e Domain Shift

La prima domanda di ricerca è stata formulata come segue:

In quale misura un NIDS supervisionato, addestrato esclusivamente sul dominio sorgente, mantiene la propria capacità discriminativa quando viene valutato su distribuzioni malevole appartenenti ai domini target?

I risultati ottenuti indicano che, nel protocollo sperimentale considerato, la capacità discriminativa appresa esclusivamente sul dominio sorgente presenta una **trasferibilità diretta limitata e fortemente dipendente dalla distribuzione target considerata**.

Tale conclusione emerge in modo particolarmente evidente dall'analisi dei modelli aggregati sorgente. Le TPR medie ottenute sui benchmark appartenenti alla tassonomia NB15 risultano pari a 0.7870, 0.7601 e 0.7833, rispettivamente per Decision Tree, Histogram-based Gradient Boosting e Random Forest. Quando i medesimi classificatori vengono valutati sui benchmark target, tali valori si riducono rispettivamente a 0.3234, 0.0607 e 0.3035. Il degrado interessa pertanto tutte le architetture considerate, sebbene con intensità differente, evidenziando che una buona capacità discriminativa sul dominio di addestramento non implica il mantenimento della medesima sensibilità nei confronti di distribuzioni malevole non osservate durante il training.

Il comportamento della specificità consente di qualificare ulteriormente tale risultato. I modelli sorgente mantengono infatti valori elevati di TNR anche durante la cross-evaluation. Il fenomeno osservato non corrisponde quindi a un collasso indiscriminato della funzione di classificazione, ma riguarda principalmente la capacità di estendere alle nuove distribuzioni malevole le regioni decisionali apprese sul dominio sorgente. Nel perimetro dei dati disponibili, il classificatore continua pertanto a riconoscere correttamente gran parte del traffico nominale, mentre una quota rilevante delle osservazioni malevole target non viene intercettata.

Tale evidenza deve tuttavia essere interpretata considerando la composizione dei benchmark utilizzati. Il traffico benigno impiegato nella campagna sperimentale proviene infatti dal dominio sorgente UNSW-NB15 anche nelle configurazioni contenenti attacchi STIN. L'elevata TNR osservata non consente quindi di concludere che la capacità di riconoscimento del traffico nominale rimarrebbe invariata in presenza di un analogo *domain shift* della componente benigna. La valutazione condotta caratterizza specificamente il trasferimento rispetto alle **distribuzioni malevole target**.

L'analisi dei classificatori specialistici mostra inoltre che la trasferibilità non è completamente assente. Alcuni modelli biclasse addestrati su specifiche famiglie sorgente mantengono infatti sensibilità elevate nei confronti di determinate distribuzioni target, risultando compatibili con una parziale sovrapposizione delle regioni dello spazio delle caratteristiche associate a differenti famiglie di attacco. Tali episodi rimangono tuttavia circoscritti a particolari combinazioni modello–benchmark e non delineano un comportamento sistematico di generalizzazione verso l'intero dominio di destinazione.

Le evidenze prestazionali risultano infine coerenti con la diagnostica distributiva sviluppata nel Capitolo 5. Le analisi PCA e KDE hanno mostrato scostamenti tra la componente malevola sorgente

e le distribuzioni target nello spazio condiviso delle caratteristiche. Il contemporaneo degrado della sensibilità dei modelli addestrati esclusivamente su NB15 risulta quindi compatibile con l'ipotesi che osservazioni malevole appartenenti al nuovo dominio occupino regioni non adeguatamente rappresentate durante l'apprendimento. Tale corrispondenza viene interpretata in termini associativi e non causali, poiché il protocollo sperimentale non comprende interventi controllati sulle singole caratteristiche.

In risposta alla **RQ1**, è pertanto possibile concludere che, nelle condizioni sperimentali considerate, **l'addestramento esclusivamente sul dominio sorgente non risulta sufficiente a garantire una capacità discriminativa uniforme nei confronti delle distribuzioni malevole target**. La conoscenza acquisita sul sorgente conserva una trasferibilità parziale verso specifiche configurazioni, ma il comportamento complessivo evidenzia una marcata sensibilità al *domain shift*. Ne consegue che la sola validazione intra-domain non costituisce un indicatore sufficiente della robustezza di un NIDS destinato a operare in presenza di distribuzioni di traffico eterogenee.

6.2.2 RQ2 – Adattamento mediante Conoscenza Target Sparsa

La seconda domanda di ricerca è stata formulata come segue:

In quale misura l'introduzione di una quantità limitata e controllata di conoscenza target consente di migliorare la capacità di generalizzazione cross-domain preservando contemporaneamente la conoscenza discriminativa acquisita sul dominio sorgente?

Le evidenze sperimentali indicano che, nelle condizioni considerate, l'introduzione di una quantità estremamente ridotta di conoscenza target può essere associata a un marcato incremento della capacità di rilevamento cross-domain senza determinare una degradazione apprezzabile delle prestazioni medie sul dominio sorgente.

La configurazione *INJECTION* costituisce il riferimento principale per tale valutazione. La relativa componente malevola comprende 9 300 osservazioni, delle quali 9 271 appartengono al dominio sorgente e soltanto 29 provengono da STIN. La conoscenza target introdotta rappresenta pertanto circa lo 0.31% della componente malevola complessiva, mantenendo pressoché invariata la predominanza della distribuzione sorgente.

Nonostante tale proporzione fortemente sbilanciata, il confronto *multi-seed* con i modelli addestrati esclusivamente su NB15 mostra una variazione sostanziale della risposta alle distribuzioni target. Per Decision Tree, la TPR media sui nove benchmark target passa da 0.3234 nella configurazione sorgente a 0.9661 nella configurazione *INJECTION*; per Histogram-based Gradient Boosting, da 0.0607 a 0.8297; per Random Forest, da 0.3035 a 0.9882. Le differenze corrispondono rispettivamente a incrementi pari a +0.6427, +0.7690 e +0.6847.

Il miglioramento osservato sulla componente target non risulta accompagnato, sul piano descrittivo, da una perdita equivalente della conoscenza sorgente. Sui sei benchmark appartenenti alla tassonomia NB15, le differenze di TPR media tra il modello sorgente e la baseline risultano infatti pari a -0.0011 per DT, $+0.0008$ per HGB e -0.0013 per RF. Anche la TNR rimane sostanzialmente stabile tra le due configurazioni. Nel protocollo considerato, l'introduzione della componente target sparsa modifica pertanto principalmente la risposta verso le distribuzioni malevole non osservate dal modello puramente sorgente, mantenendo pressoché invariata la sensibilità media nei confronti delle distribuzioni NB15.

La valutazione sull'intera matrice di *cross-evaluation* rafforza tale interpretazione. La configurazione *INJECTION* presenta la maggiore media globale dell'F1-Score tra le configurazioni confrontate per tutte e tre le famiglie algoritmiche. L'analisi inferenziale mediante test t di Welch mostra inoltre differenze statisticamente significative rispetto ai modelli sorgente secondo il criterio adottato nel protocollo sperimentale. Tale risultato non implica una superiorità della baseline su ogni singolo benchmark, ma indica che il comportamento complessivo osservato lungo le differenti distribuzioni non risulta riconducibile alla sola variabilità stocastica associata all'inizializzazione dei classificatori.

Un ulteriore elemento di interpretazione deriva dal confronto con le configurazioni ibride, nelle quali la componente malevola target viene incorporata in misura sostanzialmente maggiore. Tali modelli raggiungono sensibilità molto elevate sulle distribuzioni target, in particolare nelle configurazioni aggregate, ma mostrano contemporaneamente una marcata perdita della capacità di riconoscere le distribuzioni d'attacco sorgente. L'incremento della conoscenza target non determina quindi, nel protocollo analizzato, un miglioramento uniforme della generalizzazione globale, ma può produrre una maggiore specializzazione verso il dominio di destinazione.

Sotto questo profilo, la configurazione *INJECTION* presenta il comportamento più uniforme

tra i tre regimi di addestramento considerati: rispetto al modello puramente sorgente acquisisce una capacità di rilevamento sensibilmente maggiore sulle distribuzioni target, mentre rispetto alle configurazioni ibride conserva in misura più consistente la conoscenza discriminativa relativa al dominio di origine. Tale osservazione suggerisce che il bilanciamento tra conoscenza sorgente e target costituisca un elemento rilevante nella progettazione di strategie di adattamento cross-domain.

La portata di tale conclusione deve tuttavia essere mantenuta entro i limiti del disegno sperimentale. La campagna non ha considerato una variazione progressiva del numero o della proporzione di osservazioni target introdotte durante l'addestramento. Non è quindi possibile stabilire se i 29 campioni impiegati costituiscano una quantità minima, ottimale o generalmente sufficiente, né determinare la forma della relazione tra quantità di conoscenza target e capacità di generalizzazione. Il risultato mostra che, per la specifica composizione dei benchmark e per le famiglie di classificatori considerate, la quota target prevista dalla configurazione *INJECTION* è associata a una modifica rilevante e favorevole del comportamento cross-domain.

In risposta alla **RQ2**, è pertanto possibile concludere che **una conoscenza target fortemente sparsa può produrre, nelle condizioni sperimentali analizzate, un rilevante miglioramento della generalizzazione verso le distribuzioni malevole target preservando sostanzialmente la capacità discriminativa acquisita sul dominio sorgente**. L'evidenza non identifica tuttavia una proporzione universalmente ottimale di campioni target, ma mostra come anche un'esposizione estremamente limitata al dominio di destinazione possa risultare associata a un cambiamento sostanziale della funzione di classificazione.

6.2.3 RQ3 – Granularità, Specializzazione e Generalizzazione

La terza domanda di ricerca è stata formulata come segue:

Come incide la granularità della rappresentazione della componente malevola sulla capacità del classificatore di generalizzare in presenza di variazioni distributive?

I risultati ottenuti indicano che la granularità della componente malevola incide in modo sostanziale sul compromesso tra specializzazione e generalizzazione. Nel protocollo sperimentale considerato, i modelli addestrati su una rappresentazione aggregata delle distribuzioni d'attacco mostrano generalmente un comportamento più uniforme quando vengono trasferiti verso benchmark

differenti, mentre i rilevatori biclasse tendono a sviluppare una risposta maggiormente specializzata rispetto alla singola famiglia utilizzata durante l'addestramento.

Tale confronto non riguarda una distinzione tra classificazione binaria e multiclasse. Lo spazio di uscita rimane infatti binario in entrambe le configurazioni, distinguendo traffico normale e traffico malevolo. Ciò che varia è la composizione della classe positiva: nei modelli aggregati essa comprende simultaneamente più famiglie d'attacco, mentre nei modelli specialistici viene circoscritta a una singola distribuzione malevola. La granularità deve pertanto essere interpretata come proprietà della conoscenza utilizzata per definire la regione positiva e non come variazione della cardinalità dello spazio delle etichette predette.

L'analisi dei modelli biclasse evidenzia chiaramente l'effetto della specializzazione. I rilevatori specialistici raggiungono frequentemente sensibilità molto elevate, o prossime all'unità, quando vengono valutati sulla medesima famiglia d'attacco utilizzata durante l'addestramento. Tale comportamento non si trasferisce tuttavia in modo sistematico alle altre distribuzioni. La risposta cross-domain e cross-family risulta fortemente eterogenea e dipendente dalla specifica configurazione considerata.

Un esempio significativo è fornito dai modelli ibridi addestrati sulla distribuzione Syn_DDoS del dominio SAT20. Sulla relativa famiglia omologa, le tre architetture raggiungono una TPR pari a 1.0000; considerando invece l'insieme dei nove benchmark target, la sensibilità media si riduce a circa 0.4244 per DT, 0.3156 per HGB e 0.4438 per RF. La forte prestazione sulla distribuzione utilizzata nel training non implica quindi, in questo caso, una capacità equivalente di rilevare altre popolazioni malevole appartenenti allo stesso insieme target.

Il comportamento degli specialistici non è tuttavia uniformemente sfavorevole. Alcune famiglie presentano una trasferibilità sensibilmente maggiore verso distribuzioni differenti. Il modello specialistico SAT20 UDP_DDoS, ad esempio, raggiunge una TPR target media pari a circa 0.9749 per DT e 0.8989 per RF, mostrando un comportamento compatibile, in specifiche condizioni, con la presenza di caratteristiche discriminative condivise tra differenti distribuzioni malevole. Anche tra i modelli sorgente sono stati osservati trasferimenti locali rilevanti tra determinate famiglie.

Tali casi impediscono di stabilire una relazione deterministica secondo cui una maggiore specializzazione conduca necessariamente a una minore generalizzazione. I risultati indicano piuttosto che la granularità ristretta aumenta la dipendenza del comportamento del classificatore dalla cor-

rispondenza tra la distribuzione utilizzata durante l'apprendimento e quella incontrata in fase di valutazione.

Un quadro differente emerge per le configurazioni aggregate. Nel paradigma ibrido, i modelli NB15_STIN, NB15_SAT20 e NB15_TER20 mantengono TPR prossime all'unità sull'insieme dei benchmark target anche quando la distribuzione di valutazione non coincide con quella specificamente impiegata per la costruzione del training set. La maggiore eterogeneità della componente positiva risulta pertanto associata, nel perimetro analizzato, a una copertura più uniforme delle distribuzioni malevole target.

La medesima differenza emerge considerando l'F1-Score medio calcolato sull'intera matrice di *cross-evaluation*. All'interno del gruppo dei modelli ibridi, le configurazioni aggregate raggiungono generalmente valori globali superiori rispetto alla maggior parte dei rilevatori specialistici. Gli specialistici possono conseguire prestazioni eccellenti localmente, ma vengono maggiormente penalizzati quando la valutazione comprende distribuzioni differenti da quella utilizzata durante l'addestramento.

Sul piano interpretativo, tali risultati sono compatibili con l'ipotesi metodologica secondo cui l'esposizione simultanea a più distribuzioni malevole consenta di apprendere una regione decisionale capace di rappresentare una porzione più ampia dello spazio occupato dalla classe positiva. Al contrario, l'addestramento su una singola famiglia può produrre una regione maggiormente aderente alle caratteristiche specifiche di quella distribuzione, aumentando la sensibilità locale ma anche la dipendenza dalla somiglianza con le osservazioni incontrate successivamente. Tale interpretazione rimane comunque descrittiva e non costituisce una dimostrazione geometrica o causale della forma delle regioni decisionali apprese.

In risposta alla **RQ3**, è quindi possibile concludere che **una rappresentazione più aggregata ed eterogenea della componente malevola risulta generalmente associata a una maggiore uniformità della generalizzazione cross-domain, mentre una granularità specialistica favorisce prestazioni elevate sulla distribuzione di riferimento ma produce una trasferibilità più variabile verso famiglie differenti**. La scelta della granularità rappresenta pertanto un compromesso tra specializzazione locale e ampiezza della capacità discriminativa, la cui configurazione più appropriata dipende dall'obiettivo operativo e dalla variabilità delle distribuzioni che il NIDS è chiamato a riconoscere.

6.2.4 RQ4 – Architettura, Stabilità e Struttura Decisionale

La quarta domanda di ricerca è stata formulata come segue:

In quale misura l'architettura del classificatore modifica il compromesso tra sensibilità, specificità, stabilità e robustezza cross-domain nei differenti regimi di addestramento?

I risultati ottenuti mostrano che l'architettura del classificatore contribuisce a modificare il compromesso tra sensibilità, specificità e stabilità, senza tuttavia determinare autonomamente il comportamento cross-domain del sistema. Le differenze osservate tra Decision Tree, Histogram-based Gradient Boosting e Random Forest devono infatti essere interpretate congiuntamente alla composizione del training set e al regime di addestramento nel quale ciascun classificatore viene utilizzato.

La configurazione *INJECTION* consente di effettuare il confronto più diretto tra le tre architetture, poiché mantiene invariata la composizione dei dati e modifica esclusivamente la famiglia algoritmica. In tale condizione, Random Forest presenta il profilo predittivo complessivamente più favorevole tra i classificatori considerati. La TPR media sui benchmark target raggiunge 0.98821, mentre la media globale dell'F1-Score lungo l'intera matrice di *cross-evaluation* è pari a 0.890221. La TNR rimane contestualmente elevata, pari a 0.99057.

Decision Tree mostra un comportamento relativamente vicino a RF sul piano della sensibilità target, raggiungendo una TPR media pari a 0.96612 e un F1-Score globale pari a 0.860388. La relativa TNR, pari a 0.98460, risulta tuttavia la più contenuta tra le tre baseline. Nel perimetro delle sole metriche predittive analizzate, DT si colloca pertanto in una posizione intermedia, mantenendo una buona capacità di rilevamento cross-domain senza raggiungere il profilo globale osservato per RF.

Histogram-based Gradient Boosting presenta invece un compromesso differente. La TNR della baseline raggiunge 0.99658, il valore più elevato tra le tre architetture, indicando una maggiore capacità di contenere i falsi positivi sul traffico nominale considerato. Tale proprietà è accompagnata da una TPR target pari a 0.82970, inferiore ai valori ottenuti da DT e RF, e da un F1-Score globale pari a 0.854074. L'architettura HGB mostra pertanto, nella configurazione analizzata, un comportamento maggiormente orientato alla specificità rispetto alla sensibilità verso le distribuzioni malevole target.

Il confronto *multi-seed* introduce un ulteriore elemento discriminante. La deviazione standard dell'F1-Score globale della baseline è pari a 0.003516 per DT, 0.036341 per HGB e 0.002452 per RF. Random Forest associa quindi alla maggiore prestazione media globale anche la minore dispersione rispetto alle inizializzazioni considerate. Decision Tree mantiene anch'esso una variabilità contenuta, mentre HGB presenta una dispersione superiore di circa un ordine di grandezza rispetto agli altri due classificatori.

Tale evidenza consente di distinguere prestazione e stabilità come proprietà complementari. Una singola esecuzione caratterizzata da metriche elevate non è infatti sufficiente a descrivere il comportamento di un classificatore quando il processo di apprendimento comprende componenti stocastiche. Nel protocollo considerato, RF mostra il comportamento più regolare tra le repliche della baseline, mentre HGB risulta maggiormente sensibile alla variazione del seed.

Le differenze architetturali emergono anche dall'analisi post-hoc delle attribuzioni SHAP. Nei modelli sorgente e nella configurazione *INJECTION*, *pkts_per_sec* occupa la prima posizione di rilevanza globale per tutte e tre le architetture, evidenziando l'esistenza di un nucleo informativo condiviso. L'ordinamento delle caratteristiche successive varia tuttavia tra i classificatori: DT e RF attribuiscono maggiore rilevanza a descrittori legati ai volumi e al carico trasmissivo, mentre HGB assegna un ruolo più marcato ad alcuni rapporti direzionali del flusso. L'architettura modifica quindi il modo in cui l'informazione disponibile viene organizzata all'interno della funzione decisionale, pur partendo dal medesimo spazio delle caratteristiche.

Un cambiamento ancora più marcato viene osservato nel paradigma ibrido. Per DT, HGB e RF, *dst_win_byt* e *src_win_byt* assumono rispettivamente la prima e la seconda posizione nella graduatoria SHAP del modello aggregato NB15_STIN. Le tre architetture convergono pertanto sulle medesime caratteristiche dominanti quando la composizione del training set viene modificata sostanzialmente verso il dominio target.

Persistono tuttavia differenze nella distribuzione delle attribuzioni. Nei modelli DT e HGB la funzione decisionale appare maggiormente concentrata sulle due principali caratteristiche di finestra, mentre RF mantiene contributi osservabili distribuiti anche su ulteriori dimensioni dello spazio delle feature. Tale differenza descrive una diversa organizzazione interna della funzione decisionale, ma non consente di attribuire causalmente a tale struttura le differenze prestazionali osservate.

Il confronto tra regimi di addestramento mostra infatti che l'effetto della composizione dei dati può risultare più marcato delle differenze tra le architetture. Il passaggio dal modello sorgente alla configurazione *INJECTION*, mantenendo invariata la famiglia algoritmica e introducendo soltanto una quota estremamente ridotta di campioni target, determina incrementi della TPR target pari a +0.6427 per DT, +0.7690 per HGB e +0.6847 per RF. Tali variazioni sono sensibilmente superiori alle differenze osservate tra i tre classificatori all'interno della medesima configurazione *INJECTION*.

Analogamente, nelle configurazioni aggregate ibride tutte e tre le architetture raggiungono sensibilità prossime all'unità sulle distribuzioni target e, contemporaneamente, perdono quasi completamente la capacità di riconoscere gli attacchi sorgente. Il fenomeno di specializzazione non viene quindi eliminato dalla scelta di DT, HGB o RF, ma coinvolge trasversalmente le tre famiglie algoritmiche quando la composizione della conoscenza di addestramento viene modificata in modo sostanziale.

In risposta alla **RQ4**, è pertanto possibile concludere che **l'architettura del classificatore modula il compromesso tra sensibilità, specificità, stabilità e struttura decisionale, ma la robustezza cross-domain dipende in misura sostanziale anche dalla composizione delle distribuzioni utilizzate durante l'addestramento**. Nel protocollo sperimentale considerato, Random Forest presenta il comportamento complessivamente più favorevole nella configurazione *INJECTION*, combinando elevata sensibilità target, maggiore F1-Score globale e ridotta dispersione inter-seed; HGB privilegia maggiormente la specificità, mentre DT mantiene un comportamento intermedio.

Tale risultato non consente tuttavia di identificare RF come architettura generalmente ottimale per un NIDS destinato a infrastrutture terrestre-spaziali. La campagna sperimentale non comprende infatti misure di latenza di inferenza, occupazione di memoria, dimensione del modello, utilizzo delle risorse hardware o consumo energetico. Le conclusioni riguardano pertanto esclusivamente le proprietà predittive e di stabilità effettivamente misurate e non costituiscono una raccomandazione definitiva rispetto a un deployment operativo.

Le conclusioni formulate per le quattro domande di ricerca sono sintetizzate nella Tabella 6.1, che associa a ciascuna RQ la risposta emersa dalla campagna sperimentale, la relativa evidenza principale e il limite interpretativo.

Tabella 6.1: Sintesi delle risposte alle domande di ricerca e delle relative evidenze sperimentali.

RQ	Risposta	Evidenza	Limite
RQ1	Trasferibilità source-only limitata e dipendente dalla distribuzione target.	Marcata riduzione della TPR sui target, con episodi locali di trasferibilità.	<i>Benign-domain shift</i> non valutato.
RQ2	Conoscenza target sparsa associata a una maggiore generalizzazione cross-domain.	<i>INJECTION</i> : 29 campioni target incrementano la sensibilità target preservando sostanzialmente la risposta su NB15.	I 29 campioni non definiscono una quantità minima od ottimale.
RQ3	Aggregazione associata a una generalizzazione più uniforme; specializzazione maggiormente dipendente dalla distribuzione.	Modelli aggregati più uniformi; rilevatori biclasse più dipendenti dalla famiglia d'attacco.	Presenti eccezioni di trasferimento tra specifiche famiglie.
RQ4	L'architettura modula sensibilità, specificità e stabilità.	RF mostra il profilo misurato più favorevole; HGB privilegia la specificità; DT risulta intermedio.	Costi computazionali e di deployment non valutati.

6.3 Contributi e Implicazioni del Lavoro

Le risposte alle domande di ricerca consentono di ricondurre le evidenze sperimentali ai contributi metodologici, sperimentali e implementativi dichiarati nel Capitolo 1. Il contributo del presente lavoro non consiste nella proposta di una nuova architettura di classificazione, ma nella definizione e nella validazione di un quadro sistematico per lo studio della robustezza cross-domain di classificatori NIDS supervisionati in presenza di distribuzioni eterogenee e differenti livelli di disponibilità della conoscenza target.

Un primo contributo riguarda la **formalizzazione di un framework metodologico per il con-**

fronto tra domini eterogenei. La definizione di uno spazio condiviso delle caratteristiche e di operatori di mappatura specifici per ciascuna sorgente ha consentito di rendere confrontabili dataset originariamente caratterizzati da schemi e semantiche differenti. L'utilità di tale impostazione non risiede esclusivamente nell'armonizzazione dei dati utilizzati nella presente campagna, ma nella separazione concettuale tra rappresentazione del dominio e protocollo di classificazione. In questo modo, il problema del *domain shift* può essere studiato mantenendo controllate le differenze di rappresentazione che, in assenza di armonizzazione, renderebbero ambiguo il confronto tra sorgente e target.

Il secondo contributo è rappresentato dalla **definizione di un protocollo controllato di addestramento e cross-evaluation.** L'introduzione dei tre regimi $\mathcal{M}_S$, $\mathcal{M}_{\text{base}}$ e $\mathcal{M}_H^{(T)}$ ha permesso di osservare il trasferimento non come una semplice contrapposizione tra modello sorgente e modello target, ma come un problema di equilibrio tra acquisizione di nuova informazione e conservazione della conoscenza precedentemente appresa. La valutazione dei modelli su un insieme comune di benchmark ha inoltre evidenziato come una prestazione elevata sul dominio utilizzato durante il training non costituisca, da sola, un'indicazione sufficiente della robustezza complessiva del classificatore.

Il terzo contributo, e principale risultato sperimentale del lavoro, riguarda la **valutazione dell'adattamento mediante conoscenza target sparsa.** La configurazione *INJECTION* ha mostrato che, nelle condizioni sperimentali considerate, l'introduzione di una quota estremamente ridotta di osservazioni malevole target può essere associata a un marcato incremento della sensibilità cross-domain senza una perdita apprezzabile della capacità discriminativa sul dominio sorgente. Il valore di tale risultato risiede soprattutto nell'evidenziare che la disponibilità di conoscenza target non deve essere necessariamente interpretata come una condizione dicotomica tra assenza completa e disponibilità estesa.

Al tempo stesso, il confronto con i modelli ibridi mostra che una maggiore esposizione al dominio target non determina necessariamente una maggiore robustezza globale. Le configurazioni maggiormente specializzate raggiungono infatti sensibilità prossime all'unità sulle distribuzioni target considerate, ma perdono quasi completamente la capacità di riconoscere gli attacchi appartenenti al dominio sorgente. Ne deriva che l'adattamento dovrebbe essere valutato congiuntamente alla *retention* della conoscenza precedente e non esclusivamente attraverso la prestazione raggiunta

sul nuovo dominio.

Un quarto contributo riguarda l'**analisi congiunta della granularità della componente malevola, dell'architettura algoritmica e della stabilità stocastica**. Il confronto tra modelli aggregati e specialistici ha mostrato che la rappresentazione di più famiglie d'attacco all'interno della classe positiva è generalmente associata a una capacità di generalizzazione più uniforme, mentre i modelli biclasse possono raggiungere prestazioni locali molto elevate mantenendo una trasferibilità più dipendente dalla specifica distribuzione considerata.

Parallelamente, il confronto tra DT, HGB e RF ha evidenziato che la famiglia algoritmica modifica il compromesso tra sensibilità, specificità e stabilità. Nella configurazione *INJECTION*, Random Forest ha presentato il profilo predittivo complessivamente più favorevole tra le architetture considerate, mentre HGB ha privilegiato maggiormente la specificità e DT ha mostrato un comportamento intermedio. Le differenze tra classificatori non hanno tuttavia annullato gli effetti prodotti dalla composizione del training set, che nel protocollo considerato ha determinato variazioni prestazionali più ampie rispetto a quelle osservate tra le tre architetture all'interno del medesimo regime di addestramento.

Il quinto contributo consiste nell'**integrazione tra valutazione predittiva, analisi statistica, diagnostica distributiva e spiegabilità post-hoc** all'interno di una pipeline software riproducibile. La replicazione *multi-seed* e il test *t* di Welch hanno permesso di affiancare alle prestazioni puntuali una caratterizzazione della variabilità tra differenti inizializzazioni. PCA e KDE hanno invece fornito una descrizione delle differenze distributive osservate nello spazio delle caratteristiche, mentre SHAP ha consentito di confrontare le dimensioni maggiormente coinvolte nelle decisioni dei classificatori al variare del regime di addestramento.

L'integrazione di tali strumenti ha mostrato, in particolare, che il cambiamento della composizione dei dati può essere accompagnato da una riorganizzazione sostanziale della funzione decisionale. Le corrispondenze osservate tra scostamento distributivo, rilevanza SHAP e andamento prestazionale costituiscono elementi interpretativi utili per caratterizzare il comportamento dei modelli, pur non consentendo di stabilire relazioni causali tra singole caratteristiche e capacità di generalizzazione.

Dai contributi descritti derivano alcune implicazioni per la futura progettazione di NIDS destinati a infrastrutture integrate terrestre-spaziali.

In primo luogo, la **validazione cross-domain dovrebbe essere considerata esplicitamente nel processo di valutazione**. I risultati dei modelli sorgente mostrano infatti che un classificatore può mantenere buone prestazioni sul dominio di origine e un'elevata specificità sul traffico nominale considerato, riducendo contemporaneamente in modo marcato la propria sensibilità verso distribuzioni malevole appartenenti a un dominio differente. Una validazione limitata a partizioni statisticamente vicine al training set rischia pertanto di fornire una caratterizzazione incompleta della robustezza del sistema.

In secondo luogo, i risultati suggeriscono l'interesse di **strategie di aggiornamento controllato mediante quantità limitate di conoscenza target**. In contesti nei quali l'acquisizione di traffico satellitare etichettato risulti onerosa o limitata, la configurazione *INJECTION* mostra che anche una disponibilità ridotta di informazione sul nuovo dominio può risultare rilevante. La presente campagna non determina tuttavia la quantità minima o ottimale di dati necessaria per ottenere tale effetto; la definizione di tale relazione richiede una valutazione sistematica a differenti livelli di iniezione.

In terzo luogo, un eventuale adattamento del classificatore dovrebbe includere una **verifica esplicita della conservazione delle distribuzioni precedentemente apprese**. La forte specializzazione osservata nei modelli ibridi evidenzia infatti il rischio che l'incremento della prestazione sul dominio target venga ottenuto a costo della capacità di riconoscere minacce appartenenti al dominio sorgente. Per sistemi destinati a operare lungo infrastrutture eterogenee, la robustezza dovrebbe pertanto essere valutata sull'insieme dei domini rilevanti e non soltanto rispetto al contesto più recentemente incorporato nel training.

Infine, la scelta dell'architettura algoritmica dovrebbe essere effettuata considerando congiuntamente gli obiettivi predittivi e i vincoli della piattaforma di destinazione. La presente sperimentazione consente di confrontare DT, HGB e RF rispetto a sensibilità, specificità e stabilità, ma non rispetto a latenza, occupazione di memoria, dimensione del modello o consumo energetico. Il profilo favorevole osservato per RF non può quindi essere trasformato direttamente in una raccomandazione per un deployment satellitare.

Nel complesso, il lavoro suggerisce che la progettazione di NIDS per infrastrutture integrate terrestre-spaziali debba considerare la robustezza come una proprietà multidimensionale, dipendente non soltanto dall'accuratezza del classificatore, ma anche dalla rappresentatività dei dati, dalla

capacità di trasferimento tra domini, dalla conservazione della conoscenza precedente, dalla granularità delle minacce rappresentate e dalla stabilità del processo di apprendimento. Le implicazioni delineate costituiscono indicazioni derivabili dal protocollo sperimentale e non una validazione di un'architettura NIDS operativa, la cui valutazione richiederebbe ulteriori dati e misure specifiche di deployment.

6.4 Limiti dello Studio

Le conclusioni formulate nelle sezioni precedenti devono essere interpretate entro il perimetro del protocollo sperimentale adottato. Sebbene il framework abbia consentito di analizzare sistematicamente differenti condizioni di trasferimento cross-domain, alcune caratteristiche dei dati, delle architetture considerate e della procedura di valutazione limitano la possibilità di estendere direttamente i risultati a scenari operativi più generali.

Un primo limite riguarda la **composizione del traffico nominale nei benchmark cross-domain**. Le distribuzioni target derivate da STIN forniscono la componente malevola utilizzata nelle configurazioni TER20 e SAT20, mentre il traffico nominale impiegato durante la campagna sperimentale rimane derivato da UNSW-NB15. Di conseguenza, la variazione di dominio analizzata interessa principalmente la classe positiva, mentre non viene valutato un corrispondente *domain shift* della componente benigna.

Tale vincolo assume particolare rilevanza nell'interpretazione della TNR. Gli elevati valori di specificità osservati nelle differenti configurazioni indicano che i classificatori mantengono una buona capacità di riconoscere il traffico nominale sorgente, ma non permettono di stabilire come il sistema si comporterebbe in presenza di traffico benigno acquisito direttamente all'interno di un segmento satellitare o, più in generale, appartenente a una distribuzione nominale target differente. La robustezza rispetto al *benign-domain shift* rimane pertanto una proprietà non verificata dal presente studio.

Un secondo limite deriva dalla **numerosità e dalla rappresentatività delle sorgenti dati**. La campagna è costruita utilizzando UNSW-NB15 come dominio sorgente e STIN, articolato nelle componenti TER20 e SAT20, come riferimento per le distribuzioni malevole target. La molteplicità dei benchmark derivati da tali sorgenti consente di valutare differenti famiglie d'attacco e differenti

configurazioni di training, ma non equivale alla validazione su una molteplicità di dataset satellitari indipendenti.

I risultati ottenuti descrivono quindi il comportamento del framework rispetto alle distribuzioni effettivamente disponibili e non permettono di assumere che le medesime relazioni quantitative si mantengano inalterate su altre infrastrutture, campagne di acquisizione, protocolli di rete o popolazioni di attacco. In particolare, l'effetto osservato per la configurazione *INJECTION* dovrà essere verificato su ulteriori dataset target prima di poterne valutare la generalità.

Un terzo limite riguarda la **rappresentazione condivisa delle caratteristiche**. L'allineamento tra UNSW-NB15 e STIN richiede di restringere l'analisi a un insieme di feature semanticamente confrontabili tra le sorgenti e di derivare, ove necessario, grandezze equivalenti mediante trasformazioni algebriche e conversioni dimensionali. Tale scelta costituisce un requisito necessario per la cross-evaluation, ma comporta la rinuncia ad attributi disponibili esclusivamente in una delle sorgenti dati.

Lo spazio condiviso utilizzato dal framework rappresenta pertanto soltanto una parte dell'informazione potenzialmente disponibile all'interno dei dataset originari. Ciò limita sia l'analisi di caratteristiche specifiche del segmento satellitare sia la possibilità di sperimentare architetture che richiedano rappresentazioni strutturali più ricche rispetto al vettore tabulare utilizzato nella presente campagna.

Un quarto limite riguarda il **numero e la tipologia delle architetture di Machine Learning valutate**. L'esperimento confronta Decision Tree, Random Forest e Histogram-based Gradient Boosting, ossia tre famiglie di classificatori riconducibili a modelli basati su alberi. Tale scelta permette un confronto controllato tra differenti strategie di costruzione della funzione decisionale, ma non consente di estendere direttamente le conclusioni ad architetture appartenenti ad altre famiglie, quali reti neurali, modelli sequenziali o approcci basati su rappresentazioni a grafo.

La valutazione delle architetture è inoltre stata condotta mantenendo gli iperparametri predefiniti forniti dalla libreria utilizzata, fatta eccezione per il parametro `random_state`. Non sono state applicate procedure di ricerca mediante *Grid Search*, *Randomized Search* o altre strategie di ottimizzazione. I risultati devono quindi essere interpretati come confronto tra le configurazioni considerate dal protocollo e non come stima della massima prestazione ottenibile da ciascuna famiglia algoritmica.

Tale scelta ha consentito di evitare che un’ottimizzazione specifica sui benchmark confondesse l’analisi della generalizzazione cross-domain, ma impedisce contemporaneamente di stabilire se differenti configurazioni iperparametriche avrebbero modificato il compromesso osservato tra sensibilità, specificità e stabilità.

Un quinto limite riguarda la **caratterizzazione della soglia decisionale**. L’analisi principale si concentra sulle metriche ottenute secondo la configurazione decisionale utilizzata dalla pipeline e integra tale valutazione con misure probabilistiche quali PR-AUC. Durante la sperimentazione sono stati inoltre generati artefatti relativi alle distribuzioni delle probabilità, alle metriche al variare della soglia e alle curve ROC; tali informazioni non sono state tuttavia oggetto di una campagna sistematica finalizzata alla selezione o all’ottimizzazione della soglia τ .

Non è quindi possibile stabilire, sulla base dell’analisi sviluppata, se il compromesso tra falsi positivi e falsi negativi possa essere ulteriormente modificato mediante soglie specifiche per modello, dominio o contesto operativo. Le conclusioni sulla sensibilità e sulla specificità rimangono riferite alla configurazione decisionale effettivamente valutata.

Un sesto limite interessa la **portata dell’analisi statistica**. Il test t di Welch è stato applicato alle distribuzioni multi-seed dell’F1-Score globale mediante confronti separati tra la baseline e le altre configurazioni. Il protocollo non applica correzioni per confronti multipli, quali Bonferroni o Benjamini–Hochberg, privilegiando deliberatamente la sensibilità esplorativa dell’analisi.

Di conseguenza, gli esiti inferenziali devono essere interpretati come supporto statistico alle differenze globali osservate e non come una caratterizzazione inferenziale esaustiva dell’intera matrice sperimentale. Inoltre, il test opera sulla sintesi dell’F1-Score lungo i benchmark e non attribuisce una significatività statistica indipendente a ciascuna coppia modello–dataset. Le differenze locali rimangono pertanto descritte principalmente attraverso le metriche prestazionali osservate.

Un ulteriore limite riguarda la **natura interpretativa delle analisi PCA, KDE e SHAP**. Tali strumenti hanno consentito di individuare corrispondenze tra variazioni distributive, rilevanza delle caratteristiche e comportamento dei classificatori. Il protocollo non comprende tuttavia studi di ablazione, interventi controllati sulle singole feature o un disegno sperimentale finalizzato all’identificazione di relazioni causali.

Le associazioni osservate non permettono quindi di affermare che una determinata variazione distributiva sia la causa diretta di uno specifico degrado o miglioramento prestazionale. Il limite

risulta particolarmente rilevante nei benchmark ibridi, nei quali dominio e classe possono risultare strutturalmente correlati: il traffico nominale deriva dal sorgente, mentre quello malevolo appartiene al target. In tale condizione, l'elevata importanza SHAP di una caratteristica può riflettere informazione relativa alla classe, al dominio o a una combinazione delle due componenti, senza che gli artefatti disponibili consentano di separarne causalmente il contributo.

Infine, il presente studio non comprende una **validazione su una piattaforma NIDS operativa né una caratterizzazione quantitativa delle risorse computazionali**. Non sono stati misurati tempi di inferenza, latenza end-to-end, occupazione di memoria, dimensione dei modelli, utilizzo delle risorse hardware o consumo energetico.

Tale assenza impedisce di stabilire quale delle architetture considerate risulti maggiormente adatta a un'esecuzione on-board, a un nodo terrestre con vincoli di risorse o a uno specifico segmento di un'infrastruttura integrata. Analogamente, il comportamento osservato in ambiente sperimentale non costituisce una validazione del sistema in presenza di traffico di rete operativo, vincoli temporali reali, evoluzione continua delle distribuzioni o condizioni hardware proprie di una piattaforma satellitare.

Nel complesso, tali limiti non modificano le evidenze ottenute all'interno del protocollo considerato, ma ne delimitano l'ambito di validità. I risultati consentono di caratterizzare il comportamento cross-domain delle configurazioni sperimentate e di individuare relazioni rilevanti tra conoscenza target, granularità, architettura e stabilità, senza estendere tali conclusioni a condizioni non direttamente osservate.

I limiti individuati definiscono contestualmente le principali direzioni attraverso cui il framework può essere esteso. La sezione successiva traduce pertanto tali vincoli in una serie di sviluppi futuri finalizzati ad ampliare sia la validità sperimentale sia la rilevanza applicativa del lavoro.

6.5 Sviluppi Futuri

I limiti discussi nella sezione precedente individuano diverse direzioni attraverso cui il framework proposto può essere esteso. Gli sviluppi futuri riguardano sia l'ampliamento della validità sperimentale dei risultati sia la progressiva transizione da un protocollo di valutazione cross-domain

verso una caratterizzazione maggiormente rappresentativa delle condizioni operative di un NIDS destinato a infrastrutture integrate terrestre-spaziali.

Una prima estensione prioritaria riguarda l'**introduzione di traffico nominale appartenente al dominio target**. La disponibilità di osservazioni benigne acquisite direttamente in un contesto satellitare consentirebbe di rimuovere uno dei principali vincoli della presente campagna, nella quale la componente nominale rimane interamente derivata da UNSW-NB15.

Tale integrazione permetterebbe di valutare simultaneamente lo scostamento distributivo delle componenti benigna e malevola, verificando se l'elevata specificità osservata nel presente studio venga mantenuta quando anche il traffico nominale differisce dalla distribuzione utilizzata durante l'addestramento. Il protocollo potrebbe quindi essere esteso da una caratterizzazione prevalentemente centrata sul trasferimento delle distribuzioni d'attacco a una valutazione più completa del *domain shift* dell'intero spazio di classificazione.

Una seconda direzione riguarda l'**ampliamento del numero di dataset target indipendenti**. L'impiego di ulteriori raccolte di traffico provenienti da infrastrutture satellitari differenti consentirebbe di verificare se le relazioni osservate tra modello sorgente, configurazione *INJECTION* e modelli ibridi risultino riproducibili anche al variare della sorgente dati.

In particolare, una validazione multi-dataset permetterebbe di distinguere maggiormente gli effetti associati al trasferimento cross-domain da quelli eventualmente specifici delle caratteristiche di STIN, TER20 e SAT20. L'estensione potrebbe comprendere differenti condizioni operative, protocolli, famiglie di minaccia e modalità di acquisizione, mantenendo invariata la logica di armonizzazione e cross-evaluation definita dal framework.

All'interno della medesima direzione risulterebbe inoltre utile approfondire sistematicamente la **quantità di conoscenza target necessaria per l'adattamento**. La configurazione *INJECTION* ha mostrato un comportamento favorevole con una quota target estremamente ridotta, ma la presente campagna non consente di individuare una quantità minima o ottimale di osservazioni.

Una possibile estensione consiste pertanto nel definire una sequenza controllata di livelli di iniezione,

$$\lambda_T^{(1)} < \lambda_T^{(2)} < \dots < \lambda_T^{(n)},$$

mantenendo invariati gli altri elementi del protocollo. Ciò permetterebbe di studiare l'evoluzione del compromesso tra *adaptation* e *retention* al crescere della conoscenza target, verificando se

esista una regione nella quale l'incremento della capacità di generalizzazione cross-domain preceda l'eventuale perdita della conoscenza sorgente.

Una terza estensione riguarda lo **studio sistematico della soglia decisionale**. La campagna attuale produce le probabilità predette dai classificatori e comprende metriche e artefatti relativi alle curve ROC, alle distribuzioni delle probabilità e alla variazione delle prestazioni al modificarsi della soglia. Tali informazioni possono essere utilizzate per estendere l'analisi oltre la configurazione decisionale adottata nella valutazione principale.

Definendo la predizione in funzione di una soglia parametrica

$$\hat{y}(\tau) = \begin{cases} 1, & p(Y = 1 \mid \mathbf{x}) \geq \tau, \\ 0, & p(Y = 1 \mid \mathbf{x}) < \tau, \end{cases}$$

sarebbe possibile analizzare sistematicamente l'andamento di TPR, TNR, Precision e F1-Score per $\tau \in [0, 1]$. Le curve ROC e Precision–Recall potrebbero essere utilizzate congiuntamente alle distribuzioni delle probabilità per verificare come il compromesso tra falsi positivi e falsi negativi cambi al variare del modello e del dominio di valutazione.

Tale analisi risulterebbe particolarmente rilevante in un contesto NIDS, nel quale il costo associato a un falso allarme e quello associato alla mancata identificazione di un attacco possono essere differenti. Lo sviluppo futuro non dovrebbe pertanto limitarsi alla ricerca di una soglia che massimizzi una singola metrica, ma caratterizzare la stabilità della soglia rispetto al *domain shift*, verificando se un valore definito sul dominio sorgente mantenga un comportamento adeguato anche sulle distribuzioni target.

Una quarta direzione riguarda la **caratterizzazione delle risorse computazionali e la validazione su piattaforme di esecuzione rappresentative**. Il confronto sviluppato nella presente tesi è limitato alle proprietà predittive e alla stabilità dei classificatori. Una successiva campagna dovrebbe affiancare a tali grandezze misure relative a:

- latenza di inferenza;
- occupazione di memoria;
- dimensione dei modelli serializzati;
- utilizzo delle risorse di calcolo;

- consumo energetico.

L'acquisizione congiunta di tali misure permetterebbe di costruire un confronto multidimensionale tra accuratezza predittiva e costo computazionale. In tale scenario sarebbe possibile verificare sperimentalmente se il vantaggio prestazionale osservato per RF nella configurazione *INJECTION* giustifichi la relativa articolazione strutturale oppure se modelli differenti offrano un compromesso più favorevole in presenza di specifici vincoli hardware.

Una successiva fase potrebbe quindi prevedere l'esecuzione del NIDS su piattaforme maggiormente rappresentative dei contesti di destinazione, includendo dispositivi embedded o nodi di elaborazione caratterizzati da risorse limitate. Solo attraverso tale valutazione sarebbe possibile passare dal confronto algoritmico sviluppato nel presente lavoro a considerazioni quantitative sull'effettiva utilizzabilità delle diverse configurazioni in un sistema operativo.

Una quinta direzione di sviluppo riguarda infine l'**estensione della rappresentazione dei dati e delle famiglie modellistiche**. Il framework attuale opera su uno spazio tabulare condiviso delle feature e utilizza classificatori basati su alberi. La disponibilità futura di dataset più completi, caratterizzati non soltanto da un insieme più ampio di attributi ma anche, ove disponibili, da informazioni utili a rappresentare le relazioni tra differenti entità o flussi della rete, permetterebbe di esplorare paradigmi modellistici differenti.

In tale contesto potrebbero essere valutate, ad esempio, architetture basate su *Graph Neural Networks* (GNN) o altri modelli capaci di sfruttare rappresentazioni strutturate del traffico. Tale estensione richiederebbe tuttavia una revisione della rappresentazione di ingresso, poiché il confronto con le architetture attuali dovrebbe essere effettuato garantendo che l'informazione aggiuntiva utilizzata dai nuovi modelli sia effettivamente disponibile e semanticamente confrontabile tra i domini sorgente e target.

L'obiettivo non sarebbe quindi sostituire necessariamente i classificatori ad albero utilizzati nella presente campagna, ma verificare se una rappresentazione più ricca della struttura delle comunicazioni consenta di apprendere proprietà maggiormente trasferibili rispetto a quelle esprimibili attraverso il solo vettore tabulare condiviso.

Le direzioni delineate possono essere considerate secondo una progressione incrementale. L'introduzione di traffico benigno target e di ulteriori dataset estenderebbe innanzitutto la validità empirica del protocollo; l'analisi della quantità di conoscenza target e della soglia decisionale

approfondirebbe il comportamento del meccanismo di adattamento; la misurazione delle risorse avvicinerebbe il framework a una valutazione ingegneristica di deployment; infine, l'utilizzo di rappresentazioni più complete consentirebbe di ampliare il confronto verso nuove famiglie di modelli.

Nel loro insieme, tali sviluppi permetterebbero di verificare quanto le evidenze emerse nella presente tesi siano generalizzabili oltre le specifiche condizioni sperimentali considerate e di evolvere progressivamente il framework da strumento di analisi della trasferibilità cross-domain a base metodologica per la progettazione e la validazione di NIDS destinati a infrastrutture di comunicazione terrestre-spaziali.

6.6 Considerazioni Conclusive

Il presente lavoro ha affrontato il problema della robustezza cross-domain dei sistemi NIDS supervisionati, analizzando in quale misura la conoscenza acquisita su un dominio sorgente terrestre possa essere trasferita verso distribuzioni malevole appartenenti a contesti target eterogenei. L'indagine ha mostrato come tale trasferimento non possa essere valutato esclusivamente attraverso le prestazioni ottenute sul dominio di addestramento, poiché classificatori efficaci in condizioni intra-domain possono presentare una marcata riduzione della capacità di rilevamento quando vengono esposti a distribuzioni differenti.

Il principale elemento emerso dalla campagna sperimentale riguarda il ruolo della conoscenza target introdotta durante l'apprendimento. Nel protocollo considerato, la configurazione *INJECTION* ha mostrato che anche un'esposizione estremamente limitata al dominio target può essere associata a un significativo miglioramento della generalizzazione cross-domain, preservando contemporaneamente la capacità discriminativa acquisita sul sorgente. Il risultato non identifica una quantità universalmente ottimale di informazione target, ma evidenzia come il problema dell'adattamento non debba necessariamente essere ricondotto all'alternativa tra assenza completa di conoscenza del nuovo dominio e addestramento estensivo sulle relative distribuzioni.

Il confronto con i modelli sorgente e ibridi ha inoltre evidenziato che la robustezza deve essere interpretata come un compromesso tra *adaptation* e *retention*. La sola conoscenza sorgente non garantisce una generalizzazione uniforme verso le distribuzioni target, mentre una forte esposizione

alla componente malevola di destinazione può determinare una specializzazione tale da compromettere il riconoscimento delle minacce precedentemente apprese. Analogamente, granularità della componente malevola e architettura del classificatore contribuiscono a modulare tale equilibrio, senza tuttavia sostituire il ruolo centrale assunto dalla composizione dei dati di addestramento.

Sotto questa prospettiva, il contributo del framework proposto risiede principalmente nella possibilità di osservare in maniera controllata tali fenomeni, integrando armonizzazione dei domini, differenti livelli di conoscenza target, cross-evaluation, analisi *multi-seed*, verifica statistica e strumenti diagnostici della struttura distributiva e decisionale. La metodologia sviluppata fornisce pertanto una base riproducibile per lo studio della trasferibilità dei NIDS in presenza di distribuzioni eterogenee, mantenendo distinte la prestazione predittiva, la stabilità del modello e le evidenze interpretative associate al *domain shift*.

Le conclusioni rimangono circoscritte alle condizioni effettivamente investigate. La disponibilità futura di traffico benigno target, ulteriori dataset satellitari, analisi sistematiche della soglia decisionale, misure delle risorse computazionali e rappresentazioni dei dati più complete permetterà di verificare quanto le evidenze osservate possano essere estese verso condizioni operative più realistiche. Nel perimetro sperimentale considerato, il risultato complessivo suggerisce comunque che la progettazione di NIDS per infrastrutture integrate terrestre-spaziali debba attribuire alla capacità di **adattarsi a nuove distribuzioni senza perdere la conoscenza precedentemente acquisita** un ruolo centrale nella valutazione della robustezza del sistema.

A. Dettagli Implementativi e Listati del Framework

La presente appendice raccoglie i principali dettagli implementativi del framework che, per estensione e livello di granularità, non sono stati riportati integralmente nel Capitolo 4. L'obiettivo è documentare le componenti software necessarie a completare la descrizione della pipeline sperimentale, preservando nel corpo principale dell'elaborato l'attenzione sulle scelte architetturali, metodologiche e implementative maggiormente rilevanti.

Sono pertanto riportate le routine relative al campionamento e all'istanziamento dei benchmark, alla nomenclatura automatica dei modelli, alla gestione dei casi limite nel calcolo delle metriche, all'esecuzione del test t di Welch e alle componenti ausiliarie della pipeline SHAP. I listati costituiscono un'integrazione della trattazione sviluppata nel Capitolo 4 e ne documentano la trasposizione operativa nel framework software realizzato.

L'organizzazione dell'appendice segue la medesima progressione logica adottata nella descrizione implementativa: preparazione dei benchmark, identificazione dei modelli, valutazione delle prestazioni, verifica statistica e analisi di spiegabilità.

A.1 Campionamento e Istanziamento dei Benchmark

A completamento della procedura di parametrizzazione e istanziamento dei benchmark descritta nella Sottosezione 4.2.3, si riportano di seguito le routine implementative responsabili dell'applicazione del vincolo di proporzione tra traffico nominale e malevolo e del successivo campionamento stratificato delle partizioni di addestramento e collaudo.

Il Listato A.1 implementa la determinazione dinamica delle cardinalità da estrarre in funzione del parametro `MLConstants.NORMAL_ANOMALY_RATIO`, mentre il Listato A.2 riporta la procedura di campionamento che preserva la proporzione tra le partizioni identificate dalla variabile `split_type`.

Codice A.1: Routine di campionamento per l'istanziamento dei benchmark.

```
1 def _get_correct_normal_and_anomaly_data_samples(  
2     normal_data, anomaly_data, normal_samples, anomaly_samples):  
3     # Calcola il corretto numero di campioni da estrarre dalle distribuzioni  
4     if normal_samples < anomaly_samples * MLConstants.NORMAL_ANOMALY_RATIO:  
5         n_anomaly_target = int(normal_samples / MLConstants.NORMAL_ANOMALY_RATIO)  
6         anomaly_data_sample = _safe_stratified_sample(anomaly_data, n_anomaly_target)  
7         normal_data_sample = normal_data  
8     else:  
9         n_normal_target = int(anomaly_samples * MLConstants.NORMAL_ANOMALY_RATIO)  
10        normal_data_sample = _safe_stratified_sample(normal_data, n_normal_target)  
11        anomaly_data_sample = anomaly_data  
12  
13    return normal_data_sample, anomaly_data_sample
```

A completamento della procedura di campionamento, il Listato A.2 riporta la routine utilizzata per ripartire le osservazioni tra le partizioni train e test, preservandone la proporzione relativa e gestendo esplicitamente gli eventuali limiti di capienza delle due partizioni.

Codice A.2: Routine di bilanciamento stratificato per l'istanziamento dei benchmark.

```
1 def _safe_stratified_sample(data, n_samples):  
2     # Se la colonna 'split_type' non è presente, esegue un campionamento casuale semplice  
3     if 'split_type' not in data.columns:  
4         return data.sample(n=n_samples, random_state=MLConstants.MAIN_SEED)  
5  
6     # Suddivide il dataset in partizioni di train e test  
7     data_train = data[data['split_type'] == 'train']  
8     data_test = data[data['split_type'] == 'test']  
9  
10    # Calcola la lunghezza totale del dataset  
11    total_len = len(data)  
12    if total_len == 0 or n_samples == 0:  
13        return pd.DataFrame(columns=data.columns)  
14  
15    train_ratio = len(data_train) / total_len  
16    n_train = round(n_samples * train_ratio)
```



```

17     n_test = n_samples - n_train
18
19     # Gestione difensiva dei limiti di capienza delle partizioni
20     if n_test > len(data_test):
21         diff = n_test - len(data_test)
22         n_test = len(data_test)
23         n_train += diff
24     elif n_train > len(data_train):
25         diff = n_train - len(data_train)
26         n_train = len(data_train)
27         n_test += diff
28
29     # Campionamento stratificato senza reinserimento
30     sampled_parts = []
31     if n_train > 0 and not data_train.empty:
32         sampled_parts.append(data_train.sample(n=n_train, random_state=MLConstants.MAIN_SEED))
33
34     if n_test > 0 and not data_test.empty:
35         sampled_parts.append(data_test.sample(n=n_test, random_state=MLConstants.MAIN_SEED))
36
37     if not sampled_parts:
38         return pd.DataFrame(columns=data.columns)
39
40     return concat_and_shuffle(sampled_parts)

```

A.2 Nomenclatura e Identificazione Automatica dei Modelli

A supporto della procedura di istanziazione dei classificatori descritta nel Capitolo 4.4, il framework adotta una convenzione automatizzata per l'assegnazione dei nomi ai modelli serializzati e ai relativi record di tracciamento.

La funzione `_get_standardized_model_name()` determina dinamicamente l'identificativo del modello a partire dalla tipologia del dataset e dall'insieme delle classi presenti. Nel caso di una configurazione contenente più di due classi viene generato l'identificativo aggregato; nel caso

biclasse viene invece individuata l'etichetta distinta da `normal` e incorporata nella nomenclatura del modello.

Il Listato A.3 riporta l'implementazione completa della procedura.

Codice A.3: Estrazione procedurale dell'etichetta di attacco per la generazione dinamica della nomenclatura del modello.

```
1 def _get_standardized_model_name(dataset_type, unique_classes):
2     # Cancella gli spazi bianchi e converte in minuscolo per coerenza
3     classes = [str(c).strip() for c in unique_classes if str(c).strip()]
4
5     # Se len(classes) > 2, restituisce un nome generico
6     if len(classes) > 2:
7         return f"{dataset_type}_aggregate"
8
9     # Identifica la classe di attacco (assumendo che 'normal' sia la classe benevola)
10    attack_classes = [c for c in classes if c.lower() != 'normal']
11    attack_name = attack_classes[0].lower() if attack_classes else "normal"
12
13    return f"{dataset_type}_{attack_name}"
```

A.3 Calcolo delle Metriche e Gestione dei Casi Limite

A completamento della procedura di valutazione descritta nella Sottosezione 4.5.2, si riporta l'implementazione della logica utilizzata per il calcolo delle metriche di classificazione e per la gestione dei casi nei quali le quantità necessarie alla loro determinazione non risultano definite.

La funzione `calculate_metrics()` ricava preliminarmente i quattro elementi della matrice di confusione imponendo l'ordine delle classi `[0, 1]`. Le metriche sintetiche vengono calcolate soltanto quando il vettore delle etichette reali contiene entrambe le classi, mentre TPR, FNR, TNR e FPR sono subordinati alla verifica esplicita dei rispettivi denominatori.

Il Listato A.4 riporta il frammento implementativo completo utilizzato per tale gestione difensiva.

Codice A.4: Gestione difensiva dei casi limite e calcolo delle metriche in `calculate_metrics()`.

```
1 has_classes = len(np.unique(y_test)) > 1
2 # [Controllo di sicurezza sul numero di classi...]
```

```

3
4 # Calcolo delle metriche
5 tn, fp, fn, tp = confusion_matrix(y_test, y_pred, labels=[0, 1]).ravel()
6
7 if has_classes:
8     accuracy = round(accuracy_score(y_test, y_pred), MLConstants.DECIMAL_DIGITS)
9     precision = round(precision_score(y_test, y_pred), MLConstants.DECIMAL_DIGITS)
10    recall = round(recall_score(y_test, y_pred), MLConstants.DECIMAL_DIGITS)
11    f1 = round(f1_score(y_test, y_pred), MLConstants.DECIMAL_DIGITS)
12    roc = round(roc_auc_score(y_test, y_scores), MLConstants.DECIMAL_DIGITS)
13    pr = round(average_precision_score(y_test, y_scores), MLConstants.DECIMAL_DIGITS)
14 else:
15     accuracy = precision = recall = f1 = roc = pr = None
16
17 if (tp + fn) > 0:
18     tpr = round(tp / (tp + fn), MLConstants.DECIMAL_DIGITS)
19     fnr = round(fn / (tp + fn), MLConstants.DECIMAL_DIGITS)
20 else:
21     tpr, fnr = None, None
22
23 if (fp + tn) > 0:
24     tnr = round(tn / (fp + tn), MLConstants.DECIMAL_DIGITS)
25     fpr = round(fp / (fp + tn), MLConstants.DECIMAL_DIGITS)
26 else:
27     tnr, fpr = None, None

```

A.4 Implementazione del Test t di Welch

A completamento del protocollo inferenziale descritto nella Sottosezione 4.5.3, si riporta l'implementazione completa della procedura utilizzata per il confronto statistico tra il modello di riferimento INJECTION e le configurazioni sottoposte a valutazione.

La procedura estrae dal *DataFrame* di sintesi i valori medi di *F1-Score* associati ai diversi seed, costruisce i campioni corrispondenti alle configurazioni confrontate ed esegue il test mediante

la funzione `scipy.stats.ttest_ind()` con `equal_var=False`. L'esito viene successivamente classificato rispetto al livello di significatività prefissato e memorizzato nella struttura dei risultati.

Il Listato A.5 riporta l'implementazione completa della procedura.

Codice A.5: Estrazione dei campioni ed esecuzione del Test t di Welch.

```
1 # Estrazione dei valori di F1-Score medi per il modello
2 # di riferimento (INJECTION) su tutti i seed
3 ref_row = data[data["model_name"] == reference_model]
4 ref_scores = (ref_row.drop(columns=["id", "model_name"]).values.flatten().astype(float))
5
6 results_list = []
7 # Itera su ciascun modello presente nel DataFrame di sintesi
8 # per eseguire i confronti incrociati
9 for _, row in data.iterrows():
10     current_model = row["model_name"]
11     if current_model == reference_model: continue
12
13     # Isola i valori numerici di test per il modello confrontato
14     current_scores = row.drop(["id", "model_name"]).values.astype(float)
15
16     # Esegue il test t di Welch assumendo varianze non uguali
17     t_stat, p_value = stats.ttest_ind(ref_scores, current_scores, equal_var=False)
18
19     # Valuta la significatività statistica
20     is_significant = "YES" if p_value < alpha else "NO"
21
22     results_list.append({
23         "Reference_Model": reference_model,
24         "Compared_Model": current_model,
25         "t_statistic": t_stat,
26         "p_value": p_value,
27         "alpha": alpha,
28         "is_significant": is_significant
29     })
```

A.5 Dettagli Implementativi della Pipeline SHAP

A completamento della pipeline di spiegabilità descritta nella Sottosezione 4.6.2, si riportano le componenti implementative relative al campionamento controllato del test set e alla successiva normalizzazione della struttura dei valori SHAP restituiti dagli *explainer*.

Il Listato A.6 riporta la procedura utilizzata per costruire il campione destinato all'analisi SHAP, preservando le quote assegnate alle classi e prevedendo un campionamento di fallback qualora non risultino disponibili indici validi.

Codice A.6: Campionamento stratificato del test set per l'analisi SHAP.

```
1 # Allineamento delle etichette con le caratteristiche
2 y_series = pd.Series(y_test, index=X_test.index if hasattr(X_test, 'index') else None)
3
4 # Calcola le quote di campionamento per le due classi
5 n_anomaly = MLConstants.SHAP_MAX_SAMPLES // MLConstants.NORMAL_ANOMALY_RATIO
6 n_normal = MLConstants.SHAP_MAX_SAMPLES - n_anomaly
7
8 # Estrazione degli indici campionati per entrambe le classi, date le istanze disponibili
9 idx_normal = pd.Index([])
10 if sum(y_series == 0) > 0:
11     idx_normal = y_series[y_series == 0].sample(
12         n=min(n_normal, sum(y_series == 0)), random_state=MLConstants.MAIN_SEED
13     ).index
14 idx_anomaly = pd.Index([])
15 if sum(y_series == 1) > 0:
16     idx_anomaly = y_series[y_series == 1].sample(
17         n=min(n_anomaly, sum(y_series == 1)), random_state=MLConstants.MAIN_SEED
18     ).index
19
20 sampled_idx = idx_normal.append(idx_anomaly)
21
22 # Filtra il test set originale utilizzando gli indici stratificati
23 # (o fallback a un campionamento casuale standard)
24 if not sampled_idx.empty:
25     X_test_sampled = X_test.loc[sampled_idx]
```

```

26 else:
27     X_test_sampled = X_test.sample(
28         n=min(MLConstants.SHAP_MAX_SAMPLES, len(X_test)), random_state=MLConstants.MAIN_SEED
29     )

```

Successivamente al calcolo dei valori SHAP, l'implementazione gestisce le differenti strutture dati che possono essere restituite dalla libreria, isolando quando necessario la componente associata alla classe positiva e predisponendo la rappresentazione mediante `shap.summary_plot()`.

Il Listato A.7 riporta la relativa implementazione.

Codice A.7: Calcolo, normalizzazione dimensionale e rendering dei valori SHAP.

```

1  # Calcolo dei valori SHAP con gestione del controllo di additività
2  try:
3      shap_values = explainer.shap_values(X_test_sampled, check_additivity=False)
4  except TypeError:
5      shap_values = explainer.shap_values(X_test_sampled)
6
7  # Gestire le disparità di output
8  shap_values_raw = shap_values.values if hasattr(shap_values, "values") else shap_values
9
10 # Estrazione dei valori della classe Anomaly in base alla struttura dei dati
11 if isinstance(shap_values_raw, list) and len(shap_values_raw) == 2:
12     shap_values_raw = shap_values_raw[1]
13 elif hasattr(shap_values_raw, 'shape') and len(shap_values_raw.shape) == 3:
14     shap_values_raw = shap_values_raw[:, :, 1]
15 elif hasattr(shap_values_raw, 'shape') and len(shap_values_raw.shape) == 2:
16     pass
17
18 # Genera e configura dinamicamente il grafico
19 n_features = X_test_sampled.shape[1]
20 plt.figure(figsize=(8, max(6, n_features * 0.4)))
21
22 # Forza la visualizzazione "dot" per mostrare gli impatti individuali delle feature
23 shap.summary_plot(
24     shap_values_raw, X_test_sampled, show=False, max_display=n_features, plot_type="dot"
25 )

```

B. Risultati Numerici Completi

La presente appendice raccoglie i risultati numerici completi associati alle analisi sperimentali sviluppate nel Capitolo 5. Al fine di preservare la leggibilità della discussione principale, nel Capitolo 5 sono riportati i risultati necessari all'interpretazione e al confronto tra i paradigmi sperimentali, mentre nel seguito sono raccolti i relativi dettagli numerici completi.

L'organizzazione dell'appendice segue la medesima articolazione logica adottata nell'analisi sperimentale: baseline INJECTION, modelli sorgente, modelli ibridi e verifiche statistiche.

B.1 Risultati Completi della Baseline INJECTION

La presente sezione raccoglie il dettaglio numerico delle valutazioni della baseline INJECTION discusse nella Sezione 5.2. Sono riportate separatamente le cardinalità complete delle matrici di confusione e le metriche complementari ottenute sui benchmark di cross-evaluation.

B.1.1 Matrici di Confusione

La Tabella B.1 riporta le cardinalità complete delle matrici di confusione ottenute dalla baseline INJECTION con i classificatori DT, HGB e RF sui 16 test set considerati per il seed $s = 42$.

Tabella B.1: Cardinalità complete delle matrici di confusione della baseline INJECTION con DT, HGB e RF sui 16 test set per il seed $s = 42$.

Test Set	DT				HGB				RF			
	TP	TN	FP	FN	TP	TN	FP	FN	TP	TN	FP	FN
nb15 (aggregato)	1539	18305	295	321	1482	18540	60	378	1530	18422	178	330
nb15 (DoS)	1693	18305	295	167	1648	18540	60	212	1705	18422	178	155
nb15 (Exploits)	1567	18305	295	293	1522	18540	60	338	1598	18422	178	262
nb15 (Fuzzers)	525	18305	295	1335	338	18540	60	1522	450	18422	178	1410
nb15 (Generic)	1843	18305	295	17	1843	18540	60	17	1843	18422	178	17
nb15 (Reconnaissance)	1619	18305	295	241	1642	18540	60	218	1596	18422	178	264
injection (aggregato)	1535	18305	295	325	1506	18540	60	354	1531	18422	178	329
nb15_stin (aggregato)	1790	18305	295	70	1405	18540	60	455	1851	18422	178	9
nb15_sat20 (aggregato)	1841	18305	295	19	1589	18540	60	271	1859	18422	178	1
nb15_sat20 (Syn_DDoS)	1825	18305	295	35	1512	18540	60	348	1860	18422	178	0
nb15_sat20 (UDP_DDoS)	1859	18305	295	1	1672	18540	60	188	1859	18422	178	1
nb15_ter20 (aggregato)	1752	18305	295	108	1295	18540	60	565	1842	18422	178	18
nb15_ter20 (Botnet)	1636	18305	295	224	1498	18540	60	362	1857	18422	178	3
nb15_ter20 (DDoS)	1860	18305	295	0	1539	18540	60	321	1860	18422	178	0
nb15_ter20 (Syn_DDoS)	1794	18305	295	66	0	18540	60	1860	1731	18422	178	129
nb15_ter20 (UDP_DDoS)	1664	18305	295	196	1286	18540	60	574	1860	18422	178	0

B.1.2 Metriche Complementari

La Tabella B.2 completa la caratterizzazione della baseline riportando i valori di *F1-Score* e PR-AUC ottenuti dai tre classificatori sui medesimi 16 test set per il seed $s = 42$.

Tabella B.2: F1-Score e PR-AUC completi della baseline INJECTION con DT, HGB e RF sui 16 test set per il seed $s = 42$.

Test Set	DT		HGB		RF	
	F1-Score	PR-AUC	F1-Score	PR-AUC	F1-Score	PR-AUC
nb15 (aggregato)	0.8332	0.7120	0.8713	0.9263	0.8576	0.9095
nb15 (DoS)	0.8799	0.7548	0.9238	0.9648	0.9110	0.9602
nb15 (Exploits)	0.8420	0.7102	0.8844	0.9469	0.8790	0.9342
nb15 (Fuzzers)	0.3918	0.2890	0.2994	0.5824	0.3617	0.5099
nb15 (Generic)	0.9220	0.8571	0.9795	0.9968	0.9498	0.9932
nb15 (Reconnaissance)	0.8580	0.7053	0.9220	0.9659	0.8784	0.9461
injection (aggregato)	0.8320	0.7104	0.8792	0.9342	0.8579	0.9154
nb15_stin (aggregato)	0.9075	0.8316	0.8451	0.9191	0.9519	0.9802
nb15_sat20 (aggregato)	0.9214	0.8560	0.9057	0.9579	0.9541	0.9873
nb15_sat20 (Syn_DDoS)	0.9171	0.8484	0.8811	0.9682	0.9543	0.9902
nb15_sat20 (UDP_DDoS)	0.9263	0.8646	0.9310	0.9604	0.9541	0.9898
nb15_ter20 (aggregato)	0.8969	0.8134	0.8056	0.8922	0.9495	0.9746
nb15_ter20 (Botnet)	0.8631	0.7581	0.8765	0.9464	0.9535	0.9675
nb15_ter20 (DDoS)	0.9265	0.8651	0.8899	0.9379	0.9543	0.9834
nb15_ter20 (Syn_DDoS)	0.9086	0.8339	0.0000	0.5501	0.9185	0.9660
nb15_ter20 (UDP_DDoS)	0.8714	0.7714	0.8022	0.9499	0.9543	0.9859

B.2 Risultati Completi dei Modelli Sorgente

La presente sezione raccoglie il dettaglio numerico delle analisi relative ai modelli addestrati esclusivamente sul dominio sorgente, discusse nella Sezione 5.3. I risultati sono organizzati distinguendo le prestazioni sul dominio sorgente, la risposta cross-domain, la specificità multi-seed e il confronto con la baseline INJECTION.

B.2.1 Prestazioni sul Dominio Sorgente e su INJECTION

La Tabella B.3 sintetizza la TPR media calcolata sui 10 seed per i modelli sorgente, considerando le valutazioni effettuate sui benchmark appartenenti al dominio sorgente e sul test set INJECTION.

Tabella B.3: TPR media sui 10 seed dei modelli sorgente valutati sui benchmark sorgente e sul test set INJECTION.

Modello	Aggr. NB15	DoS	Exploits	Fuzzers	Generic	Recon.	INJECTION
DT							
Aggregato	0.8215	0.9073	0.8432	0.2851	0.9916	0.8737	0.8274
DoS	0.5908	0.9306	0.7211	0.1725	0.6300	0.2015	0.5847
Exploits	0.3942	0.9261	0.8927	0.1903	0.0220	0.2504	0.4167
Fuzzers	0.3197	0.7847	0.4175	0.4794	0.0805	0.1906	0.3201
Generic	0.6042	0.7359	0.4273	0.1213	0.9867	0.1421	0.5972
Reconnaissance	0.6592	0.7911	0.4459	0.1450	0.9444	0.9386	0.6627
HGB							
Aggregato	0.8018	0.8941	0.8173	0.1775	0.9900	0.8797	0.8039
DoS	0.7029	0.9131	0.7357	0.1391	0.9648	0.1933	0.7048
Exploits	0.4278	0.9099	0.8714	0.1629	0.1310	0.2248	0.4442
Fuzzers	0.2524	0.7605	0.3610	0.3517	0.0089	0.1470	0.2520
Generic	0.5454	0.5847	0.3317	0.0913	0.9879	0.1095	0.5426
Reconnaissance	0.6724	0.7794	0.4054	0.1375	0.9785	0.9465	0.6671
RF							
Aggregato	0.8236	0.9261	0.8619	0.2337	0.9915	0.8629	0.8272
DoS	0.7164	0.9320	0.7305	0.1487	0.9874	0.2039	0.7202
Exploits	0.3991	0.9282	0.9047	0.1750	0.0224	0.2386	0.4147
Fuzzers	0.3007	0.7704	0.3906	0.4739	0.0459	0.1669	0.2950
Generic	0.5792	0.7169	0.3621	0.1159	0.9870	0.1373	0.5694
Reconnaissance	0.6602	0.7832	0.4235	0.1410	0.9580	0.9406	0.6621

B.2.2 Prestazioni Cross-Domain

La Tabella B.4 riporta la TPR media sui 10 seed ottenuta dai modelli sorgente nella valutazione cross-domain sui benchmark target, distinguendo le configurazioni aggregate da quelle biclasse.

Tabella B.4: TPR media sui 10 seed dei modelli sorgente valutati sui benchmark target aggregati e biclasse.

Modello	STIN	SAT20	TER20	SAT Syn	SAT UDP	Botnet	DDoS	TER Syn	TER UDP
DT									
Aggregato	0.3807	0.1947	0.5294	0.0725	0.2917	0.6726	0.6669	0.0484	0.0538
DoS	0.4824	0.8149	0.2537	0.9528	0.6946	0.1320	0.0848	0.6024	0.8877
Exploits	0.2033	0.2978	0.1455	0.0715	0.4973	0.3573	0.0673	0.0284	0.0406
Fuzzers	0.4181	0.3712	0.4698	0.0178	0.6797	0.8898	0.4467	0.0092	0.0191
Generic	0.1267	0.3068	0.0141	0.0485	0.5289	0.0057	0.0118	0.0039	0.0459
Reconnaissance	0.0501	0.0044	0.0812	0.0000	0.0063	0.0988	0.0079	0.3774	0.0000
HGB									
Aggregato	0.0662	0.1055	0.0438	0.0000	0.2020	0.0906	0.0378	0.0000	0.0000
DoS	0.1380	0.1540	0.1436	0.0000	0.2921	0.2309	0.1578	0.0000	0.0000
Exploits	0.0428	0.0287	0.0547	0.0000	0.0527	0.1013	0.0536	0.0000	0.0000
Fuzzers	0.2781	0.2157	0.3301	0.0000	0.4071	0.6226	0.3009	0.0000	0.0000
Generic	0.1137	0.2625	0.0204	0.0000	0.5016	0.0703	0.0006	0.0000	0.0000
Reconnaissance	0.0005	0.0002	0.0000	0.0000	0.0001	0.0001	0.0001	0.0000	0.0000
RF									
Aggregato	0.3601	0.2613	0.4564	0.0000	0.4929	0.5570	0.6036	0.0000	0.0000
DoS	0.3558	0.6878	0.1296	0.5753	0.8007	0.1061	0.0594	0.1293	0.5109
Exploits	0.1594	0.3199	0.0522	0.0000	0.6077	0.1314	0.0355	0.0000	0.0000
Fuzzers	0.5040	0.4818	0.5338	0.0000	0.9023	0.9191	0.5841	0.0000	0.0000
Generic	0.1089	0.2572	0.0139	0.0000	0.4856	0.0448	0.0054	0.0000	0.0000
Reconnaissance	0.0050	0.0156	0.0000	0.0000	0.0200	0.0029	0.0001	0.0000	0.0000

B.2.3 Specificità Multi-Seed

La Tabella B.5 riporta la media e la varianza della TNR calcolate sui 10 seed per ciascuna configurazione sorgente e per i tre classificatori considerati.

Tabella B.5: Media e varianza della TNR sui 10 seed per i modelli sorgente. Il valore è indipendente dal test set malevolo poiché la componente nominale rimane invariata all'interno del protocollo sperimentale.

Modello	DT		HGB		RF	
	$\overline{TNR}$	$\text{Var}(TNR)$	$\overline{TNR}$	$\text{Var}(TNR)$	$\overline{TNR}$	$\text{Var}(TNR)$
Aggregato	0.98317	1.51×10^{-7}	0.99659	2.32×10^{-8}	0.99150	6.00×10^{-8}
DoS	0.99362	5.51×10^{-8}	0.99776	5.38×10^{-8}	0.99672	8.44×10^{-9}
Exploits	0.99049	4.99×10^{-8}	0.99588	7.07×10^{-8}	0.99413	2.46×10^{-8}
Fuzzers	0.96248	1.77×10^{-7}	0.98900	2.38×10^{-7}	0.96847	8.01×10^{-8}
Generic	0.99950	2.22×10^{-9}	0.99960	8.89×10^{-9}	0.99964	2.67×10^{-9}
Reconnaissance	0.99521	1.21×10^{-8}	0.99555	7.17×10^{-8}	0.99608	1.51×10^{-8}

B.2.4 Confronto Completo con la Baseline INJECTION

La Tabella B.6 confronta la media e la varianza della TPR ottenute sui benchmark target aggregati dal modello sorgente aggregato e dalla baseline INJECTION, separatamente per DT, HGB e RF.

Tabella B.6: Media e varianza della TPR sui benchmark target aggregati per il modello sorgente aggregato e la baseline.

Test Set	Modello sorgente		Baseline INJECTION	
	$\overline{TPR}$	$\text{Var}(TPR)$	$\overline{TPR}$	$\text{Var}(TPR)$
DT				
nb15_stin	0.38071	7.74×10^{-3}	0.97282	1.24×10^{-4}
nb15_sat20	0.19473	1.87×10^{-2}	0.98630	2.15×10^{-5}
nb15_ter20	0.52940	3.61×10^{-3}	0.96182	4.07×10^{-4}
HGB				
nb15_stin	0.06624	5.25×10^{-3}	0.84945	8.17×10^{-3}
nb15_sat20	0.10553	7.18×10^{-3}	0.90956	8.31×10^{-3}
nb15_ter20	0.04378	8.58×10^{-3}	0.81505	9.90×10^{-3}
RF				
nb15_stin	0.36006	1.81×10^{-4}	0.99253	9.12×10^{-5}
nb15_sat20	0.26130	7.19×10^{-4}	0.99954	9.38×10^{-8}
nb15_ter20	0.45636	5.01×10^{-5}	0.98600	2.28×10^{-4}

A completamento del confronto, la Tabella B.7 quantifica, per ciascun benchmark target, la differenza di TPR tra la baseline INJECTION e il migliore modello sorgente disponibile per ciascun classificatore.

Tabella B.7: Vantaggio TPR della baseline rispetto al migliore modello sorgente disponibile su ciascun benchmark target.

Test Set Target	ΔTPR_{DT}^{best}	ΔTPR_{HGB}^{best}	ΔTPR_{RF}^{best}
nb15_stin (aggregato)	+0.49045	+0.57134	+0.48851
nb15_sat20 (aggregato)	+0.17140	+0.64707	+0.31176
nb15_ter20 (aggregato)	+0.43242	+0.48495	+0.45224
nb15_sat20 (Syn_DDoS)	+0.02042	+0.92871	+0.42382
nb15_sat20 (UDP_DDoS)	+0.30487	+0.39284	+0.09739
nb15_ter20 (Botnet)	+0.04918	+0.24576	+0.06542
nb15_ter20 (DDoS)	+0.33281	+0.57548	+0.39645
nb15_ter20 (Syn_DDoS)	+0.36490	+0.49886	+0.81039
nb15_ter20 (UDP_DDoS)	+0.00767	+0.82656	+0.48200

B.2.5 Mappe di Calore Aggregate della TPR

A completamento del dettaglio numerico riportato nelle tabelle precedenti, le Figure B.1, B.2 e B.3 forniscono una rappresentazione sinottica della *cross-evaluation* dei modelli sorgente rispetto alla baseline INJECTION.

Per ciascuna architettura, le righe identificano i modelli addestrati sulle differenti configurazioni sorgente, mentre le colonne rappresentano i benchmark e le classi utilizzati in fase di valutazione. La configurazione INJECTION è riportata separatamente come riferimento sperimentale. Ogni cella delle matrici aggregate riporta la TPR media ottenuta sui $K = 10$ seed e la corrispondente varianza inter-seed; la colonna finale riassume inoltre il valore medio sull'intera *cross-evaluation*.

Le mappe costituiscono pertanto la controparte grafica dei risultati quantitativi discussi nel Capitolo 5 e riportati in forma tabellare nella presente appendice, senza introdurre una metrica ulteriore rispetto al protocollo sperimentale.




Figura B.1: Matrice aggregata della TPR per Decision Tree nel confronto tra modelli sorgente e baseline INJECTION. Per ciascuna cella sono riportate la media e la varianza calcolate sui $K = 10$ seed.




Figura B.2: Matrice aggregata della TPR per Histogram-based Gradient Boosting nel confronto tra modelli sorgente e baseline INJECTION.

Per ciascuna cella sono riportate la media e la varianza calcolate sui $K = 10$ seed.




Figura B.3: Matrice aggregata della TPR per Random Forest nel confronto tra modelli sorgente e baseline INJECTION. Per ciascuna cella sono riportate la media e la varianza calcolate sui $K = 10$ seed.

B.3 Risultati Completi dei Modelli Ibridi

La presente sezione riporta il dettaglio numerico delle valutazioni dei modelli ibridi discusse nella Sezione 5.4. Sono riportate separatamente le prestazioni sui benchmark target omologhi e i risultati della cross-evaluation sulle differenti distribuzioni considerate.

B.3.1 Prestazioni sui Benchmark Omologhi

La Tabella B.8 riporta i valori di TPR e *F1-Score* ottenuti dai modelli ibridi sui rispettivi benchmark target omologhi per il seed $s = 42$.

Tabella B.8: TPR e F1-Score dei modelli ibridi sui rispettivi test set target omologhi per il seed $s = 42$.

Modello / Test Set	DT		HGB		RF	
	TPR	F1	TPR	F1	TPR	F1
nb15_stin (aggregato)	0.9995	0.9997	0.9995	0.9997	0.9995	0.9997
nb15_sat20 (aggregato)	0.9995	0.9997	0.9995	0.9997	0.9995	0.9997
nb15_ter20 (aggregato)	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
nb15_sat20 (Syn_DDoS)	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
nb15_sat20 (UDP_DDoS)	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
nb15_ter20 (Botnet)	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
nb15_ter20 (DDoS)	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
nb15_ter20 (Syn_DDoS)	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
nb15_ter20 (UDP_DDoS)	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000

B.3.2 Cross-Evaluation dei Modelli Ibridi

La Tabella B.9 sintetizza la TPR media multi-seed dei modelli ibridi nella cross-evaluation sui benchmark sorgente, sulla configurazione INJECTION e sui benchmark target.

Tabella B.9: TPR media multi-seed dei modelli ibridi sui benchmark sorgente, INJECTION e target. Le colonne NB15 e Target rappresentano rispettivamente la media sui sei e sui nove test set dei corrispondenti gruppi.

Modello	DT			HGB			RF		
	NB15	INJ.	Target	NB15	INJ.	Target	NB15	INJ.	Target
nb15_stin_aggregate	0.000000	0.00320	0.999922	0.000000	0.00320	0.999944	0.000000	0.00320	0.999922
nb15_sat20_aggregate	0.000000	0.00320	0.999889	0.000000	0.00320	0.981796	0.000000	0.00320	0.999894
nb15_ter20_aggregate	0.000000	0.00320	0.999922	0.000000	0.00320	0.999944	0.000000	0.00320	0.999906
nb15_sat20_syn_ddos	0.000000	0.00050	0.424387	0.000000	0.00050	0.315589	0.000000	0.00050	0.443831
nb15_sat20_udp_ddos	0.000000	0.00320	0.974900	0.000000	0.00270	0.551311	0.000000	0.00320	0.898881
nb15_ter20_botnet	0.000000	0.00320	0.952424	0.000000	0.00310	0.842102	0.000000	0.00320	0.910777
nb15_ter20_ddos	0.000000	0.00310	0.829924	0.000000	0.00270	0.551311	0.000000	0.00285	0.664007
nb15_ter20_syn_ddos	0.000000	0.00320	0.999928	0.000025	0.00196	0.629574	0.000000	0.00320	0.999910
nb15_ter20_udp_ddos	0.000000	0.00320	0.978669	0.000000	0.00050	0.350036	0.000000	0.00050	0.448567

B.3.3 Mappe di Calore Aggregate della TPR

Le Figure B.4, B.5 e B.6 completano la caratterizzazione della *cross-evaluation* dei modelli ibridi mediante una rappresentazione grafica delle matrici aggregate della TPR.

Le righe comprendono i modelli aggregati e biclasse addestrati utilizzando la componente malevola target, mentre le colonne corrispondono ai medesimi benchmark sorgente, INJECTION e target impiegati nel protocollo di valutazione. La baseline INJECTION è riportata separatamente come riferimento comune. Analogamente alle matrici relative ai modelli sorgente, ciascuna cella riporta la TPR media e la relativa varianza ottenute sui $K = 10$ seed, mentre la colonna finale sintetizza la risposta media lungo l'intera matrice di valutazione.

Tale rappresentazione integra il dettaglio numerico della Tabella B.9, consentendo di preservare nell'appendice la struttura completa dei risultati multi-seed senza appesantire la discussione principale del Capitolo 5.




Figura B.4: Matrice aggregata della TPR per Decision Tree nel confronto tra modelli ibridi e baseline INJECTION. Per ciascuna cella sono riportate la media e la varianza calcolate sui $K = 10$ seed.




Figura B.5: Matrice aggregata della TPR per Histogram-based Gradient Boosting nel confronto tra modelli ibridi e baseline INJECTION. Per ciascuna cella sono riportate la media e la varianza calcolate sui $K = 10$ seed.




Figura B.6: Matrice aggregata della TPR per Random Forest nel confronto tra modelli ibridi e baseline INJECTION. Per ciascuna cella sono riportate la media e la varianza calcolate sui $K = 10$ seed.

B.4 Risultati Completi dei Test Statistici

La presente sezione raccoglie le statistiche descrittive e i risultati completi dei test t di Welch discussi nel Capitolo 5. I confronti sono organizzati separatamente per i modelli sorgente e per i modelli ibridi, assumendo in entrambi i casi la configurazione INJECTION come riferimento sperimentale.

B.4.1 Modelli Sorgente rispetto alla Baseline INJECTION

Prima dell'applicazione del test inferenziale, la Tabella B.10 riporta le statistiche descrittive dei valori medi di $F1$ -Score ottenuti sui 10 seed dalla baseline INJECTION e dai modelli sorgente.

Tabella B.10: Media e deviazione standard campionaria dei valori $\overline{F1}_i^{(k)}$ sui 10 seed per la baseline e i modelli sorgente. $\Delta F1$ è calcolato come baseline meno modello sorgente.

Modello	DT			HGB			RF		
	$\overline{F1}$	s	$\Delta F1$	$\overline{F1}$	s	$\Delta F1$	$\overline{F1}$	s	$\Delta F1$
injection_aggregate	0.86039	0.00352	–	0.85407	0.03634	–	0.89022	0.00245	–
nb15_aggregate	0.56308	0.04017	+0.29731	0.41231	0.05289	+0.44177	0.57651	0.00647	+0.31371
nb15_dos	0.63163	0.01413	+0.22876	0.41671	0.05056	+0.43737	0.57207	0.05750	+0.31815
nb15_exploits	0.37742	0.01922	+0.48297	0.27167	0.03931	+0.58240	0.34199	0.02338	+0.54823
nb15_fuzzers	0.38778	0.02178	+0.47261	0.35018	0.02762	+0.50390	0.41666	0.01181	+0.47356
nb15_generic	0.37596	0.01366	+0.48443	0.33977	0.01613	+0.51430	0.35185	0.01199	+0.53837
nb15_reconnaissance	0.38165	0.00983	+0.47874	0.32058	0.00053	+0.53349	0.32659	0.00129	+0.56364

Sulla base dei campioni così caratterizzati, la Tabella B.11 riporta, per ciascun modello sorgente e classificatore, la statistica t , il corrispondente p -value e l'esito della verifica di significatività rispetto alla soglia $\alpha = 0,05$.

Tabella B.11: Risultati del test t di Welch tra injection_aggregate e i modelli sorgente, con $\alpha = 0,05$.

Modello confrontato	DT			HGB			RF		
	t	p	Sign.	t	p	Sign.	t	p	Sign.
nb15_aggregate	23.3150	1.8720×10^{-9}	Sì	21.7698	2.7489×10^{-13}	Sì	143.4423	4.0594×10^{-20}	Sì
nb15_dos	49.6699	2.0529×10^{-13}	Sì	22.2139	1.2228×10^{-13}	Sì	17.4802	2.8399×10^{-8}	Sì
nb15_exploits	78.1496	8.6609×10^{-15}	Sì	34.4010	8.5047×10^{-18}	Sì	73.7488	4.5473×10^{-14}	Sì
nb15_fuzzers	67.7344	4.8440×10^{-14}	Sì	34.9112	4.0724×10^{-17}	Sì	124.1469	5.8434×10^{-17}	Sì
nb15_generic	108.6316	6.0030×10^{-17}	Sì	40.9031	1.2819×10^{-14}	Sì	139.1262	2.0720×10^{-17}	Sì
nb15_reconnaissance	144.9748	8.7646×10^{-20}	Sì	46.4184	4.9595×10^{-12}	Sì	643.0892	5.6491×10^{-32}	Sì

B.4.2 Modelli Ibridi rispetto alla Baseline INJECTION

Analogamente al confronto precedente, la Tabella B.12 riporta le statistiche descrittive dei valori medi di $F1$ -Score ottenuti sui 10 seed dalla baseline INJECTION e dalle differenti configurazioni dei modelli ibridi.

Tabella B.12: Media e deviazione standard campionaria dei valori medi di F1-Score sui 10 seed per la baseline e i modelli ibridi. $\Delta F1$ è calcolato come baseline meno modello ibrido.

Modello	DT			HGB			RF		
	$\overline{F1}$	s	$\Delta F1$	$\overline{F1}$	s	$\Delta F1$	$\overline{F1}$	s	$\Delta F1$
injection_aggregate	0.860388	0.003516	–	0.854074	0.036341	–	0.890221	0.002452	–
nb15_sat20_aggregate	0.562863	0.000000	+0.297526	0.556714	0.009015	+0.297360	0.562864	0.000006	+0.327357
nb15_sat20_syn_ddos	0.272674	0.010401	+0.587714	0.203331	0.000000	+0.650743	0.280766	0.001831	+0.609456
nb15_sat20_udp_ddos	0.554609	0.011598	+0.305779	0.335325	0.000000	+0.518749	0.529931	0.000483	+0.360290
nb15_stin_aggregate	0.562874	0.000010	+0.297514	0.562881	0.000000	+0.291193	0.562874	0.000010	+0.327348
nb15_ter20_aggregate	0.562874	0.000010	+0.297514	0.562881	0.000000	+0.291193	0.562868	0.000009	+0.327353
nb15_ter20_botnet	0.547373	0.015805	+0.313016	0.496752	0.078046	+0.357322	0.533624	0.005028	+0.356598
nb15_ter20_ddos	0.491250	0.082180	+0.369138	0.335325	0.000000	+0.518749	0.401911	0.085435	+0.488310
nb15_ter20_syn_ddos	0.562876	0.000009	+0.297513	0.408438	0.018932	+0.445636	0.562871	0.000022	+0.327351
nb15_ter20_udp_ddos	0.555778	0.008641	+0.304611	0.230466	0.023354	+0.623608	0.282475	0.000000	+0.607746

La Tabella B.13 completa l'analisi inferenziale riportando, per ciascun modello ibrido e classificatore, la statistica t , il corrispondente p -value e l'esito della verifica di significatività rispetto alla soglia $\alpha = 0,05$.

Tabella B.13: Risultati del test t di Welch tra injection_aggregate e i modelli ibridi, con $\alpha = 0,05$.

Modello confrontato	DT			HGB			RF		
	t	p	Sign.	t	p	Sign.	t	p	Sign.
nb15_sat20_aggregate	267.5863	7.2356×10^{-19}	Sì	25.1143	1.9370×10^{-10}	Sì	422.2333	1.1929×10^{-20}	Sì
nb15_sat20_syn_ddos	169.2801	3.4456×10^{-20}	Sì	56.6262	8.4088×10^{-13}	Sì	629.8796	6.8206×10^{-38}	Sì
nb15_sat20_udp_ddos	79.7886	3.9878×10^{-16}	Sì	45.1404	6.4262×10^{-12}	Sì	455.9473	2.4901×10^{-22}	Sì
nb15_stin_aggregate	267.5751	7.2343×10^{-19}	Sì	25.3389	1.1170×10^{-9}	Sì	422.2191	1.1923×10^{-20}	Sì
nb15_ter20_aggregate	267.5751	7.2343×10^{-19}	Sì	25.3389	1.1170×10^{-9}	Sì	422.2268	1.1923×10^{-20}	Sì
nb15_ter20_botnet	61.1330	4.4121×10^{-14}	Sì	13.1250	9.0594×10^{-9}	Sì	201.5742	3.4772×10^{-24}	Sì
nb15_ter20_ddos	14.1915	1.7560×10^{-7}	Sì	45.1404	6.4262×10^{-12}	Sì	18.0668	2.1765×10^{-8}	Sì
nb15_ter20_syn_ddos	267.5736	7.2352×10^{-19}	Sì	34.3910	1.4012×10^{-14}	Sì	422.2097	1.1864×10^{-20}	Sì
nb15_ter20_udp_ddos	103.2535	6.1024×10^{-19}	Sì	45.6509	8.1098×10^{-18}	Sì	783.8890	4.5557×10^{-23}	Sì

Bibliografia

- [1] A. S. Tanenbaum, N. Feamster e D. Wetherall, *Computer Networks*, 6th. Pearson, 2021, ISBN: 978-1-292-37406-2.
- [2] W. Stallings, *Cryptography and Network Security: Principles and Practice*, 8th. Pearson, 2020, ISBN: 978-1-292-43748-4.
- [3] O. Kodheli et al., «Satellite Communications in the New Space Era: A Survey and Future Challenges,» *IEEE Communications Surveys & Tutorials*, vol. 23, n. 1, pp. 70–109, 2021. DOI: 10.1109/COMST.2020.3028247 indirizzo: <https://ieeexplore.ieee.org/document/9210567>
- [4] S. Lightman, T. Suloway e J. Brule, «Satellite Ground Segment: Applying the Cybersecurity Framework to Satellite Command and Control,» National Institute of Standards e Technology, NIST Interagency Report NIST IR 8401, 2022. DOI: 10.6028/NIST.IR.8401 indirizzo: <https://nvlpubs.nist.gov/nistpubs/ir/2022/NIST.IR.8401.pdf>
- [5] A. Khraisat, I. Gondal, P. Vamplew e J. Kamruzzaman, «Survey of intrusion detection systems: techniques, datasets and challenges,» *Cybersecurity*, vol. 2, n. 1, p. 20, 2019, ISSN: 2523-3246. DOI: 10.1186/s42400-019-0038-7 indirizzo: <https://link.springer.com/article/10.1186/s42400-019-0038-7>
- [6] H. Hindy et al., «A Taxonomy of Network Threats and the Effect of Current Datasets on Intrusion Detection Systems,» *IEEE Access*, vol. 8, pp. 104 650–104 675, 2020, ISSN: 2169-3536. DOI: 10.1109/access.2020.3000179 indirizzo: <https://ieeexplore.ieee.org/document/9108270>
- [7] S. J. Pan e Q. Yang, «A Survey on Transfer Learning,» *IEEE Transactions on Knowledge and Data Engineering*, vol. 22, n. 10, pp. 1345–1359, 2010. DOI: 10.1109/TKDE.2009.191 indirizzo: <https://ieeexplore.ieee.org/document/5288526>
- [8] A. T. Azar, E. Shehab, A. M. Mattar, I. A. Hameed e S. A. Elsaid, «Deep Learning Based Hybrid Intrusion Detection Systems to Protect Satellite Networks,» *Journal of Network and Systems Management*, vol. 31, n. 4, p. 82, 2023, ISSN: 1573-7705. DOI:

10.1007/s10922-023-09767-8 indirizzo:

<https://link.springer.com/article/10.1007/s10922-023-09767-8>

- [9] N. Moustafa e J. Slay, «UNSW-NB15: a comprehensive data set for network intrusion detection systems (UNSW-NB15 network data set),» in *2015 Military Communications and Information Systems Conference (MilCIS)*, IEEE, 2015, pp. 1–6. DOI: 10.1109/MilCIS.2015.7348942 indirizzo: <https://ieeexplore.ieee.org/document/7348942>
- [10] K. Li, H. Zhou, Z. Tu, W. Wang e H. Zhang, «Distributed Network Intrusion Detection System in Satellite-Terrestrial Integrated Networks Using Federated Learning,» *IEEE Access*, vol. 8, pp. 214 852–214 865, 2020. DOI: 10.1109/ACCESS.2020.3041641 indirizzo: <https://ieeexplore.ieee.org/document/9274426>
- [11] I. F. Kilincer, F. Ertam e A. Sengur, «Machine learning methods for cyber security intrusion detection: Datasets and comparative study,» *Computer Networks*, vol. 188, p. 107 840, 2021, ISSN: 1389-1286. DOI: 10.1016/j.comnet.2021.107840 indirizzo: <https://www.sciencedirect.com/science/article/pii/S1389128621000141?via%3Dihub>
- [12] R. Sommer e V. Paxson, «Outside the Closed World: On Using Machine Learning for Network Intrusion Detection,» in *Proceedings of the IEEE Symposium on Security and Privacy (S&P)*, 2010, pp. 305–316. DOI: 10.1109/SP.2010.25 indirizzo: <https://ieeexplore.ieee.org/document/5504793>
- [13] M. Tavallaei, E. Bagheri, W. Lu e A. A. Ghorbani, «A detailed analysis of the KDD CUP 99 data set,» in *2009 IEEE Symposium on Computational Intelligence for Security and Defense Applications*, IEEE, 2009, pp. 1–6. DOI: 10.1109/CISDA.2009.5356528 indirizzo: <https://ieeexplore.ieee.org/document/5356528>
- [14] I. Sharafaldin, A. H. Lashkari e A. A. Ghorbani, «Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization,» in *Proceedings of the 4th International Conference on Information Systems Security and Privacy (ICISSP)*, SciTePress, 2018, pp. 108–116. DOI: 10.5220/0006639801080116 indirizzo: <https://api.semanticscholar.org/CorpusID:4707749>

- [15] M. Wan et al., «A Federated Learning-Based Intrusion Detection System for Satellite-Terrestrial Integrated Networks,» in *ICASSP 2025 - 2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, IEEE, 2025, pp. 1–5. doi: 10.1109/ICASSP49660.2025.10890330 indirizzo: <https://ieeexplore.ieee.org/document/10890330>
- [16] S. Alam e W.-C. Song, «Intent-Based Network Resource Orchestration in Space-Air-Ground Integrated Networks: A Graph Neural Networks and Deep Reinforcement Learning Approach,» *IEEE Access*, vol. 12, pp. 185 057–185 077, 2024. doi: 10.1109/ACCESS.2024.3507829 indirizzo: <https://ieeexplore.ieee.org/document/10770209>
- [17] A. Farahani, S. Voghoei, K. Rasheed e H. R. Arabnia, «A Brief Review of Domain Adaptation,» in *Advances in Data Science and Information Engineering*, Springer, 2021, pp. 877–894. doi: 10.1007/978-3-030-71704-9_59 indirizzo: <https://arxiv.org/abs/2010.03978>
- [18] G. Wilson e D. J. Cook, «A Survey of Unsupervised Deep Domain Adaptation,» *ACM Transactions on Intelligent Systems and Technology*, vol. 11, n. 5, pp. 1–46, 2020. doi: 10.1145/3400066 indirizzo: <https://arxiv.org/abs/1812.02849>
- [19] H. Daumé III, «Frustratingly Easy Domain Adaptation,» *CoRR*, vol. abs/0907.1815, 2009. doi: 10.48550/arXiv.0907.1815 indirizzo: <https://arxiv.org/abs/0907.1815>
- [20] S. Motiian, M. Piccirilli, D. A. Adjeroh e G. Doretto, «Unified Deep Supervised Domain Adaptation and Generalization,» *CoRR*, vol. abs/1709.10190, 2017. doi: 10.48550/arXiv.1709.10190 indirizzo: <https://arxiv.org/abs/1709.10190>
- [21] L. Breiman, J. H. Friedman, R. A. Olshen e C. J. Stone, *Classification and Regression Trees*. Belmont, CA: Wadsworth International Group, 1984, ISBN: 978-0534980535.
- [22] T. Hastie, R. Tibshirani e J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd. Springer, 2009, ISBN: 978-0387848570.
- [23] V. N. Vapnik, *Statistical Learning Theory*. New York: John Wiley & Sons, 1998, ISBN: 978-0-471-03003-4.

- [24] T. Chen e C. Guestrin, «XGBoost: A Scalable Tree Boosting System,» *CoRR*, vol. abs/1603.02754, 2016. DOI: 10.1145/2939672.2939785 indirizzo: <http://arxiv.org/abs/1603.02754>
- [25] L. Breiman, «Random Forests,» *Machine Learning*, vol. 45, n. 1, pp. 5–32, 2001, ISSN: 1573-0565. DOI: 10.1023/A:1010933404324 indirizzo: <https://link.springer.com/article/10.1023/A:1010933404324#citeas>
- [26] J. H. Friedman, «Greedy Function Approximation: A Gradient Boosting Machine,» *The Annals of Statistics*, vol. 29, n. 5, pp. 1189–1232, 2001. DOI: 10.1214/aos/1013203451 indirizzo: <https://projecteuclid.org/journals/annals-of-statistics/volume-29/issue-5/Greedy-function-approximation-A-gradient-boosting-machine/10.1214/aos/1013203451.full>
- [27] G. Ke et al., «LightGBM: a highly efficient gradient boosting decision tree,» in *Proceedings of the 31st International Conference on Neural Information Processing Systems*, Curran Associates Inc., 2017, pp. 3149–3157. DOI: 10.5555/3294996.3295074 indirizzo: <https://dl.acm.org/doi/10.5555/3294996.3295074>
- [28] B. L. Welch, «The Generalization of "Student's" Problem when Several Different Population Variances are Involved,» *Biometrika*, vol. 34, n. 1-2, pp. 28–35, 1947. DOI: 10.1093/biomet/34.1-2.28 indirizzo: <https://academic.oup.com/biomet/article-abstract/34/1-2/28/210174?redirectedFrom=fulltext#no-access-message>
- [29] J. Demšar, «Statistical Comparisons of Classifiers over Multiple Data Sets,» *Journal of Machine Learning Research*, vol. 7, pp. 1–30, 2006. DOI: 10.5555/1248547.1248548 indirizzo: https://www.researchgate.net/publication/220320196_Statistical_Comparisons_of_Classifiers_over_Multiple_Data_Sets
- [30] K. Pearson, «LIII. On Lines and Planes of Closest Fit to Systems of Points in Space,» *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, Series 6, vol. 2, n. 11, pp. 559–572, 1901. DOI: 10.1080/14786440109462720 indirizzo: <https://www.tandfonline.com/doi/abs/10.1080/14786440109462720>

- [31] H. Hotelling, «Analysis of a Complex of Statistical Variables into Principal Components,» *Journal of Educational Psychology*, vol. 24, n. 6, pp. 417–441, 1933. doi: 10.1037/h0071325 indirizzo: <https://psycnet.apa.org/record/1934-00645-001>
- [32] M. Rosenblatt, «Remarks on Some Nonparametric Estimates of a Density Function,» *The Annals of Mathematical Statistics*, vol. 27, n. 3, pp. 832–837, 1956. doi: 10.1214/aoms/1177728190 indirizzo: <https://projecteuclid.org/journals/annals-of-mathematical-statistics/volume-27/issue-3/Remarks-on-Some-Nonparametric-Estimates-of-a-Density-Function/10.1214/aoms/1177728190.full>
- [33] E. Parzen, «On Estimation of a Probability Density Function and Mode,» *The Annals of Mathematical Statistics*, vol. 33, n. 3, pp. 1065–1076, 1962. doi: 10.1214/aoms/1177704472 indirizzo: <https://projecteuclid.org/journals/annals-of-mathematical-statistics/volume-33/issue-3/On-Estimation-of-a-Probability-Density-Function-and-Mode/10.1214/aoms/1177704472.full>
- [34] S. M. Lundberg e S.-I. Lee, «A unified approach to interpreting model predictions,» *CoRR*, vol. abs/1705.07874, 2017. doi: 10.48550/arXiv.1705.07874 indirizzo: <https://arxiv.org/abs/1705.07874>
- [35] L. S. Shapley, «A value for n-person games,» *Contributions to the Theory of Games*, vol. 2, n. 28, pp. 307–317, 1953. doi: 10.1515/9781400881970-018 indirizzo: <https://www.scirp.org/reference/referencespapers?referenceid=2126587>
- [36] S. M. Lundberg et al., «Explainable AI for Trees: From Local Explanations to Global Understanding,» *CoRR*, vol. abs/1905.04610, 2019. doi: 10.48550/arXiv.1905.04610 indirizzo: <https://arxiv.org/abs/1905.04610>
- [37] T. Fawcett, «An introduction to ROC analysis,» *Pattern Recognition Letters*, vol. 27, n. 8, pp. 861–874, 2006. doi: 10.1016/j.patrec.2005.10.010 indirizzo: https://www.researchgate.net/publication/222511520_Introduction_to_ROC_analysis
- [38] T. Saito e M. Rehmsmeier, «The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets,» *PLOS ONE*, vol. 10, n. 3, pp. 1–21, 2015. doi: 10.1371/journal.pone.0118432 indirizzo: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0118432>

Ringraziamenti

Qui i ringraziamenti, se lo desideri.