



UNIMORE
UNIVERSITÀ DEGLI STUDI DI
MODENA E REGGIO EMILIA

UNIVERSITÀ DEGLI STUDI DI MODENA E REGGIO EMILIA

Dipartimento di Ingegneria "Enzo Ferrari"

Corso di Laurea Triennale in Ingegneria Informatica (L-08)

<Titolo dell'Elaborato>

Tutor:

Prof. Mirco Marchetti

Candidato:

Alessandro Marchesini

Matricola 187179

ANNO ACCADEMICO 2025/2026

<Dedica, opzionale. Cancella tutto in questa pagina per saltarla>

Indice

1	Introduzione	1
1.1	Contesto generale	1
1.2	Obiettivo dell'Elaborato	1
2	Contesto di Riferimento e Stato dell'Arte	2
2.1	Telecomunicazioni	2
2.1.1	Telecomunicazioni terrestri	3
2.1.2	Telecomunicazioni satellitari	4
2.1.3	Analisi comparativa e necessità di monitoraggio intelligente	5
2.2	Sistemi NIDS basati su Machine Learning	7
2.2.1	NIDS in Machine Learning per le telecomunicazioni terrestri	8
2.2.2	NIDS in Machine Learning per le telecomunicazioni satellitari	9
2.3	Adattamento di Dominio e Scarsità dei Dati	12
2.3.1	Il fenomeno del domain shift nei sistemi NIDS	13
2.3.2	Adattamento di dominio supervisionato per la mitigazione dello sbilanciamento	14
2.4	Sintesi e Posizionamento del Lavoro	16
3	Formulazione Teorica e Framework Metodologico	18
3.1	Modello del Sistema e Spazi di Rappresentazione	18
3.1.1	Formalizzazione dei Domini e Composizione Asimmetrica del Traffico	20
3.1.2	Allineamento dello Spazio delle Feature e Preprocessing Astratto	25
3.2	Tassonomia delle Architetture di Classificazione e Valutazione Multi-Modello	28
3.2.1	Modello di Riferimento (Baseline) e Modelli Aggregati	30
3.2.2	Decomposizione Specialistica Biclasse	35
3.2.3	Spazio delle Famiglie di Decisione Alberiformi ed Ensembling	39
3.3	Framework di Adattamento, Granularità e Stabilità Statistica	44

3.3.1	Incertezza Stocastica e Valutazione Multi-Seed	46
3.3.2	Granularità della Risposta: Formulazione Binaria vs. Multiclasse	51
3.4	Framework Analitico, Spiegabilità e Significatività Statistica	54
3.4.1	Caratterizzazione Densometrica e Proiezioni Latenti	56
3.4.2	Spiegabilità e Attribuzione delle Feature	60
3.4.3	Metriche, Soglia e Significatività dei Confronti	63
3.5	Sintesi del Capitolo e Raccordo con la Campagna Sperimentale	68
4	Implementazione del Framework Metodologico	69
4.1	Ambiente Sperimentale e Riproducibilità	70
4.1.1	Repository e Organizzazione del Codice	70
4.1.2	Stack Tecnologico e Dipendenze	73
4.1.3	Gestione della Riproducibilità Stocastica	74
4.2	Caratterizzazione dei Dataset e Composizione dei Benchmark	75
4.2.1	Dominio Sorgente: UNSW-NB15	75
4.2.2	Domini di Destinazione: Segmento Satellitare/Terrestre STIN	76
4.2.3	Parametrizzazione e Istanziamento dei Benchmark	78
4.3	Allineamento delle Feature e Pipeline di Preprocessing	85
4.3.1	Feature Grezze e Criteri di Filtraggio Applicati	88
4.3.2	Implementazione dell'Operatore di Mappatura	90
4.3.3	Verifica dell'Omissione della Scalatura Esplicita	96
4.4	Implementazione dei Classificatori	97
4.4.1	Algoritmi di Base e Iperparametri	97
4.4.2	Istanziamento dei Modelli Aggregati	100
4.4.3	Istanziamento dei Modelli Biclasse	103
4.5	Protocollo di Addestramento e Valutazione	105
4.5.1	Orchestrazione del Ciclo di Addestramento Multi-Seed	106
4.5.2	Calcolo delle Metriche e Costruzione della Matrice di Valutazione	109
4.5.3	Implementazione del Test di Welch	118
4.6	Strumenti di Analisi Diagnostica e Spiegabilità	124

4.6.1	Standardizzazione Diagnostica, PCA e KDE	126
4.6.2	Implementazione di SHAP e TreeSHAP	133
4.6.3	Pipeline di Aggregazione SHAP–KDE	141
4.7	Sintesi della Pipeline Implementativa	144
5	Analisi dei Risultati e Discussione Sperimentale	150
5.1	Diagnostica Spaziale e Distributiva	150
5.1.1	Proiezioni PCA dello Spazio delle Feature	151
5.1.2	Stime di Densità di Kernel (KDE) e Domain Shift	155
5.2	Valutazione della Baseline INJECTION	161
5.2.1	Prestazioni Quantitative del Modello di Baseline	162
5.2.2	Analisi di Spiegabilità SHAP della Baseline INJECTION	165
5.3	Valutazione dei Modelli Sorgente rispetto alla Baseline	169
5.3.1	Prestazioni dei Modelli Biclasse e Aggregato Sorgente	169
5.3.2	Analisi Comparativa Incrociata: Modelli Sorgente vs Baseline	172
5.3.3	Analisi SHAP del Modello Aggregato Sorgente NB15	175
5.3.4	Analisi della Significatività Statistica (Test t di Welch) dei Modelli Sorgente vs Baseline	179
5.4	Valutazione dei Modelli Ibridi rispetto alla Baseline	181
5.4.1	Prestazioni dei Modelli Biclasse e Aggregati Ibridi	182
5.4.2	Analisi Comparativa Incrociata: Modelli Ibridi vs Baseline	185
5.4.3	Analisi SHAP del Modello Aggregato Ibrido NB15_STIN	188
5.4.4	Analisi della Significatività Statistica (Test t di Welch) dei Modelli Ibridi vs Baseline	192
5.5	Discussione Generale e Quadro Comparativo Globale	195
5.5.1	Quadro Comparativo Globale	195
5.5.2	Mappatura delle Associazioni tra Proprietà della Rete e Comportamento del Modello	198
5.5.3	Compromesso tra Complessità Computazionale e Prestazioni	203
5.5.4	Considerazioni Operative per l'Applicabilità in Ambito NIDS Satellitare . .	205

5.6 Sintesi e Conclusioni del Capitolo	209
A Risultati Numerici Completi	212
A.1 Risultati Completi della Baseline INJECTION	212
A.2 Risultati Completi dei Modelli Sorgente	214
A.3 Risultati Completi dei Modelli Ibridi	219
A.4 Risultati Completi dei Test Statistici	220
A.4.1 Modelli Sorgente rispetto alla Baseline INJECTION	220
A.4.2 Modelli Ibridi rispetto alla Baseline INJECTION	221
Riferimenti	222

Elenco delle Figure

2.1	Architettura di rete integrata Terrestre-Spaziale: rappresentazione della superficie d'attacco e posizionamento dei punti di monitoraggio <i>Network Intrusion Detection System</i> (NIDS).	6
2.2	Confronto schematico tra la valutazione intra-dominio (Scenario A) e l'impatto del domain shift sul trasferimento delle prestazioni tra il contesto terrestre e quello satellitare (Scenario B).	12
3.1	Pipeline logica astratta: allineamento dello spazio delle feature $\mathcal{X}$, isolamento preventivo Train/Test anti- <i>data leakage</i> , sintesi parametrica con ratio ρ senza reinserimento (con ancoraggio alla classe minoritaria) e istanziazione logica dei benchmark. I blocchi tratteggiati indicano le elaborazioni logiche, mentre i blocchi a linea continua rappresentano gli insiemi di dati e le categorie di output.	23
3.2	Flusso di mappatura e omogeneizzazione dello spazio delle <i>feature</i> : gli operatori ψ_S e ψ_T , definiti separatamente per ciascun dominio grezzo, convergono verso lo stesso spazio condiviso $\mathcal{X}$ attraverso i tre criteri comuni di filtraggio e armonizzazione descritti nel testo.	27
3.3	Flusso concettuale del protocollo di addestramento, inferenza e disaggregazione delle prestazioni per i modelli aggregati ($\mathcal{M}_{\text{base}}, \mathcal{M}_S, \mathcal{M}_H^{(T)}$). I modelli, congelati post-ottimizzazione, vengono valutati sia sull'intero benchmark multi-classe per misurare la generalizzazione di dominio, sia sulle singole partizioni per famiglia d'attacco $\mathcal{D}_a^{(\text{test})}$ per l'analisi di disaggregazione puntuale.	35
3.4	Flusso concettuale del protocollo di valutazione incrociata (<i>cross-evaluation</i>). Il modello specialistico $\mathcal{M}_{S,a}$, addestrato esclusivamente sulla singola minaccia a , rimane invariato e viene proiettato in fase di inferenza sull'intero benchmark eterogeneo $\mathcal{D}^{(\text{test})}$	39

3.5	Confronto logico-procedurale tra gli schemi di aggregazione. A sinistra, il paradigma <i>Bagging</i> esegue un addestramento parallelo su campionamenti bootstrap indipendenti. A destra, il paradigma <i>Gradient Boosting</i> adotta un approccio sequenziale in cui ciascun albero mira a correggere i residui iterativi generati dall'insieme precedente.	44
3.6	Diagramma di flusso del protocollo di isolamento e valutazione stocastica. La stabilità della partizione dei dati è forzata top-down dall'unico seed deterministico s_0 , delegando la totalità della varianza osservata tra le matrici H_k all'inizializzazione stocastica dettata dall'insieme dei seed $\mathcal{S}$ interni agli stimatori.	47
3.7	Rappresentazione bidimensionale nello spazio delle caratteristiche $\mathcal{X}$ dell'impatto del <i>domain shift</i> (vettore di traslazione $\boldsymbol{\eta}$) a seconda della granularità del modello. A sinistra, la maggiore ampiezza spaziale del modello aggregato garantisce tolleranza generalista; a destra, l'ottimizzazione specialistica sul singolo supporto malevolo determina rigidità sotto perturbazione.	53
3.8	Mappatura della probabilità a posteriori $f(\mathbf{x})$ sulla regola decisionale binaria $\hat{y}(\tau)$ in funzione della soglia τ	65
3.9	Rappresentazione schematica dell'Area Sottesa alla Curva (AUC) per le analisi grafiche ROC (a) e Precision-Recall (b).	67
4.1	Rappresentazione schematica della gerarchia delle directory del progetto e delle risorse generate a runtime.	72
4.2	Diagramma di flusso del processo di estrazione, pulizia, campionamento vincolato ($\rho = 10$) e partizionamento stratificato 80/20 per la generazione dei benchmark fisici aggregati e biclasse.	85
4.3	Diagramma di flusso della pipeline di preprocessing e armonizzazione tra il dominio sorgente $\mathcal{D}_S$ e i domini target $\mathcal{D}_T$, dall'estrazione delle feature grezze alla generazione dello spazio coordinato finale a 16 dimensioni.	87
4.4	Architettura del flusso dati per l'addestramento dei Modelli Aggregati. Le percentuali indicano l'origine logica dei pacchetti che compongono i <i>training set</i> , forzati strutturalmente al vincolo $\rho_{\text{ben/mal}} = 10/1$	102

4.5	Flusso operativo dell'orchestrazione multi-seed e isolamento degli artefatti persistiti.	107
4.6	Pipeline a due stadi per il calcolo delle metriche di classificazione, tracciamento su file system e aggregazione statistica multi-seed.	116
4.7	Pipeline di trasformazione dei dati per l'esecuzione del Test t di Welch, dal recupero delle metriche sui singoli seed alla persistenza degli esiti statistici.	120
4.8	Schema concettuale della Standardizzazione Diagnostica Dipendente dal Sorgente: le statistiche di centralità e variabilità (μ_S, σ_S) e gli autovettori della PCA ($\mathbf{W}_S$) vengono stimati esclusivamente sul benchmark sorgente S e congelati. La trasformazione dei benchmark target T_k avviene per applicazione diretta di tali parametri, preservando lo scostamento distributivo reale (<i>domain shift</i>).	128
4.9	Architettura della pipeline di spiegabilità SHAP per i modelli di classificazione. Il diagramma illustra le quattro fasi sequenziali disposte in blocchi verticalmente allineati con connessioni di flusso circolare (effetto Pacman) sul margine destro/sinistro tra le diverse fasi.	137
4.10	Diagramma architetturale del raccordo <i>Human-in-the-Loop</i> tra l'analisi diagnostica (SHAP) e la valutazione densometrica (KDE). L'intervento manuale (Fase 2) funge da disaccoppiamento metodologico tra le due pipeline automatizzate.	142
4.11	Architettura software end-to-end e flusso di esecuzione unificato: dall'ingestione dei dataset grezzi, passando per l'armonizzazione delle feature e il ciclo di addestramento multi-seed, fino alla biforcazione tra ramo inferenziale (valutazione prestazionale) e ramo diagnostico (PCA, KDE e TreeSHAP).	148
5.1	Proiezione PCA bidimensionale del benchmark sorgente NB15 nel sistema di riferimento ottenuto mediante standardizzazione e fitting sul dominio sorgente.	152
5.2	Proiezione PCA bidimensionale del benchmark INJECTION, utilizzato per l'addestramento della baseline $\mathcal{M}_{\text{base}}$, nel sistema di riferimento PCA definito dal dominio sorgente.	153
5.3	Proiezione PCA bidimensionale del benchmark ibrido NB15_STIN, composto da traffico nominale sorgente NB15 e traffico malevolo target STIN, nel sistema di riferimento PCA definito dal dominio sorgente.	154

5.4	Stime KDE delle feature <code>pkts_per_sec</code> , <code>total_bytes</code> e <code>dst_win_byt</code> per il benchmark sorgente NB15, espresse mediante standardizzazione ancorata al dominio sorgente.	157
5.5	Stime KDE delle feature <code>pkts_per_sec</code> , <code>total_bytes</code> e <code>dst_win_byt</code> per il benchmark INJECTION, utilizzato per l'addestramento della baseline $\mathcal{M}_{\text{base}}$	158
5.6	Stime KDE delle feature <code>pkts_per_sec</code> , <code>total_bytes</code> e <code>dst_win_byt</code> per il benchmark ibrido NB15_STIN, costituito da traffico nominale sorgente NB15 e traffico malevolo target STIN.	159
5.7	Summary plot SHAP della baseline INJECTION per Decision Tree, Histogram-based Gradient Boosting e Random Forest, valutati sul test set INJECTION con seed $s = 42$. 166	
5.8	Summary plot SHAP del modello aggregato sorgente NB15 implementato mediante Decision Tree, Histogram-based Gradient Boosting e Random Forest, valutati sul test set aggregato NB15 con seed $s = 42$	176
5.9	Summary plot SHAP del modello aggregato ibrido NB15_STIN implementato mediante Decision Tree, Histogram-based Gradient Boosting e Random Forest, valutati sul benchmark NB15_STIN con seed $s = 42$	189

Elenco delle Tabelle

2.1	Sintesi e confronto della letteratura principale sui NIDS nei domini terrestre e satellitare.	11
3.1	Sintesi della notazione matematica e dei simboli del framework.	20
3.2	Tassonomia astratta delle cinque categorie di benchmark sperimentali istanziate dinamicamente.	25
3.3	Sintesi della notazione relativa alle architetture e ai parametri di classificazione. . .	30
3.4	Sintesi comparativa dei modelli di riferimento e aggregati: composizione del training set e finalità concettuale.	34
3.5	Sintesi dei modelli biclasse specializzati: composizione del <i>training set</i> e finalità concettuale.	37
3.6	Confronto delle proprietà architetture e degli obiettivi di ottimizzazione tra i paradigmi di <i>ensembling</i> Bagging e Gradient Boosting.	43
3.7	Sintesi della notazione relativa al framework di valutazione e alla stabilità statistica.	45
3.8	Rappresentazione concettuale della matrice di valutazione incrociata $H_k \in \mathbb{R}^{ \mathcal{M} \times \mathcal{B} }$.	48
3.9	Sintesi della notazione relativa al framework analitico, all'interpretabilità e alla valutazione statistica.	55
3.10	Sintesi del ruolo e dell'impatto della standardizzazione dipendente dal sorgente (μ_S, σ_S) sulle componenti diagnostiche del framework.	60
3.11	Struttura della Matrice di Confusione parametrizzata rispetto alla soglia decisionale τ .	64
4.1	Stack tecnologico, librerie e relative versioni vincolate nell'ambiente di runtime. . .	73
4.2	Distribuzione delle istanze del dataset UNSW-NB15 a seguito della procedura di <i>minority removal</i>	76
4.3	Distribuzione delle istanze del dataset TER20 a seguito del processo di <i>minority merge</i> .	78
4.4	Distribuzione delle istanze del dataset SAT20.	78
4.5	Riepilogo delle cardinalità finali per i benchmark aggregati.	83

4.6	Prospetto sintetico della cardinalità e del partizionamento per i Set Nativi Sorgente Biclasse e Ibridi Biclasse.	84
4.7	Feature eliminate durante la fase di pre-processing nei domini sorgente e target. . .	89
4.8	Sintesi del processo di selezione e allineamento dimensionale tra il dominio sorgente ($\mathcal{D}_S$) e i domini di destinazione ($\mathcal{D}_T$).	90
4.9	Formulazione algebrica dell'operatore di mappatura vettoriale nei domini $\mathcal{D}_S$ e $\mathcal{D}_T$. . .	91
4.10	Descrizione semantica delle feature coordinate.	92
4.11	Configurazione degli iperparametri di default e classi scikit-learn utilizzate per ciascuna famiglia di classificatori.	99
4.12	Struttura e campi del record di tracciamento persistito nel registro <code>models_metadata</code> . . .	100
4.13	Istanze dei modelli biclasse generati per il dominio sorgente e i domini target ibridizzati.	104
4.14	Metriche di valutazione delle prestazioni utilizzate per la caratterizzazione dei modelli di apprendimento automatico.	110
4.15	Tassonomia e suddivisione concettuale dei campi costituenti il record di tracciamento delle prestazioni.	114
4.16	Struttura e descrizione dei campi costituenti i file CSV per le matrici delle metriche individuali e aggregate ($M \times D$).	118
4.17	Struttura e descrizione semantica dei campi costituenti il file di registro statistico <code>welch_ttest</code>	124
4.18	Confronto sinottico tra gli strumenti diagnostici (PCA, KDE) e di spiegabilità (TreeSHAP) integrati nell'architettura software.	126
4.19	Confronto sinottico tra le procedure diagnostiche di proiezione PCA e stima della densità KDE nel modulo <code>plotting</code>	133
4.20	Sintesi dei parametri di configurazione e delle scelte ingegneristiche della pipeline SHAP.	140
4.21	Distribuzione delle frequenze di occorrenza C_j delle caratteristiche registrate nelle prime tre posizioni dei grafici SHAP.	143
4.22	Riepilogo dell'architettura software end-to-end.	145

5.1	Statistiche descrittive delle tre feature KDE per il traffico nominale sorgente e per le componenti malevole di NB15, INJECTION e NB15_STIN.	156
5.2	Precision, TPR e TNR della baseline INJECTION con DT, HGB e RF sui 16 test set per il seed $s = 42$	163
5.3	Prime cinque feature nella graduatoria SHAP della baseline INJECTION per DT, HGB e RF al seed $s = 42$	168
5.4	Prestazioni dei modelli sorgente sui rispettivi test set omologhi per il seed $s = 42$. .	170
5.5	Confronto multi-seed tra modello aggregato sorgente e baseline. Le differenze Δ sono calcolate come baseline meno modello sorgente.	173
5.6	Prime cinque feature nella graduatoria SHAP del modello aggregato sorgente NB15 per DT, HGB e RF al seed $s = 42$	177
5.7	Differenze di TPR e TNR tra i modelli aggregati ibridi e la baseline INJECTION. I valori sono calcolati come modello ibrido meno baseline.	186
5.8	Prime cinque feature nella graduatoria SHAP del modello aggregato ibrido NB15_STIN per DT, HGB e RF al seed $s = 42$	191
5.9	Quadro comparativo globale dei modelli aggregati sorgente, baseline e ibridi. Per $\mathcal{M}_H$ gli intervalli rappresentano i valori minimo e massimo osservati tra i tre modelli aggregati ibridi.	196
5.10	Mappatura sinottica delle associazioni osservate tra evidenze distributive, rilevanza SHAP e comportamento prestazionale. Le relazioni riportate non rappresentano nessi causali dimostrati.	202
5.11	Sintesi qualitativa del compromesso tra articolazione del modello e prestazioni osservate nella configurazione INJECTION.	205
5.12	Sintesi delle implicazioni operative dei tre paradigmi di addestramento nell'ambito del protocollo NIDS considerato.	208
A.1	Cardinalità complete delle matrici di confusione della baseline INJECTION con DT, HGB e RF sui 16 test set per il seed $s = 42$	212
A.2	F1-Score e PR-AUC completi della baseline INJECTION con DT, HGB e RF sui 16 test set per il seed $s = 42$	213

A.3	TPR media sui 10 seed dei modelli sorgente valutati sui benchmark sorgente e sul test set INJECTION.	214
A.4	TPR media sui 10 seed dei modelli sorgente valutati sui benchmark target aggregati e biclasse.	215
A.5	Media e varianza della TNR sui 10 seed per i modelli sorgente. Il valore è indipendente dal test set malevolo poiché la componente nominale rimane invariata all'interno del protocollo sperimentale.	216
A.6	Media e varianza della TPR sui benchmark target aggregati per il modello sorgente aggregato e la baseline.	217
A.7	Vantaggio TPR della baseline rispetto al migliore modello sorgente disponibile su ciascun benchmark target.	218
A.8	TPR e F1-Score dei modelli ibridi sui rispettivi test set target omologhi per il seed $s = 42$	219
A.9	TPR media multi-seed dei modelli ibridi sui benchmark sorgente, INJECTION e target. Le colonne NB15 e Target rappresentano rispettivamente la media sui sei e sui nove test set dei corrispondenti gruppi.	220
A.10	Media e deviazione standard campionaria dei valori $\overline{F1}_i^{(k)}$ sui 10 seed per la baseline e i modelli sorgente. $\Delta F1$ è calcolato come baseline meno modello sorgente.	220
A.11	Risultati del test t di Welch tra injection_aggregate e i modelli sorgente, con $\alpha = 0,05$	221
A.12	Media e deviazione standard campionaria dei valori medi di F1-Score sui 10 seed per la baseline e i modelli ibridi. $\Delta F1$ è calcolato come baseline meno modello ibrido.	221

Elenco dei Codici

4.1	Routine di campionamento per l'istanziamento dei benchmark.	79
4.2	Routine di bilanciamento stratificato per l'istanziamento dei benchmark.	81
4.3	Trasposizione operativa dell'operatore di mappatura ψ_k tramite vettorializzazione pandas per il dominio UNSW-NB15.	94
4.4	Trasposizione operativa dell'operatore di mappatura ψ_k tramite vettorializzazione pandas per il dominio STIN.	95
4.5	Estrazione procedurale dell'etichetta di attacco per la generazione dinamica della nomenclatura del modello.	105
4.6	Gestione difensiva dei casi limite e calcolo delle metriche in <code>calculate_metrics()</code>	112
4.7	Estrazione dei campioni ed esecuzione del Test t di Welch.	122
4.8	Standardizzazione e adattamento della PCA sul benchmark sorgente.	129
4.9	Applicazione della trasformazione diagnostica ancorata al benchmark sorgente.	129
4.10	Adattamento dello standardizzatore sulle feature utilizzate per la KDE.	130
4.11	Trasformazione diagnostica feature-per-feature ancorata ai parametri dello scaler sorgente.	131
4.12	Generazione delle stime KDE ed impostazione della scala logaritmica simmetrica su asse y	132
4.13	Campionamento stratificato del test set per l'analisi SHAP.	135
4.14	Inizializzazione dinamica dello spiegatore SHAP con catena di fallback.	136
4.15	Calcolo, normalizzazione dimensionale e rendering dei valori SHAP.	139
4.16	Configurazione delle feature selezionate per l'analisi KDE.	143

1. Introduzione

1.1 Contesto generale

1.2 Obiettivo dell'Elaborato

2. Contesto di Riferimento e Stato dell'Arte

Il presente capitolo delinea il quadro concettuale, metodologico e bibliografico all'interno del quale si posiziona il lavoro di ricerca, ponendo le basi per l'analisi dei sistemi di rilevamento delle intrusioni in ambienti di rete complessi ed eterogenei. L'obiettivo primario è chiarire come la natura del canale trasmissivo e le relative dinamiche fisiche influenzino la rappresentazione vettoriale dei dati, condizionando la stabilità e la capacità di generalizzazione dei modelli di sicurezza basati su Machine Learning.

La trattazione si articola come segue. La Sezione 2.1 analizza le caratteristiche strutturali, le vulnerabilità e i profili di rischio che differenziano le infrastrutture terrestri dai segmenti spaziali, evidenziando la necessità di paradigmi di monitoraggio attivo. La Sezione 2.2 esamina i principi operativi dei *Network Intrusion Detection Systems* (NIDS) guidati dall'apprendimento automatico, fornendo una disamina critica della letteratura principale e identificando i limiti dei modelli attuali nel gestire transizioni tra domini differenti. Successivamente, la Sezione 2.3 formalizza rigorosamente i fenomeni di disallineamento distributivo (*domain shift*) e di scarsità dei dati etichettati, definendo le strategie di adattamento di dominio supervisionato. Infine, la Sezione 2.4 sintetizza i gap metodologici emersi dallo stato dell'arte e colloca puntualmente i contributi innovativi e l'approccio proposto da questo lavoro di tesi nel panorama scientifico di riferimento.

2.1 Telecomunicazioni

L'evoluzione delle infrastrutture di rete ha elevato i sistemi di telecomunicazione a componenti abilitanti fondamentali per la società moderna, la cui resilienza rappresenta un prerequisito imprescindibile per la protezione delle infrastrutture critiche e la continuità dei servizi essenziali [33]. Con l'affermazione di un paradigma trasmissivo interamente digitale, la convergenza di supporti fisici elettrici, ottici ed elettromagnetici su topologie geografiche complesse ha determinato un ampliamento esponenziale della superficie d'attacco¹.

¹La superficie d'attacco definisce l'insieme complessivo dei vettori di ingresso, delle vulnerabilità software, delle interfacce di rete e dei nodi fisici attraverso cui un agente malevolo può tentare di accedere, degradare o alterare un

La compromissione o la degradazione intenzionale di un canale trasmissivo non si limita a generare una temporanea interruzione della connettività, ma è in grado di innescare fallimenti sistemici a cascata, inficiando l'integrità dei flussi e paralizzando processi decisionali in tempo reale [32]. In un panorama di minacce caratterizzato dall'azione di attori malevoli ad alta persistenza², la difesa dei vettori di trasmissione non può prescindere da una progettazione orientata alla sicurezza nativa (*security-by-design*).

Tale paradigma mira a garantire i requisiti fondamentali di riservatezza, integrità, disponibilità e autenticità dei flussi informativi. L'impostazione di un'efficace strategia difensiva richiede pertanto una disamina puntuale dei vincoli strutturali e dei profili di rischio che caratterizzano i diversi contesti trasmissivi, tracciando una distinzione rigorosa tra le peculiarità delle reti di superficie e le criticità emergenti dei canali orbitali.

2.1.1 Telecomunicazioni terrestri

In questo quadro, la conformazione delle infrastrutture di comunicazione terrestri evidenzia un profondo compromesso tra prestazioni trasmissive e complessità delle contromisure di sicurezza. Da un lato, la combinazione di mezzi guidati ad elevata ampiezza di banda — quali le fibre ottiche — e di vettori radio ad alta frequenza garantisce latenze di propagazione estremamente ridotte, rendendo tali reti il supporto d'elezione per le applicazioni in tempo reale [33]. Dall'altro, la natura distribuita e fisicamente accessibile dei nodi e degli apparati di instradamento intermedi espone l'infrastruttura a un ampio spettro di minacce, agevolando sia intercettazioni sulla tratta fisica sia attacchi logici di tipo *Man-in-the-Middle* (MitM) e *Denial of Service* (DoS) [32].

Sebbene i protocolli crittografici a livello di rete e trasporto (quali IPsec e TLS³) garantiscano la riservatezza e l'integrità dei dati contro l'ascolto passivo, essi si dimostrano intrinsecamente insufficienti a proteggere l'infrastruttura nella sua interezza. Tali meccanismi non ostacolano infatti

sistema di comunicazione.

²Con minacce ad alta persistenza (*Advanced Persistent Threats*, APT) si identificano campagne d'attacco mirate e prolungate nel tempo, condotte da organizzazioni strutturate che impiegano tecniche avanzate per infiltrarsi e mantenere un accesso stealth non autorizzato all'infrastruttura.

³IPsec (*Internet Protocol Security*) opera a livello di rete (Livello 3 del modello ISO/OSI) cifrando l'intero pacchetto IP o il relativo payload, mentre TLS (*Transport Layer Security*) agisce a livello di trasporto/sessione (Livelli 4-5 ISO/OSI) per proteggere il canale sopra protocolli orientati alla connessione come il TCP.

l'analisi del traffico e dei metadati⁴ condotta da osservatori esterni, né risultano efficaci nel contrastare aggressioni volumetriche di tipo DoS o manomissioni strutturali della catena trasmissiva. Si rende quindi indispensabile l'integrazione di sistemi di monitoraggio attivo, come i *Network Intrusion Detection Systems* (NIDS), capaci di analizzare continuamente i flussi di rete per identificare tempestivamente deviazioni dal comportamento nominale prima che si traducano in disservizi sistemici [15].

Ciononostante, la sola protezione del segmento di superficie si rivela insufficiente laddove si richieda la copertura di regioni orograficamente complesse, l'interconnessione di nodi isolati o una ridondanza critica per la continuità operativa. Tali vincoli impongono l'estensione dell'architettura trasmissiva verso il segmento spaziale, introducendo nuove dinamiche di canale e ulteriori sfide di sicurezza.

2.1.2 Telecomunicazioni satellitari

In tale contesto di integrazione, l'impiego di piattaforme orbitali rappresenta una soluzione architetturealmente imprescindibile per garantire una copertura geografica globale, introducendo tuttavia severe sfide operative e di sicurezza. La capacità di superare i vincoli orografici rende i collegamenti spaziali il vettore primario per la connettività in contesti isolati o d'emergenza, garantendo un'essenziale ridondanza per le infrastrutture terrestri [17]. Tuttavia, la natura *broadcast* del canale radio e la vasta impronta a terra (*footprint*) dei fasci di copertura espongono il segnale a continui rischi di intercettazione passiva e a tentativi di *jamming* volti alla saturazione dello spettro [19].

A tali vulnerabilità si sovrappongono i vincoli fisici e trasmissivi specifici delle diverse orbite. Se da un lato i collegamenti in orbita geostazionaria (GEO) sono penalizzati da un elevato ritardo di propagazione (con tempi di *Round Trip Time*, RTT, di circa 500 ms) che degrada le prestazioni dei meccanismi di controllo della congestione del TCP, dall'altro le costellazioni in orbita bassa (LEO) introducono elevate dinamiche di spostamento Doppler (*doppler shift*, con scostamenti fino a ± 100 kHz nelle bande Ku/Ka) e frequenti disconnessioni di *handoff* dovute al ridotto tempo di visibilità dei satelliti (5–10 minuti) [17].

⁴L'analisi del traffico (*traffic analysis*) consiste nell'estrazione di informazioni sensibili tramite l'osservazione dei metadati non cifrati (es. indirizzi IP di sorgente e destinazione, dimensione dei pacchetti, frequenza dei flussi e distribuzioni temporali degli interarrivi), anche in presenza di un payload completamente cifrato.

Inoltre, la potenziale iniezione non autorizzata di pacchetti o comandi di controllo verso il segmento spaziale evidenzia la chiara inadeguatezza della sola cifratura passiva. In conformità con le linee guida di difesa in profondità e monitoraggio continuo per i segmenti di terra e di bordo [19], risulta indispensabile combinare contromisure a livello fisico — quali tecniche di modulazione a spettro espanso a protezione della trasmissione (*TRANSEC*)⁵ — con sistemi di rilevamento delle intrusioni (NIDS) a livello logico, capaci di identificare tempestivamente deviazioni comportamentali del traffico prima che compromettano la disponibilità dell'intero collegamento.

2.1.3 Analisi comparativa e necessità di monitoraggio intelligente

In questa prospettiva di sintesi, l'analisi comparativa tra le architetture di telecomunicazione terrestri e satellitari evidenzia una fondamentale complementarietà strutturale, affiancata da sostanziali divergenze operative nei profili di prestazione, copertura e superficie di vulnerabilità. Se le infrastrutture terrestri garantiscono elevati valori di *throughput* e latenze di propagazione ridotte grazie ai mezzi guidati, esse risultano vincolate da una rigida topologia e da un'alta densità di nodi esposti ad aggressioni sia fisiche sia logiche [33]. Al contrario, i segmenti spaziali offrono una connettività pervasiva e affrancata da barriere orografiche, ma introducono criticità legate ai ritardi di propagazione, alle attenuazioni atmosferiche e alla vulnerabilità intrinseca del canale etere a intercettazioni e interferenze intenzionali (*jamming*) [17].

La convergenza di questi ambienti eterogenei nei moderni ecosistemi di comunicazione definisce un perimetro difensivo complesso (schematizzato nella Figura 2.1). In tale contesto, le contromisure di sicurezza tradizionali — quali la sola cifratura del dato o l'impiego di firewall statici — si dimostrano intrinsecamente insufficienti a contrastare vettori d'attacco dinamici e tecniche di evasione avanzate [32]. Ciò impone la transizione verso paradigmi di monitoraggio attivo e resiliente, in grado di rilevare tempestivamente anomalie di flusso lungo l'intero percorso trasmissivo.

Per rispondere a questa crescente complessità, si rende indispensabile l'integrazione di architetture *Network Intrusion Detection Systems* (NIDS) concepite per l'ispezione continua e non invasiva del traffico trasversale alle tratte terrestri e orbitali. Tuttavia, la massiva volumetria dei flussi e

⁵Le contromisure *TRANSEC* (*Transmission Security*) agiscono a livello fisico mediante modulazioni a spettro espanso, quali *DSSS* (*Direct Sequence Spread Spectrum*) o *FHSS* (*Frequency Hopping Spread Spectrum*), per rendere il segnale indistinguibile dal rumore di fondo o garantirne la resilienza contro interferenze intenzionali.

le fluttuazioni stocastiche del canale radio rendono i tradizionali NIDS basati su firme (*signature-based*⁶) inadeguati nei confronti di attacchi inediti (*zero-day*) o di alterazioni comportamentali sottili.

In tale scenario, l'adozione di modelli di Machine Learning si rivela determinante per profilare la dinamica del traffico nominale e identificare in tempo reale deviazioni marginali riconducibili ad attività malevole [15]. L'apprendimento automatico consente di automatizzare l'analisi predittiva e la correlazione di sicurezza multi-dominio, fornendo un presidio difensivo adattivo sia per le tratte di superficie sia per quelle satellitari. Ai fini di un'adeguata contestualizzazione del ruolo di tali strumenti nell'infrastruttura di rete, la sezione seguente introduce la formalizzazione teorica e metodologica dei NIDS e dei modelli di Machine Learning che ne costituiscono il motore analitico.




Figura 2.1: Architettura di rete integrata Terrestre-Spaziale: rappresentazione della superficie d'attacco e posizionamento dei punti di monitoraggio *Network Intrusion Detection System* (NIDS).

⁶I sistemi NIDS basati su firme, quali ad esempio Snort o Suricata, eseguono un'ispezione deterministica del traffico confrontando il contenuto dei pacchetti con un database di regole e pattern malevoli predefiniti, risultando ciechi di fronte a variazioni di formato, traffico cifrato o minacce non ancora catalogate.

2.2 Sistemi NIDS basati su Machine Learning

Muovendo da tali premesse, l'evoluzione delle minacce informatiche all'interno delle moderne infrastrutture di rete ha confermato l'inadeguatezza delle sole difese perimetrali e dei controlli d'accesso, rendendo indispensabile l'adozione di sistemi di rilevamento delle intrusioni basati su rete (*Network Intrusion Detection Systems*, NIDS) per il monitoraggio profondo e continuo del traffico logico. A differenza delle architetture *Host-based* (HIDS), progettate per analizzare i log locali e le chiamate di sistema del singolo dispositivo, un NIDS opera nei punti snodo dell'infrastruttura, ispezionando i flussi di dati per identificare tentativi di accesso non autorizzato, violazioni delle politiche di sicurezza o compromissioni dell'integrità del canale [12].

Tradizionalmente, la rilevazione delle intrusioni nei NIDS si articola in due macro-approcci: l'ispezione basata sulle firme (*Signature-based Detection*) e la rilevazione basata sulle anomalie (*Anomaly-based Detection*). Sebbene il primo garantisca un'elevata accuratezza nel riconoscere minacce note confrontando il traffico con un database di pattern malevoli predefiniti, esso mostra un'intrinseca inefficacia di fronte ad attacchi inediti (*Zero-Day*) e a varianti strutturali concepite per eludere i controlli [15]. Tale limite ha orientato la ricerca verso modelli analitici capaci di apprendere la profilazione comportamentale del traffico nominale.

Per superare la rigidità dei meccanismi deterministici basati su firme, l'integrazione delle tecniche di Machine Learning nei NIDS ha introdotto un paradigma adattivo e altamente generalizzabile, in grado di modellare la complessa dinamica del traffico trasmissivo moderno. Attraverso la formalizzazione di *feature* statistiche e sintattiche rilevanti⁷ — quali la frequenza dei pacchetti, la dimensione degli *header* e la distribuzione dei tempi di interarrivo —, un NIDS basato su Machine Learning costruisce una rappresentazione statistica del flusso informativo per rilevare deviazioni microscopiche riconducibili ad attività malevole senza la necessità di una firma preesistente [12, 15].

In questo contesto, la scelta metodologica di privilegiare classificatori di tipo supervisionato rispetto a soluzioni non supervisionate offre un vantaggio determinante in termini di affidabilità

⁷Nei NIDS moderni, la caratterizzazione del traffico poggia sull'estrazione di attributi di flusso (es. formato NetFlow/IPFIX), tra cui la dimensione degli *header*, la frequenza dei pacchetti, la dimensione delle finestre TCP e la distribuzione temporale degli interarrivi.

operativa⁸. Laddove l'apprendimento non supervisionato risente di un'elevata sensibilità alle fluttuazioni fisiologiche della rete, i modelli supervisionati permettono di tracciare confini di decisione precisi e stabili, ottimizzando la separazione tra flussi leciti e malevoli sia in formulazioni di classificazione binaria sia in configurazioni multiclasse per la caratterizzazione delle specifiche famiglie di minaccia [16].

2.2.1 NIDS in Machine Learning per le telecomunicazioni terrestri

L'applicazione dei *Network Intrusion Detection Systems* (NIDS) basati su Machine Learning alle infrastrutture di telecomunicazione terrestri risponde alla necessità imperativa di proteggere canali ad elevata ampiezza di banda e ad altissima densità di traffico. Nelle reti di terra ad alta velocità, i vettori d'attacco si manifestano prevalentemente attraverso aggressioni volumetriche di tipo *Distributed Denial of Service* (DDoS) o mediante attività di scansione coordinata (*port scanning*) finalizzate alla mappatura delle vulnerabilità del sistema [12, 15]. I modelli analitici sviluppati in letteratura si dividono principalmente tra approcci non supervisionati e classificatori supervisionati, ciascuno caratterizzato da specifici compromessi tra flessibilità applicativa e stabilità operativa [16]. Tuttavia, l'analisi dello stato dell'arte evidenzia un limite metodologico diffuso: la quasi totalità della letteratura valuta tali modelli esclusivamente all'interno del medesimo contesto di addestramento, sottovalutando il severo degrado prestazionale causato dalla variazione delle condizioni del canale e della distribuzione dei dati.

Un primo filone di ricerca nell'ambito del monitoraggio non presidiato poggia sull'analisi fondamentale di Sommer e Paxson [31], incentrata sullo studio critico dei limiti dell'anomaly detection basata su Machine Learning non supervisionato in reti di grande scala. Sebbene questo paradigma offra il vantaggio teorico di identificare deviazioni dal profilo di traffico nominale senza richiedere dataset etichettati — promettendo una potenziale copertura contro minacce inedite —, lo studio ne evidenzia i severi vincoli operativi. In particolare, l'assenza di confini di decisione guidati da etichette rende i modelli non supervisionati estremamente sensibili al rumore di fondo e alle fluttuazioni stocastiche del traffico, traducendosi in un elevato e inaccettabile tasso di falsi allarmi (*False Positive Rate*, FPR). Per superare tali criticità analitiche, la nostra trattazione privilegia

⁸L'apprendimento supervisionato consente di contenere drasticamente il tasso di falsi allarmi (*False Positive Rate*, FPR), che costituisce una delle principali criticità applicative dei NIDS in ambienti ad alta variabilità stocastica.

l'apprendimento supervisionato, al fine di garantire confini di separazione stabili, interpretabili e misurabili di fronte al disallineamento distributivo.

Spostando l'attenzione sui modelli guidati da dati etichettati, un primo contributo pionieristico per i classificatori supervisionati terrestri è rappresentato dallo studio di Tavallae et al. [34]. Gli autori hanno formalizzato le metodologie di *benchmarking* per la sicurezza di rete attraverso la bonifica dei bias di ridondanza con il dataset NSL-KDD⁹. Nonostante l'importanza storica di tale lavoro nel validare l'accuratezza dei modelli supervisionati, il nostro approccio se ne discosta nettamente: la valutazione condotta da Tavallae et al. rimane circoscritta a un dominio sintetico e stazionario, senza indagare il comportamento dei classificatori di fronte a fenomeni di *domain shift*¹⁰.

Successivamente, Sharafaldin et al. [30] hanno esteso la caratterizzazione dei NIDS supervisionati a flussi ad alta dimensionalità e a vettori d'attacco complessi tramite l'introduzione del dataset CIC-IDS2017. Sebbene questo studio costituisca uno standard di riferimento per la modellazione del traffico moderno, la nostra proposta segna un chiaro elemento di discontinuità: l'analisi di Sharafaldin et al. valuta le prestazioni focalizzandosi su una risposta prevalentemente multiclasse all'interno di un singolo contesto trasmissivo locale. Il nostro lavoro mette invece a confronto diretto la granularità binaria e multiclasse sotto scostamenti distributivi eterogenei, valutando come la struttura della risposta incida sulla stabilità dei confini discriminativi durante il trasferimento cross-dominio.

2.2.2 NIDS in Machine Learning per le telecomunicazioni satellitari

L'impiego dei *Network Intrusion Detection Systems* (NIDS) basati su Machine Learning nelle comunicazioni satellitari deve misurarsi con vincoli operativi e dinamiche di canale radicalmente divergenti rispetto al contesto terrestre. Le tratte orbitali sono penalizzate da elevati tempi di latenza di propagazione, capacità di canale fortemente asimmetriche e da una marcata suscettibilità

⁹Il dataset NSL-KDD ha risolto i problemi di duplicazione dei record presenti nell'originale KDD'99, i quali sbilanciavano le metriche di valutazione e alteravano la capacità dei classificatori di apprendere pattern di attacco rari.

¹⁰Con *domain shift* (o scostamento distributivo) si intende la variazione della distribuzione di probabilità congiunta dei dati tra il dominio di addestramento e quello di test ($P_S(X,Y) \neq P_T(X,Y)$), la quale determina un drastico decadimento della capacità di generalizzazione del modello.

al rumore atmosferico e ai fenomeni di *fading* stocastico del segnale [17]. In questo scenario, ai tradizionali vettori d'attacco logici si sovrappongono minacce specifiche del canale radio spaziale, quali le interferenze intenzionali di tipo *jamming* e l'iniezione non autorizzata di telecomandi malevoli (*command injection*) [19]. In ambienti caratterizzati da tale variabilità, la scelta di adottare classificatori supervisionati si rivela essenziale per contenere il tasso di falsi allarmi (*False Positive Rate*, FPR), a cui i modelli non supervisionati risultano strutturalmente vulnerabili quando esposti alle fluttuazioni stocastiche della rete [15, 17]. Tuttavia, la barriera primaria allo sviluppo di NIDS nativi per lo spazio risiede nella severa indisponibilità di dataset pubblici e realistici contenenti tracce etichettate di traffico satellitare malevolo [2].

Nell'ambito della letteratura focalizzata sulle reti integrate spazio-terra, un punto di riferimento di primaria importanza è costituito dallo studio di Wan et al. [36], incentrato su un NIDS distribuito basato su *Federated Learning* per la protezione delle infrastrutture satellitari. Il pregio principale di questo contributo risiede nell'adozione di un paradigma di addestramento cooperativo che tutela la riservatezza dei dati locali e riduce l'ampiezza di banda richiesta sui collegamenti spaziali. Ciononostante, il nostro approccio si diversifica in modo sostanziale da tale impostazione: lo studio di Wan et al. presuppone un'architettura federata attiva che richiede continui cicli di aggregazione e sincronizzazione dei parametri tra i nodi della costellazione. Al contrario, la nostra soluzione valuta la trasferibilità diretta (*zero-shot*¹¹) di un modello addestrato nel dominio terrestre verso l'ambiente satellitare, affrontando il *domain shift* senza gravare sui collegamenti orbitali con l'onere computazionale e comunicativo di un protocollo distribuito.

Infine, un ulteriore filone di ricerca sulle reti integrate spazio-aria-terra (SAGIN¹²) è rappresentato dal lavoro di Alam e Song [1], focalizzato sull'orchestrazione dinamica delle risorse mediante l'impiego combinato di *Graph Neural Networks* (GNN) e *Deep Reinforcement Learning* (DRL). Il merito fondamentale di tale studio risiede nella capacità di adattarsi alla topologia fortemente dinamica dei nodi spaziali per l'ottimizzazione delle prestazioni di rete. Tuttavia, il nostro lavoro si distingue nettamente da questa prospettiva: la trattazione di Alam e Song è orientata all'allocazione

¹¹Nel contesto considerato, l'approccio *zero-shot* indica la valutazione diretta delle prestazioni di un classificatore, addestrato esclusivamente su dati di origine terrestre, nei confronti del traffico proveniente dal canale satellitare, senza applicare riaddestramenti o adattamenti specifici (*fine-tuning*).

¹²*Space-Air-Ground Integrated Networks*: architetture di rete tridimensionali ed eterogenee che integrano la segmentazione spaziale (satelliti LEO/MEO/GEO), aerea (droni, HAPS) e terrestre.

delle risorse infrastrutturali e richiede modelli decisionali complessi caratterizzati da elevati costi computazionali e frequenti cicli di riaddestramento. La nostra proposta si concentra invece sulla caratterizzazione della sicurezza e sul rilevamento delle intrusioni tramite un’architettura di classificazione alleggerita, valutandone la robustezza discriminativa di fronte alle distorsioni di canale senza ricorrere a complessi processi di riapprendimento in tempo reale.

Tabella 2.1: Sintesi e confronto della letteratura principale sui NIDS nei domini terrestre e satellitare.

Rif.	Dominio	Approccio	Punto di Forza	Limiti e Gap Metodologico
[31]	Terrestre	ML Unsupervised	Rilevamento di minacce <i>zero-day</i> senza dataset etichettati.	Elevato tasso di falsi allarmi (FPR) dovuto alle fluttuazioni stocastiche di rete.
[34]	Terrestre	ML Supervised	Benchmarking rigido e bonifica dei bias di ridondanza (NSL-KDD).	Analisi circoscritta a dati sintetici e stazionari; assenza di valutazione su <i>domain shift</i> .
[30]	Terrestre	ML Supervised	Caratterizzazione di flussi ad alta dimensionalità (CIC-IDS2017).	Ristretto alla sola risposta multiclasse; omette la valutazione binaria e cross-dominio.
[36]	Spazio-Terra	Federated Learning	Addestramento distribuito e cooperativo con tutela della privacy.	Elevato <i>overhead</i> per sincronizzazione continua dei parametri su tratte orbitali.
[1]	SAGIN	GNN + DRL	Adattamento dinamico alle topologie spaziali ad alta variabilità.	Elevato carico computazionale; orientato alle risorse anziché alla rilevazione.

L'analisi dello stato dell'arte, i cui contributi fondamentali e i relativi elementi di discontinuità sono sintetizzati nella Tabella 2.1, evidenzia come la progettazione di NIDS basati su Machine Learning per infrastrutture integrate debba superare l'ipotesi di stazionarietà¹³ e omogeneità prevalente nella letteratura attuale.

Come illustrato nello schema concettuale di Figura 2.2, l'estensione dei modelli dal contesto terrestre a quello satellitare richiede di formalizzare le problematiche di degrado prestazionale causate dal disallineamento distributivo del traffico (*domain shift*) e dalla severa indisponibilità di dati etichettati nel segmento spaziale. Tali sfide metodologiche costituiscono l'oggetto della trattazione dettagliata sviluppata nella sezione seguente.




Figura 2.2: Confronto schematico tra la valutazione intra-dominio (Scenario A) e l'impatto del domain shift sul trasferimento delle prestazioni tra il contesto terrestre e quello satellitare (Scenario B).

2.3 Adattamento di Dominio e Scarsità dei Dati

A completamento dell'analisi delle criticità connesse all'integrazione di sistemi di sicurezza basati sull'apprendimento automatico nei moderni ecosistemi di telecomunicazione, risulta indispensabile

¹³L'ipotesi di stazionarietà assume che le proprietà statistiche dei flussi di rete (es. media, varianza e distribuzione dei pacchetti) rimangano invariati nel tempo e tra domini differenti, condizione regolarmente smentita nella transizione tra reti terrestri e spaziali.

esaminare le problematiche metodologiche e teoriche legate alla variazione dei contesti operativi e alla disponibilità delle informazioni. La transizione da architetture trasmissive omogenee a scenari eterogenei impone infatti di superare i limiti strutturali associati non solo alla natura fisica dei canali, ma anche alla portabilità dei modelli analitici e alla disomogeneità statistica dei dataset di riferimento.

2.3.1 Il fenomeno del domain shift nei sistemi NIDS

L'efficacia dei modelli di Machine Learning applicati ai Network Intrusion Detection Systems (NIDS) poggia fondamentalmente sull'assunto teorico che i dati di addestramento e quelli operativi siano indipendenti e identicamente distribuiti (*i.i.d.*). Tuttavia, nelle infrastrutture di rete reali la natura dinamica e fortemente variabile del traffico invalida frequentemente tale ipotesi, introducendo un marcato scostamento distributivo [24]. In questo scenario, l'adozione di paradigmi di *transfer learning* diventa essenziale per mitigare il decadimento prestazionale dei classificatori. Tale approccio permette, infatti, di trasferire la conoscenza estratta dal dominio di origine eludendo il severo onere computazionale e logistico imposto dalla raccolta ex novo di dati etichettati e dal riaddestramento integrale dei modelli.

In termini formali, un dominio $\mathcal{D}$ è definito dalla coppia costituita da uno spazio delle *feature* $\mathcal{X}$ ¹⁴ e da una distribuzione di probabilità marginale $P(X)$, tale per cui $\mathcal{D} = \{\mathcal{X}, P(X)\}$. Assumendo uno spazio delle *feature* condiviso ($\mathcal{X}_S = \mathcal{X}_T = \mathcal{X}$), dati un dominio di origine (*source*) $\mathcal{D}_S = \{\mathcal{X}, P_S(X)\}$ e un dominio di destinazione (*target*) $\mathcal{D}_T = \{\mathcal{X}, P_T(X)\}$, il fenomeno del *domain shift* si verifica quando le distribuzioni marginali differiscono tra i contesti, ossia $P_S(X) \neq P_T(X)$ (*covariate shift*). In alternativa, o in concomitanza, esso si manifesta quando muta la distribuzione condizionata delle classi $Y \in \mathcal{Y}$ rispetto alle osservazioni, ovvero $P_S(Y|X) \neq P_T(Y|X)$ (*concept drift*) [24].

Nelle telecomunicazioni, questa discrepanza matematica si traduce in una tangibile alterazione dei profili di traffico. La transizione dal canale terrestre a quello satellitare introduce, infatti, elevati tempi di latenza di propagazione¹⁵, fluttuazioni stocastiche della larghezza di banda e severi effetti di

¹⁴Nel contesto dei NIDS basati su flussi di rete, lo spazio $\mathcal{X}$ codifica attributi statistici del traffico, quali la dimensione media dei pacchetti, la durata dei flussi e i tempi di interarrivo.

¹⁵Nei collegamenti satellitari geostazionari (GEO), il solo ritardo di propagazione *one-way* si attesta tipicamente sui 250-280 ms, alterando radicalmente le dinamiche temporali del protocollo TCP rispetto alle reti terrestri.

attenuazione atmosferica. Tali dinamiche fisiche modificano pesantemente la distribuzione dei tempi di interarrivo dei pacchetti e l'architettura dei flussi trasmessi, determinando una distorsione diretta nella rappresentazione vettoriale delle *feature* estratte dal sensore NIDS [17, 2]. Geometricamente, tale scostamento trasla i vettori di test rispetto agli iperpiani di separazione appresi durante la fase di *training* terrestre, provocando un grave collasso della capacità discriminativa del classificatore e un incremento incontrollato dei falsi allarmi [8].

In letteratura, il problema dell'adattamento di dominio (*domain adaptation*) viene affrontato prevalentemente ricercando uno spazio latente invariante o minimizzando metriche di distanza statistica (es. *Maximum Mean Discrepancy*) tra le distribuzioni. In questo ambito, il contributo di Wilson e Cook [38] fornisce un'esaustiva analisi teorica dei metodi di *unsupervised domain adaptation*, finalizzati a riallineare le distribuzioni marginali senza ricorrere a etichette nel dominio *target*. Tuttavia, sebbene efficaci nell'abbattere il *bias* in scenari standard, questi metodi sono calibrati su ambienti di rete intrinsecamente omogenei. Di conseguenza, il nostro approccio si differenzia posizionandosi in un'area ancora poco esplorata: la gestione della profonda asimmetria strutturale e della drastica corruzione dei profili di traffico indotte dal trasferimento diretto della sorveglianza dal canale terrestre a quello orbitale.

2.3.2 Adattamento di dominio supervisionato per la mitigazione dello sbilanciamento

Sul piano metodologico, la risoluzione del *domain shift* deve misurarsi con il severo sbilanciamento informativo tra gli ambienti di origine e destinazione. Nelle applicazioni reali di Network Intrusion Detection (NIDS), infatti, la cronica scarsità di campioni etichettati appartenenti al dominio *target* costituisce l'ostacolo primario all'addestramento di modelli di classificazione nativi. Tale vincolo configura scenari di apprendimento semi-supervisionato o a pochi campioni (*few-shot learning*), nei quali la disponibilità di osservazioni etichettate nel contesto di destinazione è estremamente ridotta o del tutto assente. Come formalizzato nel paradigma del *transfer learning* [24], in presenza di un set limitato di dati nel dominio *target*, è possibile trasferire la conoscenza strutturata appresa dal dominio di origine per preservare le proprietà di generalizzazione del classificatore.

Nelle comunicazioni satellitari, tale criticità risulta ulteriormente esacerbata dalla marcata

assenza di tracce di traffico etichettate relative al segmento spaziale. Tale carenza è imputabile a stringenti vincoli di riservatezza industriale e militare, agli elevati costi operativi di monitoraggio in orbita e alla natura intrinsecamente critica delle infrastrutture spaziali, fattori che rendono arduo il reperimento di dataset operativi rappresentativi [17, 2]. Sebbene parte della letteratura proponga l'impiego di modelli puramente non supervisionati per prescindere dalle etichette, tali approcci — basati sulla sola stima della densità di probabilità — mostrano un'intrinseca fragilità nei contesti ad alto rumore stocastico¹⁶. Essi tendono infatti a scambiare le fisiologiche fluttuazioni dinamiche del canale radio per attività malevole [19, 15].

Per preservare la capacità di definire confini di decisione netti tipica dei classificatori supervisionati, una strategia rigorosa consiste nell'adottare paradigmi di *supervised domain adaptation* basati sull'ottimizzazione congiunta del rischio empirico (*joint empirical risk minimization*) [6, 22].

In termini formali, sia $\mathcal{D}_S = \{(x_i^S, y_i^S)\}_{i=1}^{N_S}$ il dataset etichettato di origine terrestre e $\mathcal{D}_T^{sub} = \{(x_j^T, y_j^T)\}_{j=1}^{N_T}$ un sottoinsieme estremamente ridotto di campioni etichettati del segmento satellitare ($N_T \ll N_S$), con $y_i^S, y_j^T \in \mathcal{Y}$. L'addestramento del modello $f(\cdot; \theta)$ viene condotto minimizzando una funzione di perdita (*loss function*) congiunta $\mathcal{L}(\theta)$:

$$\mathcal{L}(\theta) = \frac{1}{N_S} \sum_{i=1}^{N_S} \ell(f(x_i^S; \theta), y_i^S) + \alpha \frac{1}{N_T} \sum_{j=1}^{N_T} \ell(f(x_j^T; \theta), y_j^T) \quad (2.1)$$

dove $\ell(\cdot)$ rappresenta la funzione di perdita istantanea (es. *cross-entropy*) e $\alpha > 0$ è un iperparametro di ponderazione della perdita¹⁷.

L'ottimizzazione dell'Equazione (2.1) permette di riallineare i confini di separazione e di inglobare la variabilità stocastica del canale di destinazione senza perdere la ricchezza informativa sugli attacchi complessi appresa dal dominio terrestre [22]. Tale approccio compensa l'impatto del disallineamento distributivo, garantendo un'elevata capacità di generalizzazione del classificatore sia nella discriminazione binaria sia nella caratterizzazione multiclasse delle minacce.

¹⁶Nelle tratte satellitari, le variazioni di canale (es. attenuazione da pioggia, effetto Doppler e ritardi stocastici) alterano la distribuzione statistica delle *feature* di rete, inducendo elevati tassi di falsi allarmi nei modelli basati su anomalie puramente non supervisionati.

¹⁷L'iperparametro α compensa la sproporzione quantitativa tra N_S e N_T , evitando che il gradiente calcolato sui dati terrestri sovrasti il segnale di adattamento proveniente dal dominio satellitare.

2.4 Sintesi e Posizionamento del Lavoro

L'analisi approfondita della letteratura scientifica condotta nel presente capitolo evidenzia come la convergenza tra le infrastrutture di comunicazione terrestri e i segmenti trasmissivi orbitali abbia ridisegnato il perimetro di sicurezza delle reti moderne. Se da un lato l'integrazione di sistemi di monitoraggio attivo basati su Machine Learning (NIDS) rappresenta la soluzione principale per contrastare vettori d'attacco dinamici e minacce *zero-day* [15, 12], dall'altro l'esame dello stato dell'arte mette in luce una marcata frammentazione metodologica, strutturata su due paradigmi tra loro disallineati:

1. **I NIDS per reti terrestri**, pur garantendo elevatissimi indici prestazionali su dataset di riferimento ad alta dimensionalità come NSL-KDD [34] e CIC-IDS2017 [30], vengono valutati quasi esclusivamente in condizioni stazionarie e intra-dominio. Tale impostazione ignora sistematicamente l'effetto che le variazioni della distribuzione dei dati (*domain shift*) producono sulla stabilità dei confini di decisione del classificatore.
2. **I NIDS per ambienti satellitari e SAGIN**, orientati ad affrontare la natura intrinsecamente dinamica del canale radio spaziale, ricorrono prevalentemente ad architetture complesse basate su *Federated Learning* [36] o all'orchestrazione con *Deep Reinforcement Learning* e Graph Neural Networks [1]. Pur offrendo soluzioni di protezione cooperativa e gestione delle risorse, tali approcci impongono continui cicli di aggregazione, riaddestramento e sincronizzazione dei parametri, generando un *overhead* comunicativo e computazionale¹⁸ difficilmente sostenibile su nodi orbitali con severe limitazioni di risorsa.

Tale scenario rivela un chiaro *Research Gap*: la letteratura scientifica manca di un'indagine sistematica e quantitativa sia sulla **trasferibilità diretta (*zero-shot cross-domain*)** dei modelli di Machine Learning addestrati su flussi terrestri verso il canale satellitare, sia sulle strategie trasversali di ***Supervised Domain Adaptation*** concepite per operare in contesti di estrema scarsità di campioni etichettati [17, 2]. L'assenza di dataset pubblici etichettati contenenti intrusioni reali registrate su

¹⁸Sui collegamenti satellitari, caratterizzati da elevati tempi di *Round Trip Time* (RTT) e da ampiezze di banda asimmetriche, lo scambio continuo di gradienti o pesi sinaptici tipico dei protocolli federati può saturare la capacità della tratta, incrementando i tempi di vulnerabilità del sistema.

tratte orbitali ha storicamente ostacolato questo filone di ricerca, favorendo l'impiego di tecniche di *unsupervised domain adaptation* [38] che tuttavia presuppongono un disallineamento distributivo contenuto e risentono dell'elevato rumore stocastico del canale radio spaziale.

In questo contesto, il presente lavoro di tesi si propone di colmare le lacune metodologiche riscontrate in letteratura, fornendo un quadro di analisi per la valutazione della robustezza discriminativa e della portabilità dei sistemi NIDS nel passaggio da ambienti di rete terrestri a segmenti satellitari.

Nello specifico, l'opera intende offrire i seguenti contributi principali:

- **Analisi del Domain Shift Cross-Domain:** Caratterizzazione teorica e quantitativa delle deformazioni indotte dal canale trasmissivo spaziale sullo spazio delle *feature* statistiche e sulla capacità di generalizzazione dei modelli terrestri.
- **Strategie di Adattamento di Dominio:** Valutazione di tecniche di *domain adaptation* per la mitigazione dello scostamento distributivo in contesti caratterizzati da forte scarsità di dati etichettati.
- **Studio sulla Granularità di Classificazione:** Indagine comparativa sull'impatto che differenti livelli di dettaglio nella risposta del classificatore (binaria e multiclasse) esercitano sulla stabilità delle prestazioni e sulla gestione dei falsi allarmi.
- **Valutazione di Architetture Difensive Efficienti:** Analisi di soluzioni di monitoraggio adeguate ai vincoli operativi delle infrastrutture satellitari, in grado di garantire stabilità discriminativa senza introdurre elevati costi computazionali o comunicativi.

Definito il quadro della letteratura e identificati i principali gap metodologici, il capitolo successivo introdurrà la formalizzazione teorica e la cornice metodologica generale adottata in questo lavoro.

3. Formulazione Teorica e Framework Metodologico

Il presente capitolo definisce l'impalcatura teorica e il framework metodologico alla base dell'intera indagine sperimentale, fornendo gli strumenti formali necessari per la modellazione, l'analisi e l'adattamento dei sistemi di *Network Intrusion Detection* (NIDS) in contesti operativi eterogenei. L'obiettivo primario risiede nell'instaurazione di un paradigma valutativo rigoroso, strutturalmente svincolato dalle specificità implementative dei singoli dataset, che consenta di quantificare oggettivamente i fenomeni di traslazione di dominio (*domain shift*) e di validare le performance di generalizzazione isolando i reali contributi algoritmici dalla varianza stocastica.

La trattazione si articola secondo una progressione logica suddivisa in quattro sezioni principali:

- La **Sezione 3.1** formalizza il modello astratto del sistema, definendo rigorosamente gli spazi vettoriali di rappresentazione, gli operatori di proiezione per l'armonizzazione delle *feature* e le regole architetturali di partizionamento dei domini.
- La **Sezione 3.2** delinea la tassonomia delle architetture di classificazione adottate e le relative strategie di *transfer learning*, uniformando le metriche di confronto mediante una formulazione omogenea basata sulla stima della probabilità a posteriori.
- La **Sezione 3.3** stabilisce il protocollo valutativo per la stabilità statistica, affrontando la gestione dell'incertezza stocastica tramite valutazione *multi-seed* e definendo gli indici morfologici di granularità dello spazio decisionale.
- Infine, la **Sezione 3.4** completa l'architettura metodologica descrivendo l'apparato diagnostico e di *explainability*, integrando strumenti di stima di densità e metriche di rilevanza fondate sulla teoria dei giochi cooperativi per la caratterizzazione e l'interpretazione causale delle divergenze distributive.

3.1 Modello del Sistema e Spazi di Rappresentazione

La presente sezione formalizza l'impalcatura teorica e matematica del framework analitico, definendo in modo rigoroso gli spazi vettoriali di rappresentazione e le distribuzioni di probabilità

necessarie per modellare i fenomeni di transizione cross-dominio nei sistemi NIDS. L'obiettivo è stabilire un modello astratto, indipendente dalle peculiarità di implementazione dei singoli dataset, in grado di garantire il rigore metodologico, la comparabilità delle metriche e l'assenza di contaminazione informativa.

Questa formalizzazione prosegue direttamente la disamina svolta nel Capitolo 2, traducendo in termini matematici e procedurali le criticità del confronto tra segmenti terrestri e spaziali e le esigenze di adattamento dei NIDS delineate nel contesto di riferimento.

A tal fine, la trattazione introduce preliminarmente la formalizzazione dei domini di origine e destinazione, delineando la semantica a doppia etichettatura (Y, A) , le regole di partizionamento preventivo anti-*data leakage* e il vincolo di proporzionamento parametrico ρ alla base delle cinque categorie astratte di benchmark, native e ibride, istanziabili dal framework. Successivamente, viene definito l'operatore di proiezione ψ_k , specifico per ciascun dominio $k \in \{S, T\}$, che mappa le caratteristiche grezze eterogenee nello spazio delle *feature* condiviso $\mathcal{X}$, esplicitando i criteri concettuali di filtraggio e armonizzazione degli attributi. La trattazione si conclude motivando, sulla base della proprietà di invarianza rispetto a trasformazioni monotoniche propria dei classificatori a partizionamento ricorsivo, l'omissione della fase esplicita di scalatura dalla definizione dello spazio delle *feature*.

Per facilitare la lettura della trattazione successiva, i principali simboli e costrutti matematici adottati sono sintetizzati nella Tabella 3.1.

Tabella 3.1: Sintesi della notazione matematica e dei simboli del framework.

Simbolo	Descrizione e Significato Concettuale
$\mathcal{D} = (\mathcal{X}, P(\mathbf{x}))$	Dominio di traffico (spazio delle <i>feature</i> e distribuzione marginale)
$\mathcal{X} \subseteq \mathbb{R}^d$	Spazio delle caratteristiche d -dimensionale omogeneizzato
$\mathbf{x} = (x_1, \dots, x_d)^\top$	Vettore delle <i>feature</i> del singolo flusso di rete
$\mathcal{Y} = \{0, 1\}$	Spazio discreto delle etichette primarie (0: Normal, 1: Malevolo)
$A \in \mathcal{A}$	Variabile descrittiva per la specifica famiglia di attacco (definita per $Y = 1$)
$\mathcal{A}_S, \mathcal{A}_T$	Insiemi delle tipologie di minaccia presenti nei domini sorgente e target
$\mathcal{D}_S, \mathcal{D}_T$	Dominio Terrestre Sorgente e Domini Target di Destinazione
$\mathcal{D}_k^{(train)}, \mathcal{D}_k^{(test)}$	Partizioni disgiunte di addestramento e test per il generico dominio k
$\psi_k(\cdot)$	Operatore di proiezione e combinazione dalle <i>feature</i> grezze allo spazio $\mathcal{X}$, specifico per il dominio $k \in \{S, T\}$
$N(\cdot)$	Operatore di cardinalità (numero di campioni estratti)

3.1.1 Formalizzazione dei Domini e Composizione Asimmetrica del Traffico

Il framework analitico richiede la definizione rigorosa degli spazi di rappresentazione vettoriale e delle distribuzioni di probabilità associate ai diversi contesti di rete considerati. Si definisce un dominio $\mathcal{D}$ come la coppia $(\mathcal{X}, P(\mathbf{x}))$, dove $\mathcal{X} \subseteq \mathbb{R}^d$ rappresenta lo spazio delle *feature* d -dimensionale condiviso e $P(\mathbf{x})$ la distribuzione di probabilità marginale definita sul vettore delle caratteristiche $\mathbf{x} = (x_1, x_2, \dots, x_d)^\top \in \mathcal{X}$.

Associato a ciascun dominio, la semantica del traffico è modellata tramite una doppia etichettatura. Lo spazio discreto primario $\mathcal{Y} = \{0, 1\}$ stabilisce la natura del flusso, dove $Y = 0$ indica il traffico nominale (*Normal*) e $Y = 1$ identifica genericamente un vettore malevolo. In aggiunta, si definisce un'ulteriore variabile descrittiva $A \in \mathcal{A}$ che specifica il nome della classe, garantendo una caratterizzazione puntuale sia per la componente benevola ($Y = 0$), per la quale A assume tipicamente un unico valore costante (*Normal*), sia per le diverse famiglie di attacco ($Y = 1$), per le quali A è genuinamente multi-valore.

Caratterizzazione Astratta dei Domini e Tassonomia delle Classi

Il framework analitico modella il fenomeno di transizione cross-dominio a partire da due macro-distribuzioni di partenza distinte:

1. **Dominio di Riferimento ($\mathcal{D}_S$):** rappresenta l'ambiente stazionario di origine, contenente sia istanze di traffico nominale ($Y = 0, A \in \mathcal{A}_S$) sia flussi malevoli ($Y = 1, A \in \mathcal{A}_S$). Per eliminare le componenti ad elevata sparsità ed esigua rappresentatività statistica, si applica una procedura di rimozione delle classi minoritarie (*minority removal*) sull'insieme $\mathcal{A}_S$, garantendo una caratterizzazione stabile del baseline di superficie.
2. **Domini di Destinazione ($\mathcal{D}_T$):** rappresentano i contesti soggetti a variazioni trasmissive o canali eterogenei, composti esclusivamente da vettori di traffico malevolo ($Y = 1, A \in \mathcal{A}_T$). Tali domini vengono strutturati applicando, laddove necessario, un raggruppamento delle classi minoritarie (*minority merge*) per accorpare famiglie d'attacco semanticamente affini e preservare la significatività campionaria.

Isolamento Preventivo delle Partizioni e Politiche Anti-Data Leakage

Per garantire il rigore metodologico ed evitare fenomeni di contaminazione informativa tra la fase di addestramento e quella di valutazione (*data leakage*)¹, la partizione di ciascun dominio primario $\mathcal{D}_k$ nei sotto-insiemi di addestramento ($\mathcal{D}_k^{(train)}$) e di verifica ($\mathcal{D}_k^{(test)}$) viene definita a monte di qualsiasi aggregazione o composizione dei benchmark derivati². In tutte le configurazioni sperimentali viene adottata una suddivisione stocastica stratificata con proporzione fissa:

$$\mathcal{D}_k = \mathcal{D}_k^{(train)} \cup \mathcal{D}_k^{(test)}, \quad \text{con } \mathcal{D}_k^{(train)} \cap \mathcal{D}_k^{(test)} = \emptyset \quad (3.1)$$

garantendo la totale indipendenza strutturale dei vettori impiegati per l'inferenza.

¹L'esecuzione dello split a monte di qualsiasi fusione previene che campioni identici della classe nominale, riutilizzati per benchmark diversi, compaiano simultaneamente negli insiemi di addestramento e di test.

²Dal punto di vista metodologico, tale partizionamento e la successiva ricomposizione dei vettori vengono eseguiti prima di qualsiasi composizione dei benchmark, evitando la creazione di dataset intermedi.

Sintesi dei Benchmark e Vincoli di Proporzionamento Riconfigurato

Sia per le configurazioni generate internamente al dominio sorgente sia per i benchmark ibridi ricomposti cross-dominio (necessari per l'assenza di traffico nominale etichettato nei contesti di destinazione), il framework applica una politica di proporzionamento controllato.

Per rispecchiare le condizioni realistiche di rete e prevenire uno sbilanciamento artificiale dei classificatori³, il framework impone un vincolo di proporzionamento parametrico ρ tra la componente benevola e la componente malevola complessiva:

$$\frac{N(Y = 0)}{\sum_{a \in \mathcal{A}_m} N(Y = 1, A = a)} = \rho \quad (3.2)$$

Tale vincolo definisce in modo esplicito l'asimmetria volumetrica tra il traffico nominale ($Y = 0$) e il traffico malevolo ($Y = 1$). Dove $N(\cdot)$ indica la cardinalità dei campioni estratti, $\mathcal{A}_m$ rappresenta l'insieme delle specifiche famiglie di attacco incluse nella configurazione e $\rho \in \mathbb{R}^+$ costituisce il fattore di asimmetria volumetrica prescritto dal protocollo metodologico.

A livello di estrazione, come regola generale si adotta il campionamento senza reinserimento (*without replacement*), precludendo la duplicazione sintetica delle istanze. Qualora, a seguito dell'applicazione del rapporto ρ , una delle due classi $Y \in \{0, 1\}$ non disponga di una quantità di dati sufficiente a raggiungere il volume teorico prefissato, il framework rifiuta l'uso del *replacing*. In tale evenienza, il dimensionamento complessivo del benchmark si ridimensiona ancorandosi alla classe minoritaria (ovvero quella con minore disponibilità di campioni): l'estrazione per l'altra classe viene riproporzionata di conseguenza per soddisfare il rapporto ρ , accettando la potenziale perdita o il mancato utilizzo di una quota di campioni della classe maggioritaria pur di preservare l'unicità e l'integrità statistica delle osservazioni.

Nei benchmark di tipo aggregato (sia sorgenti che ibridi), la composizione interna del sottoinsieme malevolo non adotta l'equiprobabilità artificiale tra le classi d'attacco. Si preserva invece la distribuzione naturale *a priori* $P(A = a \mid Y = 1)$ caratteristica dei domini di origine, evitando alterazioni sintetiche e mantenendo la fedeltà alle frequenze di occorrenza reali delle minacce.

³Nei sistemi NIDS reali, il traffico lecito costituisce la stragrande maggioranza del volume di rete. La parametrizzazione del rapporto emula tale asimmetria mantenendo una densità di attacchi sufficiente a garantire la stabilità statistica delle metriche.

L'intero processo di isolamento procedurale e ricomposizione dei benchmark è schematizzato nella Figura 3.1.




Figura 3.1: Pipeline logica astratta: allineamento dello spazio delle feature $\mathcal{X}$, isolamento preventivo Train/Test anti-*data leakage*, sintesi parametrica con ratio ρ senza reinserimento (con ancoraggio alla classe minoritaria) e istanziazione logica dei benchmark. I blocchi tratteggiati indicano le elaborazioni logiche, mentre i blocchi a linea continua rappresentano gli insiemi di dati e le categorie di output.

Tassonomia Astratta delle Configurazioni Sperimentali

L'applicazione sistematica delle regole metodologiche descritte porta alla generazione dinamica di cinque categorie funzionali di benchmark. Ognuna di queste configurazioni viene istanziata logicamente rispettando il preventivo isolamento logico delle partizioni di train e test e imponendo il vincolo di proporzionamento parametrico ρ tra traffico benevolo e malevolo:

1. **Set Nativo Sorgente Aggregato:** composto dalla baseline nominale $Y = 0$ di $\mathcal{D}_S$ unita alla totalità delle famiglie di attacco sorgenti $A \in \mathcal{A}_S$ (a valle della procedura di *minority removal*), preservando la distribuzione naturale a priori $P(A = a \mid Y = 1)$ caratteristica del dominio di origine.
2. **Set Nativi Sorgente Biclasse:** formati dall'unione della classe nominale $Y = 0$ con una singola famiglia di attacco $A = a \in \mathcal{A}_S$ isolata all'interno del dominio sorgente.
3. **Set Ibridi Aggregati:** composti dalla classe nominale $Y = 0$ del dominio sorgente unita alla totalità delle minacce dei domini di destinazione $A \in \mathcal{A}_T$ (strutturate tramite *minority merge*), preservando le frequenze *a priori* originali del dominio target.
4. **Set Ibridi Biclasse:** formati dalla combinazione della classe nominale $Y = 0$ sorgente con le singole famiglie d'attacco $A = a \in \mathcal{A}_T$ isolate all'interno dei domini target.
5. **Set di Iniezione di Riferimento:** progettato in conformità agli standard di letteratura [2], mantiene l'intera distribuzione nativa del dominio sorgente (sia il traffico nominale che l'aggregato malevolo di $\mathcal{D}_S$) integrandola con un'iniezione sparsa e controllata di vettori d'attacco provenienti dai domini target $\mathcal{D}_T$.

I dettagli analitici di composizione per ciascuna delle cinque categorie, opportunamente suddivisi per natura del traffico, sono riassunti nella Tabella 3.2.

Tabella 3.2: Tassonomia astratta delle cinque categorie di benchmark sperimentali istanziate dinamicamente.

Categoria Benchmark	Componente Benevola ($Y = 0$)	Componente Malevola ($Y = 1$)
Set Nativo Sorgente Aggregato	Baseline nativa $P_S(\mathbf{x} \mid Y = 0, A \in \mathcal{A}_S)$	Tutte le minacce sorgente $P_S(\mathbf{x} \mid Y = 1, A \in \mathcal{A}_S)$ con distribuzioni <i>a priori</i> naturali.
Set Nativo Sorgente Biclasse	Baseline nativa $P_S(\mathbf{x} \mid Y = 0, A \in \mathcal{A}_S)$	Singola minaccia sorgente $P_S(\mathbf{x} \mid Y = 1, A = a)$ isolata ($a \in \mathcal{A}_S$).
Set Ibrido Aggregato	Baseline nativa $P_S(\mathbf{x} \mid Y = 0, A \in \mathcal{A}_S)$	Tutte le minacce target $P_T(\mathbf{x} \mid Y = 1, A \in \mathcal{A}_T)$ con distribuzioni <i>a priori</i> naturali.
Set Ibrido Biclasse	Baseline nativa $P_S(\mathbf{x} \mid Y = 0, A \in \mathcal{A}_S)$	Singola minaccia target $P_T(\mathbf{x} \mid Y = 1, A = a)$ isolata ($a \in \mathcal{A}_T$).
Set di Iniezione di Riferimento	Baseline nativa $P_S(\mathbf{x} \mid Y = 0, A \in \mathcal{A}_S)$	Minacce sorgente in aggregato $P_S(\mathbf{x} \mid Y = 1, A \in \mathcal{A}_S)$ + iniezione altamente sparsa da $\mathcal{D}_T$ ($A \in \mathcal{A}_T$).

3.1.2 Allineamento dello Spazio delle Feature e Preprocessing Astratto

La disomogeneità strutturale tra le sonde di rilevamento e i formati di tracciamento adottati nei diversi ambienti di rete comporta un’asimmetria nativa negli spazi delle caratteristiche grezze. Per consentire la comparabilità cross-dominio, il framework definisce una procedura astratta di riallineamento spaziale e un impianto di trasformazione che mappa osservazioni eterogenee in uno spazio vettoriale comune, preservando la semantica trasmissiva e ottimizzando l’efficienza

concettuale. L'intero flusso di mappatura è sintetizzato in Figura 3.2.

Mappatura e Omogeneizzazione dello Spazio Vettoriale

Siano $\mathcal{X}_S^{(grezzo)} \subseteq \mathbb{R}^{d_S}$ e $\mathcal{X}_T^{(grezzo)} \subseteq \mathbb{R}^{d_T}$ gli spazi delle caratteristiche grezze associati rispettivamente al dominio sorgente e ai domini di destinazione. Per superare le differenze nomenclaturali, metriche e strutturali tra le d_S e d_T variabili native, si definisce, per ciascun dominio $k \in \{S, T\}$, un operatore di trasformazione e combinazione funzionale $\psi_k : \mathbb{R}^{d_k} \rightarrow \mathbb{R}^d$ tale per cui⁴:

$$\mathbf{x}_k = \psi_k(\mathbf{x}_k^{(grezzo)}) = \left(\psi_{k,1}(\mathbf{x}_k^{(grezzo)}), \psi_{k,2}(\mathbf{x}_k^{(grezzo)}), \dots, \psi_{k,d}(\mathbf{x}_k^{(grezzo)}) \right)^\top \in \mathcal{X} \subseteq \mathbb{R}^d \quad (3.3)$$

Ciascuna componente $\psi_{k,j}$ ($j = 1, \dots, d$) rappresenta una combinazione algebrica o un'estrazione semantica costruita a partire dalle variabili primarie disponibili nel dominio k . Sebbene ψ_S e ψ_T siano definite separatamente per adattarsi alle rispettive variabili native grezze, entrambe sono vincolate a produrre uno spazio d'arrivo $\mathcal{X}$ condiviso e semanticamente equivalente, secondo i criteri di armonizzazione descritti di seguito. La formulazione consente di derivare un set di *feature* condiviso e omogeneo $\mathcal{X}$, indipendentemente dalle difformità applicative dei formati di origine.

Invarianza Concettuale e Filtraggio degli Attributi

La definizione dello spazio proiettato $\mathcal{X}$ risponde a rigorosi vincoli di filtraggio e armonizzazione basati su tre criteri fondamentali:

1. **Rimozione degli identificatori univoci e locali:** gli attributi legati all'identità specifica delle sessioni (es. indirizzi IP, marcatori temporali assoluti o porte di rete puntuali) vengono esclusi a priori per prevenire fenomeni di memorizzazione o correlazioni spurie (*shortcut learning*)⁵, garantendo che i modelli apprendano esclusivamente pattern trasmissivi e comportamentali generalizzabili.
2. **Vincoli di calcolabilità e misurabilità cross-dominio:** le variabili per le quali non sussiste la possibilità fisica o analitica di calcolo equivalente in entrambe le distribuzioni P_S e P_T

⁴La dimensione ridotta d costituisce una costante uniforme per l'intero framework.

⁵Nei contesti NIDS, lo *shortcut learning* si verifica quando il classificatore apprende associazioni mnemoniche tra identificatori locali rigidi (es. un IP specifico) e la classe malevola, perdendo qualsiasi capacità di generalizzare su topologie di rete non viste.

vengono omesse dal set condiviso. Ciò garantisce che ogni dimensione $x^{(j)} \in \mathcal{X}$ possieda un significato concettuale identico e direttamente confrontabile tra i domini.

3. **Armonizzazione delle unità di misura ed equivalenza dimensionale:** qualora una medesima metrica sia presente o ricavabile in entrambi i domini ma espressa mediante scala o unità di misura differenti, l'operatore ψ_k applica le necessarie trasformazioni dimensionali per ricondurla a una grandezza standard condivisa. L'uniformazione preventiva delle unità di misura garantisce che discrepanze puramente nominali nelle scale originarie non vengano erroneamente interpretate dai modelli come fenomeno di *domain shift*.




Figura 3.2: Flusso di mappatura e omogeneizzazione dello spazio delle *feature*: gli operatori ψ_S e ψ_T , definiti separatamente per ciascun dominio grezzo, convergono verso lo stesso spazio condiviso $\mathcal{X}$ attraverso i tre criteri comuni di filtraggio e armonizzazione descritti nel testo.

Invarianza Monotonica e Omissione della Scalatura Esplicita

La gestione della scala delle variabili è centrale. Sebbene le tecniche di riscaldamento lineare o di standardizzazione (Z-score, Min-Max scaling) siano ampiamente adottate in letteratura per

uniformare i domini di variabilità, il framework teorico sfrutta una nota proprietà algebrica delle famiglie di classificatori impiegate in questa tesi [4, 11].

Per la classe dei modelli basati sul partizionamento ricorsivo dello spazio dei dati⁶, la funzione di suddivisione $s(\mathbf{x})$ lungo ciascuna dimensione j poggia sull'ordinamento relativo dei valori rispetto a una soglia $\theta \in \mathbb{R}$:

$$s(\mathbf{x}) = \mathbb{I}(x^{(j)} \leq \theta) \quad (3.4)$$

Poiché l'indicatore di partizione $\mathbb{I}(\cdot)$ è rigorosamente invariante rispetto a qualsiasi trasformazione monotonica strettamente crescente $h : \mathbb{R} \rightarrow \mathbb{R}$, si verifica che:

$$\mathbb{I}(x^{(j)} \leq \theta) \iff \mathbb{I}(h(x^{(j)}) \leq h(\theta)) \quad (3.5)$$

Di conseguenza, la topologia dell'albero di decisione e la costruzione dei confini di separazione risultano algebricamente identiche sia operando sulle componenti nello spazio nativo $\mathbf{x}$, sia applicando una trasformazione di scala $h(\mathbf{x})$. Omettendo la fase di normalizzazione esplicita, il framework preserva la geometria naturale dei dati senza alterare la capacità discriminativa dei modelli, riducendo l'overhead computazionale nello stadio di parsificazione iniziale.

È opportuno precisare che tale omissione riguarda esclusivamente lo stadio di addestramento e inferenza dei classificatori. Qualora strumenti diagnostici non invarianti alla scala (es. *Principal Component Analysis* o stime di densità kernel, *KDE*) vengano impiegati a valle per l'ispezione visiva del *covariate shift* o per finalità di spiegabilità, essi richiedono una normalizzazione dedicata, applicata unicamente a scopo diagnostico-visivo e non reintrodotta nello stadio di classificazione.

3.2 Tassonomia delle Architetture di Classificazione e Valutazione Multi-Modello

La presente sezione formalizza la tassonomia delle architetture di classificazione impiegate all'interno del framework metodologico, delineando i criteri per la valutazione multi-modello e l'analisi

⁶Tale famiglia include architetture ad albero di decisione singolo e relative estensioni ad *ensemble*. La presente derivazione, e la conseguente omissione della scalatura esplicita, è valida esclusivamente per questa famiglia di modelli; qualora il framework venisse esteso a classificatori sensibili alla scala delle variabili (es. reti neurali, SVM a kernel, k -NN, regressione logistica regolarizzata), la normalizzazione andrebbe reintrodotta esplicitamente nello stadio di elaborazione iniziale.

prestazionale incrociata. L'intera architettura condivide una formulazione matematica unificata fondata sulla stima della probabilità a posteriori: subordinando l'assegnazione finale della classe a una soglia decisionale parametrica τ , viene garantita una base di confronto rigorosa, omogenea e strutturalmente indipendente dallo specifico algoritmo di apprendimento sottostante.

La trattazione procede definendo lo spazio dei modelli aggregati e le relative strategie di *transfer learning*, per poi introdurre la decomposizione in classificatori specialistici biclasse per l'isolamento analitico delle singole minacce e il relativo protocollo di valutazione incrociata (*cross-evaluation*). La sezione si conclude con la caratterizzazione formale delle famiglie di decisione alberiformi e dei paradigmi di *ensembling* (Bagging e Gradient Boosting), evidenziandone le proprietà algebriche di invarianza e robustezza rispetto alle distorsioni di canale.

Per agevolare la consultazione, i formalismi architetturali e i parametri funzionali introdotti in questa sezione sono riepilogati nella Tabella 3.3.

Tabella 3.3: Sintesi della notazione relativa alle architetture e ai parametri di classificazione.

Simbolo	Descrizione e Significato Concettuale
$f_{\theta}(\mathbf{x}) \approx P(Y = 1 \mid \mathbf{x})$	Funzione decisionale parametrica: stima della probabilità a posteriori che il campione appartenga alla classe malevola
$\hat{Y} \in \{0, 1\}$	Decisione binaria finale predetta dal classificatore
$\tau \in (0, 1)$	Soglia decisionale parametrica, tarabile lungo la curva ROC per il bilanciamento dei falsi positivi
$\mathcal{M}_{\text{base}}$	Modello baseline, addestrato sul <i>Set di Iniezione</i> $\mathcal{D}_{\text{inj}}^{(\text{train})}$ includendo conoscenza target sparsa
$\mathcal{M}_S$	Modello aggregato nativo sorgente, addestrato esclusivamente sulle distribuzioni stazionarie originarie $\mathcal{D}_S^{(\text{train})}$
$\mathcal{M}_H^{(T)}$	Modello aggregato ibrido (<i>Oracle</i>), addestrato unendo la componente lecita sorgente con la totalità degli attacchi target
$\mathcal{M}_{S,a}, \mathcal{M}_{H,T,a}$	Modelli biclasse (sorgente e ibridi), focalizzati analiticamente sulla rilevabilità della singola famiglia d'attacco $a \in \mathcal{A}$
$\mathcal{L}$	Funzione di perdita <i>Binary Cross-Entropy</i> (BCE) per l'ottimizzazione della stima parametrica
$I(R_m)$	Criterio di impurità (es. indice di Gini o entropia) per la scissione ottima dei nodi nello spazio delle caratteristiche

3.2.1 Modello di Riferimento (Baseline) e Modelli Aggregati

In questa sezione si formalizza lo spazio dei classificatori supervisionati operanti all'interno del framework analitico. Indipendentemente dalle specifiche architetture algoritmiche impiegate per la stima dei parametri, il problema di rilevamento delle intrusioni viene modellato in chiave rigorosamente binaria. Sebbene i sottoinsiemi malevoli racchiudano al loro interno un insieme eterogeneo di famiglie d'attacco $A \in \mathcal{A}$, la funzione di decisione appresa mappa lo spazio delle *feature* $\mathcal{X} \subseteq \mathbb{R}^d$ direttamente sulla natura del flusso $\mathcal{Y} = \{0, 1\}$, isolando le componenti lecite ($Y = 0$) da qualsiasi manifestazione anomala o minaccia ($Y = 1$).

Formulazione Matematica Astratta dell'Apprendimento Supervisionato

Sia $\mathcal{D}^{(\text{train})}$ una generica partizione di addestramento generata dalle procedure di sintesi descritte nella Sezione 3.1.1, definita come:

$$\mathcal{D}^{(\text{train})} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N, \quad \mathbf{x}_i \in \mathcal{X}, y_i \in \{0, 1\} \quad (3.6)$$

Un classificatore parametrico o non parametrico viene rappresentato astrattamente da una funzione $f_\theta : \mathcal{X} \rightarrow [0, 1]$, dove $f_\theta(\mathbf{x})$ stima la probabilità a posteriori $P(Y = 1 \mid \mathbf{x})$ dato il vettore delle caratteristiche $\mathbf{x}$.

Seguendo il principio di Minimizzazione del Rischio Empirico (ERM) proposto da Vapnik [35], l'addestramento si configura come la ricerca della configurazione parametrica θ^* che minimizza la perdita media valutata sul dataset di addestramento. Adottando la funzione di perdita canonica di *Binary Cross-Entropy* (BCE), definita per il singolo campione come:

$$\mathcal{L}(f_\theta(\mathbf{x}_i), y_i) = -[y_i \log f_\theta(\mathbf{x}_i) + (1 - y_i) \log (1 - f_\theta(\mathbf{x}_i))] \quad (3.7)$$

il problema di ottimizzazione assume la seguente formulazione analitica:

$$\theta^* = \arg \min_{\theta} \mathcal{R}_{\text{emp}}(\theta; \mathcal{D}^{(\text{train})}) = \arg \min_{\theta} \frac{1}{|\mathcal{D}^{(\text{train})}|} \sum_{(\mathbf{x}_i, y_i) \in \mathcal{D}^{(\text{train})}} \mathcal{L}(f_\theta(\mathbf{x}_i), y_i) \quad (3.8)$$

Per la classe di modelli basati su alberi di decisione adottata nel framework, tale formalizzazione esprime la minimizzazione diretta dell'errore nel caso di ensemble additivi basati su boosting (es. *Gradient Boosted Decision Trees*), in cui l'ottimizzazione avviene tramite discesa funzionale del gradiente sulla loss BCE. Nel caso di foreste casuali (es. *Random Forest*), l'addestramento locale minimizza i criteri di impurità nei nodi e $f_\theta(\mathbf{x})$ rappresenta la frequenza relativa dei campioni malevoli nelle foglie, rendendo la BCE il criterio di misura globale dell'errore di calibrazione probabilistica.

La decisione binaria finale $\hat{Y} \in \{0, 1\}$ per un generico vettore di test viene determinata applicando la funzione indicatrice $\mathbb{I}(\cdot)$ rispetto a una soglia canonica di decisione τ^7 :

$$\hat{Y} = \mathbb{I}(f_{\theta^*}(\mathbf{x}) \geq \tau) \quad (3.9)$$

⁷Sebbene $\tau = 0.5$ sia neutro sotto costi simmetrici, nei contesti NIDS reali la soglia viene adattata lungo la curva ROC in funzione del trade-off tra sensibilità e falsi positivi. L'Area Under the ROC Curve (AUC) quantifica la capacità discriminativa complessiva indipendentemente dalla soglia.

Il Modello Baseline Proposto ($\mathcal{M}_{\text{base}}$)

Contrariamente agli approcci convenzionali della letteratura che adottano come baseline modelli addestrati su sole distribuzioni stazionarie native, il framework metodologico propone come unico modello baseline di riferimento ($\mathcal{M}_{\text{base}}$) un classificatore addestrato sulla partizione di train del *Set di Iniezione di Riferimento* ($\mathcal{D}_{\text{inj}}^{(\text{train})}$).

Questo modello definisce un'ancora di prestazione per contesti affetti da transizione trasmissiva (es. il passaggio da reti terrestri a canali satellitari). In tale ruolo, $\mathcal{M}_{\text{base}}$ fornisce un riferimento stabilizzante per la valutazione dei modelli e consente di confrontare le prestazioni lungo una traiettoria di cambiamento di canale reale. $\mathcal{M}_{\text{base}}$ è un sistema NIDS ad elevata capacità adattiva, in grado di generalizzare non solo su minacce non viste della medesima distribuzione, ma anche su distribuzioni eterogenee grazie alla conoscenza preventiva sparsa. Il vettore dei parametri ottimali θ_{base}^* viene ottenuto mediante:

$$\theta_{\text{base}}^* = \arg \min_{\theta} \mathcal{R}_{\text{emp}} \left(\theta; \mathcal{D}_{\text{inj}}^{(\text{train})} \right) \quad (3.10)$$

dove la composizione del dataset di addestramento incorpora la baseline unita all'iniezione target:

$$\mathcal{D}_{\text{inj}}^{(\text{train})} = \mathcal{D}_S^{(\text{train})} \cup \Delta \mathcal{D}_T^{(\text{train})} \quad (3.11)$$

con $\Delta \mathcal{D}_T^{(\text{train})}$ rappresentante il campionamento ridotto ed altamente sparso delle classi d'attacco ($Y = 1, A \in \mathcal{A}_T$)⁸.

In conformità al rigoroso protocollo di isolamento delle partizioni, il modello $\mathcal{M}_{\text{base}}$ viene inizialmente addestrato su $\mathcal{D}_{\text{inj}}^{(\text{train})}$ e validato sulla rispettiva partizione di test isolata $\mathcal{D}_{\text{inj}}^{(\text{test})}$, garantendo la riproducibilità e l'assenza di *data leakage*.

Classificatori Aggregati e Mappatura delle Distribuzioni

Per isolare in modo analitico l'impatto del *domain shift* e valutare le capacità di trasferimento della conoscenza, il framework affianca alla baseline proposta due categorie di modelli aggregati multi-classe (ma a decisione binaria):

⁸Matematicamente, la condizione di sparsità è definita dal vincolo cardinale $|\Delta \mathcal{D}_T^{(\text{train})}| \ll |\mathcal{D}_S^{(\text{train})}|$, emulando uno scenario di *few-shot learning* in cui la visibilità sul canale di destinazione è limitata a pochissimi campioni rappresentativi.

1. **Modello Aggregato Nativo Sorgente ($\mathcal{M}_S$):** addestrato esclusivamente sulla partizione di addestramento del dominio sorgente nativo ($\mathcal{D}_S^{(\text{train})}$). Rappresenta il sistema NIDS tradizionale addestrato su sole distribuzioni stazionarie:

$$\theta_S^* = \arg \min_{\theta} \mathcal{R}_{\text{emp}} \left(\theta; \mathcal{D}_S^{(\text{train})} \right) \quad (3.12)$$

La valutazione di $\mathcal{M}_S$ sui benchmark target consente di misurare la pura degradazione prestazionale causata dalle distorsioni di canale senza alcuna forma di adattamento.

2. **Modelli Aggregati Ibridi ($\mathcal{M}_H^{(T)}$):** per ciascun contesto di destinazione T , viene istanziata un'opportuna variante di modello ibrido $\mathcal{M}_H^{(T)}$ addestrata sulla relativa partizione di addestramento ricomposta ($\mathcal{D}_{H,T}^{(\text{train})}$):

$$\mathcal{D}_{H,T}^{(\text{train})} = \mathcal{D}_S^{(\text{train})} \Big|_{Y=0} \cup \mathcal{D}_T^{(\text{train})} \quad (3.13)$$

in cui la classe nominale $Y = 0$ di origine è unita alla totalità dei vettori d'attacco $Y = 1$ del contesto di destinazione ($\mathcal{D}_T^{(\text{train})}$). Il rispettivo vettore di parametri ottimali risponde alla formulazione:

$$\theta_{H,T}^* = \arg \min_{\theta} \mathcal{R}_{\text{emp}} \left(\theta; \mathcal{D}_{H,T}^{(\text{train})} \right) \quad (3.14)$$

Tali modelli formalizzano il limite teorico di rilevamento (*upper bound*) raggiungibile quando il classificatore acquisisce piena visibilità della componente malevola nel dominio target⁹.

⁹Nella letteratura del trasferimento di dominio, $\mathcal{M}_H^{(T)}$ risponde al paradigma dell'*Oracle supervised*: fornisce la massima accuratezza raggiungibile se si disponesse del dataset target integralmente etichettato.

Tabella 3.4: Sintesi comparativa dei modelli di riferimento e aggregati: composizione del training set e finalità concettuale.

Modello	Composizione del <i>Training Set</i>	Finalità Concettuale
$\mathcal{M}_{\text{base}}$	$\mathcal{D}_{\text{inj}}^{(\text{train})} = \mathcal{D}_S^{(\text{train})} \cup \Delta \mathcal{D}_T^{(\text{train})}$	Baseline proposta: ancora di prestazione con conoscenza preventiva sparsa (<i>few-shot</i>) sul canale target.
$\mathcal{M}_S$	$\mathcal{D}_S^{(\text{train})}$	NIDS tradizionale addestrato su sole distribuzioni stazionarie; misura la degradazione da <i>domain shift</i> senza adattamento.
$\mathcal{M}_H^{(T)}$	$\mathcal{D}_{H,T}^{(\text{train})} = \mathcal{D}_S^{(\text{train})} _{Y=0} \cup \mathcal{D}_T^{(\text{train})}$	Limite teorico (<i>upper bound</i> , paradigma <i>Oracle supervised</i>) con piena visibilità della componente malevola target.

Conservazione dei Modelli, Inferenza e Disaggregazione delle Prestazioni

Al completamento della fase di ottimizzazione parametrica e dopo la verifica della convergenza sui rispettivi set di test locali, tutti i modelli generati ($\mathcal{M}_{\text{base}}$, $\mathcal{M}_S$ e le istanze $\mathcal{M}_H^{(T)}$) vengono mantenuti fissi nella propria struttura.

Il protocollo di valutazione per tali classificatori, schematizzato in Figura 3.3 secondo la notazione standard a diagramma di flusso (*flowchart*)¹⁰, segue un doppio binario analitico:

1. **Valutazione di Generalizzazione Globale:** ciascun modello immutabile viene proiettato sulle partizioni di test eterogenee $\mathcal{D}^{(\text{test})}$, consentendo di quantificare la tolleranza al cambio di canale e la capacità di generalizzazione rispetto a minacce target mai osservate in addestramento;

¹⁰A differenza degli schemi architetturali e compositivi delle Figure 3.1 e 3.2, che rappresentano relazioni statiche tra insiemi di dati, la Figura 3.3 e la successiva Figura 3.4 descrivono un protocollo procedurale con un autentico punto di biforcazione (il confronto $f_{\theta^*}(\mathbf{x}) \geq \tau$). Per tale ragione si adotta qui la notazione a diagramma di flusso convenzionale (nodi ellittici per gli insiemi di dati, rombi per i punti di decisione, rettangoli per i processi), coerentemente con la prassi diffusa in letteratura per la rappresentazione di protocolli algoritmici a bivi condizionali.

2. **Disaggregazione delle Prestazioni per Classe:** i modelli aggregati vengono contestualmente valutati sulle singole sottopartizioni per famiglia d’attacco $\mathcal{D}_a^{(\text{test})} \subseteq \mathcal{D}^{(\text{test})}$, ristrette ai soli vettori con $A = a$ per una data classe di minaccia $a \in \mathcal{A}$. Tale analisi disaggregata evita l’effetto di mascheramento delle prestazioni (*class shadowing*), verificando se un’elevata accuratezza globale celi un decadimento selettivo su specifiche classi di minaccia.

È fondamentale sottolineare che l’insieme di test $\mathcal{D}^{(\text{test})}$ non rappresenta un bacino dati specifico e isolato, locale alla sola famiglia dei modelli aggregati. Al contrario, esso coincide formalmente con l’insieme universale condiviso dei benchmark $\mathcal{B}$, che verrà rigorosamente definito nella Sezione 3.3.1. Di conseguenza, l’intero pool di modelli (siano essi aggregati o biclasse) viene proiettato sistematicamente sull’intera totalità di $\mathcal{B}$, garantendo un incrocio analitico esaustivo tra tutte le architetture e tutte le partizioni sperimentali.

Si precisa che la formalizzazione dei modelli biclasse specialistici e il relativo protocollo di *cross-evaluation* speculare sono trattati separatamente nella Sezione 3.2.2.




Figura 3.3: Flusso concettuale del protocollo di addestramento, inferenza e disaggregazione delle prestazioni per i modelli aggregati ($\mathcal{M}_{\text{base}}, \mathcal{M}_S, \mathcal{M}_H^{(T)}$). I modelli, congelati post-ottimizzazione, vengono valutati sia sull’intero benchmark multi-classe per misurare la generalizzazione di dominio, sia sulle singole partizioni per famiglia d’attacco $\mathcal{D}_a^{(\text{test})}$ per l’analisi di disaggregazione puntuale.

3.2.2 Decomposizione Specialistica Biclasse

In integrazione ai modelli aggregati definiti nella Sezione 3.2.1, il framework metodologico prevede una formalizzazione specialistica basata sulla decomposizione del problema di rilevamento in

classificatori biclasse focalizzati su singole famiglie d'attacco $a \in \mathcal{A}$. L'obiettivo primario di tale decomposizione non consiste nella riconfigurazione dell'architettura di inferenza, bensì nell'isolamento analitico delle singole tipologie di minaccia per valutarne la rilevabilità puntuale rispetto al profilo di traffico nominale e confrontarne direttamente le prestazioni con le rispettive varianti multi-classe¹¹.

Sintesi e Bilanciamento delle Partizioni Biclasse

Ciascun dataset biclasse viene generato rispettando rigorosamente il medesimo protocollo di partizionamento, il rapporto di suddivisione train/test e il bilanciamento tra componente lecita e malevola formalizzati nella Sezione 3.1.1. Per ogni specifica famiglia d'attacco a , sia la partizione di addestramento che quella di test comprendono:

1. una frazione di traffico lecito ($Y = 0$), costantemente estratta dalla distribuzione sorgente nativa $\mathcal{D}_S$;
2. una frazione di traffico anomalo ($Y = 1$), ristretta esclusivamente ai vettori associati alla specifica classe di minaccia a .

Tassonomia dei Modelli Biclasse

A differenza della caratterizzazione adottata per i classificatori aggregati, la famiglia dei modelli biclasse esclude la formulazione di architetture basate su iniezione sparsa (ovvero non è definita alcuna variante biclasse analoga a $\mathcal{M}_{\text{base}}$)¹². Lo spazio dei modelli biclasse si articola pertanto nelle seguenti due categorie:

1. **Modelli Biclasse Sorgente ($\mathcal{M}_{S,a}$):** specializzati sulle singole famiglie d'attacco $a \in \mathcal{A}_S$ appartenenti al dominio sorgente nativo. La relativa partizione di addestramento $\mathcal{D}_{S,a}^{(\text{train})}$ è

¹¹La decomposizione introduce un costo computazionale di addestramento proporzionale alla cardinalità del set delle minacce $O(|\mathcal{A}|)$. Tale overhead rappresenta un compromesso metodologico consapevole, poiché l'obiettivo primario della formulazione risiede nell'isolamento analitico della rilevabilità e non nell'ottimizzazione dell'efficienza.

¹²L'assenza di modelli biclasse con iniezione deriva dalla volontà di valutare la risposta specialistica o nella condizione di assoluta assenza di adattamento (sorgente pura) o nella condizione di visibilità integrale della minaccia nel dominio target (ibrido/oracle).

definita come:

$$\mathcal{D}_{S,a}^{(\text{train})} = \mathcal{D}_S^{(\text{train})} \Big|_{Y=0} \cup \mathcal{D}_S^{(\text{train})} \Big|_{Y=1, A=a} \quad (3.15)$$

Il vettore ottimale dei parametri $\theta_{S,a}^*$ viene determinato mediante la minimizzazione del rischio empirico ristretto al dominio dell'attacco a :

$$\theta_{S,a}^* = \arg \min_{\theta} \mathcal{R}_{\text{emp}} \left(\theta; \mathcal{D}_{S,a}^{(\text{train})} \right) \quad (3.16)$$

2. **Modelli Biclasse Ibridi/Target ($\mathcal{M}_{H,T,a}$):** istanziati per ciascuna sotto-distribuzione target T e per ciascuna specifica famiglia d'attacco $a \in \mathcal{A}_T$ presente nel dominio di destinazione. La composizione del dataset ricomposto $\mathcal{D}_{H,T,a}^{(\text{train})}$ adotta la componente lecita sorgente unita alla sola classe malevola a del contesto target:

$$\mathcal{D}_{H,T,a}^{(\text{train})} = \mathcal{D}_S^{(\text{train})} \Big|_{Y=0} \cup \mathcal{D}_T^{(\text{train})} \Big|_{Y=1, A=a} \quad (3.17)$$

con la corrispondente stima parametrica fornita da:

$$\theta_{H,T,a}^* = \arg \min_{\theta} \mathcal{R}_{\text{emp}} \left(\theta; \mathcal{D}_{H,T,a}^{(\text{train})} \right) \quad (3.18)$$

Le caratteristiche essenziali e le finalità concettuali delle due categorie di modelli biclasse sono sintetizzate nella Tabella 3.5.

Tabella 3.5: Sintesi dei modelli biclasse specializzati: composizione del *training set* e finalità concettuale.

Modello	Composizione del <i>Training Set</i>	Finalità Concettuale
$\mathcal{M}_{S,a}$	$\mathcal{D}_{S,a}^{(\text{train})} = \mathcal{D}_S^{(\text{train})} \Big _{Y=0} \cup \mathcal{D}_S^{(\text{train})} \Big _{Y=1, A=a}$	Rilevatore specialistico addestrato su una singola minaccia sorgente $a \in \mathcal{A}_S$; valuta la selettività senza distorsioni di canale.
$\mathcal{M}_{H,T,a}$	$\mathcal{D}_{H,T,a}^{(\text{train})} = \mathcal{D}_S^{(\text{train})} \Big _{Y=0} \cup \mathcal{D}_T^{(\text{train})} \Big _{Y=1, A=a}$	Limite teorico (<i>Oracle</i> specialistico) per la singola minaccia $a \in \mathcal{A}_T$ nel dominio target T .

Invarianza dell’Inferenza, Valutazione Incrociata e Persistenza

Il meccanismo decisionale dei classificatori biclasse rimane del tutto identico a quello formalizzato nell’Equazione (3.9): la funzione appresa $f_{\theta^*,a}(\mathbf{x})$ stima la probabilità a posteriori $P(Y = 1 \mid \mathbf{x})$, e la decisione finale $\hat{Y} \in \{0, 1\}$ viene determinata dal confronto con la soglia canonica τ .

Poiché l’output di classificazione è limitato al dominio binario $\mathcal{Y} = \{0, 1\}$ (presenza o assenza di intrusione), ciascun modello biclasse è strutturalmente autocontenuto e indipendente. Non viene applicata alcuna regola di aggregazione d’insieme (es. sistemi di voto o regole di massimo); i modelli rimangono invariati nello stato post-addestramento, rispecchiando la procedura di conservazione definita per i modelli aggregati.

In fase di valutazione sperimentale, il protocollo per i classificatori biclasse, schematizzato in Figura 3.4 secondo la medesima notazione a diagramma di flusso introdotta in Figura 3.3, segue due direttive analitiche complementari:

1. **Valutazione Nominale Specialistica (*In-Domain*):** ciascun modello $\mathcal{M}_{S,a}$ (o $\mathcal{M}_{H,T,a}$) viene inizialmente testato sulla partizione dedicata alla singola minaccia $\mathcal{D}_a^{(\text{test})}$, stabilendo la prestazione ideale del classificatore nel proprio dominio di addestramento primario;
2. **Valutazione Incrociata di Classe (*Cross-Evaluation*):** il modello specialistico viene successivamente proiettato sull’intera gamma di benchmark multi-classe eterogenei $\mathcal{D}^{(\text{test})}$. Tale analisi permette di verificare se la firma appresa per la minaccia a generi falsi allarmi su attacchi $b \neq a$, quantificando la selettività di classe e l’eventuale polarizzazione dello spazio decisionale.

Come anticipato per la famiglia dei modelli aggregati, l’insieme eterogeneo $\mathcal{D}^{(\text{test})}$ impiegato nella *cross-evaluation* coincide esattamente con l’insieme universale dei benchmark $\mathcal{B}$ (Sezione 3.3.1). In quella sede verrà introdotta la matrice strutturata $H_k \in \mathbb{R}^{|\mathcal{M}| \times |\mathcal{B}|}$, in cui verranno incrociati tutti i modelli formulati $\{\mathcal{M}_{\text{base}}, \mathcal{M}_S, \mathcal{M}_H^{(T)}, \mathcal{M}_{S,a}, \mathcal{M}_{H,T,a}\}$ con l’intera estensione dei domini di test generati, fornendo così la rappresentazione visiva e matematica unificata che concretizza questo incrocio prestazionale.




Figura 3.4: Flusso concettuale del protocollo di valutazione incrociata (*cross-evaluation*). Il modello specialistico $\mathcal{M}_{S,a}$, addestrato esclusivamente sulla singola minaccia a , rimane invariato e viene proiettato in fase di inferenza sull'intero benchmark eterogeneo $\mathcal{D}^{(\text{test})}$.

3.2.3 Spazio delle Famiglie di Decisione Alberiformi ed Ensembling

La modellazione della superficie di decisione nei sistemi di *Network Intrusion Detection* (NIDS) operanti su canali ibridi terrestri-spaziali richiede architetture di apprendimento capaci di gestire elevata non-linearità, eterogeneità delle metriche e degradazioni del segnale trasmissivo. Questa sezione formalizza lo spazio delle famiglie di decisione basate sul partizionamento dello spazio delle caratteristiche, analizzandone le proprietà di invarianza e l'estensione a schemi di stima aggregata (*ensembling*).

Partizionamento Ricorsivo dello Spazio delle Caratteristiche

Sia $\mathcal{X} \subseteq \mathbb{R}^d$ lo spazio delle caratteristiche d -dimensionale rappresentativo delle metriche di traffico di rete e telemetria, e sia $\mathcal{Y} = \{0, 1\}$ lo spazio delle etichette corrispondente a traffico lecito o malevolo. Un albero di decisione [4] definisce una mappa $f : \mathcal{X} \rightarrow [0, 1]$ mediante un partizionamento ricorsivo dello spazio $\mathcal{X}$ in M regioni disgiunte e iper-rettangolari $\{R_m\}_{m=1}^M$, tali per cui:

$$\bigcup_{m=1}^M R_m = \mathcal{X} \quad \text{e} \quad R_m \cap R_k = \emptyset, \quad \forall m \neq k \quad (3.19)$$

La funzione di decisione associata all'albero assume la forma analitica espressa da:

$$f(\mathbf{x}) = \sum_{m=1}^M c_m \mathbb{I}(\mathbf{x} \in R_m) \quad (3.20)$$

dove $\mathbb{I}(\cdot)$ denota la funzione indicatrice e $c_m \in [0, 1]$ rappresenta la stima della probabilità a posteriori della classe malevola all'interno della regione R_m , coerentemente con la formulazione $f_\theta : \mathcal{X} \rightarrow [0, 1]$ introdotta nella Sezione 3.2.1. Sulla base del dataset di addestramento $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$, tale stima è definita come la frequenza relativa empirica della classe positiva nella foglia:

$$c_m = \frac{1}{|R_m|} \sum_{\mathbf{x}_i \in R_m} \mathbb{I}(y_i = 1) \quad (3.21)$$

La decisione binaria finale $\hat{Y}$ viene poi ottenuta applicando la soglia canonica τ già formalizzata nell'Equazione (3.9), in coerenza con l'intero framework di ottimizzazione ERM/BCE.

La selezione delle soglie ottimali di split θ_j per la j -esima caratteristica x_j avviene ricorsivamente minimizzando un criterio di impurità $I(R_m)$, come l'indice di Gini o l'entropia cross-entropica [4]. Formalmente, in un task di classificazione binaria, tali criteri sono espressi in funzione della probabilità stimata c_m come:

$$I_{\text{Gini}}(R_m) = 2c_m(1 - c_m), \quad I_{\text{entropy}}(R_m) = -c_m \log_2(c_m) - (1 - c_m) \log_2(1 - c_m) \quad (3.22)$$

Proprietà di Invarianza e Tolleranza alle Distorsioni di Canale

Gli alberi di decisione esibiscono proprietà algebriche e geometriche fondamentali che li rendono intrinsecamente robusti alle perturbazioni introdotte dai canali trasmissivi radiofrequenza (RF) e dalle perdite di pacchetto.

Invarianza alle Trasformazioni Monotone Come introdotto nella Sezione 3.1.2 a giustificazione dell'omissione della fase di scalatura esplicita, le metriche estratte dai canali spaziali possono subire variazioni di scala, attenuazioni o calibrazioni non-lineari. La proprietà viene qui derivata in forma rigorosa e generalizzata a trasformazioni specifiche per singola caratteristica. Sia $h_j : \mathbb{R} \rightarrow \mathbb{R}$ una trasformazione strettamente monotonica crescente applicata alla caratteristica x_j . Poiché la decisione di uno split ad un generico nodo dell'albero è governata dalla funzione di soglia $\mathbb{I}(x_j > \theta_j)$, si osserva che:

$$x_j > \theta_j \iff h_j(x_j) > h_j(\theta_j) \quad (3.23)$$

Definendo la nuova soglia $\theta'_j = h_j(\theta_j)$, l'ordinamento topologico dei punti all'interno dello spazio $\mathcal{X}$ rimane inalterato, garantendo l'invarianza della partizione R_m e della decisione $f(\mathbf{x})$:

$$f(\mathbf{x}) = f(h_1(x_1), h_2(x_2), \dots, h_d(x_d)) \quad (3.24)$$

Tale proprietà elimina la necessità di normalizzazioni rigide (es. z-score o Min-Max) che risulterebbero instabili sotto condizioni di variabilità dinamica del canale.

Robustezza a Rumore Additivo e Distorsione Si consideri una misura corrotta da distorsione o rumore di canale $\tilde{\mathbf{x}} = \mathbf{x} + \boldsymbol{\eta}$, dove $\boldsymbol{\eta}$ rappresenta una componente stocastica con $\mathbb{E}[\boldsymbol{\eta}] = \mathbf{0}$. Poiché le regioni R_m sono delimitate da iperpiani di decisione paralleli agli assi coordinati, la classificazione del vettore perturbato $\tilde{\mathbf{x}}$ risulta invariante rispetto al vettore nominale $\mathbf{x}$ per qualsiasi perturbazione limitata che non attraversi il confine dell'iperpiano:

$$f(\tilde{\mathbf{x}}) = f(\mathbf{x}), \quad \forall \boldsymbol{\eta} \text{ t.c. } \text{sgn}(x_j + \eta_j - \theta_j) = \text{sgn}(x_j - \theta_j) \quad (3.25)$$

Questa natura a scalino (*step function*) riduce la sensibilità al rumore gaussiano e alle fluttuazioni di piccola entità rispetto ai modelli a separazione lineare o a base di distanza euclidea.

Gestione Nativa dei Dati Mancanti (*Packet Loss*) In presenza di perdite di pacchetti o corruzione dei dati di header, alcune caratteristiche x_j possono risultare non disponibili ($x_j = \text{NaN}$). Le strutture alberiformi gestiscono tale incompletezza mediante due meccanismi distinti proposti in letteratura, entrambi privi della necessità di imputazione esplicita del dato: gli *split surrogati*, introdotti nella formulazione originaria di CART [4], che individuano uno split alternativo su una caratteristica correlata a x_j qualora quest'ultima risulti mancante; e l'instradamento a *direzione predefinita* (*default direction*), proposto nel contesto degli algoritmi di boosting scalabili [5], in cui la direzione ottimale $\delta_j^* \in \{\text{sinistra}, \text{destra}\}$ per ciascun nodo di split su x_j viene appresa direttamente durante l'addestramento, minimizzando la perdita empirica sui pattern di sparsità osservati:

$$\text{Posizione}(\mathbf{x}) = \begin{cases} \text{Sinistra} & \text{se } x_j \leq \theta_j \\ \text{Destra} & \text{se } x_j > \theta_j \\ \delta_j^* & \text{se } x_j = \text{NaN} \end{cases} \quad (3.26)$$

Formulazione Generale degli Ensemble per la Riduzione dell'Errore

Sebbene il singolo albero di decisione presenti un basso errore di bias, esso soffre di elevata varianza. Per mitigare tale limite, si ricorre a tecniche di *ensembling* che combinano B stimatori base $\{f_b(\mathbf{x})\}_{b=1}^B$ per formare un predittore aggregato $F(\mathbf{x})$:

$$F(\mathbf{x}) = \sum_{b=1}^B \beta_b f_b(\mathbf{x}) \quad (3.27)$$

Questa astrazione unifica i due principali approcci¹³: l'addestramento parallelo per la riduzione della varianza e l'addestramento sequenziale per la riduzione del bias, le cui differenze chiave sono schematizzate in Tabella 3.6 e in Figura 3.5.

Riduzione della Varianza via Bagging (*Bootstrap Aggregating*) Nello schema Bagging, di cui le architetture *Random Forest* [3] costituiscono l'estensione fondamentale, ciascun stimatore $f_b(\mathbf{x})$ viene addestrato in modo indipendente su un campionamento bootstrap del dataset $\mathcal{D}_b^*$, introducendo un'ulteriore de-correlazione mediante la selezione casuale di un sottoinsieme di $k < d$ caratteristiche a ciascun nodo.

Sia σ^2 la varianza del singolo albero e ρ il coefficiente di correlazione campionaria medio tra le predizioni di due alberi distinti. La varianza dello stimatore mediato $\bar{f}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B f_b(\mathbf{x})$ si esprime analiticamente come [11]:

$$\text{Var}(\bar{f}(\mathbf{x})) = \rho \sigma^2 + \frac{1 - \rho}{B} \sigma^2 \quad (3.28)$$

Al crescere del numero di alberi $B \rightarrow \infty$, il secondo termine tende a zero, riducendo la varianza complessiva del modello al limite teorico $\rho \sigma^2$. La de-correlazione forzata delle caratteristiche riduce il fattore ρ , garantendo un'elevata capacità di generalizzazione anche su traffico malevolo mai osservato.

Riduzione del Bias via Gradient Boosting A differenza dell'approccio parallelo del Bagging, gli algoritmi di *Gradient Boosting* [10] (incluso il paradigma con discretizzazione a istogrammi

¹³Come formalizzato nei paragrafi seguenti, nel caso del Bagging si assegna un peso uniforme $\beta_b = 1/B$, mentre la ricorsione additiva del Boosting, se srotolata su B passi, si riconduce a questa formulazione ponendo $\beta_b = \nu$ (a meno di un predittore costante iniziale F_0).

Histogram-based Gradient Boosting [14]) costruiscono l'ensemble in modo sequenziale ed additivo. Dato un modello al passo $b - 1$ pari a $F_{b-1}(\mathbf{x})$, lo stimatore successivo $f_b(\mathbf{x})$ viene addestrato per approssimare i pseudo-residui $r_{i,b}$, definiti come il gradiente negativo della funzione di perdita differenziabile $L(y_i, F(\mathbf{x}_i))$ valutato sulla predizione corrente:

$$r_{i,b} = - \left[\frac{\partial L(y_i, F(\mathbf{x}_i))}{\partial F(\mathbf{x}_i)} \right]_{F(\mathbf{x}_i)=F_{b-1}(\mathbf{x}_i)} \quad (3.29)$$

L'aggiornamento del modello aggregato avviene secondo la regola:

$$F_b(\mathbf{x}) = F_{b-1}(\mathbf{x}) + \nu \cdot f_b(\mathbf{x}) \quad (3.30)$$

dove $\nu \in (0, 1]$ rappresenta il tasso di apprendimento (*learning rate*). Tale approccio garantisce una minimizzazione progressiva del bias dell'errore di classificazione, consentendo di catturare sottili pattern di attacco ad alta dimensionalità tipici delle minacce cibernetiche complesse.

Tabella 3.6: Confronto delle proprietà architetturali e degli obiettivi di ottimizzazione tra i paradigmi di *ensembling* Bagging e Gradient Boosting.

Caratteristica	Bagging	Gradient Boosting
Costruzione	Parallela, stimatori indipendenti	Sequenziale, additiva
Obiettivo primario	Riduzione della varianza	Riduzione del bias
Combinazione	Media: $\bar{f} = \frac{1}{B} \sum f_b$	Somma pesata: $F_b = F_{b-1} + \nu f_b$
Target addestramento per f_b	Etichette originali su campionamenti bootstrap $\mathcal{D}_b^*$	Pseudo-residui $r_{i,b}$ valutati al passo $b - 1$




Figura 3.5: Confronto logico-procedurale tra gli schemi di aggregazione. A sinistra, il paradigma *Bagging* esegue un addestramento parallelo su campionamenti bootstrap indipendenti. A destra, il paradigma *Gradient Boosting* adotta un approccio sequenziale in cui ciascun albero mira a correggere i residui iterativi generati dall'insieme precedente.

3.3 Framework di Adattamento, Granularità e Stabilità Statistica

La valutazione dell'efficacia delle architetture e delle strategie di *transfer learning* precedentemente formalizzate richiede un apparato metodologico capace di isolare i reali guadagni prestazionali dal rumore stocastico intrinseco ai processi di apprendimento. Questa sezione definisce il framework di valutazione e di analisi teorica adottato per garantire la solidità e la riproducibilità dei risultati.

Nella prima parte della trattazione viene affrontato il problema dell'incertezza algoritmica legata ai modelli ad albero, introducendo un rigoroso protocollo di valutazione *multi-seed*. Vengono definite le metriche prestazionali di aggregazione e viene formalizzato l'impiego del test t di

Welch per stabilire oggettivamente la significatività statistica degli scostamenti osservati rispetto al modello di riferimento (*baseline*). Successivamente, l'analisi si sposta sulle proprietà strutturali e geometriche dello spazio decisionale. Viene introdotto l'indice di granularità per valutare l'impatto della formulazione del problema — differenziando tra partizioni a grana grossa e a grana fine — sulla morfologia dei confini decisionali, discutendo il compromesso teorico tra rigidità specialistica e tolleranza al *domain shift*.

Per agevolare la consultazione delle metriche e dei parametri statistici discussi, la notazione principale introdotta in questa sezione è riepilogata nella Tabella 3.7.

Tabella 3.7: Sintesi della notazione relativa al framework di valutazione e alla stabilità statistica.

Simbolo	Descrizione e Significato Concettuale
s_0	Seed deterministico utilizzato per il partizionamento dei dati e la generazione invariante dei benchmark
$S = \{s_1, \dots, s_K\}$	Insieme di K seed pseudo-casuali per l'inizializzazione stocastica e l'addestramento dei classificatori
$H_k(M, D)$	Matrice delle prestazioni (es. TPR, TNR) ottenute dal modello M sul benchmark D con il seed s_k
$\hat{\mu}(M, D), \hat{\sigma}^2(M, D)$	Stima puntuale del valore atteso e della varianza campionaria delle metriche prestazionali marginalizzate sui K seed
t, ν_{eff}	Statistica del test e gradi di libertà effettivi nel test t di Welch per la significatività rispetto al baseline
$\Gamma(M) = \mathcal{A}_m(M) $	Indice di granularità: cardinalità delle famiglie d'attacco osservate in addestramento dal modello M
$R_1(M)$	Regione decisionale positiva nello spazio $\mathcal{X}$, corrispondente alla previsione dell'etichetta malevola ($Y = 1$)
$\text{supp } P(\mathbf{x} \mid Y = 1, A = a)$	Supporto spaziale effettivo della distribuzione condizionata associata a una singola famiglia di attacco a

3.3.1 Incertezza Stocastica e Valutazione Multi-Seed

Le famiglie di classificatori adottate nel framework (Sezione 3.2.3) presentano componenti algoritmiche intrinsecamente stocastiche: il campionamento bootstrap e la selezione casuale del sottoinsieme di caratteristiche per nodo negli ensemble Bagging, così come le procedure di inizializzazione e di sotto-campionamento stocastico tipiche degli algoritmi di Gradient Boosting. Di conseguenza, la prestazione puntuale di un singolo modello addestrato con un'unica inizializzazione non costituisce, di per sé, una stima affidabile della sua reale capacità discriminativa: un risultato favorevole isolato potrebbe essere l'esito di una particolare configurazione stocastica favorevole, piuttosto che un'evidenza sistematica della superiorità del modello. Il framework metodologico introduce pertanto un protocollo di valutazione *multi-seed*, volto a stimare non solo il valore atteso della prestazione, ma anche la sua dispersione, e a verificarne la significatività statistica rispetto al modello di riferimento.

Separazione tra Seed di Composizione del Dataset e Seed di Addestramento

Per isolare la stocasticità algoritmica dei classificatori da qualsivoglia variabilità indotta dalla composizione dei dati, il framework distingue rigorosamente due categorie di seed pseudo-casuali, aventi ruolo e ambito di applicazione disgiunti:

- un seed deterministico s_0 , fissato una tantum e impiegato esclusivamente nelle procedure di split stratificato e di sintesi dei benchmark descritte nella Sezione 3.1.1. Tale seed determina univocamente le partizioni $\mathcal{D}_k^{(\text{train})}$, $\mathcal{D}_k^{(\text{test})}$ e la composizione di ciascun benchmark derivato, mantenendole identiche e invarianti per l'intero protocollo sperimentale;
- un insieme di K seed indipendenti $\mathcal{S} = \{s_1, s_2, \dots, s_K\}$, impiegati esclusivamente nelle fasi di addestramento dei classificatori (inizializzazione degli stimatori, campionamento bootstrap, selezione casuale delle caratteristiche), con K inteso come parametro simbolico del framework teorico.




Figura 3.6: Diagramma di flusso del protocollo di isolamento e valutazione stocastica. La stabilità della partizione dei dati è forzata top-down dall’unico seed deterministico s_0 , delegando la totalità della varianza osservata tra le matrici H_k all’inizializzazione stocastica dettata dall’insieme dei seed $\mathcal{S}$ interni agli stimatori.

La netta separazione tra s_0 e $\mathcal{S}$ garantisce che tutti i modelli, per ciascuna replica k , operino esattamente sullo stesso insieme di dati di addestramento e di test: nessun seed di modello risulta favorito da una composizione del dataset a lui più congeniale, e l’intera variabilità osservata tra le K repliche è pertanto attribuibile univocamente alla stocasticità algoritmica del classificatore, e non a un artefatto della partizione dei dati.

Metriche di Valutazione e Aggregazione Multi-Seed

Per un generico modello M (istanza di una qualsiasi delle famiglie $\mathcal{M}_{\text{base}}, \mathcal{M}_S, \mathcal{M}_H^{(T)}, \mathcal{M}_{S,a}, \mathcal{M}_{H,T,a}$) addestrato con il seed $s_k \in \mathcal{S}$ e valutato su un benchmark di test D , siano TP_k, TN_k, FP_k, FN_k le cardinalità della matrice di confusione ottenute dal confronto tra $\hat{Y}$ e l'etichetta reale Y^{14} . Si definiscono la *True Positive Rate* (TPR, sensibilità) e la *True Negative Rate* (TNR, specificità) come:

$$\text{TPR}_k(M, D) = \frac{TP_k}{TP_k + FN_k}, \quad \text{TNR}_k(M, D) = \frac{TN_k}{TN_k + FP_k} \quad (3.31)$$

Per ciascun seed s_k , i valori $\text{TPR}_k(M, D)$ e $\text{TNR}_k(M, D)$ vengono organizzati in una matrice $H_k \in \mathbb{R}^{|\mathcal{M}| \times |\mathcal{B}|}$, con righe indicizzate dai modelli $M \in \mathcal{M}$ e colonne dai benchmark di test $D \in \mathcal{B}$ coinvolti nel protocollo di valutazione incrociata (Sezioni 3.2.1 e 3.2.2), corredata da una colonna aggiuntiva di media di riga:

$$\bar{H}_k(M) = \frac{1}{|\mathcal{B}|} \sum_{D \in \mathcal{B}} H_k(M, D) \quad (3.32)$$

L'impianto metodologico fin qui descritto culmina nella definizione della matrice H_k , che concretizza l'operazione di proiezione incrociata di *tutte* le architetture formulate (siano esse aggregati multiclasse o specialisti biclasse) sull'intera estensione dei domini di test disponibili. Come illustrato nella Tabella 3.8, lo spazio delle valutazioni si articola in una griglia strutturata che elimina ogni barriera valutativa tra le categorie di classificazione e quelle di benchmark, rendendo esplicita l'universalità dell'insieme di test $\mathcal{B}$.

Tabella 3.8: Rappresentazione concettuale della matrice di valutazione incrociata $H_k \in \mathbb{R}^{|\mathcal{M}| \times |\mathcal{B}|}$.

$\mathbf{H}_k \in \mathbb{R}^{ \mathcal{M} \times \mathcal{B} }$	$\mathcal{D}^{(\text{test})}$	$\mathcal{D}_a^{(\text{test})}$	$\mathcal{D}_{b \neq a}^{(\text{test})}$
	(Aggregati)	(Biclasse In-Domain)	(Biclasse Cross)
$\mathcal{M}_{\text{base}}$	✓	✓	✓
$\mathcal{M}_S$	✓	✓	✓
$\mathcal{M}_H^{(T)}$	✓	✓	✓
$\mathcal{M}_{S,a}$	✓	✓	✓
$\mathcal{M}_{H,T,a}$	✓	✓	✓

¹⁴Rispettivamente: veri positivi, veri negativi, falsi positivi e falsi negativi, secondo la convenzione per cui $Y = 1$ denota traffico malevolo.

La stima puntuale del valore atteso e della dispersione prestazionale per la coppia (M, D) , marginalizzata sulle K repliche stocastiche, è data dalla media e dalla varianza campionarie:

$$\hat{\mu}(M, D) = \frac{1}{K} \sum_{k=1}^K H_k(M, D), \quad \hat{\sigma}^2(M, D) = \frac{1}{K-1} \sum_{k=1}^K (H_k(M, D) - \hat{\mu}(M, D))^2 \quad (3.33)$$

La matrice aggregata $\hat{H} = [\hat{\mu}(M, D)]$, corredata dai corrispondenti valori di $\hat{\sigma}^2(M, D)$, costituisce la sintesi prestazionale multi-seed per ciascuna tipologia di modello, riducendo l'influenza di configurazioni stocastiche anomale sulla valutazione complessiva del framework.

A partire dalle medesime cardinalità TP_k, TN_k, FP_k, FN_k , si definiscono inoltre le metriche di *Precision* e di *F1-Score*, quest'ultima impiegata specificamente nel protocollo di verifica della significatività statistica formalizzato nella Sezione 3.3.1:

$$\text{Precision}_k(M, D) = \frac{TP_k}{TP_k + FP_k}, \quad \text{F1}_k(M, D) = \frac{2 \cdot \text{Precision}_k(M, D) \cdot \text{TPR}_k(M, D)}{\text{Precision}_k(M, D) + \text{TPR}_k(M, D)} \quad (3.34)$$

dove l'F1-Score, in quanto media armonica di Precision e Recall ($\equiv$ TPR), costituisce una metrica sintetica particolarmente indicata a penalizzare squilibri tra falsi positivi e falsi negativi, coerentemente con l'asimmetria di classe intrinseca ai benchmark del framework (Sezione 3.1.1).

Verifica di Significatività Statistica mediante Test di Welch

La sola stima di $\hat{\mu}$ e $\hat{\sigma}^2$ non è sufficiente a stabilire se lo scostamento prestazionale tra un modello M e il modello baseline M_{base} sia statisticamente rilevante o riconducibile alla naturale variabilità campionaria. Il framework adotta a tal fine il test t di Welch [37], nella sua formulazione per campioni indipendenti a varianza non necessariamente omogenea.

La letteratura sul confronto statistico di classificatori [7] sconsiglia, in generale, l'impiego di test parametrici quando il confronto avviene su un numero ridotto di dataset eterogenei, per i quali ciascun dataset fornisce un singolo valore appaiato e l'assunzione di normalità risulta difficilmente verificabile; in tali condizioni sono raccomandate alternative non parametriche (test dei ranghi con segno di Wilcoxon, test di Friedman). Lo scenario qui considerato è tuttavia strutturalmente distinto: ciascuna osservazione $\overline{\text{F1}}_k(M)$ non è un valore puntuale su un singolo dataset, bensì la media di riga dell'F1-Score, calcolata su $|\mathcal{B}|$ benchmark di test per un dato seed s_k . In virtù del Teorema del Limite Centrale, tale quantità aggregata tende a una distribuzione approssimativamente normale al

crescere di $|\mathcal{B}|$, indipendentemente dalla distribuzione delle singole osservazioni F1 per dataset, fornendo una base più solida per l'impiego di un test parametrico rispetto al caso di confronto diretto su valori singoli non aggregati. La formulazione di Welch, in particolare, è preferita alla variante omoschedastica dello Student's t -test poiché non assume l'uguaglianza delle varianze tra le distribuzioni per-seed del modello M e del baseline, condizione non garantita a priori tra famiglie di modelli strutturalmente eterogenee.

Per ciascun modello M (con esclusione del baseline stesso), sia $\overline{\text{F1}}_k(M) = \frac{1}{|\mathcal{B}|} \sum_{D \in \mathcal{B}} \text{F1}_k(M, D)$ la media di riga dell'F1-Score per il seed s_k , definita in analogia all'Equazione (3.32) a partire dalla metrica dell'Equazione (3.34). Siano $\{\overline{\text{F1}}_k(M)\}_{k=1}^K$ e $\{\overline{\text{F1}}_k(\mathcal{M}_{\text{base}})\}_{k=1}^K$ le rispettive sequenze di medie per seed per il modello M e per il baseline. Definita l'ipotesi nulla $H_0 : \mu_M = \mu_{\text{base}}$, la statistica del test è espressa come:

$$t = \frac{\bar{x}_M - \bar{x}_{\text{base}}}{\sqrt{\frac{s_M^2}{K} + \frac{s_{\text{base}}^2}{K}}} \quad (3.35)$$

dove $\bar{x}_M$, $\bar{x}_{\text{base}}$ e s_M^2 , s_{base}^2 denotano rispettivamente la media e la varianza campionaria dell'F1-Score calcolate sulle K osservazioni per-seed di M e di $\mathcal{M}_{\text{base}}$. I gradi di libertà effettivi ν_{eff} sono stimati mediante l'approssimazione di Welch–Satterthwaite:

$$\nu_{\text{eff}} = \frac{\left(\frac{s_M^2}{K} + \frac{s_{\text{base}}^2}{K} \right)^2}{\frac{(s_M^2/K)^2}{K-1} + \frac{(s_{\text{base}}^2/K)^2}{K-1}} \quad (3.36)$$

Il valore p risultante viene confrontato con una soglia di significatività α : qualora $p < \alpha$, l'ipotesi nulla viene rigettata, e lo scostamento prestazionale tra il modello M e il baseline $\mathcal{M}_{\text{base}}$ è considerato statisticamente significativo e non attribuibile alla sola variabilità stocastica intrinseca degli stimatori. Il confronto viene condotto in modo puntuale per ciascun modello rispetto al baseline, coerentemente con il ruolo di $\mathcal{M}_{\text{base}}$ quale ancora di prestazione di riferimento stabilita nella Sezione 3.2.1.

3.3.2 Granularità della Risposta: Formulazione Binaria vs. Multiclasse

Sebbene lo spazio di uscita del framework rimanga rigorosamente binario ($\mathcal{Y} = \{0, 1\}$, cfr. Sezione 3.1.1)¹⁵, le due famiglie di classificatori sin qui formalizzate differiscono strutturalmente per il numero di famiglie d'attacco rappresentate simultaneamente all'interno della medesima frontiera di decisione. Si definisce pertanto un indice di *granularità di rappresentazione* $\Gamma(M)$, pari alla cardinalità dell'insieme delle famiglie d'attacco incluse nella partizione di addestramento di un modello M :

$$\Gamma(M) = |\mathcal{A}_m(M)|, \quad \mathcal{A}_m(M) \subseteq \mathcal{A} \quad (3.37)$$

dove $\mathcal{A}_m(M)$ denota l'insieme delle famiglie d'attacco osservate in addestramento dal modello M . Per i modelli aggregati (Sezione 3.2.1) si ha $\Gamma(\mathcal{M}_S) = |\mathcal{A}_S|$ e $\Gamma(\mathcal{M}_H^{(T)}) = |\mathcal{A}_T|$, ossia l'intera tassonomia disponibile nel rispettivo dominio; per i modelli biclasse (Sezione 3.2.2) si ha invece $\Gamma(\mathcal{M}_{S,a}) = \Gamma(\mathcal{M}_{H,T,a}) = 1$ per costruzione. In questo senso, i modelli aggregati costituiscono l'estremo a granularità grossolana ("*multiclasse*", in quanto la loro frontiera deve generalizzare simultaneamente su una molteplicità eterogenea di segnature d'attacco), mentre i modelli biclasse costituiscono l'estremo a granularità fine ("*biclasse*" propriamente detto, con una frontiera dedicata alla singola famiglia).

Regione Decisionale e Copertura del Supporto Malevolo

Sia $R_1(M) = \{\mathbf{x} \in \mathcal{X} : f_{\theta^*}(\mathbf{x}) \geq \tau\}$ la regione decisionale positiva associata al modello M , secondo la regola già formalizzata nell'Equazione (3.9). Per un modello aggregato, tale regione deve necessariamente coprire l'unione dei supporti delle distribuzioni condizionate di ciascuna famiglia d'attacco osservata:

$$R_1(\mathcal{M}_S) \supseteq \bigcup_{a \in \mathcal{A}_S} \text{supp } P_S(\mathbf{x} \mid Y = 1, A = a) \quad (3.38)$$

¹⁵Nell'ambito della presente trattazione, l'uso dei termini "multiclasse" e "biclasse" non si riferisce alla cardinalità dello spazio di codifica delle uscite $\mathcal{Y}$, che rimane sempre scalare e binario, bensì alla granularità semantica delle componenti d'attacco aggregate all'interno della medesima etichetta positiva $Y = 1$.

mentre per un modello biclasse la regione positiva è calibrata in modo mirato sul supporto di un'unica sotto-distribuzione¹⁶:

$$R_1(\mathcal{M}_{S,a}) \supseteq \text{supp } P_S(\mathbf{x} \mid Y = 1, A = a) \quad (3.39)$$

Tale distinzione strutturale ha una diretta implicazione geometrica, coerente con il partizionamento ricorsivo $\{R_m\}_{m=1}^M$ formalizzato nella Sezione 3.2.3: al crescere di $\Gamma(M)$, la regione $R_1(M)$ deve estendersi su un volume dello spazio $\mathcal{X}$ tendenzialmente più ampio ed eterogeneo, risultante dalla composizione delle regioni foglia associate a più sotto-distribuzioni distinte; al diminuire di $\Gamma(M)$ (limite $\Gamma = 1$), $R_1(M)$ si concentra invece attorno a un unico manifold di supporto, con margine decisionale calibrato sulla sola distribuzione della famiglia a .

Compromesso tra Rigidità Specialistica e Copertura Generalista

La calibrazione di $R_1(M)$ su un manifold ristretto ($\Gamma(M) = 1$) produce un confine decisionale a elevata specificità: il classificatore biclasse è, per costruzione, ottimizzato per discriminare la sola famiglia a dal traffico nominale, senza compromessi indotti dalla necessità di generalizzare su segnature eterogenee. Tale specificità comporta tuttavia una maggiore *rigidità* del confine sotto *domain shift*: qualora il vettore osservato nel dominio di destinazione risulti sistematicamente perturbato secondo il modello $\tilde{\mathbf{x}} = \mathbf{x} + \boldsymbol{\eta}$ già discusso in Sezione 3.2.3, uno spostamento del manifold malevolo oltre il margine appreso in fase di addestramento non è compensato da alcuna informazione di supporto proveniente da altre famiglie d'attacco, risultando in un decadimento prestazionale puntuale e localizzato.

Al contrario, un modello aggregato, essendo vincolato a costruire una regione $R_1(M)$ che copra congiuntamente più sotto-distribuzioni (Equazione (3.38)), sviluppa margini decisionali strutturalmente più ampi e meno specifici per la singola famiglia d'attacco. Tale maggiore ampiezza può conferire una tolleranza intrinseca a perturbazioni locali di una singola sotto-distribuzione, a scapito però della purezza discriminativa per classe¹⁷.

¹⁶In un contesto d'apprendimento induttivo reale, la regione decisionale $R_1(\mathcal{M}_{S,a})$ racchiude il supporto effettivo $\text{supp } P_S(\mathbf{x} \mid Y = 1, A = a)$ estendendosi oltre di esso per un margine di generalizzazione $\epsilon > 0$, indotto dalla struttura dell'iperpiano o dagli split degli alberi decisionali.

¹⁷Questo compromesso è la controparte teorica dei fenomeni empirici già anticipati nel framework: il *class shadowing* (Sezione 3.2.1), per cui un'elevata accuratezza aggregata può mascherare un decadimento su famiglie




Figura 3.7: Rappresentazione bidimensionale nello spazio delle caratteristiche $\mathcal{X}$ dell'impatto del *domain shift* (vettore di traslazione η) a seconda della granularità del modello. A sinistra, la maggiore ampiezza spaziale del modello aggregato garantisce tolleranza generalista; a destra, l'ottimizzazione specialistica sul singolo supporto malevolo determina rigidità sotto perturbazione.

Il Modello Baseline come Punto di Riferimento Intermedio

Il modello $\mathcal{M}_{\text{base}}$ (Sezione 3.2.1) occupa, rispetto all'indice Γ , una posizione concettualmente intermedia tra i due estremi. La sua regione decisionale eredita la copertura ad ampio spettro propria dei modelli aggregati, essendo $\mathcal{A}_S \subseteq \mathcal{A}_m(\mathcal{M}_{\text{base}})$, ma viene incrementalmente perturbata da una conoscenza mirata e altamente sparsa del dominio target ($\Delta\mathcal{D}_T^{(\text{train})}$, Equazione (3.11)), la cui esiguità cardinale ($|\Delta\mathcal{D}_T^{(\text{train})}| \ll |\mathcal{D}_S^{(\text{train})}|$) ne impedisce una piena riqualificazione come copertura multiclasse del dominio di destinazione. $\mathcal{M}_{\text{base}}$ costituisce pertanto l'ancora di riferimento rispetto alla quale entrambi gli estremi della granularità — l'ampia copertura generalista dei modelli aggregati $\mathcal{M}_S, \mathcal{M}_H^{(T)}$ e l'elevata specificità dei modelli biclasse $\mathcal{M}_{S,a}, \mathcal{M}_{H,T,a}$ — vengono confrontati, secondo il protocollo di verifica statistica formalizzato in Sezione 3.3.1, al fine di determinare quale

specifiche, e la polarizzazione dello spazio decisionale osservabile in fase di *cross-evaluation* per i modelli biclasse (Sezione 3.2.2).

livello di granularità offra il compromesso più favorevole tra specificità discriminativa e robustezza al *domain shift*.

3.4 Framework Analitico, Spiegabilità e Significatività

Statistica

La presente sezione definisce il framework analitico, diagnostico e statistico adottato per caratterizzare lo scostamento distributivo (*domain shift*), decodificare le logiche decisionali dei modelli e valutare la significatività delle variazioni prestazionali tra domini eterogenei. L'impianto metodologico integra tecniche di riduzione dimensionale, stima non parametrica di densità e attribuzione dell'importanza delle caratteristiche fondata sulla teoria dei giochi cooperativi, affiancandole a un formalismo rigoroso per la gestione delle soglie e la verifica di ipotesi statistiche.

Per agevolare la consultazione della trattazione, i simboli matematici, i costrutti diagnostici e le metriche prestazionali introdotti in questa sezione sono riepilogati nella Tabella 3.9.

Tabella 3.9: Sintesi della notazione relativa al framework analitico, all’interpretabilità e alla valutazione statistica.

Simbolo	Descrizione e Significato Concettuale
$\mathbf{Z}_D$	Matrice dei dati del benchmark D standardizzata mediante la media μ_S e la deviazione standard σ_S del solo dominio sorgente
$\Sigma_D, \mathbf{W}_D$	Matrice di covarianza campionaria e matrice di proiezione ortogonale sui primi due assi della PCA
$\hat{f}_y(z), h_{\text{KDE}}$	Stima di densità univariata KDE per la classe y e relativo parametro di liscio (<i>bandwidth</i>) con kernel gaussiano $\kappa(\cdot)$
$\phi_j(\mathbf{x})$	Valore SHAP associato alla j -esima caratteristica del vettore $\mathbf{x}$, rappresentante il suo contributo marginale esatto
$I_j^{(D)}, C_j$	Importanza media assoluta SHAP della j -esima caratteristica sul benchmark D e frequenza globale di inclusione nella <i>top-3</i>
$TP(\tau), FP(\tau), TN(\tau), FN(\tau)$	Cardinalità della matrice di confusione determinate in funzione della soglia decisionale parametrica τ
AUC_{ROC}, AUC_{PR}	Area sottesa alle curve <i>Receiver Operating Characteristic</i> e <i>Precision-Recall</i> per la caratterizzazione al variare di $\tau \in [0, 1]$
ΔF_1	Variazione prestazionale in termini di F_1 -score per la quantificazione del degrado da <i>covariate shift</i> tra sorgente $\mathcal{D}_S$ e target $\mathcal{D}_T$
t, ν, H_0	Statistica del test t di Welch, gradi di libertà effettivi di Welch–Satterthwaite e ipotesi nulla di equivalenza delle medie prestazionali

3.4.1 Caratterizzazione Densometrica e Proiezioni Latenti

L'analisi dello scostamento distributivo (*domain shift*) e la valutazione della separabilità geometrica tra traffico nominale e traffico malevolo richiedono l'impiego di tecniche di riduzione dimensionale e stima di densità. Come anticipato nella Sezione 3.1.2, mentre l'architettura di classificazione basata su modelli ad albero gode dell'invarianza alle trasformazioni monotoniche e prescinde dalla scala dei dati, gli strumenti diagnostici e visivi (PCA e KDE) sono sensibili alla grandezza numerica delle variabili.

Prima dell'estrazione delle proiezioni e della stima densometrica, viene applicata una normalizzazione dedicata a ciascun benchmark $D \in \mathcal{B}$, secondo l'insieme dei benchmark di test già introdotto nella Sezione 3.3.1. Tale trasformazione è ancorata unicamente alle statistiche del dominio sorgente $\mathcal{D}_S$ e rimane rigorosamente disaccoppiata dallo stadio di addestramento dei modelli.

Standardizzazione Diagnostica Dipendente dal Sorgente

Per evitare fenomeni di contaminazione informativa (*data leakage*), derivati dall'estrazione di statistiche da domini target incogniti, e per preservare la reale ampiezza del *domain shift*, i dati di ciascun benchmark $D \in \mathcal{B}$ vengono standardizzati utilizzando esclusivamente la media μ_S e la deviazione standard σ_S calcolate sul benchmark sorgente di riferimento S .

Sia $\mathbf{X}_D \in \mathbb{R}^{N_D \times d}$ la matrice dei dati grezzi del generico benchmark D . Il generico elemento della matrice trasformata $\mathbf{Z}_D \in \mathbb{R}^{N_D \times d}$ è definito come:

$$\mathbf{Z}_{D,ij} = \frac{\mathbf{X}_{D,ij} - \mu_{S,j}}{\sigma_{S,j} + \epsilon} \quad (3.40)$$

dove $\mu_{S,j}$ e $\sigma_{S,j}$ rappresentano la media e la deviazione standard campionarie della j -esima caratteristica stimata sul set sorgente S , e $\epsilon > 0$ è una costante infinitesima introdotta a scopo di stabilità numerica, per prevenire divisioni per valori prossimi a zero in presenza di caratteristiche a varianza sorgente quasi nulla (es. indicatori binari fortemente sbilanciati).

L'ancoraggio a (μ_S, σ_S) , anziché a statistiche ricalcolate localmente su ciascun benchmark D , garantisce che eventuali traslazioni di media o contrazioni di varianza presenti nel benchmark D non vengano annullate artificialmente: una standardizzazione locale ricentrerebbe infatti ogni benchmark sulla propria origine, occultando esattamente lo scostamento distributivo che l'analisi

si propone di rendere visibile. Questo ancoraggio è una scelta di riferimento per la sola finalità diagnostico-visiva e non implica alcuna dipendenza dalla scala da parte del classificatore: come dimostrato nella Sezione 3.1.2, la decisione dei modelli ad albero è invariante rispetto a qualsiasi trasformazione monotonica crescente, ancorata o meno al dominio sorgente. L'ancoraggio a (μ_S, σ_S) risponde dunque esclusivamente all'esigenza di disporre di un sistema di riferimento fisso e interpretabile per l'ispezione visiva, non a un requisito del modello di classificazione.

Proiezioni Ortogonali e Relatività dello Spazio Latente (PCA)

Per ispezionare visivamente le relazioni topologiche del traffico di rete, lo spazio delle caratteristiche viene mappato in un sottospazio latente a due dimensioni tramite Analisi delle Componenti Principali (PCA) [26, 13].

Necessità tecnica dello scaling per la PCA La PCA si basa sulla decomposizione spettrale della matrice di covarianza Σ_D , massimizzando la varianza lungo gli assi ortogonali. In assenza della trasformazione espressa nell'Equazione (3.40), l'impiego diretto di caratteristiche in scala grezza eterogenea (es. volumi in byte con varianze dell'ordine di 10^6 affiancati a *ratio* adimensionali compresi in $[0, 1]$) causerebbe una dominanza artificiale della matrice di covarianza da parte delle variabili a magnitudo numerica maggiore. La prima componente principale si schiaccerebbe unicamente sulle variabili a scala più ampia, indipendentemente dal loro effettivo valore informativo o discriminante.

Sulla matrice standardizzata $\mathbf{Z}_D$, la matrice di covarianza campionaria Σ_D è formulata come:

$$\Sigma_D = \frac{1}{N_D - 1} \mathbf{Z}_D^\top \mathbf{Z}_D \quad (3.41)$$

La matrice di proiezione $\mathbf{W}_D \in \mathbb{R}^{d \times 2}$ è composta dagli autovettori ortonormali associati ai due principali autovalori di Σ_D .

La standardizzazione preventiva isola una proprietà rilevante del framework: sebbene i campioni della classe lecita ($Y = 0$) derivino dalla medesima distribuzione stazionaria di base in tutti i benchmark, la loro proiezione nel piano latente muta geometricamente al variare del benchmark D . Poiché Σ_D risente della varianza congiunta dell'intero set di dati, l'accoppiamento con vettori malevoli ($Y = 1$) eterogenei riorienta gli assi di massima varianza. L'eliminazione degli artefatti di

scala mediante (μ_S, σ_S) assicura che tali rotazioni non siano attribuibili a discrepanze puramente dimensionali, ma riflettano la specifica struttura dell'attacco contestuale e il relativo *domain shift*. Va precisato che, trattandosi di una tecnica non supervisionata, la PCA massimizza la varianza totale dei dati senza impiego esplicito dell'etichetta Y : l'osservazione secondo cui l'asse di massima varianza tende a riflettere la separazione tra le classi è pertanto un comportamento empiricamente frequente, ma non una proprietà garantita in generale, a differenza di tecniche supervisionate come l'Analisi Discriminante Lineare (LDA).

Stima di Densità (KDE) su Sub-spazio Selettivo

Per quantificare la sovrapposizione distributiva e l'incertezza decisionale tra le classi, l'analisi si avvale della *Kernel Density Estimation* (KDE) univariata, i cui fondamenti teorici risalgono ai lavori di Rosenblatt [27] e Parzen [25]. Per garantire l'interpretabilità geometrica e superare la sparsità dei dati in alta dimensione, la KDE viene confinata alle tre caratteristiche di maggiore rilevanza empirica individuate tramite l'aggregazione dei valori di Shapley (SHAP, Sezione 3.4.2).

Motivazione metodologica dello scaling per la KDE A differenza della PCA, dal punto di vista strettamente matematico la forma della stima di densità univariata è equivariante alle trasformazioni lineari (la geometria della curva non si distorce, ma trasla e si riscalda coerentemente). Tuttavia, l'applicazione della standardizzazione Z-score dipendente dal sorgente risulta indispensabile per tre ragioni pratiche e metodologiche:

1. **Preservazione visiva del Domain Shift:** l'utilizzo delle metriche del sorgente $(\mu_{S,j}, \sigma_{S,j})$ fa sì che se una caratteristica nel benchmark D subisce una traslazione sistematica della media, la curva di densità KDE risulti fisicamente traslata rispetto all'origine $z = 0$, rendendo immediata l'ispezione visiva del *domain shift*;
2. **Comparabilità grafica cross-feature:** le tre *feature* selezionate mediante SHAP, originariamente espresse in unità di misura disomogenee (es. microsecondi vs. byte/s), vengono mappate sullo stesso asse adimensionale espresso in deviazioni standard dal sorgente, consentendone l'affiancamento visivo su scale omogenee;

3. **Calibrazione stabile della Bandwidth (h_{KDE}):** la condivisione dello spazio adimensionale ($z \sim \mathcal{N}(0, 1)$ sul dominio sorgente) stabilizza l'ottimizzazione della larghezza di banda del kernel h_{KDE} , prevenendo fenomeni di *undersmoothing* (una banda eccessivamente stretta, che produce una curva frastagliata e sovra-adattata al singolo campione osservato) o di *oversmoothing* selettivo (una banda eccessivamente ampia, che appiattisce dettagli distributivi rilevanti) tra variabili a diversa varianza grezza.

Sia $z \in \mathbb{R}$ la variabile standardizzata derivata tramite l'Equazione (3.40) per una singola caratteristica del sottoinsieme SHAP. Coerentemente con la natura dicotomica delle decisioni dei sistemi NIDS, i dati vengono raggruppati secondo l'etichetta binaria $Y \in \mathcal{Y} = \{0, 1\}$ (traffico lecito vs. malevolo). La stima marginale di densità continua $\hat{f}_y(z)$ per la classe $Y = y$ calcolata su N_y campioni è definita da:

$$\hat{f}_y(z) = \frac{1}{N_y h_{\text{KDE}}} \sum_{i=1}^{N_y} \kappa\left(\frac{z - z_{i,y}}{h_{\text{KDE}}}\right) \quad (3.42)$$

dove h_{KDE} è il parametro di liscio (*bandwidth*), da non confondersi con la trasformazione monotonica h_j della Sezione 3.2.3, e $\kappa(\cdot)$ è la funzione kernel, per la quale si adotta la forma gaussiana standard¹⁸:

$$\kappa(u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{u^2}{2}\right) \quad (3.43)$$

Compensazione dello Squilibrio di Classe tramite Scala Logaritmica

Per contrastare lo schiacciamento visivo della classe minoritaria derivante dal forte sbilanciamento cardinale ($P(Y = 0) \gg P(Y = 1)$ o viceversa nei vari benchmark), i valori di densità stimata $\hat{f}_y(z)$ vengono proiettati su scala logaritmica in base 10:

$$\hat{f}_{y,\log}(z) = \log_{10}\left(\hat{f}_y(z) + \epsilon\right) \quad (3.44)$$

dove $\epsilon > 0$ è una costante infinitesima di stabilizzazione numerica. La rappresentazione logaritmica permette di ispezionare visivamente le code delle distribuzioni e le micro-aree di sovrapposizione ad alta incertezza, fornendo supporto analitico alla comprensione dei falsi positivi al variare della soglia decisionale τ .

¹⁸Il simbolo $\kappa(\cdot)$, anziché la più comune notazione $K(\cdot)$, è adottato per evitare ambiguità con la cardinalità K dell'insieme dei seed stocastici $\mathcal{S}$ introdotta nella Sezione 3.3.1.

Il ruolo e l'impatto della standardizzazione dipendente dal sorgente sulle diverse componenti diagnostiche del framework sono sintetizzati nella Tabella 3.10.

Tabella 3.10: Sintesi del ruolo e dell'impatto della standardizzazione dipendente dal sorgente (μ_S, σ_S) sulle componenti diagnostiche del framework.

Strumento	Natura del Requisito	Impatto Tecnico e Motivazione Metodologica
Classificatori (Tree-Based)	Nessuno (Nessuna Trasformazione)	Invarianza Monotonica: gli algoritmi basati su albero operano su ordinamenti relativi dei dati. Nessun impatto sulle metriche di accuratezza.
Proiezioni Latenti (PCA)	Matematicamente Indispensabile	Prevenzione della Dominanza delle Scale: la matrice di covarianza Σ_D richiede unità adimensionali; in caso contrario, le componenti principali catturano solo la scala numerica grezza più ampia.
Stima di Densità (KDE)	Metodologico e Visivo	Preservazione del Shift e Omogeneità: non altera la forma intrinseca della stima 1D, ma rende visibile lo spostamento di media dal sorgente $z = 0$, rende i grafici affiancati comparabili e stabilizza la <i>bandwidth</i> h_{KDE} .

3.4.2 Spiegabilità e Attribuzione delle Feature

Allo scopo di decodificare le logiche decisionali dei classificatori *black-box* e isolare le caratteristiche dello spazio condiviso $\mathcal{X}$ che governano la stima della probabilità a posteriori al variare dei

domini, il framework integra un impianto di interpretabilità basato su SHAP (*SHapley Additive exPlanations*) [20]. Tale approccio, fondato sui rigorosi principi della teoria dei giochi cooperativi [29], consente di quantificare analiticamente il contributo marginale esatto di ciascuna variabile vettoriale alla stima predittiva locale.

Formulazione Teorica dei Valori di Shapley e Proprietà Assiomatiche

Nella teoria dei giochi, il valore di Shapley definisce un metodo per distribuire equamente un "guadagno" totale tra un insieme di giocatori cooperanti. Nel contesto dell'apprendimento supervisionato formalizzato dal framework, il "gioco" corrisponde alla funzione decisionale parametrica $f_{\theta^*}(\mathbf{x})$, e i "giocatori" coincidono con le caratteristiche in ingresso.

Sia $\mathcal{F}$ l'insieme totale delle caratteristiche a disposizione del modello (con $|\mathcal{F}| = d$) e $C \subseteq \mathcal{F}$ un generico sottoinsieme (coalizione) di esse. Definita $v(C)$ la funzione di valore che esprime l'output atteso del modello condizionato al solo sottoinsieme C ¹⁹, il valore di Shapley $\phi_j(\mathbf{x})$ per la j -esima caratteristica del singolo vettore $\mathbf{x} \in \mathcal{X}$ è calcolato come:

$$\phi_j(\mathbf{x}) = \sum_{C \subseteq \mathcal{F} \setminus \{j\}} \frac{|C|!(|\mathcal{F}| - |C| - 1)!}{|\mathcal{F}|!} [v(C \cup \{j\}) - v(C)] \quad (3.45)$$

La robustezza di SHAP e la sua superiorità metodologica rispetto a metriche di impurità alternative risiedono nel soddisfacimento di quattro assiomi matematici fondamentali²⁰:

1. **Efficienza Locale (Additività):** la somma dei valori SHAP di tutte le caratteristiche eguaglia la differenza tra la predizione per lo specifico vettore $\mathbf{x}$ e la predizione media del modello (baseline). Ovvero: $f_{\theta^*}(\mathbf{x}) = \phi_0 + \sum_{j=1}^d \phi_j(\mathbf{x})$.
2. **Simmetria:** se due caratteristiche i e j apportano il medesimo contributo marginale a ogni possibile sottoinsieme C , i loro valori SHAP risultano algebricamente identici ($\phi_i = \phi_j$).

¹⁹In un contesto applicativo di apprendimento automatico, tale funzione coincide con il valore atteso condizionato della stima parametrica, ovvero $v(C) = \mathbb{E}[f_{\theta^*}(\mathbf{x}) \mid \mathbf{x}_C]$.

²⁰L'aderenza a questi assiomi garantisce che l'importanza delle *feature* sia equa e non soggetta a paradossi di attribuzione tipici delle metriche puramente empiriche.

3. **Giocatore Nullo (Missingness):** una caratteristica che non altera mai la predizione, indipendentemente dal sottoinsieme di attributi a cui viene aggiunta, possiede un valore SHAP rigorosamente pari a zero.
4. **Coerenza:** se un modello viene modificato in modo tale che il contributo marginale di una caratteristica aumenti (o rimanga invariato), il relativo valore SHAP non può diminuire.

TreeSHAP e Ottimizzazione Algoritmica

Dal punto di vista algoritmico, l'estrazione dei valori ϕ_j è condotta tramite un'ottimizzazione basata sulla struttura interna degli stimatori. Considerata l'architettura dei classificatori impiegati, basati sul partizionamento ricorsivo dello spazio (e.g., *Random Forest*, *Histogram-based Gradient Boosting*), la metodologia sfrutta l'algoritmo *TreeSHAP* [21]²¹.

Per garantire la stabilità statistica delle stime limitando contestualmente l'overhead computazionale, la spiegazione locale viene calcolata su un sottoinsieme $\mathcal{D}_{\text{sample}}^{(\text{test})} \subset \mathcal{D}^{(\text{test})}$, estratto mediante campionamento stratificato. Tale campionamento preserva inalterato il vincolo di proporzionamento parametrico ρ originario tra il traffico nominale ($Y = 0$) e il traffico malevolo ($Y = 1$).

L'output dell'operazione consiste in matrici ad alta dimensionalità contenenti i valori ϕ_j . Limitando l'analisi al dominio di classificazione binario e alla classe malevola ($Y = 1$), tali valori esprimono l'impatto sul margine non normalizzato del modello (es. *log-odds*) e vengono resi interpretabili attraverso proiezioni a dispersione (*summary dot plot*). In tali costrutti visivi, la posizione sull'asse orizzontale quantifica il valore SHAP (intensità e direzione dell'impatto decisionale), mentre lo spettro cromatico codifica il valore quantitativo grezzo della caratteristica, consentendo di individuare relazioni dirette o inverse tra le metriche trasmissive e l'etichetta di intrusione.

Aggregazione Trasversale e Selezione per l'Analisi Densometrica

I risultati prodotti da SHAP a livello locale per ciascuna configurazione di benchmark sono stati impiegati per alimentare l'indagine densometrica trasversale descritta nella Sezione 3.4.1. A tal

²¹*TreeSHAP* [21] abbatte la complessità computazionale del calcolo esatto dei valori di Shapley da esponenziale $O(2^{|\mathcal{F}|})$ a polinomiale $O(TLD^2)$, dove T è il numero di alberi dell'ensemble, L il numero massimo di foglie e D la profondità massima.

fine, è stata definita una metrica di aggregazione progettata per estrarre le tre dimensioni dello spazio $\mathcal{X}$ globalmente più influenti.

Per ogni generico benchmark di test $D \in \mathcal{B}$, le caratteristiche vengono inizialmente ordinate in senso decrescente in base alla loro importanza media assoluta $I_j^{(D)}$:

$$I_j^{(D)} = \frac{1}{N} \sum_{i=1}^N |\phi_j(\mathbf{x}_i^{(D)})| \quad (3.46)$$

dove $N = |\mathcal{D}_{\text{sample}}^{(\text{test})}|$ rappresenta la cardinalità del sottoinsieme campionato estratto in precedenza, e non l'intero dataset a disposizione.

Sia $\mathcal{T}_D \subset \mathcal{F}$ l'insieme contenente le prime tre caratteristiche classificate nel benchmark D . Per identificare i descrittori maggiormente resilienti e discriminanti ai confini tra domini $\mathcal{D}_S$ e $\mathcal{D}_T$, si definisce un contatore di frequenza globale C_j :

$$C_j = \sum_{D \in \mathcal{B}} \mathbb{I}(j \in \mathcal{T}_D) \quad (3.47)$$

dove $\mathbb{I}(\cdot)$ è la funzione indicatrice che assume valore 1 se la caratteristica j figura nella *top-3* dello scenario D , e 0 altrimenti. Le tre dimensioni vettoriali associate ai valori massimi di C_j al termine di tutte le combinazioni di addestramento e inferenza costituiscono il nucleo stabile informativo utilizzato per tracciare le curve KDE precedentemente illustrate. Questo processo di selezione garantisce che la valutazione del *domain shift* si concentri unicamente sulle proiezioni spaziali che i modelli considerano universalmente più critiche per l'isolamento delle anomalie.

3.4.3 Metriche, Soglia e Significatività dei Confronti

Per valutare analiticamente le prestazioni dei modelli di classificazione formalizzati nella sezione precedente e quantificare l'impatto del *domain shift*, si definisce un framework di valutazione fondato sulla teoria della decisione statistica. In particolare, si distingue la valutazione puntuale delle prestazioni, riferita a una specifica soglia decisionale, dall'analisi del comportamento discriminativo del classificatore al variare della soglia di decisione.

Formalizzazione della Matrice di Confusione

Richiamando la regola di decisione parametrica introdotta nella Sezione 3.2.1, la classe predetta $\hat{y}_i(\tau)$ consente di definire le cardinalità della matrice di confusione, espresse come funzioni della soglia decisionale τ :

$$TP(\tau) = \sum_{i=1}^N \mathbb{I}(y_i = 1 \wedge \hat{y}_i(\tau) = 1) \quad (3.48)$$

$$FP(\tau) = \sum_{i=1}^N \mathbb{I}(y_i = 0 \wedge \hat{y}_i(\tau) = 1) \quad (3.49)$$

$$TN(\tau) = \sum_{i=1}^N \mathbb{I}(y_i = 0 \wedge \hat{y}_i(\tau) = 0) \quad (3.50)$$

$$FN(\tau) = \sum_{i=1}^N \mathbb{I}(y_i = 1 \wedge \hat{y}_i(\tau) = 0) \quad (3.51)$$

Le quattro quantità rappresentano rispettivamente il numero di veri positivi, falsi positivi, veri negativi e falsi negativi prodotti dal classificatore per una determinata soglia decisionale.

Tabella 3.11: Struttura della Matrice di Confusione parametrizzata rispetto alla soglia decisionale τ .

Classe Predetta ($\hat{y}(\tau)$) $\times$ Classe Reale (y)	Positivo ($y = 1$)	Negativo ($y = 0$)
Positivo ($\hat{y} = 1$)	True Positive ($TP(\tau)$)	False Positive ($FP(\tau)$)
Negativo ($\hat{y} = 0$)	False Negative ($FN(\tau)$)	True Negative ($TN(\tau)$)




Figura 3.8: Mappatura della probabilità a posteriori $f(\mathbf{x})$ sulla regola decisionale binaria $\hat{y}(\tau)$ in funzione della soglia τ .

Formalizzazione delle Metriche Derivate

Per rendere la valutazione indipendente dalla numerosità del campione di test, si introducono i principali tassi relativi derivati dalla matrice di confusione [9]:

$$TPR(\tau) = \frac{TP(\tau)}{TP(\tau) + FN(\tau)}, \quad FPR(\tau) = \frac{FP(\tau)}{FP(\tau) + TN(\tau)} \quad (3.52)$$

cui corrispondono i rispettivi complementari

$$\begin{aligned} FNR(\tau) &= 1 - TPR(\tau) & TNR(\tau) &= 1 - FPR(\tau) \\ &= \frac{FN(\tau)}{TP(\tau) + FN(\tau)}, & &= \frac{TN(\tau)}{TN(\tau) + FP(\tau)}. \end{aligned} \quad (3.53)$$

L'affidabilità delle segnalazioni generate dal classificatore è invece misurata dalla *Precision*:

$$Precision(\tau) = \frac{TP(\tau)}{TP(\tau) + FP(\tau)} \quad (3.54)$$

Per sintetizzare il compromesso tra capacità di rilevamento degli attacchi e contenimento dei falsi allarmi si utilizza l'*F1-score*, definito come media armonica tra Precision e Recall²²:

²²Nei sistemi NIDS la media armonica è preferita alla media aritmetica poiché penalizza maggiormente modelli caratterizzati da un forte sbilanciamento tra sensibilità agli attacchi e precisione delle segnalazioni.

$$F_1(\tau) = 2 \cdot \frac{Precision(\tau) \cdot TPR(\tau)}{Precision(\tau) + TPR(\tau)} \quad (3.55)$$

Infine, l'*Accuracy* rappresenta la proporzione complessiva di classificazioni corrette:

$$Accuracy(\tau) = \frac{TP(\tau) + TN(\tau)}{N} \quad (3.56)$$

Tale indicatore assume tuttavia un ruolo secondario nei problemi di intrusion detection, poiché non risulta sufficientemente informativo in presenza di distribuzioni fortemente sbilanciate tra traffico nominale e traffico malevolo.

Dinamica della Soglia e Analisi Grafica (ROC e PR AUC)

La valutazione puntuale delle metriche presuppone la scelta di uno specifico valore della soglia decisionale (ad esempio $\tau = 0.5$). Una caratterizzazione più completa del comportamento discriminativo del classificatore richiede invece l'analisi dell'intero intervallo di valori della soglia, $\tau \in [0, 1]$.

A tale scopo si impiegano le curve *Receiver Operating Characteristic* (ROC) e *Precision–Recall* (PR), sintetizzate mediante l'area sottesa alla rispettiva curva (*Area Under the Curve*, AUC):

$$AUC_{ROC} = \int_0^1 TPR d(FPR), \quad AUC_{PR} = \int_0^1 Precision d(TPR) \quad (3.57)$$




Figura 3.9: Rappresentazione schematica dell'Area Sottesa alla Curva (AUC) per le analisi grafiche ROC (a) e Precision-Recall (b).

L'indice AUC_{ROC} fornisce una misura della capacità discriminativa complessiva del classificatore, mentre AUC_{PR} risulta particolarmente indicato nei sistemi NIDS, dove la forte prevalenza del traffico legittimo rende più significativa la valutazione del compromesso tra Precision e Recall [28].

Degrado Prestazionale e Significatività Statistica (Welch's t-test)

Il trasferimento di un modello tra domini caratterizzati da differenti distribuzioni marginali delle caratteristiche $P(\mathbf{x})$ (*covariate shift*) può determinare una degradazione delle prestazioni di classificazione [24]. Tale variazione dell'efficacia discriminativa di un modello M , valutato sul dominio sorgente $\mathcal{D}_S$ e sul dominio target $\mathcal{D}_T$, può essere espressa come

$$\Delta F_1 = F_1(M, \mathcal{D}_S) - F_1(M, \mathcal{D}_T). \quad (3.58)$$

Per valutare la significatività statistica delle differenze prestazionali tra modelli differenti, oppure tra un modello e una baseline di riferimento, si adotta il test t di Welch, appropriato nel caso di campioni indipendenti con varianze non necessariamente uguali. Date due distribuzioni campionarie della metrica di interesse, caratterizzate da medie $\bar{x}_1, \bar{x}_2$, varianze s_1^2, s_2^2 e numerosità n_1, n_2 , la statistica del test è definita da

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}. \quad (3.59)$$

I corrispondenti gradi di libertà effettivi sono stimati mediante l'approssimazione di Welch–Satterthwaite:

$$\nu \approx \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{(s_1^2/n_1)^2}{n_1-1} + \frac{(s_2^2/n_2)^2}{n_2-1}}. \quad (3.60)$$

L'ipotesi nulla di uguaglianza delle medie,

$$H_0 : \mu_1 = \mu_2,$$

viene respinta qualora il valore p associato alla statistica t risulti inferiore al livello di significatività prefissato α (tipicamente $\alpha = 0.05$), indicando che la differenza prestazionale osservata è statisticamente significativa e non può essere ragionevolmente attribuita al solo errore campionario.

3.5 Sintesi del Capitolo e Raccordo con la Campagna

Sperimentale

L'impalcatura teorica e metodologica formalizzata nel presente capitolo definisce un modello astratto e rigoroso per la valutazione dei sistemi NIDS soggetti a *domain shift*. Attraverso l'allineamento degli spazi delle *feature*, la formalizzazione dei modelli di classificazione (aggregati e specialistici) e la definizione di un protocollo stocastico fondato su valutazioni *multi-seed* e test di significatività, il framework garantisce l'isolamento dei reali contributi algoritmici dal rumore di misura.

Tuttavia, la validità dei vincoli analitici e delle proprietà di invarianza descritte richiede un riscontro quantitativo su scenari operativi concreti. Nel Capitolo 4, il framework teorico viene pertanto istanziato ed eseguito empiricamente. Verranno presentati la caratterizzazione dei dataset di traffico reale, il setup infrastrutturale di addestramento e la discussione critica dei risultati ottenuti, valutando le capacità di generalizzazione e le prestazioni dei modelli al variare dei contesti di rete.

4. Implementazione del Framework Metodologico

Il presente capitolo traduce l'impalcatura teorica e il framework metodologico, definiti nel capitolo precedente, in una configurazione sperimentale concreta e riproducibile. L'obiettivo primario risiede nel dettagliare l'istanziamento software, le scelte architetturelle e i protocolli operativi impiegati per l'addestramento e la valutazione dei sistemi di *Network Intrusion Detection* (NIDS), rimanendo esplicitamente l'analisi dei risultati empirici e delle metriche prestazionali al Capitolo 5. Questa trasposizione materiale garantisce la totale trasparenza tecnologica e fornisce gli strumenti implementativi necessari per quantificare oggettivamente i fenomeni di *domain shift*.

La trattazione si articola secondo una progressione logica suddivisa in sette sezioni principali:

- La **Sezione 4.1** descrive l'ambiente sperimentale, dettagliando l'organizzazione modulare della repository software, lo stack tecnologico adottato e i rigorosi meccanismi di isolamento per la gestione della riproducibilità stocastica.
- La **Sezione 4.2** analizza le fonti di dati originarie, definendo la caratterizzazione del dominio sorgente e dei segmenti di destinazione, per poi formalizzare la parametrizzazione che guida la composizione fisica dei benchmark aggregati e ristretti.
- La **Sezione 4.3** illustra la pipeline di pre-elaborazione, declinando operativamente l'operatore di mappatura per l'allineamento degli spazi delle *feature* e giustificando la scelta architetturelle di omettere la scalatura esplicita globale.
- La **Sezione 4.4** dettaglia l'infrastruttura di classificazione supervisionata, specificando gli algoritmi di base, la configurazione degli iperparametri e le logiche di istanziamento dei modelli aggregati e biclasse.
- La **Sezione 4.5** completa la descrizione del framework operativo definendo l'orchestrazione gerarchica del ciclo di addestramento *multi-seed*, le procedure di inferenza sugli insiemi di collaudo e le logiche costruttive delle matrici di valutazione.

- La **Sezione 4.6** formalizza l'implementazione degli strumenti diagnostici e di spiegabilità, integrando le proiezioni PCA, le stime di densità KDE con ancoraggio al sorgente e l'infrastruttura TreeSHAP per l'interpretazione dei modelli ad albero.
- Infine, la **Sezione 4.7** fornisce la sintesi dell'architettura software end-to-end, illustrando la separazione funzionale tra il flusso computazionale principale di addestramento/valutazione e il ramo diagnostico.

4.1 Ambiente Sperimentale e Riproducibilità

Al fine di garantire la totale trasparenza e la riproducibilità end-to-end degli esperimenti, la presente sezione dettaglia la struttura della repository software, le dipendenze tecnologiche impiegate e i meccanismi di controllo dell'aleatorietà stocastica.

4.1.1 Repository e Organizzazione del Codice

L'intera architettura software sviluppata è stata resa pubblicamente accessibile su piattaforma GitHub¹. Il progetto, distribuito sotto licenza open-source MIT alla versione v4.0.0, è organizzato secondo una struttura modulare concepita per disaccoppiare la logica di pre-elaborazione dei dati, la definizione dei modelli, l'esecuzione della suite sperimentale e la produzione degli artefatti documentali.

La gerarchia fondamentale delle directory, illustrata nella Figura 4.1, si articola nei seguenti moduli principali:

- `src/`: racchiude il core logico dell'applicazione, integrando i moduli di pre-elaborazione (`data_preprocessing.py`), definizione dei classificatori (`models.py`), esecuzione delle procedure di classificazione (`classification.py`) e generazione grafica (`plotting.py`). La sotto-cartella `utils/` gestisce le configurazioni di sistema (`config.py`), l'I/O su disco (`file_utils.py`) e la formalizzazione delle metriche (`metrics.py`).
- `data/`: destinata alla memorizzazione dei dataset nello stato successivo alle fasi di pulizia e trasformazione (`preprocessed/`) unitamente ai relativi metadati.

¹<https://github.com/marchesinia187179/earth-trained-satellite-ids>

- `runs/`: ambiente di persistenza strutturato per tipologia di modello usato per il confronto con la baseline (es. `hybrid_models/`, `nb15_models/`) e scomposizione per seme stocastico. Ogni cartella raccoglie gli artefatti serializzati dei modelli (`models/`), le misurazioni grezze (`results/`) e i prodotti delle analisi di significatività statistica (es. test t di Welch e mappe di calore).
- `doc/`: contiene i sorgenti $\text{\LaTeX}$ e le risorse grafiche della documentazione scientifica.




Figura 4.1: Rappresentazione schematica della gerarchia delle directory del progetto e delle risorse generate a runtime.

L'esecuzione dell'infrastruttura non richiede configurazioni manuali complesse. L'avvio del

punto di ingresso principale (`main.py`), previa installazione delle dipendenze dichiarate nel file di testo `requirement.txt`, attiva un'interfaccia a riga di comando (CLI) interattiva. Tale interfaccia guida l'operatore attraverso le fasi di preparazione dei dati, addestramento multi-seed e generazione delle analisi comparative.

4.1.2 Stack Tecnologico e Dipendenze

L'infrastruttura software è stata sviluppata adottando l'interprete Python (v3.14.4) quale ambiente di esecuzione. Per isolare il runtime e prevenire conflitti con librerie di sistema, le dipendenze sono state gestite in un ambiente virtuale dedicato tramite il modulo nativo `venv`.

Le librerie e i pacchetti impiegati per la manipolazione dati, l'addestramento dei modelli e le verifiche statistiche sono riassunti nella Tabella 4.1.

Tabella 4.1: Stack tecnologico, librerie e relative versioni vincolate nell'ambiente di runtime.

Libreria	Versione	Scopo Applicativo
Python ²	3.14.4	Ambiente di esecuzione e interprete base
pandas ³	3.0.3	Manipolazione ed elaborazione di strutture dati tabulari
numpy ⁴	2.5.1	Calcolo scientifico e operazioni vettoriali ad alte prestazioni
scikit-learn ⁵	1.9.0	Pre-elaborazione <i>feature</i> e addestramento classificatori
scipy ⁶	1.18.0	Verifiche di significatività statistica (es. test <i>t</i> di Welch)
shap ⁷	0.52.0	Calcolo dei valori Shapley per l'analisi di <i>explainability</i> (XAI)
joblib ⁸	1.5.3	Serializzazione e caricamento efficiente dei modelli su disco
matplotlib ⁹	3.11.1	Generazione di grafici e diagrammi prestazionali
seaborn ¹⁰	0.13.2	Visualizzazione avanzata e mappe di calore comparative

La suite sperimentale è stata eseguita su un calcolatore Apple MacBook Air 2020 (modello A2179), equipaggiato con un processore quad-core Intel Core i5, una GPU Intel Iris Plus Graphics e con 8 GB di memoria RAM unificata¹¹. Per azzerare l'overhead della virtualizzazione e garantire un controllo diretto sulle risorse hardware, l'esecuzione è avvenuta in ambiente nativo *dual-boot* sotto distribuzione Linux Xubuntu.

4.1.3 Gestione della Riproducibilità Stocastica

Il controllo della variabilità stocastica negli algoritmi di apprendimento automatico costituisce un requisito imprescindibile del framework. L'aleatorietà viene gestita separando nettamente la fase di preparazione deterministica del dato dall'addestramento dei classificatori.

La fase di pulizia e trasformazione del dataset originale è vincolata in modo univoco al seme stocastico primario $s_0 = 127001$. Tale vincolo assicura che la generazione dei metadati e il salvataggio dei dati pre-elaborati in `data/preprocessed/` avvengano in maniera deterministica e immutabile.

La campagna di addestramento e validazione si sviluppa invece su un insieme di $K = 10$ semi stocastici distinti:

$$S = \{0, 1, 7, 42, 101, 123, 999, 1337, 2026, 12345\} \quad (4.1)$$

L'iniezione del controllo stocastico avviene tramite l'assegnazione esplicita del parametro `random_state` nelle routine di `scikit-learn`. Per evitare contaminazioni incrociate (*cross-seed contamination*), il framework garantisce l'isolamento dei processi: ogni esecuzione riferita

²Link alla documentazione ufficiale della libreria python

³Link alla documentazione ufficiale della libreria pandas

⁴Link alla documentazione ufficiale della libreria numpy

⁵Link alla documentazione ufficiale della libreria scikit-learn

⁶Link alla documentazione ufficiale della libreria scipy

⁷Link alla documentazione ufficiale della libreria shap

⁸Link alla documentazione ufficiale della libreria joblib

⁹Link alla documentazione ufficiale della libreria matplotlib

¹⁰Link alla documentazione ufficiale della libreria seaborn

¹¹Tale configurazione impone un vincolo operativo sull'impronta mnemonica (*memory footprint*) dell'ambiente di calcolo, richiedendo un'ottimizzazione accurata delle strutture dati `pandas.DataFrame` e la profilazione dei vettori `numpy` durante la fase di allineamento e trasformazione delle feature.

a un seme $s_k \in \mathcal{S}$ opera in maniera autonoma, leggendo le risorse e scrivendo i propri artefatti esclusivamente nella directory dedicata (es. `runs/hybrid_models/rf/42/`).

4.2 Caratterizzazione dei Dataset e Composizione dei Benchmark

La presente sezione è dedicata alla traduzione dell’impianto teorico del framework, definito nel capitolo precedente, in una configurazione sperimentale concreta e riproducibile. Affinché i modelli di *Intrusion Detection* possano essere addestrati e valutati rispetto alle sfide imposte dal *domain shift*, è fondamentale istanziare fisicamente il dominio sorgente ($\mathcal{D}_S$) e i domini di destinazione ($\mathcal{D}_T$). Nelle sottosezioni seguenti verranno analizzate le fonti di dati originarie, descrivendo le tassonomie di minaccia native e le relative procedure di pulizia e normalizzazione (Sezioni 4.2.1 e 4.2.2). Infine, la Sezione 4.2.3 formalizzerà l’algoritmo di campionamento e scalatura che ha guidato l’aggregazione di tali fonti, culminando nella generazione dei benchmark fisici standardizzati su cui poggeranno le successive fasi di addestramento e classificazione.

4.2.1 Dominio Sorgente: UNSW-NB15

Il dataset UNSW-NB15 [23]¹² è stato adottato come rappresentazione concreta del dominio sorgente $\mathcal{D}_S$. Il dataset, acquisito nella sua formulazione tabulare in formato CSV, comprende inizialmente un volume complessivo di 257.673 record.

La tassonomia nativa delle minacce, indicata formalmente con $\mathcal{A}_S$, include oltre alla classe di traffico lecito (*Normal*) nove categorie di attacco: *Fuzzers*, *Analysis*, *Backdoors*, *DoS*, *Exploits*, *Generic*, *Reconnaissance*, *Shellcode* e *Worms*.

Al fine di prevenire il degrado prestazionale dei modelli di apprendimento automatico causato da un marcato sbilanciamento delle classi, è stata applicata una procedura di rimozione delle classi fortemente minoritarie (*minority removal*), in accordo con la metodologia validata in letteratura da Azar et al. [2]. In particolare, sono state eliminate quattro categorie di attacco caratterizzate da una frequenza relativa estremamente ridotta nell’insieme originario:

¹²<https://research.unsw.edu.au/projects/unsw-nb15-dataset>

- *Analysis* (1,141% delle istanze totali);
- *Backdoors* (0,996% delle istanze totali);
- *Shellcode* (0,646% delle istanze totali);
- *Worms* (0,074% delle istanze totali).

A seguito dell'eliminazione delle classi minoritarie, la volumetria complessiva del dominio sorgente si attesta a 250.982 record. La distribuzione dettagliata delle istanze per le sei classi residue è riassunta nella Tabella 4.2. Il successivo campionamento e la scalatura in funzione del parametro ρ vengono formalizzati nella Sezione 4.2.3.

Tabella 4.2: Distribuzione delle istanze del dataset UNSW-NB15 a seguito della procedura di *minority removal*.

Classe Nativa	Tipologia	Conteggio Istanze
<i>Normal</i>	Traffico Lecito	93.000
<i>Generic</i>	Attacco Malevolo	58.871
<i>Exploits</i>	Attacco Malevolo	44.525
<i>Fuzzers</i>	Attacco Malevolo	24.246
<i>DoS</i>	Attacco Malevolo	16.353
<i>Reconnaissance</i>	Attacco Malevolo	13.987
Totale		250.982

4.2.2 Domini di Destinazione: Segmento Satellitare/Terrestre STIN

I domini di destinazione $\mathcal{D}_T$ sono stati formalizzati a partire dal dataset STIN (*Satellite-Terrestrial Integrated Network*) [18]¹³, focalizzato sull'identificazione di minacce informatiche in architetture di rete e infrastrutture spaziali integrate. Acquisiti nella formulazione tabulare in formato CSV, a

¹³<https://github.com/kun9717/STIN-data-set/>

differenza del dominio sorgente $\mathcal{D}_S$, i dataset target considerati contengono esclusivamente traffico malevolo, con una totale assenza di campioni appartenenti alla classe di traffico lecito (*Normal*)¹⁴.

La caratterizzazione del target si articola su due segmenti operativi distinti:

- **Segmento Terrestre (TER20):** Rappresenta il traffico rilevato dai nodi di terra dell'infrastruttura STIN.
- **Segmento Satellitare (SAT20):** Modellizza il traffico intercettato dai vettori spaziali, precisamente quelli satellitari.

Segmento Terrestre (TER20)

Il dataset TER20 comprende originariamente 127.244 record ripartiti su dieci classi native di attacco: *Botnet*, *DDoS*, *Syn_DDoS*, *UDP_DDoS*, *Web Attack*, *Backdoor*, *LDAP_DDoS*, *MSSQL_DDoS*, *NetBIOS_DDoS* e *Portmap_DDoS*.

In linea con la metodologia di accorpamento delle classi minoritarie (*minority merge*) proposta da Azar et al. [2], le categorie con caratteristiche funzionali sovrapponibili e frequenza ridotta sono state raggruppate per preservare la significatività statistica e riflettere la tassonomia delle macro-minacce. Nello specifico:

1. Le classi *Web Attack* e *Backdoor* sono state accorpate alla classe principale *Botnet*;
2. Le sottoclassi di attacco volumetrico *LDAP_DDoS*, *MSSQL_DDoS*, *NetBIOS_DDoS* e *Portmap_DDoS* sono state fuse nella macro-categoria *DDoS*.

A seguito del processo di *minority merge*, la volumetria complessiva rimane invariata a 127.244 record, strutturata nelle quattro macro-classi risultanti riportate nella Tabella 4.3.

¹⁴La composizione asimmetrica dei dataset STIN è determinata dalla struttura del testbed di cattura originario, progettato unicamente per isolare ed etichettare flussi di attacco in scenari operativi reali. Di conseguenza, per la costruzione dei benchmark di valutazione biclasse cross-dominio, la componente di traffico benigno ($Y = 0$) viene estratta in modo coerente dal dominio sorgente UNSW-NB15, garantendo l'omogeneità del traffico lecito e preservando il rapporto di sbilanciamento prefissato ($\rho = 10$).

Tabella 4.3: Distribuzione delle istanze del dataset TER20 a seguito del processo di *minority merge*.

Macro-Classe Target ($\mathcal{A}_T$)	Classi Native Accorpate	Conteggio Istanze
<i>DDoS</i>	<i>DDoS, LDAP_DDoS, MSSQL_DDoS, NetBIOS_DDoS, Portmap_DDoS</i>	57.292
<i>Botnet</i>	<i>Botnet, Web Attack, Backdoor</i>	40.401
<i>Syn_DDoS</i>	<i>Syn_DDoS</i>	15.713
<i>UDP_DDoS</i>	<i>UDP_DDoS</i>	13.838
Totale		127.244

Segmento Satellitare (SAT20)

Il dataset SAT20 include un totale di 82.320 istanze, focalizzate in modo specifico sulle minacce dirette al segmento spaziale. La tassonomia nativa si articola esclusivamente su due vettori di attacco volumetrico: *UDP_DDoS* e *Syn_DDoS*. Vista l'assenza di classi marginali o fortemente sbilanciate, non è stata applicata alcuna procedura di *minority merge*. La distribuzione finale del segmento SAT20 è dettagliata nella Tabella 4.4.

Tabella 4.4: Distribuzione delle istanze del dataset SAT20.

Classe Target ($\mathcal{A}_T$)	Tipologia Minaccia	Conteggio Istanze
<i>UDP_DDoS</i>	Attacco Volumetrico Satellitare	43.244
<i>Syn_DDoS</i>	Attacco Volumetrico Satellitare	39.076
Totale		82.320

Per entrambi i dataset target, il successivo campionamento e la scalatura in funzione del parametro ρ vengono formalizzati nella Sezione 4.2.3.

4.2.3 Parametrizzazione e Istanziamento dei Benchmark

Al fine di garantire un confronto rigoroso, equo e immune da bias legati alle fluttuazioni nella cardinalità dei dati tra i diversi scenari di test, la costruzione materiale dei benchmark fisici a partire

dai domini sorgente e target ($\mathcal{D}_S$ e $\mathcal{D}_T$) è stata sottoposta a un rigido vincolo di bilanciamento matematico. Il parametro di scalatura e proporzione tra classi, definito formalmente come ρ , è stato fissato a un valore numerico pari a 10. Tale configurazione (NORMAL_ANOMALY_RATIO nell'infrastruttura di codice) impone che per ogni istanza appartenente allo spazio delle etichette primarie malevole ($Y = 1$), siano presenti esattamente dieci istanze relative al traffico lecito ($Y = 0$).

Il processo di istanziazione opera mediante un campionamento stratificato senza reinserimento (*without-replacement stratified sampling*). Poiché l'operatore di cardinalità applicato alla componente benevola del dominio sorgente restituisce $N(\mathbf{x} \in \mathcal{D}_S \mid Y = 0) = 93.000$ record, l'algoritmo vincola l'estrazione della componente anomala a esattamente 9.300 istanze complessive per ciascun benchmark. La partizione dei domini in insiemi di addestramento e collaudo ($\mathcal{D}_k^{(train)}$ e $\mathcal{D}_k^{(test)}$) è mantenuta costante attraverso uno *split* dell'80% per il training e del 20% per il test.

La realizzazione pratica del vincolo di bilanciamento $\rho = 10$ e del campionamento senza reinserimento è affidata alle routine ausiliarie implementate nel modulo `file_preprocessing.py`.

In particolare, la funzione `_get_correct_normal_and_anomaly_data_samples` valuta le cardinalità relative delle componenti lecite e anomale, determinando dinamicamente il volume di campioni da estrarre per rispettare la costante `MLConstants.NORMAL_ANOMALY_RATIO`. Successivamente, la funzione `_safe_stratified_sample` garantisce che il campionamento mantenga inalterata la proporzione originaria tra le partizioni di addestramento e collaudo (`split_type`), prevenendo fenomeni di sbilanciamento tra i sotto-insiemi *train* e *test*.

Codice 4.1: Routine di campionamento per l'istanziazione dei benchmark.

```

1 def _get_correct_normal_and_anomaly_data_samples(normal_data, anomaly_data,
2                                                  normal_samples, anomaly_samples):
3     # Calcola il corretto numero di campioni da estrarre dalle distribuzioni
4     if normal_samples < anomaly_samples * MLConstants.NORMAL_ANOMALY_RATIO:
5         n_anomaly_target = int(
6             normal_samples / MLConstants.NORMAL_ANOMALY_RATIO
7         )
8         anomaly_data_sample = _safe_stratified_sample(
9             anomaly_data, n_anomaly_target
10        )
11        normal_data_sample = normal_data
12    else:

```

```
13     n_normal_target = int(  
14         anomaly_samples * MLConstants.NORMAL_ANOMALY_RATIO  
15     )  
16     normal_data_sample = _safe_stratified_sample(  
17         normal_data, n_normal_target  
18     )  
19     anomaly_data_sample = anomaly_data  
20  
21     return normal_data_sample, anomaly_data_sample
```

Codice 4.2: Routine di bilanciamento stratificato per l'istanziamento dei benchmark.

```
1 def _safe_stratified_sample(data, n_samples):
2     # Se la colonna 'split_type' non è presente,
3     # esegue un campionamento casuale semplice
4     if 'split_type' not in data.columns:
5         return data.sample(n=n_samples, random_state=MLConstants.MAIN_SEED)
6
7     # Suddivide il dataset in partizioni di train e test
8     data_train = data[data['split_type'] == 'train']
9     data_test = data[data['split_type'] == 'test']
10
11     # Calcola la lunghezza totale del dataset
12     total_len = len(data)
13     if total_len == 0 or n_samples == 0:
14         return pd.DataFrame(columns=data.columns)
15
16     train_ratio = len(data_train) / total_len
17     n_train = round(n_samples * train_ratio)
18     n_test = n_samples - n_train
19
20     # Gestione difensiva dei limiti di capienza delle partizioni
21     if n_test > len(data_test):
22         diff = n_test - len(data_test)
23         n_test = len(data_test)
24         n_train += diff
25     elif n_train > len(data_train):
26         diff = n_train - len(data_train)
27         n_train = len(data_train)
28         n_test += diff
29
30     # Campionamento stratificato senza reinserimento
31     sampled_parts = []
32     if n_train > 0 and not data_train.empty:
33         sampled_parts.append(data_train.sample(
34             n=n_train, random_state=MLConstants.MAIN_SEED
35         ))
```



```

36     if n_test > 0 and not data_test.empty:
37         sampled_parts.append(data_test.sample(
38             n=n_test, random_state=MLConstants.MAIN_SEED
39         ))
40
41     if not sampled_parts:
42         return pd.DataFrame(columns=data.columns)
43
44     return concat_and_shuffle(sampled_parts)

```

L'applicazione di questa logica ha permesso di istanziare i dataset aggregati previsti dal framework teorico. In tutte le configurazioni, la componente benevola corrisponde invariabilmente alle distribuzioni stazionarie originarie del dominio sorgente, $P_S(\mathbf{x} \mid Y = 0)$. La differenziazione degli scenari avviene modulando la componente malevola ($Y = 1$) in funzione della famiglia di attacco esplorata ($A \in \mathcal{A}_S$ oppure $A \in \mathcal{A}_T$):

1. **Set di Iniezione di Riferimento (INJECTION):** Costituisce la baseline proposta dall'architettura ($\mathcal{M}_{base}$). Progettato per fornire un'ancora di prestazione basata su *few-shot learning*, questo set combina le minacce sorgente $P_S(\mathbf{x} \mid Y = 1, A \in \mathcal{A}_S)$ (pari a 9.271 istanze) con l'infusione controllata di una porzione altamente sparsa di traffico target $\Delta\mathcal{D}_T$. La cardinalità di tale quota di iniezione è determinata formalmente dalla relazione:

$$|\Delta\mathcal{D}_T| = \lceil N_{\text{mal},T} \times \eta_{\text{inj}} \rceil = \lceil 9.300 \times 0,003 \rceil = 29 \text{ campioni} \quad (4.2)$$

dove $N_{\text{mal},T} = 9.300$ rappresenta la popolazione anomala totale e $\eta_{\text{inj}} = 0,3\%$ la percentuale di iniezione prescritta. L'operatore d'arrotondamento per eccesso ($\lceil \cdot \rceil$) garantisce il rispetto della soglia minima teorica.

2. **Set Nativo Sorgente (NB15):** Rappresenta il NIDS tradizionale ($\mathcal{M}_S$). La componente anomala ammonta a 9.300 istanze appartenenti esclusivamente alla tassonomia nativa sorgente $\mathcal{A}_S$. È impiegato per misurare analiticamente la degradazione prestazionale causata dal *domain shift* in totale assenza di adattamento al target.
3. **Set Ibridi Aggregati (NB15_SAT20, NB15_TER20, NB15_STIN):** Formulati per addestrare i modelli aggregati ibridi ($\mathcal{M}_H^{(T)}$), questi dataset istituiscono il limite teorico di rilevamento

(*upper bound*, paradigma Oracle). La componente anomala di 9.300 record è interamente governata dalle distribuzioni a priori del dominio target $P_T(\mathbf{x} \mid Y = 1, A \in \mathcal{A}_T)$, prelevate rispettivamente dal segmento spaziale (SAT20), terrestre (TER20) o dall’ecosistema olistico congiunto (STIN).

Grazie al vincolo imposto da ρ , i cinque benchmark aggregati presentano un’architettura dimensionale e un partizionamento perfettamente identici, come esposto nella Tabella 4.5. Tale standardizzazione volumetrica neutralizza il rischio di divergenze prestazionali derivanti dalle variazioni della mole campionaria.

Tabella 4.5: Riepilogo delle cardinalità finali per i benchmark aggregati.

Benchmark	Istanze Normali <i>Normal $Y = 0$</i>	Istanze Anomale <i>$Y = 1$</i>	Totale Istanze	Training Set <i>(80%)</i>	Test Set <i>(20%)</i>
INJECTION (Baseline)	93.000	9.300	102.300	81.840	20.460
NB15	93.000	9.300	102.300	81.840	20.460
NB15_SAT20	93.000	9.300	102.300	81.840	20.460
NB15_TER20	93.000	9.300	102.300	81.840	20.460
NB15_STIN	93.000	9.300	102.300	81.840	20.460

Infine, a partire dai macro-dataset aggregati e scalati finora descritti, la pipeline di pre-elaborazione procede alla derivazione sistematica dei Set Nativi Sorgente Biclasse e dei Set Ibridi Biclasse. Tramite un filtraggio a livello di etichetta secondaria $A = a$, le singole famiglie di minaccia (es. $a \in \mathcal{A}_S$ per NB15 o $a \in \mathcal{A}_T$ per STIN) vengono isolate e combinate esclusivamente con la baseline nativa lecita $P_S(\mathbf{x} \mid Y = 0)$. Questi dataset ristretti risultano indispensabili per l’addestramento dei rilevatori specialistici ($\mathcal{M}_{S,a}$ e $\mathcal{M}_{H,T,a}$), consentendo di valutare la sensibilità del sistema verso singole tipologie di attacco senza incorrere nelle distorsioni intrinseche generate dalla sovrapposizione di distribuzioni anomale eterogenee.

La struttura dettagliata degli 11 benchmark biclasse così generati — 5 per il dominio sorgente NB15, 4 per il segmento terrestre TER20 e 2 per il segmento satellitare SAT20 — è sintetizzata nella Tabella 4.6. Come si evince dai dati di partizionamento, l’applicazione rigorosa del rapporto $\rho = 10$ garantisce che ciascun rilevatore specialistico ($\mathcal{M}_{S,a}$ o $\mathcal{M}_{H,T,a}$) venga addestrato su una

distribuzione uniforme composta da esattamente 93.000 campioni leciti ($Y = 0$) e 9.300 campioni malevoli ($Y = 1$) dedicati alla singola famiglia d'attacco a , mantenendo costante lo *split* 80/20 tra training (81.840 record) e test set (20.460 record).

Tabella 4.6: Prospetto sintetico della cardinalità e del partizionamento per i Set Nativi Sorgente Biclasse e Ibridi Biclasse.

Dominio	Nome Dataset Biclasse (File CSV)	Istanze Normali Normal ($Y = 0$)	Istanze Attacco Classe a ($Y = 1$)	Totale Istanze	Train Set (80%)	Test Set (20%)
<i>Set Nativi Sorgente Biclasse</i>						
NB15	Normal_Generic.csv	93.000	9.300	102.300	81.840	20.460
NB15	Normal_Exploits.csv	93.000	9.300	102.300	81.840	20.460
NB15	Normal_Fuzzers.csv	93.000	9.300	102.300	81.840	20.460
NB15	Normal_DoS.csv	93.000	9.300	102.300	81.840	20.460
NB15	Normal_Reconnaissance.csv	93.000	9.300	102.300	81.840	20.460
<i>Set Ibridi Biclasse Terrestri</i>						
TER20	Normal_DDoS.csv	93.000	9.300	102.300	81.840	20.460
TER20	Normal_Botnet.csv	93.000	9.300	102.300	81.840	20.460
TER20	Normal_Syn_DDoS.csv	93.000	9.300	102.300	81.840	20.460
TER20	Normal_UDP_DDoS.csv	93.000	9.300	102.300	81.840	20.460
<i>Set Ibridi Biclasse Satellitari</i>						
SAT20	Normal_UDP_DDoS.csv	93.000	9.300	102.300	81.840	20.460
SAT20	Normal_Syn_DDoS.csv	93.000	9.300	102.300	81.840	20.460




Figura 4.2: Diagramma di flusso del processo di estrazione, pulizia, campionamento vincolato ($\rho = 10$) e partizionamento stratificato 80/20 per la generazione dei benchmark fisici aggregati e biclasse.

4.3 Allineamento delle Feature e Pipeline di Preprocessing

La presente sezione illustra l'istanziatura concreta e l'architettura software dell'operatore di mappatura $\psi_k : \mathcal{X}_k \rightarrow \mathcal{X}_{\text{shared}}$, formalizzato sul piano teorico nella Sezione 3.1.2. L'obiettivo primario della pipeline di preprocessing consiste nel colmare il divario strutturale e semantico esistente tra le rappresentazioni grezze del dominio sorgente ($\mathcal{D}_S$, basato su UNSW-NB15) e dei domini di

destinazione ($\mathcal{D}_T$, articolato sulle catture STIN TER20 e SAT20), proiettando i rispettivi spazi delle feature in uno spazio coordinato condiviso, omogeneo e privo di distorsioni di tracciamento.

L'architettura generale del flusso di elaborazione e la sua ripartizione in stadi sequenziali sono schematizzate nella Figura 4.3. La pipeline si sviluppa lungo tre fasi principali: un filtraggio preliminare per la rigida eliminazione di attributi non trasferibili o ridondanti, l'applicazione delle trasformazioni algebriche e analitiche definite dall'operatore ψ_k , e la strutturazione della tabella coordinata finale composta da $d = 16$ feature predittive continue e 3 variabili di controllo. Nelle sottosezioni seguenti vengono analizzati nel dettaglio i singoli criteri di selezione, la formulazione analitica delle trasformazioni e le proprietà di invarianza del grafo computazionale risultante.

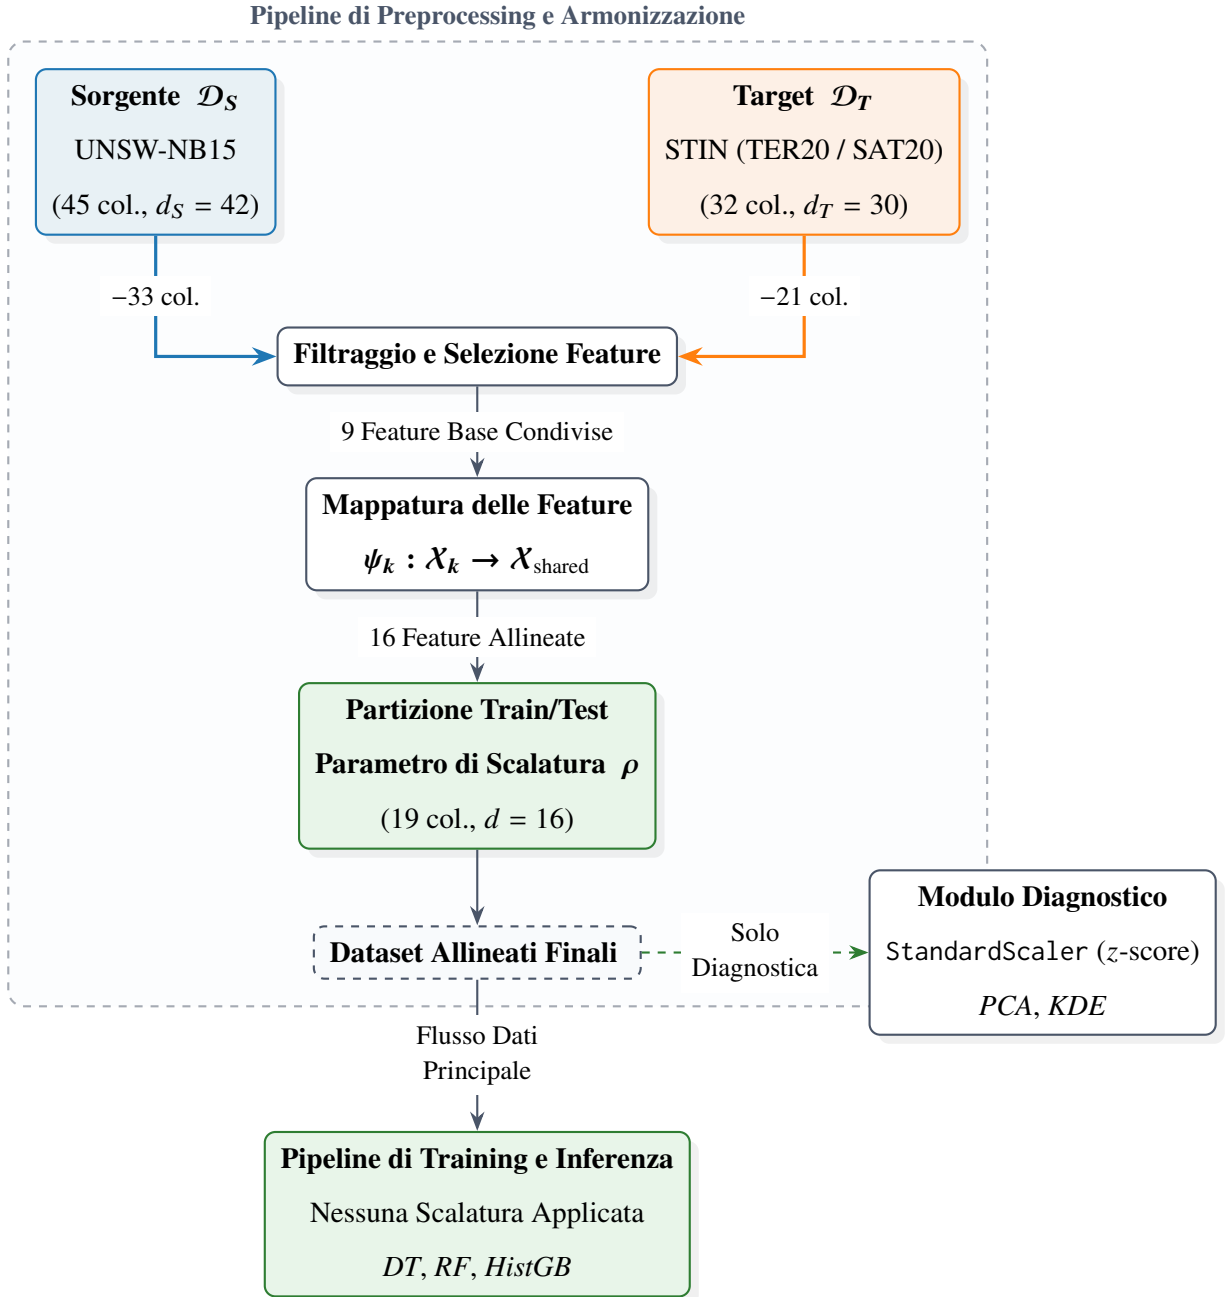


Figura 4.3: Diagramma di flusso della pipeline di preprocessing e armonizzazione tra il dominio sorgente $\mathcal{D}_S$ e i domini target $\mathcal{D}_T$, dall'estrazione delle feature grezze alla generazione dello spazio coordinato finale a 16 dimensioni.

4.3.1 Feature Grezze e Criteri di Filtraggio Applicati

La fase preliminare della pipeline di preprocessing è volta ad allineare gli spazi delle feature originariamente eterogenei del dominio sorgente $\mathcal{D}_S$ (UNSW-NB15) e dei domini di destinazione $\mathcal{D}_T$ (STIN, declinato in TER20 e SAT20). Il dataset sorgente si articola originariamente su un vettore di $d_S = 42$ attributi predittivi grezzi (a cui si aggiungono l'identificatore `id` e la doppia etichettatura nativa `attack_cat` e `label`, per un totale di 45 colonne). Diversamente, le sorgenti di destinazione presentano una struttura nativa derivata da catture di flusso composta da $d_T = 30$ attributi predittivi (unitamente all'identificatore `id` e all'etichetta binaria `label`, per un totale di 32 colonne).

Per garantire l'interoperabilità e la generalizzabilità dei modelli di apprendimento automatico rispetto al *domain shift*, la selezione dello spazio delle feature condiviso d è stata regolata da tre criteri di filtraggio sequenziali:

1. **Rimozione di identificatori univoci e metadati di tracciamento:** Sia nel dominio sorgente che in quelli target, l'attributo identificativo progressivo (`id`) è stato rimosso. Tale eliminazione è indispensabile per prevenire fenomeni di correlazione spuria o *overfitting* legati all'ordinamento sequenziale delle registrazioni di rete.
2. **Criterio di non calcolabilità e assenza di corrispondenza cross-dominio:** Sono stati scartati tutti gli attributi presenti esclusivamente in una delle due sorgenti che non potevano essere matematicamente o logicamente ricostruiti a partire dai dati dell'altra, o le cui metriche sono state scartate in favore di un ricalcolo run-time per garantire la consistenza tra i domini. La classificazione dettagliata delle feature eliminate per ciascun dominio in questa fase è sintetizzata nella Tabella 4.7.

Tabella 4.7: Feature eliminate durante la fase di pre-processing nei domini sorgente e target.

Dominio	Categoria	Feature Rimosse
Sorgente ($\mathcal{D}_S$)	Protocolli Applicativi	service, trans_depth, response_body_len, is_ftp_login, ct_ftp_cmd, ct_flw_http_mthd
	Contatori Aggregati	ct_srv_src, ct_state_ttl, ct_dst_ltm, ct_src_dport_ltm, ct_dst_sport_ltm, ct_dst_src_ltm, ct_src_ltm, ct_srv_dst
	TTL e Perdita Pacchetti	sttl, dttl, sloss, dloss, is_sm_ips_ports
	Jitter, TCP e Metriche	sjit, djit, sinpkt, dinpkt, tcprtt, synack, ackdat, stcpb, dtcpb
	Metriche Ridondanti	smean, dmean, rate
Target ($\mathcal{D}_T$)	Statistiche Lunghezza	pkt_len_min, pkt_len_max, pkt_len_std, fw_hdr_len
	Flag TCP	bw_psh_flag, fw_urg_flag, bw_urg_flag, fin_cnt, syn_cnt, psh_cnt, urg_cnt, ece_cnt
	Intervalli Inter-arrivo	fl_iat_min, bw_iat_tot, bw_iat_min
	Contatori Burst	fw_byt_blk_avg, fw_pkt_blk_avg, fw_blk_rate_avg, bw_byt_blk_avg, bw_pkt_blk_avg, bw_blk_rate_avg

3. **Criterio di incompatibilità e impossibilità di armonizzazione:** Gli attributi categoriali ad alta cardinalità relativi al protocollo di trasporto (proto) e allo stato della connessione (state) presenti in UNSW-NB15 sono stati scartati. Tale scelta è stata motivata dall'assenza di attributi categoriali equivalenti nei dataset STIN e dall'impossibilità di stabilire una mappatura biunivoca senza introdurre codifiche arbitrarie che avrebbero distorto lo spazio delle feature.

A seguito dell'applicazione di tali criteri di scarto, in entrambi i domini si isola un sottoinsieme condiviso di 9 feature predittive di base. A partire da queste, mediante operazioni algebriche calcolate a tempo di esecuzione (quali somme, rapporti e differenze dirette), vengono derivate 7

ulteriori feature sintetiche (es. `total_bytes`, `pkts_per_sec`, `byte_ratio`). Si ottiene così uno spazio condiviso armonizzato finale composto da $d = 16$ feature predittive continue e quantitative.

Nei dataset pre-processati finali, a questo vettore di 16 dimensioni si affiancano 3 variabili di controllo e destinazione (`class` per la macro/micro tassonomia della minaccia, `label` per la classificazione binaria, e `split_type` per l'indicazione della partizione di addestramento o collaudo), portando la cardinalità complessiva delle tabelle a 19 colonne. La Tabella 4.8 riassume il processo logico di riduzione, derivazione e allineamento dimensionale.

Tabella 4.8: Sintesi del processo di selezione e allineamento dimensionale tra il dominio sorgente ($\mathcal{D}_S$) e i domini di destinazione ($\mathcal{D}_T$).

Dominio / Sorgente	Colonne Totali	Feature Predittive Grezze	Feature Scartate
Sorgente ($\mathcal{D}_S$)	45	$d_S = 42$	33
Target ($\mathcal{D}_T$)	32	$d_T = 30$	21
Spazio Allineato Finale	19	$d = 16$	–

4.3.2 Implementazione dell'Operatore di Mappatura

Al fine di proiettare gli spazi delle feature originari in uno spazio latente condiviso omogeneo, è stato implementato formalmente l'operatore di mappatura $\psi_k : \mathcal{X}_k \rightarrow \mathcal{X}_{\text{shared}}$, con $k \in \{S, T\}$. Tale operatore agisce sui vettori grezzi applicando trasformazioni algebriche, conversioni di unità di misura e derivazioni analitiche, garantendo la rigorosa coerenza semantica delle grandezze fisiche e di rete.

La Tabella 4.9 formalizza le trasformazioni scalari $\psi_{k,j}$ applicate a ciascuna feature condivisa j , mettendo a confronto il dominio sorgente (UNSW-NB15) e il dominio target (STIN/TER20/SAT20).

Tabella 4.9: Formulazione algebrica dell'operatore di mappatura vettoriale nei domini $\mathcal{D}_S$ e $\mathcal{D}_T$.

Feature Coordinata (x_j)	Dominio Sorgente ($\psi_{S,j}$)	Dominio Target ($\psi_{T,j}$)	Unità di Misura
duration	$dur \cdot 10^6$	fl_dur	μs
src_bytes	sbytes	l_fw_pkt	Byte
dst_bytes	dbytes	l_bw_pkt	Byte
src_pkts	spkts	fw_pk	Adimensionale
dst_pkts	dpkts	$(bw_pkt_s \cdot fl_dur)/10^6$	Adimensionale
src_win_byt	swin	fw_win_byt	Byte
dst_win_byt	dwin	bw_win_byt	Byte
load_s	$(sload + dload)/8$	fl_byt_s	Byte/s
down_up_ratio	$dpkts/(spkts + \epsilon)$	down_up_ratio	Adimensionale
total_bytes		src_bytes + dst_bytes	Byte
total_pkts		src_pkts + dst_pkts	Adimensionale
src_mean_pkt_size		$src_bytes/(src_pkts + \epsilon)$	Byte
dst_mean_pkt_size		$dst_bytes/(dst_pkts + \epsilon)$	Byte
win_diff		$src_win_byt - dst_win_byt$	Byte
byte_ratio		$dst_bytes/(src_bytes + \epsilon)$	Adimensionale
pkts_per_sec	$total_pkts/(dur + \epsilon)$	$[total_pkts/(duration + \epsilon)] \cdot 10^6$	1/s

Tabella 4.10: Descrizione semantica delle feature coordinate.

Feature Coordinata (x_j)	Descrizione
duration	Durata di esecuzione
src_bytes	Lunghezza totale dei pacchetti in direzione forward
dst_bytes	Lunghezza totale dei pacchetti in direzione backward
src_pkts	Numero totale di pacchetti in direzione forward
dst_pkts	Numero totale di pacchetti in direzione backward
src_win_byt	Lunghezza finestra iniziale in direzione forward
dst_win_byt	Lunghezza finestra iniziale in direzione backward
load_s	Throughput totale
down_up_ratio	Asimmetria dei pacchetti
total_bytes	Bytes totali
total_pkts	Pacchetti totali
src_mean_pkt_size	Dimensione media dei pacchetti in direzione forward
dst_mean_pkt_size	Dimensione media dei pacchetti in direzione backward
win_diff	Differenza di finestra
byte_ratio	Rapporto di byte
pkts_per_sec	Tasso di pacchetti per secondo

Nel processo di mappatura emergono tre aspetti architetturali critici:

- **Conversioni di Scala e Armonizzazione Temporale:** Per allineare le metriche, la durata dei flussi nel dominio sorgente è stata riscalata da secondi a microsecondi (fattore moltiplicativo 10^6). Parallelamente, il throughput nominale (sload, dload), originariamente quantificato in bit/s in UNSW-NB15, è stato convertito in Byte/s (dividendolo per 8) per coincidere con l'unità di misura nativa dei domini target.
- **Derivazione Analitica di Metriche Mancanti:** Nel dominio $\mathcal{D}_T$, il conteggio totale dei pacchetti di destinazione (dst_pkts) non è fornito in forma diretta. Per garantire la ricostruzione fedele dello spazio latente, tale grandezza è stata derivata indirettamente tramite il prodotto

analitico tra il tasso di arrivo pacchetti di ritorno (bw_pkt_s) e la durata del flusso (fl_dur), normalizzato per i microsecondi (10^6).

- **Stabilizzazione Numerica:** Durante il calcolo di indici razionali (come $down_up_ratio$, $byte_ratio$, le densità di pacchetti e il *packet rate*), è stata introdotta una costante di regolarizzazione $\epsilon = 10^{-6}$ ai denominatori. Questo accorgimento previene singolarità algebriche causate da divisioni per zero indotte da flussi anomali o malformati.

A completamento della trattazione teorica, i Listati 4.3 e 4.4 riportano l'implementazione in linguaggio Python delle funzioni `_align_nb15` e `_align_stin`. Tali funzioni costituiscono la trasposizione operativa diretta degli operatori ψ_S e ψ_T , sfruttando l'esecuzione vettorializzata su strutture dati *DataFrame* della libreria pandas per massimizzare le prestazioni computazionali su dataset ad alta dimensionalità.

Codice 4.3: Trasposizione operativa dell'operatore di mappatura ψ_k tramite vettorializzazione pandas per il dominio UNSW-NB15.

```
1 def _align_nb15(data):
2     required_columns = ['dur', 'sbytes', 'dbytes', 'spkts', 'dpkts', 'swin',
3         'dwin', 'sload', 'dload', 'sinpkt', 'dinpkt', 'attack_cat', 'label']
4     # [Controllo di sicurezza per le required_columns...]
5
6     new_df = pd.DataFrame()
7
8     # Trasposizione operativa dell'operatore di mappatura
9     new_df['duration'] = data['dur'] * 1000000
10    new_df['src_bytes'] = data['sbytes']
11    new_df['dst_bytes'] = data['dbytes']
12    new_df['src_pkts'] = data['spkts']
13    new_df['dst_pkts'] = data['dpkts']
14    new_df['src_win_byt'] = data['swin']
15    new_df['dst_win_byt'] = data['dwin']
16    new_df['load_s'] = ((data['sload'] + data['dload']) / 8)
17    new_df['down_up_ratio'] = data['dpkts'] / (data['spkts'] + 1e-6)
18    new_df['total_bytes'] = new_df['src_bytes'] + new_df['dst_bytes']
19    new_df['total_pkts'] = new_df['src_pkts'] + new_df['dst_pkts']
20    new_df['src_mean_pkt_size'] = \
21        new_df['src_bytes'] / (new_df['src_pkts'] + 1e-6)
22    new_df['dst_mean_pkt_size'] = \
23        new_df['dst_bytes'] / (new_df['dst_pkts'] + 1e-6)
24    new_df['pkts_per_sec'] = \
25        (new_df['src_pkts'] + new_df['dst_pkts']) / (data['dur'] + 1e-6)
26    new_df['win_diff'] = new_df['src_win_byt'] - new_df['dst_win_byt']
27    new_df['byte_ratio'] = new_df['dst_bytes'] / (new_df['src_bytes'] + 1e-6)
28    new_df['class'] = data['attack_cat']
29    new_df['label'] = data['label']
30
31    return new_df
```

Codice 4.4: Trasposizione operativa dell'operatore di mappatura ψ_k tramite vettorializzazione pandas per il dominio STIN.

```
1 def _align_stin(data):
2     required_columns = ['fl_dur', 'l_fw_pkt', 'l_bw_pkt', 'fw_pk',
3                         'bw_pkt_s', 'fw_win_byt', 'bw_win_byt', 'fl_byt_s',
4                         'fl_iat_min', 'down_up_ratio', 'label']
5     # [Controllo di sicurezza per le required_columns...]
6
7     new_df = pd.DataFrame()
8
9     # Trasposizione operativa dell'operatore di mappatura
10    new_df['duration'] = data['fl_dur']
11    new_df['src_bytes'] = data['l_fw_pkt']
12    new_df['dst_bytes'] = data['l_bw_pkt']
13    new_df['src_pkts'] = data['fw_pk']
14    new_df['dst_pkts'] = data['bw_pkt_s'] * data['fl_dur'] / 1000000
15    new_df['src_win_byt'] = data['fw_win_byt']
16    new_df['dst_win_byt'] = data['bw_win_byt']
17    new_df['load_s'] = data['fl_byt_s']
18    new_df['down_up_ratio'] = data['down_up_ratio']
19    new_df['total_bytes'] = new_df['src_bytes'] + new_df['dst_bytes']
20    new_df['total_pkts'] = new_df['src_pkts'] + new_df['dst_pkts']
21    new_df['src_mean_pkt_size'] = \
22        new_df['src_bytes'] / (new_df['src_pkts'] + 1e-6)
23    new_df['dst_mean_pkt_size'] = \
24        new_df['dst_bytes'] / (new_df['dst_pkts'] + 1e-6)
25    new_df['pkts_per_sec'] = ((new_df['src_pkts'] + new_df['dst_pkts']) \
26        / (new_df['duration'] + 1e-6)) * 1000000
27    new_df['win_diff'] = new_df['src_win_byt'] - new_df['dst_win_byt']
28    new_df['byte_ratio'] = new_df['dst_bytes'] / (new_df['src_bytes'] + 1e-6)
29    new_df['class'] = data['label']
30    new_df['label'] = 1
31
32    return new_df
```

4.3.3 Verifica dell'Omissione della Scalatura Esplicita

Un elemento caratterizzante dell'architettura della pipeline di preprocessing risiede nella scelta metodologica di omettere qualsiasi operazione di normalizzazione o re-scalatura globale dei dati (quali la standardizzazione z -score o il ridimensionamento Min-Max) dalle fasi di addestramento e inferenza valutativa cross-dominio.

Tale impostazione si giustifica formalmente sulla base di tre considerazioni teorico-applicative:

1. **Invarianza Monotonica dei Modelli Adottati:** Gli algoritmi di classificazione integrati nella pipeline principale comprendono *Decision Tree*, *Random Forest* e *Histogram-based Gradient Boosting*. Tali modelli determinano i punti di separazione negli iperpiani di decisione (*split points*) valutando esclusivamente le relazioni d'ordine relativo tra i valori ($x_j \leq \theta$). Essendo tali decisioni invarianti rispetto a qualsiasi trasformazione strettamente monotona, la presenza o l'assenza di scalatura lineare non altera la struttura degli alberi generati né la superficie di separazione appresa.
2. **Preservazione della Semantica Fisica e Trasparenza:** Il mantenimento degli attributi nelle rispettive unità di misura fisiche originarie e derivate (microsecondi per le durate, byte per i volumi e valori adimensionali per i rapporti) preserva la leggibilità diretta delle feature. Ciò risulta determinante per l'interpretabilità dei vettori d'attacco e per l'estrazione di spiegazioni mediante attributori di importanza (*SHAP* e *Permutation Feature Importance*).
3. **Prevenzione del Data Leakage e Invarianza nell'Inferenza:** L'eliminazione dei trasformatori di scala nel flusso di dati principale evita la necessità di stimare e congelare parametri statistici (media e deviazione standard) sul dominio sorgente $\mathcal{D}_S$ da proiettare sui domini target $\mathcal{D}_T$. In contesti di *domain shift*, la proiezione di parametri di scala estratti da sorgenti eterogenee rischia di introdurre distorsioni o anomalie numeriche dovute a valori fuori scala (*outliers*) non previsti.

Si evidenzia che l'utilizzo di algoritmi di normalizzazione è stato rigorosamente limitato alle sole procedure di diagnostica ed esplorazione delle distribuzioni, analizzate sul piano teorico nel Capitolo 3. In particolare, la classe `StandardScaler` del modulo `sklearn.preprocessing` è stata impiegata unicamente all'interno del modulo di supporto `plotting.py` per standardizzare le feature

a media nulla e varianza unitaria prima dell'esecuzione dell'Analisi delle Componenti Principali (*PCA*) e della stima della densità di kernel (*KDE*). Tali trasformazioni diagnostiche sono state isolate all'interno delle routine di visualizzazione e non sono mai state integrate nel grafo computazionale di addestramento e inferenza dei classificatori.

4.4 Implementazione dei Classificatori

La presente sezione traduce in architettura software e in moduli operativi l'impianto di classificazione supervisionata introdotto nella Sezione 3.2.3. A valle del processo di armonizzazione e allineamento dello spazio delle feature descritto nel capitolo precedente, l'infrastruttura software è progettata per istanziare, addestrare e tracciare in modo sistematico le diverse famiglie di modelli predittivi. L'obiettivo primario di questo modulo consiste nel definire una pipeline di fitting rigorosa, capace di gestire sia i classificatori basati su dataset aggregati (per la valutazione complessiva del *domain shift*) sia la suite di modelli biclasse (per l'isolamento e l'analisi granulare di minacce mirate).

Nelle sottosezioni seguenti vengono dettagliate le librerie di machine learning adottate, la configurazione degli iperparametri e la struttura dei registri di tracciamento persistenti (Sottosezione 4.4.1). Infine, le Sottosezioni 4.4.2 e 4.4.3 formalizzano le logiche procedurali e i criteri di campionamento stratificato impiegati per la generazione dei rispettivi insiemi di addestramento.

4.4.1 Algoritmi di Base e Iperparametri

L'infrastruttura di classificazione del framework è stata sviluppata in ambiente Python basandosi sulla libreria open-source `scikit-learn` (versione 1.9.0). Coerentemente con le premesse metodologiche discusse nella Sezione 3.2.3, sono state selezionate tre famiglie di algoritmi di apprendimento supervisionato basati su alberi di decisione, caratterizzate da differenti livelli di complessità strutturale e capacità espressiva:

- **Decision Tree (DT):** Classificatore a singolo albero di decisione, implementato tramite la classe `DecisionTreeClassifier`¹⁵.

¹⁵Link alla documentazione del classificatore DT

- **Random Forest (RF):** Architettura d'insieme di tipo *bagging*, implementata mediante la classe `RandomForestClassifier`¹⁶.
- **Histogram-based Gradient Boosting (HGB):** Algoritmo d'insieme di tipo *boosting* ottimizzato per dataset di grandi dimensioni, implementato tramite la classe `HistGradientBoostingClassifier`¹⁷.

Al fine di valutare la capacità intrinseca di generalizzazione cross-dominio delle diverse famiglie di modelli ed evitare fenomeni di adattamento spurio (*overfitting*) delle configurazioni alle specificità statistiche del solo dominio sorgente $\mathcal{D}_S$, non sono state applicate procedure di ricerca ed ottimizzazione automatica degli iperparametri (quali *GridSearchCV* o *RandomizedSearchCV*). Tutti i modelli sono stati pertanto istanziati mantenendo i valori di iperparametri predefiniti (*default*) forniti dall'API di `scikit-learn`.

L'unico parametro esplicitamente vincolato in fase di inizializzazione è il seme di determinismo numerico (`random_state`), il quale viene impostato in modo dinamico iterando su un pool di seed predefiniti (es. `seed = 42`) per garantire la perfetta riproducibilità statistica degli esperimenti. La Tabella 4.11 sintetizza la corrispondenza tra le classi Python adottate e la configurazione degli iperparametri operativi associati.

¹⁶Link alla documentazione del classificatore RF

¹⁷Link alla documentazione del classificatore HGB

Tabella 4.11: Configurazione degli iperparametri di default e classi `scikit-learn` utilizzate per ciascuna famiglia di classificatori.

Algoritmo	Classe <code>scikit-learn</code>	Iperparametri di Default
Decision Tree (DT)	<code>DecisionTreeClassifier</code>	<code>criterion='gini',</code> <code>max_depth=None,</code> <code>min_samples_split=2</code>
Random Forest (RF)	<code>RandomForestClassifier</code>	<code>n_estimators=100,</code> <code>criterion='gini',</code> <code>max_depth=None,</code> <code>max_features='sqrt',</code> <code>min_samples_split=2</code>
Hist. Gradient Boosting	<code>HistGradientBoostingClassifier</code>	<code>learning_rate=0.1,</code> <code>max_iter=100,</code> <code>max_depth=None,</code> <code>max_leaf_nodes=31,</code> <code>l2_regularization=0.0</code>

Per garantire un tracciamento rigoroso del ciclo di vita dei modelli, l'istanziamento e l'addestramento non disperdono lo stato interno degli stimatori. Al termine del fitting di ciascun classificatore su uno specifico dataset di addestramento (sorgente o ibrido) e per ogni seed di esecuzione, le informazioni di configurazione hardware/temporale, l'assetto completo degli iperparametri e le metriche di prestazione in-sample (*training set*) vengono persistite in modo strutturato all'interno del file di registro `models_metadata.csv`.

Tale meccanismo di tracciamento memorizza per ogni modello un record identificativo univoco, la cui struttura logica e i relativi attributi sono riepilogati nella Tabella 4.12.

Tabella 4.12: Struttura e campi del record di tracciamento persistito nel registro `models_metadata`.

Categoria Logica	Campi Registrati
Metadati di Identificazione	<code>id</code> , <code>timestamp</code> , <code>model_name</code> , <code>dataset_type</code> , <code>random_state</code>
Proprietà Struttura Dati	<code>samples</code> , <code>train_split</code> , <code>n_features_in</code> , <code>n_classes</code>
Config. Iperparametrica	<code>n_estimators</code> , <code>max_depth</code> , <code>max_features</code> , <code>criterion</code> , <code>min_samples_split</code> , <code>learning_rate</code> , <code>max_iter</code>
Valutazione In-Sample	Matrice di confusione grezza (TP, TN, FP, FN) e metriche derivate di addestramento (Accuracy, Precision, Recall, F1-Score, ROC-AUC, PR-AUC, TPR, FPR)

L'archiviazione sistematica in `models_metadata.csv` assicura la completa uditabilità dell'infrastruttura di addestramento, fornendo la base informativa per le successive fasi di inferenza e valutazione cross-dominio sui dataset di test target.

4.4.2 Istanziamento dei Modelli Aggregati

La strategia di istanziamento dei classificatori aggregati prevede la generazione di tre distinte classi di modelli per ciascun seed stocastico, corrispondenti alla formalizzazione teorica discussa nella Sezione 3.2.1. Nonostante i dataset integrino l'etichettatura multi-classe (identificando la specifica tipologia di attacco), le architetture aggregate sono addestrate a risolvere un task di rilevamento binario, discriminando il traffico benevolo (Normal) dal generico traffico ostile (Attack).

La composizione dei *training set* per l'addestramento segue precise regole di proporzionalità e campionamento, ancorate al parametro di *Injection Ratio* $\rho_{ben/mal} = 10/1$:

1. **Modello Base (M_{base}):** Costituisce la *baseline* teorica. È addestrato su un dataset ingegnerizzato ad hoc tramite un approccio di *injection* controllata. Mantenendo il rapporto 10/1, i campioni benigni sono estratti integralmente dal dataset UNSW-NB15, mentre la componente malevola è ripartita proporzionalmente: $\frac{299}{300}$ dei campioni anomali richiesti proviene da UNSW-NB15, mentre la frazione residua $\frac{1}{300}$ è popolata con attacchi estratti dal dataset

satellitare integrato (STIN, composto da TER20 e SAT20). Nei registri di esecuzione, tale modello è identificato come `injection_aggregate`.

2. **Modello Sorgente ($\mathcal{M}_S$):** È il modello aggregato nativo, istanziato esclusivamente sui campioni appartenenti al dominio sorgente terrestre ($\mathcal{D}_S$). Si compone di traffico benigno e attacchi estratti unicamente dal dataset UNSW-NB15, denominato `nb15_aggregate`.
3. **Modelli Ibridi ($\mathcal{M}_H^{(T)}$):** Rappresentano la concretizzazione della procedura di *fine-tuning* in ottica cross-dominio. Vengono istanziati combinando tutti i record benigni nativi del dataset sorgente (UNSW-NB15) con la totalità dei campioni malevoli estratti dai domini target armonizzati ($\Delta\mathcal{D}_T^{(\text{train})}$). Anche per l'addestramento di queste architetture viene garantito e forzato il rigoroso rispetto del rapporto di sbilanciamento $\rho_{ben/mal} = 10/1$. Sono state istanziate tre varianti di modelli ibridi aggregati:

- `nb15_stin_aggregate`: Ibrido su dataset STIN complessivo.
- `nb15_ter20_aggregate`: Ibrido sul solo canale target TER20.
- `nb15_sat20_aggregate`: Ibrido sul solo canale target SAT20.

La Figura 4.4 schematizza visivamente il flusso di composizione dei dati appena descritto, evidenziando il rigoroso mantenimento del vincolo proporzionale tra le classi in fase di addestramento.




Figura 4.4: Architettura del flusso dati per l’addestramento dei Modelli Aggregati. Le percentuali indicano l’origine logica dei pacchetti che compongono i *training set*, forzati strutturalmente al vincolo $\rho_{\text{ben/mal}} = 10/1$.

Il prelievo dei campioni dalla partizione target ($\Delta\mathcal{D}_T^{(\text{train})}$) è governato da una procedura di campionamento casuale stratificato (*stratified random sampling*)¹⁸. Questa metodologia garantisce che i sotto-insiemi estratti rispettino le proporzioni imposte dal ratio 10/1 e salvaguarda la rigida compartimentazione logica tra *train set* e *test set*, risultando fondamentale per scongiurare qualsiasi fenomeno di dispersione dell’informazione (*Data Leakage*) in fase di validazione.

Dal punto di vista dell’ingegneria del software, la pipeline di istanziazione e addestramento è centralizzata all’interno del modulo `models.py`. La logica architetturale espone un punto di accesso pubblico, la funzione `model_processing()`, la quale orchestra dinamicamente l’esecuzione. Tale funzione delega il calcolo matematico del fitting a un *helper* interno denominato `_train_classifier()`, responsabile dell’inizializzazione dell’algoritmo di ML richiesto e della

¹⁸Implementato avvalendosi della funzione `train_test_split` di `scikit-learn`, valorizzando il parametro `stratify` per garantire la corretta preservazione delle proporzioni relative alle classi originali durante l’estrazione.

valutazione asincrona delle metriche sul *test set* in-sample. Lo script gestisce inoltre il salvataggio dei pesi strutturali (formato `.joblib`). Tale formato rappresenta lo standard *de facto* nell'ecosistema Python per la serializzazione efficiente di oggetti che ospitano array NumPy di grandi dimensioni, rendendolo particolarmente ottimizzato per il salvataggio dei modelli basati su alberi di decisione, garantendo l'aggiornamento automatico del registro `models_metadata.csv` tramite l'assegnazione procedurale del *Naming Standard* in base al dominio analizzato.

4.4.3 Istanziamento dei Modelli Biclasse

Al fine di condurre un'analisi comparativa granulare e valutare le prestazioni analitiche dei classificatori rispetto a minacce mirate, la metodologia prevede l'addestramento di una suite parallela di modelli biclasse, come anticipato nella Sezione 3.2.2. A differenza delle varianti aggregate (discusse nella Sottosezione 4.4.2), ciascun classificatore biclasse è progettato per isolare e discriminare un'unica e specifica famiglia di attacco dal normale traffico di rete (Normal). Tale approccio consente di misurare le metriche di accuratezza del modello dinanzi a pattern di traffico ostile altamente caratterizzati.

Dal punto di vista dell'ingegnerizzazione dei dati, i sotto-insiemi impiegati per il *fitting* di questi modelli vengono strutturati *a priori* durante la macro-fase di pre-elaborazione del file. In questa sede, i record appartenenti a vettori di attacco estranei al contesto di analisi vengono filtrati e scartati, restituendo un dominio di riferimento strettamente binario (es. [Normal, DDoS]). Durante la generazione di questi dataset isolati, l'algoritmo di elaborazione impone rigorosamente il mantenimento del rapporto di sbilanciamento $\rho_{ben/mal} = 10/1$. Contestualmente, viene preservata e fissata la partizione logica dei dati tramite etichettatura statica dei set di *train* e *test*, scongiurando eventuali contaminazioni informative (*Data Leakage*).

In perfetta simmetria con la suddivisione concettuale tra dominio sorgente e domini target ibridizzati, la pipeline ha generato le istanze biclasse riepilogate nella Tabella 4.13.

Tabella 4.13: Istanze dei modelli biclasse generati per il dominio sorgente e i domini target ibridizzati.

Categoria	Dominio	Istanze Modello Biclasse
Modelli Sorgente	UNSW-NB15	nb15_dos
		nb15_exploits
		nb15_fuzzers
		nb15_generic
		nb15_reconnaissance
Modelli Ibridi Target	SAT20	nb15_sat20_syn_ddos
		nb15_sat20_udp_ddos
Modelli Ibridi Target	TER20	nb15_ter20_botnet
		nb15_ter20_ddos
		nb15_ter20_syn_ddos
		nb15_ter20_udp_ddos

L'integrazione di questa logica all'interno del codice sorgente sfrutta elevati livelli di automazione. L'assegnazione della nomenclatura ai file serializzati e ai registri di metadati è gestita in maniera trasparente dalla subroutine `_get_standardized_model_name()` del modulo `models.py`. La funzione elabora il vettore delle classi uniche del dataset in input: verificata l'esatta cardinalità binaria, estrae computazionalmente l'etichetta divergente dalla stringa `Normal` e la concatena in modo canonico alla tipologia del dataset (generando dinamicamente stringhe come `dataset_attackname`). Tale soluzione ingegneristica ha garantito la standardizzazione dei log per tutti i successivi processi di inferenza. Il Listato 4.5 riporta il frammento di codice responsabile di tale elaborazione logica.

Codice 4.5: Estrazione procedurale dell’etichetta di attacco per la generazione dinamica della nomenclatura del modello.

```
1 def _get_standardized_model_name(dataset_type, unique_classes):
2     # Cancella gli spazi bianchi e converte in minuscolo per coerenza
3     classes = [str(c).strip() for c in unique_classes if str(c).strip()]
4
5     # Se len(classes) > 2, restituisce un nome generico
6     if len(classes) > 2:
7         return f"{dataset_type}_aggregate"
8
9     # Identifica la classe di attacco
10    # (assumendo che 'normal' sia la classe benevola)
11    attack_classes = [c for c in classes if c.lower() != 'normal']
12    attack_name = attack_classes[0].lower() if attack_classes else "normal"
13
14    return f"{dataset_type}_{attack_name}"
```

4.5 Protocollo di Addestramento e Valutazione

La presente sezione formalizza e declina in moduli operativi il protocollo sperimentale di addestramento, valutazione ed analisi inferenziale introdotto dal punto di vista teorico nel Capitolo 3. A fronte dell’esigenza di garantire la stabilità stocastica dei modelli e la piena riproducibilità dei risultati, l’infrastruttura software è progettata per gestire in modo sistematico l’intero ciclo di vita degli stimatori: dalla fase di fitting strutturata su molteplici semi stocastici, all’inferenza rigorosa sugli insiemi di collaudo, fino alla validazione statistica delle prestazioni relative. L’obiettivo primario di questo modulo consiste nel definire una pipeline esecutiva automatizzata e rigorosa, capace di integrare la persistenza degli artefatti, la generazione delle matrici di valutazione e la verifica formale delle ipotesi di significatività.

Nelle sottosezioni seguenti vengono dettagliate le componenti e le logiche procedurali che costituiscono l’architettura del protocollo. In primo luogo, la Sottosezione 4.5.1 descrive l’orchestrazione gerarchica del ciclo di addestramento multi-seed, le modalità di serializzazione degli oggetti predittivi e i meccanismi di tracciamento dei metadati nei registri persistenti. Successiva-

mente, la Sottosezione 4.5.2 illustra il flusso di classificazione e inferenza sugli insiemi di test, la gestione difensiva dei casi limite, la derivazione delle metriche di prestazione e la costruzione delle matrici di valutazione per singolo seed ed aggregate. Infine, la Sottosezione 4.5.3 analizza l'implementazione del test t di Welch, dettagliando la procedura di aggregazione dei dati di *F1-Score* e i criteri di decisione statistica adottati per il confronto tra le diverse configurazioni e il modello di riferimento.

4.5.1 Orchestrazione del Ciclo di Addestramento Multi-Seed

L'esecuzione della campagna di addestramento è stata strutturata secondo un'organizzazione gerarchica basata sulla tipologia di modello (`model_type`) e sul seme stocastico (`seed`). I dataset impiegati nel processo sono univoci e vengono istanziati una sola volta durante la fase di preprocessing, utilizzando il seme deterministico primario $s_0 = 127001$, come descritto nella Sezione 4.1.3. Le successive esecuzioni multi-seed operano pertanto sugli stessi dataset pre-processati, senza introdurre nuove istanziazioni o modifiche alla composizione dei benchmark.

L'orchestrazione globale è demandata al punto di ingresso `main.py`, nel quale il ciclo di costruzione dei modelli viene realizzato iterando sul prodotto cartesiano tra l'insieme delle tipologie di classificatore e l'insieme dei seed definiti dal framework. In termini procedurali, per ciascun `model_type` vengono quindi eseguite in successione le dieci configurazioni associate ai semi dell'Equazione (4.1).

Il flusso operativo dell'infrastruttura di addestramento e la relativa logica di persistenza sono schematizzati nella Figura 4.5.




Figura 4.5: Flusso operativo dell'orchestrazione multi-seed e isolamento degli artefatti persistiti.

Tale organizzazione garantisce che ogni combinazione (m, s_k) , con m appartenente all'insieme delle tipologie di modello e $s_k \in \mathcal{S}$, costituisca un'esecuzione logicamente indipendente. Il parametro `random_state` viene trasferito esplicitamente all'istanziamento del classificatore, preservando il controllo della componente stocastica senza alterare i dataset di ingresso. La distinzione tra le diverse configurazioni di algoritmo e seed è quindi mantenuta a livello di file system e di stato interno degli stimatori, in coerenza con il principio di isolamento già adottato nella gestione della riproducibilità.

Dal punto di vista implementativo, la logica di addestramento è centralizzata nel modulo `models.py`. La funzione pubblica `model_processing()` costituisce il punto di ingresso della procedura e riceve il *DataFrame* del benchmark, il relativo `dataset_type`, la tipologia di classificatore e il seed corrente. Tale funzione provvede alla predisposizione della struttura di persistenza associata all'esecuzione, delegando il fitting vero e proprio alla funzione interna `_train_classifier()`. Quest'ultima separa il dataset nelle partizioni `train` e `test`, rimuove le colonne non destinate all'apprendimento e istanzia dinamicamente il classificatore richiesto. La centralizzazione della

pipeline consente di applicare la medesima procedura operativa alle diverse famiglie di modelli ultimate nel framework.

L'istanziamento dell'algoritmo mantiene gli iperparametri ai valori predefiniti forniti da `scikit-learn`, mentre il parametro `random_state` viene vincolato al seed dell'esecuzione. Per la *Random Forest*, inoltre, il parametro `n_jobs=-1` abilita l'impiego parallelo dei processori disponibili durante la costruzione dell'ensemble; per il *Decision Tree* e l'*Histogram-based Gradient Boosting* non viene invece specificata una configurazione equivalente nel codice applicativo. La scelta mantiene separata la parallelizzazione interna dell'algoritmo dalla logica di orchestrazione, che continua a processare sequenzialmente le diverse combinazioni di `model_type` e `seed`.

Una volta completato il fitting, lo stato dello stimatore viene congelato mediante serializzazione su disco. La funzione `_save_model()` utilizza la libreria `joblib` per esportare l'oggetto addestrato in formato binario `.joblib`, registrandone contestualmente il percorso nel registro dei modelli. La struttura gerarchica adottata separa la tipologia di modello dal seed e dagli artefatti prodotti, secondo lo schema generale:

```
runs/model_type/seed/models/
```

Un'istanza concreta è rappresentata dal percorso:

```
runs/hybrid_models/rf/42/models/injection_aggregate.joblib
```

nel quale `rf` identifica la famiglia del classificatore, `42` il seed dell'esecuzione e `injection_aggregate.joblib` il modello serializzato associato al benchmark considerato. La nomenclatura dei modelli viene determinata automaticamente sulla base del `dataset_type` e delle classi presenti nel dataset, così da mantenere una corrispondenza univoca tra configurazione sperimentale e artefatto persistito.

Parallelamente alla serializzazione dello stimatore, per ogni configurazione vengono registrati i relativi metadati nel file `models_metadata.csv`. Il meccanismo di aggiornamento è implementato mediante la funzione `update_or_append_csv()` del modulo `file_utils.py`, la quale verifica preventivamente l'eventuale presenza di un record corrispondente alle chiavi di identificazione e, in assenza di una corrispondenza, genera un nuovo identificatore incrementale. La funzione mantiene inoltre il campo `id` come prima colonna del file e allinea lo schema del nuovo record a quello già presente. Per ciascun modello vengono quindi mantenute, oltre alle informazioni identificative, le

principali proprietà strutturali e configurazionali dello stimatore, inclusi il valore di `random_state`, il numero di feature in ingresso, il numero di classi e gli iperparametri specifici dell'algoritmo. Il registro costituisce pertanto la traccia persistente dell'esecuzione e permette di associare ogni artefatto serializzato alla precisa configurazione che ne ha determinato la costruzione.

La procedura adottata garantisce infine una netta separazione tra produzione e successivo utilizzo degli stimatori. Una volta completato il ciclo di fitting e serializzazione per un determinato seed, il relativo modello non viene più modificato nelle fasi successive: la valutazione viene infatti eseguita caricando da disco l'artefatto precedentemente congelato. In questo modo, la fase di classificazione successiva opera esclusivamente in modalità di inferenza sul modello già addestrato, evitando che le procedure di valutazione possano alterarne lo stato interno.

4.5.2 Calcolo delle Metriche e Costruzione della Matrice di Valutazione

La valutazione dei classificatori è stata implementata mediante una procedura comune a tutte le configurazioni sperimentali, così da garantire uniformità nel calcolo delle metriche e nella successiva organizzazione dei risultati. La fase di classificazione opera esclusivamente sugli insiemi di collaudo, identificati tramite il campo `split_type`, mentre le informazioni relative alle feature e alle etichette vengono separate prima dell'esecuzione dell'inferenza. Per ciascun modello precedentemente serializzato, l'artefatto `.joblib` viene ricaricato da disco e utilizzato senza apportare modifiche al suo stato interno.

La procedura è centralizzata nella funzione `classification_processing()` del modulo `classification.py`, che delega il calcolo delle predizioni alla propria funzione interna `_classification()`. Una volta isolato il sottoinsieme associato a `split_type = test`, vengono eliminate dalle feature le colonne `label`, `class` e `split_type`, mentre la variabile `label` viene mantenuta separatamente come vettore delle classi reali. L'inferenza viene quindi effettuata mediante i metodi `predict()` e `predict_proba()`, utilizzando quest'ultimo per estrarre il punteggio associato alla classe positiva. Non viene applicata una soglia decisionale personalizzata: le etichette predette sono pertanto quelle direttamente restituite dall'estimatore secondo il comportamento predefinito del classificatore.

Il calcolo delle metriche è stato incapsulato nella funzione `calculate_metrics()` del modulo `src/utils/metrics.py`, con l'impiego delle funzioni messe a disposizione da `sklearn.metrics`.

In particolare, vengono utilizzate le metriche descritte in Tabella 4.14.

Tabella 4.14: Metriche di valutazione delle prestazioni utilizzate per la caratterizzazione dei modelli di apprendimento automatico.

Funzione Scikit-Learn	Descrizione Operativa
<code>confusion_matrix</code>	Matrice di confusione per il conteggio delle predizioni binarie.
<code>accuracy_score</code>	Proporzione complessiva di predizioni corrette rispetto al totale delle istanze.
<code>precision_score</code>	Frazione di istanze malevole identificate correttamente rispetto a tutte quelle classificate come tali.
<code>recall_score</code>	Sensibilità o tasso di veri positivi (<i>TPR</i>): frazione di anomalie rilevate rispetto al totale reale.
<code>f1_score</code>	Media armonica tra Precision e Recall, indicatore sintetico in presenza di sbilanciamento delle classi.
<code>roc_auc_score</code>	Area sotto la curva ROC (True Positive Rate vs False Positive Rate) al variare della soglia decisionale.
<code>average_precision_score</code>	Area sotto la curva Precision-Recall, pesata sull'incremento della Recall ad ogni soglia.

La matrice di confusione viene esplicitamente calcolata imponendo l'ordine delle classi $[0, 1]$ e successivamente scomposta nei quattro termini fondamentali:

$$\mathbf{C} = \begin{bmatrix} TN & FP \\ FN & TP \end{bmatrix}. \quad (4.3)$$

A partire da tali quantità vengono inoltre calcolati direttamente il *True Positive Rate* (TPR), il *False Negative Rate* (FNR), il *True Negative Rate* (TNR) e il *False Positive Rate* (FPR), secondo le relazioni riportate nella Sezione 3.4.3.

Il *Recall* restituito da `recall_score()` coincide, nel caso binario adottato dal framework, con il TPR. Le ulteriori metriche calcolate comprendono *Accuracy*, *Precision*, *F1-Score*, *ROC-AUC* e *PR-AUC*. Le metriche *Accuracy*, *Precision*, *Recall* e *F1-Score* sono ottenute a partire

dalle etichette predette `y_pred`, mentre *ROC-AUC* e *PR-AUC* vengono determinate utilizzando i punteggi `y_scores` associati alla classe positiva. Tutti i valori numerici prodotti dalle funzioni di metrica vengono arrotondati al numero di cifre decimali stabilito nella configurazione globale `MLConstants.DECIMAL_DIGITS`¹⁹.

Particolare attenzione è stata riservata ai casi nei quali il vettore delle etichette reali contiene una sola classe. Prima del calcolo delle metriche viene pertanto verificata la presenza di almeno due classi distinte mediante il numero di valori univoci presenti in `y_test`. Qualora tale condizione non sia soddisfatta, le metriche *Accuracy*, *Precision*, *Recall*, *F1-Score*, *ROC-AUC* e *PR-AUC* vengono impostate a `None`. I quattro elementi della matrice di confusione vengono invece sempre ricavati imponendo le classi `[0, 1]`, mentre *TPR*, *FNR*, *TNR* e *FPR* vengono calcolati separatamente e assumono valore `None` esclusivamente quando il denominatore della relativa espressione risulta nullo²⁰. La struttura logica di tale gestione difensiva è sintetizzata nel Listing 4.6.

¹⁹Nella configurazione sperimentale corrente, il parametro `DECIMAL_DIGITS` è impostato su 4 decimali per preservare la precisione numerica nei calcoli aggregati.

²⁰Questa guardia condizionale esplicita sui denominatori ($(TP + FN) > 0$ e $(FP + TN) > 0$) e sul conteggio delle classi univoche previene eccezioni di divisione per zero e avvisi a runtime (*RuntimeWarning/UndefinedMetricWarning*), garantendo la continuità dell'esecuzione e la tracciabilità dei casi degeneri nei report salvati.

Codice 4.6: Gestione difensiva dei casi limite e calcolo delle metriche in `calculate_metrics()`.

```
1 has_classes = len(np.unique(y_test)) > 1
2 # [Controllo di sicurezza sul numero di classi...]
3
4 # Calcolo delle metriche
5 tn, fp, fn, tp = confusion_matrix(y_test, y_pred, labels=[0, 1]).ravel()
6
7 if has_classes:
8     accuracy = round(accuracy_score(y_test, y_pred),
9                       MLConstants.DECIMAL_DIGITS)
10    precision = round(precision_score(y_test, y_pred),
11                      MLConstants.DECIMAL_DIGITS)
12    recall = round(recall_score(y_test, y_pred),
13                   MLConstants.DECIMAL_DIGITS)
14    f1 = round(f1_score(y_test, y_pred),
15               MLConstants.DECIMAL_DIGITS)
16    roc = round(roc_auc_score(y_test, y_scores),
17                MLConstants.DECIMAL_DIGITS)
18    pr = round(average_precision_score(y_test, y_scores),
19               MLConstants.DECIMAL_DIGITS)
20 else:
21     accuracy = precision = recall = f1 = roc = pr = None
22
23 if (tp + fn) > 0:
24     tpr = round(tp / (tp + fn), MLConstants.DECIMAL_DIGITS)
25     fnr = round(fn / (tp + fn), MLConstants.DECIMAL_DIGITS)
26 else:
27     tpr, fnr = None, None
28
29 if (fp + tn) > 0:
30     tnr = round(tn / (fp + tn), MLConstants.DECIMAL_DIGITS)
31     fpr = round(fp / (fp + tn), MLConstants.DECIMAL_DIGITS)
32 else:
33     tnr, fpr = None, None
```

L'insieme completo dei risultati viene quindi organizzato all'interno del file nominato come

`classifications.csv`, generato separatamente per ciascuna combinazione di `model_type` e `seed`. Ogni record contiene i metadati identificativi della classificazione, il tipo di dataset e la relativa composizione delle classi, oltre alle quantità della matrice di confusione e alle metriche derivate. La struttura complessiva del record e la relativa suddivisione funzionale dei campi sono dettagliate nella Tabella 4.15.

Tabella 4.15: Tassonomia e suddivisione concettuale dei campi costituenti il record di tracciamento delle prestazioni.

Campo	Descrizione Operativa
Metadati ed Esecuzione Sperimentale	
id	Identificatore univoco progressivo della singola esecuzione.
timestamp	Marca temporale di completamento della valutazione.
model_name	Architettura o denominazione del modello di apprendimento valutato.
dataset_type	Tipologia di partizione o dominio di test utilizzato.
classes	Cardinalità o identificativi delle classi analizzate.
samples	Numero totale di campioni elaborati nella sessione.
Conteggi della Matrice di Confusione	
TP	Conteggio dei Veri Positivi (<i>True Positives</i>).
TN	Conteggio dei Veri Negativi (<i>True Negatives</i>).
FP	Conteggio dei Falsi Positivi (<i>False Positives</i>).
FN	Conteggio dei Falsi Negativi (<i>False Negatives</i>).
Metriche di Prestazione Sintetiche	
Accuracy	Tasso di accuratezza globale sul totale dei campioni.
Precision	Frazione di predizioni positive risultate corrette.
Recall	Sensibilità o tasso di rilevamento delle anomalie.
F1-Score	Media armonica bilanciata tra Precision e Recall.
ROC-AUC	Area sotto la curva <i>Receiver Operating Characteristic</i> .
PR-AUC	Area sotto la curva <i>Precision-Recall (Average Precision)</i> .
Tassi e Proporzioni Operative	
TPR	<i>True Positive Rate</i> , coincidente con la Recall.
FNR	<i>False Negative Rate</i> , o tasso di mancato allarme.
TNR	<i>True Negative Rate</i> , o specificità del sistema.
FPR	<i>False Positive Rate</i> , o tasso di falso allarme.

La persistenza viene effettuata mediante `update_or_append_csv()`, che individua un'eventuale

voce preesistente sulla base delle chiavi di corrispondenza (`model_name`, `dataset_type` e `classes`) e, in caso contrario, assegna un identificatore al nuovo record.

A partire dai risultati persistiti viene costruita la matrice di valutazione definita teoricamente nel Capitolo 3. Per ciascun seed $s_k \in \mathcal{S}$, tale matrice può essere formalmente rappresentata come:

$$H_k = \left[h_{ij}^{(k)} \right] \in \mathbb{R}^{M \times D}, \quad (4.4)$$

dove M identifica l'insieme dei modelli addestrati, D l'insieme dei dataset di valutazione e ciascun elemento $h_{ij}^{(k)}$ rappresenta il valore della metrica considerata per la coppia costituita dal i -esimo modello e dal j -esimo dataset al seed s_k .

Nell'implementazione concreta, la rappresentazione generale viene articolata in due matrici indipendenti, una relativa al *True Positive Rate* e una relativa al *True Negative Rate*:

$$H_k^{TPR} = \left[TPR_{ij}^{(k)} \right], \quad H_k^{TNR} = \left[TNR_{ij}^{(k)} \right]. \quad (4.5)$$

Le due matrici presentano la medesima organizzazione bidimensionale, con i modelli addestrati disposti sulle righe e i dataset di valutazione sulle colonne. La suddivisione fisica viene invece effettuata a livello di gruppi di modelli: una matrice raccoglie le configurazioni aggregate del dominio sorgente, i modelli biclasse sorgente e il relativo modello *INJECTION*, mentre l'altra raccoglie le configurazioni aggregate ibride, i modelli biclasse ibridi e il medesimo modello di riferimento *INJECTION*.

Per ciascuna matrice, la colonna finale è reserved al valore medio associato alla riga del modello, mentre il modello *INJECTION* viene riportato in una sezione graficamente separata nella parte inferiore della rappresentazione. Gli artefatti relativi alle singole esecuzioni sono salvati nella directory

`runs/<model_group>/<model_type>/<seed>/results/plots/performance/`

attraverso i file `TPR_matrix.png` e `TNR_matrix.png`.

L'intero flusso operativo di valutazione e la successiva aggregazione statistica tra i diversi seed sono schematizzati nella Figura 4.6.

Fase 1: Valutazione e Persistenza per Singolo Seed (s_k)




Figura 4.6: Pipeline a due stadi per il calcolo delle metriche di classificazione, tracciamento su file system e aggregazione statistica multi-seed.

Al termine dell'elaborazione dei singoli seed, viene eseguita una seconda fase di aggregazione che considera congiuntamente i risultati prodotti per tutti i valori di s_k . La routine `_aggregated_heatmaps()` legge i file `classifications.csv` presenti nelle directory associa-

te ai diversi seed, li concatena in un unico *DataFrame* e associa esplicitamente a ciascun record il seed di provenienza.

Per ciascuna coppia modello–dataset vengono successivamente determinate le statistiche aggregate della metrica considerata sui diversi seed. In particolare, per TPR e TNR viene prodotta un’unica matrice contenente due valori numerici distinti per ogni coppia modello–dataset: rispettivamente la media

$$\bar{h}_{ij} = \frac{1}{K} \sum_{k=1}^K h_{ij}^{(k)}, \quad (4.6)$$

e la varianza

$$\sigma_{ij}^2 = \frac{1}{K} \sum_{k=1}^K \left(h_{ij}^{(k)} - \bar{h}_{ij} \right)^2. \quad (4.7)$$

La rappresentazione aggregata combina quindi l’informazione relativa al valore medio e alla dispersione osservata tra i seed, senza sostituire i dati relativi alle singole esecuzioni. Per ciascun tipo di classificatore, le matrici aggregate vengono memorizzate sotto la directory

`runs/<model_group>/<model_type>/aggregated_heatmaps/`

con una sottocartella dedicata alla metrica considerata. Per ciascuna metrica vengono conservati sia i valori tabellari della media e della varianza in formato CSV, sia la rappresentazione grafica finale in formato PNG.

La struttura organizzativa e la composizione tabellare dei file CSV generati per rappresentare le matrici aggregate di media ($\bar{h}_{ij}$) e varianza (σ_{ij}^2) sono descritte nella Tabella 4.16.

Tabella 4.16: Struttura e descrizione dei campi costituenti i file CSV per le matrici delle metriche individuali e aggregate ($M \times D$).

Colonna	Tipo Dati	Descrizione Operativa
model_label	Stringa	Architettura o denominazione del modello valutato (i -esima riga della matrice).
<dataset_1>	Float	Valore (puntuale, medio $\bar{h}_{ij}$ o varianza σ_{ij}^2) della metrica sul primo dataset.
<dataset_2>	Float	Valore (puntuale, medio $\bar{h}_{ij}$ o varianza σ_{ij}^2) della metrica sul secondo dataset.
...	...	Valori associati ai restanti dataset di valutazione di test $j \in \{1, \dots, D\}$.
<dataset_D>	Float	Valore (puntuale, medio $\bar{h}_{ij}$ o varianza σ_{ij}^2) della metrica sull'ultimo dataset.
Average	Float	Media complessiva della metrica calcolata per la riga del modello su tutti i D dataset.

La separazione tra risultati per singolo seed e risultati aggregati consente pertanto di mantenere distinti due livelli di organizzazione implementativa: il primo conserva integralmente la configurazione associata a ciascuna realizzazione stocastica, mentre il secondo sintetizza le osservazioni relative alla stessa coppia modello–dataset lungo l’insieme dei seed. Tale organizzazione costituisce la trasposizione operativa della matrice di valutazione H_k definita nel modello teorico e produce gli artefatti persistenti utilizzati nelle successive procedure di analisi statistica.

4.5.3 Implementazione del Test di Welch

La verifica statistica della variabilità associata alle diverse configurazioni di addestramento è stata implementata mediante il test t di Welch, applicato separatamente a ciascuna tipologia di classificatore e al relativo gruppo di modelli. La procedura è stata progettata per confrontare le prestazioni del

modello *INJECTION*, assunto come configurazione di riferimento, con quelle dei restanti modelli generati durante la campagna multi-seed. L'analisi viene eseguita indipendentemente per i gruppi `nb15_models` e `hybrid_models`, mantenendo pertanto la distinzione architetturale già adottata nella struttura di persistenza dei risultati.

L'esecuzione della procedura è orchestrata dalla funzione `_welch_ttest()` del punto di ingresso `main.py`. Per una specifica tipologia di classificatore, vengono innanzitutto raccolti i file `classifications.csv` prodotti dalle precedenti fasi di valutazione per tutti i seed appartenenti all'insieme $\mathcal{S}$. I risultati vengono quindi forniti alla funzione `aggregate_welch_ttest_feature_scores_by_seed()`, che costituisce il primo livello di aggregazione dei dati destinati all'analisi statistica.

La funzione di aggregazione opera esclusivamente sulla metrica *F1-Score*, il cui utilizzo è definito tramite il parametro di configurazione `MLConstants.WELCH_TTEST_FEATURE`. Per ciascun file di classificazione vengono selezionate le colonne `model_name` e `F1-Score`, mentre il seed viene ricavato dalla `directory` che contiene il file `classifications.csv`. I dati provenienti dalle diverse esecuzioni vengono successivamente concatenati in un unico *DataFrame*.

Poiché ciascun file di classificazione contiene più osservazioni relative a differenti dataset valutati dallo stesso modello, la procedura effettua un'ulteriore aggregazione mediante un raggruppamento per coppia `model_name`–seed. Per ciascuna coppia viene calcolata la media della *F1-Score* sui dataset disponibili. Indicando con $f_{ij}^{(k)}$ il valore della *F1-Score* associato al modello i , al dataset j e al seed s_k , il valore utilizzato nel successivo test statistico è pertanto

$$\overline{F1}_i^{(k)} = \frac{1}{D_i} \sum_{j=1}^{D_i} f_{ij}^{(k)}, \quad (4.8)$$

dove D_i rappresenta il numero di dataset di valutazione considerati per il modello i nella configurazione corrente. Ne consegue che ciascun modello è rappresentato da un campione costituito dai valori medi ottenuti sui $K = 10$ seed, anziché dalla totalità delle singole osservazioni modello–dataset.

Il risultato di tale aggregazione viene trasformato in una struttura matriciale mediante un'operazione di *pivot*. I modelli costituiscono le righe, mentre ciascun seed viene trasformato in una colonna distinta. La struttura risultante presenta quindi una configurazione del tipo

id, model_name, seed_0, seed_1, ... , seed_12345

e costituisce la matrice di input per il test statistico. L'artefatto viene persistito nella directory

runs/<model_group>/<model_type>/welch_ttest/

con il nome F1-Score_means.csv. Tale file rappresenta esclusivamente la sintesi dei valori medi di *F1-Score* per modello e seed e costituisce una rappresentazione intermedia necessaria alla successiva procedura statistica. L'intero flusso di aggregazione dei dati e la pipeline di calcolo del test statistico sono schematizzati nella Figura 4.7.




Figura 4.7: Pipeline di trasformazione dei dati per l'esecuzione del Test *t* di Welch, dal recupero delle metriche sui singoli seed alla persistenza degli esiti statistici.

Il Welch test viene quindi eseguito dalla funzione `calculate_welch_ttest_from_summary()` del modulo `src/utls/metrics.py`, utilizzando la funzione `ttest_ind()` del modulo `scipy.stats`. L'opzione `equal_var=False` impone esplicitamente l'utilizzo della formulazione di Welch, nella quale non viene assunta l'uguaglianza delle varianze delle due popolazioni campionarie.

Per ogni gruppo di analisi viene individuato il modello di riferimento ricercando nel campo `model_name` la configurazione contenente la stringa `INJECTION`. La struttura dei benchmark garantisce la presenza di una sola configurazione di questo tipo nel *DataFrame* considerato; tale modello viene pertanto utilizzato come riferimento per tutti i successivi confronti. I valori corrispondenti ai dieci seed del modello di riferimento costituiscono il campione

$$\mathcal{F}_{\text{base}} = \left\{ \overline{F1}_{\text{base}}^{(1)}, \overline{F1}_{\text{base}}^{(2)}, \dots, \overline{F1}_{\text{base}}^{(K)} \right\}. \quad (4.9)$$

Per ciascun modello confrontato m , viene analogamente costruito il campione

$$\mathcal{F}_m = \left\{ \overline{F1}_m^{(1)}, \overline{F1}_m^{(2)}, \dots, \overline{F1}_m^{(K)} \right\}. \quad (4.10)$$

Il test inferenziale viene condotto assumendo l'indipendenza statistica delle osservazioni generate dalle diverse iterazioni con seed sintetici distinti ($s_k \in \mathcal{S}$) e senza vincoli sulla varianza delle due popolazioni. L'ipotesi nulla e l'ipotesi alternativa sono pertanto formulate, per ciascun confronto diretto tra $\mathcal{F}_{\text{base}}$ e $\mathcal{F}_m$, come

$$H_0 : \mu_{\text{base}} = \mu_m, \quad H_1 : \mu_{\text{base}} \neq \mu_m, \quad (4.11)$$

dove μ_{base} e μ_m rappresentano i valori medi teorici della *F1-Score* delle rispettive popolazioni campionarie.

La traduzione di tale impianto teorico nella sua controparte implementativa è riportata nel Listing 4.7, il quale illustra la procedura di estrazione dei campioni vettoriali dal *DataFrame* matriciale e l'invocazione del modulo `scipy.stats`. L'utilizzo del parametro `equal_var=False` applica rigorosamente la formulazione di Welch e la valutazione viene eseguita a due code (configurazione predefinita), senza introdurre una direzione privilegiata per l'ipotesi alternativa.

Codice 4.7: Estrazione dei campioni ed esecuzione del Test t di Welch.

```
1 # Estrazione dei valori di F1-Score medi per il modello
2 # di riferimento (INJECTION) su tutti i seed
3 ref_row = data[data["model_name"] == reference_model]
4 ref_scores = (
5     ref_row.drop(columns=["id", "model_name"]).values.flatten().astype(float)
6 )
7
8 results_list = []
9 # Itera su ciascun modello presente nel DataFrame di sintesi
10 # per eseguire i confronti incrociati
11 for _, row in data.iterrows():
12     current_model = row["model_name"]
13
14     if current_model == reference_model: continue
15
16     # Isola i valori numerici di test per il modello confrontato
17     current_scores = row.drop(["id", "model_name"]).values.astype(float)
18
19     # Esegue il test t di Welch assumendo varianze non uguali
20     t_stat, p_value = stats.ttest_ind(
21         ref_scores, current_scores, equal_var=False
22     )
23
24     # Valuta la significatività statistica
25     is_significant = "YES" if p_value < alpha else "NO"
26
27     results_list.append({
28         "Reference_Model": reference_model,
29         "Compared_Model": current_model,
30         "t_statistic": t_stat,
31         "p_value": p_value,
32         "alpha": alpha,
33         "is_significant": is_significant
34     })
```

Il livello di significatività è stabilito *a priori* al valore di primo tipo

$$\alpha = 0,05, \quad (4.12)$$

acquisito dal parametro di configurazione `MLConstants.WELCH_TTEST_ALFA_VALUE`. La decisione statistica viene determinata direttamente confrontando il *p-value* restituito dal test con tale soglia prefissata. In particolare, la differenza prestazionale tra il modello in esame e la baseline viene marcata come statisticamente significativa quando

$$p < \alpha, \quad (4.13)$$

mentre in caso contrario il confronto viene classificato come non significativo. Non viene applicata alcuna procedura di correzione per confronti multipli ai *p-value* ottenuti dai diversi confronti tra modelli²¹.

Il confronto del modello *INJECTION* con sé stesso viene esplicitamente escluso dalla procedura, poiché non costituisce un confronto statistico tra configurazioni differenti. Per ciascuno degli altri modelli vengono invece registrati il valore della statistica *t*, il relativo *p-value*, il livello α adottato e l'esito della verifica mediante il campo `is_significant`.

I risultati vengono infine serializzati mediante la funzione `create_csv_from_data()` nel file `welch_ttest.csv`, salvato nella sottocartella di analisi

`runs/<model_group>/<model_type>/welch_ttest/`

La struttura complessiva del registro finale e la descrizione semantica dei singoli campi sono dettagliate nella Tabella 4.17. Tale schematizzazione consente di associare univocamente ogni confronto alla configurazione di riferimento, al modello sottoposto a verifica e ai parametri descrittivi restituiti dal test.

²¹L'assenza di correzioni per test multipli (quali Bonferroni o Benjamini-Hochberg) è stata adottata in modo deliberato per preservare la sensibilità esplorativa dell'analisi. In tale contesto, ridurre la probabilità di errori di II tipo (falsi negativi) è stato ritenuto prioritario rispetto al controllo rigido del *Family-Wise Error Rate* (FWER), evitando così di smorzare prematuramente deviazioni prestazionali potenzialmente rilevanti indotte dalle diverse configurazioni di addestramento.

Tabella 4.17: Struttura e descrizione semantica dei campi costituenti il file di registro statistico `welch_ttest`.

Campo	Descrizione Operativa
Reference_Model	Denominazione del modello di riferimento assunto come baseline (variante <i>INJECTION</i>).
Compared_Model	Denominazione del modello di confronto sottoposto a verifica statistica.
t_statistic	Valore numerico della statistica t di Welch calcolato tra i campioni di <i>F1-Score</i> .
p_value	Probabilità osservata di ottenere un valore uguale o più estremo sotto l'ipotesi nulla H_0 .
alpha	Livello di significatività stabilito <i>a priori</i> per la decisione statistica ($\alpha = 0,05$).
is_significant	Indicatore booleano dell'esito della verifica (True se $p < \alpha$, False altrimenti).

In tal modo, la pipeline mantiene formalmente separati il livello di aggregazione delle prestazioni sui singoli seed, memorizzato in `F1-Score_means.csv`, e il livello di diagnostica statistica inferenziale, rappresentato da `welch_ttest.csv`.

4.6 Strumenti di Analisi Diagnostica e Spiegabilità

La presente sezione formalizza l'implementazione degli strumenti di analisi diagnostica e di spiegabilità introdotti dal punto di vista metodologico nel Capitolo 3. L'infrastruttura software integra procedure dedicate alla caratterizzazione geometrica e distributiva dei benchmark, mediante proiezioni *Principal Component Analysis* (PCA) e stime di densità *Kernel Density Estimation* (KDE), nonché strumenti di interpretabilità post-hoc basati sui valori di Shapley per l'analisi del contributo delle singole caratteristiche alle decisioni dei classificatori. Tali componenti sono concepiti esclusivamente come strumenti diagnostici e non intervengono né nella fase di addestramento né nella modifica degli stimatori precedentemente serializzati.

Particolare attenzione viene dedicata alla coerenza del sistema di riferimento utilizzato nelle analisi diagnostiche. In accordo con il principio di standardizzazione dipendente dal sorgente introdotto nella Sezione 3.4.1, le statistiche di posizione e scala vengono ancorate al benchmark sorgente e successivamente riutilizzate per la trasformazione dei benchmark considerati, evitando il ricalcolo locale dei parametri di standardizzazione. La medesima impostazione viene applicata alle rappresentazioni PCA e KDE, con finalità rispettivamente orientate all'ispezione della disposizione dei dati nello spazio delle caratteristiche e all'analisi delle distribuzioni delle variabili selezionate.

Nelle sottosezioni seguenti vengono descritte le componenti che costituiscono l'architettura diagnostica. In primo luogo, la Sottosezione 4.6.1 illustra l'implementazione della standardizzazione diagnostica dipendente dal sorgente e delle procedure PCA e KDE, specificando le modalità di trasformazione dei benchmark e la configurazione delle rappresentazioni grafiche. Successivamente, la Sottosezione 4.6.2 descrive l'integrazione di SHAP nella pipeline di classificazione, il campionamento stratificato del test set e la gestione degli *explainer* per i classificatori basati su alberi. Infine, la Sottosezione 4.6.3 illustra il raccordo tra l'analisi SHAP e la successiva selezione delle caratteristiche per la rappresentazione KDE, evidenziando il carattere supervisionato della procedura e la definizione manuale della configurazione KDE_TOP_FEATURES.

La Tabella 4.18 sintetizza le caratteristiche operative, lo spazio di input e i moduli software associati a ciascuno degli strumenti considerati.

Tabella 4.18: Confronto sinottico tra gli strumenti diagnostici (PCA, KDE) e di spiegabilità (TreeSHAP) integrati nell’architettura software.

Strumento	Obiettivo	Spazio Input	Interpretabilità
PCA	Ispezione geometrica della separabilità globale e variabilità nello spazio 2D	Scalato (Z-Score ancorato al benchmark sorgente S)	Globale (riduzione dimensionale per componenti principali)
KDE	Analisi densometrica univariata del <i>domain shift</i> sulle feature chiave	Scalato (Z-Score ancorato sulle Top-3 feature di S)	Distribuzionale (stima della densità per classe in scala symlog)
TreeSHAP	Spiegabilità post-hoc del contributo delle feature alle predizioni dei classificatori	Originale (matrice delle caratteristiche del test set X_{test})	Locale e Aggregata (valori di Shapley e <i>summary plot</i>)

4.6.1 Standardizzazione Diagnostica, PCA e KDE

L’implementazione degli strumenti diagnostici descritti nella Sezione 3.4.1 è centralizzata nel modulo `plotting.py`. Le due procedure ricevono come input il file di configurazione contenente i percorsi dei benchmark e i relativi identificativi di dataset e producono automaticamente le rappresentazioni grafiche previste dal framework. L’analisi è finalizzata esclusivamente all’ispezione diagnostica della distribuzione dei dati e della loro disposizione nello spazio delle caratteristiche, senza intervenire nel processo di addestramento o nella fase di classificazione.

Per entrambe le procedure viene adottato il benchmark identificato dalla costante `SOURCE_IDENTIFIER`, impostata a `nb15_aggr_scaled`, come riferimento per la standardizzazione diagnostica. Tale scelta implementa il principio teorico introdotto nella Sezione 3.4.1, secondo il quale le statistiche di riferimento devono essere mantenute fisse durante la trasformazione dei diversi benchmark, così da preservare nello spazio trasformato eventuali traslazioni distributive riconducibili al *domain shift*.

L'architettura logica di questo processo di trasformazione dipendente dal sorgente è schematizzata nella Figura 4.8. Come mostrato nel diagramma di flusso, la stima dei parametri di posizione e scala (μ_S, σ_S) , così come la matrice di proiettori vettoriali $\mathbf{W}_S$, viene effettuata in modo atomico durante la fase di *fitting* sul solo benchmark sorgente. Successivamente, tali parametri congelati vengono applicati per via diretta sia a S sia a ciascun benchmark target T_k , garantendo l'invarianza del sistema di riferimento e scongiurando qualunque forma di *data leakage*.




Figura 4.8: Schema concettuale della Standardizzazione Diagnostica Dipendente dal Sorgente: le statistiche di centralità e variabilità (μ_S, σ_S) e gli autovettori della PCA ($\mathbf{W}_S$) vengono stimati esclusivamente sul benchmark sorgente S e congelati. La trasformazione dei benchmark target T_k avviene per applicazione diretta di tali parametri, preservando lo scostamento distributivo reale (*domain shift*).

Proiezione PCA La procedura `save_all_pca_plots()` carica ciascun benchmark indicato nel file di configurazione ed estrae preliminarmente il sottoinsieme associato alla partizione test, identificata tramite la colonna `split_type`. Dalla matrice delle caratteristiche vengono rimosse le colonne `label`, `class` e `split_type`, mentre la variabile `label` viene conservata separatamente

per la successiva caratterizzazione delle classi nel grafico.

Per realizzare la standardizzazione diagnostica viene istanziato uno `StandardScaler` di `scikit-learn`. Nel caso della PCA, il modello di scaling viene adattato esclusivamente al sottoinsieme test del benchmark sorgente. Indicando con $\mathbf{X}_{S,\text{test}}$ tale matrice, l'operazione è implementata mediante:

Codice 4.8: Standardizzazione e adattamento della PCA sul benchmark sorgente.

```
1 scaler = StandardScaler()
2 pca = PCA(
3     n_components=MLConstants.PCA_COMPONENTS,
4     random_state=MLConstants.MAIN_SEED
5 )
6
7 X_source_scaled = scaler.fit_transform(X_source)
8 pca.fit(X_source_scaled)
```

La configurazione `PCA_COMPONENTS=2` vincola la trasformazione alla costruzione di un sottospazio bidimensionale, coerentemente con la finalità esclusivamente visuale dell'analisi. Gli autovettori principali sono quindi determinati una sola volta sul riferimento sorgente e successivamente riutilizzati per tutti i benchmark. Per ciascun dataset, la matrice delle caratteristiche viene trasformata mediante `scaler.transform()` e `pca.transform()`, evitando un nuovo adattamento locale:

Codice 4.9: Applicazione della trasformazione diagnostica ancorata al benchmark sorgente.

```
1 X_scaled = scaler.transform(X_test)
2 X_pca = pca.transform(X_scaled)
```

La procedura garantisce pertanto che tutti i benchmark siano rappresentati all'interno del medesimo sistema di riferimento statistico e geometrico. Tale impostazione è coerente con la formulazione teorica della standardizzazione dipendente dal sorgente, nella quale le statistiche (μ_S, σ_S) vengono mantenute fisse per evitare che una standardizzazione locale annulli le traslazioni distributive che si intendono osservare.

Per ogni benchmark viene infine generato uno scatter plot bidimensionale delle prime due componenti principali. Le osservazioni sono differenziate in funzione dell'etichetta binaria, con la

codifica Normal Traffic per la classe 0 e Attack/Anomaly per la classe 1. Il titolo del grafico riporta inoltre la percentuale complessiva di varianza spiegata dalle due componenti, mentre gli assi riportano separatamente il contributo percentuale di PC1 e PC2. I grafici vengono salvati con risoluzione pari a 300 dpi nella directory

```
data/preprocessed/metadata/plots/pca/
```

in formato png.

Stima KDE delle feature selezionate La procedura `save_all_kde_plots()` realizza invece l'analisi densometrica delle tre caratteristiche definite dalla costante `KDE_TOP_FEATURES`, pari a `pkts_per_sec`, `total_bytes` e `dst_win_byt`. La selezione coincide quindi con il sottoinsieme di caratteristiche individuato a livello metodologico mediante l'aggregazione dei valori SHAP, come previsto nella Sezione 3.4.1.

A differenza della procedura PCA, nella funzione `save_all_kde_plots()` non viene applicato un filtraggio esplicito sulla colonna `split_type`: le caratteristiche selezionate vengono caricate direttamente dai file dei benchmark e utilizzate per la costruzione delle distribuzioni. Il riferimento statistico è nuovamente individuato tramite `SOURCE_IDENTIFIER`; uno `StandardScaler` viene adattato alle sole feature disponibili nel dataset sorgente:

Codice 4.10: Adattamento dello standardizzatore sulle feature utilizzate per la KDE.

```
1 scaler = StandardScaler()
2 scaler.fit(df_source[valid_source_features])
```

Per ciascun benchmark, la trasformazione viene quindi applicata feature per feature utilizzando la media e il fattore di scala memorizzati nello scaler sorgente. La procedura implementa operativamente l'ancoraggio a (μ_S, σ_S) previsto dall'Equazione (3.40), mantenendo invariato il riferimento statistico anche per i benchmark target²².

²²Il vettore `scaler.scale_` calcolato da `StandardScaler` contiene la deviazione standard per ciascuna caratteristica, comprensiva del fattore di tolleranza $\epsilon > 0$ introdotto automaticamente dalla libreria per garantire la stabilità numerica ed evitare divisioni per zero in presenza di varianza nulla.

Codice 4.11: Trasformazione diagnostica feature-per-feature ancorata ai parametri dello scaler sorgente.

```
1 for feature in valid_features:
2     if feature in scaler.feature_names_in_:
3         idx = list(scaler.feature_names_in_).index(feature)
4         mu_s = scaler.mean_[idx]
5         sigma_s = scaler.scale_[idx]
6         X_test_scaled[feature] = (X_test_raw[feature] - mu_s) / sigma_s
```

La stima della densità viene effettuata mediante `seaborn.kdeplot()`, con separazione delle curve sulla base della classe binaria e con normalizzazione indipendente delle densità (`common_norm=False`). La regione sottostante le curve viene riempita mediante `fill=True`, mentre il parametro `cut=0` limita la rappresentazione all'intervallo definito dai dati osservati. Non viene specificato esplicitamente alcun parametro di *bandwidth*: la larghezza del kernel è quindi determinata mediante il comportamento predefinito della procedura KDE utilizzata da `seaborn`.

Poiché l'implementazione deve consentire l'ispezione di distribuzioni caratterizzate da scale molto differenti e da possibili forti sbilanciamenti nella densità, l'asse verticale dei grafici viene rappresentato mediante una scala *symlog*, con parametro `linthresh=1e-5`²³. Questa configurazione è distinta dalla formulazione teorica della proiezione logaritmica della densità riportata nella Sezione 3.4.1: nel codice non viene calcolato esplicitamente $\log_{10}(\hat{f}_y + \epsilon)$, ma viene modificata direttamente la scala dell'asse mediante le funzionalità grafiche di `Matplotlib`.

²³La scala *symlog* (Symmetric Logarithmic) applica una trasformazione logaritmica all'asse y mantenendo un intervallo puramente lineare all'interno della soglia `[-linthresh, +linthresh]`. Ciò previene divergenze verso $-\infty$ per densità prossime o pari a zero.

Codice 4.12: Generazione delle stime KDE ed impostazione della scala logaritmica simmetrica su asse y.

```
1 sns.kdeplot(  
2     data=X_test_scaled, x=feature, hue=labels, fill=True, alpha=0.3,  
3     common_norm=False, linewidth=2,  
4     palette={'Normal Traffic': '#1f77b4', 'Attack/Anomaly': '#ff7f0e'},  
5     ax=ax, warn_singular=False, cut=0  
6 )  
7  
8 ax.set_yscale('symlog', linthresh=1e-5)
```

Per ciascun benchmark viene prodotto un pannello contenente una KDE per ogni feature disponibile tra quelle richieste. Le tre caratteristiche selezionate vengono pertanto visualizzate in forma affiancata, con asse orizzontale espresso in termini di *Z-Score* e asse verticale etichettato come densità. I grafici vengono salvati a 300 dpi nella directory

data/preprocessed/metadata/plots/kde/

con nomenclatura determinata dall'identificativo del benchmark e dal nome del dataset.

Nel complesso, le due procedure costituiscono istanze distinte del medesimo principio di standardizzazione diagnostica dipendente dal sorgente: la PCA utilizza il riferimento sorgente per costruire una trasformazione geometrica comune a tutti i benchmark, mentre la KDE utilizza il medesimo riferimento per rendere confrontabili, su scala adimensionale, le distribuzioni delle tre caratteristiche selezionate. La standardizzazione rimane in entrambi i casi confinata alla componente diagnostico-visiva del framework e non modifica i dati impiegati dall'addestramento dei classificatori, in accordo con la separazione metodologica stabilita nel Capitolo 3.

A completamento dell'analisi implementativa, la Tabella 4.19 riassume in modo sinottico le principali differenze operative e concettuali che intercorrono tra la procedura di proiezione PCA e la stima della densità KDE. Sebbene entrambe le funzioni condividano la medesima filosofia di standardizzazione ancorata al benchmark sorgente *S*, esse operano su granularità differenti: la PCA offre una vista spazio-geometrica ad ampio spettro sull'intero set di caratteristiche, mentre la KDE consente un'ispezione analitica e mirata sul comportamento distributivo delle singole variabili a più alto impatto decisionale.

Tabella 4.19: Confronto sinottico tra le procedure diagnostiche di proiezione PCA e stima della densità KDE nel modulo plotting.

Dimensione di Confronto	Procedura <code>save_all_pca_plots()</code>	Procedura <code>save_all_kde_plots()</code>
Obiettivo Diagnostico	Ispezione geometrica della separabilità globale e variabilità nello spazio 2D	Analisi densometrica univariata del <i>domain shift</i> sulle feature chiave
Partizione Input	Filtraggio esplicito della sola partizione di test	Dataset completo senza filtraggio sulla colonna <code>split_type</code>
Feature Considerate	Tutto lo spazio vettoriale (escluse colonne target e meta-dati)	Sottoinsieme ridotto Top-3 SHAP (<code>pkts_per_sec</code> , <code>total_bytes</code> , <code>dst_win_byt</code>)
Ancoraggio Statistico	Fit di <code>StandardScaler</code> e <code>PCA(n_components=2)</code> su $\mathbf{X}_{S,\text{test}}$	Fit di <code>StandardScaler</code> sulle sole 3 feature del sorgente S
Trasformazione Target	Applica <code>scaler.transform()</code> e <code>pca.transform()</code> congelati	Mappatura vettoriale ancorata: $Z_D = (X_D - \mu_S) / (\sigma_S + \epsilon)$
Spazio di Rappresentazione	Spazio proiettato bidimensionale (PC1 vs PC2) con % varianza spiegata	Asse orizzontale in Z-Score adimensionale; asse verticale in scala <code>symlog</code>
Output Grafico	Scatter plot 2D con distinzione cromatica binaria per classe	Pannelli affiancati di stime KDE riempite (<code>fill=True</code>)

4.6.2 Implementazione di SHAP e TreeSHAP

L'analisi di spiegabilità viene integrata nella pipeline di classificazione mediante la funzione `save_shap_plot()`, invocata da `classification_processing()`. La procedura riceve il modello precedentemente addestrato, la matrice delle caratteristiche del test set, le relative etichette e i metadati necessari alla generazione e alla persistenza della rappresentazione grafica. L'ana-

lisi rimane pertanto confinata alla fase diagnostica e non modifica il modello precedentemente serializzato.

Prima della costruzione delle spiegazioni viene effettuato un campionamento stratificato e deterministico del test set (ancorato al seed di esecuzione), utilizzato per definire il dataset di background dell'algoritmo TreeSHAP. La dimensione massima del campione è fissata dalla costante `SHAP_MAX_SAMPLES=500`²⁴. Le quote assegnate alle due classi sono calcolate mediante il parametro `NORMAL_ANOMALY_RATIO`, secondo:

$$N_{\text{anom}} = \left\lfloor \frac{\text{SHAP_MAX_SAMPLES}}{\text{NORMAL_ANOMALY_RATIO}} \right\rfloor, \quad N_{\text{norm}} = \text{SHAP_MAX_SAMPLES} - N_{\text{anom}}. \quad (4.14)$$

Nel codice il valore effettivamente assegnato a `NORMAL_ANOMALY_RATIO` è pari a 10 (corrispondente al rapporto di sbilanciamento $\rho = 10 : 1$), mentre il campionamento delle singole classi viene effettuato mediante `pandas.Series.sample()` con `random_state=127001`. Gli indici estratti per il traffico nominale e per quello anomalo vengono successivamente concatenati e utilizzati per selezionare le corrispondenti righe di `X_test`. Nel caso in cui non sia disponibile alcun campione valido, viene applicato un campionamento casuale del test set, anch'esso limitato a `SHAP_MAX_SAMPLES` e controllato dallo stesso seed.

Nel Listato 4.13 è riportata la porzione di codice responsabile dell'estrazione stratificata, che bilancia i vincoli prestazionali con la necessità di mantenere una corretta rappresentatività di entrambe le classi.

²⁴Il sotto-campionamento deterministico del dataset di background costituisce una misura essenziale per contenere la complessità computazionale del calcolo dei valori di Shapley. Riducendo la cardinalità del campione di riferimento a una quota rappresentativa, si previene un incremento insostenibile dei tempi di esecuzione e dell'occupazione di memoria durante l'algoritmo TreeSHAP, preservando al contempo la convergenza stocastica delle stime empiriche e la stabilità delle spiegazioni rese.

Codice 4.13: Campionamento stratificato del test set per l'analisi SHAP.

```

1  # Allineamento delle etichette con le caratteristiche
2  y_series = pd.Series(
3      y_test, index=X_test.index if hasattr(X_test, 'index') else None
4  )
5
6  # Calcola le quote di campionamento per le due classi
7  n_anomaly = MLConstants.SHAP_MAX_SAMPLES // MLConstants.NORMAL_ANOMALY_RATIO
8  n_normal = MLConstants.SHAP_MAX_SAMPLES - n_anomaly
9
10 # Estrazione degli indici campionati per entrambe le classi,
11 # limitando al numero di istanze disponibili
12 idx_normal = pd.Index([])
13 if sum(y_series == 0) > 0:
14     idx_normal = y_series[y_series == 0].sample(
15         n=min(n_normal, sum(y_series == 0)),
16         random_state=MLConstants.MAIN_SEED
17     ).index
18 idx_anomaly = pd.Index([])
19 if sum(y_series == 1) > 0:
20     idx_anomaly = y_series[y_series == 1].sample(
21         n=min(n_anomaly, sum(y_series == 1)),
22         random_state=MLConstants.MAIN_SEED
23     ).index
24
25 sampled_idx = idx_normal.append(idx_anomaly)
26
27 # Filtra il test set originale utilizzando gli indici stratificati
28 # (o fallback a un campionamento casuale standard)
29 if not sampled_idx.empty:
30     X_test_sampled = X_test.loc[sampled_idx]
31 else:
32     X_test_sampled = X_test.sample(
33         n=min(MLConstants.SHAP_MAX_SAMPLES, len(X_test)),
34         random_state=MLConstants.MAIN_SEED
35     )

```

La costruzione dello spiegatore viene effettuata dinamicamente in funzione del classificatore ricevuto. L'implementazione tenta inizialmente di utilizzare `shap.TreeExplainer`, configurato con `feature_perturbation="tree_path_dependent"`²⁵ e `model_output="raw"`, opzioni orientate all'analisi di modelli ad albero quali `RandomForestClassifier` e `DecisionTreeClassifier`. Nel caso in cui tale configurazione non sia compatibile con il modello, viene eseguito un secondo tentativo mediante `shap.TreeExplainer(model)`. Qualora anche questa inizializzazione fallisca, viene utilizzato il costrutto generico `shap.Explainer(model, X_test_sampled)`. Tale meccanismo consente di mantenere un'unica interfaccia di generazione delle spiegazioni anche in presenza delle differenti modalità di supporto offerte dalla libreria SHAP ai classificatori considerati, come evidenziato dalla struttura condizionale `try-except` del Listato 4.14.

Codice 4.14: Inizializzazione dinamica dello spiegatore SHAP con catena di fallback.

```
1 # Inizializzazione dinamica dello spiegatore per supportare RF, DT e HGB
2 try:
3     # Primo tentativo: TreeExplainer standard ottimizzato per RF e DT
4     explainer = shap.TreeExplainer(
5         model,
6         feature_perturbation="tree_path_dependent",
7         model_output="raw"
8     )
9 except Exception as explainer_err:
10     # Tentativo di fallback: TreeExplainer generico o Explainer universale
11     try:
12         explainer = shap.TreeExplainer(model)
13     except Exception:
14         explainer = shap.Explainer(model, X_test_sampled)
```

L'intera architettura della pipeline, articolata nelle sue quattro fasi di elaborazione (dal campionamento iniziale alla persistenza dell'artefatto), è schematizzata in Figura 4.9.

²⁵La modalità `tree_path_dependent` calcola le aspettative condizionali seguendo la struttura trasversale dei nodi degli alberi senza richiedere un dataset di *background* esplicito (a differenza dell'approccio *interventional*). Ciò riduce drasticamente il costo computazionale e gestisce la correlazione tra le variabili.




Figura 4.9: Architettura della pipeline di spiegabilità SHAP per i modelli di classificazione. Il diagramma illustra le quattro fasi sequenziali disposte in blocchi verticalmente allineati con connessioni di flusso circolare (effetto Pacman) sul margine destro/sinistro tra le diverse fasi.

I valori di Shapley vengono quindi calcolati sul campione selezionato mediante il metodo `shap_values()`. L'implementazione disabilita esplicitamente il controllo di additività mediante `check_additivity=False`²⁶, quando tale argomento è supportato dallo specifico explainer. In caso contrario, viene eseguita una seconda chiamata senza tale parametro. La procedura prevede inoltre una normalizzazione della struttura restituita dalla libreria, necessaria a gestire le differenti

²⁶La disabilitazione del controllo di additività previene l'interruzione improvvisa dell'esecuzione dovuta a microscopiche discrepanze numeriche dovute alla precisione in virgola mobile (*floating-point precision*) tra la somma dei valori SHAP e l'output teorico in modelli ad albero complessi.

rappresentazioni possibili dei valori SHAP. In particolare, quando viene restituita una lista di matrici corrispondenti alle due classi, viene selezionata la componente relativa alla classe positiva, ossia Attack/Anomaly. Analogamente, nel caso di un array tridimensionale, viene selezionata la componente associata all'indice di classe 1, mentre una matrice già bidimensionale viene utilizzata direttamente.

La spiegazione risultante è infine visualizzata mediante `shap.summary_plot()` utilizzando la configurazione `plot_type="dot"`. Tale rappresentazione associa a ciascuna caratteristica i valori SHAP osservati sui campioni selezionati, permettendo di rappresentare simultaneamente l'ampiezza e il verso del contributo delle singole variabili alla predizione. Il numero massimo di caratteristiche visualizzate viene impostato dinamicamente al numero di colonne della matrice `X_test_sampled`, mediante il parametro `max_display=n_features`. La dimensione verticale della figura viene inoltre adattata al numero complessivo di feature, secondo una dimensione minima di 6 pollici e un incremento proporzionale pari a 0.4 pollici per caratteristica.

Il Listato 4.15 illustra la sequenza logica che, partendo dall'estrazione tensoriale tramite l'oggetto `explainer`, normalizza la struttura dati e ne adatta il rendering in funzione della dimensione del *feature space*.

Codice 4.15: Calcolo, normalizzazione dimensionale e rendering dei valori SHAP.

```
1 # Calcolo dei valori SHAP con gestione del controllo di additività
2 try:
3     shap_values = explainer.shap_values(
4         X_test_sampled, check_additivity=False
5     )
6 except TypeError:
7     shap_values = explainer.shap_values(X_test_sampled)
8
9 # Gestire le disparità di output
10 if hasattr(shap_values, "values"):
11     shap_values_raw = shap_values.values
12 else:
13     shap_values_raw = shap_values
14
15 # Estrazione dei valori della classe Anomaly in base alla struttura dei dati
16 if isinstance(shap_values_raw, list) and len(shap_values_raw) == 2:
17     shap_values_raw = shap_values_raw[1]
18 elif hasattr(shap_values_raw, 'shape') and len(shap_values_raw.shape) == 3:
19     shap_values_raw = shap_values_raw[:, :, 1]
20 elif hasattr(shap_values_raw, 'shape') and len(shap_values_raw.shape) == 2:
21     pass
22
23 # Genera e configura dinamicamente il grafico
24 n_features = X_test_sampled.shape[1]
25 plt.figure(figsize=(8, max(6, n_features * 0.4)))
26
27 # Forza la visualizzazione "dot" per mostrare
28 # gli impatti individuali delle feature
29 shap.summary_plot(
30     shap_values_raw,
31     X_test_sampled,
32     show=False,
33     max_display=n_features,
34     plot_type="dot"
35 )
```

Il grafico SHAP prodotto viene salvato con risoluzione pari a 300 dpi nella directory shap e organizzata per modello. Il nome del file png viene costruito combinando il tipo di dataset, il nome del dataset. La procedura consente pertanto di mantenere separati gli artefatti di spiegabilità relativi ai diversi modelli e benchmark analizzati.

A completamento della descrizione implementativa, la Tabella 4.20 sintetizza i parametri principali definiti all'interno del modulo, esplicitando le configurazioni adottate e le rispettive motivazioni ingegneristiche.

Tabella 4.20: Sintesi dei parametri di configurazione e delle scelte ingegneristiche della pipeline SHAP.

Parametro = Impostazione	Scopo Ingegnistico e Funzionale
SHAP_MAX_SAMPLES = 500	Contenimento del costo computazionale e della complessità temporale $O(N)$ nel calcolo dei valori SHAP.
NORMAL_ANOMALY_RATIO = 10	Preservazione del rapporto di sbilanciamento nativo ($\rho = 10 : 1$) tra la classe nominale e quella anomala.
feature_perturbation = "tree_path_dependent"	Calcolo rapido delle aspettative condizionali lungo i percorsi degli alberi senza dipendenza da un dataset di <i>background</i> esplicito.
plot_type = "dot"	Visualizzazione ad alta densità che mostra simultaneamente ampiezza, verso e dispersione dei contributi di ciascuna caratteristica.
check_additivity = False	Prevenzione dell'interruzione della pipeline causata da microscopiche discrepanze numeriche di precisione in virgola mobile (<i>floating-point</i>).

Nel complesso, l'implementazione realizza una pipeline di spiegabilità indipendente dalla fase di addestramento: il modello già addestrato viene utilizzato come input per TreeExplainer o, quando necessario, per l'explainer generico di shap, mentre le spiegazioni vengono calcolate su un campione controllato del test set. Questa separazione mantiene coerente l'analisi con il

principio metodologico secondo cui SHAP viene utilizzato come strumento diagnostico post-hoc per analizzare il contributo delle caratteristiche alle decisioni dei classificatori ad albero.

4.6.3 Pipeline di Aggregazione SHAP–KDE

Il raccordo tra l'analisi di spiegabilità SHAP e la successiva analisi densometrica KDE non è implementato mediante una procedura automatizzata all'interno del framework software²⁷. La selezione delle caratteristiche destinate alla rappresentazione KDE viene infatti effettuata attraverso un passaggio di analisi manuale dei grafici SHAP prodotti dalla pipeline diagnostica.

Al fine di formalizzare la natura ibrida di tale procedura, la Figura 4.10 illustra l'architettura logica del raccordo *Human-in-the-Loop*. Il diagramma evidenzia la scomposizione del flusso di lavoro in tre fasi sequenziali: una prima fase di automazione diagnostica, una fase intermedia di supervisione umana in cui avviene l'estrazione quantitativa del parametro empirico, e una successiva fase di esecuzione densometrica automatizzata.

²⁷La scelta di non automatizzare tale raccordo previene la propagazione non controllata di rumore transitorio o di instabilità di *ranking* tra i differenti *seed* sperimentali.




Figura 4.10: Diagramma architetturale del raccordo *Human-in-the-Loop* tra l'analisi diagnostica (SHAP) e la valutazione densometrica (KDE). L'intervento manuale (Fase 2) funge da disaccoppiamento metodologico tra le due pipeline automatizzate.

Per ciascun grafico SHAP generato vengono considerate le prime tre caratteristiche riportate nel `summary_plot`. Poiché la rappresentazione `plot_type="dot"` ordina le caratteristiche sulla base della loro rilevanza globale, le prime tre righe del grafico costituiscono il sottoinsieme di interesse per la procedura di conteggio. L'analisi viene ripetuta considerando tutti i grafici SHAP prodotti per le combinazioni di modelli, benchmark e seed previste dal protocollo sperimentale.

A partire da tale ispezione viene costruito manualmente un contatore per ciascuna caratteristica

j , definito come:

$$C_j = \sum_{r=1}^R \mathbb{I}(j \in \mathcal{T}_r), \quad (4.15)$$

dove R rappresenta il numero complessivo di grafici SHAP analizzati, $\mathcal{T}_r$ denota l'insieme delle tre caratteristiche collocate nelle prime posizioni del grafico r e $\mathbb{I}(\cdot)$ è la funzione indicatrice. Di conseguenza, C_j esprime il numero di occorrenze con cui la caratteristica j compare tra le prime tre posizioni nelle spiegazioni considerate. I risultati del conteggio empirico effettuato sulle spiegazioni diagnostiche sono sintetizzati nella Tabella 4.21.

Tabella 4.21: Distribuzione delle frequenze di occorrenza C_j delle caratteristiche registrate nelle prime tre posizioni dei grafici SHAP.

Caratteristica (j)	Occorrenze (C_j)	Frequenza Relativa (C_j/R)
pkts_per_sec	C_1	$\sim 18.89\%$
total_bytes	C_2	$\sim 17.04\%$
dst_win_byt	C_3	$\sim 11.67\%$

La frequenza così ottenuta viene utilizzata come criterio empirico di selezione delle caratteristiche da sottoporre alla successiva stima KDE. Le tre caratteristiche caratterizzate dai valori di C_j più elevati sono risultate essere `pkts_per_sec`, `total_bytes` e `dst_win_byt`. La selezione viene quindi trasferita manualmente nella configurazione del framework mediante la costante:

Codice 4.16: Configurazione delle feature selezionate per l'analisi KDE.

```
1 KDE_TOP_FEATURES = ['pkts_per_sec', 'total_bytes', 'dst_win_byt']
```

La funzione `save_all_kde_plots()` utilizza successivamente tale lista come insieme di caratteristiche da analizzare, senza ricalcolare automaticamente il conteggio C_j né eseguire una nuova selezione sulla base dei grafici SHAP. Il passaggio SHAP-KDE deve pertanto essere inteso come una procedura di selezione supervisionata manualmente dall'analista: SHAP fornisce il criterio diagnostico per individuare le caratteristiche più ricorrenti nelle posizioni di maggiore rilevanza, mentre la KDE costituisce lo strumento successivo per l'ispezione delle rispettive distribuzioni.

Nel protocollo adottato non si è verificata alcuna situazione di parità tra caratteristiche nei valori del contatore C_j ²⁸ tali da richiedere una regola di spareggio. La lista finale KDE_TOP_FEATURES rappresenta pertanto la selezione conclusiva utilizzata nella fase di analisi densometrica descritta nella Sezione 4.6.1.

4.7 Sintesi della Pipeline Implementativa

La pipeline implementativa descritta nel presente capitolo costituisce la traduzione operativa del framework metodologico definito nel Capitolo 3. L'architettura è organizzata in moduli logicamente distinti, corrispondenti alle principali fasi del ciclo di elaborazione: acquisizione e armonizzazione dei dati, costruzione dei benchmark, addestramento multi-seed, inferenza, valutazione e analisi diagnostica. Tale decomposizione consente di mantenere separati il flusso computazionale principale e le procedure di analisi, preservando la modularità dell'infrastruttura software e la riproducibilità delle singole fasi. Inoltre, la struttura disaccoppiata garantisce un'elevata estensibilità dell'architettura software: l'integrazione di nuovi dataset target o l'inclusione di ulteriori algoritmi di classificazione può essere effettuata in modo trasparente, agendo unicamente sulle definizioni contenute nel file di configurazione centralizzato (`config.py`), senza dover modificare la logica di elaborazione dei singoli moduli computazionali.

La Tabella 4.22 riassume la mappa dei moduli Python sviluppati, i rispettivi file sorgente, le responsabilità primarie e i flussi di Input/Output che attraversano l'architettura software.

²⁸In caso di parità nel contatore C_j , la regola formale di spareggio avrebbe previsto un ordinamento secondario decrescente basato sull'impatto medio assoluto di Shapley $|\bar{\phi}_j| = \frac{1}{R} \sum_{r=1}^R |\phi_{j,r}|$, calcolato esclusivamente sulle esecuzioni che hanno generato l'ex aequo.

Tabella 4.22: Riepilogo dell'architettura software end-to-end.

File Sorgente	Responsabilità Principale	Input / Output
Punto di Ingresso		
main.py	Gestione CLI interattiva e orchestrazione del ciclo esecutivo multi-seed (s_0 e S).	In: Comandi CLI, parametri Out: Trigger pipeline esecutive
Allineamento Feature		
src/data_preprocessing.py	Mappatura ψ_k , derivazione metriche e allineamento allo spazio coordinato ($d = 16$).	In: Dataframe parziali Out: Dataframe coordinati (16 feature)
Core Preprocessing		
src/file_preprocessing.py	Pulizia, campionamento stratificato ($\rho = 10$), bilanciamento e split 80/20 train/test.	In: Dataframe coordinati Out: Benchmark (data/preprocessed/)
Gestione Modelli		
src/models.py	Istanziamento, fitting dei classificatori (DT, RF, HGB), naming e serializzazione pesi.	In: Dataset pre-processati Out: Pesi .joblib, update models_metadata.csv
Inferenza & Valutazione		
src/classification.py	Inferenza sui test set, generazione matrici di confusione e calcolo metriche.	In: Modelli .joblib e test set Out: CSV risultati in runs/.../results/

Diagnostica & Visualizzazione		
src/plotting.py	Mappe di calore, diagnostica spaziale (PCA, KDE con StandardScaler) e XAI (TreeSHAP).	In: Matrici, log e dataset Out: Grafici e diagrammi (PNG/PDF)
Configurazione		
src/utils/config.py	Centralizzazione costanti (MLConstants, $\rho = 10$, semi stocastici, path).	In: N.D. Out: Parametri globali di runtime
I/O & Persistenza		
src/utils/file_utils.py	Gestione I/O su disco, salvataggio/caricamento sicuro di artefatti e registri CSV.	In: Oggetti Python, file dati Out: Persistenza strutturata su disco
Metriche Spiegabili		
src/utils/metrics.py	Formalizzazione e calcolo sintetico delle metriche (Accuracy, F1, ROC-AUC, ecc.).	In: Vettori etichette y e $\hat{y}$ Out: Dizionari/Dataframe di metriche

Il processo ha origine dai domini sorgente e target, i cui dati vengono sottoposti alle procedure di filtraggio e allineamento descritte nella Sezione 4.3. L'operatore ψ_k riconduce le rappresentazioni eterogenee a uno spazio condiviso di caratteristiche, sul quale vengono successivamente applicati i criteri di composizione e partizionamento necessari alla costruzione dei benchmark sperimentali. I dataset risultanti costituiscono l'input del modulo di classificazione, senza introdurre alcuna ulteriore scalatura esplicita nel flusso principale, in accordo con quanto discusso nella Sezione 4.3.3.

La fase di apprendimento viene quindi eseguita mediante l'istanziatura dei classificatori *Decision Tree*, *Random Forest* e *Histogram-based Gradient Boosting*, ripetuta sui semi stocastici definiti dal protocollo. Per ogni combinazione tra algoritmo, benchmark e seme vengono prodotti gli artefatti relativi al modello e ai relativi metadati, mantenendo l'isolamento delle diverse esecuzioni nella struttura gerarchica della directory runs/.

I modelli così ottenuti vengono successivamente utilizzati nella fase di inferenza sugli insiemi

di test, generando predizioni e punteggi di probabilità SHAP. Le predizioni e i relativi punteggi alimentano il calcolo delle metriche e la costruzione delle matrici di valutazione, mentre l'aggregazione delle osservazioni sui diversi semi fornisce gli ingressi per la successiva procedura di confronto statistico. Gli artefatti prodotti lungo tale percorso vengono persistiti secondo la struttura organizzativa descritta nella Sezione 4.1.1, mantenendo distinti modelli, risultati e prodotti delle analisi.

Parallelamente al flusso principale opera il modulo diagnostico. La standardizzazione utilizzata per PCA e KDE viene mantenuta separata dal grafo computazionale di training e inferenza. Le caratteristiche individuate mediante l'ispezione dei grafici SHAP vengono quindi utilizzate per configurare l'analisi KDE, secondo la procedura supervisionata descritta nella Sezione 4.6.3.

La composizione complessiva degli stadi implementativi è sintetizzata nella Figura 4.11, che evidenzia, con il relativo dettaglio parametrico, il flusso principale della pipeline e il relativo ramo diagnostico.

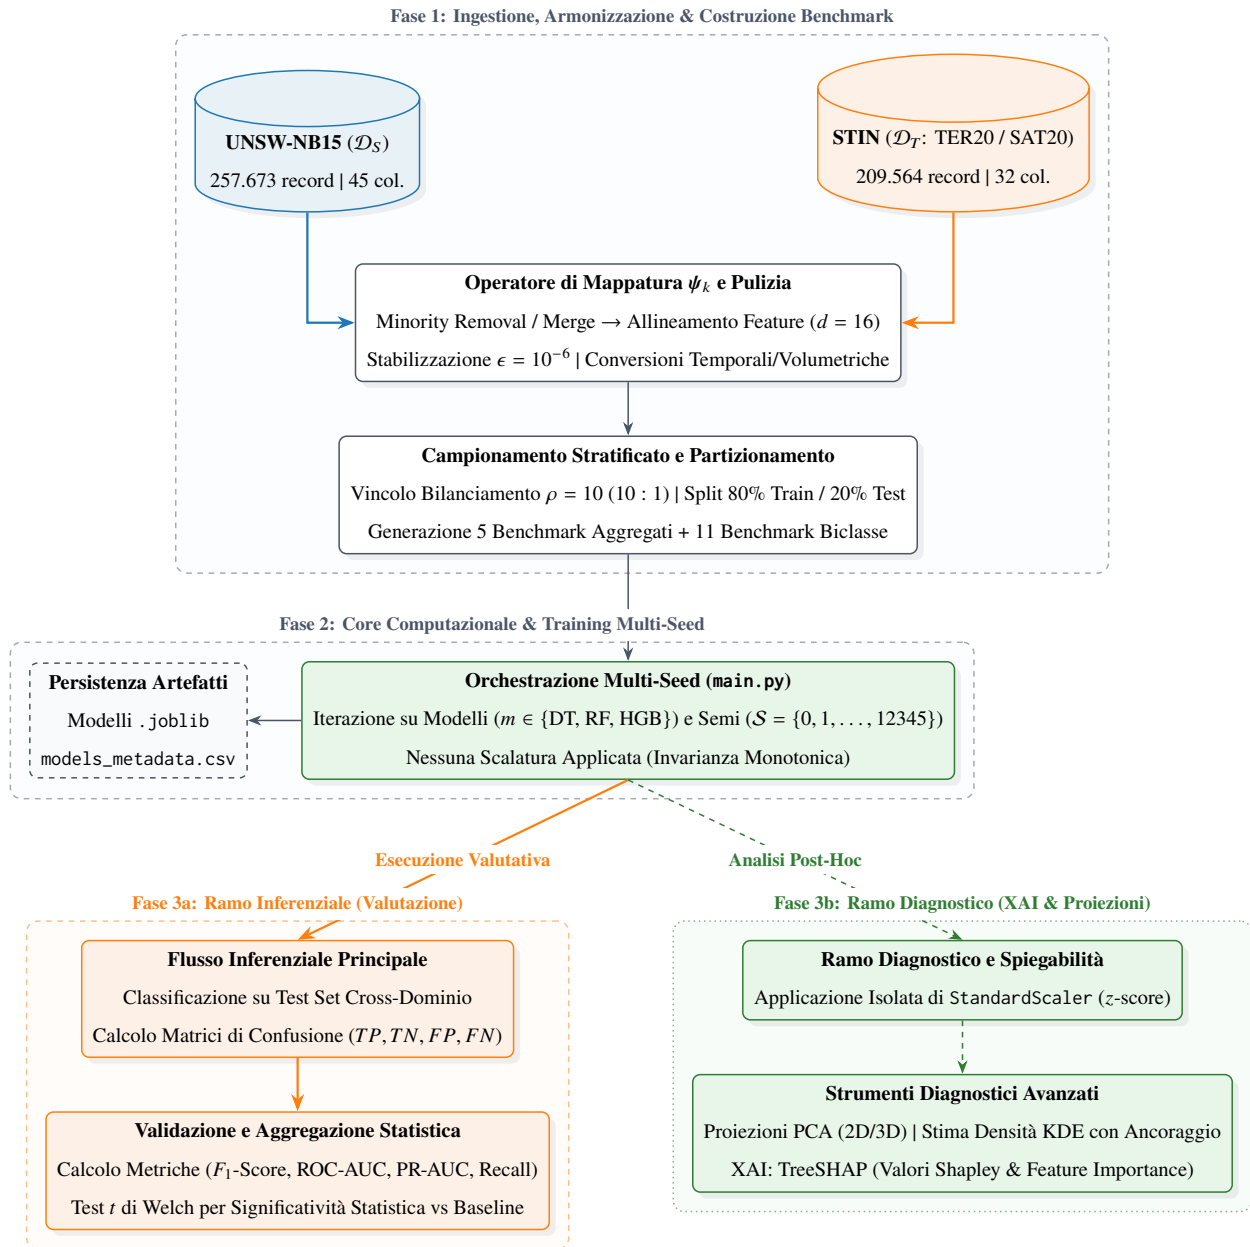


Figura 4.11: Architettura software end-to-end e flusso di esecuzione unificato: dall'ingestione dei dataset grezzi, passando per l'armonizzazione delle feature e il ciclo di addestramento multi-seed, fino alla biforcazione tra ramo inferenziale (valutazione prestazionale) e ramo diagnostico (PCA, KDE e TreeSHAP).

La Figura 4.11 evidenzia pertanto la separazione funzionale tra il percorso principale, destinato alla costruzione e alla valutazione degli stimatori, e il ramo diagnostico, dedicato alla caratterizzazione geometrica, distributiva e interpretativa dei dati e dei modelli. La persistenza degli artefatti

costituisce il punto comune tra le diverse fasi, consentendo di mantenere disponibili modelli, metriche, matrici e rappresentazioni grafiche secondo una struttura riproducibile.

La descrizione implementativa si conclude con la definizione di tale catena end-to-end. Gli output generati dalla pipeline costituiscono quindi la base documentale e quantitativa sulla quale viene sviluppata, nel Capitolo 5, l'analisi dei risultati sperimentali.

5. Analisi dei Risultati e Discussione Sperimentale

Il presente capitolo espone e analizza i risultati ottenuti mediante il protocollo sperimentale implementato nel Capitolo 4, ponendo particolare attenzione alla capacità delle differenti configurazioni di classificazione di mantenere un comportamento discriminativo stabile in presenza di variazioni del dominio di traffico.

L'analisi viene condotta secondo una progressione coerente con il framework metodologico definito nel Capitolo 3. In primo luogo, viene esaminata la struttura geometrica e distributiva dei benchmark mediante gli strumenti diagnostici PCA e KDE, al fine di caratterizzare preliminarmente l'entità dello scostamento tra il dominio sorgente e le configurazioni contenenti traffico target. Successivamente, vengono valutate le prestazioni della baseline *INJECTION*, assunta come riferimento sperimentale, e confrontate separatamente con quelle dei modelli addestrati esclusivamente sul dominio sorgente e con quelle dei modelli ibridi.

La valutazione quantitativa viene sviluppata combinando i risultati puntuali ottenuti per il seed rappresentativo $s = 42$ con le statistiche aggregate sulle $K = 10$ repliche stocastiche definite nel protocollo *multi-seed*. Tale impostazione consente di distinguere la descrizione analitica delle singole configurazioni dalla verifica della stabilità dei risultati rispetto all'inizializzazione degli stimatori. Il confronto viene infine completato mediante il test t di Welch sull'*F1-Score* e attraverso l'analisi post-hoc SHAP delle caratteristiche maggiormente coinvolte nelle decisioni dei classificatori.

La parte conclusiva del capitolo integra quindi le evidenze prestazionali, distributive e di spiegabilità, con l'obiettivo di individuare associazioni coerenti tra variazioni dello spazio delle caratteristiche e comportamento predittivo. Le eventuali relazioni individuate vengono interpretate nei limiti consentiti dagli artefatti sperimentali disponibili, distinguendo le evidenze direttamente osservabili dalle possibili spiegazioni di carattere trasmissivo e di rete.

5.1 Diagnostica Spaziale e Distributiva

Prima di procedere alla valutazione quantitativa dei classificatori, viene caratterizzata la disposizione dei benchmark nello spazio condiviso delle caratteristiche $\mathcal{X}$ mediante gli strumenti diagnostici

PCA e KDE implementati nella Sezione 4.6.1. L'analisi considera tre configurazioni rappresentative del protocollo: il benchmark sorgente NB15, la baseline INJECTION e il benchmark ibrido NB15_STIN. Tale sequenza descrive il passaggio da una componente malevola interamente sorgente, a una configurazione contenente una conoscenza target sparsa, fino alla sostituzione completa degli attacchi sorgente con traffico malevolo target.

A seguito del ricampionamento con rapporto $\rho_{\text{ben}/\text{mal}} = 10/1$, ciascun benchmark aggregato comprende 102 300 osservazioni, delle quali 93 000 nominali e 9 300 malevole. La proporzione tra le due macro-classi rimane quindi invariata; ciò che varia tra le configurazioni è la composizione e la distribuzione della componente malevola.

5.1.1 Proiezioni PCA dello Spazio delle Feature

Riferimento statistico e composizione dei test set. L'Analisi delle Componenti Principali viene impiegata esclusivamente a scopo diagnostico sulle partizioni di test, utilizzando il sistema di riferimento dipendente dal dominio sorgente definito nel Capitolo 4. Lo standardizzatore è adattato su NB15 e le statistiche (μ_S, σ_S) così ottenute vengono mantenute fisse per le configurazioni successive. Analogamente, la matrice degli autovettori $\mathbf{W}_S$ viene determinata una sola volta mediante il fitting della PCA sul benchmark sorgente standardizzato. Un generico benchmark D viene pertanto proiettato secondo

$$\mathbf{P}_D = \left(\frac{\mathbf{X}_D - \mu_S}{\sigma_S + \epsilon} \right) \mathbf{W}_S, \quad (5.1)$$

senza ricalcolare localmente lo standardizzatore o gli assi principali.

Le tre partizioni di test presentano la medesima cardinalità, pari a 20 460 osservazioni, suddivise in 18 600 campioni nominali e 1 860 malevoli. La composizione della classe positiva risulta tuttavia differente: in NB15 tutti i 1 860 attacchi appartengono al dominio sorgente; in INJECTION, 1 854 sono sorgente e soltanto 6 sono target; in NB15_STIN, tutti i 1 860 attacchi provengono invece da STIN. I 6 campioni target presenti nel test set INJECTION comprendono 1 Botnet, 1 DDoS e 4 UDP_DDoS, senza osservazioni Syn_DDoS. Nel test set NB15_STIN, la componente positiva è costituita da 349 Botnet, 497 DDoS, 494 Syn_DDoS e 520 UDP_DDoS.

Le prime due componenti spiegano rispettivamente il 40.35% e il 16.00% della varianza della distribuzione sorgente, per una quota complessiva pari al 56.36%. Poiché scaler e PCA rimangono congelati, tali percentuali identificano il sistema di coordinate definito da NB15 e non implicano che i tre benchmark possiedano la medesima struttura di varianza.




Figura 5.1: Proiezione PCA bidimensionale del benchmark sorgente NB15 nel sistema di riferimento ottenuto mediante standardizzazione e fitting sul dominio sorgente.

Distribuzione geometrica del dominio sorgente. La Figura 5.1 costituisce il riferimento geometrico dell'analisi. La maggior parte delle osservazioni occupa una regione relativamente compatta e curvilinea del piano, accompagnata da estensioni periferiche lungo entrambe le componenti. All'interno della regione principale è presente una consistente sovrapposizione tra traffico nominale e malevolo, mentre alcune osservazioni anomale assumono posizioni più periferiche.

Le prime due componenti non evidenziano pertanto una separazione globale netta delle classi. Poiché la PCA non utilizza l'etichetta Y nella costruzione degli assi, tale risultato indica esclusivamente che la struttura discriminativa dello spazio originario a 16 dimensioni non è riconducibile a una semplice separazione lineare nel piano formato da PC1 e PC2.




Figura 5.2: Proiezione PCA bidimensionale del benchmark INJECTION, utilizzato per l’addestramento della baseline $\mathcal{M}_{\text{base}}$, nel sistema di riferimento PCA definito dal dominio sorgente.

Effetto dell’iniezione target sparsa. La configurazione INJECTION, mostrata nella Figura 5.2, conserva una geometria complessivamente prossima a quella sorgente. Dei 1 860 campioni malevoli del test set, infatti, 1 854 appartengono a NB15 (99.68%) e soltanto 6 a STIN (0.32%). La regione maggiormente popolata rimane quindi dominata dalla distribuzione sorgente e conserva l’estesa sovrapposizione tra le due macro-classi osservata in Figura 5.1.

Sono contestualmente presenti osservazioni malevole collocate a notevole distanza dal nucleo principale. La loro posizione è compatibile con valori fortemente esterni alla distribuzione dominante; tuttavia, la rappresentazione codifica esclusivamente le classi *Normal Traffic* e *Attack/Anomaly*, senza distinguere il dominio di origine dei singoli campioni. Non è pertanto possibile attribuire visivamente tali punti periferici ai 6 campioni target presenti nel test set.




Figura 5.3: Proiezione PCA bidimensionale del benchmark ibrido NB15_STIN, composto da traffico nominale sorgente NB15 e traffico malevolo target STIN, nel sistema di riferimento PCA definito dal dominio sorgente.

Sostituzione completa della componente malevola. Una configurazione sostanzialmente differente emerge per NB15_STIN, riportato nella Figura 5.3. In questo caso tutti i 1 860 campioni positivi del test set appartengono a STIN. Proiettati nel sistema statistico adattato esclusivamente su NB15, tali vettori raggiungono coordinate di ordine sensibilmente superiore rispetto al benchmark sorgente, con una scala del piano dell'ordine di 10^6 . Il traffico nominale appare conseguentemente compresso nell'intorno dell'origine, pur mantenendo invariata la propria cardinalità di 18 600 campioni.

L'interpretazione della separazione richiede tuttavia una cautela fondamentale: in NB15_STIN, classe e dominio di origine risultano strutturalmente associati,

$$Y = 0 \Rightarrow D = \text{NB15}, \quad Y = 1 \Rightarrow D = \text{STIN}.$$

La distanza osservata nel piano PCA incorpora quindi sia la differenza tra classe nominale e malevola sia lo scostamento distributivo tra i due domini, senza consentire di separarne i rispettivi

contributi. La proiezione fornisce pertanto evidenza diagnostica di un marcato scostamento rispetto al riferimento sorgente, ma non permette di attribuirlo esclusivamente alla separabilità delle classi.

Sintesi dell'evidenza PCA. Le tre proiezioni descrivono una progressione geometrica coerente con la composizione della componente malevola: NB15 costituisce il riferimento, INJECTION rimane largamente dominato dal sorgente, mentre NB15_STIN presenta un marcato scostamento nel sistema di coordinate ancorato a NB15. La PCA non identifica tuttavia quali caratteristiche dello spazio originario siano maggiormente associate a tale variazione; questo aspetto viene approfondito mediante l'analisi densometrica successiva.

5.1.2 Stime di Densità di Kernel (KDE) e Domain Shift

Impostazione dell'analisi distributiva. L'analisi PCA viene affiancata da un'ispezione delle distribuzioni marginali mediante *Kernel Density Estimation* (KDE). L'analisi è circoscritta alle tre caratteristiche selezionate mediante la procedura SHAP-KDE descritta nel Capitolo 4: `pkts_per_sec`, `total_bytes` e `dst_win_byt`.

I valori sono rappresentati mediante la standardizzazione dipendente dal sorgente definita nel framework metodologico. Di conseguenza, $z = 0$ corrisponde alla media sorgente della specifica caratteristica e gli scostamenti sono espressi rispetto alle statistiche calcolate su NB15.

A differenza della PCA, la routine KDE considera l'intero benchmark ricampionato e non soltanto la partizione di test. Ciascuna configurazione comprende quindi 93 000 campioni nominali e 9 300 malevoli. In NB15 tutti gli attacchi sono sorgente; in INJECTION la componente positiva comprende 9 271 attacchi sorgente e 29 target; in NB15_STIN tutti i 9 300 attacchi appartengono invece al dominio target.

Le densità delle due macro-classi sono normalizzate indipendentemente (`common_norm=False`); l'altezza relativa delle curve non esprime pertanto la diversa numerosità delle classi. L'interpretazione riguarda posizione, dispersione, estensione e sovrapposizione dei rispettivi supporti.

A supporto delle rappresentazioni grafiche, le statistiche disponibili per le singole famiglie d'attacco sono aggregate nelle rispettive componenti malevole. Indicando con C_A l'insieme delle classi malevole, la media aggregata è

$$\mu_A = \frac{\sum_{c \in C_A} n_c \mu_c}{\sum_{c \in C_A} n_c}, \quad (5.2)$$

mentre la varianza complessiva, comprendente sia la dispersione interna alle classi sia quella tra le rispettive medie, è

$$\sigma_A^2 = \frac{\sum_{c \in C_A} [(n_c - 1)\sigma_c^2 + n_c(\mu_c - \mu_A)^2]}{\sum_{c \in C_A} n_c - 1}. \quad (5.3)$$

La Tabella 5.1 riporta le statistiche così ottenute. I valori descrivono le popolazioni di classe originarie dalle quali sono costruiti i benchmark ricampionati e devono essere utilizzati come riferimento quantitativo dello scostamento distributivo, non come coordinate Z-score dei singoli punti rappresentati nelle KDE.

Tabella 5.1: Statistiche descrittive delle tre feature KDE per il traffico nominale sorgente e per le componenti malevole di NB15, INJECTION e NB15_STIN.

Configurazione	Componente	pkts_per_sec		total_bytes		dst_win_byt	
		μ	σ^2	μ	σ^2	μ	σ^2
NB15	Nominale	6.7933×10^4	5.7237×10^{10}	3.0231×10^4	1.7286×10^{10}	176.6758	1.3836×10^4
NB15	Malevola	2.0131×10^5	5.1871×10^{10}	1.9513×10^4	7.4651×10^{10}	87.5202	1.4658×10^4
INJECTION	Malevola	4.5475×10^8	9.0889×10^{20}	1.9463×10^4	7.4455×10^{10}	87.2266	1.4635×10^4
NB15_STIN	Malevola	1.1202×10^{11}	2.1150×10^{23}	1.0891×10^3	1.4180×10^6	-0.7813	4.0057×10^3




Figura 5.4: Stime KDE delle feature `pkts_per_sec`, `total_bytes` e `dst_win_byt` per il benchmark sorgente NB15, espresse mediante standardizzazione ancorata al dominio sorgente.

Distribuzioni del dominio sorgente. La Figura 5.4 costituisce il riferimento distributivo dell'analisi. Per `pkts_per_sec`, entrambe le macro-classi presentano un'elevata concentrazione in prossimità della regione centrale e una consistente sovrapposizione. Come riportato nella Tabella 5.1, le rispettive varianze risultano dello stesso ordine di grandezza, confermando un'elevata dispersione intraclasse.

Anche `total_bytes` presenta supporti ampiamente sovrapposti, con una dispersione della componente malevola superiore a quella nominale. `dst_win_byt` mostra invece una struttura più articolata e bimodale, accompagnata da varianze confrontabili tra le due macro-classi. Nel complesso, nessuna delle tre feature produce isolatamente una separazione distributiva semplice e completa tra traffico nominale e malevolo, in accordo con la sovrapposizione osservata nel piano PCA sorgente.

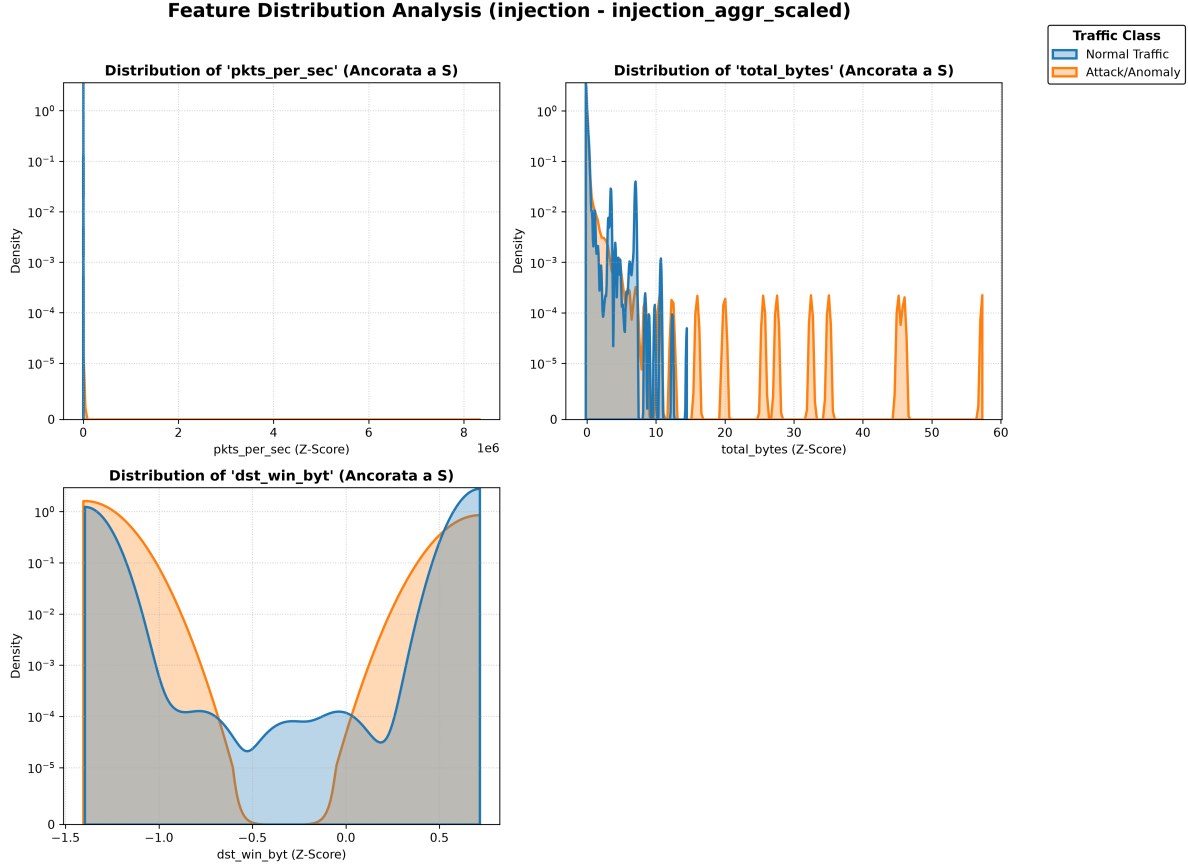


Figura 5.5: Stime KDE delle feature `pkts_per_sec`, `total_bytes` e `dst_win_byt` per il benchmark INJECTION, utilizzato per l'addestramento della baseline $\mathcal{M}_{\text{base}}$.

Effetto distributivo dell'iniezione sparsa. La configurazione INJECTION, mostrata nella Figura 5.5, conserva una morfologia dominante prossima al dominio sorgente, coerentemente con la presenza di soli 29 campioni target sui 9 300 attacchi complessivi, pari a circa lo 0.31% della componente malevola.

La variazione più evidente interessa `pkts_per_sec`. Alla regione principale, ancora dominata dagli attacchi NB15, si affianca una coda estremamente estesa verso valori positivi dello Z-score. Rispetto alla componente malevola sorgente, la media aggregata aumenta di oltre tre ordini di grandezza, mentre la varianza cresce di oltre dieci ordini. Una quota target numericamente ridotta produce quindi un effetto chiaramente osservabile sui primi due momenti di questa caratteristica, senza modificare la regione di maggiore densità del benchmark.

Un comportamento differente emerge per `total_bytes` e `dst_win_byt`. Per entrambe le

caratteristiche, media e varianza della componente malevola rimangono prossime ai corrispondenti valori NB15 riportati nella Tabella 5.1, coerentemente con la forte dominanza numerica della componente sorgente.

L'effetto dell'iniezione risulta pertanto eterogeneo tra le dimensioni analizzate: lo scostamento è già marcato per `pkts_per_sec`, mentre risulta molto più contenuto per `total_bytes` e `dst_win_byt`. Il *domain shift* non assume quindi la forma di una traslazione uniforme dell'intero spazio delle caratteristiche.




Figura 5.6: Stime KDE delle feature `pkts_per_sec`, `total_bytes` e `dst_win_byt` per il benchmark ibrido NB15_STIN, costituito da traffico nominale sorgente NB15 e traffico malevolo target STIN.

Domain shift nella configurazione ibrida. La sostituzione completa della componente malevola in NB15_STIN, mostrata nella Figura 5.6, determina una variazione distributiva sensibilmente più pronunciata.

Per `pkts_per_sec`, la media della componente malevola passa da 2.0131×10^5 nel dominio sorgente a 1.1202×10^{11} nel traffico STIN, con un rapporto superiore a 5.5×10^5 . La varianza aumenta contestualmente da 5.1871×10^{10} a 2.1150×10^{23} , ossia di oltre dodici ordini di grandezza. Quando tali osservazioni vengono standardizzate mediante le statistiche sorgente, la presenza di Z-score dell'ordine di 10^6 risulta pertanto coerente con la scala dei momenti empirici e non costituisce di per sé un'anomalia della procedura diagnostica.

Per `total_bytes`, lo scostamento assume una forma differente: la media malevola si riduce da circa 1.95×10^4 Byte a 1.09×10^3 Byte, pari a circa il 5.6% del valore sorgente, mentre la varianza presenta una forte contrazione. Il traffico malevolo target occupa quindi una regione caratterizzata da volumi complessivi inferiori e da una dispersione sensibilmente ridotta.

Anche `dst_win_byt` evidenzia una modifica strutturale: la media passa da 87.52 per gli attacchi NB15 a circa -0.78 per STIN, mentre la varianza diminuisce da circa 1.47×10^4 a 4.01×10^3 . La distribuzione target risulta conseguentemente concentrata in regioni differenti rispetto a quelle maggiormente popolate dal traffico nominale sorgente.

Le tre caratteristiche descrivono quindi modalità distinte di variazione cross-domain: `pkts_per_sec` combina una forte traslazione con una marcata espansione della dispersione; `total_bytes` presenta una riduzione della posizione centrale e una contrazione della varianza; `dst_win_byt` modifica sia la posizione sia la concentrazione della distribuzione. Lo scostamento tra NB15 e STIN non risulta pertanto riconducibile a una singola trasformazione di scala, ma interessa in modo eterogeneo le diverse dimensioni osservate.

Raccordo tra evidenza PCA e KDE. Le analisi PCA e KDE forniscono evidenze diagnostiche complementari. La prima descrive lo scostamento geometrico globale dei benchmark nel sistema di riferimento costruito sul sorgente; la seconda identifica specifiche dimensioni lungo le quali la variazione distributiva risulta osservabile.

In INJECTION, la forte prevalenza della componente sorgente mantiene la geometria complessiva prossima a NB15, mentre la KDE evidenzia già una variazione particolarmente marcata di `pkts_per_sec`. In NB15_STIN, la sostituzione completa della componente malevola è invece associata sia al marcato scostamento nel piano PCA sia a variazioni sostanziali delle tre distribuzioni analizzate.

Tale corrispondenza non consente tuttavia di attribuire alle sole feature selezionate mediante KDE la geometria osservata nella PCA, poiché quest'ultima è calcolata sull'intero spazio condiviso delle 16 caratteristiche. Le due analisi descrivono quindi livelli differenti e complementari del medesimo fenomeno distributivo.

Sintesi della diagnostica distributiva. La diagnostica distingue tre regimi sperimentali: un riferimento sorgente caratterizzato da ampia sovrapposizione tra le macro-classi; una configurazione INJECTION che conserva prevalentemente la struttura sorgente ma rende già osservabile la presenza target lungo specifiche dimensioni; e NB15_STIN, nel quale la sostituzione completa della componente malevola produce il maggiore scostamento distributivo tra le configurazioni considerate.

Tale quadro costituisce il riferimento per la successiva analisi prestazionale, nella quale viene verificato se la conoscenza target sparsa introdotta mediante soli 29 campioni malevoli su 9 300 sia associata a un miglioramento della risposta cross-domain rispetto ai modelli puramente sorgente e come tale comportamento differisca dalla specializzazione ottenuta con i benchmark ibridi.

5.2 Valutazione della Baseline INJECTION

A valle della caratterizzazione geometrica e distributiva sviluppata nella Sezione 5.1, l'analisi si concentra sulla configurazione di riferimento $\mathcal{M}_{\text{base}}$, addestrata sul benchmark INJECTION. Tale configurazione conserva prevalentemente la componente malevola sorgente e integra 29 campioni provenienti da STIN sui 9 300 attacchi complessivamente presenti nel benchmark, pari a circa lo 0.31% della classe positiva.

La medesima strategia di composizione del training set viene applicata ai tre classificatori considerati nel framework: Decision Tree (DT), Histogram-based Gradient Boosting (HGB) e Random Forest (RF). Ciascuna istanza viene successivamente valutata sui 16 benchmark previsti dal protocollo di cross-evaluation, consentendo di confrontarne il comportamento sul dominio sorgente, sul benchmark INJECTION e sulle distribuzioni target aggregate e biclasse.

La valutazione viene sviluppata secondo due livelli complementari. La Sottosezione 5.2.1 analizza il profilo prestazionale, assumendo TPR e TNR come metriche operative principali e

utilizzando Precision, F1-Score, PR-AUC e cardinalità della matrice di confusione come supporto interpretativo. La Sottosezione 5.2.2 esamina invece, mediante SHAP, le caratteristiche maggiormente coinvolte nelle funzioni decisionali delle tre architetture.

5.2.1 Prestazioni Quantitative del Modello di Baseline

Criterio di lettura dei risultati. L'analisi puntuale utilizza l'esecuzione associata al seed rappresentativo $s = 42$, mantenendo invariata la composizione dei benchmark ottenuta mediante il seed deterministico di preprocessing $s_0 = 127001$. La stabilità rispetto all'inizializzazione degli stimatori viene analizzata successivamente sulle $K = 10$ repliche previste dal protocollo multi-seed.

Tutti i test set condividono la medesima cardinalità: 18 600 campioni nominali e 1 860 malevoli, per un totale di 20 460 osservazioni. Tale uniformità rende direttamente confrontabili anche le cardinalità TP , TN , FP e FN . La lettura prestazionale viene tuttavia condotta prioritariamente mediante

$$TPR = \text{Recall}, \quad TNR,$$

che descrivono rispettivamente la sensibilità verso il traffico malevolo e la capacità di preservare il traffico nominale. La matrice completa delle cardinalità ottenute sui 16 benchmark è riportata in Tabella A.1, in Appendice A.1.

Preservazione del traffico nominale e sensibilità agli attacchi. La componente nominale produce un comportamento costante attraverso i 16 benchmark per ciascun classificatore: DT registra 18 305 veri negativi e 295 falsi positivi, HGB rispettivamente 18 540 e 60, mentre RF produce 18 422 veri negativi e 178 falsi positivi. Tale regolarità è coerente con la costruzione sperimentale, nella quale la componente nominale dei diversi test set deriva dalla medesima distribuzione sorgente NB15. La variabilità cross-domain interessa quindi principalmente la risposta alla classe positiva.

La Tabella 5.2 riporta Precision, TPR e TNR per l'intera cross-evaluation.

Tabella 5.2: Precision, TPR e TNR della baseline INJECTION con DT, HGB e RF sui 16 test set per il seed $s = 42$.

Test Set	DT			HGB			RF		
	Precision	TPR	TNR	Precision	TPR	TNR	Precision	TPR	TNR
nb15 (aggregato)	0.8391	0.8274	0.9841	0.9611	0.7968	0.9968	0.8958	0.8226	0.9904
nb15 (DoS)	0.8516	0.9102	0.9841	0.9649	0.8860	0.9968	0.9055	0.9167	0.9904
nb15 (Exploits)	0.8416	0.8425	0.9841	0.9621	0.8183	0.9968	0.8998	0.8591	0.9904
nb15 (Fuzzers)	0.6402	0.2823	0.9841	0.8492	0.1817	0.9968	0.7166	0.2419	0.9904
nb15 (Generic)	0.8620	0.9909	0.9841	0.9685	0.9909	0.9968	0.9119	0.9909	0.9904
nb15 (Reconnaissance)	0.8459	0.8704	0.9841	0.9647	0.8828	0.9968	0.8997	0.8581	0.9904
injection (aggregato)	0.8388	0.8253	0.9841	0.9617	0.8097	0.9968	0.8958	0.8231	0.9904
nb15_stin (aggregato)	0.8585	0.9624	0.9841	0.9590	0.7554	0.9968	0.9123	0.9952	0.9904
nb15_sat20 (aggregato)	0.8619	0.9898	0.9841	0.9636	0.8543	0.9968	0.9126	0.9995	0.9904
nb15_sat20 (Syn_DDoS)	0.8608	0.9812	0.9841	0.9618	0.8129	0.9968	0.9127	1.0000	0.9904
nb15_sat20 (UDP_DDoS)	0.8630	0.9995	0.9841	0.9654	0.8989	0.9968	0.9126	0.9995	0.9904
nb15_ter20 (aggregato)	0.8559	0.9419	0.9841	0.9557	0.6962	0.9968	0.9119	0.9903	0.9904
nb15_ter20 (Botnet)	0.8472	0.8796	0.9841	0.9615	0.8054	0.9968	0.9125	0.9984	0.9904
nb15_ter20 (DDoS)	0.8631	1.0000	0.9841	0.9625	0.8274	0.9968	0.9127	1.0000	0.9904
nb15_ter20 (Syn_DDoS)	0.8588	0.9645	0.9841	0.0000	0.0000	0.9968	0.9068	0.9306	0.9904
nb15_ter20 (UDP_DDoS)	0.8494	0.8946	0.9841	0.9554	0.6914	0.9968	0.9127	1.0000	0.9904

La TNR distingue chiaramente i tre profili: HGB raggiunge 0.9968, RF 0.9904 e DT 0.9841. HGB produce pertanto il numero più contenuto di falsi positivi, ma tale vantaggio non coincide con una sensibilità altrettanto uniforme.

Sui benchmark target aggregati, infatti, la TPR di HGB è pari a 0.7554 su nb15_stin, 0.8543 su nb15_sat20 e 0.6962 su nb15_ter20. DT raggiunge rispettivamente 0.9624, 0.9898 e 0.9419, mentre RF ottiene 0.9952, 0.9995 e 0.9903. Nel seed considerato, RF presenta quindi il profilo di sensibilità più uniforme sulle tre distribuzioni target aggregate, mantenendo contestualmente una TNR pari a 0.9904.

Le valutazioni biclasse confermano tuttavia che la risposta dipende dalla specifica famiglia d'attacco. RF raggiunge TPR pari a 1.0000 su nb15_sat20-Syn_DDoS, nb15_ter20-DDoS e nb15_ter20-UDP_DDoS; DT raggiunge 1.0000 su nb15_ter20-DDoS. Il caso più critico è invece nb15_ter20-Syn_DDoS per HGB, dove $TP = 0$ e $FN = 1\,860$, corrispondenti a TPR nulla.

Una variabilità rilevante emerge anche all'interno del dominio sorgente. Fuzzers costituisce il caso più problematico, con TPR pari a 0.2823 per DT, 0.1817 per HGB e 0.2419 per RF; per Generic, al contrario, tutte le architetture raggiungono 0.9909. La capacità di rilevamento della baseline non risulta quindi uniforme neppure tra le famiglie native NB15.

La Precision completa tale quadro. HGB mantiene generalmente i valori più elevati, coerentemente con la maggiore TNR e il numero ridotto di falsi positivi; tuttavia, una maggiore affidabilità delle predizioni positive deve essere interpretata insieme alla sensibilità. Il caso nb15_ter20-Syn_DDoS, nel quale HGB presenta simultaneamente Precision e TPR nulle, costituisce l'esempio più evidente di tale compromesso.

F1-Score, PR-AUC e dipendenza dalla soglia. L'F1-Score viene utilizzato come sintesi del compromesso tra Precision e TPR, mentre la PR-AUC caratterizza la qualità della graduatoria probabilistica lungo l'intera curva Precision-Recall. I valori completi sui 16 benchmark sono riportati in Tabella A.2, in Appendice A.1.

Sul benchmark INJECTION, l'F1-Score è pari a 0.8320 per DT, 0.8792 per HGB e 0.8579 per RF; le corrispondenti PR-AUC sono 0.7104, 0.9342 e 0.9154. HGB ottiene quindi il maggiore F1-Score sulla distribuzione di riferimento, grazie al compromesso tra Precision elevata e TPR pari a 0.8097.

Sui tre benchmark target aggregati, RF raggiunge F1-Score pari a 0.9519, 0.9541 e 0.9495 rispettivamente su nb15_stin, nb15_sat20 e nb15_ter20. DT ottiene 0.9075, 0.9214 e 0.8969, mentre HGB raggiunge 0.8451, 0.9057 e 0.8056. Per RF, le corrispondenti PR-AUC sono 0.9802, 0.9873 e 0.9746, mostrando che l'elevata sensibilità osservata alla soglia operativa è accompagnata anche da una buona qualità della graduatoria probabilistica.

La criticità di Fuzzers rimane evidente anche nell'F1-Score: 0.3918 per DT, 0.2994 per HGB e 0.3617 per RF, rispetto ai valori 0.9220, 0.9795 e 0.9498 ottenuti sulla famiglia Generic.

Particolare attenzione richiede nuovamente HGB su nb15_ter20-Syn_DDoS. Alla soglia operativa utilizzata dalla pipeline si osserva

$$\text{TPR} = 0, \quad \text{F1} = 0, \quad \text{PR-AUC} = 0.5501.$$

L’F1-Score descrive il fallimento della decisione binaria nella configurazione effettivamente valutata, mentre la PR-AUC indica che la graduatoria probabilistica conserva informazione lungo soglie alternative. Tale evidenza non viene utilizzata per introdurre una nuova configurazione sperimentale: il protocollo adottato non prevede infatti l’ottimizzazione o la ricalibrazione della soglia decisionale.

Sintesi del profilo prestazionale della baseline. Nel seed $s = 42$, HGB privilegia la preservazione del traffico nominale, raggiungendo la maggiore TNR ma mostrando una sensibilità maggiormente dipendente dalla distribuzione malevola. RF presenta il profilo più uniforme sui benchmark target, mentre DT mantiene prestazioni intermedie associate a un numero superiore di falsi positivi. Tali differenze emergono pur utilizzando la medesima strategia di composizione INJECTION; diventa pertanto rilevante analizzare come le tre architetture organizzino le caratteristiche dello spazio condiviso nella rispettiva funzione decisionale.

5.2.2 Analisi di Spiegabilità SHAP della Baseline INJECTION

Criterio di lettura delle attribuzioni. L’analisi SHAP considera, per tutte e tre le architetture, il seed $s = 42$ e il test set INJECTION, mantenendo quindi lo stesso riferimento sperimentale della valutazione precedente. La procedura segue l’implementazione descritta nella Sottosezione 4.6.2 del Capitolo 4 e considera le attribuzioni relative alla classe positiva *Attack/Anomaly*.

Nei *summary dot plot*, l’ordinamento verticale esprime la rilevanza globale delle feature sul campione analizzato, mentre la posizione orizzontale descrive direzione e ampiezza del contributo all’output del modello. Valori SHAP positivi spostano la risposta verso la classe malevola e valori negativi nella direzione opposta; la codifica cromatica distingue valori elevati e ridotti della caratteristica. Poiché l’implementazione utilizza, ove supportato, l’output raw dello specifico explainer, le ampiezze assolute dei valori SHAP non vengono confrontate quantitativamente tra differenti famiglie di classificatori. Il confronto riguarda pertanto principalmente la gerarchia delle feature e il verso qualitativo dei relativi contributi.




Figura 5.7: Summary plot SHAP della baseline INJECTION per Decision Tree, Histogram-based Gradient Boosting e Random Forest, valutati sul test set INJECTION con seed $s = 42$.

Decision Tree. Nel Decision Tree, Figura 5.7(a), `pkts_per_sec` occupa la prima posizione, seguita da `load_s`, `total_bytes`, `src_bytes` e `byte_ratio`. Per `load_s` e `total_bytes`, numerosi

valori elevati risultano associati a contributi positivi, mentre `byte_ratio` presenta diversi valori elevati nella regione negativa. `pkts_per_sec`, pur risultando la feature globalmente più rilevante, mostra contributi distribuiti su entrambi i lati dell'origine e non evidenzia una relazione univariata strettamente monotona.

Histogram-based Gradient Boosting. Per HGB, Figura 5.7(b), `pkts_per_sec` rimane in prima posizione, seguita da `load_s`, `down_up_ratio`, `src_bytes` e `src_mean_pkt_size`. Anche in questo caso `pkts_per_sec` presenta una struttura non monotona, mentre `load_s` mostra numerosi valori elevati associati a contributi positivi. Per `down_up_ratio`, al contrario, valori elevati tendono a collocarsi nella regione negativa. Ulteriori andamenti strutturati sono osservabili per `dst_pkts`, prevalentemente negativo in corrispondenza di valori elevati, e per `total_bytes`, dove numerosi valori elevati producono contributi positivi.

Random Forest. Nel Random Forest, Figura 5.7(c), la graduatoria è guidata da `pkts_per_sec`, seguita da `total_bytes`, `src_bytes`, `src_mean_pkt_size` e `load_s`. Anche per RF la caratteristica principale non evidenzia una relazione cromatica strettamente monotona. Per `load_s`, valori elevati tendono invece a essere associati a contributi positivi, mentre `down_up_ratio` mostra prevalentemente il comportamento opposto. Le feature di finestra `src_win_byt` e `dst_win_byt`, pur collocate più in basso nella graduatoria globale, presentano inoltre contributi positivi principalmente in corrispondenza di valori ridotti.

Confronto sinottico delle gerarchie decisionali. Le prime cinque feature delle tre architetture sono sintetizzate nella Tabella 5.3.

Tabella 5.3: Prime cinque feature nella graduatoria SHAP della baseline INJECTION per DT, HGB e RF al seed $s = 42$.

Rank	DT	HGB	RF
1	pkts_per_sec	pkts_per_sec	pkts_per_sec
2	load_s	load_s	total_bytes
3	total_bytes	down_up_ratio	src_bytes
4	src_bytes	src_bytes	src_mean_pkt_size
5	byte_ratio	src_mean_pkt_size	load_s

L'elemento comune più netto è `pkts_per_sec`, collocata al primo posto per tutte le architetture. Anche `load_s` e `src_bytes` costituiscono un nucleo condiviso, pur con ordinamenti differenti. Le principali specificità riguardano invece `total_bytes`, seconda per RF, `down_up_ratio`, terza per HGB, e `byte_ratio`, quinta per DT. La condivisione del medesimo benchmark di addestramento non determina quindi una gerarchia decisionale identica tra i tre classificatori.

Raccordo tra SHAP, diagnostica distributiva e prestazioni. Il collegamento con la diagnostica della Sezione 5.1 risulta particolarmente evidente per `pkts_per_sec`. La feature occupa la prima posizione SHAP in tutte e tre le architetture baseline e coincide con la variabile per la quale la KDE ha evidenziato lo scostamento quantitativamente più marcato tra la componente malevola sorgente e quella target.

La corrispondenza individua quindi un punto di convergenza tra evidenza distributiva e rilevanza decisionale. Essa non dimostra tuttavia che il comportamento cross-domain della baseline sia determinato causalmente da `pkts_per_sec`: i classificatori operano nello spazio multidimensionale e le attribuzioni mostrano il contributo contemporaneo di numerose caratteristiche.

Analogamente, la posizione relativamente bassa di `dst_win_byt` nelle graduatorie della sola baseline non contraddice la sua inclusione tra le feature sottoposte a KDE. La selezione `{pkts_per_sec, total_bytes, dst_win_byt}` deriva infatti dall'aggregazione trasversale delle evidenze SHAP dell'intera campagna sperimentale e non esclusivamente dall'istanza INJECTION analizzata in questa sottosezione.

Nel complesso, la baseline associa una conoscenza target estremamente sparsa a tre profili distinti: maggiore specificità per HGB, maggiore uniformità della sensibilità target per RF e comportamento intermedio per DT. L'analisi SHAP mostra contestualmente una gerarchia condivisa nella feature principale ma differenze nell'organizzazione delle variabili successive. Tale configurazione costituisce il riferimento sperimentale per il confronto con i modelli addestrati esclusivamente sul dominio sorgente sviluppato nella Sezione 5.3.

5.3 Valutazione dei Modelli Sorgente rispetto alla Baseline

Dopo aver caratterizzato il comportamento della configurazione di riferimento $\mathcal{M}_{\text{base}}$, l'analisi viene estesa ai modelli $\mathcal{M}_S$, addestrati esclusivamente sul dominio sorgente NB15 e privi di conoscenza esplicita delle distribuzioni malevole target. Il gruppo comprende il modello aggregato nb15_aggregate e cinque rilevatori biclasse specializzati nelle famiglie DoS, Exploits, Fuzzers, Generic e Reconnaissance, ciascuno istanziato mediante DT, HGB e RF.

La valutazione sui medesimi 16 benchmark impiegati per la baseline permette di distinguere la capacità di riconoscimento in-domain dalla generalizzazione verso distribuzioni differenti. Coerentemente con la gerarchia introdotta nella Sezione 5.2, TPR e TNR costituiscono gli indicatori operativi principali, mentre F1-Score e le ulteriori metriche vengono richiamati quando apportano informazioni complementari.

5.3.1 Prestazioni dei Modelli Biclasse e Aggregato Sorgente

Prestazioni sulle distribuzioni sorgente omologhe. Una prima valutazione considera ciascun modello sulla distribuzione corrispondente alla propria configurazione di addestramento. La Tabella 5.4 riporta TPR, TNR e F1-Score ottenuti nel seed rappresentativo $s = 42$.

Tabella 5.4: Prestazioni dei modelli sorgente sui rispettivi test set omologhi per il seed $s = 42$.

Modello Sorgente	DT			HGB			RF		
	TPR	TNR	F1	TPR	TNR	F1	TPR	TNR	F1
Aggregato	0.8242	0.9826	0.8251	0.8022	0.9964	0.8728	0.8220	0.9917	0.8629
DoS	0.9280	0.9934	0.9307	0.9129	0.9974	0.9415	0.9317	0.9968	0.9491
Exploits	0.8919	0.9906	0.8982	0.8694	0.9954	0.9079	0.9043	0.9942	0.9216
Fuzzers	0.4763	0.9626	0.5150	0.3403	0.9898	0.4720	0.4747	0.9684	0.5303
Generic	0.9876	0.9995	0.9914	0.9882	0.9997	0.9924	0.9866	0.9997	0.9916
Reconnaissance	0.9414	0.9954	0.9473	0.9425	0.9956	0.9488	0.9409	0.9960	0.9501

La difficoltà di classificazione varia sensibilmente tra le famiglie sorgente. *Generic* presenta il comportamento più favorevole, con TPR comprese tra 0.9866 e 0.9882, TNR prossime all'unità e F1-Score superiori a 0.991. Prestazioni elevate vengono osservate anche per *DoS* e *Reconnaissance*, mentre *Exploits* assume un comportamento intermedio.

La principale criticità è rappresentata da *Fuzzers*, per la quale la TPR scende a 0.4763 per DT, 0.3403 per HGB e 0.4747 per RF. Le corrispondenti TNR, pari rispettivamente a 0.9626, 0.9898 e 0.9684, mostrano che il degrado riguarda principalmente la capacità di riconoscere la classe positiva. Anche la PR-AUC conferma la maggiore difficoltà della distribuzione *Fuzzers*, assumendo valori pari a 0.3568, 0.6498 e 0.6063 per DT, HGB e RF, rispetto a 0.9839, 0.9974 e 0.9953 ottenuti su *Generic*.

Stabilità multi-seed e risposta sulle distribuzioni sorgente. La sintesi sulle $K = 10$ repliche conferma il comportamento osservato nel seed rappresentativo. Per il modello aggregato, la TPR media risulta pari a 0.8215 per DT, 0.8018 per HGB e 0.8236 per RF, valori prossimi a quelli ottenuti con $s = 42$. Anche la criticità *Fuzzers* permane nella valutazione multi-seed, con TPR medie pari a 0.4794, 0.3517 e 0.4739. Le varianze osservate sulle configurazioni omologhe risultano generalmente contenute, indicando che tali caratteristiche non sono associate alla sola inizializzazione rappresentativa.

La matrice completa delle TPR medie dei modelli sorgente sui benchmark NB15 e sul test set INJECTION è riportata nella Tabella A.3 in Appendice. Essa evidenzia la specializzazione

dei rilevatori biclasse, senza tuttavia mostrare una risposta esclusivamente diagonale. Il modello Exploits, ad esempio, mantiene una TPR elevata sul benchmark DoS, pari a 0.9261, 0.9099 e 0.9282 rispettivamente per DT, HGB e RF; analogamente, Reconnaissance raggiunge valori compresi tra 0.9444 e 0.9785 sulla classe Generic. Altre combinazioni mostrano invece trasferibilità ridotta: Exploits su Generic raggiunge 0.0220, 0.1310 e 0.0224, mentre Generic su Fuzzers si ferma a 0.1213, 0.0913 e 0.1159.

Il modello nb15_aggregate mantiene inoltre sul benchmark INJECTION una risposta prossima a quella osservata sul test aggregato sorgente: la TPR media passa da 0.8215 a 0.8274 per DT, da 0.8018 a 0.8039 per HGB e da 0.8236 a 0.8272 per RF. Tale prossimità risulta coerente con la predominanza della componente sorgente nella distribuzione INJECTION evidenziata nella Sezione 5.1.

Generalizzazione verso i benchmark target. Il comportamento cambia sostanzialmente quando la componente malevola appartiene ai domini target. La matrice completa delle TPR medie sulle nove distribuzioni target aggregate e biclasse è riportata nella Tabella A.4 in Appendice.

Per il modello aggregato, considerando congiuntamente i sei benchmark sorgente, la TPR media è pari a 0.7870, 0.7601 e 0.7833 rispettivamente per DT, HGB e RF. Sui nove benchmark target i valori si riducono invece a

0.3234 (DT), 0.0607 (HGB), 0.3035 (RF).

Il degrado è particolarmente pronunciato per HGB, il cui modello aggregato raggiunge TPR medie pari a 0.0662, 0.1055 e 0.0438 sui benchmark aggregati nb15_stin, nb15_sat20 e nb15_ter20. DT raggiunge rispettivamente 0.3807, 0.1947 e 0.5294, mentre RF ottiene 0.3601, 0.2613 e 0.4564.

Il degrado non implica tuttavia l'assenza di qualunque trasferimento tra famiglie. Per DT, il rilevatore DoS raggiunge TPR pari a 0.9528 su nb15_sat20-Syn_DDoS e 0.8877 su nb15_ter20-UDP_DDoS. Il modello Fuzzers raggiunge invece sulla classe Botnet 0.8898 per DT, 0.6226 per HGB e 0.9191 per RF; sulla classe UDP_DDoS di SAT20, RF raggiunge 0.9023. Si osservano quindi trasferimenti locali tra specifiche distribuzioni, ma non una capacità di generalizzazione target uniforme.

Il modello Reconnaissance rappresenta il caso opposto: HGB produce valori sostanzialmente nulli sull'intero insieme target e RF non supera 0.0200, mentre DT presenta prevalentemente sensibilità ridotte. Nel complesso, la risposta cross-domain dipende quindi dalla specifica combinazione tra modello sorgente e distribuzione target e risulta compatibile con il domain shift osservato mediante PCA e KDE, senza consentire di attribuirne causalmente l'effetto a una singola caratteristica.

Preservazione del traffico nominale. La riduzione della sensibilità target non è accompagnata da un analogo deterioramento della TNR. La Tabella A.5 in Appendice riporta media e varianza della specificità per tutte le configurazioni. I valori risultano generalmente elevati e presentano variabilità inter-seed molto contenuta. Il modello Generic raggiunge TNR medie comprese tra 0.99950 e 0.99964, mentre l'eccezione principale è nuovamente Fuzzers, con 0.96248 per DT, 0.98900 per HGB e 0.96847 per RF.

La combinazione tra TNR sostanzialmente stabile e TPR fortemente dipendente dal dominio localizza quindi il principale limite dei modelli sorgente nella risposta alla componente malevola: il traffico nominale NB15 continua a essere riconosciuto con elevata specificità, mentre la capacità di associare le nuove distribuzioni d'attacco alla classe positiva non viene trasferita con la stessa regolarità.

Nel complesso, $\mathcal{M}_S$ mostra pertanto buone prestazioni in-domain, con una criticità persistente sulla famiglia Fuzzers, ma una generalizzazione target disomogenea e generalmente ridotta. Tale evidenza motiva il confronto diretto con la baseline INJECTION, volto a quantificare l'effetto prestazionale associato alla presenza di conoscenza target sparsa.

5.3.2 Analisi Comparativa Incrociata: Modelli Sorgente vs Baseline

Criterio di confronto. Il confronto viene condotto separatamente per DT, HGB e RF tra il modello aggregato sorgente nb15_aggregate e la baseline injection_aggregate. Le configurazioni condividono componente nominale, rapporto tra le classi e cardinalità complessiva; la differenza riguarda la classe positiva, poiché la baseline sostituisce 29 dei 9 300 campioni malevoli NB15 con osservazioni provenienti da STIN.

Indicando con $\overline{TPR}_{\text{base},j}$ e $\overline{TPR}_{S,j}$ le TPR medie sui $K = 10$ seed relative al test set j , viene definita

$$\Delta TPR_j = \overline{TPR}_{\text{base},j} - \overline{TPR}_{S,j}, \quad (5.4)$$

dove $\Delta TPR_j > 0$ indica un vantaggio della baseline.

Conservazione delle prestazioni sorgente e incremento cross-domain. La Tabella 5.5 sintetizza il confronto separando i sei benchmark NB15 dai nove benchmark target e riportando, come controllo, la TNR media.

Tabella 5.5: Confronto multi-seed tra modello aggregato sorgente e baseline. Le differenze Δ sono calcolate come baseline meno modello sorgente.

Alg.	TPR media – benchmark NB15			TPR media – benchmark target			TNR media	
	$\mathcal{M}_S$	$\mathcal{M}_{\text{base}}$	Δ	$\mathcal{M}_S$	$\mathcal{M}_{\text{base}}$	Δ	$\mathcal{M}_S$	$\mathcal{M}_{\text{base}}$
DT	0.7870	0.7860	−0.0011	0.3234	0.9661	+0.6427	0.98317	0.98460
HGB	0.7601	0.7609	+0.0008	0.0607	0.8297	+0.7690	0.99659	0.99658
RF	0.7833	0.7820	−0.0013	0.3035	0.9882	+0.6847	0.99150	0.99057

L'asimmetria tra comportamento sorgente e cross-domain è netta. Sui sei benchmark NB15, le differenze di TPR media rimangono dell'ordine di 10^{-3} : −0.0011 per DT, +0.0008 per HGB e −0.0013 per RF. Una prossimità analoga si osserva sul test INJECTION, dove le TPR medie sorgente/baseline sono rispettivamente 0.82742/0.82748 per DT, 0.80387/0.80695 per HGB e 0.82719/0.82558 per RF.

Sui benchmark target, al contrario, la baseline incrementa la TPR media da 0.3234 a 0.9661 per DT, da 0.0607 a 0.8297 per HGB e da 0.3035 a 0.9882 per RF, corrispondenti a vantaggi assoluti pari a +0.6427, +0.7690 e +0.6847. L'incremento non è accompagnato da una variazione comparabile della TNR, che passa da 0.98317 a 0.98460 per DT, da 0.99659 a 0.99658 per HGB e da 0.99150 a 0.99057 per RF.

La medesima asimmetria emerge considerando l'intera cross-evaluation: la TPR media sui 16 test set passa da 0.5288 a 0.8899 per DT, da 0.3694 a 0.8025 per HGB e da 0.5161 a 0.9007 per

RF. Poiché la risposta sui benchmark NB15 rimane pressoché invariata, il miglioramento globale è associato principalmente alla differente sensibilità verso le distribuzioni target.

Media prestazionale e variabilità sui benchmark target. Le statistiche complete di media e varianza della TPR sui tre benchmark target aggregati sono riportate nella Tabella A.6 in Appendice. Per DT, il passaggio alla baseline associa l’aumento della sensibilità a una riduzione della varianza sulle tre distribuzioni considerate. Un comportamento analogo è osservabile per RF su nb15_stin e, in particolare, nb15_sat20, dove la baseline raggiunge $\overline{TPR} = 0.99954$ con $\text{Var}(TPR) = 9.38 \times 10^{-8}$.

Per HGB, invece, la baseline presenta varianze leggermente superiori rispetto al modello sorgente sui tre benchmark aggregati, ma contestualmente incrementa la TPR da 0.06624 a 0.84945 su nb15_stin, da 0.10553 a 0.90956 su nb15_sat20 e da 0.04378 a 0.81505 su nb15_ter20. La sola stabilità non costituisce pertanto un indicatore di efficacia: una risposta può risultare poco variabile tra seed pur mantenendo una sensibilità sistematicamente ridotta.

Confronto con il migliore rilevatore sorgente disponibile. Per evitare che il confronto con il solo modello aggregato sottostimi la capacità del paradigma sorgente, per ciascun benchmark target viene inoltre considerata la migliore TPR media ottenuta tra il modello aggregato e i cinque rilevatori specialistici. Si definisce

$$\Delta TPR_j^{\text{best}} = \overline{TPR}_{\text{base},j} - \max_{m \in \mathcal{M}_S} \overline{TPR}_{m,j}. \quad (5.5)$$

I 27 valori completi sono riportati nella Tabella A.7 in Appendice e risultano tutti positivi. La baseline presenta quindi una TPR media superiore su ciascuno dei nove benchmark target e per tutte le tre architetture anche quando il termine di confronto viene selezionato a posteriori come il migliore modello sorgente disponibile.

Il vantaggio non è uniforme. Per DT, il modello sorgente DoS si avvicina alla baseline su nb15_sat20–Syn_DDoS, con un margine di +0.02042, e soprattutto su nb15_ter20–UDP_DDoS, dove $\Delta TPR^{\text{best}} = +0.00767$. Per RF, Fuzzers raggiunge 0.91909 sul test Botnet rispetto a 0.98451 della baseline e 0.90226 su UDP_DDoS satellitare rispetto a 0.99965. Nel caso HGB il margine minimo è più ampio, pari a +0.24576 sul test Botnet.

Tali eccezioni confermano l'esistenza di trasferimenti locali tra alcune famiglie sorgente e target, ma non modificano il risultato complessivo: nessuna delle configurazioni puramente sorgente supera la baseline nei 27 confronti considerati.

Raccordo con il domain shift osservato. Il comportamento prestazionale è coerente con la diagnostica della Sezione 5.1. I modelli $\mathcal{M}_S$ apprendono la funzione decisionale esclusivamente su NB15, mentre PCA e KDE hanno evidenziato uno scostamento marcato quando la componente malevola viene sostituita da STIN. Contestualmente, la TNR rimane elevata perché la distribuzione nominale continua a essere costituita da traffico sorgente.

Nel protocollo considerato, l'introduzione nella baseline di soli 29 campioni target è quindi associata a un incremento sostanziale della sensibilità cross-domain, senza una variazione apprezzabile delle prestazioni medie sui benchmark NB15 né della specificità. Tale evidenza rimane, a questo livello, descrittiva: la successiva analisi statistica verifica se le differenze globali osservate lungo le repliche multi-seed risultino compatibili con l'ipotesi di uguaglianza delle medie.

Nel complesso, il confronto mostra che la conoscenza target sparsa distingue i due paradigmi soprattutto nella risposta cross-domain, mentre la conoscenza sorgente viene sostanzialmente preservata. L'analisi SHAP viene quindi utilizzata per verificare come il modello aggregato sorgente organizzi la rilevanza delle feature in assenza della componente target introdotta nella baseline.

5.3.3 Analisi SHAP del Modello Aggregato Sorgente NB15

Criterio di analisi. L'analisi considera il modello nb15_aggregate per DT, HGB e RF, utilizzando il seed $s = 42$ e il test set aggregato NB15. Il criterio di lettura delle attribuzioni è quello introdotto nella Sottosezione 5.2.2; il confronto tra architetture viene pertanto condotto sulla gerarchia globale delle feature e sulla direzione qualitativa dei contributi, senza confrontare direttamente le ampiezze assolute degli assi SHAP.




Figura 5.8: Summary plot SHAP del modello aggregato sorgente NB15 implementato mediante Decision Tree, Histogram-based Gradient Boosting e Random Forest, valutati sul test set aggregato NB15 con seed $s = 42$.

Decision Tree. Nel DT, Figura 5.8(a), `pkts_per_sec` occupa la prima posizione, seguita da `total_bytes`, `load_s`, `src_mean_pkt_size` e `byte_ratio`. `total_bytes` e `load_s` mostrano numerosi valori elevati associati a contributi positivi, mentre per `byte_ratio` valori elevati tendono maggiormente a collocarsi nella regione negativa. `pkts_per_sec`, pur dominando la graduatoria, non evidenzia invece una relazione univariata strettamente monotona.

Histogram-based Gradient Boosting. Per HGB, Figura 5.8(b), la feature principale rimane `pkts_per_sec`, seguita da `down_up_ratio`, `byte_ratio`, `load_s` e `src_bytes`. Rispetto alle altre architetture, assumono quindi maggiore rilevanza i rapporti tra le due direzioni del flusso. Per `down_up_ratio` e `byte_ratio`, valori elevati risultano prevalentemente associati a contributi negativi, mentre `load_s` presenta una tendenza opposta, con numerosi valori elevati nella regione positiva.

Random Forest. Nel RF, Figura 5.8(c), `pkts_per_sec` è seguita da `total_bytes`, `src_mean_pkt_size`, `duration` e `src_bytes`. La feature principale e `total_bytes` mostrano distribuzioni articolate su entrambi i lati dell'origine, mentre `load_s`, collocata immediatamente dopo le prime cinque caratteristiche, presenta valori elevati prevalentemente associati a contributi positivi. Per `down_up_ratio` si osserva invece una tendenza qualitativamente inversa.

Confronto sinottico delle gerarchie sorgente. La Tabella 5.6 sintetizza le cinque feature principali delle tre architetture.

Tabella 5.6: Prime cinque feature nella graduatoria SHAP del modello aggregato sorgente NB15 per DT, HGB e RF al seed $s = 42$.

Rank	DT	HGB	RF
1	<code>pkts_per_sec</code>	<code>pkts_per_sec</code>	<code>pkts_per_sec</code>
2	<code>total_bytes</code>	<code>down_up_ratio</code>	<code>total_bytes</code>
3	<code>load_s</code>	<code>byte_ratio</code>	<code>src_mean_pkt_size</code>
4	<code>src_mean_pkt_size</code>	<code>load_s</code>	<code>duration</code>
5	<code>byte_ratio</code>	<code>src_bytes</code>	<code>src_bytes</code>

Il principale elemento comune è `pkts_per_sec`, prima in tutte le graduatorie. `total_bytes` occupa inoltre la seconda posizione per DT e RF, mentre HGB attribuisce maggiore priorità a `down_up_ratio` e `byte_ratio`. DT mantiene `load_s` tra le prime tre caratteristiche, mentre RF introduce `duration` nella Top-5 e colloca `load_s` immediatamente al di fuori di essa. Le architetture condividono quindi la principale dimensione informativa, ma organizzano diversamente le feature successive.

Confronto qualitativo con la baseline INJECTION. Il confronto con la Sottosezione 5.2.2 mostra una sostanziale continuità nella feature dominante e variazioni nell'ordinamento delle caratteristiche secondarie. Per DT, `pkts_per_sec`, `total_bytes`, `load_s` e `byte_ratio` rimangono nella Top-5; nella baseline, tuttavia, `load_s` precede `total_bytes` e `src_bytes` sostituisce `src_mean_pkt_size`.

Per RF le prime due posizioni rimangono `pkts_per_sec` e `total_bytes`; nella baseline acquisiscono maggiore priorità `src_bytes` e `load_s`, mentre `duration` esce dalle prime cinque. La riorganizzazione più evidente riguarda HGB: nel modello sorgente `down_up_ratio` e `byte_ratio` occupano la seconda e la terza posizione, mentre nella baseline `load_s` sale al secondo posto e `byte_ratio` non compare più nella Top-5.

Il confronto descrive una diversa organizzazione empirica delle attribuzioni, ma non consente di attribuire causalmente tali variazioni ai soli 29 campioni target. I grafici derivano infatti da modelli addestrati su benchmark differenti e valutati rispettivamente su NB15 e INJECTION.

Raccordo con PCA, KDE e comportamento cross-domain. Il collegamento più evidente con la diagnostica distributiva riguarda `pkts_per_sec`. La feature occupa il primo posto per tutti i modelli aggregati sorgente e, contestualmente, presenta il maggiore scostamento quantitativo osservato mediante KDE tra la componente malevola NB15 e STIN. L'elevata rilevanza decisionale della variabile nel dominio sorgente non implica tuttavia robustezza al cambiamento della sua distribuzione: importanza SHAP e capacità di generalizzazione cross-domain rappresentano proprietà distinte.

Un secondo raccordo riguarda `total_bytes`, seconda feature per DT e RF e caratterizzata nella diagnostica KDE da una sostanziale variazione della distribuzione target. Al contrario,

dst_win_byt, pur mostrando un evidente scostamento distributivo tra NB15 e STIN, rimane nelle posizioni inferiori delle graduatorie SHAP dei tre modelli sorgente.

L'evidenza complessiva mostra quindi che

ampiezza del domain shift $\neq$ rilevanza predittiva.

Una feature può essere fortemente rilevante nel dominio sorgente e non garantire robustezza rispetto allo shift; analogamente, uno scostamento distributivo marcato non implica che la caratteristica sia tra quelle maggiormente utilizzate dal classificatore.

L'analisi SHAP completa pertanto il quadro prestazionale dei modelli $\mathcal{M}_S$: le architetture condividono alcune dimensioni informative centrali, ma la relativa funzione decisionale rimane appresa esclusivamente sulla distribuzione sorgente. La significatività delle differenze globali rispetto alla baseline viene verificata nella sottosezione successiva.

5.3.4 Analisi della Significatività Statistica (Test t di Welch) dei Modelli Sorgente vs Baseline

Costruzione dei campioni statistici. La verifica inferenziale segue il protocollo definito nel Capitolo 4. Per ciascun modello i e seed s_k , la quantità sottoposta al confronto è la media dell'F1-Score sui 16 test set della cross-evaluation:

$$\overline{F1}_i^{(k)} = \frac{1}{16} \sum_{j=1}^{16} F1_{ij}^{(k)}. \quad (5.6)$$

Ogni configurazione è quindi rappresentata da $K = 10$ valori $\overline{F1}_i^{(k)}$. Il test confronta il vettore della baseline injection_aggregate con quello di ciascun modello sorgente mediante un test t di Welch bilaterale, senza assumere uguaglianza delle varianze:

$$H_0 : \mu_{\text{base}} = \mu_m, \quad H_1 : \mu_{\text{base}} \neq \mu_m, \quad \alpha = 0.05.$$

La natura della variabile deve rimanere esplicita: il test fornisce una valutazione *globale* del comportamento lungo i 16 benchmark e non una verifica di significatività separata per ciascun test set.

Sintesi descrittiva delle distribuzioni multi-seed. Le statistiche complete dei 10 valori per modello sono riportate nella Tabella A.10 in Appendice. La baseline presenta la maggiore media inter-seed dell’F1-Score per tutte le architetture.

Per DT, *injection_aggregate* raggiunge 0.86039, mentre il migliore modello sorgente è *nb15_dos* con 0.63163, per un divario pari a 0.22876. Nel caso HGB, la baseline raggiunge 0.85407, contro 0.41671 del migliore modello sorgente *nb15_dos*. Per RF, il valore della baseline è 0.89022, mentre *nb15_aggregate* raggiunge 0.57651.

Le deviazioni standard della baseline sono pari a 0.00352 per DT, 0.03634 per HGB e 0.00245 per RF. HGB presenta quindi una dispersione inter-seed superiore rispetto alle altre due architetture, circostanza coerente con l’impiego del test di Welch, che non richiede l’assunzione di varianze uguali.

Risultati del test *t* di Welch. I valori completi della statistica *t* e del *p-value* sono riportati nella Tabella A.11 in Appendice. Tutti i 18 confronti soddisfano il criterio $p < 0.05$; secondo il test adottato, le distribuzioni delle medie F1 multi-seed non risultano quindi compatibili con l’ipotesi nulla di uguaglianza delle medie per nessuna delle configurazioni sorgente considerate.

Tutte le statistiche *t* assumono inoltre segno positivo. Poiché la baseline costituisce il primo campione fornito al test e presenta in ogni confronto una media inter-seed superiore, la direzione empirica delle differenze è sistematicamente favorevole a M_{base} .

L’interpretazione rimane necessariamente globale. Il risultato non permette di concludere che la baseline sia statisticamente superiore a ciascun modello sorgente su ognuno dei 16 benchmark considerati individualmente. Esso indica invece che, secondo la misura definita nell’Equazione (5.6), le differenze tra le medie complessive della baseline e quelle dei modelli sorgente risultano significative nel protocollo statistico adottato, tenuto conto della variabilità osservata tra le inizializzazioni.

Coerentemente con la metodologia sperimentale, i *p-value* non sono sottoposti a una correzione per confronti multipli. L’analisi mantiene quindi carattere esplorativo e ciascuno dei 18 confronti viene valutato individualmente rispetto alla soglia $\alpha = 0.05$.

Sintesi della valutazione dei modelli sorgente. Le evidenze prestazionali, distributive, esplicative e inferenziali convergono su un quadro coerente. I modelli sorgente mantengono buone

prestazioni su numerose distribuzioni NB15, ma presentano una sensibilità target generalmente ridotta e fortemente dipendente dalla specifica combinazione modello–attacco, mentre la TNR rimane elevata. L’analisi SHAP mostra inoltre che alcune caratteristiche centrali per la funzione decisionale sorgente, in particolare `pkts_per_sec` e `total_bytes`, appartengono anche alle dimensioni interessate dal domain shift osservato nella diagnostica.

Il confronto con INJECTION mostra contestualmente che la presenza di una quota target sparsa è associata alla sostanziale conservazione delle prestazioni NB15 e a un incremento marcato della sensibilità target. Tale vantaggio permane rispetto al migliore modello sorgente in tutti i 27 confronti target e, nella misura globale utilizzata dal test di Welch, tutti i 18 confronti con la baseline risultano significativi secondo il criterio adottato. La successiva Sezione 5.4 estende il confronto al paradigma nel quale la componente malevola di addestramento viene invece sostituita integralmente da traffico target.

5.4 Valutazione dei Modelli Ibridi rispetto alla Baseline

La valutazione viene ora estesa ai modelli ibridi $\mathcal{M}_H$, nei quali la componente nominale continua a essere derivata dal dominio sorgente NB15, mentre la componente malevola di addestramento appartiene interamente ai domini target. Il gruppo comprende i tre modelli aggregati `nb15_stin_aggregate`, `nb15_sat20_aggregate` e `nb15_ter20_aggregate`, oltre ai sei rilevatori biclasse specializzati nelle famiglie target considerate. Ciascuna configurazione viene istanziata mediante DT, HGB e RF e sottoposta alla medesima cross-evaluation sui 16 benchmark utilizzata nelle sezioni precedenti.

La costruzione dei benchmark ibridi richiede una cautela interpretativa specifica. Nel training, infatti, il traffico nominale appartiene sempre al dominio sorgente, mentre quello malevolo appartiene al dominio target:

$$Y = 0 \Rightarrow D = \text{NB15}, \quad Y = 1 \Rightarrow D = \text{Target}.$$

Classe e dominio risultano pertanto strutturalmente correlati. Prestazioni elevate sul target non possono quindi essere attribuite automaticamente all’apprendimento di proprietà semantiche generali degli attacchi, poiché la funzione decisionale può sfruttare anche differenze distributive associate

alla provenienza dei campioni. Tale confondimento viene mantenuto esplicito nell'interpretazione delle evidenze prestazionali e SHAP.

5.4.1 Prestazioni dei Modelli Biclasse e Aggregati Ibridi

Prestazioni sulle distribuzioni target omologhe. Una prima valutazione riguarda le condizioni nelle quali ciascun modello viene applicato alla distribuzione target corrispondente alla propria configurazione di addestramento. I risultati completi per il seed rappresentativo $s = 42$ sono riportati nella Tabella A.8 in Appendice.

Le prestazioni risultano sostanzialmente sature. Sui benchmark aggregati NB15_STIN e NB15_SAT20, DT, HGB e RF identificano 1 859 dei 1 860 campioni malevoli, producendo un solo falso negativo e nessun falso positivo. Ne conseguono TPR pari a 0.9995, TNR e Precision pari a 1.0000 e F1-Score pari a 0.9997. Sul benchmark aggregato NB15_TER20 e sui sei test biclasse omologhi, le tre architetture raggiungono invece TPR, TNR, Precision e F1-Score pari a 1.0000.

Il riconoscimento quasi perfetto della distribuzione utilizzata nel training non è tuttavia sufficiente a caratterizzare la robustezza dei modelli. La generalizzazione deve essere valutata anche sugli attacchi sorgente e sulle distribuzioni target differenti da quella impiegata durante l'addestramento.

Preservazione della componente nominale. Un comportamento completamente uniforme emerge per la specificità. Sulle $K = 10$ repliche, tutti i modelli ibridi e tutte le architetture presentano

$$\overline{TNR} = 1.0000, \quad \text{Var}(TNR) = 0.$$

Il traffico nominale NB15 viene quindi classificato correttamente in tutte le repliche considerate. Tale risultato non deve tuttavia essere interpretato isolatamente: una TNR perfetta non implica l'apprendimento di un criterio generale di rilevamento delle anomalie e deve essere letta congiuntamente alla sensibilità sulle differenti popolazioni positive.

Trasferimento verso dominio sorgente, INJECTION e distribuzioni target. La Tabella A.9 in Appendice riporta la matrice completa delle TPR medie multi-seed, distinguendo tre condizioni: i sei benchmark NB15, il benchmark INJECTION e i nove benchmark target.

L'asimmetria tra dominio sorgente e target è particolarmente netta. Per DT e RF, tutti i modelli ibridi presentano TPR media nulla sui sei benchmark NB15. HGB mostra il medesimo comportamento, con la sola eccezione di nb15_ter20_syn_ddos, la cui media rimane comunque pari a 2.5×10^{-5} . Nel seed $s = 42$, le configurazioni applicate ai test sorgente producono generalmente $TP = 0$, $FN = 1\,860$, $FP = 0$ e $TN = 18\,600$.

La contemporanea presenza di TNR unitaria e TPR nulla descrive quindi un comportamento fortemente polarizzato: il traffico nominale sorgente viene preservato, ma gli attacchi appartenenti allo stesso dominio non vengono associati alla regione positiva appresa mediante traffico target.

Un'evidenza coerente emerge sul benchmark INJECTION. Per i tre modelli aggregati la TPR media è pari a 0.00320 per DT, HGB e RF. Poiché la componente malevola del benchmark è quasi interamente sorgente, il valore è compatibile con la perdita di sensibilità verso gli attacchi NB15. La prossimità numerica rispetto alla ridotta quota target presente in INJECTION non consente tuttavia di identificare quali singoli campioni abbiano prodotto i veri positivi; non è quindi possibile attribuire puntualmente le classificazioni corrette alla sola componente target.

Generalizzazione tra distribuzioni target. Il comportamento cambia radicalmente quando la componente malevola appartiene al dominio target. Per i tre modelli aggregati, la TPR media sui nove benchmark target risulta:

	NB15_STIN	NB15_SAT20	NB15_TER20
<i>DT</i>	0.999922	0.999889	0.999922
<i>HGB</i>	0.999944	0.981796	0.999944
<i>RF</i>	0.999922	0.999894	0.999906

La sensibilità non risulta quindi limitata alla singola distribuzione target utilizzata nel fitting: i modelli aggregati mantengono TPR prossime all'unità anche sulle altre distribuzioni target considerate. Tale evidenza indica un'elevata trasferibilità all'interno del gruppo target, ma non permette di stabilire se essa derivi da proprietà condivise degli attacchi o da caratteristiche distributive comuni ai domini target, dato il confondimento tra classe e provenienza presente nel training.

Specializzazione dei modelli biclasse. I rilevatori specialistici mostrano una maggiore eterogeneità. Pur raggiungendo prestazioni perfette o quasi perfette sulla distribuzione omologa,

la loro sensibilità media sui nove benchmark target può ridursi considerevolmente. Il modello nb15_sat20_syn_ddos, ad esempio, raggiunge TPR unitaria sulla propria classe ma TPR target medie pari a 0.424387, 0.315589 e 0.443831 rispettivamente per DT, HGB e RF.

Una maggiore trasferibilità emerge per nb15_sat20_udp_ddos, che raggiunge 0.974900 per DT, 0.551311 per HGB e 0.898881 per RF. Il modello nb15_ter20_syn_ddos evidenzia invece una forte dipendenza dall'architettura: DT e RF raggiungono rispettivamente 0.999928 e 0.999910, mentre HGB si arresta a 0.629574.

Un'elevata prestazione sulla distribuzione omologa non implica pertanto una generalizzazione cross-target altrettanto elevata. Tale proprietà distingue in particolare i rilevatori biclasse dai modelli aggregati, che presentano una risposta sostanzialmente uniforme nell'intero gruppo target.

Stabilità multi-seed e raccordo con la diagnostica distributiva. La stabilità sulle distribuzioni omologhe risulta molto elevata. Per la quasi totalità delle configurazioni, la TPR media rimane pari a 1.0000 con varianza nulla; anche le poche variazioni osservate sono dell'ordine di 10^{-8} . Il comportamento rilevato nel seed $s = 42$ non rappresenta quindi un'anomalia isolata della specifica inizializzazione.

La forte asimmetria tra sorgente e target è inoltre compatibile con la diagnostica sviluppata nella Sezione 5.1. La PCA di NB15_STIN ha evidenziato una marcata separazione geometrica tra traffico nominale sorgente e traffico malevolo target, mentre le KDE hanno mostrato variazioni distributive rilevanti per pkts_per_sec, total_bytes e dst_win_byt. Nel paradigma ibrido tali differenze coincidono strutturalmente con la distinzione tra le etichette.

Il profilo

$$TNR_{NB15, \text{benigno}} = 1, \quad TPR_{\text{Target}} \simeq 1, \quad TPR_{NB15, \text{attacco}} \simeq 0$$

risulta pertanto compatibile con una funzione decisionale fortemente allineata alla struttura distributiva presente nei benchmark ibridi. Le sole metriche non consentono tuttavia di determinare quali caratteristiche producano tale separazione né di distinguere informazione di classe e informazione di dominio.

Nel complesso, $\mathcal{M}_H$ presenta quindi una specializzazione target molto pronunciata e stabile, accompagnata dalla perdita quasi completa della sensibilità verso gli attacchi sorgente. Tale po-

larizzazione motiva il confronto diretto con $\mathcal{M}_{\text{base}}$, caratterizzata invece da una conoscenza target estremamente sparsa.

5.4.2 Analisi Comparativa Incrociata: Modelli Ibridi vs Baseline

Criterio di confronto. Il confronto con la baseline viene condotto distinguendo la TPR media sui sei benchmark NB15, la risposta sul benchmark INJECTION, la TPR media sui nove benchmark target e la TPR media sull'intera cross-evaluation.

Per un generico modello ibrido h e un gruppo di benchmark g , viene definita

$$\Delta TPR_{h,g} = \overline{TPR}_{h,g} - \overline{TPR}_{\text{base},g}, \quad (5.7)$$

mentre per la specificità viene utilizzata

$$\Delta TNR_h = \overline{TNR}_h - \overline{TNR}_{\text{base}}. \quad (5.8)$$

Un valore positivo indica quindi un vantaggio del modello ibrido rispetto alla baseline sulla misura considerata.

Confronto dei modelli aggregati. La Tabella 5.7 sintetizza il confronto multi-seed tra i tre modelli aggregati ibridi e injection_aggregate.

Tabella 5.7: Differenze di TPR e TNR tra i modelli aggregati ibridi e la baseline INJECTION. I valori sono calcolati come modello ibrido meno baseline.

Modello Ibrido	ΔTPR_{NB15}	ΔTPR_{INJ}	ΔTPR_{Target}	ΔTPR_{16}	ΔTNR
DT					
nb15_stin_aggregate	-0.78597	-0.82428	+0.03381	-0.32724	+0.01540
nb15_sat20_aggregate	-0.78597	-0.82428	+0.03377	-0.32726	+0.01540
nb15_ter20_aggregate	-0.78597	-0.82428	+0.03381	-0.32724	+0.01540
HGB					
nb15_stin_aggregate	-0.76085	-0.80375	+0.17025	-0.23979	+0.00342
nb15_sat20_aggregate	-0.76085	-0.80375	+0.15210	-0.25000	+0.00342
nb15_ter20_aggregate	-0.76085	-0.80375	+0.17025	-0.23979	+0.00342
RF					
nb15_stin_aggregate	-0.78198	-0.82238	+0.01171	-0.33805	+0.00943
nb15_sat20_aggregate	-0.78198	-0.82238	+0.01168	-0.33807	+0.00943
nb15_ter20_aggregate	-0.78198	-0.82238	+0.01169	-0.33806	+0.00943

Il segno delle differenze evidenzia una netta inversione del vantaggio in funzione del dominio. Sui benchmark target, tutti i modelli aggregati ibridi presentano una sensibilità media superiore alla baseline. Per DT, l'incremento è pari a circa +0.034; per HGB varia tra +0.15210 e +0.17025; per RF si riduce a circa +0.0117, poiché la baseline raggiunge già una TPR target media pari a 0.98821.

Il vantaggio target è tuttavia accompagnato da una perdita di magnitudine molto maggiore sul dominio sorgente. La TPR media NB15 della baseline è pari a 0.78597 per DT, 0.76085 per HGB e 0.78198 per RF, mentre i tre modelli aggregati ibridi assumono valore nullo. La stessa asimmetria emerge su INJECTION: la baseline raggiunge rispettivamente 0.82748, 0.80695 e 0.82558, contro 0.00320 dei modelli aggregati ibridi.

Vantaggio sui benchmark target e specificità. Considerando separatamente i tre modelli aggregati e i nove benchmark target, DT produce 27 confronti su 27 con TPR superiore alla baseline; il

vantaggio varia da +0.00025 a +0.10464. Anche per HGB tutti i 27 confronti risultano favorevoli agli aggregati ibridi, con differenze comprese tra +0.07129 e +0.50114. Per RF, 24 confronti producono un incremento e i restanti tre, relativi alla classe DDoS di TER20, una parità a 1.0000; nessun confronto risulta sfavorevole al modello ibrido e il vantaggio massimo è pari a +0.06032.

Se il criterio fosse limitato alla sensibilità sulle distribuzioni target, gli aggregati ibridi rappresenterebbero quindi le configurazioni più performanti tra quelle considerate.

La TNR introduce tuttavia un'ulteriore cautela. I modelli ibridi raggiungono 1.0000, rispetto a 0.98460 per DT, 0.99658 per HGB e 0.99057 per RF nella baseline. Gli incrementi di specificità, pari rispettivamente a 0.01540, 0.00342 e 0.00943, non possono però essere interpretati indipendentemente dalla TPR nulla sugli attacchi NB15. La classificazione corretta di tutto il traffico nominale sorgente coesiste infatti con la mancata identificazione delle anomalie appartenenti allo stesso dominio.

Generalizzazione lungo l'intera cross-evaluation. Il compromesso diventa evidente considerando la TPR media sui 16 test set. La baseline raggiunge

0.88990 (DT), 0.80246 (HGB), 0.90071 (RF).

Gli aggregati ibridi rimangono invece compresi tra 0.56264 e 0.56266 per DT, tra 0.55246 e 0.56267 per HGB e intorno a 0.56265 per RF. L'incremento di sensibilità sui target non compensa quindi la perdita sui sei benchmark NB15 e su INJECTION.

La configurazione che massimizza la TPR sul solo dominio target non coincide pertanto con quella che presenta la risposta più uniforme sull'intero insieme delle condizioni sperimentali. $\mathcal{M}_{\text{base}}$ rinuncia a una quota di sensibilità target rispetto agli aggregati ibridi, ma conserva contestualmente la capacità di riconoscere gli attacchi sorgente.

Modelli biclasse: specializzazione locale e trasferimento cross-target. Il confronto con la baseline conferma la maggiore dipendenza dei rilevatori biclasse dalla specifica distribuzione utilizzata nel training. Per DT, tre dei sei specialisti superano la TPR target media della baseline: nb15_sat20_udp_ddos, con 0.97490; nb15_ter20_syn_ddos, con 0.99993; e nb15_ter20_udp_ddos, con 0.97867.

Per HGB soltanto nb15_ter20_botnet, con 0.84210, supera la baseline, pari a 0.82970. Per RF, la cui baseline raggiunge 0.98821, soltanto nb15_ter20_syn_ddos, con 0.99991, mantiene un vantaggio nella media sui nove benchmark target.

Il risultato distingue quindi specializzazione omologa e generalizzazione cross-target: una TPR unitaria sulla famiglia utilizzata durante il training non implica necessariamente una risposta altrettanto efficace sulle altre popolazioni target.


Raccordo con la struttura distributiva. Il profilo dei modelli ibridi risulta coerente con la separazione osservata mediante PCA e KDE tra traffico nominale NB15 e traffico malevolo target. Nel paradigma ibrido tali differenze distributive sono sistematicamente associate alle etichette durante l'addestramento; nella baseline, al contrario, la classe positiva rimane prevalentemente sorgente e integra soltanto una quota target sparsa.

Le metriche non consentono di determinare se i modelli ibridi utilizzino direttamente informazione riconducibile al dominio o caratteristiche semantiche degli attacchi. Esse mostrano tuttavia una generalizzazione asimmetrica: l'estensione della conoscenza target non determina il mantenimento della sensibilità verso le anomalie sorgente.

Il confronto quantitativo identifica pertanto due profili distinti: $\mathcal{M}_H$ massimizza la sensibilità sulle distribuzioni target, mentre $\mathcal{M}_{base}$ mantiene un comportamento più uniforme tra dominio sorgente e target. L'analisi SHAP approfondisce la diversa organizzazione delle feature associata a tali profili.


5.4.3 Analisi SHAP del Modello Aggregato Ibrido NB15_STIN

Criterio di analisi. L'analisi considera il modello nb15_stin_aggregate per DT, HGB e RF, utilizzando il seed $s = 42$ e il benchmark NB15_STIN. Il criterio di lettura delle attribuzioni è quello introdotto nella Sottosezione 5.2.2; vengono pertanto confrontate la gerarchia globale delle feature e la direzione qualitativa dei contributi, senza utilizzare l'ampiezza assoluta degli assi SHAP per confronti quantitativi tra architetture.



(a) Decision Tree

(b) Histogram-based Gradient Boosting



(c) Random Forest

Figura 5.9: Summary plot SHAP del modello aggregato ibrido NB15_STIN implementato mediante Decision Tree, Histogram-based Gradient Boosting e Random Forest, valutati sul benchmark NB15_STIN con seed $s = 42$.

Decision Tree. Nel DT, Figura 5.9(a), le prime due posizioni sono occupate da `dst_win_byt` e `src_win_byt`, seguite da `byte_ratio`, `win_diff` e `src_mean_pkt_size`. Per `dst_win_byt`, valori elevati risultano prevalentemente associati a contributi negativi, mentre alcune osservazioni con valori ridotti producono contributi positivi di ampiezza marcata. Le feature successive presentano invece attribuzioni molto più concentrate intorno allo zero.

Histogram-based Gradient Boosting. Per HGB, Figura 5.9(b), `dst_win_byt` e `src_win_byt` mantengono rispettivamente la prima e la seconda posizione, seguite da `duration`, `pkts_per_sec` e `src_bytes`. Anche in questo caso i valori elevati di `dst_win_byt` risultano prevalentemente associati a contributi negativi, mentre alcune osservazioni caratterizzate da valori ridotti producono contributi positivi di ampiezza sensibilmente superiore alle feature successive. La funzione decisionale rappresentata appare quindi fortemente concentrata sulle due variabili di finestra.

Random Forest. Nel RF, Figura 5.9(c), le feature `dst_win_byt` e `src_win_byt` occupano ancora le prime due posizioni, seguite da `dst_mean_pkt_size`, `load_s` e `win_diff`. RF mantiene una distribuzione delle attribuzioni relativamente più articolata rispetto a DT e HGB, ma la centralità delle due feature di finestra rimane evidente.

Per `dst_win_byt`, valori elevati tendono nuovamente a produrre contributi negativi, mentre alcune osservazioni con valori ridotti sono associate agli spostamenti positivi più marcati. Per `src_win_byt` la relazione risulta meno monotona e sono osservabili contributi positivi associati a differenti regioni della feature.

Confronto sinottico delle gerarchie ibride. La Tabella 5.8 sintetizza le prime cinque feature delle tre architetture.

Tabella 5.8: Prime cinque feature nella graduatoria SHAP del modello aggregato ibrido NB15_STIN per DT, HGB e RF al seed $s = 42$.

Rank	DT	HGB	RF
1	dst_win_byt	dst_win_byt	dst_win_byt
2	src_win_byt	src_win_byt	src_win_byt
3	byte_ratio	duration	dst_mean_pkt_size
4	win_diff	pkts_per_sec	load_s
5	src_mean_pkt_size	src_bytes	win_diff

Il risultato principale è la completa concordanza delle prime due posizioni: DT, HGB e RF attribuiscono la maggiore rilevanza globale a `dst_win_byt` e `src_win_byt`. Nei modelli DT e HGB, inoltre, gran parte delle feature successive presenta attribuzioni prossime allo zero, mentre RF mantiene una funzione decisionale relativamente più distribuita.

Riorganizzazione rispetto ai modelli sorgente e alla baseline. La gerarchia ibrida differisce nettamente da quelle analizzate nelle Sottosezioni 5.3.3 e 5.2.2. `pkts_per_sec`, prima feature per DT, HGB e RF sia nel modello sorgente sia nella baseline, scende al settimo posto per DT e RF e al quarto per HGB nel modello ibrido. Analogamente, `total_bytes`, seconda per DT e RF sorgente e comunque centrale nella baseline, viene collocata al decimo posto per DT, al nono per HGB e all'undicesimo per RF.

Parallelamente, `dst_win_byt` e `src_win_byt` diventano rispettivamente prima e seconda feature in tutte le architetture. Il passaggio al training ibrido è quindi associato a una sostanziale riorganizzazione della gerarchia delle attribuzioni, e non alla semplice amplificazione delle medesime caratteristiche predominanti nei paradigmi precedenti.

Raccordo con KDE e comportamento prestazionale. Il ruolo assunto da `dst_win_byt` trova un riscontro nella diagnostica KDE. Per la componente malevola, la media passa da circa 87.52 nel dominio sorgente a circa -0.78 in STIN, mentre la varianza si riduce da circa 1.47×10^4 a

4.01×10^3 . Nel modello ibrido, i valori ridotti della feature sono contestualmente quelli associati a numerosi contributi SHAP positivi di maggiore ampiezza.

KDE e SHAP identificano pertanto `dst_win_byt` come una dimensione che presenta sia una variazione distributiva tra sorgente e target sia un'elevata rilevanza decisionale nel paradigma ibrido. Tale convergenza non costituisce tuttavia una dimostrazione causale.

`pkts_per_sec` rappresenta il caso complementare: pur mostrando nella KDE lo scostamento quantitativo più marcato tra NB15 e STIN, non occupa le prime posizioni della gerarchia ibrida. Si conferma quindi il principio già emerso nella Sezione 5.3:

ampiezza del domain shift $\neq$ rilevanza predittiva.

Il raccordo con le prestazioni deve inoltre considerare il confondimento strutturale del benchmark NB15_STIN. La combinazione tra TNR unitaria sul traffico nominale sorgente, TPR prossime all'unità sul target, TPR sostanzialmente nulla sugli attacchi NB15 e predominanza SHAP delle feature di finestra è compatibile con una funzione decisionale fortemente allineata alla separazione distributiva presente nel training set.

Non è tuttavia possibile stabilire se le variabili di finestra vengano utilizzate perché descrivono proprietà intrinseche degli attacchi, perché distinguono efficacemente i domini o per una combinazione delle due informazioni. L'evidenza SHAP mostra quindi una concreta riorganizzazione della funzione decisionale rispetto alla baseline, senza permettere di attribuirle un'interpretazione causale univoca.

Nel complesso, il modello aggregato ibrido concentra la propria gerarchia su feature differenti rispetto ai paradigmi sorgente e INJECTION. Tale struttura accompagna una forte specializzazione target e una ridotta trasferibilità inversa verso gli attacchi sorgente. La significatività delle differenze globali viene verificata mediante il medesimo protocollo multi-seed utilizzato nella Sezione 5.3.

5.4.4 Analisi della Significatività Statistica (Test t di Welch) dei Modelli Ibridi vs Baseline

Criterio statistico. La verifica inferenziale utilizza la medesima procedura definita nella Sottosezione 5.3.4. Per ciascun modello e seed viene quindi utilizzata la media dell'F1-Score sui 16

benchmark, $\overline{F1}_i^{(k)}$, definita nell'Equazione (5.6). I $K = 10$ valori seed-level di ciascuno dei nove modelli ibridi vengono confrontati con quelli della baseline *injection_aggregate* mediante un test t di Welch bilaterale, con $\alpha = 0.05$ e senza assumere uguaglianza delle varianze.

Anche in questo caso il test riguarda la prestazione *globale* lungo l'intera cross-evaluation e non produce una verifica separata per i singoli benchmark sorgente o target.

Sintesi descrittiva dell'F1-Score multi-seed. Le statistiche complete sono riportate nella Tabella A.12 in Appendice. Per DT, la baseline raggiunge una media globale pari a 0.860388, mentre i tre modelli aggregati ibridi si attestano intorno a 0.56287. Per HGB, *injection_aggregate* raggiunge 0.854074, contro 0.562881 dei modelli aggregati *nb15_stin_aggregate* e *nb15_ter20_aggregate*. Per RF, la baseline raggiunge 0.890221, mentre gli aggregati ibridi rimangono nuovamente prossimi a 0.56287.

Il valore intorno a 0.5625 non rappresenta una prestazione uniformemente intermedia sui singoli test set. Esso sintetizza due regimi fortemente differenti: prestazioni quasi perfette sui nove benchmark target e prestazioni prossime allo zero sui sei benchmark NB15 e su INJECTION.

Numerose configurazioni ibride presentano inoltre dispersioni inter-seed estremamente contenute, fino a deviazioni standard nulle. Tale stabilità non costituisce di per sé un indicatore di migliore qualità predittiva: una configurazione può riprodurre con elevata regolarità un comportamento fortemente specializzato e mantenere comunque una prestazione globale inferiore alla baseline.

Risultati del test t di Welch. I risultati completi dei 27 confronti sono riportati nella Tabella ?? in Appendice. Tutti soddisfano la condizione $p < 0.05$ e tutte le statistiche t assumono segno positivo. Secondo il test adottato, le distribuzioni delle medie F1 multi-seed non risultano quindi compatibili con l'ipotesi nulla di uguaglianza delle medie per nessuna delle configurazioni ibride considerate.

Il segno delle statistiche deve essere letto congiuntamente alle medie campionarie: la baseline costituisce il primo campione fornito alla procedura e presenta in ogni confronto una media globale superiore. Il test rimane comunque bilaterale e la direzione empirica del divario deriva dal confronto delle statistiche descrittive, non dalla formulazione dell'ipotesi alternativa.

La significatività globale non implica che la baseline superi i modelli ibridi su ciascun benchmark individualmente. Tale interpretazione sarebbe incompatibile con i risultati precedenti, nei quali gli

aggregati ibridi raggiungono TPR superiori alla baseline sulle distribuzioni target. Il test indica invece che, secondo la misura globale sui 16 benchmark, i due paradigmi presentano medie differenti; la direzione osservata è favorevole alla baseline perché quest'ultima conserva contemporaneamente prestazioni elevate sul sorgente e sul target.

I modelli aggregati raggiungono generalmente le maggiori medie globali all'interno del gruppo ibrido, coerentemente con la loro maggiore trasferibilità cross-target. I rilevatori biclasse possono invece ottenere prestazioni perfette sulla distribuzione omologa mantenendo una copertura molto inferiore delle altre famiglie.

Come nella precedente analisi di Welch, i *p-value* vengono valutati individualmente rispetto a $\alpha = 0.05$ senza applicare correzioni per confronti multipli. La valutazione mantiene pertanto il carattere esplorativo previsto dal protocollo sperimentale e non realizza un controllo globale dell'errore di I tipo sull'insieme dei 27 confronti.

Sintesi della valutazione dei modelli ibridi. La valutazione di $\mathcal{M}_H$ distingue nettamente specializzazione target e generalizzazione globale. I modelli aggregati ibridi raggiungono le maggiori sensibilità sulle distribuzioni target e una TNR sistematicamente unitaria, ma perdono quasi completamente la capacità di riconoscere gli attacchi sorgente. L'analisi SHAP mostra contestualmente una riorganizzazione della gerarchia decisionale verso le feature di finestra, in presenza del confondimento strutturale tra dominio e classe.

La baseline INJECTION, pur non massimizzando la TPR sui soli benchmark target, mantiene un comportamento più uniforme sull'intera cross-evaluation. I 27 confronti Welch risultano significativi secondo il criterio adottato e le medie globali sono sistematicamente superiori per la baseline. Il risultato non identifica pertanto un paradigma intrinsecamente superiore in ogni condizione, ma due strategie con proprietà differenti: specializzazione target per $\mathcal{M}_H$ e maggiore conservazione congiunta della conoscenza sorgente e target per $\mathcal{M}_{\text{base}}$.

La Sezione 5.5 integra tali evidenze con quelle ottenute per i modelli sorgente e per la baseline in un quadro comparativo globale.

5.5 Discussione Generale e Quadro Comparativo Globale

Le sezioni precedenti hanno analizzato separatamente i tre paradigmi di addestramento considerati nel protocollo sperimentale: i modelli puramente sorgente $\mathcal{M}_S$, la baseline con conoscenza target sparsa $\mathcal{M}_{\text{base}}$ e i modelli ibridi $\mathcal{M}_H$. La presente sezione integra tali evidenze in un unico quadro interpretativo, mettendo in relazione capacità di rilevamento, generalizzazione cross-domain, stabilità multi-seed e organizzazione delle feature utilizzate dai classificatori.

L'obiettivo non consiste nel reiterare le singole metriche già discusse, ma nel distinguere tre proprietà complementari: conservazione della conoscenza sorgente, specializzazione verso il dominio target e capacità di mantenere simultaneamente entrambe le componenti. Tale distinzione risulta necessaria poiché la configurazione che massimizza la sensibilità sul solo dominio target non coincide necessariamente con quella che presenta il comportamento più uniforme lungo l'intera matrice di *cross-evaluation*.

5.5.1 Quadro Comparativo Globale

Criterio di sintesi. Il confronto viene effettuato sui medesimi raggruppamenti utilizzati nelle analisi precedenti. Indicando con $\mathcal{G}_S$ l'insieme dei sei benchmark appartenenti alla tassonomia NB15 e con $\mathcal{G}_T$ l'insieme dei nove benchmark target, la sensibilità media di un generico modello i sul gruppo $\mathcal{G}$ viene espressa come

$$\overline{TPR}_{i,\mathcal{G}} = \frac{1}{|\mathcal{G}|} \sum_{j \in \mathcal{G}} \overline{TPR}_{ij}, \quad (5.9)$$

dove $\overline{TPR}_{ij}$ rappresenta la TPR media sulle $K = 10$ repliche per la coppia modello–test set. Il benchmark INJECTION e la media sull'intero insieme dei 16 test vengono mantenuti separati, così da preservare l'informazione relativa all'asimmetria tra comportamento sorgente e target. Per l'F1-Score viene richiamata la misura globale multi-seed già definita nell'Equazione (5.6).

Nel paradigma $\mathcal{M}_S$ viene considerato nb15_aggregate; per $\mathcal{M}_{\text{base}}$ viene utilizzato injection_aggregate; per $\mathcal{M}_H$ vengono invece riportati gli intervalli minimo–massimo osservati tra i tre modelli aggregati nb15_stin_aggregate, nb15_sat20_aggregate e nb15_ter20_aggregate.

Sintesi quantitativa dei tre paradigmi. La Tabella 5.9 costituisce il riferimento quantitativo principale della discussione, riunendo le metriche necessarie a confrontare direttamente i tre paradigmi.

Tabella 5.9: Quadro comparativo globale dei modelli aggregati sorgente, baseline e ibridi. Per $\mathcal{M}_H$ gli intervalli rappresentano i valori minimo e massimo osservati tra i tre modelli aggregati ibridi.

Paradigma	Configurazione	$\overline{TPR}_{NB15}$	TPR_{INJ}	$\overline{TPR}_{Target}$	$\overline{TPR}_{16}$	$\overline{TNR}$	$\overline{F1}$
DT							
$\mathcal{M}_S$	nb15_aggregate	0.7870	0.82742	0.3234	0.5288	0.98317	0.56308
$\mathcal{M}_{base}$	injection_aggregate	0.78597	0.82748	0.96612	0.88990	0.98460	0.860388
$\mathcal{M}_H^{aggr}$	NB15+Target	0.0000	0.00320	0.999889–0.999922	0.56264–0.56266	1.0000	0.562863–0.562874
HGB							
$\mathcal{M}_S$	nb15_aggregate	0.7601	0.80387	0.0607	0.3694	0.99659	0.41231
$\mathcal{M}_{base}$	injection_aggregate	0.76085	0.80695	0.82970	0.80246	0.99658	0.854074
$\mathcal{M}_H^{aggr}$	NB15+Target	0.0000	0.00320	0.981796–0.999944	0.55246–0.56267	1.0000	0.556714–0.562881
RF							
$\mathcal{M}_S$	nb15_aggregate	0.7833	0.82719	0.3035	0.5161	0.99150	0.57651
$\mathcal{M}_{base}$	injection_aggregate	0.78198	0.82558	0.98821	0.90071	0.99057	0.890221
$\mathcal{M}_H^{aggr}$	NB15+Target	0.0000	0.00320	0.999894–0.999922	0.56264–0.56266	1.0000	0.562864–0.562874

Tre differenti regimi di generalizzazione. Il paradigma sorgente $\mathcal{M}_S$ conserva una capacità discriminativa significativa sui benchmark NB15 e mantiene TNR elevate, ma mostra una riduzione marcata della sensibilità quando la componente malevola appartiene ai domini target. Il limite osservato riguarda pertanto principalmente la generalizzazione della regione positiva appresa e non una degradazione generalizzata della classificazione del traffico nominale.

La baseline $\mathcal{M}_{base}$ mantiene invece sul gruppo NB15 valori sostanzialmente coincidenti con quelli del corrispondente modello sorgente, con differenze della TPR media dell'ordine di 10^{-3} . Il comportamento sul target cambia tuttavia radicalmente: la sensibilità media raggiunge 0.96612 per DT, 0.82970 per HGB e 0.98821 per RF, mentre la TNR rimane sostanzialmente preservata. La presenza di conoscenza target sparsa è quindi associata, nel protocollo analizzato, a una forte estensione della capacità cross-domain senza una corrispondente perdita della sensibilità sorgente.

Il paradigma ibrido $\mathcal{M}_H$ rappresenta l'estremo opposto. I modelli aggregati raggiungono sensibilità target prossime all'unità e TNR pari a 1.0000, ma presentano TPR nulla sui benchmark NB15 e circa 0.00320 su INJECTION. La conoscenza target estesa non produce quindi un semplice

ampliamento della funzione decisionale precedente: nei dati osservati emerge una sostituzione della specializzazione, nella quale l'elevata copertura del dominio target è accompagnata dalla perdita della capacità di riconoscere le anomalie sorgente.

Specializzazione target e generalizzazione globale. La progressione tra i tre paradigmi mostra che una maggiore quantità di conoscenza target nel training set non determina un miglioramento monotono della generalizzazione complessiva. Il passaggio da $\mathcal{M}_S$ a $\mathcal{M}_{base}$ produce un forte incremento della sensibilità target preservando il comportamento sul sorgente; il passaggio successivo a $\mathcal{M}_H$ incrementa ulteriormente la sensibilità target, ma sacrifica quasi completamente la retention delle anomalie NB15.

La conseguenza è evidente nelle metriche globali. La baseline raggiunge la maggiore TPR media sui 16 benchmark per tutte le architetture: 0.88990 per DT, 0.80246 per HGB e 0.90071 per RF. La medesima gerarchia emerge dall'F1-Score globale multi-seed, pari rispettivamente a 0.860388, 0.854074 e 0.890221. I modelli aggregati ibridi, pur massimizzando la sensibilità target, rimangono invece intorno a 0.56 nelle misure globali a causa del comportamento fortemente polarizzato tra i due domini.

Il risultato principale non consiste pertanto nella massimizzazione assoluta di una singola metrica, ma nel compromesso tra adattamento al nuovo dominio e conservazione delle conoscenze precedentemente apprese.

Influenza dell'architettura e della composizione del training set. L'architettura del classificatore modula tale compromesso senza modificarne la struttura generale. Nella baseline, RF presenta il profilo predittivo globale più favorevole, con la maggiore TPR target, la maggiore TPR sui 16 benchmark e il maggiore F1-Score globale. HGB presenta invece la maggiore specificità, pari a 0.99658, accompagnata da una sensibilità target inferiore; DT assume una posizione intermedia e mantiene valori relativamente prossimi a RF nella sensibilità target.

Le variazioni associate alla composizione del training set risultano tuttavia di magnitudine maggiore rispetto a molte delle differenze tra architetture. Il passaggio dal modello aggregato sorgente alla baseline incrementa la TPR target di +0.6427 per DT, +0.7690 per HGB e +0.6847 per RF, mantenendo invariata la famiglia algoritmica. Nel protocollo considerato, la composizione

dei dati di addestramento costituisce quindi un fattore determinante per la generalizzazione cross-domain almeno quanto la scelta tra i tre classificatori analizzati.

Stabilità e significatività delle differenze globali. L'analisi multi-seed rafforza il quadro descrittivo. Tutti i 18 confronti di Welch tra baseline e modelli sorgente e tutti i 27 confronti tra baseline e modelli ibridi risultano significativi secondo il criterio $p < 0.05$ adottato dal protocollo. In tutti i casi la media globale dell'F1-Score risulta superiore per INJECTION.

Tale risultato riguarda la misura aggregata sui 16 benchmark e non implica una superiorità della baseline su ciascun test individuale: i modelli aggregati ibridi, ad esempio, mantengono TPR superiori sui benchmark target. I p -value sono inoltre valutati individualmente senza correzione per confronti multipli, per cui l'evidenza inferenziale conserva il carattere esplorativo definito dalla metodologia.

Nel complesso, $\mathcal{M}_S$ identifica il regime di conservazione in-domain con limitata robustezza al *domain shift*, $\mathcal{M}_H$ quello di massima specializzazione target, mentre $\mathcal{M}_{\text{base}}$ realizza il comportamento più uniforme nell'intera matrice sperimentale. Le differenti strutture decisionali associate a tali regimi vengono integrate nella sottosezione successiva con le evidenze distributive e SHAP.

5.5.2 Mappatura delle Associazioni tra Proprietà della Rete e Comportamento del Modello

Criterio interpretativo. Le analisi PCA e KDE hanno caratterizzato lo scostamento tra le distribuzioni sorgente e target, mentre SHAP ha identificato le feature maggiormente coinvolte nelle funzioni decisionali dei classificatori. La presente sottosezione mette in relazione tali evidenze con i profili prestazionali dei tre paradigmi.

Le corrispondenze discusse hanno carattere associativo e non causale. Il protocollo sperimentale non comprende interventi controllati sulle singole feature né studi di ablazione che permettano di isolare il contributo causale di una variabile alle prestazioni. Distribuzione, attribuzioni SHAP e comportamento predittivo vengono quindi considerate come evidenze complementari osservate nella medesima campagna sperimentale.

pkts_per_sec: elevato shift e centralità nei paradigmi sorgente e baseline. Tra le feature analizzate mediante KDE, `pkts_per_sec` presenta lo scostamento quantitativo più marcato tra la componente malevola NB15 e STIN, con differenze superiori a cinque ordini di grandezza nella media e a dodici ordini nella varianza.

La stessa variabile occupa la prima posizione SHAP per DT, HGB e RF sia nei modelli sorgente sia nella baseline. Una delle dimensioni maggiormente interessate dal *domain shift* coincide quindi con la feature alla quale tali modelli attribuiscono concordemente la maggiore rilevanza globale. Contestualmente, $\mathcal{M}_S$ presenta una forte perdita di sensibilità sul target, mentre $\mathcal{M}_{base}$ conserva la medesima feature dominante ma raggiunge una generalizzazione molto superiore.

L'evidenza non permette di attribuire il degrado dei modelli sorgente a `pkts_per_sec` isolatamente. Le attribuzioni mostrano infatti un comportamento non monotono e le funzioni decisionali utilizzano simultaneamente più dimensioni. La variabile rappresenta piuttosto un caso nel quale forte variazione distributiva ed elevata rilevanza predittiva coesistono.

Conoscenza target sparsa e conservazione della struttura sorgente. La baseline fornisce un secondo elemento interpretativo. Pur sostituendo soltanto 29 dei 9 300 campioni della componente malevola con traffico target, INJECTION mantiene una gerarchia SHAP largamente sovrapposta a quella del modello sorgente: `pkts_per_sec` rimane prima per tutte le architetture e numerose feature secondarie continuano a occupare posizioni elevate.

La conoscenza target sparsa non coincide quindi con una completa riorganizzazione della funzione decisionale. Nel protocollo osservato, essa è associata alla conservazione della sensibilità NB15 e, simultaneamente, a un forte incremento della risposta sulle distribuzioni target. Non può essere concluso che i soli 29 campioni siano causalmente responsabili dell'intero incremento; è invece possibile affermare che la loro introduzione distingue sperimentalmente la baseline dal corrispondente paradigma sorgente.

total_bytes: variazione distributiva e rilevanza sorgente. Un comportamento analogo, ma meno estremo, riguarda `total_bytes`. La KDE mostra nel dominio target una forte riduzione della posizione media e della dispersione rispetto alla componente malevola NB15. Contestualmente, la

feature occupa la seconda posizione per DT e RF nei modelli sorgente e mantiene elevata rilevanza nella baseline, dove è seconda per RF e terza per DT.

Nel modello aggregato ibrido la feature assume invece un ruolo molto più ridotto. La variazione della sua importanza tra i paradigmi conferma che una caratteristica fortemente informativa nel dominio sorgente non mantiene necessariamente la medesima priorità quando cambia radicalmente la composizione della classe positiva.

Feature di finestra e specializzazione del paradigma ibrido. La riorganizzazione più netta emerge nel modello aggregato NB15_STIN. La KDE mostra per `dst_win_byt` una distribuzione malevola target sensibilmente differente rispetto al riferimento NB15. Nei modelli sorgente tale feature occupa posizioni inferiori nelle graduatorie SHAP; nel paradigma ibrido diventa invece la caratteristica con maggiore rilevanza globale per DT, HGB e RF. `src_win_byt` assume contemporaneamente la seconda posizione in tutte le architetture.

Per `dst_win_byt`, valori ridotti sono frequentemente associati ai contributi SHAP positivi di maggiore ampiezza, mentre valori elevati tendono a produrre contributi negativi. Tale riorganizzazione delle attribuzioni coesiste con il profilo prestazionale caratteristico del paradigma ibrido: TNR unitaria sul traffico nominale sorgente, TPR prossime all'unità sulle distribuzioni target e sensibilità sostanzialmente nulla verso gli attacchi NB15.

L'interpretazione deve tuttavia considerare che nel benchmark NB15_STIN dominio e classe sono strutturalmente confusi: $Y = 0$ identifica traffico nominale NB15 e $Y = 1$ traffico malevolo STIN. Non è pertanto possibile determinare se la centralità delle feature di finestra rifletta proprietà intrinseche degli attacchi, differenze di dominio o una combinazione delle due informazioni.

Domain shift e rilevanza predittiva come proprietà distinte. Il confronto tra `pkts_per_sec` e `dst_win_byt` evidenzia un principio trasversale. La prima presenta lo scostamento quantitativo più estremo nella diagnostica KDE, ma nel paradigma ibrido scende alla settima posizione SHAP per DT e RF e alla quarta per HGB. La seconda presenta uno scostamento meno estremo, ma diventa la feature dominante in tutte le architetture ibride.

Ne consegue che

ampiezza del domain shift $\neq$ rilevanza predittiva.

La distanza marginale tra due distribuzioni e l'utilità della feature nella funzione decisionale descrivono proprietà differenti dello spazio dei dati. La classificazione dipende infatti dall'interazione multidimensionale tra le caratteristiche e non dalla sola entità dello scostamento osservato su una singola variabile.

Ruolo della composizione del training set. La lettura congiunta dei tre paradigmi mostra infine che la composizione della classe malevola è sistematicamente associata a differenti organizzazioni della funzione decisionale. Nel paradigma sorgente, la classe positiva è interamente NB15; nella baseline rimane prevalentemente sorgente e incorpora una componente target di 29 osservazioni; nel paradigma ibrido la classe nominale è sorgente e quella malevola interamente target.

La progressione non descrive quindi un semplice incremento quantitativo della conoscenza target, ma tre differenti condizioni distributive di addestramento. Le rispettive gerarchie SHAP e i profili di generalizzazione mostrano che la modalità con cui il nuovo dominio viene incorporato nel training set è associata al tipo di conoscenza successivamente trasferito dal classificatore.

Mappatura sinottica delle evidenze. La Tabella 5.10 sintetizza le principali associazioni tra diagnostica distributiva, attribuzioni SHAP e comportamento prestazionale.

Tabella 5.10: Mappatura sinottica delle associazioni osservate tra evidenze distributive, rilevanza SHAP e comportamento prestazionale. Le relazioni riportate non rappresentano nessi causali dimostrati.

Evidenza distributiva	Evidenza SHAP	Comportamento associato
pkts_per_sec: scostamento più marcato tra componente malevola NB15 e STIN.	Prima feature per DT, HGB e RF nei modelli sorgente e nella baseline; rilevanza inferiore nei modelli ibridi.	Fragilità target dei modelli sorgente e forte incremento della generalizzazione nella baseline, che mantiene la feature dominante.
total_bytes: riduzione marcata di posizione e dispersione nel traffico malevolo STIN.	Elevata rilevanza soprattutto nei modelli sorgente e baseline DT/RF; posizione inferiore nel modello ibrido.	Dimensione rilevante nelle configurazioni che conservano una struttura decisionale maggiormente sovrapposta a quella sorgente.
dst_win_byt: distribuzione target differente e più concentrata rispetto al riferimento sorgente.	Prima feature per DT, HGB e RF nel modello aggregato NB15_STIN.	Centralità associata al profilo fortemente specializzato del paradigma ibrido: TPR target prossime all'unità e TPR sorgente prossime a zero.
src_win_byt: non inclusa tra le tre feature sottoposte a KDE; non viene quindi assunta una caratterizzazione densometrica specifica.	Seconda feature per DT, HGB e RF nel modello aggregato ibrido.	Ulteriore evidenza della riorganizzazione della funzione decisionale nel passaggio a NB15_STIN.
INJECTION: 29 campioni target su 9 300 campioni malevoli; composizione ancora fortemente dominata dal sorgente.	Gerarchie SHAP largamente sovrapposte a quelle dei modelli NB15.	TPR sorgente sostanzialmente preservata e forte incremento della sensibilità target.
Composizione ibrida: classe nominale NB15 e classe malevola interamente target; marcata separazione distributiva.	Centralità condivisa delle feature di finestra e riduzione del ruolo di diverse feature dominanti nel paradigma sorgente.	Massima sensibilità target ma perdita quasi completa del riconoscimento degli attacchi sorgente.

Nel complesso, nessuna singola feature o misura di distanza distributiva fornisce una spiegazione sufficiente del comportamento cross-domain. Le evidenze mostrano invece un'interazione

tra composizione del training set, scostamento delle distribuzioni e caratteristiche effettivamente utilizzate dai classificatori. In tale quadro, la baseline rappresenta la configurazione nella quale l'integrazione di conoscenza target è associata alla modifica della generalizzazione senza una sostituzione completa della struttura decisionale sorgente.

5.5.3 Compromesso tra Complessità Computazionale e Prestazioni

Perimetro dell'analisi. Il confronto tra classificatori deve essere mantenuto entro le grandezze effettivamente raccolte durante la campagna sperimentale. Il protocollo non comprende misure di tempo di addestramento, latenza di inferenza, occupazione di memoria, dimensione dei modelli serializzati, utilizzo della CPU o consumo energetico. Non è pertanto possibile costruire un rapporto quantitativo tra prestazioni e costo computazionale né stabilire quale architettura sia più adatta a specifici vincoli hardware.

Il termine “complessità computazionale” viene quindi utilizzato esclusivamente in senso qualitativo e architetturale. DT è costituito da un singolo albero decisionale; RF aggrega una molteplicità di alberi e, nella configurazione implementata, utilizza $n_jobs=-1$; HGB costruisce invece iterativamente un ensemble mediante gradient boosting su rappresentazioni a istogrammi. Tali differenze non vengono convertite in stime di latenza, memoria o consumo non disponibili sperimentalmente.

Prestazioni delle tre architetture nella baseline. La configurazione INJECTION costituisce il riferimento più informativo per il confronto, poiché il quadro globale ha mostrato che essa realizza il comportamento più uniforme tra sorgente e target.

RF presenta il miglior profilo predittivo complessivo: TPR target pari a 0.98821, TPR globale pari a 0.90071, TNR pari a 0.99057 e F1-Score globale multi-seed pari a 0.890221. DT raggiunge rispettivamente 0.96612, 0.88990, 0.98460 e 0.860388. Rispetto al singolo albero, RF incrementa quindi la TPR target di 0.02209 e l'F1-Score globale di 0.029833.

HGB presenta un profilo differente. La TNR raggiunge 0.99658, valore più elevato tra le tre baseline, mentre la TPR target si riduce a 0.82970 e l'F1-Score globale a 0.854074. Rispetto a HGB, RF presenta quindi un vantaggio di 0.15851 nella TPR target e di 0.036147 nell'F1-Score globale, a fronte di una specificità leggermente inferiore.

Il protocollo evidenzia pertanto un effettivo compromesso tra i due tipi di errore. HGB privilegia maggiormente la preservazione del traffico nominale, mentre RF riduce sensibilmente la quota di attacchi target non riconosciuti. DT mantiene un profilo competitivo mediante la struttura meno articolata tra quelle considerate, senza che tale proprietà possa essere trasformata in un vantaggio computazionale misurato.

Stabilità rispetto alle inizializzazioni. La dispersione della media globale dell’F1-Score lungo i 10 seed è pari a 0.003516 per DT, 0.036341 per HGB e 0.002452 per RF. RF combina quindi il maggiore valore medio con la minore dispersione tra le tre architetture della baseline; DT presenta anch’esso una variabilità contenuta, mentre HGB mostra una maggiore sensibilità all’inizializzazione.

La stabilità non rappresenta una misura di costo computazionale, ma costituisce un ulteriore elemento nella valutazione predittiva: il confronto non riguarda soltanto la prestazione media, ma anche la regolarità con cui essa viene riprodotta nelle differenti repliche.

Composizione del training set e articolazione del modello. Le differenze tra algoritmi devono essere interpretate insieme alla composizione dei dati di addestramento. Mantenendo invariata l’architettura, il passaggio dal modello aggregato sorgente alla baseline incrementa la TPR target di +0.6427 per DT, +0.7690 per HGB e +0.6847 per RF. Tali scostamenti sono sensibilmente superiori alle differenze osservate tra DT, HGB e RF all’interno della sola baseline.

Analogamente, nei modelli aggregati ibridi tutte le architetture convergono verso TPR target prossime all’unità e TPR sorgente nulle. La maggiore articolazione algoritmica non elimina quindi gli effetti associati alla distribuzione utilizzata per il training. Nel protocollo considerato, composizione dei dati e architettura interagiscono nel determinare il comportamento finale, ma la prima produce in diversi confronti le variazioni prestazionali di maggiore magnitudine.

Sintesi qualitativa del compromesso. La Tabella 5.11 riassume il confronto senza attribuire ai classificatori costi computazionali non misurati.

Tabella 5.11: Sintesi qualitativa del compromesso tra articolazione del modello e prestazioni osservate nella configurazione INJECTION.

Articolazione strutturale	Punto di forza osservato	Limite / compromesso osservato
DT: singolo albero	Elevata TPR target (0.96612) e buona prestazione globale.	Prestazioni inferiori a RF; TNR più bassa tra le tre baseline (0.98460).
HGB: ensemble iterativo basato su boosting	Massima TNR (0.99658).	Sensibilità target più ridotta (0.82970) e maggiore dispersione inter-seed dell’F1-Score.
RF: ensemble di alberi	Massima TPR target (0.98821), massimo F1 globale (0.890221) e minore dispersione inter-seed (0.002452).	Struttura più articolata rispetto al singolo DT; il relativo costo computazionale non è quantificato dal protocollo.

Considerando esclusivamente le grandezze misurate, RF costituisce quindi il riferimento prestazionale più favorevole nella baseline, mentre HGB presenta il profilo maggiormente orientato alla specificità e DT conserva prestazioni competitive mediante una struttura algoritmica meno articolata. Non è tuttavia possibile derivare da tali risultati un ordinamento rispetto a latenza, memoria, energia o idoneità a una specifica piattaforma di esecuzione.

5.5.4 Considerazioni Operative per l’Applicabilità in Ambito NIDS Satellitare

Perimetro delle considerazioni operative. Le evidenze sperimentali consentono di derivare alcune implicazioni per la valutazione di un NIDS in presenza di *domain shift*, ma non costituiscono una validazione di deployment satellitare. La campagna misura prestazioni predittive, generaliz-

zazione cross-domain, stabilità multi-seed e caratteristiche della funzione decisionale; non misura invece proprietà della piattaforma quali latenza, memoria o consumo energetico.

Le considerazioni seguenti riguardano pertanto esclusivamente il comportamento osservato nei benchmark e nelle condizioni sperimentali definite dal framework.

Generalizzazione cross-domain come requisito di valutazione. Il primo risultato operativo riguarda i modelli addestrati esclusivamente sul sorgente. Le elevate prestazioni in-domain non vengono preservate in modo uniforme quando la distribuzione degli attacchi viene sostituita dal target, mentre la TNR rimane elevata.

Una valutazione limitata al dataset utilizzato durante l'addestramento non risulta quindi sufficiente a caratterizzare la robustezza del classificatore. Nel protocollo considerato, la matrice di *cross-evaluation* risulta essenziale proprio perché separa la capacità di riconoscere il traffico noto dalla capacità di estendere la regione positiva a distribuzioni malevole differenti.

Conoscenza target sparsa e preservazione della conoscenza sorgente. La baseline INJECTION costituisce l'evidenza principale in questa prospettiva. La sostituzione di 29 campioni sui 9 300 appartenenti alla classe malevola, pari a circa lo 0.31%, è associata a un forte incremento della sensibilità target senza una perdita sostanziale della sensibilità sui benchmark NB15.

Tale risultato deve essere mantenuto strettamente circoscritto alla configurazione sperimentale analizzata. Non dimostra che 29 osservazioni siano universalmente sufficienti per adattare un NIDS a un nuovo dominio; mostra invece che, nel trasferimento NB15→STIN considerato, una conoscenza target molto sparsa distingue nettamente il comportamento della baseline da quello dei modelli puramente sorgente.

Specializzazione target e retention. I modelli aggregati ibridi mostrano il limite complementare. Essi massimizzano la sensibilità sulle distribuzioni target e raggiungono TNR unitaria, ma perdono quasi completamente la capacità di riconoscere gli attacchi NB15. L'adattamento esteso al nuovo dominio non può quindi essere valutato soltanto rispetto alla prestazione ottenuta dopo il cambiamento.

Nel protocollo considerato, un aggiornamento efficace deve essere caratterizzato contemporaneamente rispetto alla nuova distribuzione, alla retention delle anomalie precedentemente apprese

e alla preservazione del traffico nominale. La cross-evaluation evidenzia precisamente tale distinzione, impedendo che la prestazione quasi perfetta sul target mascheri la perdita della conoscenza sorgente.

Compromesso tra falsi positivi e attacchi non rilevati. Le tre architetture della baseline producono inoltre profili differenti tra sensibilità e specificità. HGB raggiunge la TNR più elevata, 0.99658, ma una TPR target pari a 0.82970; RF associa una TNR pari a 0.99057 a una TPR target di 0.98821; DT raggiunge rispettivamente 0.98460 e 0.96612.

Non emerge pertanto un classificatore che domini simultaneamente ogni dimensione. Se il criterio di selezione è limitato alle prestazioni predittive globali e alla stabilità multi-seed, RF costituisce il riferimento più favorevole tra le configurazioni analizzate. Tale risultato non equivale tuttavia a una selezione definitiva per un sistema operativo, poiché il protocollo non misura il costo dell'esecuzione.

Diagnostica del domain shift e interpretabilità. PCA, KDE e SHAP forniscono inoltre strumenti complementari per caratterizzare variazioni del dominio. Le prime due tecniche evidenziano modificazioni geometriche e distributive dello spazio delle feature, mentre SHAP consente di verificare se tali condizioni siano accompagnate da una riorganizzazione delle caratteristiche maggiormente utilizzate dal modello.

Nel presente lavoro tali tecniche svolgono esclusivamente una funzione diagnostica. Non è definita una soglia automatica di *drift detection* e non viene implementato un meccanismo autonomo di aggiornamento o riaddestramento. Analogamente, SHAP permette di identificare la diversa struttura decisionale dei paradigmi, ma non risolve causalmente il confondimento tra classe e dominio presente nei benchmark ibridi.

Limite della componente nominale condivisa. Un limite sperimentale rilevante riguarda la distribuzione del traffico nominale. Nei differenti benchmark di valutazione la componente benign proviene sempre dal dominio sorgente NB15; la variazione cross-domain riguarda quindi la componente malevola.

Le TNR elevate osservate dimostrano pertanto la preservazione della classificazione sul traffico nominale effettivamente incluso nel protocollo, ma non permettono di concludere che la specificità

rimarrebbe invariata in presenza di un differente dominio benigno. Il presente esperimento non valuta quindi un *benign-domain shift*.

Soglia decisionale. La pipeline utilizza inoltre le predizioni dei classificatori senza una calibrazione personalizzata della soglia decisionale per i differenti benchmark. Le metriche riportate descrivono quindi la configurazione effettivamente implementata e non il risultato di un’ottimizzazione successiva del compromesso tra falsi positivi e falsi negativi.

Le curve Precision–Recall e le diagnostiche di soglia generate dal framework non vengono utilizzate nel presente capitolo per selezionare una soglia operativa ottimale; nessuna conclusione in tal senso viene pertanto derivata dai risultati.

Sintesi delle implicazioni operative. La Tabella 5.12 riassume le principali implicazioni direttamente supportate dal protocollo sperimentale.

Tabella 5.12: Sintesi delle implicazioni operative dei tre paradigmi di addestramento nell’ambito del protocollo NIDS considerato.

Paradigma	Evidenza favorevole	Criticità osservata	Implicazione operativa
$\mathcal{M}_S$	Conservazione della sensibilità sul dominio sorgente e TNR elevata.	Forte riduzione della TPR sulle distribuzioni target.	La sola validazione in-domain non è sufficiente a caratterizzare la robustezza cross-domain.
$\mathcal{M}_{base}$	Conservazione della TPR sorgente accompagnata da un forte incremento della sensibilità target mediante conoscenza target sparsa.	Prestazioni target inferiori agli aggregati ibridi e dipendenti dall’architettura utilizzata.	Configurazione più uniforme per la copertura simultanea di distribuzioni sorgente e target nell’insieme sperimentale considerato.
$\mathcal{M}_H$	TPR target prossime all’unità e TNR pari a 1.0000 nei modelli aggregati.	Perdita quasi completa della sensibilità verso gli attacchi sorgente.	L’adattamento esteso al nuovo dominio deve essere valutato anche rispetto alla retention delle conoscenze precedentemente apprese.

Nel complesso, i risultati mostrano che la robustezza cross-domain non può essere valutata esclusivamente mediante la massima prestazione ottenuta su un singolo dominio. Nel perimetro sperimentale analizzato, il criterio più discriminante è la capacità di acquisire informazione sul target preservando contemporaneamente la conoscenza sorgente e la corretta classificazione del traffico nominale.

Sotto tale criterio, INJECTION realizza il compromesso più uniforme tra i tre paradigmi considerati. All'interno della baseline, RF presenta il profilo predittivo globale più favorevole, mentre l'assenza di misure computazionali e di una variazione del dominio nominale impedisce di estendere tale risultato a una selezione definitiva per un deployment satellitare. Le evidenze raccolte costituiscono pertanto la sintesi interpretativa della campagna sperimentale e preparano la conclusione del capitolo.

5.6 Sintesi e Conclusioni del Capitolo

Il presente capitolo ha completato la validazione sperimentale del framework attraverso una lettura congiunta delle proprietà distributive dei benchmark, delle prestazioni predittive, della stabilità multi-seed e delle caratteristiche maggiormente coinvolte nelle funzioni decisionali dei classificatori.

La diagnostica mediante PCA e KDE ha mostrato che il passaggio dal dominio sorgente NB15 alle distribuzioni target non corrisponde a una perturbazione uniforme dello spazio delle feature. Le variabili analizzate presentano infatti scostamenti differenti per scala, posizione e dispersione, confermando la presenza di un *domain shift* rilevante tra le componenti malevole sorgente e target. Tale evidenza costituisce il contesto distributivo entro il quale devono essere interpretate le prestazioni dei modelli, senza attribuire a una singola feature un ruolo causale nel comportamento osservato.

Il confronto tra i tre paradigmi di addestramento ha evidenziato regimi di generalizzazione distinti. I modelli puramente sorgente $\mathcal{M}_S$ mantengono una capacità discriminativa significativa sui benchmark NB15 e una TNR elevata, ma presentano una marcata perdita di sensibilità sulle distribuzioni malevole target. I modelli ibridi $\mathcal{M}_H$ raggiungono invece TPR target prossime all'unità e, nelle configurazioni aggregate, TNR pari a 1.0000, ma perdono quasi completamente la capacità

di riconoscere gli attacchi sorgente. La massima specializzazione sul nuovo dominio non coincide pertanto, nel protocollo considerato, con la migliore generalizzazione complessiva.

Tra tali estremi si colloca la baseline $\mathcal{M}_{\text{base}}$, addestrata mediante INJECTION. La sostituzione di 29 dei 9 300 campioni malevoli con osservazioni target, pari a circa lo 0.31% della classe positiva di training, risulta associata a un marcato incremento della sensibilità cross-domain senza una perdita sostanziale della sensibilità sorgente. La TPR media sui benchmark target raggiunge 0.96612 per DT, 0.82970 per HGB e 0.98821 per RF, mentre il comportamento sui benchmark NB15 rimane sostanzialmente sovrapposto a quello dei corrispondenti modelli sorgente.

La medesima distinzione emerge considerando l'intera matrice di *cross-evaluation*. La baseline raggiunge la maggiore TPR media sui 16 benchmark per tutte le architetture, pari a 0.88990 per DT, 0.80246 per HGB e 0.90071 per RF. Anche la sintesi multi-seed mediante F1-Score conferma tale comportamento, con valori globali rispettivamente pari a 0.860388, 0.854074 e 0.890221. Il vantaggio della configurazione INJECTION deve quindi essere interpretato come maggiore uniformità tra conservazione della conoscenza sorgente e riconoscimento delle distribuzioni target, e non come massimizzazione della prestazione su ogni singolo benchmark.

L'analisi inferenziale ha qualificato ulteriormente tale risultato. Tutti i 18 confronti di Welch tra la baseline e i modelli sorgente e tutti i 27 confronti con le configurazioni ibride risultano significativi secondo il criterio $p < 0.05$ adottato dal protocollo. Il test è applicato alla media dell'F1-Score sui 16 benchmark per ciascun seed; gli esiti caratterizzano pertanto una differenza globale tra le distribuzioni delle prestazioni multi-seed e non implicano una superiorità della baseline su ciascun test individuale. Secondo il test adottato, tali distribuzioni non risultano compatibili con l'ipotesi nulla di uguaglianza delle medie, tenuto conto della variabilità inter-seed osservata. I risultati mantengono inoltre il carattere esplorativo previsto dalla metodologia, poiché non è stata applicata una correzione per confronti multipli.

Le analisi SHAP hanno mostrato che i differenti regimi prestazionali sono accompagnati da differenti organizzazioni della funzione decisionale. Nei modelli sorgente e nella baseline, `pkts_per_sec` occupa la prima posizione di rilevanza globale per DT, HGB e RF; la baseline preserva quindi una struttura informativa largamente sovrapposta a quella sorgente, pur modificando l'ordinamento delle caratteristiche secondarie. Nel modello aggregato ibrido NB15_STIN, invece, `dst_win_byt` e `src_win_byt` assumono rispettivamente la prima e la seconda posizione in tutte le

architetture. La maggiore specializzazione target risulta pertanto associata anche a una sostanziale riorganizzazione delle feature utilizzate dal classificatore. Le corrispondenze tra diagnostica distribuita, SHAP e comportamento prestazionale devono tuttavia essere interpretate come associazioni empiriche e non come relazioni causali dimostrate.

Il confronto tra le architetture ha infine mostrato che DT, HGB e RF modulano diversamente il compromesso tra sensibilità, specificità e stabilità, senza annullare l'effetto della composizione del training set. Nella baseline, RF presenta il profilo predittivo globale più favorevole, associando la maggiore sensibilità target, la maggiore TPR globale, il maggiore F1-Score medio multi-seed e la minore dispersione di quest'ultimo tra le tre architetture. HGB privilegia maggiormente la specificità, raggiungendo la TNR più elevata a fronte di una sensibilità target inferiore, mentre DT mantiene prestazioni competitive mediante una struttura algoritmica qualitativamente meno articolata.

Tale confronto rimane circoscritto alle grandezze effettivamente misurate. La campagna sperimentale non comprende misure di latenza di inferenza, occupazione di memoria, dimensione dei modelli, utilizzo delle risorse o consumo energetico; non è quindi possibile derivare un ordinamento quantitativo dei classificatori rispetto al costo computazionale né identificare una configurazione definitivamente idonea a un deployment satellitare. Analogamente, la componente nominale dei benchmark rimane sempre derivata da NB15 e non viene quindi valutato un *domain shift* del traffico benigno.

Nel complesso, i risultati mostrano che la robustezza cross-domain non può essere valutata né attraverso la sola prestazione in-domain né mediante la massimizzazione della sensibilità sul nuovo dominio. Nel perimetro sperimentale analizzato, il criterio discriminante è rappresentato dalla capacità di acquisire informazione sul target preservando contemporaneamente la conoscenza precedentemente appresa e la corretta classificazione del traffico nominale. Sotto tale criterio, la configurazione INJECTION realizza il compromesso più uniforme tra i tre paradigmi considerati.

Con la presente sezione si conclude l'analisi sperimentale del framework. Le evidenze quantitative, statistiche e interpretative ottenute costituiscono la base empirica per le conclusioni complessive della tesi, nelle quali il contributo del lavoro verrà ricondotto agli obiettivi definiti nei capitoli precedenti e distinto dai limiti e dalle possibili estensioni del protocollo sperimentale.

A. Risultati Numerici Completi

La presente appendice raccoglie i risultati numerici completi associati alle analisi sperimentali sviluppate nel Capitolo 5. Le tabelle riportate nel seguito costituiscono il dettaglio integrale delle matrici di valutazione e delle analisi statistiche richiamate nel corpo principale della trattazione, dove sono mantenuti i risultati necessari all’interpretazione e al confronto tra i differenti paradigmi sperimentali.

A.1 Risultati Completi della Baseline INJECTION

Tabella A.1: Cardinalità complete delle matrici di confusione della baseline INJECTION con DT, HGB e RF sui 16 test set per il seed $s = 42$.

Test Set	DT				HGB				RF			
	TP	TN	FP	FN	TP	TN	FP	FN	TP	TN	FP	FN
nb15 (aggregato)	1539	18305	295	321	1482	18540	60	378	1530	18422	178	330
nb15 (DoS)	1693	18305	295	167	1648	18540	60	212	1705	18422	178	155
nb15 (Exploits)	1567	18305	295	293	1522	18540	60	338	1598	18422	178	262
nb15 (Fuzzers)	525	18305	295	1335	338	18540	60	1522	450	18422	178	1410
nb15 (Generic)	1843	18305	295	17	1843	18540	60	17	1843	18422	178	17
nb15 (Reconnaissance)	1619	18305	295	241	1642	18540	60	218	1596	18422	178	264
injection (aggregato)	1535	18305	295	325	1506	18540	60	354	1531	18422	178	329
nb15_stin (aggregato)	1790	18305	295	70	1405	18540	60	455	1851	18422	178	9
nb15_sat20 (aggregato)	1841	18305	295	19	1589	18540	60	271	1859	18422	178	1
nb15_sat20 (Syn_DDoS)	1825	18305	295	35	1512	18540	60	348	1860	18422	178	0
nb15_sat20 (UDP_DDoS)	1859	18305	295	1	1672	18540	60	188	1859	18422	178	1
nb15_ter20 (aggregato)	1752	18305	295	108	1295	18540	60	565	1842	18422	178	18
nb15_ter20 (Botnet)	1636	18305	295	224	1498	18540	60	362	1857	18422	178	3
nb15_ter20 (DDoS)	1860	18305	295	0	1539	18540	60	321	1860	18422	178	0
nb15_ter20 (Syn_DDoS)	1794	18305	295	66	0	18540	60	1860	1731	18422	178	129
nb15_ter20 (UDP_DDoS)	1664	18305	295	196	1286	18540	60	574	1860	18422	178	0

Tabella A.2: F1-Score e PR-AUC completi della baseline INJECTION con DT, HGB e RF sui 16 test set per il seed $s = 42$.

Test Set	DT		HGB		RF	
	F1-Score	PR-AUC	F1-Score	PR-AUC	F1-Score	PR-AUC
nb15 (aggregato)	0.8332	0.7120	0.8713	0.9263	0.8576	0.9095
nb15 (DoS)	0.8799	0.7548	0.9238	0.9648	0.9110	0.9602
nb15 (Exploits)	0.8420	0.7102	0.8844	0.9469	0.8790	0.9342
nb15 (Fuzzers)	0.3918	0.2890	0.2994	0.5824	0.3617	0.5099
nb15 (Generic)	0.9220	0.8571	0.9795	0.9968	0.9498	0.9932
nb15 (Reconnaissance)	0.8580	0.7053	0.9220	0.9659	0.8784	0.9461
injection (aggregato)	0.8320	0.7104	0.8792	0.9342	0.8579	0.9154
nb15_stin (aggregato)	0.9075	0.8316	0.8451	0.9191	0.9519	0.9802
nb15_sat20 (aggregato)	0.9214	0.8560	0.9057	0.9579	0.9541	0.9873
nb15_sat20 (Syn_DDoS)	0.9171	0.8484	0.8811	0.9682	0.9543	0.9902
nb15_sat20 (UDP_DDoS)	0.9263	0.8646	0.9310	0.9604	0.9541	0.9898
nb15_ter20 (aggregato)	0.8969	0.8134	0.8056	0.8922	0.9495	0.9746
nb15_ter20 (Botnet)	0.8631	0.7581	0.8765	0.9464	0.9535	0.9675
nb15_ter20 (DDoS)	0.9265	0.8651	0.8899	0.9379	0.9543	0.9834
nb15_ter20 (Syn_DDoS)	0.9086	0.8339	0.0000	0.5501	0.9185	0.9660
nb15_ter20 (UDP_DDoS)	0.8714	0.7714	0.8022	0.9499	0.9543	0.9859

A.2 Risultati Completi dei Modelli Sorgente

Tabella A.3: TPR media sui 10 seed dei modelli sorgente valutati sui benchmark sorgente e sul test set INJECTION.

Modello	Aggr. NB15	DoS	Exploits	Fuzzers	Generic	Recon.	INJECTION
DT							
Aggregato	0.8215	0.9073	0.8432	0.2851	0.9916	0.8737	0.8274
DoS	0.5908	0.9306	0.7211	0.1725	0.6300	0.2015	0.5847
Exploits	0.3942	0.9261	0.8927	0.1903	0.0220	0.2504	0.4167
Fuzzers	0.3197	0.7847	0.4175	0.4794	0.0805	0.1906	0.3201
Generic	0.6042	0.7359	0.4273	0.1213	0.9867	0.1421	0.5972
Reconnaissance	0.6592	0.7911	0.4459	0.1450	0.9444	0.9386	0.6627
HGB							
Aggregato	0.8018	0.8941	0.8173	0.1775	0.9900	0.8797	0.8039
DoS	0.7029	0.9131	0.7357	0.1391	0.9648	0.1933	0.7048
Exploits	0.4278	0.9099	0.8714	0.1629	0.1310	0.2248	0.4442
Fuzzers	0.2524	0.7605	0.3610	0.3517	0.0089	0.1470	0.2520
Generic	0.5454	0.5847	0.3317	0.0913	0.9879	0.1095	0.5426
Reconnaissance	0.6724	0.7794	0.4054	0.1375	0.9785	0.9465	0.6671
RF							
Aggregato	0.8236	0.9261	0.8619	0.2337	0.9915	0.8629	0.8272
DoS	0.7164	0.9320	0.7305	0.1487	0.9874	0.2039	0.7202
Exploits	0.3991	0.9282	0.9047	0.1750	0.0224	0.2386	0.4147
Fuzzers	0.3007	0.7704	0.3906	0.4739	0.0459	0.1669	0.2950
Generic	0.5792	0.7169	0.3621	0.1159	0.9870	0.1373	0.5694
Reconnaissance	0.6602	0.7832	0.4235	0.1410	0.9580	0.9406	0.6621

Tabella A.4: TPR media sui 10 seed dei modelli sorgente valutati sui benchmark target aggregati e biclasse.

Modello	STIN	SAT20	TER20	SAT Syn	SAT UDP	Botnet	DDoS	TER Syn	TER UDP
DT									
Aggregato	0.3807	0.1947	0.5294	0.0725	0.2917	0.6726	0.6669	0.0484	0.0538
DoS	0.4824	0.8149	0.2537	0.9528	0.6946	0.1320	0.0848	0.6024	0.8877
Exploits	0.2033	0.2978	0.1455	0.0715	0.4973	0.3573	0.0673	0.0284	0.0406
Fuzzers	0.4181	0.3712	0.4698	0.0178	0.6797	0.8898	0.4467	0.0092	0.0191
Generic	0.1267	0.3068	0.0141	0.0485	0.5289	0.0057	0.0118	0.0039	0.0459
Reconnaissance	0.0501	0.0044	0.0812	0.0000	0.0063	0.0988	0.0079	0.3774	0.0000
HGB									
Aggregato	0.0662	0.1055	0.0438	0.0000	0.2020	0.0906	0.0378	0.0000	0.0000
DoS	0.1380	0.1540	0.1436	0.0000	0.2921	0.2309	0.1578	0.0000	0.0000
Exploits	0.0428	0.0287	0.0547	0.0000	0.0527	0.1013	0.0536	0.0000	0.0000
Fuzzers	0.2781	0.2157	0.3301	0.0000	0.4071	0.6226	0.3009	0.0000	0.0000
Generic	0.1137	0.2625	0.0204	0.0000	0.5016	0.0703	0.0006	0.0000	0.0000
Reconnaissance	0.0005	0.0002	0.0000	0.0000	0.0001	0.0001	0.0001	0.0000	0.0000
RF									
Aggregato	0.3601	0.2613	0.4564	0.0000	0.4929	0.5570	0.6036	0.0000	0.0000
DoS	0.3558	0.6878	0.1296	0.5753	0.8007	0.1061	0.0594	0.1293	0.5109
Exploits	0.1594	0.3199	0.0522	0.0000	0.6077	0.1314	0.0355	0.0000	0.0000
Fuzzers	0.5040	0.4818	0.5338	0.0000	0.9023	0.9191	0.5841	0.0000	0.0000
Generic	0.1089	0.2572	0.0139	0.0000	0.4856	0.0448	0.0054	0.0000	0.0000
Reconnaissance	0.0050	0.0156	0.0000	0.0000	0.0200	0.0029	0.0001	0.0000	0.0000

Tabella A.5: Media e varianza della TNR sui 10 seed per i modelli sorgente. Il valore è indipendente dal test set malevolo poiché la componente nominale rimane invariata all'interno del protocollo sperimentale.

Modello	DT		HGB		RF	
	$\overline{TNR}$	$\text{Var}(TNR)$	$\overline{TNR}$	$\text{Var}(TNR)$	$\overline{TNR}$	$\text{Var}(TNR)$
Aggregato	0.98317	1.51×10^{-7}	0.99659	2.32×10^{-8}	0.99150	6.00×10^{-8}
DoS	0.99362	5.51×10^{-8}	0.99776	5.38×10^{-8}	0.99672	8.44×10^{-9}
Exploits	0.99049	4.99×10^{-8}	0.99588	7.07×10^{-8}	0.99413	2.46×10^{-8}
Fuzzers	0.96248	1.77×10^{-7}	0.98900	2.38×10^{-7}	0.96847	8.01×10^{-8}
Generic	0.99950	2.22×10^{-9}	0.99960	8.89×10^{-9}	0.99964	2.67×10^{-9}
Reconnaissance	0.99521	1.21×10^{-8}	0.99555	7.17×10^{-8}	0.99608	1.51×10^{-8}

Tabella A.6: Media e varianza della TPR sui benchmark target aggregati per il modello sorgente aggregato e la baseline.

Test Set	Modello sorgente		Baseline INJECTION	
	$\overline{TPR}$	$\text{Var}(TPR)$	$\overline{TPR}$	$\text{Var}(TPR)$
DT				
nb15_stin	0.38071	7.74×10^{-3}	0.97282	1.24×10^{-4}
nb15_sat20	0.19473	1.87×10^{-2}	0.98630	2.15×10^{-5}
nb15_ter20	0.52940	3.61×10^{-3}	0.96182	4.07×10^{-4}
HGB				
nb15_stin	0.06624	5.25×10^{-3}	0.84945	8.17×10^{-3}
nb15_sat20	0.10553	7.18×10^{-3}	0.90956	8.31×10^{-3}
nb15_ter20	0.04378	8.58×10^{-3}	0.81505	9.90×10^{-3}
RF				
nb15_stin	0.36006	1.81×10^{-4}	0.99253	9.12×10^{-5}
nb15_sat20	0.26130	7.19×10^{-4}	0.99954	9.38×10^{-8}
nb15_ter20	0.45636	5.01×10^{-5}	0.98600	2.28×10^{-4}

Tabella A.7: Vantaggio TPR della baseline rispetto al migliore modello sorgente disponibile su ciascun benchmark target.

Test Set Target	ΔTPR_{DT}^{best}	ΔTPR_{HGB}^{best}	ΔTPR_{RF}^{best}
nb15_stin (aggregato)	+0.49045	+0.57134	+0.48851
nb15_sat20 (aggregato)	+0.17140	+0.64707	+0.31176
nb15_ter20 (aggregato)	+0.43242	+0.48495	+0.45224
nb15_sat20 (Syn_DDoS)	+0.02042	+0.92871	+0.42382
nb15_sat20 (UDP_DDoS)	+0.30487	+0.39284	+0.09739
nb15_ter20 (Botnet)	+0.04918	+0.24576	+0.06542
nb15_ter20 (DDoS)	+0.33281	+0.57548	+0.39645
nb15_ter20 (Syn_DDoS)	+0.36490	+0.49886	+0.81039
nb15_ter20 (UDP_DDoS)	+0.00767	+0.82656	+0.48200

A.3 Risultati Completi dei Modelli Ibridi

Tabella A.8: TPR e F1-Score dei modelli ibridi sui rispettivi test set target omologhi per il seed $s = 42$.

Modello / Test Set	DT		HGB		RF	
	TPR	F1	TPR	F1	TPR	F1
nb15_stin (aggregato)	0.9995	0.9997	0.9995	0.9997	0.9995	0.9997
nb15_sat20 (aggregato)	0.9995	0.9997	0.9995	0.9997	0.9995	0.9997
nb15_ter20 (aggregato)	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
nb15_sat20 (Syn_DDoS)	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
nb15_sat20 (UDP_DDoS)	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
nb15_ter20 (Botnet)	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
nb15_ter20 (DDoS)	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
nb15_ter20 (Syn_DDoS)	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
nb15_ter20 (UDP_DDoS)	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000

Tabella A.9: TPR media multi-seed dei modelli ibridi sui benchmark sorgente, INJECTION e target. Le colonne NB15 e Target rappresentano rispettivamente la media sui sei e sui nove test set dei corrispondenti gruppi.

Modello	DT			HGB			RF		
	NB15	INJ.	Target	NB15	INJ.	Target	NB15	INJ.	Target
nb15_stin_aggregate	0.000000	0.00320	0.999922	0.000000	0.00320	0.999944	0.000000	0.00320	0.999922
nb15_sat20_aggregate	0.000000	0.00320	0.999889	0.000000	0.00320	0.981796	0.000000	0.00320	0.999894
nb15_ter20_aggregate	0.000000	0.00320	0.999922	0.000000	0.00320	0.999944	0.000000	0.00320	0.999906
nb15_sat20_syn_ddos	0.000000	0.00050	0.424387	0.000000	0.00050	0.315589	0.000000	0.00050	0.443831
nb15_sat20_udp_ddos	0.000000	0.00320	0.974900	0.000000	0.00270	0.551311	0.000000	0.00320	0.898881
nb15_ter20_botnet	0.000000	0.00320	0.952424	0.000000	0.00310	0.842102	0.000000	0.00320	0.910777
nb15_ter20_ddos	0.000000	0.00310	0.829924	0.000000	0.00270	0.551311	0.000000	0.00285	0.664007
nb15_ter20_syn_ddos	0.000000	0.00320	0.999928	0.000025	0.00196	0.629574	0.000000	0.00320	0.999910
nb15_ter20_udp_ddos	0.000000	0.00320	0.978669	0.000000	0.00050	0.350036	0.000000	0.00050	0.448567

A.4 Risultati Completi dei Test Statistici

A.4.1 Modelli Sorgente rispetto alla Baseline INJECTION

Tabella A.10: Media e deviazione standard campionaria dei valori $\overline{F1}_i^{(k)}$ sui 10 seed per la baseline e i modelli sorgente. $\Delta F1$ è calcolato come baseline meno modello sorgente.

Modello	DT			HGB			RF		
	$\overline{F1}$	s	$\Delta F1$	$\overline{F1}$	s	$\Delta F1$	$\overline{F1}$	s	$\Delta F1$
injection_aggregate	0.86039	0.00352	–	0.85407	0.03634	–	0.89022	0.00245	–
nb15_aggregate	0.56308	0.04017	+0.29731	0.41231	0.05289	+0.44177	0.57651	0.00647	+0.31371
nb15_dos	0.63163	0.01413	+0.22876	0.41671	0.05056	+0.43737	0.57207	0.05750	+0.31815
nb15_exploits	0.37742	0.01922	+0.48297	0.27167	0.03931	+0.58240	0.34199	0.02338	+0.54823
nb15_fuzzers	0.38778	0.02178	+0.47261	0.35018	0.02762	+0.50390	0.41666	0.01181	+0.47356
nb15_generic	0.37596	0.01366	+0.48443	0.33977	0.01613	+0.51430	0.35185	0.01199	+0.53837
nb15_reconnaissance	0.38165	0.00983	+0.47874	0.32058	0.00053	+0.53349	0.32659	0.00129	+0.56364

Tabella A.11: Risultati del test t di Welch tra injection_aggregate e i modelli sorgente, con $\alpha = 0,05$.

Modello confrontato	DT			HGB			RF		
	t	p	Sign.	t	p	Sign.	t	p	Sign.
nb15_aggregate	23.3150	1.8720×10^{-9}	Sì	21.7698	2.7489×10^{-13}	Sì	143.4423	4.0594×10^{-20}	Sì
nb15_dos	49.6699	2.0529×10^{-13}	Sì	22.2139	1.2228×10^{-13}	Sì	17.4802	2.8399×10^{-8}	Sì
nb15_exploits	78.1496	8.6609×10^{-15}	Sì	34.4010	8.5047×10^{-18}	Sì	73.7488	4.5473×10^{-14}	Sì
nb15_fuzzers	67.7344	4.8440×10^{-14}	Sì	34.9112	4.0724×10^{-17}	Sì	124.1469	5.8434×10^{-17}	Sì
nb15_generic	108.6316	6.0030×10^{-17}	Sì	40.9031	1.2819×10^{-14}	Sì	139.1262	2.0720×10^{-17}	Sì
nb15_reconnaissance	144.9748	8.7646×10^{-20}	Sì	46.4184	4.9595×10^{-12}	Sì	643.0892	5.6491×10^{-32}	Sì

A.4.2 Modelli Ibridi rispetto alla Baseline INJECTION

Tabella A.12: Media e deviazione standard campionaria dei valori medi di F1-Score sui 10 seed per la baseline e i modelli ibridi. $\Delta F1$ è calcolato come baseline meno modello ibrido.

Modello	DT			HGB			RF		
	$\overline{F1}$	s	$\Delta F1$	$\overline{F1}$	s	$\Delta F1$	$\overline{F1}$	s	$\Delta F1$
injection_aggregate	0.860388	0.003516	–	0.854074	0.036341	–	0.890221	0.002452	–
nb15_sat20_aggregate	0.562863	0.000000	+0.297526	0.556714	0.009015	+0.297360	0.562864	0.000006	+0.327357
nb15_sat20_syn_ddos	0.272674	0.010401	+0.587714	0.203331	0.000000	+0.650743	0.280766	0.001831	+0.609456
nb15_sat20_udp_ddos	0.554609	0.011598	+0.305779	0.335325	0.000000	+0.518749	0.529931	0.000483	+0.360290
nb15_stin_aggregate	0.562874	0.000010	+0.297514	0.562881	0.000000	+0.291193	0.562874	0.000010	+0.327348
nb15_ter20_aggregate	0.562874	0.000010	+0.297514	0.562881	0.000000	+0.291193	0.562868	0.000009	+0.327353
nb15_ter20_botnet	0.547373	0.015805	+0.313016	0.496752	0.078046	+0.357322	0.533624	0.005028	+0.356598
nb15_ter20_ddos	0.491250	0.082180	+0.369138	0.335325	0.000000	+0.518749	0.401911	0.085435	+0.488310
nb15_ter20_syn_ddos	0.562876	0.000009	+0.297513	0.408438	0.018932	+0.445636	0.562871	0.000022	+0.327351
nb15_ter20_udp_ddos	0.555778	0.008641	+0.304611	0.230466	0.023354	+0.623608	0.282475	0.000000	+0.607746

Bibliografia

- [1] Sajid Alam e Wang-Cheol Song. «Intent-Based Network Resource Orchestration in Space-Air-Ground Integrated Networks: A Graph Neural Networks and Deep Reinforcement Learning Approach». In: *IEEE Access* 12 (2024), pp. 185057–185077. DOI: 10.1109/ACCESS.2024.3507829. URL: <https://ieeexplore.ieee.org/document/10770209>.
- [2] Ahmad Taher Azar et al. «Deep Learning Based Hybrid Intrusion Detection Systems to Protect Satellite Networks». In: *Journal of Network and Systems Management* 31.4 (2023), p. 82. ISSN: 1573-7705. DOI: 10.1007/s10922-023-09767-8. URL: <https://link.springer.com/article/10.1007/s10922-023-09767-8>.
- [3] Leo Breiman. «Random Forests». In: *Machine Learning* 45.1 (2001), pp. 5–32. ISSN: 1573-0565. DOI: 10.1023/A:1010933404324. URL: <https://link.springer.com/article/10.1023/A:1010933404324#citeas>.
- [4] Leo Breiman et al. *Classification and Regression Trees*. Belmont, CA: Wadsworth International Group, 1984. ISBN: 978-0534980535.
- [5] Tianqi Chen e Carlos Guestrin. «XGBoost: A Scalable Tree Boosting System». In: *CoRR* abs/1603.02754 (2016). DOI: 10.1145/2939672.2939785. URL: <http://arxiv.org/abs/1603.02754>.
- [6] Hal Daumé III. «Frustratingly Easy Domain Adaptation». In: *CoRR* abs/0907.1815 (2009). DOI: 10.48550/arXiv.0907.1815. URL: <https://arxiv.org/abs/0907.1815>.
- [7] Janez Demšar. «Statistical Comparisons of Classifiers over Multiple Data Sets». In: *Journal of Machine Learning Research* 7 (2006), pp. 1–30. DOI: 10.5555/1248547.1248548. URL: https://www.researchgate.net/publication/220320196_Statistical_Comparisons_of_Classifiers_over_Multiple_Data_Sets.
- [8] Abolfazl Farahani et al. «A Brief Review of Domain Adaptation». In: *Advances in Data Science and Information Engineering*. Springer, 2021, pp. 877–894. DOI: 10.1007/978-3-030-71704-9_59. URL: <https://arxiv.org/abs/2010.03978>.

- [9] Tom Fawcett. «An introduction to ROC analysis». In: *Pattern Recognition Letters* 27.8 (2006), pp. 861–874. DOI: 10.1016/j.patrec.2005.10.010. URL: https://www.researchgate.net/publication/222511520_Introduction_to_ROC_analysis.
- [10] Jerome H. Friedman. «Greedy Function Approximation: A Gradient Boosting Machine». In: *The Annals of Statistics* 29.5 (2001), pp. 1189–1232. DOI: 10.1214/aos/1013203451. URL: <https://projecteuclid.org/journals/annals-of-statistics/volume-29/issue-5/Greedy-function-approximation-A-gradient-boosting-machine/10.1214/aos/1013203451.full>.
- [11] Trevor Hastie, Robert Tibshirani e Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2nd. Springer, 2009. ISBN: 978-0387848570.
- [12] Hanan Hindy et al. «A Taxonomy of Network Threats and the Effect of Current Datasets on Intrusion Detection Systems». In: *IEEE Access* 8 (2020), pp. 104650–104675. ISSN: 2169-3536. DOI: 10.1109/access.2020.3000179. URL: <https://ieeexplore.ieee.org/document/9108270>.
- [13] Harold Hotelling. «Analysis of a Complex of Statistical Variables into Principal Components». In: *Journal of Educational Psychology* 24.6 (1933), pp. 417–441. DOI: 10.1037/h0071325. URL: <https://psycnet.apa.org/record/1934-00645-001>.
- [14] Guolin Ke et al. «LightGBM: a highly efficient gradient boosting decision tree». In: *Proceedings of the 31st International Conference on Neural Information Processing Systems*. Curran Associates Inc., 2017, pp. 3149–3157. DOI: 10.5555/3294996.3295074. URL: <https://dl.acm.org/doi/10.5555/3294996.3295074>.
- [15] Ansam Khraisat et al. «Survey of intrusion detection systems: techniques, datasets and challenges». In: *Cybersecurity* 2.1 (2019), p. 20. ISSN: 2523-3246. DOI: 10.1186/s42400-019-0038-7. URL: <https://link.springer.com/article/10.1186/s42400-019-0038-7>.
- [16] Ilhan Firat Kilincer, Fatih Ertam e Abdulkadir Sengur. «Machine learning methods for cyber security intrusion detection: Datasets and comparative study». In: *Computer Networks* 188 (2021), p. 107840. ISSN: 1389-1286. DOI: 10.1016/j.comnet.2021.107840. URL: <https://www.sciencedirect.com/science/article/pii/S1389128621000141?via%3Dihub>.

- [17] Oltjon Kodheli et al. «Satellite Communications in the New Space Era: A Survey and Future Challenges». In: *IEEE Communications Surveys & Tutorials* 23.1 (2021), pp. 70–109. DOI: 10.1109/COMST.2020.3028247. URL: <https://ieeexplore.ieee.org/document/9210567>.
- [18] Kun Li et al. «Distributed Network Intrusion Detection System in Satellite-Terrestrial Integrated Networks Using Federated Learning». In: *IEEE Access* 8 (2020), pp. 214852–214865. DOI: 10.1109/ACCESS.2020.3041641. URL: <https://ieeexplore.ieee.org/document/9274426>.
- [19] Suzanne Lightman, Theresa Suloway e Joseph Brule. *Satellite Ground Segment: Applying the Cybersecurity Framework to Satellite Command and Control*. NIST Interagency Report NIST IR 8401. National Institute of Standards e Technology, 2022. DOI: 10.6028/NIST.IR.8401. URL: <https://nvlpubs.nist.gov/nistpubs/ir/2022/NIST.IR.8401.pdf>.
- [20] Scott M Lundberg e Su-In Lee. «A unified approach to interpreting model predictions». In: *CoRR* abs/1705.07874 (2017). DOI: 10.48550/arXiv.1705.07874. URL: <https://arxiv.org/abs/1705.07874>.
- [21] Scott M Lundberg et al. «Explainable AI for Trees: From Local Explanations to Global Understanding». In: *CoRR* abs/1905.04610 (2019). DOI: 10.48550/arXiv.1905.04610. URL: <https://arxiv.org/abs/1905.04610>.
- [22] Saeid Motiian et al. «Unified Deep Supervised Domain Adaptation and Generalization». In: *CoRR* abs/1709.10190 (2017). DOI: 10.48550/arXiv.1709.10190. URL: <https://arxiv.org/abs/1709.10190>.
- [23] Nour Moustafa e Jill Slay. «UNSW-NB15: a comprehensive data set for network intrusion detection systems (UNSW-NB15 network data set)». In: *2015 Military Communications and Information Systems Conference (MilCIS)*. IEEE, 2015, pp. 1–6. DOI: 10.1109/MilCIS.2015.7348942. URL: <https://ieeexplore.ieee.org/document/7348942>.

- [24] Sinno Jialin Pan e Qiang Yang. «A Survey on Transfer Learning». In: *IEEE Transactions on Knowledge and Data Engineering* 22.10 (2010), pp. 1345–1359. DOI: 10.1109/TKDE.2009.191. URL: <https://ieeexplore.ieee.org/document/5288526>.
- [25] Emanuel Parzen. «On Estimation of a Probability Density Function and Mode». In: *The Annals of Mathematical Statistics* 33.3 (1962), pp. 1065–1076. DOI: 10.1214/aoms/1177704472. URL: <https://projecteuclid.org/journals/annals-of-mathematical-statistics/volume-33/issue-3/On-Estimation-of-a-Probability-Density-Function-and-Mode/10.1214/aoms/1177704472.full>.
- [26] Karl Pearson. «LIII. On Lines and Planes of Closest Fit to Systems of Points in Space». In: *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*. Series 6 2.11 (1901), pp. 559–572. DOI: 10.1080/14786440109462720. URL: <https://www.tandfonline.com/doi/abs/10.1080/14786440109462720>.
- [27] Murray Rosenblatt. «Remarks on Some Nonparametric Estimates of a Density Function». In: *The Annals of Mathematical Statistics* 27.3 (1956), pp. 832–837. DOI: 10.1214/aoms/1177728190. URL: <https://projecteuclid.org/journals/annals-of-mathematical-statistics/volume-27/issue-3/Remarks-on-Some-Nonparametric-Estimates-of-a-Density-Function/10.1214/aoms/1177728190.full>.
- [28] Takaya Saito e Marc Rehmsmeier. «The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets». In: *PLOS ONE* 10.3 (2015), pp. 1–21. DOI: 10.1371/journal.pone.0118432. URL: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0118432>.
- [29] Lloyd S Shapley. «A value for n-person games». In: *Contributions to the Theory of Games* 2.28 (1953), pp. 307–317. DOI: 10.1515/9781400881970-018. URL: <https://www.scirp.org/reference/referencespapers?referenceid=2126587>.
- [30] Iman Sharafaldin, Arash Habibi Lashkari e Ali A. Ghorbani. «Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization». In: *Proceedings of the 4th International Conference on Information Systems Security and Privacy (ICISSP)*. SciTePress, 2018, pp. 108–116. DOI: 10.5220/0006639801080116. URL: <https://api.semanticscholar.org/CorpusID:4707749>.

- [31] Robin Sommer e Vern Paxson. «Outside the Closed World: On Using Machine Learning for Network Intrusion Detection». In: *Proceedings of the IEEE Symposium on Security and Privacy (S&P)*. 2010, pp. 305–316. DOI: 10.1109/SP.2010.25. URL: <https://ieeexplore.ieee.org/document/5504793>.
- [32] William Stallings. *Cryptography and Network Security: Principles and Practice*. 8th. Pearson, 2020. ISBN: 978-1-292-43748-4.
- [33] Andrew S. Tanenbaum, Nick Feamster e David Wetherall. *Computer Networks*. 6th. Pearson, 2021. ISBN: 978-1-292-37406-2.
- [34] Mahbod Tavallae et al. «A detailed analysis of the KDD CUP 99 data set». In: *2009 IEEE Symposium on Computational Intelligence for Security and Defense Applications*. IEEE, 2009, pp. 1–6. DOI: 10.1109/CISDA.2009.5356528. URL: <https://ieeexplore.ieee.org/document/5356528>.
- [35] Vladimir N. Vapnik. *Statistical Learning Theory*. New York: John Wiley & Sons, 1998. ISBN: 978-0-471-03003-4.
- [36] Mengke Wan et al. «A Federated Learning-Based Intrusion Detection System for Satellite-Terrestrial Integrated Networks». In: *ICASSP 2025 - 2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2025, pp. 1–5. DOI: 10.1109/ICASSP49660.2025.10890330. URL: <https://ieeexplore.ieee.org/document/10890330>.
- [37] B. L. Welch. «The Generalization of "Student's" Problem when Several Different Population Variances are Involved». In: *Biometrika* 34.1-2 (1947), pp. 28–35. DOI: 10.1093/biomet/34.1-2.28. URL: <https://academic.oup.com/biomet/article-abstract/34/1-2/28/210174?redirectedFrom=fulltext#no-access-message>.
- [38] Garrett Wilson e Diane J. Cook. «A Survey of Unsupervised Deep Domain Adaptation». In: *ACM Transactions on Intelligent Systems and Technology* 11.5 (2020), pp. 1–46. DOI: 10.1145/3400066. URL: <https://arxiv.org/abs/1812.02849>.