



UNIMORE
UNIVERSITÀ DEGLI STUDI DI
MODENA E REGGIO EMILIA

UNIVERSITÀ DEGLI STUDI DI MODENA E REGGIO EMILIA

Dipartimento di Ingegneria "Enzo Ferrari"

Corso di Laurea Triennale in Ingegneria Informatica (L-08)

<Titolo dell'Elaborato>

Tutor:

Prof. Mirco Marchetti

Candidato:

Alessandro Marchesini

Matricola 187179

ANNO ACCADEMICO 2025/2026

<Dedica, opzionale. Cancella tutto in questa pagina per saltarla>

Indice

1	Introduzione	1
1.1	Contesto generale	1
1.2	Obiettivo dell'Elaborato	1
2	Contesto di Riferimento e Stato dell'Arte	2
2.1	Telecomunicazioni terrestri e satellitari	2
2.2	Intrusion Detection Systems in Machine Learning	5
2.3	Adattamento di Dominio e Scarsità dei Dati	9
2.4	Sintesi e Posizionamento del Lavoro	10
3	Elementi Base	11
3.1	Sezione nel Secondo Capitolo	11
3.2	Un'Altra Sezione nel Secondo Capitolo	12
3.3	Formule Matematiche	13
3.4	Esempio di Algoritmo	13
3.5	Esempi di Codice	14
3.6	Gestione della Bibliografia	15
4	Tabelle e Immagini	16
4.1	Griglia 1x3	16
4.2	Griglia 2x2	16
4.3	Esempio di Tabella Complessa	17
5	Conclusioni	19
	Ringraziamenti	20
	Riferimenti	21

Elenco delle Figure

3.1	L'architettura introdotta da Vaswani nel famoso Paper " <i>Attention is All You Need</i> " [23].	12
4.1	Foto di frutta fresca in griglia 1x3.	16
4.2	Foto di frutta fresca in griglia 2x2.	17

Elenco dei Codici

3.1 Codice di esempio, tratto da helloworldspam.py 14

1. Introduzione

1.1 Contesto generale

1.2 Obiettivo dell'Elaborato

2. Contesto di Riferimento e Stato dell'Arte

2.1 Telecomunicazioni terrestri e satellitari

L'evoluzione delle infrastrutture di rete ha trasformato i sistemi di telecomunicazione da meri strumenti di interconnessione a veri e propri pilastri strategici della società moderna, la cui resilienza è un prerequisito imprescindibile per il funzionamento delle infrastrutture critiche [20]. Con il progressivo passaggio a un paradigma interamente digitale, il trasferimento di informazioni mediante segnali elettrici, ottici o elettromagnetici su tratte geografiche complesse non rappresenta più solo una facilitazione operativa, ma costituisce il tessuto connettivo su cui si reggono l'economia globale, l'erogazione dei servizi essenziali e la sovranità dei sistemi governativi [20]. Di conseguenza, la superficie d'attacco si è ampliata in modo esponenziale: la violazione o la degradazione intenzionale di un canale di comunicazione non implica soltanto una temporanea perdita di connettività, ma può innescare effetti a cascata devastanti, capaci di compromettere l'integrità dei dati sensibili e di paralizzare processi produttivi o decisionali in tempo reale [19]. In un contesto caratterizzato da minacce informatiche sempre più sofisticate e persistenti, la protezione dei vettori di trasmissione non può più essere considerata un elemento accessorio o posticcio, bensì deve configurarsi come un requisito di progettazione fondamentale per garantire la riservatezza, l'autenticità e la continuità operativa dei servizi [19]. Tale imperativo di sicurezza richiede tuttavia una disamina puntuale delle specificità che caratterizzano i diversi contesti trasmissivi, a partire dall'analisi dei vincoli strutturali e dei profili di rischio propri del dominio di superficie.

Telecomunicazioni terrestri In questo quadro generale, la strutturazione delle infrastrutture di comunicazione terrestri evidenzia un profondo compromesso architetturale tra efficienza prestazionale e complessità delle misure di protezione richieste. Da un lato, la combinazione di mezzi fisici guidati ad altissimo throughput, come le fibre ottiche, e di vettori radio a frequenze elevate consente di raggiungere latenze di propagazione ridottissime, rendendo tali reti il supporto d'elezione per processi ad alta reattività e applicazioni in tempo reale [20]. Dall'altro, tuttavia, la natura intrinsecamente distribuita e accessibile dei nodi terrestri espone l'infrastruttura a un panorama di

minacce ampio e variegato: la presenza di tratti cablati fisicamente raggiungibili ed elementi di instradamento intermedi moltiplica i punti di potenziale compromissione, agevolando attacchi di intercettazione o manipolazione del traffico di tipo Man-In-The-Middle [19]. A tale vulnerabilità fisica si aggiunge il costante rischio di attacchi logici sferrati mediante vettori di denial of service o iniezione di pacchetti malevoli, ideati per saturare le risorse di rete o alterare il normale flusso dei dati [19]. Di fronte a questo scenario, la sicurezza non può limitarsi all'applicazione passiva di cifratura a livello di rete e trasporto; essa necessita dell'affiancamento dinamico di sistemi di monitoraggio e intelligenza analitica, come gli Intrusion Detection Systems, capaci di ispezionare continuamente il traffico per identificare tempestivamente pattern anomali e deviazioni dal comportamento nominale prima che possano tradursi in disservizi sistemici. Ciononostante, la sola protezione del dominio di superficie si rivela insufficiente laddove la continuità operativa richieda la copertura di regioni orograficamente complesse o la ridondanza di tratte critiche, imponendo l'estensione dell'architettura trasmissiva verso lo spazio.

Telecomunicazioni satellitari In tale prospettiva di integrazione e complementarietà, l'impiego di piattaforme orbitali nelle reti di telecomunicazione rappresenta una soluzione architettuale imprescindibile per il raggiungimento di una copertura geografica globale, ma introduce al contempo severe sfide dal punto di vista operativo e della sicurezza. L'assenza di barriere fisiche e la capacità di superare qualsiasi vincolo orografico rendono i sistemi satellitari il vettore primario per la connettività in contesti isolati, transoceanici o di emergenza, garantendo una ridondanza fondamentale per le infrastrutture di terra [13]. Tuttavia, questa stessa natura broadcast e pervasiva del canale spaziale costituisce un elemento di intrinseca vulnerabilità: l'uso di frequenze radio condivise e la vasta impronta a terra dei fasci di copertura espongono il segnale a rischi continui di intercettazione passiva e a tentativi di jamming volti alla saturazione o al degrado del canale [10]. A ciò si sommano i vincoli prestazionali dovuti alle distanze orbitali, quali l'elevato ritardo di propagazione e la suscettibilità ai fenomeni di attenuazione atmosferica, che rendono i protocolli di rete tradizionali meno efficienti e più complessi da proteggere in tempo reale [13]. Inoltre, la potenziale iniezione non autorizzata di pacchetti o comandi diretti verso il segmento spaziale o di terra accentua la necessità di superare la semplice cifratura dei dati: si rende indispensabile l'adozione combinata di tecniche di modulazione a spettro espanso a livello fisico e di sistemi

intelligenti di rilevamento delle intrusioni a livello logico, capaci di analizzare in modo dinamico i flussi di traffico per identificare anomalie comportamentali prima che possano compromettere la disponibilità dell'intero collegamento [10]. L'esame dettagliato delle specificità del canale spaziale, unito all'analisi del contesto terrestre, evidenzia la necessità di una visione d'insieme capace di sintetizzare i punti di forza e le fragilità di ciascun dominio.

Analisi comparativa e necessità di monitoraggio intelligente In questa prospettiva di sintesi, l'analisi comparativa tra le architetture di telecomunicazione terrestri e satellitari mette in luce una fondamentale complementarità strutturale, accompagnata tuttavia da divergenze operative sostanziali in termini di prestazioni, copertura e vettori di vulnerabilità. Se da un lato le infrastrutture terrestri garantiscono throughput elevati e latenze di propagazione ridottissime grazie ai mezzi fisici guidati e ai ponti radio dedicati, dall'altro esse risultano limitate dalla rigidità della topologia geografica e da un'elevata densità di nodi esposti ad attacchi sia fisici che logici [20]. Al contrario, le reti satellitari offrono un'infrastruttura pervasiva e intrinsecamente immune alle barriere orografiche, pagando tuttavia il prezzo di un ritardo di propagazione notevolmente superiore, di un'alta attenuazione di canale e di un'intrinseca esposizione dei segnali a broadcast ad attività di intercettazione e jamming [13]. La coesistenza di tali ambienti eterogenei all'interno dei moderni ecosistemi di comunicazione crea un perimetro difensivo complesso, in cui i meccanismi di sicurezza tradizionali, quali la sola cifratura o i firewall perimetrali statici, si rivelano insufficienti a contrastare minacce dinamiche ed evasioni avanzate [19], evidenziando la necessità di estendere le difese verso paradigmi di monitoraggio attivo.

In risposta a questo scenario altamente dinamico, sorge la stringente necessità di integrare architetture di Intrusion Detection Systems avanzati, capaci di operare un monitoraggio continuo e non invasivo del traffico sia su collegamenti di terra sia su tratte orbitali. La rilevazione tempestiva e la caratterizzazione delle anomalie diventano tuttavia problematiche a causa dell'enorme mole di dati trasmessi e della variabilità delle condizioni di canale, rendendo i classici IDS basati su firme strutturalmente inadeguati nei confronti di attacchi inediti o variazioni comportamentali del traffico [6]. Diventa quindi indispensabile l'adozione di modelli di Machine Learning integrati nei sistemi di intrusion detection, in grado di apprendere i pattern nominali della rete e identificare deviazioni microscopiche correlate ad attività malevole in tempo reale [1]. L'impiego dell'appren-

dimento automatico consente di automatizzare l'analisi predittiva e la correlazione degli eventi di sicurezza su canali sia terrestri che satellitari, garantendo una protezione adattiva e resiliente contro il panorama in continua evoluzione delle minacce cyber [1]. Per comprendere appieno il contributo e la collocazione di tali strumenti nell'infrastruttura di rete, si rende tuttavia necessaria una formalizzazione teorica e metodologica del funzionamento degli Intrusion Detection Systems e dei modelli di apprendimento che ne costituiscono il motore analitico.

2.2 Intrusion Detection Systems in Machine Learning

Muovendo da tali premesse, l'evoluzione delle minacce informatiche all'interno delle moderne infrastrutture di rete ha confermato l'inadeguatezza dei soli meccanismi di difesa perimetrali e di controllo degli accessi, determinando la necessità di adottare sistemi di Intrusion Detection Systems (IDS) per il monitoraggio continuo del traffico logico. Un IDS è un dispositivo hardware o una soluzione software progettata per ispezionare le attività di rete o di singolo host al fine di identificare tentativi non autorizzati di accesso, violazioni delle politiche di sicurezza o compromissioni dell'integrità dei dati [14]. Tradizionalmente, la rilevazione delle intrusioni si articola in due macro-approcci: l'ispezione basata sulle firme (Signature-based Detection) e la rilevazione basata sulle anomalie (Anomaly-based Detection) [6]. Sebbene la prima garantisca un'elevata accuratezza nel riconoscere minacce note confrontando il traffico con un database di pattern malevoli prestabiliti, essa mostra un'intrinseca inefficacia di fronte ad attacchi inediti, noti come minacce Zero-Day, e a varianti strutturali generate per eludere i controlli [6], spostando l'interesse scientifico e applicativo verso modelli analitici basati sulle anomalie.

Proprio per superare la rigidità dei modelli deterministici basati su firme, l'integrazione delle tecniche di Machine Learning negli Intrusion Detection Systems ha introdotto un paradigma adattivo capace di analizzare la complessa e dinamica natura del traffico di rete moderno. Attraverso l'impiego di algoritmi di apprendimento supervisionato, non supervisionato o semi-supervisionato, un IDS basato su Machine Learning costruisce un modello comportamentale del traffico nominale mediante l'estrazione e la formalizzazione di feature rilevanti, quali la frequenza dei pacchetti, la dimensione delle righe di intestazione e la distribuzione dei tempi di interarrivo [1]. Durante la fase di inferenza, il modello valuta lo scostamento statistico delle nuove osservazioni rispetto al

profilo di riferimento stabilito, consentendo l'identificazione tempestiva di comportamenti devianti riconducibili ad attacchi informatici senza la necessità di una firma preesistente [1]. Tale approccio risulta particolarmente strategico nelle architetture di telecomunicazione complesse, poiché l'apprendimento automatico permette di scalare l'analisi dei dati su grandi volumi e di adattarsi autonomamente ai mutamenti fisiologici del traffico, garantendo una protezione resiliente contro vettori d'attacco complessi e distribuiti [7].

IDS in Machine Learning per le connessioni terrestri L'applicazione degli Intrusion Detection Systems basati su Machine Learning al dominio delle telecomunicazioni terrestri risponde alla specifica esigenza di proteggere un'architettura ad altissima velocità e ad elevata densità di traffico. Nelle reti di terra, caratterizzate da canali in fibra ottica e ponti radio con larghezze di banda nell'ordine dei gigabit o terabit al secondo, i vettori d'attacco si manifestano spesso sotto forma di burst improvvisi di pacchetti, come nei distributed denial of service (DDoS), o di raffinate scansioni di porta distribuite volte alla mappatura delle vulnerabilità [6]. In questo contesto, l'adozione di modelli di apprendimento automatico di tipo supervisionato offre vantaggi determinanti rispetto agli approcci non supervisionati: laddove questi ultimi soffrono di elevati tassi di falsi allarmi a causa delle fisiologiche fluttuazioni del traffico di rete, i classificatori supervisionati garantiscono un'elevata accuratezza e una netta delimitazione dei confini di decisione tra flussi leciti e malevoli, sfruttando feature aggregate a livello di trasporto e IP [17]. Ciononostante, la gran parte della letteratura scientifica tende a confinare l'addestramento e la validazione di tali modelli all'interno di un singolo dominio generativo, focalizzandosi spesso esclusivamente su valutazioni multiclasse o binarie senza esaminarne la robustezza al variare delle condizioni di test [1].

L'efficacia dei modelli supervisionati nel contesto terrestre è stata ampiamente documentata da diversi studi di riferimento, i cui approcci evidenziano tuttavia precise scelte metodologiche rispetto alle quali è opportuno tracciare elementi di confronto. Nel lavoro condotto da Tavallae et al. [21], gli autori dimostrano la validità dell'apprendimento supervisionato nel rilevare intrusioni su dataset terrestri standardizzati; il punto di forza primario di questo contributo risiede nella rigida formalizzazione del benchmarking e nell'abbattimento dei bias di ridondanza del traffico, pur limitando l'analisi a un contesto valutativo rigorosamente intra-dominio in cui le distribuzioni di addestramento e test coincidono perfettamente. Parallelamente, lo studio di Sharafaldin et al. [15]

evidenzia le eccellenti prestazioni dei classificatori supervisionati nel gestire dataset moderni ad alta dimensionalità e con classi sbilanciate; il pregio fondamentale risiede nel tracciamento accurato di complessi vettori d'attacco su infrastrutture multilivello, differenziandosi tuttavia da un approccio orientato alla trasferibilità in quanto la validazione rimane confinata al medesimo dominio di origine, senza analizzare il degrado prestazionale derivante da un eventuale domain-shift o il comportamento comparato tra granularità biclasse e multiclasse. Infine, l'opera di Ferrag et al. [5] dimostra come l'addestramento supervisionato consenta di ottimizzare l'accuratezza predittiva su grandi volumi di dati; il punto di forza risiede nella rapida convergenza dei modelli su traffico complesso, sebbene l'analisi mantenga la priorità sulla sola convergenza intra-dominio e non valuti l'impatto dello scostamento distributivo quando il modello viene trasferito verso ambienti trasmissivi eterogenei.

La stabilità dei collegamenti cablati facilita l'implementazione di tali architetture supervisionate in tempo quasi reale [14]. I classificatori supervisionati traggono un netto vantaggio dalla regolarità dei pattern terrestri, garantendo tassi di falsi positivi contenuti sia nella classificazione biclasse, finalizzata alla mera separazione tra traffico normale e anomalo, sia in quella multiclasse, volta all'identificazione della specifica famiglia d'attacco [7]. Tuttavia, la forte dipendenza dei modelli supervisionati dalla distribuzione dei dati di training pone una sfida aperta circa la loro reale capacità di generalizzazione, evidenziando come la semplice validazione su scenari terrestri omogenei non sia sufficiente a garantire l'operatività dell'IDS in presenza di variazioni strutturali del canale di trasmissione [1].

IDS in Machine Learning per le connessioni satellitari L'impiego degli Intrusion Detection Systems basati su Machine Learning nelle comunicazioni satellitari deve affrontare vincoli operativi e dinamiche di canale sensibilmente differenti rispetto ai sistemi terrestri, dovuti alle caratteristiche fisiche e topologiche delle tratte orbitali. Le reti satellitari sono penalizzate da elevati tempi di latenza di propagazione, larghezze di banda asimmetriche e da un'intrinseca suscettibilità al rumore atmosferico e ai fenomeni di fading del segnale [13]. In questo ambito, la scelta di prediligere classificatori supervisionati rispetto a tecniche non supervisionate risponde all'esigenza di discriminare con certezza le anomalie malevole, quali jamming o iniezione di comandi, dalle fisiologiche attenuazioni del canale radio spaziale, evitando l'elevata frequenza di falsi positivi tipica dei modelli non supervisionati guidati da sole metriche di distanza statistica [10, 6]. Tuttavia, la

principale criticità del contesto satellitare risiede nella marcata scarsità di dati benevoli etichettati, che rende problematico l'addestramento di modelli nativi e impone la ricerca di strategie per compensare l'assenza di un baseline di traffico nominale spaziale [16].

La letteratura scientifica dedicata alla sicurezza satellitare ha affrontato tali problematiche attraverso diverse formulazioni, evidenziando tuttavia significative divergenze metodologiche. Il contributo di Zhao et al. [25] esplora l'efficacia di modelli supervisionati nel rilevare minacce di jamming e intrusioni nei collegamenti radio spaziali; il punto di forza risiede nell'elevata accuratezza ottenuta nell'isolamento di attacchi a livello fisico su canali rumorosi, ma l'approccio si differenzia poiché presuppone la disponibilità a priori di un dataset satellitare completo per l'addestramento, ignorando la valutazione di modelli addestrati su dati terrestri e testati in presenza di domain-shift. Un altro lavoro significativo è quello di Liu et al. [8], che applica classificatori supervisionati ad alte prestazioni per identificare anomalie nei segmenti satellitari; il pregio di questa ricerca consiste nella drastica riduzione della complessità computazionale per l'esecuzione a bordo, ma mantiene la limitazione di valutare il sistema esclusivamente in configurazione multiclasse all'interno di uno scenario stazionario, senza affrontare il problema della carenza di dati nominali di test o l'impatto delle variazioni di dominio. Infine, lo studio di Al-Makhadmeh et al. [9] propone un'architettura supervisionata per l'ispezione del traffico integrato satellitare-terrestre; il punto di forza risiede nella capacità di gestire volumi di dati ad alta dimensionalità, ma si differenzia in quanto richiede un dataset d'addestramento ibrido già bilanciato, laddove risulta invece fondamentale valutare la capacità di un classificatore puramente terrestre di adattarsi al canale satellitare tramite tecniche di iniezione mirata di dati per sopperire alla mancanza di un riferimento di traffico lecito.

In conclusione, la progettazione di un IDS supervisionato per comunicazioni satellitari non può prescindere da una valutazione rigorosa che superi il singolo dominio di addestramento. L'esplorazione combinata delle prestazioni in ambiti sia biclasse sia multiclasse, unita all'analisi sistematica del degrado prestazionale causato dal domain-shift e all'adozione di strategie per sopperire alla scarsità di dati benevoli satellitari, rappresenta un passaggio cruciale per garantire la reale usabilità degli Intrusion Detection Systems nelle infrastrutture di telecomunicazione spaziali di nuova generazione [1, 16].

2.3 Adattamento di Dominio e Scarsità dei Dati

A completamento dell'analisi delle criticità connesse all'integrazione di sistemi di sicurezza basati sull'apprendimento automatico nei moderni ecosistemi di telecomunicazione, risulta indispensabile esaminare le problematiche metodologiche e teoriche legate alla variazione dei contesti operativi e alla disponibilità delle informazioni. La transizione da architetture trasmissive omogenee a scenari eterogenei impone infatti di superare i limiti strutturali associati non solo alla natura fisica dei canali, ma anche alla portabilità dei modelli analitici e alla disomogeneità statistica dei dataset di riferimento.

Il fenomeno del domain-shift nei sistemi NIDS Dal punto di vista della teoria dell'apprendimento statistico, l'impiego di modelli di Machine Learning per la rilevazione delle intrusioni in contesti di rete eterogenei risente del fenomeno del disallineamento distributivo, noto in letteratura come domain-shift [12]. In termini formali, un dominio è definito da uno spazio delle feature e da una distribuzione di probabilità congiunta; il domain-shift si verifica quando la distribuzione marginale dei dati del dominio di origine differisce da quella del dominio di destinazione, oppure quando muta la distribuzione condizionata delle classi rispetto alle osservazioni [12]. Nelle infrastrutture di telecomunicazione, tale discrepanza teorica si traduce nella variazione dei profili di traffico: la transizione dal canale terrestre a quello satellitare introduce ritardi di propagazione elevati, fluttuazioni della larghezza di banda e fenomeni stocastici di attenuazione atmosferica che alterano significativamente la distribuzione dei tempi di interarrivo e la struttura dei pacchetti [16]. Tale scostamento sposta i vettori di test rispetto agli iperpiani di separazione appresi in fase di training, provocando un grave degrado della capacità discriminativa del classificatore e un incremento incontrollato dei tassi di falso allarme [17]. In letteratura, il problema dell'adattamento di dominio viene affrontato principalmente mediante la ricerca di uno spazio latente comune o la minimizzazione di metriche di distanza statistica tra le distribuzioni [24]. In quest'ambito, il lavoro di Wilson et al. [24] fornisce un'analisi teorica esaustiva dei metodi di domain adaptation volti a riallineare le distribuzioni marginali tra contesti differenti; il punto di forza di tale contributo risiede nella formalizzazione di modelli capaci di abbattere il bias di dominio senza richiedere etichette nel contesto di destinazione, differenziandosi tuttavia dal nostro approccio in quanto la trattazione della

letteratura è orientata prevalentemente ad ambienti omogenei e non affronta la specifica asimmetria strutturale e la marcata alterazione dei profili di traffico derivante dal trasferimento diretto tra il canale terrestre e quello orbitale.

Strategie di iniezione di dati per la mitigazione dello sbilanciamento Sul piano metodologico e teorico, l'adattamento di dominio deve confrontarsi con il problema dello sbilanciamento e della limitata disponibilità di informazioni etichettate nel dominio target. Nelle applicazioni reali di Network Intrusion Detection, la scarsità di campioni appartenenti al dominio di destinazione costituisce un ostacolo primario all'addestramento di modelli nativi, configurando scenari di apprendimento semi-supervisionato o a pochi campioni (few-shot learning) [12]. Nelle comunicazioni satellitari, tale criticità è esacerbata dalla profonda scarsità di tracce etichettate relative al traffico nominale del segmento spaziale, dovuta ai vincoli di riservatezza, all'elevato costo operativo e alla natura critica delle infrastrutture orbitali [16]. Sebbene la letteratura proponga l'adozione di modelli puramente non supervisionati per ovviare alla mancanza di etichette, tali approcci teorici basati sulla sola stima della densità di probabilità mostrano un'intrinseca fragilità nei contesti ad alto rumore stocastico, scambiando le fisiologiche fluttuazioni del canale radio per attività malevole [10, 6]. Per preservare la capacità di definire confini di decisione rigidi tipica dei classificatori supervisionati, una strategia teoricamente solida consiste nell'adattamento del modello mediante l'iniezione mirata di dati del dominio target nel dataset di origine [12]. Dal punto di vista teorico, l'integrazione di una frazione ridotta di campioni del dominio satellitare durante l'addestramento altera la funzione di perdita del modello, permettendo di riallineare i confini di separazione e di inglobare la variabilità stocastica del canale di destinazione senza perdere la ricchezza informativa sugli attacchi complessi appresa dal dominio terrestre [1, 17]. Tale approccio di iniezione mitiga lo sbilanciamento distributivo, garantendo un'elevata generalizzazione del classificatore sia nella discriminazione biclasse sia nella caratterizzazione multiclasse delle minacce.

2.4 Sintesi e Posizionamento del Lavoro

3. Elementi Base

In questo capitolo ci saranno esempi base di elenchi puntati, figure, tabelle, formule, algoritmi e codici.

Esempio di elenco puntato:

- **primo punto in grassetto;**
- secondo punto, se preferisci che non sia in grassetto;

3.1 Sezione nel Secondo Capitolo

Esempio di immagine in Figura 3.1. Ricorda di menzionare sempre nel testo, usando `\ref`, tutte le figure/tabelle/algoritmi/codici che inserisci. ¹

¹Un'esempio di come aggiungere una footnote, spesso magari usata per citare o riportare qualche sito, come tipo <https://ditto.ing.unimore.it/>,




Figura 3.1: L'architettura introdotta da Vaswani nel famoso Paper "*Attention is All You Need*" [23].

3.2 Un'Altra Sezione nel Secondo Capitolo

Esempio di una tabella con relativa citazione, Tabella 3.1.

Tabella 3.1: Esempio di tabella con vari campi, spunte e croci.

Frutto	Arancione	Si sbuccia	Peso	Prezzo	Zucch.	Voto (1–10)
Arancia	✓	✓	0.200	2.50	9.0	8
Mandarino	✓	✓	0.120	3.20	8.5	9
Limone	✗	✓	0.100	3.50	2.5	6
Mela	✗	✗	0.180	2.80	10.0	8
Banana	✗	✓	0.150	1.10	12.2	9
Kiwi	✗	✓	0.120	4.00	9.1	7
Mango	✓	✓	0.300	5.00	14.0	10

3.3 Formule Matematiche

Qui due esempi di come fare formule matematiche, come riconoscerete bene in Eq. 3.1 abbiamo la versione integrale della Trasformata di Fourier mentre in Eq. 3.2 ne abbiamo la formulazione discretizzata con la sommatoria.

$$X(f) = \int_{-\infty}^{\infty} x(t) e^{-j2\pi ft} dt \quad (3.1)$$

$$X_k = \sum_{n=0}^{N-1} x_n \cdot e^{-i \frac{2\pi}{N} kn} \quad (3.2)$$

3.4 Esempio di Algoritmo

Nell'Algoritmo 1 si può vedere un modo per ottenere il cammino minimo.

Algorithm 1 Dijkstra's Algorithm

```
1: procedure DIJKSTRA( $G, s$ )
2:    $dist[] \leftarrow \infty$                                 ▶ Initialize distances to infinity
3:    $dist[s] \leftarrow 0$                                     ▶ Distance to source is 0
4:    $Q \leftarrow V[G]$                                        ▶ Add all nodes to the queue
5:   while  $Q$  is not empty do
6:      $u \leftarrow$  vertex in  $Q$  with min  $dist[u]$ 
7:     remove  $u$  from  $Q$ 
8:     for each neighbor  $v$  of  $u$  do
9:        $alt \leftarrow dist[u] + length(u, v)$ 
10:      if  $alt < dist[v]$  then
11:         $dist[v] \leftarrow alt$ 
12:         $prev[v] \leftarrow u$ 
13:      end if
14:    end for
15:  end while
16:  return  $dist[], prev[]$ 
17: end procedure
```

3.5 Esempi di Codice

Puoi anche includere alcuni esempi di codice, purché non siano troppo lunghi. Un esempio di può vedere nel Codice 3.1

Codice 3.1: Codice di esempio, tratto da helloworldspam.py

```
print('Starting the ultimate hello world spammer')
for i in range(10000000):
    print("Hello , world!")
```

3.6 Gestione della Bibliografia

Tutti i riferimenti bibliografici andranno inseriti nel file “.bib” del progetto. In questo template il file è “bibliography.bib”. Per citare un riferimento occorre usare il comando “\cite{<id>}”, come ad esempio [23].

4. Tabelle e Immagini

In questo capitolo ci saranno esempi di tabelle di grandi dimensioni e immagini disposte a griglia.

4.1 Griglia 1x3

Ecco un esempio di una griglia di immagini, come mostrato in Figura 4.1.



(a) Arancia



(b) Mela



(c) Banana

Figura 4.1: Foto di frutta fresca in griglia 1x3.

4.2 Griglia 2x2

Ecco un esempio di una griglia di immagini, come mostrato in Figura 4.2.



(a) Arancia



(b) Mela



(c) Banana



(d) Pera

Figura 4.2: Foto di frutta fresca in griglia 2×2.

4.3 Esempio di Tabella Complessa

Tabella 4.1: Analisi comparativa di diversi frutti combinando vari metodi di maturazione, provenienze e punti di vista. Le Run ID rappresentano differenti esperimenti su raccolti.

Score Prov.	Frutto	Raccolti											
		R1	R2	R3	R4	R5	R6	R7	R8A	R8S	R9	R10	
Dolcezza	Tutti	Mela	87.23	88.01	87.44	86.99	88.12	87.55	88.23	87.66	88.42	88.09	87.77
		Banana	91.31	92.05	91.74	91.92	90.84	92.18	91.95	92.02	91.85	91.99	91.88
	Tropic.	Ananas	84.45	85.02	84.60	84.99	84.25	85.15	84.79	84.92	85.11	84.85	84.88
		Mango	90.12	90.89	91.10	90.67	90.33	91.21	90.97	91.03	91.30	90.95	91.12
	Mediterr.	Arancia	88.44	89.11	88.99	89.23	88.51	89.34	89.28	89.21	89.43	89.15	89.32
		Limone	72.62	73.40	73.88	72.95	72.50	73.91	73.65	73.75	73.84	73.70	73.78
Succosità	Tutti	Mela	65.42	67.19	66.85	67.00	65.99	67.45	67.11	67.38	67.80	67.21	67.43
		Banana	78.84	79.11	79.67	79.40	78.72	79.91	79.63	79.85	80.10	79.74	79.87
		Uva	82.17	82.69	82.33	82.50	82.02	82.91	82.65	82.84	83.05	82.73	82.91
	Tropic.	Mango	85.15	85.44	85.98	85.67	85.01	86.11	85.79	85.92	86.22	85.83	85.96
		Papaya	74.83	75.02	75.37	75.14	74.76	75.49	75.23	75.40	75.60	75.28	75.39
		Ananas	77.04	77.49	77.71	77.31	77.05	77.80	77.58	77.66	77.93	77.60	77.74
	Mediterr.	Arancia	81.90	82.30	82.65	82.49	81.87	82.76	82.52	82.68	82.95	82.59	82.70
		Limone	61.35	61.88	62.09	61.95	61.24	62.22	62.05	62.17	62.44	62.10	62.26
		Pompelmo	68.75	69.21	69.58	69.37	68.80	69.83	69.65	69.70	69.99	69.68	69.82

5. Conclusioni

Qui andrebbero le tue conclusioni.

Ringraziamenti

Qui i ringraziamenti, se lo desideri.

Bibliografia

- [1] Anna L. Buczak e Erhan Guven. «A survey of data mining and machine learning methods for cyber security intrusion detection». In: *IEEE Communications Surveys & Tutorials* 18.2 (2016), pp. 1153–1176.
- [2] Celery Project. *Celery: Distributed Task Queue*. Framework per la gestione concorrente ed asincrona di task. 2025. URL: <https://docs.celeryproject.org/en/stable/>.
- [3] Django Software Foundation. *Django Web Framework*. Framework per lo sviluppo di webapp. 2024. URL: <https://www.djangoproject.com/>.
- [4] Docker Inc. *Docker Documentation*. Piattaforma per lo sviluppo di container software. 2024. URL: <https://docs.docker.com>.
- [5] Mohamed Amine Ferrag et al. «Deep learning for cyber security intrusion detection: Approaches, datasets, and comparative study». In: *Journal of Information Security and Applications* 50 (2020), p. 102419.
- [6] Pedro Garcia-Teodoro et al. «Anomaly-based network intrusion detection: Techniques, systems and challenges». In: *Computers & Security* 28.1-2 (2009), pp. 18–28.
- [7] Pavel Laskov et al. «Learning intrusion detection: supervised or unsupervised?» In: *Proceedings of the 8th International Conference on Image Analysis and Processing (ICIAP 2005)*. Springer, 2005, pp. 50–57.
- [8] Yanjun Liu et al. «Lightweight decision tree and boosting-based intrusion detection for space-ground integrated networks». In: *IEEE Internet of Things Journal* 8.14 (2021), pp. 11502–11514.
- [9] Zafer Al-Makhadmeh e Amr Tolba. «An efficient ensemble learning-based network intrusion detection system for satellite-terrestrial networks». In: *IEEE Access* 10 (2022), pp. 34210–34221.
- [10] National Institute of Standards and Technology. *Cybersecurity Framework Profile for Public Safety Land Mobile Radio*. NIST Special Publication 800-187. U.S. Department of Commerce, 2022.

- [11] OpenAI. *Whisper*. Modello IA open source per il riconoscimento vocale automatico. 2022. URL: <https://github.com/openai/whisper>.
- [12] Sinno Jialin Pan e Qiang Yang. «A survey on transfer learning». In: *IEEE Transactions on Knowledge and Data Engineering* 22.10 (2009), pp. 1345–1359.
- [13] Timothy Pratt, Charles Bostian e Jeremy Allnutt. *Satellite Communications*. John Wiley & Sons, 2002.
- [14] Karen Scarfone e Peter Mell. *Guide to Intrusion Detection and Prevention Systems (IDPS)*. NIST Special Publication 800-94. National Institute of Standards e Technology, 2007.
- [15] Iman Sharafaldin, Arash Habibi Lashkari e Ali A. Ghorbani. «Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization». In: *Proceedings of the 4th International Conference on Information Systems Security and Privacy (ICISSP 2018)*. SCITEPRESS, 2018, pp. 108–116.
- [16] Giuseppe Siracusano et al. «Machine learning for satellite communication security: A survey». In: *IEEE Access* 9 (2021), pp. 112450–112468.
- [17] Robin Sommer e Vern Paxson. «Outside the closed world: On using machine learning for network intrusion detection». In: *Proceedings of the 2010 IEEE Symposium on Security and Privacy (SP)*. IEEE, 2010, pp. 305–316.
- [18] SQLAlchemy Project. *SQLAlchemy — The Database Toolkit for Python*. Toolkit e ORM per la gestione di database in Python. 2025. URL: <https://www.sqlalchemy.org/>.
- [19] William Stallings. *Cryptography and Network Security: Principles and Practice*. Pearson, 2017.
- [20] Andrew S. Tanenbaum e David J. Wetherall. *Computer Networks*. Pearson, 2011.
- [21] Mahbod Tavallaei et al. «A detailed analysis of the KDD CUP 99 data set». In: *Proceedings of the Second IEEE Symposium on Computational Intelligence for Security and Defense Applications (CISDA 2009)*. IEEE, 2009, pp. 1–6.
- [22] Flower Team. *Flower: A Friendly Federated Learning Framework*. Frontend web per il monitoraggio delle tasks Celery. 2025. URL: <https://flower.dev>.

- [23] Ashish Vaswani et al. «Attention is all you need». In: *Advances in neural information processing systems* 30 (2017).
- [24] Garrett Wilson e Diane J. Cook. «A Survey of Unsupervised Deep Domain Adaptation». In: *ACM Transactions on Intelligent Systems and Technology* 11.5 (2020), pp. 1–46.
- [25] Bo Zhao et al. «Machine learning-based intrusion and jamming detection in satellite communication networks». In: *IEEE Transactions on Wireless Communications* 19.5 (2020), pp. 3310–3324.