



UNIMORE
UNIVERSITÀ DEGLI STUDI DI
MODENA E REGGIO EMILIA

UNIVERSITÀ DEGLI STUDI DI MODENA E REGGIO EMILIA

Dipartimento di Ingegneria "Enzo Ferrari"

Corso di Laurea Triennale in Ingegneria Informatica (L-08)

<Titolo dell'Elaborato>

Tutor:

Prof. Mirco Marchetti

Candidato:

Alessandro Marchesini

Matricola 187179

ANNO ACCADEMICO 2025/2026

<Dedica, opzionale. Cancella tutto in questa pagina per saltarla>

Indice

1	Introduzione	1
1.1	Contesto generale	1
1.2	Obiettivo dell'Elaborato	1
2	Contesto di Riferimento e Stato dell'Arte	2
2.1	Telecomunicazioni terrestri e satellitari	2
2.2	Intrusion Detection Systems in Machine Learning	4
3	Elementi Base	10
3.1	Sezione nel Secondo Capitolo	10
3.2	Un'Altra Sezione nel Secondo Capitolo	11
3.3	Formule Matematiche	12
3.4	Esempio di Algoritmo	12
3.5	Esempi di Codice	13
3.6	Gestione della Bibliografia	14
4	Tabelle e Immagini	15
4.1	Griglia 1x3	15
4.2	Griglia 2x2	15
4.3	Esempio di Tabella Complessa	16
5	Conclusioni	18
	Ringraziamenti	19
	Riferimenti	20

Elenco delle Figure

- 3.1 L'architettura introdotta da Vaswani nel famoso Paper "*Attention is All You Need*" [22]. 11
- 4.1 Foto di frutta fresca in griglia 1x3. 15
- 4.2 Foto di frutta fresca in griglia 2x2. 16

Elenco dei Codici

3.1 Codice di esempio, tratto da helloworldspam.py 13

1. Introduzione

1.1 Contesto generale

1.2 Obiettivo dell'Elaborato

2. Contesto di Riferimento e Stato dell'Arte

2.1 Telecomunicazioni terrestri e satellitari

L'evoluzione delle infrastrutture di rete ha trasformato i sistemi di telecomunicazione da meri strumenti di interconnessione a veri e propri pilastri strategici della società moderna, la cui resilienza è un prerequisito imprescindibile per il funzionamento delle infrastrutture critiche [19]. Con il progressivo passaggio a paradigma interamente digitale, il trasferimento di informazioni mediante segnali elettrici, ottici o elettromagnetici su tratte geografiche complesse non rappresenta più solo una facilitazione operativa, ma costituisce il tessuto connettivo su cui si reggono l'economia globale, l'erogazione dei servizi essenziali e la sovranità dei sistemi governativi [19]. Di conseguenza, la superficie d'attacco si è ampliata in modo esponenziale: la violazione o la degradazione intenzionale di un canale di comunicazione non implica soltanto una temporanea perdita di connettività, ma può innescare effetti a cascata devastanti, capaci di compromettere l'integrità dei dati sensibili e di paralizzare processi produttivi o decisionali in tempo reale [18]. In un contesto caratterizzato da minacce informatiche sempre più sofisticate e persistenti, la protezione dei vettori di trasmissione non può più essere considerata un elemento accessorio o posticcio, bensì deve configurarsi come un requisito di progettazione fondamentale per garantire la riservatezza, l'autenticità e la continuità operativa dei servizi [18].

Telecomunicazioni terrestri La strutturazione delle infrastrutture di comunicazione terrestri evidenzia un profondo compromesso architetturale tra efficienza prestazionale e complessità delle misure di protezione richieste. Da un lato, la combinazione di mezzi fisici guidati ad altissimo throughput, come le fibre ottiche, e di vettori radio a frequenze elevate consente di raggiungere latenze di propagazione ridottissime, rendendo tali reti il supporto d'elezione per processi ad alta reattività e applicazioni in tempo reale [19]. Dall'altro, tuttavia, la natura intrinsecamente distribuita e accessibile dei nodi terrestri espone l'infrastruttura a un panorama di minacce ampio e variegato: la presenza di tratti cablati fisicamente raggiungibili ed elementi di instradamento intermedi moltiplica i punti di potenziale compromissione, agevolando attacchi di intercettazione o

manipolazione del traffico di tipo Man-In-The-Middle [18]. A tale vulnerabilità fisica si aggiunge il costante rischio di attacchi logici sferrati mediante vettori di denial of service o iniezione di pacchetti malevoli, ideati per saturare le risorse di rete o alterare il normale flusso dei dati [18]. Di fronte a questo scenario, la sicurezza non può limitarsi all'applicazione passiva di cifratura a livello di rete e trasporto; essa necessita dell'affiancamento dinamico di sistemi di monitoraggio e intelligenza analitica, come gli Intrusion Detection Systems, capaci di ispezionare continuamente il traffico per identificare tempestivamente pattern anomali e deviazioni dal comportamento nominale prima che possano tradursi in disservizi sistemici.

Telecomunicazioni satellitari L'impiego di piattaforme orbitali nelle reti di telecomunicazione rappresenta una soluzione architeturale imprescindibile per il raggiungimento di una copertura geografica globale, ma introduce al contempo severe sfide dal punto di vista operativo e della sicurezza. L'assenza di barriere fisiche e la capacità di superare qualsiasi vincolo orografico rendono i sistemi satellitari il vettore primario per la connettività in contesti isolati, transoceanici o di emergenza, garantendo una ridondanza fondamentale per le infrastrutture di terra [12]. Tuttavia, questa stessa natura broadcast e pervasiva del canale spaziale costituisce un elemento di intrinseca vulnerabilità: l'uso di frequenze radio condivise e la vasta impronta a terra dei fasci di copertura espongono il segnale a rischi continui di intercettazione passiva e a tentativi di jamming volti alla saturazione o al degrado del canale [10]. A ciò si sommano i vincoli prestazionali dovuti alle distanze orbitali, quali l'elevato ritardo di propagazione e la suscettibilità ai fenomeni di attenuazione atmosferica, che rendono i protocolli di rete tradizionali meno efficienti e più complessi da proteggere in tempo reale [12]. Inoltre, la potenziale iniezione non autorizzata di pacchetti o comandi diretti verso il segmento spaziale o di terra accentua la necessità di superare la semplice cifratura dei dati: si rende indispensabile l'adozione combinata di tecniche di modulazione a spettro espanso a livello fisico e di sistemi intelligenti di rilevamento delle intrusioni a livello logico, capaci di analizzare in modo dinamico i flussi di traffico per identificare anomalie comportamentali prima che possano compromettere la disponibilità dell'intero collegamento [10].

Analisi comparativa e necessità di monitoraggio intelligente L'analisi comparativa tra le architetture di telecomunicazione terrestri e satellitari evidenzia una fondamentale complementarità

strutturale, accompagnata tuttavia da divergenze operative sostanziali in termini di prestazioni, copertura e vettori di vulnerabilità. Se da un lato le infrastrutture terrestri garantiscono Throughput elevati e latenze di propagazione ridottissime grazie ai mezzi fisici guidati e ai ponti radio dedicati, dall'altro esse risultano limitate dalla rigidità della topologia geografica e da un'elevata densità di nodi esposti ad attacchi sia fisici che logici [19]. Al contrario, le reti satellitari offrono un'infrastruttura pervasiva e intrinsecamente immune alle barriere orografiche, pagando tuttavia il prezzo di un ritardo di propagazione notevolmente superiore, di un'alta attenuazione di canale e di un'intrinseca esposizione dei segnali a broadcast ad attività di intercettazione e jamming [12]. La coesistenza di tali ambienti eterogenei all'interno dei moderni ecosistemi di comunicazione crea un perimetro difensivo complesso, in cui i meccanismi di sicurezza tradizionali, quali la sola cifratura o i firewall perimetrali statici, si rivelano insufficienti a contrastare minacce dinamiche ed evasioni avanzate [18].

In questo scenario altamente dinamico, sorge la stringente necessità di integrare architetture di Intrusion Detection Systems avanzati, capaci di operare un monitoraggio continuo e non invasivo del traffico sia su collegamenti di terra sia su tratte orbitali. La rilevazione temporanea e la caratterizzazione delle anomalie diventano tuttavia problematiche a causa dell'enorme mole di dati trasmessi e della variabilità delle condizioni di canale, rendendo i classici IDS basati su firme strutturalmente inadeguati nei confronti di attacchi inediti o variazioni comportamentali del traffico [6]. Diventa quindi indispensabile l'adozione di modelli di Machine Learning integrati nei sistemi di intrusion detection, in grado di apprendere i pattern nominali della rete e identificare deviazioni microscopiche correlate ad attività malevole in tempo reale [1]. L'impiego dell'apprendimento automatico consente di automatizzare l'analisi predittiva e la correlazione degli eventi di sicurezza su canali sia terrestri che satellitari, garantendo una protezione adattiva e resiliente contro il panorama in continua evoluzione delle minacce cyber [1].

2.2 Intrusion Detection Systems in Machine Learning

L'evoluzione delle minacce informatiche all'interno delle moderne infrastrutture di rete ha reso inadeguati i soli meccanismi di difesa perimetrali e di controllo degli accessi, determinando la necessità di adottare sistemi di Intrusion Detection Systems (IDS) per il monitoraggio continuo del traffico

logico. Un IDS è un dispositivo hardware o una soluzione software progettata per ispezionare le attività di rete o di singolo host al fine di identificare tentativi non autorizzati di accesso, violazioni delle politiche di sicurezza o compromissioni dell'integrità dei dati [13]. Tradizionalmente, la rilevazione delle intrusioni si articola in due macro-approcci: l'ispezione basata sulle firme (Signature-based Detection) e la rilevazione basata sulle anomalie (Anomaly-based Detection) [6]. Sebbene la prima garantisca un'elevata accuratezza nel riconoscere minacce note confrontando il traffico con un database di pattern malevoli prestabiliti, essa mostra un'intrinseca inefficacia di fronte ad attacchi inediti, noti come minacce Zero-Day, e a varianti strutturali generate per eludere i controlli [6].

Per superare la rigidità dei modelli deterministici, l'integrazione delle tecniche di Machine Learning negli Intrusion Detection Systems ha introdotto un paradigma adattivo capace di analizzare la complessa e dinamica natura del traffico di rete moderno. Attraverso l'impiego di algoritmi di apprendimento supervisionato, non supervisionato o semi-supervisionato, un IDS basato su Machine Learning costruisce un modello comportamentale del traffico nominale mediante l'estrazione e la formalizzazione di feature rilevanti, quali la frequenza dei pacchetti, la dimensione delle righe di intestazione e la distribuzione dei tempi di interarrivo [1]. Durante la fase di inferenza, il modello valuta lo scostamento statistico delle nuove osservazioni rispetto al profilo di riferimento stabilito, consentendo l'identificazione tempestiva di comportamenti devianti riconducibili ad attacchi informatici senza la necessità di una firma preesistente [1]. Tale approccio risulta particolarmente strategico nelle architetture di telecomunicazione complesse, poiché l'apprendimento automatico permette di scalare l'analisi dei dati su grandi volumi e di adattarsi autonomamente ai mutamenti fisiologici del traffico, garantendo una protezione resiliente contro vettori d'attacco complessi e distribuiti [7].

IDS in Machine Learning per le connessioni terrestri L'applicazione degli Intrusion Detection Systems basati su Machine Learning al dominio delle telecomunicazioni terrestri risponde alla specifica esigenza di proteggere un'architettura ad altissima velocità e ad elevata densità di traffico. Nelle reti di terra, caratterizzate da canali in fibra ottica e ponti radio con larghezze di banda nell'ordine dei gigabit o terabit al secondo, i vettori d'attacco si manifestano spesso sotto forma di burst improvvisi di pacchetti, come nei distributed denial of service (DDoS), o di raffinate scansioni

di porta distribuite volte alla mappatura delle vulnerabilità [6]. In questo contesto, i modelli di apprendimento automatico di tipo supervisionato basati su strutture ad albero svolgono un ruolo di primaria importanza nell'elaborazione ad alte prestazioni di feature estratte a livello di flusso IP e di trasporto [16]. Algoritmi come Decision Tree (DT), Random Forest (RF) e Hist Gradient Boosting (HGB) risultano particolarmente idonei per questo ambiente grazie alla loro capacità di modellare relazioni non lineari tra le feature, quali la distribuzione dei tempi di interarrivo e la dimensione dei payload, mantenendo una complessità computazionale contenuta in fase di inferenza e garantendo un'elevata discriminazione tra traffico lecito e malevolo [1].

L'efficacia e la scalabilità di questi modelli supervisionati sono state ampiamente documentate nella letteratura scientifica di settore attraverso diversi studi di riferimento. Nel lavoro condotto da Tavallae et al. [20], gli autori dimostrano la validità degli alberi di decisione singoli e d'insieme nel rilevare intrusioni di rete su dataset terrestri standardizzati; il punto di forza primario di questo contributo risiede nella rigida formalizzazione del benchmarking e nell'abbattimento dei bias di ridondanza del traffico, pur limitando l'analisi a un contesto valutativo omogeneo in cui addestramento e test condividono la medesima distribuzione di rete. Parallelamente, lo studio di Sharafaldin et al. [14] evidenzia le eccellenti prestazioni della Random Forest nel gestire dataset di traffico moderno caratterizzati da un'elevata dimensionalità delle feature e da classi di attacco sbilanciate; il pregio fondamentale del loro approccio consiste nel tracciamento accurato dei profili di attacco su infrastrutture multilivello, differenziandosi tuttavia dalle configurazioni a dominio incrociato in quanto la validazione del modello rimane confinata ed eseguita esclusivamente all'interno del medesimo dominio generativo terrestre. Infine, l'opera di Ferrag et al. [5] dimostra come l'impiego di algoritmi basati su gradient boosting, tra cui varianti ad alte prestazioni analoghe all'Hist Gradient Boosting, consenta di ottimizzare drasticamente i tempi di addestramento e l'accuratezza predittiva sia in contesti di classificazione binaria che multiclasse; il punto di forza risiede nella capacità di calcolare velocemente le soglie di decisione ottimali su grandi volumi di dati, sebbene l'approccio mantenga la priorità sulla convergenza intra-dominio senza valutare la degradazione prestazionale derivante dal trasferimento diretto del modello verso canali trasmissivi eterogenei o affetti da disturbi fisici stocastici.

La stabilità strutturale dei collegamenti cablati e la disponibilità di nodi di calcolo ad elevate prestazioni lungo le dorsali terrestri facilitano l'implementazione di tali architetture IDS supervi-

sionate in modalità in-line o passiva in tempo quasi reale [13]. I modelli ad albero e d'insieme traggono un netto vantaggio dalla costanza dei pattern terrestri, garantendo tassi di falsi positivi estremamente contenuti nella classificazione sia biclasse, volta alla semplice distinzione tra traffico anomalo e nominale, sia multiclasse, finalizzata alla caratterizzazione specifica della famiglia d'attacco [7]. Tuttavia, la dipendenza dei modelli supervisionati dalla distribuzione dei dati di training impone la necessità di considerare con attenzione la loro capacità di generalizzazione, poiché la sola valutazione su scenari terrestri statici rischia di celare la vulnerabilità dell'IDS di fronte a variazioni dei parametri fisici e logici del canale trasmissivo [1].

IDS in Machine Learning per le connessioni satellitari L'impiego degli Intrusion Detection Systems basati su Machine Learning nelle comunicazioni satellitari deve affrontare vincoli operativi e dinamiche di canale sensibilmente differenti rispetto ai sistemi terrestri, dovuti alle caratteristiche fisiche e topologiche delle tratte orbitali. Le reti satellitari sono penalizzate da elevati tempi di latenza di propagazione, larghezze di banda asimmetriche e da un'intrinseca suscettibilità al rumore atmosferico e ai fenomeni di fading del segnale [12]. In questo contesto, i vettori d'attacco tradizionali si sommano a minacce specifiche della tratta radio spaziale, quali attacchi di jamming mirato, spoofing del segnale GPS/GNSS, intercettazione e iniezione malevola di comandi di telemetria e controllo [10]. La presenza di disturbi ambientali e variazioni stocastiche di canale rende la distinzione tra un'interferenza naturale e un'aggressione malevola un compito complesso per gli IDS convenzionali, determinando tassi elevati di falsi allarmi se gestiti tramite regole statiche o firme predefinite [6].

Per superare tali limitazioni, l'applicazione di modelli di apprendimento automatico supervisionati basati su alberi di decisione rappresenta una soluzione primaria per strutturare un rilevamento comportamentale adattivo e a bassa latenza computazionale. Algoritmi quali Decision Tree (DT), Random Forest (RF) e Histogram-based Gradient Boosting (HGB) offrono capacità intrinseche nell'isolare relazioni non lineari tra le feature di rete, consentendo di classificare il traffico sia in configurazione biclasse (rilevamento binario dell'anomalia) sia in configurazione multiclasse (caratterizzazione della specifica tipologia di attacco) [1]. La ridotta impronta di memoria in fase di inferenza e la robustezza verso feature irrilevanti o rumore stocastico rendono questi modelli ad albero particolarmente adatti all'integrazione su nodi di bordo o gateway terrestri con vincoli di

risorse [15].

L'efficacia e la caratterizzazione dei modelli supervisionati ad albero per il dominio satellitare o spaziale sono state analizzate da diversi studi rilevanti in letteratura. Il contributo di Zhao et al. [23] esplora l'utilizzo di algoritmi d'insieme quali la Random Forest per il rilevamento delle intrusioni e delle minacce di jamming nei collegamenti radio spaziali; il punto di forza principale di questo lavoro risiede nell'elevata precisione ottenuta nel classificare attacchi complessi a livello fisico e di collegamento su canali ad alto rumore. Tuttavia, l'approccio si differenzia radicalmente in quanto assume che l'addestramento e la validazione del modello avvengano all'interno del medesimo dominio trasmissivo satellitare, ignorando la valutazione della trasferibilità di un modello addestrato esclusivamente su traffico di origine terrestre. Un altro lavoro significativo è quello di Liu et al. [8], che applica algoritmi di Decision Tree e varianti di Gradient Boosting per identificare anomalie e iniezioni malevole di dati nei segmenti di comunicazione satellitare; il pregio di questa ricerca risiede nella minimizzazione del tempo di elaborazione dei flussi, essenziale per rispettare i vincoli di calcolo a bordo, ma mantiene la limitazione di addestrare e testare i classificatori su distribuzioni di dati omogenee, senza esplorare tecniche di adattamento o iniezione mirata di dati da domini eterogenei per mitigare lo shift distributivo. Infine, lo studio di Al-Makhadmeh et al. [9] propone un'architettura di sicurezza basata su algoritmi ad albero d'ensemble per l'ispezione del traffico integrato satellitare-terrestre; il punto di forza risiede nella capacità di gestire dataset ad alta dimensionalità con bilanciamento delle classi in ambienti complessi. Tuttavia, la differenziazione risiede nel fatto che il modello viene validato assumendo la disponibilità completa di dati satellitari etichettati durante l'intero processo di addestramento primario, laddove la valutazione della capacità di generalizzazione di un classificatore puramente terrestre verso scenari spaziali non viene affrontata.

A causa dei vincoli di risorsa computazionale ed energetica presenti sulle piattaforme spaziali, l'architettura ideale degli IDS supervisionati tende verso un rilevamento distribuito o alleggerito: i modelli leggono ed elaborano le feature rilevanti direttamente presso i segmenti di terra o nei nodi di bordo, riducendo l'overhead di trasmissione e garantendo una risposta tempestiva contro le minacce informatiche [15]. Ciononostante, la variabilità intrinseca del canale satellitare pone una sfida aperta per i modelli supervisionati, evidenziando come l'accuratezza predittiva dipenda strettamente dalla composizione dei dati di addestramento e dalla capacità del classificatore di

tollerare lo scostamento tra la distribuzione del traffico nominale di terra e le condizioni fisiche reali della tratta orbita-terra [1].

3. Elementi Base

In questo capitolo ci saranno esempi base di elenchi puntati, figure, tabelle, formule, algoritmi e codici.

Esempio di elenco puntato:

- **primo punto in grassetto;**
- secondo punto, se preferisci che non sia in grassetto;

3.1 Sezione nel Secondo Capitolo

Esempio di immagine in Figura 3.1. Ricorda di menzionare sempre nel testo, usando `\ref`, tutte le figure/tabelle/algoritmi/codici che inserisci. ¹

¹Un'esempio di come aggiungere una footnote, spesso magari usata per citare o riportare qualche sito, come tipo <https://ditto.ing.unimore.it/>,




Figura 3.1: L'architettura introdotta da Vaswani nel famoso Paper "*Attention is All You Need*" [22].

3.2 Un'Altra Sezione nel Secondo Capitolo

Esempio di una tabella con relativa citazione, Tabella 3.1.

Tabella 3.1: Esempio di tabella con vari campi, spunte e croci.

Frutto	Arancione	Si sbuccia	Peso	Prezzo	Zucch.	Voto (1–10)
Arancia	✓	✓	0.200	2.50	9.0	8
Mandarino	✓	✓	0.120	3.20	8.5	9
Limone	✗	✓	0.100	3.50	2.5	6
Mela	✗	✗	0.180	2.80	10.0	8
Banana	✗	✓	0.150	1.10	12.2	9
Kiwi	✗	✓	0.120	4.00	9.1	7
Mango	✓	✓	0.300	5.00	14.0	10

3.3 Formule Matematiche

Qui due esempi di come fare formule matematiche, come riconoscerete bene in Eq. 3.1 abbiamo la versione integrale della Trasformata di Fourier mentre in Eq. 3.2 ne abbiamo la formulazione discretizzata con la sommatoria.

$$X(f) = \int_{-\infty}^{\infty} x(t) e^{-j2\pi f t} dt \quad (3.1)$$

$$X_k = \sum_{n=0}^{N-1} x_n \cdot e^{-i \frac{2\pi}{N} k n} \quad (3.2)$$

3.4 Esempio di Algoritmo

Nell'Algoritmo 1 si può vedere un modo per ottenere il cammino minimo.

Algorithm 1 Dijkstra's Algorithm

```
1: procedure DIJKSTRA( $G, s$ )
2:    $dist[] \leftarrow \infty$                                 ▶ Initialize distances to infinity
3:    $dist[s] \leftarrow 0$                                     ▶ Distance to source is 0
4:    $Q \leftarrow V[G]$                                        ▶ Add all nodes to the queue
5:   while  $Q$  is not empty do
6:      $u \leftarrow$  vertex in  $Q$  with min  $dist[u]$ 
7:     remove  $u$  from  $Q$ 
8:     for each neighbor  $v$  of  $u$  do
9:        $alt \leftarrow dist[u] + length(u, v)$ 
10:      if  $alt < dist[v]$  then
11:         $dist[v] \leftarrow alt$ 
12:         $prev[v] \leftarrow u$ 
13:      end if
14:    end for
15:  end while
16:  return  $dist[], prev[]$ 
17: end procedure
```

3.5 Esempi di Codice

Puoi anche includere alcuni esempi di codice, purché non siano troppo lunghi. Un esempio di può vedere nel Codice 3.1

Codice 3.1: Codice di esempio, tratto da helloworldspam.py

```
print('Starting the ultimate hello world spammer')
for i in range(10000000):
    print("Hello , world!")
```

3.6 Gestione della Bibliografia

Tutti i riferimenti bibliografici andranno inseriti nel file “.bib” del progetto. In questo template il file è “bibliography.bib”. Per citare un riferimento occorre usare il comando “\cite{<id>}”, come ad esempio [22].

4. Tabelle e Immagini

In questo capitolo ci saranno esempi di tabelle di grandi dimensioni e immagini disposte a griglia.

4.1 Griglia 1x3

Ecco un esempio di una griglia di immagini, come mostrato in Figura 4.1.



(a) Arancia



(b) Mela



(c) Banana

Figura 4.1: Foto di frutta fresca in griglia 1x3.

4.2 Griglia 2x2

Ecco un esempio di una griglia di immagini, come mostrato in Figura 4.2.



(a) Arancia



(b) Mela



(c) Banana



(d) Pera

Figura 4.2: Foto di frutta fresca in griglia 2×2.

4.3 Esempio di Tabella Complessa

Tabella 4.1: Analisi comparativa di diversi frutti combinando vari metodi di maturazione, provenienze e punti di vista. Le Run ID rappresentano differenti esperimenti su raccolti.

Score Prov.	Frutto	Raccolti											
		R1	R2	R3	R4	R5	R6	R7	R8A	R8S	R9	R10	
Dolcezza	Tutti	Mela	87.23	88.01	87.44	86.99	88.12	87.55	88.23	87.66	88.42	88.09	87.77
		Banana	91.31	92.05	91.74	91.92	90.84	92.18	91.95	92.02	91.85	91.99	91.88
	Tropic.	Ananas	84.45	85.02	84.60	84.99	84.25	85.15	84.79	84.92	85.11	84.85	84.88
		Mango	90.12	90.89	91.10	90.67	90.33	91.21	90.97	91.03	91.30	90.95	91.12
	Mediterr.	Arancia	88.44	89.11	88.99	89.23	88.51	89.34	89.28	89.21	89.43	89.15	89.32
		Limone	72.62	73.40	73.88	72.95	72.50	73.91	73.65	73.75	73.84	73.70	73.78
Succosità	Tutti	Mela	65.42	67.19	66.85	67.00	65.99	67.45	67.11	67.38	67.80	67.21	67.43
		Banana	78.84	79.11	79.67	79.40	78.72	79.91	79.63	79.85	80.10	79.74	79.87
		Uva	82.17	82.69	82.33	82.50	82.02	82.91	82.65	82.84	83.05	82.73	82.91
	Tropic.	Mango	85.15	85.44	85.98	85.67	85.01	86.11	85.79	85.92	86.22	85.83	85.96
		Papaya	74.83	75.02	75.37	75.14	74.76	75.49	75.23	75.40	75.60	75.28	75.39
		Ananas	77.04	77.49	77.71	77.31	77.05	77.80	77.58	77.66	77.93	77.60	77.74
	Mediterr.	Arancia	81.90	82.30	82.65	82.49	81.87	82.76	82.52	82.68	82.95	82.59	82.70
		Limone	61.35	61.88	62.09	61.95	61.24	62.22	62.05	62.17	62.44	62.10	62.26
		Pompelmo	68.75	69.21	69.58	69.37	68.80	69.83	69.65	69.70	69.99	69.68	69.82

5. Conclusioni

Qui andrebbero le tue conclusioni.

Ringraziamenti

Qui i ringraziamenti, se lo desideri.

Bibliografia

- [1] Anna L. Buczak e Erhan Guven. «A survey of data mining and machine learning methods for cyber security intrusion detection». In: *IEEE Communications Surveys & Tutorials* 18.2 (2016), pp. 1153–1176.
- [2] Celery Project. *Celery: Distributed Task Queue*. Framework per la gestione concorrente ed asincrona di task. 2025. URL: <https://docs.celeryproject.org/en/stable/>.
- [3] Django Software Foundation. *Django Web Framework*. Framework per lo sviluppo di webapp. 2024. URL: <https://www.djangoproject.com/>.
- [4] Docker Inc. *Docker Documentation*. Piattaforma per lo sviluppo di container software. 2024. URL: <https://docs.docker.com>.
- [5] Mohamed Amine Ferrag et al. «Deep learning for cyber security intrusion detection: Approaches, datasets, and comparative study». In: *Journal of Information Security and Applications* 50 (2020), p. 102419.
- [6] Pedro Garcia-Teodoro et al. «Anomaly-based network intrusion detection: Techniques, systems and challenges». In: *Computers & Security* 28.1-2 (2009), pp. 18–28.
- [7] Pavel Laskov et al. «Learning intrusion detection: supervised or unsupervised?» In: *Proceedings of the 8th International Conference on Image Analysis and Processing (ICIAP 2005)*. Springer, 2005, pp. 50–57.
- [8] Yanjun Liu et al. «Lightweight decision tree and boosting-based intrusion detection for space-ground integrated networks». In: *IEEE Internet of Things Journal* 8.14 (2021), pp. 11502–11514.
- [9] Zafer Al-Makhadmeh e Amr Tolba. «An efficient ensemble learning-based network intrusion detection system for satellite-terrestrial networks». In: *IEEE Access* 10 (2022), pp. 34210–34221.
- [10] National Institute of Standards and Technology. *Cybersecurity Framework Profile for Public Safety Land Mobile Radio*. NIST Special Publication 800-187. U.S. Department of Commerce, 2022.

- [11] OpenAI. *Whisper*. Modello IA open source per il riconoscimento vocale automatico. 2022. URL: <https://github.com/openai/whisper>.
- [12] Timothy Pratt, Charles Bostian e Jeremy Allnutt. *Satellite Communications*. John Wiley & Sons, 2002.
- [13] Karen Scarfone e Peter Mell. *Guide to Intrusion Detection and Prevention Systems (IDPS)*. NIST Special Publication 800-94. National Institute of Standards e Technology, 2007.
- [14] Iman Sharafaldin, Arash Habibi Lashkari e Ali A. Ghorbani. «Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization». In: *Proceedings of the 4th International Conference on Information Systems Security and Privacy (ICISSP 2018)*. SCITEPRESS, 2018, pp. 108–116.
- [15] Giuseppe Siracusano et al. «Machine learning for satellite communication security: A survey». In: *IEEE Access* 9 (2021), pp. 112450–112468.
- [16] Robin Sommer e Vern Paxson. «Outside the closed world: On using machine learning for network intrusion detection». In: *Proceedings of the 2010 IEEE Symposium on Security and Privacy (SP)*. IEEE, 2010, pp. 305–316.
- [17] SQLAlchemy Project. *SQLAlchemy — The Database Toolkit for Python*. Toolkit e ORM per la gestione di database in Python. 2025. URL: <https://www.sqlalchemy.org/>.
- [18] William Stallings. *Cryptography and Network Security: Principles and Practice*. Pearson, 2017.
- [19] Andrew S. Tanenbaum e David J. Wetherall. *Computer Networks*. Pearson, 2011.
- [20] Mahbod Tavallaei et al. «A detailed analysis of the KDD CUP 99 data set». In: *Proceedings of the Second IEEE Symposium on Computational Intelligence for Security and Defense Applications (CISDA 2009)*. IEEE, 2009, pp. 1–6.
- [21] Flower Team. *Flower: A Friendly Federated Learning Framework*. Frontend web per il monitoraggio delle tasks Celery. 2025. URL: <https://flower.dev>.
- [22] Ashish Vaswani et al. «Attention is all you need». In: *Advances in neural information processing systems* 30 (2017).

- [23] Bo Zhao et al. «Machine learning-based intrusion and jamming detection in satellite communication networks». In: *IEEE Transactions on Wireless Communications* 19.5 (2020), pp. 3310–3324.