

Analisi della Trasferibilità di NIDS basati su Machine Learning al Dominio Satellitare

Relatore:

Prof. Mirco Marchetti

Correlatore:

Dott. Dimitri Galli

Candidato:

Alessandro Marchesini

Matricola 187179

Discussione della Prova Finale – A.A. 2025/2026


Dipartimento di Ingegneria “Enzo Ferrari”



UNIMORE

UNIVERSITÀ DEGLI STUDI DI
MODENA E REGGIO EMILIA

NIDS tra Dominio Terrestre e Satellitare



Limite

Le prestazioni **in-domain** non sono sufficienti per caratterizzare la robustezza di un NIDS in presenza di **domain shift**.


Problema di Ricerca e Domande Sperimentali

Obiettivo

Valutare la **generalizzazione cross-domain** di modelli addestrati sul dominio sorgente terrestre verso distribuzioni target terrestre-spaziali.


- **RQ1** Trasferibilità diretta e Domain Shift
- **RQ2** Adattamento mediante Conoscenza Target Sparsa
- **RQ3** Granularità, Specializzazione e Generalizzazione
- **RQ4** Architettura, Stabilità e Struttura Decisionale

Contributo: Framework di Valutazione Cross-Domain



Il contributo consiste in un protocollo sistematico per studiare la **trasferibilità** di NIDS supervisionati tra domini eterogenei.

Dataset e Allineamento nello Spazio Condiviso



Vincoli comuni

- $\rho_{ben/mal} = 10 : 1$
- split 80/20
- 93 000 benigni
- 9 300 malevoli
- 102 300 record / benchmark aggregato

Composizione

Tre Paradigmi di Addestramento

$\mathcal{M}_S$ — **Source-only**

Benigno: 100% $\mathcal{D}_S$

Malevolo: 100% $\mathcal{D}_S$

0 campioni target

$\mathcal{M}_{base}$ — **IN-
JECTION**

Benigno: 100% $\mathcal{D}_S$

Malevolo:

9271 source
+ 29 target

$\approx 0.31\%$ della
classe positiva

$\mathcal{M}_H$ — **Hybrid**

Benigno: 100% $\mathcal{D}_S$

Malevolo: 100% $\mathcal{D}_T$


**specializzazione
target**

Assenza di conoscenza

Conoscenza target

Conoscenza target

Implementazione e Protocollo Sperimentale



Riproducibilità

$K = 10$ seed
stesso protocollo e stessi
test set

Valutazione


TPR / TNR / Precision /
F1 / AP
PCA / KDE / SHAP

Analisi statistica

macro-F1 sui 16
benchmark
test t di Welch esplorativo

Risultato Principale: Effetto della Conoscenza Target Sparsa

TPR media sui nove benchmark target



Solo 29 campioni target

Incremento TPR target:

- DT: +0.6427
- HGB: +0.7690
- RF: +0.6847

Prestazioni sorgente

La TPR media sui

Risultati Globali: Generalizzazione vs Specializzazione

TPR media sull'intera cross-evaluation (16 benchmark)

Paradigma	DT	HGB	RF
Source-only	0.5288	0.3694	0.5161
INJECTION	0.8899	0.8025	0.9007
Hybrid aggregato	0.5626	0.5525–0.5627	0.5626

Specializzazione ibrida

TPR target: circa 0.9818–0.9999.

TPR sugli attacchi NB15: quasi nulla.

Architetture nella baseline

RF: miglior profilo predittivo misurato

$TPR_{target} = 0.98821$, $F1 = 0.890221$

Conclusioni

1. Trasferibilità diretta

Limitata e dipendente dalla distribuzione target.

2. Conoscenza target sparsa

INJECTION è associata a una forte crescita della sensibilità target preservando il sorgente.

3. Specializzazione

Massimizzare il target non equivale a massimizzare la robustezza cross-domain.

Limiti da mantenere espliciti

Benign-domain shift non valutato • target basato su STIN • 29 campioni